Das **A**'ilto

Wörterbuch des Maschinellen Lernens

Alexander Jung and Konstantina Olioumtsevits

5. Mai 2025



please cite as: A. Jung and K. Olioumtsevits "The Aalto Dictionary of Machine Learning," Aalto University, 2024.

Zusammenfassung

Dieses Wörterbuch des Maschinellen Lernens entstand während der Entwicklung und Umsetzung der Kurse CS-E3210 Machine Learning: Basic Principles, CS-C3240 Machine Learning, CS-E4800 Artificial Intelligence, CS-EJ3211 Machine Learning with Python, CS-EJ3311 Deep Learning with Python, CS-E4740 Federated Learning und CS-E407507 Human-Centered Machine Learning. Diese Kurse wurden über die Aalto-Universität https://www.aalto.fi/de, über das Finnish Institute of Technology (FITech) https://fitech.io.und.die Europäische Universitätsallianz Unite! https://www.aalto.fi/de/unite angeboten.

Glossar

Daten Ein Datensatz (Daten) besteht aus einem oder mehreren Datenpunkten und ist eine zentrale Komponente der meisten KI Anwendungen. Diese Anwendungen verwenden Datensätze zum Trainieren und Validieren von KI-Modellen. Verschiedene mathematische Modelle und formale Sprachen wurden entwickelt um Datensätze zu beschreiben und zu analysieren [?,?,?,?]. Eines der am weitesten verbreiteten Datenmodelle ist das relationale Modell, das Daten in Tabellen (oder Beziehungen) organisiert [?]. Eine Tabelle besteht aus Zeilen und Spalten:

- Jede Zeile der Tabelle repräsentiert einen einzelnen Datenpunkt.
- Jede Spalte der Tabelle entspricht einem bestimmten Attribut (oder Merkmal) der Datenpunkte.

Tabelle 1 zeigt beispielsweise einen Datensatz mit Wetterbeobachtungen. Im relationalen Modell ist die Reihenfolge der Zeilen irrelevant und für jedes Attribut (Spalte) muss ein Wertebereich definiert sein. Diese Wertebereiche entsprechen dem Merkmalsraum der Datenpunkte. Während das relationale Modell ein nützliches Instrument für die Beschreibung und Analyse von KI System bietet, ist es unzureichend für die Dokumentation von vertrauenswürdiger KI. Moderne Ansätze wie Datenblätter für Datensätze bieten eine umfassendere Dokumentation, einschließlich Details zum Erfassungsprozess des Datensatzes und zur

FMI Station	Year	Month	Day	Time	Temp. [°C]
Kustavi Isokari	2023	4	1	00:00	-0.2
Kustavi Isokari	2023	4	2	00:00	-0.1
Kustavi Isokari	2023	4	3	00:00	-1.0
Kustavi Isokari	2023	4	4	00:00	-0.4
Kustavi Isokari	2023	4	5	00:00	0.9

Tabelle 1: Beobachtungen der Wetter-Station nahe der finnischen Gemeinde Kustavi.

beabsichtigten Verwendung [?].

Klassifizierung Klassifizierung bezeichnet ML Anwendungen die darauf abzielen, Datenpunkte in eine von mehreren vorgegebenen Kategorien oder Klassen einzuordnen.

Optimismus im Angesicht der Unsicherheit ML-Methoden verwenden ein Leistungsmaß $\bar{f}(\mathbf{w})$ um Modell-Parameter \mathbf{w} zu lernen. Allerdings haben sie in der Regel keinen direkten Zugriff auf $\bar{f}(\mathbf{w})$, sondern nur auf eine Schätzung (oder Annäherung) $f(\mathbf{w})$. Zum Beispiel verwenden herkömmliche ML Methoden einen Trainingsfehler als Schätzung für den erwarteten Verlust. Mit einem probabilistischen Modell lässt sich ein Konfidenzintervall $\left[l^{(\mathbf{w})}, u^{(\mathbf{w})}\right]$ für jede Wahl von Modellparametern konstruieren. Eine einfache Konstruktion hierfür ist $l^{(\mathbf{w})} := f(\mathbf{w}) - \sigma/2$, $u^{(\mathbf{w})} := f(\mathbf{w}) + \sigma/2$, wobei σ ein Maß für die (erwartete) Abweichung von $f(\mathbf{w})$ zu $\bar{f}(\mathbf{w})$ ist. Es können auch andere Konstruktionen für dieses

Intervall verwendet werden, solange sie sicherstellen, dass mit ausreichend hoher Wahrscheinlichkeit $\bar{f}(\mathbf{w}) \in [l^{(\mathbf{w})}, u^{(\mathbf{w})}]$ gilt. Als Optimist wählen wir \mathbf{w} gemäß dem günstigsten – aber dennoch plausiblen – Wert $\tilde{f}(\mathbf{w}) := l^{(\mathbf{w})}$ des Leistungsmaßes. Zwei Beispiele für diese Konstruktion findet man in der strukturellen Risikominimierung [?, Kap. 11] sowie bei Methoden für die sequentielle Entscheidungsfindung [?, Abschnitt 2.2].

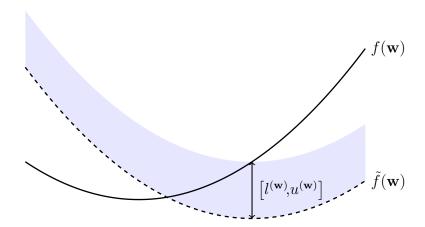


Abbildung 1: Wir verwenden eine Schätzung $f(\mathbf{w})$ für das Leistungsmaß $\bar{f}(\mathbf{w})$ um ein Konfidenzintervall $\left[l^{(\mathbf{w})},u^{(\mathbf{w})}\right]$ zu konstruieren. Ein Optimist im Angesicht der Unsicherheit wählt Modellparameter \mathbf{w} gemäß dem günstigsten – aber dennoch plausiblen – Wert $\tilde{f}(\mathbf{w}) := l^{(\mathbf{w})}$.

\mathbf{Index}

Daten, 2

Klassifizierung, 3

Optimismus im Angesicht der Unsicherheit, 3

Literatur