

# Το **A**'alto

## Λεξικό της Μηχανικής Μάθησης

Alexander Jung<sup>1</sup>, Konstantina Olioumtsevs<sup>1</sup>, Ekkehard Schnoor<sup>1</sup>,  
Tommi Flores Rynänen<sup>1</sup>, Juliette Gronier<sup>2</sup>, και Salvatore Rastelli<sup>1</sup>

<sup>1</sup>Aalto University    <sup>2</sup>ENS Lyon

Μετάφραση από την Konstantina Olioumtsevs

September 19, 2025



αναφορά ως: A. Jung, K. Olioumtsevs, E. Schnoor, T. Rynänen,  
J. Gronier, and S. Rastelli, *The Aalto Dictionary of Machine  
Learning*, (in Greek). Espoo, Finland: Aalto University, 2025.

## Ευχαριστίες

Αυτό το λεξικό της μηχανικής μάθησης αναπτύχθηκε κατά τον σχεδιασμό και την υλοποίηση διαφορετικών μαθημάτων, συμπεριλαμβανομένων των CS-E3210 Machine Learning: Basic Principles, CS-C3240 Machine Learning, CS-E4800 Artificial Intelligence, CS-EJ3211 Machine Learning with Python, CS-EJ3311 Deep Learning with Python, CS-E4740 Federated Learning, και CS-E407507 Human-Centered Machine Learning. Αυτά τα μαθήματα προσφέρονται στο Aalto University <https://www.aalto.fi/en>, σε ενήλικους/ες σπουδαστές/σπουδάστριες μέσω του The Finnish Institute of Technology (FITech) <https://fitech.io/en/>, και σε διεθνείς φοιτητές/φοιτήτριες μέσω της European University Alliance Unite! <https://www.aalto.fi/en/unite>.

Είμαστε ευγνώμονες στους/στις σπουδαστές/σπουδάστριες που παρείχαν πολύτιμα σχόλια που ήταν καθοριστικά για το συγκεκριμένο λεξικό. Ιδιαίτερες ευχαριστίες στον Mikko Seesto για τη σχολαστική του διόρθωση προσχεδίων. Αυτό το έργο υποστηρίχθηκε από

- το Research Council of Finland (grants 331197, 363624, 349966)·
- την Ευρωπαϊκή Ένωση (grant 952410)·
- το Jane and Aatos Erkkö Foundation (grant A835)·
- την Business Finland, ως μέρος του έργου Forward-Looking AI Governance in Banking and Insurance (FLAIG).

Η μετάφραση στα ελληνικά βασίστηκε ιδιαίτερα σε σχετικά σχολικά βιβλία λυκείου <https://ebooks.edu.gr/ebooks>, σε αρχεία από την Εθνική Υπηρεσία Πληροφοριών της Ελλάδας <https://www.nis.gr/en>, και σε σχετικά λεξικά:

Γ. Γεωργίου, *Αγγλοελληνικό Λεξικό Μαθηματικής Ορολογίας*, 1999. [Διαδικτυακά]. Διαθέσιμο: <https://www.mas.ucy.ac.cy/georgios/bookfiles/dict1.pdf>. Πρόσβαση: 30 Μαΐου 2025.

Α. Καλογεροπούλου, Μ. Γκίκας, Δ. Καραγιαννάκης, και Μ. Λάμπρου, *Αγγλοελληνικό Λεξικό Μαθηματικών Όρων*. Αθήνα, Ελλάδα: Τροχαλία, 1992.

Σ. Καπιδάκης, Κ. Τοράκη, Σ. Χατζημαρή, Κ. Βαλεοντής, και Υ. Κύττα, *Λεξικό Επιστήμης της Πληροφόρησης*. Αθήνα, Ελλάδα: Κάλλιπος, Ανοιχτές Ακαδημαϊκές Εκδόσεις, 2024.

## Contents

Εργαλεία	25
Έννοιες Μηχανικής Μάθησης	36

# Κατάλογοι Συμβόλων

## Σύνολα και Συναρτήσεις

$a \in \mathcal{A}$  Το αντικείμενο  $a$  είναι ένα στοιχείο του συνόλου  $\mathcal{A}$ .

---

$a := b$  Χρησιμοποιούμε το  $a$  ως συντομογραφία για το  $b$ .

---

$|\mathcal{A}|$  Η καρδινικότητα (δηλαδή ο αριθμός των στοιχείων) ενός πεπερασμένου συνόλου  $\mathcal{A}$ .

---

$\mathcal{A} \subseteq \mathcal{B}$  Το  $\mathcal{A}$  είναι ένα υποσύνολο του  $\mathcal{B}$ .

---

$\mathcal{A} \subset \mathcal{B}$  Το  $\mathcal{A}$  είναι ένα αυστηρό υποσύνολο του  $\mathcal{B}$ .

---

$\mathcal{A} \times \mathcal{B}$  Το Καρτεσιανό γινόμενο των συνόλων  $\mathcal{A}$  και  $\mathcal{B}$ .

---

$\mathbb{N}$  Οι φυσικοί αριθμοί  $1, 2, \dots$ .

---

$\mathbb{R}$  Οι πραγματικοί αριθμοί  $x$   $[1]$ .

---

$\mathbb{R}_+$  Οι μη αρνητικοί πραγματικοί αριθμοί  $x \geq 0$ .

---

$\mathbb{R}_{++}$  Οι θετικοί πραγματικοί αριθμοί  $x > 0$ .

---

$\{0, 1\}$  Το σύνολο που αποτελείται από τους δύο πραγματικούς αριθμούς  $0$  και  $1$ .

---

$[0, 1]$  Το κλειστό διάστημα των πραγματικών αριθμών  $x$  με  $0 \leq x \leq 1$ .

$\arg \min_{\mathbf{w}} f(\mathbf{w})$	<p>Το σύνολο των ελαχιστοποιητών για μια συνάρτηση πραγματικής τιμής <math>f(\mathbf{w})</math>.</p> <p>Βλέπε επίσης: συνάρτηση.</p>
$\mathbb{S}^{(n)}$	<p>Το σύνολο των διανυσμάτων μοναδιαίας νόρμας στο <math>\mathbb{R}^{n+1}</math>.</p> <p>Βλέπε επίσης: νόρμα, διάνυσμα.</p>
$\exp(a)$	<p>Η εκθετική συνάρτηση που αξιολογείται στον πραγματικό αριθμό <math>a \in \mathbb{R}</math>.</p> <p>Βλέπε επίσης: συνάρτηση.</p>
$\log a$	<p>Ο λογάριθμος του θετικού αριθμού <math>a \in \mathbb{R}_{++}</math>.</p>
$f(\cdot): \mathcal{A} \rightarrow \mathcal{B} : a \mapsto f(a)$	<p>Μία συνάρτηση (ή map) από ένα σύνολο <math>\mathcal{A}</math> σε ένα σύνολο <math>\mathcal{B}</math>, η οποία αποδίδει σε κάθε είσοδο <math>a \in \mathcal{A}</math> μία καλά ορισμένη έξοδο <math>f(a) \in \mathcal{B}</math>. Το σύνολο <math>\mathcal{A}</math> είναι το πεδίο της συνάρτησης <math>f</math> και το σύνολο <math>\mathcal{B}</math> είναι το πεδίο τιμών της <math>f</math>. Η μηχανική μάθηση στοχεύει να μάθει μία συνάρτηση που αντιστοιχεί χαρακτηριστικά <math>\mathbf{x}</math> ενός σημείου δεδομένων σε μία πρόβλεψη <math>h(\mathbf{x})</math> για την ετικέτα του <math>y</math>.</p> <p>Βλέπε επίσης: συνάρτηση, map, ml, χαρακτηριστικό, data point, πρόβλεψη, ετικέτα.</p>

$\text{epi}(f)$	<p>Το επίγραμμα μίας συνάρτησης πραγματικής τιμής <math>f : \mathbb{R}^d \rightarrow \mathbb{R}</math>.</p> <p>Βλέπε επίσης: epigraph, συνάρτηση.</p>
$\frac{\partial f(w_1, \dots, w_d)}{\partial w_j}$	<p>Η μερική παράγωγος (αν υπάρχει) μίας συνάρτησης πραγματικής τιμής <math>f : \mathbb{R}^d \rightarrow \mathbb{R}</math> αναφορικά με το <math>w_j</math> [2, Κεφ. 9].</p> <p>Βλέπε επίσης: συνάρτηση.</p>
$\nabla f(\mathbf{w})$	<p>Η κλίση μίας παραγωγίσιμης συνάρτησης πραγματικής τιμής <math>f : \mathbb{R}^d \rightarrow \mathbb{R}</math> είναι το διάνυσμα <math>\nabla f(\mathbf{w}) = (\partial f / \partial w_1, \dots, \partial f / \partial w_d)^T \in \mathbb{R}^d</math> [2, Κεφ. 9].</p> <p>Βλέπε επίσης: κλίση, παραγωγίσιμη, συνάρτηση, διάνυσμα.</p>

## Πίνακες και Διανύσματα

$\mathbf{x} = (x_1, \dots, x_d)^T$	Ένα διάνυσμα μήκους $d$ , με την $j$ στή του καταχώριση να είναι $x_j$ . Βλέπε επίσης: διάνυσμα.
$\mathbb{R}^d$	Το σύνολο των διανυσμάτων $\mathbf{x} = (x_1, \dots, x_d)^T$ που αποτελούνται από $d$ καταχωρίσεις πραγματικών τιμών $x_1, \dots, x_d \in \mathbb{R}$ . Βλέπε επίσης: διάνυσμα.
$\mathbf{I}_{l \times d}$	Ένας γενικευμένος πίνακας ταυτότητας με $l$ γραμμές και $d$ στήλες. Οι καταχωρίσεις του $\mathbf{I}_{l \times d} \in \mathbb{R}^{l \times d}$ είναι ίσες με 1 κατά μήκος της κύριας διαγωνίου και διαφορετικά ίσες με 0. Βλέπε επίσης: πίνακας.
$\mathbf{I}_d, \mathbf{I}$	Ένας τετραγωνικός πίνακας ταυτότητας μεγέθους $d \times d$ . Αν το μέγεθος είναι προφανές από τα συμφραζόμενα, παραλείπουμε τον δείκτη. Βλέπε επίσης: πίνακας.
$\ \mathbf{x}\ _2$	Η Ευκλείδειος (ή $\ell_2$ ) νόρμα του διανύσματος $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$ ορίζεται ως $\ \mathbf{x}\ _2 := \sqrt{\sum_{j=1}^d x_j^2}$ . Βλέπε επίσης: νόρμα, διάνυσμα.
$\ \mathbf{x}\ $	Κάποια νόρμα του διανύσματος $\mathbf{x} \in \mathbb{R}^d$ [3]. Εκτός αν προσδιορίζεται διαφορετικά, εννοούμε την Ευκλείδεια νόρμα $\ \mathbf{x}\ _2$ . Βλέπε επίσης: νόρμα, διάνυσμα.



$\mathbf{x}^T$	<p>Ο ανάστροφος πίνακας που έχει το διάνυσμα <math>\mathbf{x} \in \mathbb{R}^d</math> ως μοναδική του στήλη.</p> <p>Βλέπε επίσης: πίνακας, διάνυσμα.</p>
$\mathbf{X}^T$	<p>Ο ανάστροφος πίνακας <math>\mathbf{X} \in \mathbb{R}^{m \times d}</math>. Ένας τετραγωνικός πίνακας παραγματικών τιμών <math>\mathbf{X} \in \mathbb{R}^{m \times m}</math> λέγεται συμμετρικός αν <math>\mathbf{X} = \mathbf{X}^T</math>.</p> <p>Βλέπε επίσης: πίνακας.</p>
$\mathbf{X}^{-1}$	<p>Ο αντίστροφος πίνακας ενός πίνακα <math>\mathbf{X} \in \mathbb{R}^{d \times d}</math>.</p> <p>Βλέπε επίσης: αντίστροφος πίνακας, πίνακας.</p>
$\mathbf{0} = (0, \dots, 0)^T$	<p>Το διάνυσμα στο <math>\mathbb{R}^d</math> με κάθε καταχώριση να είναι ίση με μηδέν.</p> <p>Βλέπε επίσης: διάνυσμα.</p>
$\mathbf{1} = (1, \dots, 1)^T$	<p>Το διάνυσμα στο <math>\mathbb{R}^d</math> με κάθε καταχώριση να είναι ίση με ένα.</p> <p>Βλέπε επίσης: διάνυσμα.</p>
$(\mathbf{v}^T, \mathbf{w}^T)^T$	<p>Το διάνυσμα μήκους <math>d + d'</math> που προκύπτει από την αλληλουχία των καταχωρίσεων του διανύσματος <math>\mathbf{v} \in \mathbb{R}^d</math> με τις καταχωρίσεις του <math>\mathbf{w} \in \mathbb{R}^{d'}</math>.</p> <p>Βλέπε επίσης: διάνυσμα.</p>

$\text{span}\{\mathbf{B}\}$	<p>Το εύρος ενός πίνακα <math>\mathbf{B} \in \mathbb{R}^{a \times b}</math>, που είναι ο υποχώρος όλων των γραμμικών συνδυασμών των στηλών του <math>\mathbf{B}</math>, έτσι ώστε <math>\text{span}\{\mathbf{B}\} = \{\mathbf{B}\mathbf{a} : \mathbf{a} \in \mathbb{R}^b\} \subseteq \mathbb{R}^a</math>.</p> <p>Βλέπε επίσης: πίνακας.</p>
$\text{null}(\mathbf{A})$	<p>Ο nullspace ενός πίνακα <math>\mathbf{A} \in \mathbb{R}^{a \times b}</math>, ο οποίος είναι ο υποχώρος των διανυσμάτων <math>\mathbf{a} \in \mathbb{R}^b</math>, έτσι ώστε <math>\mathbf{A}\mathbf{a} = \mathbf{0}</math>.</p> <p>Βλέπε επίσης: nullspace, πίνακας, διάνυσμα.</p>
$\det(\mathbf{C})$	<p>Η ορίζουσα του πίνακα <math>\mathbf{C}</math>.</p> <p>Βλέπε επίσης: ορίζουσα, πίνακας.</p>
$\mathbf{A} \otimes \mathbf{B}$	<p>Το γινόμενο Kronecker των <math>\mathbf{A}</math> και <math>\mathbf{B}</math> [4].</p> <p>Βλέπε επίσης: γινόμενο Kronecker.</p>

## Θεωρία Πιθανοτήτων

$\mathbf{x} \sim p(\mathbf{z})$  Η τυχαία μεταβλητή  $\mathbf{x}$  κατανέμεται σύμφωνα με την κατανομή πιθανότητας  $p(\mathbf{z})$  [5], [6].

Βλέπε επίσης: τυχαία μεταβλητή, κατανομή πιθανότητας.

---

$\mathbb{E}_p\{f(\mathbf{z})\}$  Η προσδοκία μίας τυχαίας μεταβλητής  $f(\mathbf{z})$  που προκύπτει από την εφαρμογή μίας ντετερμινιστικής συνάρτησης  $f$  σε μία τυχαία μεταβλητή  $\mathbf{z}$  της οποίας η κατανομή πιθανότητας είναι  $\mathbb{P}(\mathbf{z})$ . Αν η κατανομή πιθανότητας είναι προφανής από τα συμφραζόμενα, γράφουμε απλώς  $\mathbb{E}\{f(\mathbf{z})\}$ .

Βλέπε επίσης: προσδοκία, τυχαία μεταβλητή, συνάρτηση, κατανομή πιθανότητας.

---

$\text{cov}(x, y)$  Η συνδιακύμανση μεταξύ δύο τυχαίων μεταβλητών πραγματικής τιμής που ορίζεται πάνω σε έναν κοινό χώρο πιθανοτήτων.

Βλέπε επίσης: συνδιακύμανση, τυχαία μεταβλητή, κατανομή πιθανότητας.

---

$\mathbb{P}(\mathbf{x}, y)$  Μία (από κοινού) κατανομή πιθανότητας μίας τυχαίας μεταβλητής της οποίας οι πραγματώσεις είναι σημεία δεδομένων με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ .

Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, πραγματώση, data point, feature, ετικέτα.

$\mathbb{P}(\mathbf{x} y)$	<p>Μία κατανομή πιθανότητας υπό συνθήκη μίας τυχαίας μεταβλητής <math>\mathbf{x}</math> δεδομένης της τιμής μίας άλλης τυχαίας μεταβλητής <math>y</math> [7, Sec. 3.5].</p> <p>Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή.</p>
$\mathbb{P}(\mathcal{A})$	<p>Η πιθανότητα του μετρήσιμου γεγονότος <math>\mathcal{A}</math>.</p> <p>Βλέπε επίσης: probability, μετρήσιμο, γεγονός.</p>
$\mathbb{P}(\mathbf{x}; \mathbf{w})$	<p>Μία παραμετροποιημένη κατανομή πιθανότητας μίας τυχαίας μεταβλητής <math>\mathbf{x}</math>. Η κατανομή πιθανότητας εξαρτάται από ένα παραμετρικό διάνυσμα <math>\mathbf{w}</math>. Για παράδειγμα, <math>\mathbb{P}(\mathbf{x}; \mathbf{w})</math> θα μπορούσε να είναι μία πολυμεταβλητή κανονική κατανομή με το παραμετρικό διάνυσμα <math>\mathbf{w}</math> που δίνεται από τις καταχωρίσεις του διανύσματος μέσης τιμής <math>\mathbb{E}\{\mathbf{x}\}</math> και τον πίνακα συνδιακύμανσης <math>\mathbb{E}\left\{(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})^T\right\}</math>.</p> <p>Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, παράμετρος, διάνυσμα, πολυμεταβλητή κανονική κατανομή, μέση τιμή, πίνακας συνδιακύμανσης, πιθανοτικό μοντέλο.</p>
$\mathcal{N}(\mu, \sigma^2)$	<p>Η κατανομή πιθανότητας μίας Gaussian τυχαίας μεταβλητής <math>x \in \mathbb{R}</math> με μέση τιμή (ή προσδοκία) <math>\mu = \mathbb{E}\{x\}</math> και διακύμανση <math>\sigma^2 = \mathbb{E}\{(x - \mu)^2\}</math>.</p> <p>Βλέπε επίσης: κατανομή πιθανότητας, Gaussian random variable (Gaussian RV), μέση τιμή, expectation, διακύμανση.</p>

$\mathcal{N}(\boldsymbol{\mu}, \mathbf{C})$	<p>Η πολυμεταβλητή κανονική κατανομή μίας Gaussian τυχαίας μεταβλητής τιμής διανύσματος <math>\mathbf{x} \in \mathbb{R}^d</math> με μέση τιμή (ή προσδοκία) <math>\boldsymbol{\mu} = \mathbb{E}\{\mathbf{x}\}</math> και πίνακα συνδιακύμανσης <math>\mathbf{C} = \mathbb{E}\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\}</math>.          Βλέπε επίσης: πολυμεταβλητή κανονική κατανομή, διάνυσμα, Gaussian RV, μέση τιμή, expectation, πίνακας συνδιακύμανσης.</p>
$\Omega$	<p>Ένας δειγματικός χώρος όλων των πιθανών αποτελεσμάτων ενός τυχαίου πειράματος.          Βλέπε επίσης: δειγματικός χώρος, τυχαίο πείραμα, γεγονός.</p>
$\mathcal{F}$	<p>Μία συλλογή μετρήσιμων υποσυνόλων ενός δειγματικού χώρου <math>\Omega</math>.          Βλέπε επίσης: μετρήσιμο, δειγματικός χώρος, γεγονός.</p>
$\mathcal{P}$	<p>Ένας χώρος πιθανοτήτων που αποτελείται από έναν δειγματικό χώρο <math>\Omega</math>, μία <math>\sigma</math>-άλγεβρα <math>\mathcal{F}</math> μετρήσιμων υποσυνόλων του <math>\Omega</math>, και μία κατανομή πιθανότητας <math>\mathbb{P}(\cdot)</math>.          Βλέπε επίσης: χώρος πιθανοτήτων, δειγματικός χώρος, μετρήσιμο, κατανομή πιθανότητας.</p>

## Μηχανική Μάθηση

$r$	<p>Ένας δείκτης <math>r = 1, 2, \dots</math> που απαριθμεί τα σημεία δεδομένων.</p> <p>Βλέπε επίσης: data point.</p>
$m$	<p>Ο αριθμός των σημείων δεδομένων σε ένα σύνολο δεδομένων (δηλαδή το μέγεθός του).</p> <p>Βλέπε επίσης: data point, σύνολο δεδομένων.</p>
$\mathcal{D}$	<p>Ένα σύνολο δεδομένων <math>\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}</math> είναι μία λίστα μεμονωμένων σημείων δεδομένων <math>\mathbf{z}^{(r)}</math>, for <math>r = 1, \dots, m</math>.</p> <p>Βλέπε επίσης: σύνολο δεδομένων, data point.</p>
$d$	<p>Ο αριθμός των χαρακτηριστικών που χαρακτηρίζουν ένα σημείο δεδομένων.</p> <p>Βλέπε επίσης: feature, data point.</p>
$x_j$	<p>Το <math>j</math>στό χαρακτηριστικό ενός σημείου δεδομένων. Το πρώτο χαρακτηριστικό δηλώνεται με <math>x_1</math>, το δεύτερο χαρακτηριστικό <math>x_2</math>, και ούτω καθεξής.</p> <p>Βλέπε επίσης: data point, feature.</p>
$\mathbf{x}$	<p>Το διάνυσμα χαρακτηριστικών <math>\mathbf{x} = (x_1, \dots, x_d)^T</math> ενός σημείου δεδομένων. Του διανύσματος οι καταχωρίσεις είναι τα μεμονωμένα χαρακτηριστικά ενός σημείου δεδομένων.</p> <p>Βλέπε επίσης: διάνυσμα χαρακτηριστικών, data point, διάνυσμα, feature.</p>

$\mathcal{X}$  Ο χώρος χαρακτηριστικών  $\mathcal{X}$  είναι το σύνολο όλων των πιθανών τιμών που μπορούν να πάρουν τα χαρακτηριστικά  $\mathbf{x}$  ενός σημείου δεδομένων. Βλέπε επίσης: χώρος χαρακτηριστικών, feature, data point.

---

$\mathbf{z}$  Αντί του συμβόλου  $\mathbf{x}$ , χρησιμοποιούμε μερικές φορές  $\mathbf{z}$  ως ένα άλλο σύμβολο για να δηλώσουμε ένα διάνυσμα του οποίου οι καταχωρίσεις είναι τα μεμονωμένα χαρακτηριστικά ενός σημείου δεδομένων. Χρειαζόμαστε δύο διαφορετικά σύμβολα για να διακρίνουμε τα ακατέργαστα χαρακτηριστικά από αυτά που έχουν μαθευτεί [8, Κεφ. 9]. Βλέπε επίσης: διάνυσμα, feature, data point.

---

$\mathbf{x}^{(r)}$  Το διάνυσμα χαρακτηριστικών του  $r$ στού σημείου δεδομένων εντός ενός συνόλου δεδομένων. Βλέπε επίσης: διάνυσμα χαρακτηριστικών, data point, σύνολο δεδομένων.

---

$x_j^{(r)}$  Το  $j$ στό χαρακτηριστικό του  $r$ στού σημείου δεδομένων εντός ενός συνόλου δεδομένων. Βλέπε επίσης: feature, data point, σύνολο δεδομένων.

---

$\mathcal{B}$  Μία μικρο-δέσμη (ή υποσύνολο) τυχαία επιλεγμένων σημείων δεδομένων. Βλέπε επίσης: δέσμη, data point.

---

$B$  Το μέγεθος μίας μικρο-δέσμης (δηλαδή ο αριθμός των σημείων δεδομένων σε αυτή). Βλέπε επίσης: data point, δέσμη.

$y$	<p>Η ετικέτα (ή η ποσότητα ενδιαφέροντος) ενός σημείου δεδομένων.</p> <p>Βλέπε επίσης: ετικέτα, data point.</p>
$y^{(r)}$	<p>Η ετικέτα του <math>r</math>στού σημείου δεδομένων.</p> <p>Βλέπε επίσης: ετικέτα, data point.</p>
$(\mathbf{x}^{(r)}, y^{(r)})$	<p>Τα χαρακτηριστικά και η ετικέτα του <math>r</math>στού σημείου δεδομένων.</p> <p>Βλέπε επίσης: feature, ετικέτα, data point.</p>
$\mathcal{Y}$	<p>Ο χώρος ετικετών <math>\mathcal{Y}</math> μίας μεθόδου μηχανικής μάθησης αποτελείται από όλες τις πιθανές τιμές ετικετών που ένα σημείο δεδομένων μπορεί να φέρει. Ο ονομαστικός χώρος ετικετών μπορεί να είναι μεγαλύτερος από το σύνολο των διαφορετικών τιμών ετικετών που προκύπτουν σε ένα συγκεκριμένο σύνολο δεδομένων (π.χ. ένα σύνολο εκπαίδευσης). Προβλήματα (ή μέθοδοι) μηχανικής μάθησης που χρησιμοποιούν έναν αριθμητικό χώρο ετικετών, όπως <math>\mathcal{Y} = \mathbb{R}</math> ή <math>\mathcal{Y} = \mathbb{R}^3</math>, αναφέρονται ως προβλήματα (ή μέθοδοι) παλινδρόμησης. Προβλήματα (ή μέθοδοι) μηχανικής μάθησης που χρησιμοποιούν έναν διακριτό χώρο ετικετών, όπως <math>\mathcal{Y} = \{0, 1\}</math> ή <math>\mathcal{Y} = \{\text{γάτα}, \text{σκύλος}, \text{ποντίκι}\}</math>, αναφέρονται ως προβλήματα (ή μέθοδοι) ταξινόμησης.</p> <p>Βλέπε επίσης: χώρος ετικετών, ml, ετικέτα, data point, σύνολο δεδομένων, σύνολο εκπαίδευσης, regression, ταξινόμηση.</p>



$\eta$	<p>Ο ρυθμός μάθησης (ή το μέγεθος βήματος) που χρησιμοποιείται από τις μεθόδους με βάση την κλίση.</p> <p>Βλέπε επίσης: ρυθμός μάθησης, μέγεθος βήματος, μέθοδοι με βάση την κλίση.</p>
$h(\cdot)$	<p>Μία map υπόθεσης που αντιστοιχεί τα χαρακτηριστικά ενός σημείου δεδομένων σε μία πρόβλεψη <math>\hat{y} = h(\mathbf{x})</math> για την ετικέτα του <math>y</math>.</p> <p>Βλέπε επίσης: υπόθεση, map, feature, data point, πρόβλεψη, ετικέτα.</p>
$\mathcal{Y}^{\mathcal{X}}$	<p>Δεδομένων δύο συνόλων <math>\mathcal{X}</math> και <math>\mathcal{Y}</math>, δηλώνουμε με <math>\mathcal{Y}^{\mathcal{X}}</math> το σύνολο όλων των πιθανών map υπόθεσης <math>h : \mathcal{X} \rightarrow \mathcal{Y}</math>.</p> <p>Βλέπε επίσης: υπόθεση, map.</p>
$\mathcal{H}$	<p>Ένας χώρος υποθέσεων ή μοντέλο που χρησιμοποιείται από μία μέθοδο μηχανικής μάθησης. Ο χώρος υποθέσεων αποτελείται από διαφορετικές map υπόθεσης <math>h : \mathcal{X} \rightarrow \mathcal{Y}</math>, μεταξύ των οποίων η μέθοδος μηχανικής μάθησης πρέπει να επιλέξει.</p> <p>Βλέπε επίσης: χώρος υποθέσεων, μοντέλο, ml, υπόθεση, map.</p>
$d_{\text{eff}}(\mathcal{H})$	<p>Η αποτελεσματική διάσταση ενός χώρου υποθέσεων <math>\mathcal{H}</math>.</p> <p>Βλέπε επίσης: αποτελεσματική διάσταση, χώρος υποθέσεων.</p>

$B^2$	<p>Η τετραγωνική μεροληψία μίας υπόθεσης <math>\hat{h}</math> που έχει μαθευτεί, ή των παραμέτρων της. Σημείωση ότι η <math>\hat{h}</math> γίνεται μία τυχαία μεταβλητή αν μαθαίνεται από σημεία δεδομένων που είναι και τα ίδια τυχαίες μεταβλητές.</p> <p>Βλέπε επίσης: μεροληψία, υπόθεση, παράμετρος, τυχαία μεταβλητή, data point.</p>
$V$	<p>Η διακύμανση μίας υπόθεσης <math>\hat{h}</math> που έχει μαθευτεί, ή των παραμέτρων της. Σημείωση ότι η <math>\hat{h}</math> γίνεται μία τυχαία μεταβλητή αν μαθαίνεται από σημεία δεδομένων που είναι και τα ίδια τυχαίες μεταβλητές.</p> <p>Βλέπε επίσης: διακύμανση, υπόθεση, παράμετρος, τυχαία μεταβλητή, data point.</p>
$L((\mathbf{x}, y), h)$	<p>Η απώλεια που προκαλείται από την πρόβλεψη της ετικέτας <math>y</math> ενός σημείου δεδομένων χρησιμοποιώντας την πρόβλεψη <math>\hat{y} = h(\mathbf{x})</math>. Η πρόβλεψη <math>\hat{y}</math> προκύπτει από την αξιολόγηση της υπόθεσης <math>h \in \mathcal{H}</math> για το διάνυσμα χαρακτηριστικών <math>\mathbf{x}</math> του σημείου δεδομένων.</p> <p>Βλέπε επίσης: απώλεια, ετικέτα, data point, πρόβλεψη, υπόθεση, διάνυσμα χαρακτηριστικών.</p>
$E_v$	<p>Το σφάλμα επικύρωσης μίας υπόθεσης <math>h</math>, που είναι η μέση της απώλεια που προκαλείται σε ένα σύνολο επικύρωσης.</p> <p>Βλέπε επίσης: σφάλμα επικύρωσης, υπόθεση, loss, σύνολο επικύρωσης.</p>

$\hat{L}(h \mathcal{D})$	<p>Η εμπειρική διακινδύνευση, ή η μέση απώλεια, που προκαλείται από την υπόθεση <math>h</math> σε ένα σύνολο δεδομένων <math>\mathcal{D}</math>.</p> <p>Βλέπε επίσης: εμπειρική διακινδύνευση, loss, υπόθεση, σύνολο δεδομένων.</p>
$E_t$	<p>Το σφάλμα εκπαίδευσης μίας υπόθεσης <math>h</math>, που είναι η μέση της απώλεια που προκαλείται σε ένα σύνολο εκπαίδευσης.</p> <p>Βλέπε επίσης: training error, υπόθεση, loss, σύνολο εκπαίδευσης.</p>
$t$	<p>Ένας δείκτης διακριτού χρόνου <math>t = 0, 1, \dots</math> που χρησιμοποιείται για την απαρίθμηση ακολουθιακών γεγονότων (ή χρονικών στιγμών).</p> <p>Βλέπε επίσης: γεγονός.</p>
$t$	<p>Ένας δείκτης που απαριθμεί τις εργασίες μάθησης εντός ενός προβλήματος μάθησης πολυδιεργασίας.</p> <p>Βλέπε επίσης: εργασία μάθησης, μάθηση πολυδιεργασίας.</p>
$\alpha$	<p>Μία παράμετρος ομαλοποίησης που ελέγχει το ποσό της ομαλοποίησης.</p> <p>Βλέπε επίσης: παράμετρος, ομαλοποίηση.</p>
$\lambda_j(\mathbf{Q})$	<p>Η <math>j</math>στή ιδιοτιμή (ταξινομημένη σε αύξουσα ή φθίνουσα σειρά) ενός θετικά ημιορισμένου πίνακα <math>\mathbf{Q}</math>. Χρησιμοποιούμε επίσης τη συντομογραφία <math>\lambda_j</math> αν ο αντίστοιχος πίνακας είναι προφανής από τα συμφραζόμενα.</p> <p>Βλέπε επίσης: ιδιοτιμή, θετικά ημιορισμένος, πίνακας.</p>

$\sigma(\cdot)$	<p>Η συνάρτηση ενεργοποίησης που χρησιμοποιείται από έναν τεχνητό νευρώνα εντός ενός τεχνητού νευρωνικού δικτύου.</p> <p>Βλέπε επίσης: συνάρτηση ενεργοποίησης, τεχνητό νευρωνικό δίκτυο.</p>
$\mathcal{R}_{\hat{y}}$	<p>Μία περιοχή αποφάσεων εντός ενός χώρου χαρακτηριστικών.</p> <p>Βλέπε επίσης: περιοχή αποφάσεων, χώρος χαρακτηριστικών.</p>
$\mathbf{w}$	<p>Ένα παραμετρικό διάνυσμα <math>\mathbf{w} = (w_1, \dots, w_d)^T</math> ενός μοντέλου, π.χ. τα βάρη ενός γραμμικού μοντέλου ή ενός τεχνητού νευρωνικού δικτύου.</p> <p>Βλέπε επίσης: παράμετρος, διάνυσμα, model, βάρη, γραμμικό μοντέλο, ΤΝΔ.</p>
$h^{(\mathbf{w})}(\cdot)$	<p>Μία map υπόθεσης που περιλαμβάνει παραμέτρους μοντέλου <math>w_1, \dots, w_d</math> που μπορούν να ρυθμιστούν στοιβαγμένες στο διάνυσμα <math>\mathbf{w} = (w_1, \dots, w_d)^T</math>.</p> <p>Βλέπε επίσης: υπόθεση, map, παράμετροι μοντέλου, διάνυσμα.</p>
$\phi(\cdot)$	<p>Ένας χάρτης χαρακτηριστικών <math>\phi : \mathcal{X} \rightarrow \mathcal{X}' : \mathbf{x} \mapsto \phi(\mathbf{x})</math> που μετασχηματίζει το διάνυσμα χαρακτηριστικών <math>\mathbf{x}</math> ενός σημείου δεδομένων σε ένα νέο διάνυσμα χαρακτηριστικών <math>\mathbf{x}' = \phi(\mathbf{x}) \in \mathcal{X}'</math>.</p> <p>Βλέπε επίσης: χάρτης χαρακτηριστικών, διάνυσμα χαρακτηριστικών, data point.</p>

$K(\cdot, \cdot)$	<p>Δεδομένου κάποιου χώρου χαρακτηριστικών <math>\mathcal{X}</math>, ένας πυρήνας είναι μία map <math>K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{C}</math> που είναι θετικά ημιορισμένη.</p> <p>Βλέπε επίσης: χώρος χαρακτηριστικών, πυρήνας, map, θετικά ημιορισμένος.</p>
$\text{VCdim}(\mathcal{H})$	<p>Η διάσταση Vapnik–Chervonenkis του χώρου υποθέσεων <math>\mathcal{H}</math>.</p> <p>Βλέπε επίσης: διάσταση Vapnik–Chervonenkis, χώρος υποθέσεων.</p>

## Ομοσπονδιακή Μάθηση

$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	<p>Ένας μη κατευθυνόμενος γράφος του οποίου οι κόμβοι <math>i \in \mathcal{V}</math> αντιπροσωπεύουν συσκευές εντός ενός δικτύου ομοσπονδιακής μάθησης. Οι μη κατευθυνόμενες σταθμισμένες ακμές <math>\mathcal{E}</math> αντιπροσωπεύουν τη συνεκτικότητα μεταξύ συσκευών και τις στατιστικές ομοιότητες μεταξύ των συνόλων δεδομένων τους και των εργασιών μάθησης.</p> <p>Βλέπε επίσης: γράφος, συσκευή, δίκτυο ομοσπονδιακής μάθησης, σύνολο δεδομένων, εργασία μάθησης.</p>
$i \in \mathcal{V}$	<p>Ένας κόμβος που αντιπροσωπεύει κάποια συσκευή εντός ενός δικτύου ομοσπονδιακής μάθησης. Η συσκευή μπορεί να έχει πρόσβαση σε ένα τοπικό σύνολο δεδομένων και να εκπαιδεύσει ένα τοπικό μοντέλο.</p> <p>Βλέπε επίσης: συσκευή, δίκτυο ομοσπονδιακής μάθησης, τοπικό σύνολο δεδομένων, local model.</p>
$\mathcal{G}^{(\mathcal{C})}$	<p>Ο επαγόμενος υπογράφος του <math>\mathcal{G}</math> χρησιμοποιώντας τους κόμβους στο <math>\mathcal{C} \subseteq \mathcal{V}</math>.</p>
$\mathbf{L}^{(\mathcal{G})}$	<p>Ο πίνακας Laplace ενός γράφου <math>\mathcal{G}</math>.</p> <p>Βλέπε επίσης: πίνακας Laplace, graph.</p>
$\mathbf{L}^{(\mathcal{C})}$	<p>Ο πίνακας Laplace του επαγόμενου γράφου <math>\mathcal{G}^{(\mathcal{C})}</math>.</p> <p>Βλέπε επίσης: πίνακας Laplace, graph.</p>

$\mathcal{N}^{(i)}$	<p>Η γειτονιά του κόμβου <math>i</math> σε έναν γράφο <math>\mathcal{G}</math>.</p> <p>Βλέπε επίσης: neighborhood, graph.</p>
$d^{(i)}$	<p>Ο σταθμισμένος βαθμός κόμβου <math>d^{(i)} := \sum_{i' \in \mathcal{N}^{(i)}} A_{i,i'}</math> ενός κόμβου <math>i</math>.</p> <p>Βλέπε επίσης: βαθμός κόμβου.</p>
$d_{\max}^{(\mathcal{G})}$	<p>Ο μέγιστος σταθμισμένος βαθμός κόμβου ενός γράφου <math>\mathcal{G}</math>.</p> <p>Βλέπε επίσης: μέγιστο, βαθμός κόμβου, graph.</p>
$\mathcal{D}^{(i)}$	<p>Το τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math> που φέρει ο κόμβος <math>i \in \mathcal{V}</math> ενός δικτύου ομοσπονδιακής μάθησης.</p> <p>Βλέπε επίσης: τοπικό σύνολο δεδομένων, δίκτυο ομοσπονδιακής μάθησης.</p>
$m_i$	<p>Ο αριθμός των σημείων δεδομένων (δηλαδή το μέγεθος δείγματος) που περιέχονται στο τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math> στον κόμβο <math>i \in \mathcal{V}</math>.</p> <p>Βλέπε επίσης: data point, μέγεθος δείγματος, τοπικό σύνολο δεδομένων.</p>
$\mathbf{x}^{(i,r)}$	<p>Τα χαρακτηριστικά του <math>r</math>στού σημείου δεδομένων στο τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math>.</p> <p>Βλέπε επίσης: feature, data point, τοπικό σύνολο δεδομένων.</p>
$y^{(i,r)}$	<p>Η ετικέτα του <math>r</math>στού σημείου δεδομένων στο τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math>.</p> <p>Βλέπε επίσης: ετικέτα, data point, τοπικό σύνολο δεδομένων.</p>

$\mathbf{w}^{(i)}$	<p>Οι τοπικοί παράμετροι μοντέλου της συσκευής <math>i</math> εντός ενός δικτύου ομοσπονδιακής μάθησης.</p> <p>Βλέπε επίσης: παράμετροι μοντέλου, συσκευή, δίκτυο ομοσπονδιακής μάθησης.</p>
$L_i(\mathbf{w})$	<p>Η τοπική συνάρτηση απώλειας που χρησιμοποιείται από την συσκευή <math>i</math> για να μετρήσει τη χρησιμότητα κάποιας επιλογής <math>\mathbf{w}</math> για τις παραμέτρους μοντέλου.</p> <p>Βλέπε επίσης: συνάρτηση απώλειας, συσκευή, παράμετροι μοντέλου.</p>
$L^{(d)}(\mathbf{x}, h(\mathbf{x}), h'(\mathbf{x}))$	<p>Η απώλεια που προκαλείται από μία υπόθεση <math>h'</math> σε ένα σημείο δεδομένων με χαρακτηριστικά <math>\mathbf{x}</math> και ετικέτα <math>h(\mathbf{x})</math> που προκύπτει από μία άλλη υπόθεση.</p> <p>Βλέπε επίσης: loss, υπόθεση, data point, feature, ετικέτα.</p>
$\text{stack}\{\mathbf{w}^{(i)}\}_{i=1}^n$	<p>Το διάνυσμα <math>\left( (\mathbf{w}^{(1)})^T, \dots, (\mathbf{w}^{(n)})^T \right)^T \in \mathbb{R}^{dn}</math> που προκύπτει από την κάθετη στοίβαξη των τοπικών παραμέτρων μοντέλου <math>\mathbf{w}^{(i)} \in \mathbb{R}^d</math>, για <math>i = 1, \dots, n</math>.</p> <p>Βλέπε επίσης: διάνυσμα, παράμετροι μοντέλου.</p>




## Εργαλεία

**διάνυσμα** Ένα διάνυσμα είναι ένα στοιχείο ενός διανυσματικού χώρου. Στο πλαίσιο της μηχανικής μάθησης, ένα ιδιαίτερα σημαντικό παράδειγμα διανυσματικού χώρου είναι ο Ευκλείδειος χώρος  $\mathbb{R}^d$ , όπου  $d \in \mathbb{N}$  είναι η (πεπερασμένη) διάσταση του χώρου. Ένα διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$  μπορεί να αναπαρασταθεί ως μία λίστα ή μονοδιάστατη (1-D) διάταξη πραγματικών αριθμών, δηλαδή  $x_1, \dots, x_d$  με  $x_j \in \mathbb{R}$  για  $j = 1, \dots, d$ . Η τιμή  $x_j$  είναι η  $j$ στή είσοδος του διανύσματος  $\mathbf{x}$ . Μπορεί επίσης να είναι χρήσιμο να θεωρήσουμε ένα διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$  ως μία συνάρτηση που αντιστοιχεί κάθε δείκτη  $j \in \{1, \dots, d\}$  σε μία τιμή  $x_j \in \mathbb{R}$ , δηλαδή  $\mathbf{x} : j \mapsto x_j$ . Αυτή η προοπτική είναι ιδιαίτερα χρήσιμη για την μελέτη των μεθόδων πυρήνα. Βλέπε Σχ. 1 για τις δύο όψεις ενός διανύσματος.

2, -1, 3, 0, -2, 1

(a)




(b)

Σχ. 1. Δύο ισοδύναμες όψεις ενός διανύσματος  $\mathbf{x} = (2, -1, 3, 0, -2, 1)^T \in \mathbb{R}^6$ . (a) Ως μία αριθμητική διάταξη. (b) Ως μία  $\text{map } j \mapsto x_j$ .

Βλέπε επίσης: διανυσματικός χώρος, `ml`, Ευκλείδειος χώρος, συνάρτηση, μέθοδος πυρήνα, `map`, `linear map`.

**διανυσματικός χώρος** Ένας διανυσματικός χώρος  $\mathcal{V}$  (που ονομάζεται επίσης γραμμικός χώρος) είναι μία συλλογή στοιχείων, τα οποία ονομάζονται διανύσματα, μαζί με τις εξής δύο λειτουργίες (βλέπε επίσης Σχ. 2): 1) πρόσθεση (που δηλώνεται με  $\mathbf{v} + \mathbf{w}$ ) δύο διανυσμάτων  $\mathbf{v}, \mathbf{w}$  και 2) πολλαπλασιασμός (που δηλώνεται με  $c \cdot \mathbf{v}$ ) ενός διανύσματος  $\mathbf{v}$  με έναν βαθμωτό  $c$  που ανήκει σε κάποιο αριθμητικό πεδίο (με μία τυπική επιλογή για αυτό το πεδίο να είναι ο  $\mathbb{R}$ ). Η καθοριστική ιδιότητα ενός διανυσματικού χώρου είναι ότι είναι κλειστός υπό δύο συγκεκριμένες λειτουργίες. Πρώτον, αν  $\mathbf{v}, \mathbf{w} \in \mathcal{V}$ , τότε  $\mathbf{v} + \mathbf{w} \in \mathcal{V}$ . Δεύτερον, αν  $\mathbf{v} \in \mathcal{V}$  και  $c \in \mathbb{R}$ , τότε  $c\mathbf{v} \in \mathcal{V}$ .



Σχ. 2. Ένας διανυσματικός χώρος  $\mathcal{V}$  είναι μία συλλογή διανυσμάτων, έτσι ώστε η κλίμακα και η πρόσθεσή τους πάντα αποφέρει ένα άλλο διάνυσμα στο  $\mathcal{V}$ .

Ένα κοινό παράδειγμα ενός διανυσματικού χώρου είναι ο Ευκλείδειος

χώρος  $\mathbb{R}^n$ , ο οποίος χρησιμοποιείται ευρέως στη μηχανική μάθηση για την αναπαράσταση συνόλων δεδομένων. Μπορούμε επίσης να χρησιμοποιήσουμε τον  $\mathbb{R}^n$  για να αναπαράστησουμε, είτε ακριβώς είτε προσεγγιστικά, τον χώρο υποθέσεων που χρησιμοποιείται από μία μέθοδο μηχανικής μάθησης. Ένα άλλο παράδειγμα διανυσματικού χώρου, ο οποίος σχετίζεται φυσικά με κάθε χώρο πιθανοτήτων  $\mathcal{P} = (\Omega, \mathcal{R}, \mathbb{P}(\cdot))$ , είναι η συλλογή όλων των τυχαίων μεταβλητών πραγματικής τιμής  $x : \Omega \rightarrow \mathbb{R}$  [1], [9].

Βλέπε επίσης: διάνυσμα, Ευκλείδειος χώρος, ml, σύνολο δεδομένων, χώρος υποθέσεων, χώρος πιθανοτήτων, τυχαία μεταβλητή, γραμμικό μοντέλο, linear map.

**Εσσιανός** Για μία συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  που είναι δύο φορές παραγωγίσιμη σε ένα σημείο  $\mathbf{x}$ , ο Εσσιανός είναι μία συλλογή τετραγωνικών πινάκων μερικών παράγωγων δεύτερης τάξης. Δηλώνεται με  $\nabla^2 f(\mathbf{w}) = [\partial^2 f(\mathbf{w}) / \partial w_i \partial w_j]_{i,j=1}^d$ . Ο Εσσιανός μπορεί να χρησιμοποιηθεί για τον υπολογισμό μίας τετραγωνικής συνάρτησης που προσεγγίζει τοπικά την  $f$ .

Βλέπε επίσης: παραγωγίσιμη, πίνακας, συνάρτηση, τετραγωνική συνάρτηση.

**κυρτή βελτιστοποίηση** TBD.

**ορίζουσα** Η ορίζουσα  $\det(\mathbf{A})$  ενός τετραγωνικού πίνακα  $\mathbf{A} = (\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)}) \in \mathbb{R}^{d \times d}$  είναι μία συνάρτηση των στηλών του  $\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)} \in \mathbb{R}^d$ , δηλαδή πληροί τις ακόλουθες ιδιότητες [10]:

- Κανονικοποιημένη:

$$\det(\mathbf{I}) = 1$$


- Πολυγραμμική:

$$\det(\mathbf{a}^{(1)}, \dots, \alpha \mathbf{u} + \beta \mathbf{v}, \dots, \mathbf{a}^{(d)}) = \alpha \det(\mathbf{a}^{(1)}, \dots, \mathbf{u}, \dots, \mathbf{a}^{(d)}) + \beta \det(\mathbf{a}^{(1)}, \dots, \mathbf{v}, \dots, \mathbf{a}^{(d)})$$

- Αντισυμμετρική:

$$\det(\dots, \mathbf{a}^{(j)}, \dots, \mathbf{a}^{(j')}, \dots) = -\det(\dots, \mathbf{a}^{(j')}, \dots, \mathbf{a}^{(j)}, \dots).$$

Μπορούμε να ερμηνεύσουμε έναν πίνακα  $\mathbf{A}$  ως έναν γραμμικό μετασχηματισμό στον  $\mathbb{R}^d$ . Η ορίζουσα  $\det(\mathbf{A})$  χαρακτηρίζει πώς οι όγκοι στον  $\mathbb{R}^d$  (και ο προσανατολισμός τους) μεταβάλλονται από αυτόν τον μετασχηματισμό (βλέπε Σχ. 3) [3], [11]. Συγκεκριμένα,  $\det(\mathbf{A}) > 0$  διατηρεί τον προσανατολισμό,  $\det(\mathbf{A}) < 0$  αντιστρέφει τον προσανατολισμό, και  $\det(\mathbf{A}) = 0$  συρρικνώνει πλήρως τον όγκο, υποδεικνύοντας ότι ο  $\mathbf{A}$  είναι μη αντιστρέψιμος. Η ορίζουσα ικανοποιεί επίσης  $\det(\mathbf{AB}) = \det(\mathbf{A}) \cdot \det(\mathbf{B})$ , και αν ο  $\mathbf{A}$  είναι διαγωνοποιήσιμος με ιδιοτιμές  $\lambda_1, \dots, \lambda_d$ , τότε  $\det(\mathbf{A}) = \prod_{j=1}^d \lambda_j$  [12]. Για τις ειδικές περιπτώσεις  $d = 2$  (δηλαδή δισδιάστατη ή 2-Δ) και  $d = 3$  (δηλαδή τρισδιάστατη ή 3-Δ), η ορίζουσα μπορεί να ερμηνευτεί ως μία προσανατολισμένη επιφάνεια ή όγκος παραγόμενος από τα διανύσματα στηλών του  $\mathbf{A}$ .



Σχ. 3. Μπορούμε να ερμηνεύσουμε έναν τετραγωνικό πίνακα  $\mathbf{A}$  ως έναν γραμμικό μετασχηματισμό του  $\mathbb{R}^d$  στον εαυτό του. Η ορίζουσα  $\det(\mathbf{A})$  χαρακτηρίζει πώς αυτός ο μετασχηματισμός μεταβάλλει έναν προσανατολισμένο όγκο.

Βλέπε επίσης: πίνακας, συνάρτηση, ιδιοτιμή, διάνυσμα, αντίστροφος πίνακας.

**πίνακας** Ένας πίνακας μεγέθους  $m \times d$  είναι μία 2-D διάταξη αριθμών, η οποία δηλώνεται με

$$\mathbf{A} = \begin{bmatrix} A_{1,1} & A_{1,2} & \dots & A_{1,d} \\ A_{2,1} & A_{2,2} & \dots & A_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m,1} & A_{m,2} & \dots & A_{m,d} \end{bmatrix} \in \mathbb{R}^{m \times d}.$$

Εδώ,  $A_{r,j}$  δηλώνει την καταχώριση του πίνακα στην  $r$ στή γραμμή και την  $j$ στή στήλη. Οι πίνακες είναι χρήσιμες αναπαραστάσεις διάφορων μαθηματικών αντικειμένων [13], συμπεριλαμβανομένων των εξής:

- Συστήματα γραμμικών εξισώσεων: Μπορούμε να χρησιμοποιήσουμε έναν πίνακα για να αναπαραστήσουμε ένα σύστημα γραμμικών

εξισώσεων


$$\begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \quad \text{συμπαγώς ως} \quad \mathbf{A}\mathbf{w} = \mathbf{y}.$$

Ένα σημαντικό παράδειγμα συστημάτων γραμμικών εξισώσεων είναι η συνθήκη βελτιστότητας για τις παραμέτρους μοντέλου εντός γραμμικής παλινδρόμησης.

- Linear maps: Θεωρούμε έναν  $d$ -διάστατο διανυσματικό χώρο  $\mathcal{U}$  και έναν  $m$ -διάστατο διανυσματικό χώρο  $\mathcal{V}$ . Αν σταθεροποιήσουμε μία βάση  $\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}$  για  $\mathcal{U}$  και μία βάση  $\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(m)}$  για  $\mathcal{V}$ , κάθε πίνακας  $\mathbf{A} \in \mathbb{R}^{m \times d}$  ορίζει φυσικά μία linear map  $\alpha : \mathcal{U} \rightarrow \mathcal{V}$  (βλέπε Σχ. 4), έτσι ώστε

$$\mathbf{u}^{(j)} \mapsto \sum_{r=1}^m A_{r,j} \mathbf{v}^{(r)}.$$

- Σύνολα δεδομένων: Μπορούμε να χρησιμοποιήσουμε έναν πίνακα για να αναπαραστήσουμε ένα σύνολο δεδομένων. Κάθε γραμμή αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και κάθε στήλη αντιστοιχεί σε ένα συγκεκριμένο χαρακτηριστικό ή ετικέτα ενός σημείου δεδομένων.



Σχ. 4. Ένας πίνακας  $\mathbf{A}$  ορίζει μία linear map μεταξύ δύο διανυσματικών χώρων.

Βλέπε επίσης: παράμετροι μοντέλου, γραμμική παλινδρόμηση, linear map, διανυσματικός χώρος, σύνολο δεδομένων, data point, feature, ετικέτα, γραμμικό μοντέλο.

**πρόβλημα βελτιστοποίησης** Ένα πρόβλημα βελτιστοποίησης (optimization problem) είναι μία μαθηματική δομή που αποτελείται από μία αντικειμενική συνάρτηση  $f : \mathcal{U} \rightarrow \mathcal{V}$  ορισμένη πάνω σε μία μεταβλητή βελτιστοποίησης  $\mathbf{w} \in \mathcal{U}$ , μαζί με ένα εφικτό σύνολο  $\mathcal{W} \subseteq \mathcal{U}$ . Το πεδίο τιμών  $\mathcal{V}$  θεωρείται ότι είναι διατεταγμένο, που σημαίνει ότι για οποιαδήποτε δύο στοιχεία  $\mathbf{a}, \mathbf{b} \in \mathcal{V}$ , μπορούμε να καθορίσουμε αν  $\mathbf{a} < \mathbf{b}$ ,  $\mathbf{a} = \mathbf{b}$ , ή  $\mathbf{a} > \mathbf{b}$ . Ο στόχος της βελτιστοποίησης είναι να βρούμε εκείνες τις τιμές  $\mathbf{w} \in \mathcal{W}$  για τις οποίες η αντικειμενική  $f(\mathbf{w})$  είναι ακρότατη—δηλαδή ελάχιστη ή μέγιστη [14], [15], [16].

Βλέπε επίσης: αντικειμενική συνάρτηση.

**στοχαστική διαδικασία** Μία στοχαστική διαδικασία είναι μία συλλογή τυχαίων μεταβλητών που ορίζονται πάνω σε έναν κοινό χώρο πιθανοτήτων και που έχουν δείκτες από κάποιο σύνολο  $\mathcal{I}$  [17], [18], [19]. Το σύνολο δεικτών  $\mathcal{I}$  συνήθως αναπαριστά χρόνο και χώρο, επιτρέποντάς μας

να αναπαραστήσουμε τυχαία φαινόμενα που εξελίσσονται στον χρόνο ή σε χωρικές διαστάσεις—για παράδειγμα, θόρυβο αισθητήρα ή οικονομικές χρονοσειρές. Οι στοχαστικές διαδικασίες δεν περιορίζονται σε χρονικά ή χωρικά περιβάλλοντα. Για παράδειγμα, τυχαίοι γράφοι όπως ο Erdős–Rényi (ER) graph ή το μοντέλο στοχαστικής ομάδας μπορούν επίσης να θεωρηθούν στοχαστικές διαδικασίες. Εδώ, το σύνολο δεικτών  $\mathcal{I}$  αποτελείται από ζεύγη κόμβων που ευρετηριάζουν τυχαίες μεταβλητές των οποίων οι τιμές κωδικοποιούν την παρουσία ή το βάρος μίας ακμής μεταξύ δύο κόμβων. Επιπλέον, οι στοχαστικές διαδικασίες προκύπτουν φυσικά στην ανάλυση στοχαστικών αλγόριθμων, όπως της στοχαστικής καθόδου κλίσης, οι οποίοι κατασκευάζουν μία ακολουθία τυχαίων μεταβλητών.

Βλέπε επίσης: στοχαστική, τυχαία μεταβλητή, χώρος πιθανοτήτων, graph, ER graph, μοντέλο στοχαστικής ομάδας, στοχαστικός αλγόριθμος, στοχαστική κάθοδος κλίσης, αβεβαιότητα, πιθανοτικό μοντέλο.


**σύγκλιση** TBD.

**συνάρτηση** Μία συνάρτηση μεταξύ δύο συνόλων  $\mathcal{U}$  και  $\mathcal{V}$  αποδίδει σε κάθε στοιχείο  $u \in \mathcal{U}$  ακριβώς ένα στοιχείο  $f(u) \in \mathcal{V}$  [2]. Το γράφουμε αυτό ως

$$f : \mathcal{U} \rightarrow \mathcal{V} : u \mapsto f(u)$$

όπου  $\mathcal{U}$  είναι το πεδίο και  $\mathcal{V}$  το πεδίο τιμών της  $f$ . Για την ακρίβεια, η συνάρτηση  $f$  ορίζει μία μοναδική έξοδο  $f(u) \in \mathcal{V}$  για κάθε είσοδο  $u \in \mathcal{U}$  (βλέπε Σχ. 5).





Σχ. 5. Μία συνάρτηση  $f: \{a, b, c\} \rightarrow \{1, 2, 3\}$  που αντιστοιχεί κάθε στοιχείο του πεδίου σε ακριβώς ένα στοιχείο του πεδίου τιμών.

**χαρακτηριστική συνάρτηση** Η χαρακτηριστική συνάρτηση μίας τυχαίας μεταβλητής πραγματικής τιμής  $x$  είναι η συνάρτηση [6, Sec. 26]

$$\phi_x(t) := \mathbb{E} \exp(jtx) \text{ με } j = \sqrt{-1}.$$

Η χαρακτηριστική συνάρτηση προσδιορίζει μοναδικά την κατανομή πιθανότητας της  $x$ .

Βλέπε επίσης: συνάρτηση, τυχαία μεταβλητή, κατανομή πιθανότητας.

**map** We use the term map as a synonym for συνάρτηση.

Βλέπε επίσης: συνάρτηση.

**Newton's method** Newton's method is an iterative μέθοδος βελτιστοποίησης for finding local ελάχιστος or maximums of a παραγωγίσιμη αντικειμενική συνάρτηση  $f(\mathbf{w})$ . Like μέθοδοι με βάση την κλίση, Newton's

method also computes a new estimate  $\widehat{\mathbf{w}}_{k+1}$  by optimizing a local approximation of  $f(\mathbf{w})$  around the current estimate  $\widehat{\mathbf{w}}_k$ . In contrast to μέθοδοι με βάση την κλίση, which use the gradient to build a local linear approximation, Newton's method uses the Εσσιανός πίνακας to build a local quadratic approximation. In particular, starting from an initial estimate  $\widehat{\mathbf{w}}_0$ , Newton's method iteratively updates the estimate according to

$$\widehat{\mathbf{w}}_{k+1} = \widehat{\mathbf{w}}_k - (\nabla^2 f(\widehat{\mathbf{w}}_k))^{-1} \nabla f(\widehat{\mathbf{w}}_k), \text{ for } k = 0, 1, \dots$$

Here,  $\nabla f(\widehat{\mathbf{w}}_k)$  is the gradient, and  $\nabla^2 f(\mathbf{w}^{(k)})$  is the Εσσιανός of the αντικειμενική συνάρτηση  $f$ . Since using a τετραγωνική συνάρτηση as local approximation is more accurate than using a linear συνάρτηση (which is a special case of a τετραγωνική συνάρτηση), Newton's method tends to converge faster than μέθοδοι με βάση την κλίση (see Fig. 6). However, this faster σύγκλιση comes at the increased computational complexity of the iterations. Indeed, each iteration of Newton's method requires the inversion of the Εσσιανός.




Fig. 6. Comparison of κάθοδος κλίσης (blue) and Newton's method (red) paths toward the ελάχιστο of a συνάρτηση απώλειας.

Βλέπε επίσης: μέθοδος βελτιστοποίησης, ελάχιστο, maximum, παραγωγίσιμη, αντικειμενική συνάρτηση, μέθοδοι με βάση την κλίση, gradient, Εσσιανός, πίνακας, τετραγωνική συνάρτηση, συνάρτηση, σύγκλιση, κάθοδος κλίσης, ελάχιστο, συνάρτηση απώλειας.


## Έννοιες Μηχανικής Μάθησης

**αβεβαιότητα** Στο πλαίσιο της μηχανικής μάθησης, η αβεβαιότητα αναφέρεται στην παρουσία πολλαπλών εύλογων αποτελεσμάτων ή εξηγήσεων με βάση τα διαθέσιμα δεδομένα. Για παράδειγμα, η πρόβλεψη  $\hat{h}(\mathbf{x})$  που παράγεται από ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης  $\hat{h}$  συχνά αντανακλά ένα πεδίο πιθανών τιμών για την αληθή ετικέτα ενός συγκεκριμένου σημείου δεδομένων. Όσο πιο ευρύ το πεδίο, τόσο μεγαλύτερη η σχετική αβεβαιότητα. Η θεωρία πιθανοτήτων μας επιτρέπει να αναπαριστούμε, να ποσοτικοποιούμε, και να συλλογιστούμε για την αβεβαιότητα με έναν μαθηματικά ενδεδειγμένο τρόπο.

Βλέπε επίσης: ml, εξήγηση, δεδομένα, πρόβλεψη, model, ετικέτα, data point, probability, πιθανοτικό μοντέλο, διακινδύνευση, εντροπία, διακύμανση.

**αισιοδοξία παρά την αβεβαιότητα** Οι μέθοδοι μηχανικής μάθησης μαθαίνουν παραμέτρους μοντέλου  $\mathbf{w}$  σύμφωνα με κάποιο κριτήριο επίδοσης  $\bar{f}(\mathbf{w})$ . Ωστόσο, δεν μπορούν να έχουν άμεση πρόσβαση στο  $\bar{f}(\mathbf{w})$ , αλλά βασίζονται σε μία εκτίμηση (ή προσέγγιση)  $f(\mathbf{w})$  του  $\bar{f}(\mathbf{w})$ . Ως ένα χαρακτηριστικό παράδειγμα, οι μέθοδοι βασιμμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης χρησιμοποιούν τη μέση απώλεια σε ένα συγκεκριμένο σύνολο δεδομένων (δηλαδή το σύνολο εκπαίδευσης) ως μία εκτίμηση για τη διακινδύνευση μίας υπόθεσης. Χρησιμοποιώντας ένα πιθανοτικό μοντέλο, μπορεί κανείς να κατασκευάσει ένα διάστημα εμπιστοσύνης  $[l^{(\mathbf{w})}, u^{(\mathbf{w})}]$  για κάθε επιλογή  $\mathbf{w}$  για τις παραμέτρους μοντέλου. Μία απλή κατασκευή είναι  $l^{(\mathbf{w})} := f(\mathbf{w}) - \sigma/2$ ,  $u^{(\mathbf{w})} := f(\mathbf{w}) + \sigma/2$ , με το

$\sigma$  να είναι ένα μέτρο της (αναμενόμενης) απόκλισης του  $f(\mathbf{w})$  από το  $\bar{f}(\mathbf{w})$ . Μπορούμε επίσης να χρησιμοποιήσουμε άλλες κατασκευές για αυτό το διάστημα εφόσον εξασφαλίζουν ότι  $\bar{f}(\mathbf{w}) \in [l^{(\mathbf{w})}, u^{(\mathbf{w})}]$  με αρκετά υψηλή πιθανότητα. Ένας αισιόδοξος επιλέγει τις παραμέτρους μοντέλου σύμφωνα με την πιο ευνοϊκή—αλλά εύλογη—τιμή  $\tilde{f}(\mathbf{w}) := l^{(\mathbf{w})}$  του κριτηρίου επίδοσης (βλέπε Σχ. 7). Δύο παραδείγματα μεθόδων μηχανικής μάθησης που χρησιμοποιούν μία τέτοια αισιόδοξη κατασκευή μίας αντικειμενικής συνάρτησης είναι οι μέθοδοι ελαχιστοποίησης δομικής διακινδύνευσης [20, Κεφ. 11] και άνω φράγματος εμπιστοσύνης για διαδοχική λήψη αποφάσεων [21, Sec. 2.2].



Σχ. 7. Οι μέθοδοι μηχανικής μάθησης μαθαίνουν παραμέτρους μοντέλου  $\mathbf{w}$  χρησιμοποιώντας κάποια εκτίμηση του  $f(\mathbf{w})$  για το τελικό κριτήριο επίδοσης  $f(\mathbf{w})$ . Χρησιμοποιώντας ένα πιθανοτικό μοντέλο, κανείς μπορεί να χρησιμοποιήσει το  $f(\mathbf{w})$  για να κατασκευάσει διαστήματα εμπιστοσύνης  $[l^{(\mathbf{w})}, u^{(\mathbf{w})}]$ , τα οποία περιέχουν το  $\bar{f}(\mathbf{w})$  με υψηλή πιθανότητα. Το καλύτερο εύλογο μέτρο επίδοσης για μία συγκεκριμένη επιλογή  $\mathbf{w}$  των παραμέτρων του μοντέλου είναι  $\tilde{f}(\mathbf{w}) := l^{(\mathbf{w})}$ .

Βλέπε επίσης: ml, παράμετροι μοντέλου, ελαχιστοποίηση εμπειρικής δια-

κινδύνευσης, loss, σύνολο δεδομένων, σύνολο εκπαίδευσης, διακινδύνευση, υπόθεση, πιθανοτικό μοντέλο, probability, αντικειμενική συνάρτηση, ελαχιστοποίηση δομικής διακινδύνευσης, άνω φράγμα εμπιστοσύνης.

**ακρίβεια** Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$  και μία κατηγορική ετικέτα  $y$  που παίρνει τιμές από ένα πεπερασμένο χώρο ετικετών  $\mathcal{Y}$ . Η ακρίβεις μίας υπόθεσης  $h : \mathcal{X} \rightarrow \mathcal{Y}$ , όταν εφαρμόζεται στα σημεία δεδομένων ενός συνόλου δεδομένων  $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ , ορίζεται τότε ως

$$1 - \frac{1}{m} \sum_{r=1}^m L^{(0/1)}((\mathbf{x}^{(r)}, y^{(r)}), h)$$

χρησιμοποιώντας την 0/1 απώλεια  $L^{(0/1)}(\cdot, \cdot)$ .

Βλέπε επίσης: data point, feature, ετικέτα, χώρος ετικετών, υπόθεση, σύνολο δεδομένων, 0/1 απώλεια, loss, μετρική.

**ακραία τιμή** Πολλές μέθοδοι μηχανικής μάθησης παρακινούνται από την παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, η οποία ερμηνεύει σημεία δεδομένων ως πραγματώσεις ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας. Η παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων είναι χρήσιμη για εφαρμογές όπου οι στατιστικές ιδιότητες της διαδικασίας παραγωγής δεδομένων είναι στάσιμες (ή χρονικά αναλλοίωτες) [17]. Ωστόσο, σε κάποιες εφαρμογές, τα δεδομένα αποτελούνται από μια πλειοψηφία ομαλών σημείων δεδομένων που συμμορφώνονται με την παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων καθώς και από έναν μικρό αριθμό σημείων δεδομένων που

έχουν θεμελιωδώς διαφορετικές στατιστικές ιδιότητες συγκριτικά με τα ομαλά σημεία δεδομένων. Αναφερόμαστε σε ένα σημείο δεδομένων που αποκλίνει ουσιαστικά από τις στατιστικές ιδιότητες των περισσότερων σημείων δεδομένων ως μία ακραία τιμή. Διαφορετικές μέθοδοι για την ανίχνευση ακραίας τιμής χρησιμοποιούν διαφορετικά μέτρα για αυτή την απόκλιση. Η θεωρία στατιστικής μάθησης μελετάει τα θεμελιώδη όρια στη δυνατότητα να μετριάσουν αξιόπιστα οι ακραίες τιμές [22], [23].

Βλέπε επίσης: ml, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, data point, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανοημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, data, ευρωστία, ευστάθεια, παλινδρόμηση Huber, πιθανοτικό μοντέλο.

**αλγόριθμος** Ένας αλγόριθμος (algorithm) είναι μία ακριβής, βήμα προς βήμα προδιαγραφή για την παραγωγή μίας εξόδου (output) από μία συγκεκριμένη είσοδο (input) εντός ενός πεπερασμένου αριθμού υπολογιστικών βημάτων [24]. Για παράδειγμα, ένας αλγόριθμος για την εκπαίδευση ενός γραμμικού μοντέλου περιγράφει ρητά πώς να μετασχηματιστεί ένα δεδομένο σύνολο εκπαίδευσης σε παραμέτρους του μοντέλου μέσω μίας ακολουθίας βημάτων κλίσης. Για να μελετήσουμε αλγόριθμους ενδελεχώς, μπορούμε να τους αναπαραστήσουμε (ή να τους προσεγγίσουμε) με διαφορετικές μαθηματικές δομές [25]. Μία προσέγγιση είναι να αναπαραστήσουμε έναν αλγόριθμο ως μία συλλογή πιθανών εκτελέσεων. Κάθε μεμονωμένη εκτέλεση είναι τότε μία ακολουθία της μορφής


input,  $s_1, s_2, \dots, s_T$ , output.

Αυτή η ακολουθία ξεκινάει από μία είσοδο και προοδεύει μέσω ενδιάμεσων βημάτων μέχρι να παραδοθεί μία έξοδος. Είναι κρίσιμο ότι ένας αλγόριθμος συμπεριλαμβάνει περισσότερα από απλώς μία αντιστοίχιση από είσοδο σε έξοδο· περιλαμβάνει επίσης ενδιάμεσα υπολογιστικά βήματα  $s_1, \dots, s_T$ .

Βλέπε επίσης: γραμμικό μοντέλο, σύνολο εκπαίδευσης, παράμετροι μοντέλου, βήμα κλίσης, model, στοχαστική.

**αλγόριθμος  $k$ -μέσων** Η αρχή του αλγόριθμου  $k$ -μέσων ( $k$ -means) είναι μία προσέγγιση βασισμένη στη βελτιστοποίηση για τη συσταδοποίηση σημείων δεδομένων που χαρακτηρίζονται από ένα αριθμητικό διάνυσμα χαρακτηριστικών [8, Κεφ. 8]. Ως μία προσέγγιση σκληρής συσταδοποίησης, ο αλγόριθμος  $k$ -μέσων χωρίζει ένα σύνολο δεδομένων σε  $k$  ξένα υποσύνολα (ή συστάδες), τα οποία έχουν δείκτες από  $c = 1, \dots, k$ . Κάθε συστάδα  $\mathcal{C}$  χαρακτηρίζεται από το μέσο διάνυσμα χαρακτηριστικών των σημείων δεδομένων που ανήκουν σε αυτό. Αυτό το μέσο (ή μέσης τιμής) διάνυσμα χαρακτηριστικών αναφέρεται ως το cluster centroid  $\mu^{(c)}$ . Μία οπτική απεικόνιση παρέχεται στο Σχ. 8.





Σχ. 8. Ένα διάγραμμα διασποράς σημείων δεδομένων, τα οποία έχουν δείκτες από  $r = 1, \dots, m$  και χαρακτηρίζονται από διανύσματα χαρακτηριστικών  $\mathbf{x}^{(r)} \in \mathbb{R}^2$ . Το διάγραμμα διασποράς περιλαμβάνει επίσης δύο cluster centroids  $\boldsymbol{\mu}^{(1)}, \boldsymbol{\mu}^{(2)} \in \mathbb{R}^2$ .

Γενικά, το πρόβλημα του αλγόριθμου  $k$ -μέσων είναι ένα δύσκολο πρόβλημα βελτιστοποίησης [26]. Ωστόσο, υπάρχει μία απλή επαναληπτική μέθοδος για την εύρεση προσεγγιστικά βέλτιστων cluster centroids. Αυτή η μέθοδος, η οποία αναφέρεται ως μέθοδος του Lloyd, εναλλάσσεται μεταξύ: 1) της ενημέρωσης των αποδόσεων συστάδας με βάση το πλησιέστερο τρέχον cluster centroid· και 2) τον επανυπολογισμό των cluster centroids δεδομένων των ενημερωμένων αποδόσεων συστάδας [27].

Βλέπε επίσης: συσταδοποίηση, data point, διάνυσμα χαρακτηριστικών, hard clustering, σύνολο δεδομένων, συστάδα, μέση τιμή, διάγραμμα διασποράς, πρόβλημα βελτιστοποίησης.

**αμοιβαίες πληροφορίες** Οι αμοιβαίες πληροφορίες (mutual information - MI)  $I(\mathbf{x}; y)$  μεταξύ δύο τυχαίων μεταβλητών  $\mathbf{x}, y$  που ορίζονται στον ίδιο χώρο πιθανοτήτων δίνονται από [28]

$$I(\mathbf{x}; y) := \mathbb{E} \left\{ \log \frac{p(\mathbf{x}, y)}{p(\mathbf{x})p(y)} \right\}.$$

Αποτελεί μέτρο του πόσο καλά μπορούμε να εκτιμήσουμε την  $y$  βάσει μόνο του  $\mathbf{x}$ . Μία μεγάλη τιμή του  $I(\mathbf{x}; y)$  υποδεικνύει ότι η  $y$  μπορεί να προβλεφθεί καλά μόνο από το  $\mathbf{x}$ . Αυτή η πρόβλεψη θα μπορούσε να προκύψει από μία υπόθεση που μαθαίνεται από μία μέθοδο μηχανικής μάθησης βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης.

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, πρόβλεψη, υπόθεση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, ml.

**αμφικλινής παλινδρόμηση** Θεωρούμε ένα πρόβλημα παλινδρόμησης όπου ο στόχος είναι να μάθουμε μία υπόθεση  $h^{(\mathbf{w})}$  για την πρόβλεψη της αριθμητικής ετικέτας ενός σημείου δεδομένων με βάση το διάνυσμα χαρακτηριστικών του. Η αμφικλινής παλινδρόμηση μαθαίνει τις παραμέτρους  $\mathbf{w}$  ελαχιστοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που έχει επιβληθεί ως ποινή. Η μέση απώλεια τετραγωνικού σφάλματος μετράται σε ένα σύνολο σημείων δεδομένων με ετικέτες (δηλαδή το σύνολο εκπαίδευσης)

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}).$$

Ο όρος ποινής είναι η ανηγμένη Ευκλείδεια νόρμα  $\alpha \|\mathbf{w}\|_2^2$  με μία παράμετρο ομαλοποίησης  $\alpha > 0$ . Ο σκοπός του όρου ποινής είναι η ομαλοποίηση, δηλαδή η αποφυγή υπερπροσαρμογής στο καθεστώς υψηλής διάστασης, όπου ο αριθμός χαρακτηριστικών  $d$  υπερβαίνει τον αριθμό σημείων δεδομένων  $m$  στο σύνολο εκπαίδευσης. η προσθήκη του  $\alpha \|\mathbf{w}\|_2^2$  στη μέση απώλεια τετραγωνικού σφάλματος ισοδυναμεί με τον υπολογισμό της μέσης απώλεια τετραγωνικού σφάλματος σε ένα επαυξημένο σύνολο εκπαίδευσης. Αυτό το επαυξημένο σύνολο εκπαίδευσης προκύπτει αντικα-

θιστώντας κάθε σημείο δεδομένων  $(\mathbf{x}^{(r)}, y^{(r)})$  στο αρχικό σύνολο εκπαίδευσης με την πραγμάτωση άπειρα πολλών ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών, των οποίων η κατανομή πιθανότητας είναι κεντρική στο  $(\mathbf{x}^{(r)}, y^{(r)})$ .

Βλέπε επίσης: regression, υπόθεση, ετικέτα, data point, διάνυσμα χαρακτηριστικών, παράμετρος, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης, νόρμα, ομαλοποίηση, υπερπροσαρμογή, feature, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, map, data augmentation.

**ανάλυση ιδιαζουσών τιμών** Η ανάλυση ιδιαζουσών τιμών (singular value decomposition - SVD) για έναν πίνακα  $\mathbf{A} \in \mathbb{R}^{m \times d}$  είναι μία παραγοντοποίηση της μορφής

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{U}^T$$

με ορθοκανονικούς πίνακες  $\mathbf{V} \in \mathbb{R}^{m \times m}$  και  $\mathbf{U} \in \mathbb{R}^{d \times d}$  [3]. Ο πίνακας  $\mathbf{\Lambda} \in \mathbb{R}^{m \times d}$  είναι μη μηδενικός μόνο κατά την κύρια διαγώνιο, της οποίας οι καταχωρίσεις  $\Lambda_{j,j}$  είναι μη αρνητικές και αναφέρονται ως ιδιάζουσες τιμές.

Βλέπε επίσης: πίνακας.

**ανάλυση ιδιοτιμών** Η ανάλυση ιδιοτιμών (eigenvalue decomposition - EVD) για έναν τετραγωνικό πίνακα  $\mathbf{A} \in \mathbb{R}^{d \times d}$  είναι μία παραγοντοποίηση της μορφής

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}.$$

Οι στήλες του πίνακα  $\mathbf{V} = (\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(d)})$  είναι τα ιδιοδιανύσματα του

πίνακα  $\mathbf{V}$ . Ο διαγώνιος πίνακας  $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \dots, \lambda_d\}$  περιέχει τις ιδιοτιμές  $\lambda_j$  που αντιστοιχούν στα ιδιοδιανύσματα  $\mathbf{v}^{(j)}$ . Σημείωση ότι η παραπάνω ανάλυση υπάρχει μόνο αν ο πίνακας  $\mathbf{A}$  είναι διαγωνοποιήσιμος. Βλέπε επίσης: πίνακας, ιδιοδιάνυσμα, ιδιοτιμή.

**ανάλυση κυρίων συνιστωσών** Η ανάλυση κυρίων συνιστωσών (principal component analysis - PCA) καθορίζει έναν γραμμικό χάρτη χαρακτηριστικών, έτσι ώστε τα νέα χαρακτηριστικά να μας επιτρέπουν να ξανακατασκευάσουμε τα αρχικά χαρακτηριστικά με το ελάχιστο σφάλμα ανακατασκευής [8].

Βλέπε επίσης: χάρτης χαρακτηριστικών, feature, ελάχιστο.

**ανεξάρτητες και ταυτόσημα κατανεμημένες** Μία συλλογή τυχαίων μεταβλητών  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$  αναφέρεται ως ανεξάρτητη και ταυτόσημα κατανεμημένη (independent and identically distributed - i.i.d.) αν κάθε  $\mathbf{z}^{(r)}$  ακολουθεί την ίδια κατανομή πιθανότητας, και οι τυχαίες μεταβλητές είναι αμοιβαία ανεξάρτητες. Για την ακρίβεια, για οποιαδήποτε συλλογή γεγονότων  $\mathcal{A}_1, \dots, \mathcal{A}_m$ , έχουμε


$$\mathbb{P}(\mathbf{z}^{(1)} \in \mathcal{A}_1, \dots, \mathbf{z}^{(m)} \in \mathcal{A}_m) = \prod_{r=1}^m \mathbb{P}(\mathbf{z}^{(r)} \in \mathcal{A}_r).$$

Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, γεγονός, data point, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων.

**ανταμοιβή** Μία ανταμοιβή αναφέρεται σε κάποια παρατηρούμενη (ή μετρημένη) ποσότητα που μας επιτρέπει να εκτιμήσουμε την απώλεια που προ-

κύπτει από την πρόβλεψη (ή απόφαση) μίας υπόθεσης  $h(\mathbf{x})$ . Για παράδειγμα, σε μία εφαρμογή μηχανικής μάθησης σε αυτοοδηγούμενα οχήματα, η  $h(\mathbf{x})$  θα μπορούσε να αναπαριστά την τρέχουσα κατεύθυνση οδήγησης ενός οχήματος. Θα μπορούσαμε να κατασκευάσουμε μία ανταμοιβή από τις μετρήσεις ενός αισθητήρα σύγκρουσης που υποδεικνύει αν το όχημα κινείται προς ένα εμπόδιο. Ορίζουμε μία χαμηλή ανταμοιβή για την κατεύθυνση οδήγησης  $h(\mathbf{x})$  αν το όχημα κινείται επικίνδυνα προς ένα εμπόδιο. Βλέπε επίσης: loss, πρόβλεψη, υπόθεση, ml, MAB, reinforcement learning (RL).

**αντικειμενική συνάρτηση** Μια αντικειμενική συνάρτηση είναι μία map που αποδίδει μία αριθμητική αντικειμενική τιμή  $f(\mathbf{w})$  σε κάθε επιλογή  $\mathbf{w}$  κάποιας μεταβλητής που θέλουμε να βελτιστοποιήσουμε (βλέπε Σχ. 9). Στο πλαίσιο της μηχανικής μάθησης, η μεταβλητή βελτιστοποίησης θα μπορούσε να είναι οι παράμετροι μοντέλου μίας υπόθεσης  $h(\mathbf{w})$ . Κοινές αντικειμενικές συναρτήσεις περιλαμβάνουν τη διακινδύνευση (δηλαδή την προσδοκώμενη απώλεια) ή την εμπειρική διακινδύνευση (δηλαδή τη μέση απώλεια πάνω σε ένα σύνολο εκπαίδευσης). Οι μέθοδοι μηχανικής μάθησης εφαρμόζουν τεχνικές βελτιστοποίησης, όπως τις μεθόδους με βάση την κλίση, για να βρουν την επιλογή  $\mathbf{w}$  με τη βέλτιστη τιμή (π.χ., το ελάχιστο ή το μέγιστο) της αντικειμενικής συνάρτησης.



Σχ. 9. Μία αντικειμενική συνάρτηση αντιστοιχεί κάθε πιθανή τιμή  $\mathbf{w}$  μίας μεταβλητής βελτιστοποίησης, όπως οι παράμετροι μοντέλου ενός μοντέλου μηχανικής μάθησης, σε μία τιμή που μετράει τη χρησιμότητα της  $\mathbf{w}$ .

Βλέπε επίσης: συνάρτηση, map, ml, παράμετροι μοντέλου, υπόθεση, διακινδύνευση, loss, empirical risk, σύνολο εκπαίδευσης, μέθοδοι με βάση την κλίση, ελάχιστο, maximum, model, συνάρτηση απώλειας, ελαχιστοποίηση εμπειρικής διακινδύνευσης, optimization problem.

**αντιστροφή μοντέλου** A model inversion is a form of επίθεση της ιδιωτικότητας on a ml system. An adversary seeks to infer ευαίσθητο ιδιοχαρακτηριστικός of individual data points by exploiting partial access to a trained model  $\hat{h} \in \mathcal{H}$ . This access typically consists of querying the model for πρόβλεψης  $\hat{h}(\mathbf{x})$  using carefully chosen inputs. Basic model inversion techniques have been demonstrated in the context of facial image ταξινόμηση, where images are reconstructed using the (gradient of) model outputs combined with auxiliary information such as a person's name [29].




Fig. 10. Model inversion techniques implemented in the context of facial image classification.


Βλέπε επίσης: model, επίθεση της ιδιωτικότητας, ml, ευαίσθητο ιδιο-  
 χαρακτηριστικό, data point, πρόβλεψη, ταξινόμηση, gradient, αξιόπιστη  
 τεχνητή νοημοσύνη (αξιόπιστη TN), προστασία της ιδιωτικότητας.

**αντίστροφος πίνακας** Ένας αντίστροφος πίνακας (inverse matrix)  $\mathbf{A}^{-1}$   
 ορίζεται για έναν τετραγωνικό πίνακα  $\mathbf{A} \in \mathbb{R}^{n \times n}$  που είναι πλήρους τάξης,  
 που σημαίνει ότι οι στήλες του είναι γραμμικά ανεξάρτητες. Σε αυτή την  
 περίπτωση, ο  $\mathbf{A}$  λέγεται ότι είναι αντιστρέψιμος, και ο αντίστροφός του  
 ικανοποιεί

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}.$$

Ένας τετραγωνικός πίνακας είναι αντιστρέψιμος αν και μόνο αν η ορίζου-  
 σά του είναι μη μηδενική. Οι αντίστροφοι πίνακες είναι θεμελιώδεις στη  
 λύση συστημάτων γραμμικών εξισώσεων και στην κλειστής μορφής λύση  
 γραμμικής παλινδρόμησης [11], [30]. Η έννοια του αντίστροφου πίνακα

μπορεί να επεκταθεί σε πίνακες που δεν είναι τετραγωνικοί ή πλήρους τάξης. Μπορεί κανείς να ορίσει έναν «αριστερό αντίστροφο»  $\mathbf{B}$  που ικανοποιεί  $\mathbf{BA} = \mathbf{I}$  ή έναν «δεξιό αντίστροφο»  $\mathbf{C}$  που ικανοποιεί  $\mathbf{AC} = \mathbf{I}$ . Για γενικούς ορθογώνιους ή ιδιάζοντες πίνακες, ο ψευδοαντίστροφος Moore–Penrose  $\mathbf{A}^+$  παρέχει μία ενοποιημένη έννοια του γενικευμένου αντίστροφου πίνακα [3].



Σχ. 11. Ένας πίνακας  $\mathbf{A}$  αναπαριστά έναν γραμμικό μετασχηματισμό του  $\mathbb{R}^2$ . Ο αντίστροφος πίνακας  $\mathbf{A}^{-1}$  αναπαριστά τον αντίστροφο μετασχηματισμό.

Βλέπε επίσης: πίνακας, ορίζουσα, γραμμική παλινδρόμηση, ψευδοαντίστροφος.

**άνω φράγμα εμπιστοσύνης (ΑΦΕ)** Θεωρούμε μία εφαρμογή μηχανικής μάθησης που απαιτεί την επιλογή, σε κάθε χρονικό βήμα  $k$ , μίας ενέργειας  $a_k$  από ένα πεπερασμένο σύνολο εναλλακτικών  $\mathcal{A}$ . Η χρησιμότητα της επιλογής της ενέργειας  $a_k$  ποσοτικοποιείται από ένα αριθμητικό σήμα ανταμοιβής  $r^{(a_k)}$ . Ένα ευρέως χρησιμοποιούμενο πιθανοτικό μοντέλο για αυτόν τον τύπο προβλήματος ακολουθιακής λήψης αποφάσεων είναι το περιβάλλον στοχαστικής MAB [21]. Σε αυτό το μοντέλο, η ανταμοιβή  $r^{(a)}$  θεωρείται ως η πραγμάτωση μίας τυχαίας μεταβλητής με άγνωστη μέση τιμή  $\mu^{(a)}$ . Ιδανικά, θα επιλέγαμε πάντα την ενέργεια με την μεγαλύτερη



αναμενόμενη ανταμοιβή  $\mu^{(a)}$ , αλλά αυτές οι μέσες τιμές είναι άγνωστες και πρέπει να εκτιμηθούν από παρατηρούμενα δεδομένα. Το να επιλεχθεί απλά η ενέργεια με τη μεγαλύτερη εκτίμηση  $\hat{\mu}^{(a)}$  μπορεί να οδηγήσει σε υποβέλτιστα αποτελέσματα λόγω της αβεβαιότητας στην εκτίμηση. Η στρατηγική ΑΦΕ (upper confidence bound - UCB) το αντιμετωπίζει αυτό επιλέγοντας ενέργειες όχι μόνο με βάση τις εκτιμώμενες μέσες τιμές αλλά και ενσωματώνοντας έναν όρο που αντανακλά την αβεβαιότητα σε αυτές τις εκτιμήσεις—ευνοώντας ενέργειες με υψηλή πιθανή ανταμοιβή και υψηλή αβεβαιότητα. Θεωρητικές εγγυήσεις για την επίδοση στρατηγικών ΑΦΕ, συμπεριλαμβανομένων των ορίων λογαριθμικής regret, καταδεικνύονται στο [21].

Βλέπε επίσης: ml, ανταμοιβή, πιθανοτικό μοντέλο, στοχαστική, MAB, model, πραγμάτωση, τυχαία μεταβλητή, μέση τιμή, data, αβεβαιότητα, regret.

**αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN)** Εκτός από τις υπολογιστικές διαστάσεις και τις στατιστικές διαστάσεις, μία τρίτη κύρια διάσταση σχεδιασμού μεθόδων μηχανικής μάθησης είναι η αξιοπιστία τους [31]. Η Ευρωπαϊκή Ένωση (ΕΕ) έχει διατυπώσει επτά βασικές απαιτήσεις για αξιόπιστη τεχνητή νοημοσύνη (trustworthy artificial intelligence - trustworthy AI) (οι οποίες συνήθως χτίζονται πάνω σε μεθόδους μηχανικής μάθησης) [32]:

- 1) Ανθρώπινη παρέμβαση και εποπτεία·
- 2) Τεχνική ευρωστία και ασφάλεια·
- 3) Ιδιωτικότητα και διακυβέρνηση των δεδομένων·

- 4) Διαφάνεια.
- 5) Διαφορετικότητα, απαγόρευση των διακρίσεων και δικαιοσύνη.
- 6) Κοινωνιακή και περιβαλλοντική ευημερία.
- 7) Λογοδοσία.

Βλέπε επίσης: υπολογιστικές διαστάσεις, στατιστικές διαστάσεις, ml, τεχνητή νοημοσύνη (TN), ευρωστία, data, transparency.

**απόκλιση** Θεωρούμε μία εφαρμογή ομοσπονδιακής μάθησης με networked data που αναπαριστώνται από ένα δίκτυο ομοσπονδιακής μάθησης. Οι μέθοδοι ομοσπονδιακής μάθησης χρησιμοποιούν ένα μέτρο απόκλισης για να συγκρίνουν maps υπόθεσης από τοπικά μοντέλα σε κόμβους  $i, i'$ , συνδεδεμένοι με μία ακμή στο δίκτυο ομοσπονδιακής μάθησης.

Βλέπε επίσης: federated learning (FL), networked data, δίκτυο ομοσπονδιακής μάθησης, υπόθεση, map, local model.

**απόκλιση Kullback–Leibler (απόκλιση KL)** Η απόκλιση KL (Kullback–Leibler divergence - KL divergence) είναι ένα ποσοτικό μέτρο του πόσο διαφορετική είναι μία κατανομή πιθανότητας από μία άλλη [28].

Βλέπε επίσης: κατανομή πιθανότητας.

**απόκλιση Rényi** Η απόκλιση Rényi μετράει την (αν)ομοιότητα μεταξύ δύο κατανομών πιθανοτήτων [33].

Βλέπε επίσης: κατανομή πιθανότητας.

**αποτελεσματική διάσταση** Η αποτελεσματική διάσταση  $d_{\text{eff}}(\mathcal{H})$  ενός άπειρου χώρου υποθέσεων  $\mathcal{H}$  είναι ένα μέτρο του μεγέθους του. Σε γενι-

κές γραμμές, η αποτελεσματική διάσταση είναι ίση με τον αποτελεσματικό αριθμό ανεξάρτητων παραμέτρων μοντέλου που μπορούν να ρυθμιστούν. Αυτές οι παράμετροι μπορεί να είναι συντελεστές που χρησιμοποιούνται σε μία linear map ή τα βάρη και οι όροι μεροληψίας ενός τεχνητού νευρωνικού δικτύου.

Βλέπε επίσης: χώρος υποθέσεων, παράμετροι μοντέλου, παράμετρος, linear map, βάρη, μεροληψία, ΤΝΔ.

**απώλεια** Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν μία συνάρτηση απώλειας  $L(\mathbf{z}, h)$  για να μετρήσουν το σφάλμα που προκαλείται από την εφαρμογή μίας συγκεκριμένης υπόθεσης σε ένα συγκεκριμένο σημείο δεδομένων. Με μία μικρή κατάχρηση του συμβολισμού, χρησιμοποιούμε τον όρο απώλεια και για την ίδια τη συνάρτηση απώλειας  $L$  και για τη συγκεκριμένη τιμή  $L(\mathbf{z}, h)$ , για ένα σημείο δεδομένων  $\mathbf{z}$  και μία υπόθεση  $h$ .

Βλέπε επίσης: ml, συνάρτηση απώλειας, υπόθεση, data point.


**απώλεια απόλυτου σφάλματος** Θεωρούμε ένα σημείο δεδομένων με χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$  και αριθμητική ετικέτα  $y \in \mathbb{R}$ . Όπως υποδηλώνει και το όνομά της, η απώλεια απόλυτου σφάλματος που προκαλείται από μία υπόθεση  $h : \mathcal{X} \rightarrow \mathbb{R}$  ορίζεται ως

$$L((\mathbf{x}, y), h) = |y - h(\mathbf{x})|.$$

Το Σχ. 12 απεικονίζει την απώλεια απόλυτου σφάλματος για ένα σταθερό σημείο δεδομένων με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ . Υποδεικνύει επίσης τις τιμές απώλειας που προκαλούνται από δύο διαφορετικές υποθέσεις  $h'$  και  $h''$ . Όμοια με την απώλεια τετραγωνικού

σφάλματος, η απώλεια απόλυτου σφάλματος είναι επίσης μία κυρτή συνάρτηση της πρόβλεψης  $\hat{y} = h(\mathbf{x})$ . Ωστόσο, σε αντίθεση με την απώλεια τετραγωνικού σφάλματος, η απώλεια απόλυτου σφάλματος είναι μη λεία, καθώς δεν είναι παραγωγίσιμη στη βέλτιστη πρόβλεψη  $\hat{y} = y$ . Αυτή η ιδιότητα καθιστά τις μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιούν την απώλεια απόλυτου σφάλματος υπολογιστικά πιο απαιτητικές [16], [34]. Για να κατανοήσουμε καλύτερα, είναι χρήσιμο να παρατηρήσουμε τις δύο υποθέσεις που απεικονίζονται στο Σχ. 12. Απλώς ελέγχοντας την κλίση της  $L$  γύρω από τα  $h'(\mathbf{x})$  και  $h''(\mathbf{x})$ , είναι απίθανο να προσδιορίσουμε εάν βρισκόμαστε πολύ κοντά στο βέλτιστο (στη  $h'$ ) ή ακόμα μακριά (στη  $h''$ ). Ως αποτέλεσμα, οποιαδήποτε μέθοδος βελτιστοποίησης που βασίζεται σε τοπικές προσεγγίσεις της συνάρτησης απώλειας (όπως η μέθοδος υποκλίσης) πρέπει να χρησιμοποιεί έναν φθίνοντα ρυθμό μάθησης για να αποφευχθεί η υπέρβαση κατά την προσέγγιση του βέλτιστου. Αυτή η απαιτούμενη μείωση στον ρυθμό μάθησης τείνει να επιβραδύνει την σύγκλιση της μεθόδου βελτιστοποίησης. Εκτός από την αυξημένη υπολογιστική πολυπλοκότητα, η χρήση της απώλειας απόλυτου σφάλματος στην ελαχιστοποίηση εμπειρικής διακινδύνευσης μπορεί να είναι ωφέλιμη στην παρουσία ακραίων τιμών στο σύνολο εκπαίδευσης. Σε αντίθεση με την απώλεια τετραγωνικού σφάλματος, η κλίση της απώλειας απόλυτου σφάλματος δεν αυξάνεται με την αύξηση του σφάλματος πρόβλεψης  $y - h(\mathbf{x})$ . Ως αποτέλεσμα, η επίδραση της εισαγωγής μίας ακραίας τιμής με μεγάλο σφάλμα πρόβλεψης στη λύση  $\hat{h}$  της ελαχιστοποίησης εμπειρικής διακινδύνευσης με απώλεια απόλυτου σφάλματος είναι πολύ μικρότερη συγκριτικά με την επίδραση στη λύση

της ελαχιστοποίησης εμπειρικής διακινδύνευσης με απώλεια τετραγωνικού σφάλματος.




Σχ. 12. Για ένα σημείο δεδομένων με αριθμητική ετικέτα  $y \in \mathbb{R}$ , το απόλυτο σφάλμα  $|y - h(\mathbf{x})|$  μπορεί να χρησιμοποιηθεί ως μία συνάρτηση απώλειας για να καθοδηγήσει τη μάθηση μίας υπόθεσης  $h$ .

Βλέπε επίσης: data point, feature, ετικέτα, loss, υπόθεση, διάνυσμα χαρακτηριστικών, απώλεια τετραγωνικού σφάλματος, κυρτός, συνάρτηση, πρόβλεψη, μη λεία, παραγωγίσιμη, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μέθοδος βελτιστοποίησης, συνάρτηση απώλειας, κάθοδος υποκλίσης, ρυθμός μάθησης, σύγκλιση, ακραία τιμή, σύνολο εκπαίδευσης.

**απώλεια άρθρωσης** Θεωρούμε ένα σημείο δεδομένων που χαρακτηρίζεται από ένα διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  και μία δυαδική ετικέτα  $y \in \{-1, 1\}$ . Η απώλεια άρθρωσης που προκαλείται από μία map υπόθεσης  $h(\mathbf{x})$  πραγματικής τιμής ορίζεται ως

$$L((\mathbf{x}, y), h) := \max\{0, 1 - yh(\mathbf{x})\}. \quad (1)$$



Σχ. 13. Η απώλεια άρθρωσης που προκαλείται από την πρόβλεψη  $h(\mathbf{x}) \in \mathbb{R}$  για ένα σημείο δεδομένων με ετικέτα  $y \in \{-1, 1\}$ . Μία ομαλοποιημένη παραλλαγή της απώλειας άρθρωσης χρησιμοποιείται από τη μηχανή διανυσμάτων υποστήριξης [35].

Βλέπε επίσης: data point, διάνυσμα χαρακτηριστικών, ετικέτα, loss, υπόθεση, map, πρόβλεψη, μηχανή διανυσμάτων υποστήριξης, ταξινόμηση, ταξινομητής.

**απώλεια τετραγωνικού σφάλματος** Η απώλεια τετραγωνικού σφάλματος (squared error loss) μετράει το σφάλμα πρόβλεψης μίας υπόθεσης  $h$  όταν προβλέπει μία αριθμητική ετικέτα  $y \in \mathbb{R}$  από τα χαρακτηριστικά  $\mathbf{x}$  ενός σημείου δεδομένων. Ορίζεται ως

$$L((\mathbf{x}, y), h) := (y - \underbrace{h(\mathbf{x})}_{=\hat{y}})^2.$$

Βλέπε επίσης: loss, πρόβλεψη, υπόθεση, ετικέτα, feature, data point.

**απώλεια Huber** Η απώλεια Huber ενώνει την απώλεια τετραγωνικού σφάλματος και την απώλεια απόλυτου σφάλματος.

Βλέπε επίσης: loss, απώλεια τετραγωνικού σφάλματος, απώλεια απόλυτου σφάλματος.

**αριθμός συνθήκης** Ο αριθμός συνθήκης  $\kappa(\mathbf{Q}) \geq 1$  ενός θετικά ορισμένου πίνακα  $\mathbf{Q} \in \mathbb{R}^{d \times d}$  είναι ο λόγος  $\alpha/\beta$  μεταξύ της μεγαλύτερης  $\alpha$  και της μικρότερης  $\beta$  ιδιοτιμής του  $\mathbf{Q}$ . Ο αριθμός συνθήκης είναι χρήσιμος για την ανάλυση μεθόδων μηχανικής μάθησης. Η υπολογιστική πολυπλοκότητα των μεθόδων με βάση την κλίση για γραμμική παλινδρόμηση εξαρτάται κρίσιμα από τον αριθμό συνθήκης του πίνακα  $\mathbf{Q} = \mathbf{X}\mathbf{X}^T$ , με τον πίνακα χαρακτηριστικών  $\mathbf{X}$  του συνόλου εκπαίδευσης. Συνεπώς, από υπολογιστικής άποψης, προτιμούμε χαρακτηριστικά σημεία δεδομένων, έτσι ώστε ο  $\mathbf{Q}$  να έχει έναν αριθμό συνθήκης κοντά στο 1.

Βλέπε επίσης: πίνακας, ιδιοτιμή, ml, μέθοδοι με βάση την κλίση, γραμμική παλινδρόμηση, πίνακας χαρακτηριστικών, σύνολο εκπαίδευσης, feature, data point.

**αρχή της ελαχιστοποίησης των δεδομένων** Ο Ευρωπαϊκός κανονισμός για την προστασία δεδομένων περιλαμβάνει μία αρχή ελαχιστοποίησης δεδομένων. Αυτή η αρχή απαιτεί έναν υπεύθυνο επεξεργασίας δεδομένων για να περιορίσει τη συλλογή προσωπικών πληροφοριών σε ό,τι είναι άμεσα σχετικό και απαραίτητο για την εκπλήρωση ενός προσδιορισμένου σκοπού. Τα δεδομένα πρέπει να φυλάσσονται μόνο για το χρονικό διάστημα που είναι απαραίτητα προκειμένου να εκπληρωθεί αυτός ο σκοπός [36, Άρθρο 5(1)(c)], [37].

Βλέπε επίσης: data.

**αυτοκωδικοποιητής** Ένας αυτοκωδικοποιητής (autoencoder) είναι μία μέθο-

δος μηχανικής μάθησης που μαθαίνει ταυτόχρονα έναν κωδικοποιητή  $\text{map } h(\cdot) \in \mathcal{H}$  και έναν αποκωδικοποιητή  $\text{map } h^*(\cdot) \in \mathcal{H}^*$ . Είναι μία περίπτωση της ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιεί μία απώλεια υπολογιζόμενη από το σφάλμα ανακατασκευής  $\mathbf{x} - h^*(h(\mathbf{x}))$ .

Βλέπε επίσης:  $\text{ml}$ ,  $\text{map}$ , ελαχιστοποίηση εμπειρικής διακινδύνευσης,  $\text{loss}$ , μάθηση χαρακτηριστικών, μείωση της διαστασιμότητας.

**βαθμός κόμβου** Ο βαθμός ενός κόμβου  $d^{(i)}$   $i \in \mathcal{V}$  σε έναν μη κατευθυνόμενο γράφο είναι ο αριθμός των γειτόνων του, δηλαδή  $d^{(i)} := |\mathcal{N}^{(i)}|$ .

Βλέπε επίσης:  $\text{graph}$ , γείτονες.

**βαθμός συσχέτισης** Ο βαθμός συσχέτισης είναι ένας αριθμός που υποδεικνύει το κατά πόσο ένα σημείο δεδομένων ανήκει σε μία συστάδα [8, Κεφ. 8]. Ο βαθμός της συσχέτισης μπορεί να ερμηνευτεί ως μία μαλακή απόδοση συστάδας. Οι μέθοδοι μαλακής συσταδοποίησης μπορούν να κωδικοποιήσουν τον βαθμό συσχέτισης με έναν πραγματικό αριθμό στο διάστημα  $[0, 1]$ . Η σκληρή συσταδοποίηση προκύπτει ως η ακραία περίπτωση όταν ο βαθμός συσχέτισης παίρνει μόνο τιμές 0 or 1.

Βλέπε επίσης:  $\text{data point}$ , συστάδα,  $\text{soft clustering}$ ,  $\text{hard clustering}$ .


**βαθύ δίκτυο** Ένα βαθύ δίκτυο είναι ένα τεχνητό νευρωνικό δίκτυο με έναν (σχετικά) μεγάλο αριθμό κρυφών στρωμάτων. Η βαθιά μάθηση είναι ένας όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που χρησιμοποιούν ένα βαθύ δίκτυο ως το μοντέλο τους [38].

Βλέπε επίσης:  $\text{TN}\Delta$ , στρώμα,  $\text{ml}$ ,  $\text{model}$ .

**βάρη** Θεωρούμε έναν παραμετροποιημένο χώρο υποθέσεων  $\mathcal{H}$ . Χρησιμοποιούμε τον όρο βάρη για αριθμητικές παραμέτρους μοντέλου που χρησιμο-



ποιούνται για να κλιμακώσουν χαρακτηριστικά ή τους μετασχηματισμούς τους προκειμένου να υπολογίσουμε  $h^{(\mathbf{w})} \in \mathcal{H}$ . Ένα γραμμικό μοντέλο χρησιμοποιεί βάρη  $\mathbf{w} = (w_1, \dots, w_d)^T$  για να υπολογίσει τον γραμμικό συνδυασμό  $h^{(\mathbf{w})}(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ . Βάρη χρησιμοποιούνται επίσης σε τεχνητά νευρωνικά δίκτυα για να σχηματιστούν γραμμικοί συνδυασμοί χαρακτηριστικών ή των εξόδων νευρώνων σε κρυφά στρώματα (βλέπε Σχ. 14).



Σχ. 14. Ένα τμήμα ενός τεχνητού νευρωνικού δικτύου που περιέχει ένα κρυφό στρώμα με εξόδους (ή ενεργοποιήσεις)  $h_1, h_2$ , και  $h_3$ . Αυτές οι εξοδοί συνδυάζονται γραμμικά για να υπολογιστεί το  $z$ , το οποίο μπορεί να χρησιμοποιηθεί είτε ως έξοδος του τεχνητού νευρωνικού δικτύου είτε ως είσοδος σε ένα άλλο στρώμα.

Βλέπε επίσης: χώρος υποθέσεων, παράμετροι μοντέλου, feature, γραμμικό μοντέλο, ΤΝΔ, στρώμα, ενεργοποίηση.

**βάρος ακμής** Σε κάθε ακμή  $\{i, i'\}$  ενός δικτύου ομοσπονδιακής μάθησης αποδίδεται ένα μη αρνητικό βάρος ακμής  $A_{i,i'} \geq 0$ . Ένα μηδενικό βάρος ακμής  $A_{i,i'} = 0$  υποδεικνύει την απουσία μίας ακμής μεταξύ κόμβων  $i, i' \in \mathcal{V}$ .

Βλέπε επίσης: δίκτυο ομοσπονδιακής μάθησης.

**βάση αναφοράς** Consider some ml method that produces a learned υπόθεση (or trained model)  $\hat{h} \in \mathcal{H}$ . We evaluate the quality of a trained model by computing the average loss on a σύνολο ελέγχου. But how can we assess whether the resulting σύνολο ελέγχου performance is sufficiently good? How can we determine if the trained model performs close to optimal such that there is little point in investing more resources (for data collection or computation) to improve it? To this end, it is useful to have a reference (or baseline) level against which we can compare the performance of the trained model.

Such a reference value might be obtained from human performance, e.g., the misclassification rate of dermatologists who diagnose cancer from visual inspection of skin [39]. Another source for a baseline is an existing, but for some reason unsuitable, ml method. For example, the existing ml method might be computationally too expensive for the intended ml application. Nevertheless, its σύνολο ελέγχου error can still serve as a baseline. Another, somewhat more principled, approach to constructing a baseline is via a πιθανοτικό μοντέλο. In many cases, given a πιθανοτικό μοντέλο  $p(\mathbf{x}, y)$ , we can precisely determine the ελάχιστο achievable διακινδύνευση among any hypotheses (not even required to belong to the χώρος υποθέσεων  $\mathcal{H}$ ) [40].

This ελάχιστο achievable διακινδύνευση (referred to as the διακινδύνευση Bayes) is the διακινδύνευση of the εκτιμήτρια Bayes for the ετικέτα  $y$  of a data point, given its features  $\mathbf{x}$ . Note that, for a given choice of συνάρτηση απώλειας, the εκτιμήτρια Bayes (if it exists) is completely determined by the κατανομή πιθανότητας  $p(\mathbf{x}, y)$  [40, Ch. 4]. However,

computing the εκτιμήτρια Bayes and διακινδύνευση Bayes presents two main challenges. First, the κατανομή πιθανότητας  $p(\mathbf{x}, y)$  is unknown and must be estimated from observed data. Second, even if  $p(\mathbf{x}, y)$  were known, computing the διακινδύνευση Bayes exactly may be computationally infeasible [41]. A widely used πιθανοτικό μοντέλο is the πολυμεταβλητή κανονική κατανομή  $(\mathbf{x}, y) \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  for data points characterized by numeric features and ετικέτας. Here, for the απώλεια τετραγωνικού σφάλματος, the εκτιμήτρια Bayes is given by the posterior μέση τιμή  $\mu_{y|\mathbf{x}}$  of the ετικέτα  $y$ , given the features  $\mathbf{x}$  [40], [18]. The corresponding διακινδύνευση Bayes is given by the posterior διακύμανση  $\sigma_{y|\mathbf{x}}^2$  (see Fig. 15).




Fig. 15. If the features and the ετικέτα of a data point are drawn from a πολυμεταβλητή κανονική κατανομή, we can achieve the ελάχιστο διακινδύνευση (under απώλεια τετραγωνικού σφάλματος) by using the εκτιμήτρια Bayes  $\mu_{y|\mathbf{x}}$  to predict the ετικέτα  $y$  of a data point with features  $\mathbf{x}$ . The corresponding ελάχιστο διακινδύνευση is given by the posterior διακύμανση  $\sigma_{y|\mathbf{x}}^2$ . We can use this quantity as a baseline for the average loss of a trained model  $\hat{h}$ .

Βλέπε επίσης: ml, υπόθεση, model, loss, σύνολο ελέγχου, data, πιθανοτικό μοντέλο, ελάχιστο, διακινδύνευση, χώρος υποθέσεων, διακινδύνευση

ση Bayes, εκτιμήτρια Bayes, ετικέτα, data point, feature, συνάρτηση απώλειας, κατανομή πιθανότητας, πολυμεταβλητή κανονική κατανομή, απώλεια τετραγωνικού σφάλματος, μέση τιμή, διαχύμανση.

**βήμα κλίσης** Given a παραγωγίσιμη real-valued συνάρτηση  $f(\cdot) : \mathbb{R}^d \rightarrow \mathbb{R}$  and a διάνυσμα  $\mathbf{w} \in \mathbb{R}^d$ , the gradient step updates  $\mathbf{w}$  by adding the scaled negative gradient  $\nabla f(\mathbf{w})$  to obtain the new διάνυσμα (see Fig. 16)

$$\hat{\mathbf{w}} := \mathbf{w} - \eta \nabla f(\mathbf{w}). \quad (2)$$

Mathematically, the gradient step is an operator  $\mathcal{T}^{(f,\eta)}$  that is parametrized by the συνάρτηση  $f$  and the μέγεθος βήματος  $\eta$ .




Fig. 16. The basic gradient step (2) maps a given διάνυσμα  $\mathbf{w}$  to the updated διάνυσμα  $\mathbf{w}'$ . It defines an operator  $\mathcal{T}^{(f,\eta)}(\cdot) : \mathbb{R}^d \rightarrow \mathbb{R}^d : \mathbf{w} \mapsto \hat{\mathbf{w}}$ .

Note that the gradient step (2) optimizes locally—in a neighborhood whose size is determined by the μέγεθος βήματος  $\eta$ —a linear approximation to the συνάρτηση  $f(\cdot)$ . A natural γενίκευση of (2) is to locally optimize the συνάρτηση itself—instead of its linear approximation—such

that

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}' \in \mathbb{R}^d} f(\mathbf{w}') + \frac{1}{\eta} \|\mathbf{w} - \mathbf{w}'\|_2^2. \quad (3)$$

We intentionally use the same symbol  $\eta$  for the παράμετρος in (3) as we used for the μέγεθος βήματος in (2). The larger the  $\eta$  we choose in (3), the more progress the update will make toward reducing the συνάρτηση value  $f(\hat{\mathbf{w}})$ . Note that, much like the gradient step (2), the update (3) also defines an operator that is parametrized by the συνάρτηση  $f(\cdot)$  and the ρυθμός μάθησης  $\eta$ . For a convex συνάρτηση  $f(\cdot)$ , this operator is known as the τελεστής εγγύτητας of  $f(\cdot)$  [42].

Βλέπε επίσης: παραγωγίσιμη, συνάρτηση, διάνυσμα, gradient, μέγεθος βήματος, neighborhood, γενίκευση, παράμετρος, ρυθμός μάθησης, convex, τελεστής εγγύτητας.

**γεγονός** Θεωρούμε μία τυχαία μεταβλητή  $\mathbf{x}$ , ορισμένη σε κάποιον χώρο πιθανοτήτων  $\mathcal{P}$ , η οποία παίρνει τιμές σε έναν μετρήσιμο χώρο  $\mathcal{X}$ . Ένα γεγονός  $\mathcal{A} \subseteq \mathcal{X}$  είναι ένα υποσύνολο του  $\mathcal{X}$ , έτσι ώστε η πιθανότητα  $\mathbb{P}(\mathbf{x} \in \mathcal{A})$  είναι καλά ορισμένη. Με άλλα λόγια, η προεικόνα  $\mathbf{x}^{-1}(\mathcal{A})$  ενός γεγονότος ανήκει στη  $\sigma$ -άλγεβρα του  $\mathcal{P}$ .

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μετρήσιμο, probability, προεικόνα, data point, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, πιθανοτικό μοντέλο.

**γείτονες** Οι γείτονες ενός κόμβου  $i \in \mathcal{V}$  εντός ενός δικτύου ομοσπονδιακής μάθησης είναι εκείνοι οι κόμβοι  $i' \in \mathcal{V} \setminus \{i\}$  που συνδέονται (μέσω μίας ακμής) με τον κόμβο  $i$ .

Βλέπε επίσης: δίκτυο ομοσπονδιακής μάθησης.

**γειτονιά** Η γειτονιά ενός κόμβου  $i \in \mathcal{V}$  είναι το υποσύνολο κόμβων που αποτελούνται από τους γείτονες του  $i$ .

Βλέπε επίσης: γείτονες.

**γενικευμένη ολική μεταβολή** Η γενικευμένη ολική μεταβολή (generalized total variation - GTV) είναι ένα μέτρο της μεταβολής των εκπαιδευμένων τοπικών μοντέλων  $h^{(i)}$  (ή των παραμέτρων του μοντέλου τους  $\mathbf{w}^{(i)}$ ) που αποδίδονται στους κόμβους  $i = 1, \dots, n$  ενός μη κατευθυνόμενου σταθμισμένου γράφου  $\mathcal{G}$  με ακμές  $\mathcal{E}$ . Δεδομένου ενός μέτρου  $d^{(h,h')}$  για την απόκλιση μεταξύ maps υπόθεσης  $h, h'$ , η γενικευμένη ολική μεταβολή είναι

$$\sum_{\{i,i'\} \in \mathcal{E}} A_{i,i'} d^{(h^{(i)}, h^{(i')})}.$$

Εδώ,  $A_{i,i'} > 0$  δηλώνει το βάρος της μη κατευθυνόμενης ακμής  $\{i, i'\} \in \mathcal{E}$ .

Βλέπε επίσης: local model, παράμετροι μοντέλου, graph, απόκλιση, υπόθεση, map.

**γενίκευση** Generalization refers to the ability of a model trained on a σύνολο εκπαίδευσης to make accurate πρόβλεψης on new unseen data points. This is a central goal of ml and TN, i.e., to learn patterns that extend beyond the σύνολο εκπαίδευσης. Most ml systems use ελαχιστοποίηση εμπειρικής διακινδύνευσης to learn a υπόθεση  $\hat{h} \in \mathcal{H}$  by minimizing the average loss over a σύνολο εκπαίδευσης of data points  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ , denoted by  $\mathcal{D}^{(\text{train})}$ . However, success on the σύνολο εκπαίδευσης does not guarantee success on unseen data—this discrepancy is the challenge

of generalization.

To study generalization mathematically, we need to formalize the notion of “unseen” data. A widely used approach is to assume a πιθανοτικό μοντέλο for data generation, such as the παραδοχή ανεξάρτητων και ταυτόσημα κατανομών. Here, we interpret data points as independent τυχαία μεταβλητές with an identical κατανομή πιθανότητας  $p(\mathbf{z})$ . This κατανομή πιθανότητας, which is assumed fixed but unknown, allows us to define the διακινδύνευση of a trained model  $\hat{h}$  as the expected loss

$$\bar{L}(\hat{h}) = \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} \{L(\hat{h}, \mathbf{z})\}.$$

The difference between διακινδύνευση  $\bar{L}(\hat{h})$  and empirical risk  $\hat{L}(\hat{h}|\mathcal{D}^{(\text{train})})$  is known as the generalization gap. Tools from probability theory, such as concentration inequalitys and uniform σύγκλιση, allow us to bound this gap under certain conditions [20].

Generalization without probability: Probability theory is one way to study how well a model generalizes beyond the σύνολο εκπαίδευσης, but it is not the only way. Another option is to use simple deterministic changes to the data points in the σύνολο εκπαίδευσης. The basic idea is that a good model  $\hat{h}$  should be robust, i.e., its πρόβλεψη  $\hat{h}(\mathbf{x})$  should not change much if we slightly change the features  $\mathbf{x}$  of a data point  $\mathbf{z}$ . For example, an object detector trained on smartphone photos should still detect the object if a few random pixels are masked [43]. Similarly, it should deliver the same result if we rotate the object in the image [44]. See Fig. 17 for a visual illustration.




Fig. 17. Two data points  $\mathbf{z}^{(1)}, \mathbf{z}^{(2)}$  that are used as a σύνολο εκπαίδευσης to learn a υπόθεση  $\hat{h}$  via ελαχιστοποίηση εμπειρικής διακινδύνευσης. We can evaluate  $\hat{h}$  outside  $\mathcal{D}^{(\text{train})}$  either by an παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων with some underlying κατανομή πιθανότητας  $p(\mathbf{z})$  or by perturbing the data points.

Βλέπε επίσης: model, σύνολο εκπαίδευσης, πρόβλεψη, data point, ml, TN, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, loss, data, πιθανοτικό μοντέλο, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, τυχαία μεταβλητή, κατανομή πιθανότητας, διακινδύνευση, empirical risk, generalization gap, probability, concentration inequality, σύγκλιση, feature, υπερπροσαρμογή, επικύρωση.

#### γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ) Ο

ΓΚΠΔ (general data protection regulation - GDPR) θεσπίστηκε από την ΕΕ και τέθηκε σε ισχύ από τις 25 Μαΐου 2018 [36]. Διαφυλάσσει την ιδιωτικότητα και τα δικαιώματα δεδομένων των ατόμων στην ΕΕ. Ο ΓΚΠΔ έχει σημαντικές επιπτώσεις για το πώς συλλέγονται δεδομένα, πώς αποθηκεύονται, και πώς χρησιμοποιούνται στις εφαρμογές μηχανικής μάθησης. Βασικές διατάξεις περιλαμβάνουν τα εξής:



- Αρχή της ελαχιστοποίησης των δεδομένων: Τα συστήματα μηχανικής μάθησης θα πρέπει να χρησιμοποιούν μόνο την απαραίτητη ποσότητα προσωπικών δεδομένων για τον σκοπό τους.
- Διαφάνεια και εξηγησιμότητα: Τα συστήματα μηχανικής μάθησης θα πρέπει να επιτρέπουν στους χρήστες τους να κατανοούν πώς τα συστήματα παίρνουν αποφάσεις που επηρεάζουν τους χρήστες.
- Δικαιώματα των υποκειμένων των δεδομένων: Οι χρήστες θα πρέπει να έχουν την ευκαιρία να έχουν πρόσβαση, να διορθώνουν, και να διαγράφουν τα προσωπικά τους δεδομένα, καθώς και να αντιτίθενται στην αυτοματοποιημένη λήψη αποφάσεων και στην κατάρτιση προφίλ.
- Λογοδοσία: Οι οργανισμοί πρέπει να εξασφαλίζουν την εύρωστη ασφάλεια δεδομένων και να αποδεικνύουν συμμόρφωση μέσω τεκμηρίων και τακτικών ελέγχων.

Βλέπε επίσης: data, ml, data minimization principle, transparency, εξηγησιμότητα.

**γινόμενο Kronecker** Το γινόμενο Kronecker (Kronecker product) δύο πινάκων  $\mathbf{A} \in \mathbb{R}^{m \times n}$  και  $\mathbf{B} \in \mathbb{R}^{p \times q}$  είναι ένας σύνθετος πίνακας που δηλώνεται με  $\mathbf{A} \otimes \mathbf{B}$  και ορίζεται ως [3], [12]

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}\mathbf{B} & \cdots & a_{1n}\mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{B} & \cdots & a_{mn}\mathbf{B} \end{bmatrix} \in \mathbb{R}^{mp \times nq}.$$

Το γινόμενο Kronecker είναι μία ειδική περίπτωση του τανυστικού γινόμε-

νου για πίνακες και χρησιμοποιείται ευρέως στην πολυμεταβλητή στατιστική, στη γραμμική άλγεβρα, και σε δομημένα μοντέλα μηχανικής μάθησης. Ικανοποιεί το ταυτοτικό στοιχείο  $(\mathbf{A} \otimes \mathbf{B})(\mathbf{x} \otimes \mathbf{y}) = (\mathbf{A}\mathbf{x}) \otimes (\mathbf{B}\mathbf{y})$  για διανύσματα  $\mathbf{x}$  και  $\mathbf{y}$  συμβατών διαστάσεων.

Βλέπε επίσης: πίνακας, ml, model, διάνυσμα.

**γραμμική παλινδρόμηση** Η γραμμική παλινδρόμηση στοχεύει να μάθει μία γραμμική map υπόθεσης για να προβλέψει μία αριθμητική ετικέτα με βάση τα αριθμητικά χαρακτηριστικά ενός σημείου δεδομένων. Η ποιότητα μίας γραμμικής map υπόθεσης μετράται χρησιμοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που προκαλείται σε ένα σύνολο σημείων δεδομένων με ετικέτες, στο οποίο αναφερόμαστε ως το σύνολο εκπαίδευσης. Βλέπε επίσης: regression, υπόθεση, map, ετικέτα, feature, data point, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

**γραμμικό μοντέλο** Consider an ml application involving data points, each represented by a numeric διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$ . A linear model defines a χώρος υποθέσεων consisting of all real-valued linear maps from  $\mathbb{R}^d$  to  $\mathbb{R}$  such that

$$\mathcal{H}^{(d)} := \{h : \mathbb{R}^d \rightarrow \mathbb{R} \mid h(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} \text{ for some } \mathbf{w} \in \mathbb{R}^d\}.$$

Each value of  $d$  defines a different χώρος υποθέσεων, corresponding to the number of features used to compute the πρόβλεψη  $h(\mathbf{x})$ . The choice of  $d$  is often guided not only by υπολογιστικές διαστάσεις (e.g., fewer features reduce computation) and στατιστικές διαστάσεις (e.g.,

more features typically reduce μεροληψία and διακινδύνευση), but also by ερμηνευσιμότητα. A linear model using a small number of well-chosen features is generally considered more interpretable [45], [46]. The linear model is attractive because it can typically be trained using scalable convex μέθοδος βελτιστοποίησης [47], [14]. Moreover, linear models often permit rigorous statistical analysis, including fundamental limits on the ελάχιστο achievable διακινδύνευση [48]. They are also useful for analyzing more complex nonlinear models such as TNΔs. For instance, a βαθύ δίκτυο can be viewed as the composition of a χάρτης χαρακτηριστικών—implemented by the input and hidden στρώμας—and a linear model in the output στρώμα. Similarly, a decision tree can be interpreted as applying a one-hot-encoded χάρτης χαρακτηριστικών based on περιοχή αποφάσεων, followed by a linear model that assigns a πρόβλεψη to each region. More generally, any trained model  $\hat{h} \in \mathcal{H}$  that is παραγωγίσιμη at some  $\mathbf{x}'$  can be locally approximated by a linear map  $g(\mathbf{x})$ . Fig. 18 illustrates such a local linear approximation, defined by the gradient  $\nabla \hat{h}(\mathbf{x}')$ . Note that the gradient is only defined where  $\hat{h}$  is παραγωγίσιμη. To ensure ευρωστία in the context of αξιόπιστη TN, one may prefer models whose associated map  $\hat{h}$  is Lipschitz continuous. A classic result in mathematical analysis—Rademacher’s Theorem—states that if  $\hat{h}$  is Lipschitz continuous with some constant  $L$  over an open set  $\Omega \subseteq \mathbb{R}^d$ , then  $\hat{h}$  is παραγωγίσιμη almost everywhere in  $\Omega$  [49, Th. 3.1].




Fig. 18. A trained model  $\hat{h}(\mathbf{x})$  that is παραγωγίσιμη at a point  $\mathbf{x}'$  can be locally approximated by a linear map  $g \in \mathcal{H}^{(d)}$ . This local approximation is determined by the gradient  $\nabla \hat{h}(\mathbf{x}')$ .

Βλέπε επίσης: ml, data point, διάνυσμα χαρακτηριστικών, model, χώρος υποθέσεων, linear map, feature, πρόβλεψη, υπολογιστικές διαστάσεις, στατιστικές διαστάσεις, μεροληψία, διακινδύνευση, ερμηνευσιμότητα, convex, μέθοδος βελτιστοποίησης, ελάχιστο, TNΔ, βαθύ δίκτυο, χάρτης χαρακτηριστικών, στρώμα, decision tree, περιοχή αποφάσεων, παραγωγίσιμη, gradient, ευρωστία, αξιόπιστη TN, map, LIME.

**γραμμικός ταξινομητής** Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά χαρακτηριστικά  $\mathbf{x} \in \mathbb{R}^d$  και μία ετικέτα  $y \in \mathcal{Y}$  από κάποιον πεπερασμένο χώρο ετικετών  $\mathcal{Y}$ . Ένας γραμμικός ταξινομητής χαρακτηρίζεται από το γεγονός ότι έχει περιοχές αποφάσεων που διαχωρίζονται από υπερεπίπεδα στο  $\mathbb{R}^d$  [8, Κεφ. 2].

Βλέπε επίσης: data point, feature, ετικέτα, χώρος ετικετών, ταξινομητής, περιοχή αποφάσεων.

**γράφος** Ένας γράφος  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  είναι ένα ζεύγος που αποτελείται από ένα σύνολο κόμβων  $\mathcal{V}$  και ένα σύνολο ακμών  $\mathcal{E}$ . Στην πιο γενική του μορφή, ένας γράφος προσδιορίζεται από μία map που αποδίδει σε κάθε ακμή

$e \in \mathcal{E}$  ένα ζεύγος κόμβων [50]. Μία σημαντική οικογένεια γράφων είναι οι απλοί μη κατευθυνόμενοι γράφοι. Ένας απλός μη κατευθυνόμενος γράφος προκύπτει από την ταυτοποίηση κάθε ακμής  $e \in \mathcal{E}$  με δύο διαφορετικούς κόμβους  $\{i, i'\}$ . Οι σταθμισμένοι γράφοι προσδιορίζουν επίσης αριθμητικά βάρη  $A_e$  για κάθε ακμή  $e \in \mathcal{E}$ .

Βλέπε επίσης: map, βάρη.

**γράφος ομοιότητας** Κάποιες εφαρμογές μηχανικής μάθησης παράγουν σημεία δεδομένων που σχετίζονται μέσω μίας έννοιας ομοιότητας που εξαρτάται από το πεδίο. Αυτές οι ομοιότητες μπορούν να αναπαρασταθούν με ευκολία χρησιμοποιώντας έναν γράφο ομοιότητας  $\mathcal{G} = (\mathcal{V} := \{1, \dots, m\}, \mathcal{E})$ . Ο κόμβος  $r \in \mathcal{V}$  αντιπροσωπεύει το  $r$ στό σημείο δεδομένων. Δύο κόμβοι συνδέονται με μία μη κατευθυνόμενη ακμή αν τα αντίστοιχα σημεία δεδομένων είναι όμοια.

Βλέπε επίσης: ml, data point, graph.

**δεδομένα** Τα δεδομένα αναφέρονται σε αντικείμενα που φέρουν πληροφορίες. Αυτά τα αντικείμενα μπορεί να είναι συγκεκριμένα φυσικά αντικείμενα (όπως άνθρωποι ή ζώα) ή αφηρημένες έννοιες (όπως αριθμοί). Συχνά χρησιμοποιούμε αναπαραστάσεις (ή προσεγγίσεις) των αρχικών δεδομένων που είναι πιο βολικές για την επεξεργασία των δεδομένων. Αυτές οι προσεγγίσεις χρησιμοποιούν διαφορετικές μαθηματικές δομές όπως σχέσεις που χρησιμοποιούνται σε σχεσιακές βάσεις δεδομένων [51], [52]

Βλέπε επίσης: model, σύνολο δεδομένων, data point.

**δείγμα** Μία πεπερασμένη ακολουθία (ή λίστα) σημείων δεδομένων  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$  που προκύπτει ή ερμηνεύεται ως η πραγμάτωση  $m$  ανε-

ξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας  $p(\mathbf{z})$ . Το μήκος  $m$  της ακολουθίας αναφέρεται ως το μέγεθος δείγματος.

Βλέπε επίσης: data point, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, μέγεθος δείγματος.

**δειγματικός χώρος** Ένας δειγματικός χώρος είναι το σύνολο όλων των πιθανών αποτελεσμάτων ενός τυχαίου πειράματος [6], [7], [19], [53].

Βλέπε επίσης: δείγμα, τυχαίο πείραμα, χώρος πιθανοτήτων.

**δέντρο αποφάσεων** A decision tree is a flowchart-like representation of a υπόθεση map  $h$ . More formally, a decision tree is a directed graph containing a root node that reads in the διάνυσμα χαρακτηριστικών  $\mathbf{x}$  of a data point. The root node then forwards the data point to one of its child nodes based on some elementary test on the features  $\mathbf{x}$ . If the receiving child node is not a leaf node, i.e., it has child nodes itself, it represents another test. Based on the test result, the data point is forwarded to one of its descendants. This testing and forwarding of the data point is continued until the data point ends up in a leaf node without any children. See Fig. 19 for visual illustrations.




Fig. 19. (a) A decision tree is a flowchart-like representation of a piecewise constant υπόθεση  $h : \mathcal{X} \rightarrow \mathbb{R}$ . Each piece is a περιοχή αποφάσεων  $\mathcal{R}_{\hat{y}} := \{\mathbf{x} \in \mathcal{X} : h(\mathbf{x}) = \hat{y}\}$ . The depicted decision tree can be applied to numeric διάνυσμα χαρακτηριστικών, i.e.,  $\mathcal{X} \subseteq \mathbb{R}^d$ . It is parametrized by the threshold  $\varepsilon > 0$  and the διάνυσμα  $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$ . (b) A decision tree partitions the χώρος χαρακτηριστικών  $\mathcal{X}$  into περιοχή αποφάσεων. Each περιοχή αποφάσεων  $\mathcal{R}_{\hat{y}} \subseteq \mathcal{X}$  corresponds to a specific leaf node in the decision tree.


Βλέπε επίσης: υπόθεση, map, graph, διάνυσμα χαρακτηριστικών, data point, feature, περιοχή αποφάσεων, διάνυσμα, χώρος χαρακτηριστικών.

**δέσμη** Στο πλαίσιο της στοχαστικής καθόδου κλίσης, μία δέσμη αναφέρεται σε ένα τυχαία επιλεγμένο υποσύνολο του γενικού συνόλου εκπαίδευσης. Χρησιμοποιούμε τα σημεία δεδομένων σε αυτό το υποσύνολο για να εκτιμήσουμε την κλίση του σφάλματος εκπαίδευσης και στη συνέχεια να ενημερώσουμε τις παραμέτρους του μοντέλου.

Βλέπε επίσης: στοχαστική κάθοδος κλίσης, σύνολο εκπαίδευσης, data point, gradient, training error, παράμετροι μοντέλου.

**διάγραμμα διασποράς** Μία τεχνική οπτικοποίησης που απεικονίζει σημεία δεδομένων χρησιμοποιώντας σημεία σε ένα 2-D επίπεδο. Το Σχ. 20

απεικονίζει ένα παράδειγμα ενός διαγράμματος διασποράς.



Σχ. 20. Ένα διάγραμμα διασποράς κάποιων σημείων δεδομένων που αντιπροσωπεύουν καθημερινές καιρικές συνθήκες στη Φινλανδία. Κάθε σημείο δεδομένων χαρακτηρίζεται από την ελάχιστη θερμοκρασία της ημέρας  $x$  ως το χαρακτηριστικό του και τη μέγιστη θερμοκρασία της ημέρας  $y$  ως την ετικέτα του. Οι θερμοκρασίες έχουν μετρηθεί στον σταθμό καιρού του Φινλανδικού Μετεωρολογικού Ινστιτούτου στο Ελσίνκι Καισάνιεμι κατά την περίοδο 1 Σεπτεμβρίου 2024—28 Οκτωβρίου 2024.

Ένα διάγραμμα διασποράς μπορεί να επιτρέψει τον οπτικό έλεγχο σημείων δεδομένων που αναπαριστώνται φυσικά από διανύσματα χαρακτηριστικών σε χώρους υψηλής διάστασης.

Βλέπε επίσης: data point, ελάχιστο, feature, maximum, ετικέτα, Φινλανδικό Μετεωρολογικό Ινστιτούτο, διάνυσμα χαρακτηριστικών, μείωση της διαστασιμότητας.

**διακινδύνευση** Θεωρούμε μία υπόθεση  $h$  που χρησιμοποιείται για να προβλεφθεί η ετικέτα  $y$  ενός σημείου δεδομένων βάσει των χαρακτηριστικών  $\mathbf{x}$ . Μετράμε την ποιότητα μίας συγκεκριμένης πρόβλεψης χρησιμοποιώντας μία συνάρτηση απώλειας  $L((\mathbf{x}, y), h)$ . Αν ερμηνεύσουμε τα σημεία δεδομένων ως τις πραγματώσεις ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών, τότε και η  $L((\mathbf{x}, y), h)$  γίνεται η πραγμάτωση μίας



τυχαίας μεταβλητής. Η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων μας επιτρέπει να ορίσουμε τη διακινδύνευση μίας υπόθεσης ως την αναμενόμενη απώλεια  $\mathbb{E}\{L((\mathbf{x}, y), h)\}$ . Σημείωση ότι η διακινδύνευση της  $h$  εξαρτάται τόσο από την συγκεκριμένη επιλογή για την συνάρτηση απώλειας όσο και από την κατανομή πιθανότητας των σημείων δεδομένων. Βλέπε επίσης: υπόθεση, ετικέτα, data point, feature, πρόβλεψη, συνάρτηση απώλειας, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαία μεταβλητή, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, loss, κατανομή πιθανότητας.

**διακινδύνευση Bayes** Θεωρούμε ένα πιθανοτικό μοντέλο με μία κοινή κατανομή πιθανότητας  $p(\mathbf{x}, y)$  για τα χαρακτηριστικά  $\mathbf{x}$  και την ετικέτα  $y$  ενός σημείου δεδομένων. Η διακινδύνευση Bayes (Bayes risk) είναι η ελάχιστη πιθανή διακινδύνευση που μπορεί να επιτευχθεί από οποιαδήποτε υπόθεση  $h : \mathcal{X} \rightarrow \mathcal{Y}$ . Οποιαδήποτε υπόθεση που επιτυγχάνει τη διακινδύνευση Bayes αναφέρεται ως μία εκτιμήτρια Bayes [40].

Βλέπε επίσης: πιθανοτικό μοντέλο, κατανομή πιθανότητας, feature, ετικέτα, data point, διακινδύνευση, ελάχιστο, υπόθεση, εκτιμήτρια Bayes.

**διακύμανση** Η διακύμανση μίας τυχαίας μεταβλητής πραγματικής τιμής  $x$  ορίζεται ως η προσδοκία  $\mathbb{E}\{(x - \mathbb{E}\{x\})^2\}$  της τετραγωνικής διαφοράς μεταξύ της  $x$  και της προσδοκίας της  $\mathbb{E}\{x\}$ . Επεκτείνουμε αυτόν τον ορισμό σε τυχαίες μεταβλητές διανυσματικής τιμής  $\mathbf{x}$  ως  $\mathbb{E}\{\|\mathbf{x} - \mathbb{E}\{\mathbf{x}\}\|_2^2\}$ . Βλέπε επίσης: τυχαία μεταβλητή, expectation, διάνυσμα.

**διάνυσμα χαρακτηριστικών** Το διάνυσμα χαρακτηριστικών αναφέρεται σε ένα διάνυσμα  $\mathbf{x} = (x_1, \dots, x_d)^T$  του οποίου οι καταχωρίσεις είναι

ξεχωριστά χαρακτηριστικά  $x_1, \dots, x_d$ . Πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν διανύσματα χαρακτηριστικών που ανήκουν σε κάποιον Ευκλείδειο χώρο  $\mathbb{R}^d$  πεπερασμένης διάστασης. Για κάποιες μεθόδους μηχανικής μάθησης, ωστόσο, μπορεί να είναι πιο βολικό να δουλεύουμε με διανύσματα χαρακτηριστικών που ανήκουν σε έναν διανυσματικό χώρο άπειρης διάστασης (π.χ. βλέπε kernel method).

Βλέπε επίσης: feature, διάνυσμα, ml, Ευκλείδειος χώρος, διανυσματικός χώρος.

**διαρροή ιδιωτικότητας** Θεωρούμε μία εφαρμογή μηχανικής μάθησης που επεξεργάζεται ένα σύνολο δεδομένων  $\mathcal{D}$  και δίνει κάποια έξοδο, όπως οι προβλέψεις που προκύπτουν για νέα σημεία δεδομένων. Διαρροή ιδιωτικότητας ανακύπτει αν η έξοδος φέρει πληροφορίες σχετικά με ένα ιδιωτικό (ή ευαίσθητο) χαρακτηριστικό ενός σημείου δεδομένων του  $\mathcal{D}$  (όπως έναν άνθρωπο). Με βάση ένα πιθανοτικό μοντέλο για την παραγωγή δεδομένων, μπορούμε να μετρήσουμε τη διαρροή ιδιωτικότητας μέσω των αμοιβαίων πληροφοριών μεταξύ της εξόδου και του ευαίσθητου χαρακτηριστικού. Ένα άλλο ποιοτικό μέτρο διαρροής ιδιωτικότητας είναι η διαφορική ιδιωτικότητα. Οι σχέσεις μεταξύ διαφορετικών μέτρων διαρροής ιδιωτικότητας έχουν μελετηθεί στη βιβλιογραφία (βλέπε [54]).

Βλέπε επίσης: ml, σύνολο δεδομένων, πρόβλεψη, data point, feature, πιθανοτικό μοντέλο, data, αμοιβαίες πληροφορίες, διαφορική ιδιωτικότητα, επίθεση της ιδιωτικότητας, γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ).

**διάσταση Vapnik–Chervonenkis** The statistical properties of an ελαχι-

στοποίηση εμπειρικής διακινδύνευσης-based method depends critically on the expressive capacity of its χώρος υποθέσεων (or model)  $\mathcal{H}$ . A standard measure of this capacity is the VC dimension (Vapnik–Chervonenkis dimension - VC dimension)  $\text{VCdim}(\mathcal{H})$  [55]. Formally, it is the largest integer  $m$  such that there exists a σύνολο δεδομένων  $\mathcal{D} = \mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \subseteq \mathcal{X}$  that can be perfectly classified (or shattered) by some  $h \in \mathcal{H}$ . In particular, for every one of the  $2^m$  possible assignments of binary ετικέτας to each διάνυσμα χαρακτηριστικών in  $\mathcal{D}$ , there exists some υπόθεση  $h \in \mathcal{H}$  that realizes this labeling. Intuitively, the VC dimension quantifies how well  $\mathcal{H}$  can fit arbitrary ετικέτα assignments, and thus captures its approximate power. It plays a central role in deriving bounds on the generalization gap. Fig. 21 illustrates the definition of the VC dimension for a γραμμικό μοντέλο  $\mathcal{H}^{(2)}$  with  $d = 2$  features. Fig. 21(a) and 21(b) show the same set of three noncollinear διάνυσμα χαρακτηριστικώνs under two different binary labelings. In both cases, a separating hyperplane exists that realizes the labeling. Since this holds for all  $2^3 = 8$  possible binary labelings of the three διάνυσμα χαρακτηριστικώνs, the set is shattered. Fig. 21(c) depicts four διάνυσμα χαρακτηριστικώνs with a specific labeling. No linear separator can correctly classify all data points in this case. Thus,  $\text{VCdim}(\mathcal{H}^{(2)}) = 3$ .




Fig. 21. Illustration of the VC dimension for a γραμμικό μοντέλο  $\mathcal{H}^{(2)}$  that is used to learn a γραμμικός ταξινομητής in the χώρος χαρακτηριστικών  $\mathbb{R}^2$ .

More generally, for a γραμμικό μοντέλο  $\mathcal{H}^{(d)}$ , the VC dimension equals  $d + 1$ . In other words, for γραμμικό μοντέλος, the VC dimension essentially matches the dimension of the underlying χώρος χαρακτηριστικών  $\mathbb{R}^d$ . For more complex χώρος υποθέσεων, such as decision trees or TNΔs, the relation between VC dimension and the dimension of the χώρος χαρακτηριστικών is far less direct. In these cases, alternative complexity measures, such as the Rademacher complexity, can be more useful for analyzing ελαχιστοποίηση εμπειρικής διακινδύνευσης-based methods.

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, χώρος υποθέσεων, model, σύνολο δεδομένων, ετικέτα, διάνυσμα χαρακτηριστικών, υπόθεση, generalization gap, γραμμικό μοντέλο, feature, data point, γραμμικός ταξινομητής, χώρος χαρακτηριστικών, decision tree, TNΔ, Rademacher complexity, γενίκευση, ml, αποτελεσματική διάσταση.

**διασταυρούμενη επικύρωση  $k$ -συνόλων** Η διασταυρούμενη επικύρωση  $k$ -συνόλων ( $k$ -fold cross-validation -  $k$ -fold CV) είναι μία μέθοδος για τη μάθηση και επικύρωση μίας υπόθεσης χρησιμοποιώντας ένα συγκεκριμένο σύνολο δεδομένων. Αυτή η μέθοδος διαιρεί το σύνολο δεδομένων ισότιμα σε  $k$  υποσύνολα και στη συνέχεια εκτελεί  $k$  επαναλήψεις

εκπαίδευσης μοντέλου (π.χ. μέσω της ελαχιστοποίησης εμπειρικής διακινδύνευσης) και επικύρωσης. Κάθε επανάληψη χρησιμοποιεί ένα διαφορετικό υποσύνολο ως το σύνολο επικύρωσης και τα υπόλοιπα  $k - 1$  υποσύνολα ως σύνολο εκπαίδευσης. Η τελική έξοδος είναι ο μέσος όρος των σφαλμάτων επικύρωσης που προκύπτουν από τις  $k$  επαναλήψεις.

Βλέπε επίσης: υπόθεση, σύνολο δεδομένων, model, ελαχιστοποίηση εμπειρικής διακινδύνευσης, επικύρωση, σύνολο επικύρωσης, σύνολο εκπαίδευσης, σφάλμα επικύρωσης.

**δίαυλος ιδιωτικότητας** Ο διάυλος ιδιωτικότητας είναι μία μέθοδος για τη μάθηση φιλικών προς την ιδιωτικότητα χαρακτηριστικών σημείων δεδομένων [56].

Βλέπε επίσης: feature, data point.

**διαφάνεια** Transparency is a fundamental requirement for αξιόπιστη TN [57].

In the context of ml methods, transparency is often used interchangeably with εξηγησιμότητα [58], [59]. However, in the broader scope of TN systems, transparency extends beyond εξηγησιμότητα and includes providing information about the system's limitations, reliability, and intended use. In medical diagnosis systems, transparency requires disclosing the confidence level for the πρόβλεψης delivered by a trained model. In credit scoring, TN-based lending decisions should be accompanied by explanations of contributing factors, such as income level or credit history. These explanations allow humans (e.g., a loan applicant) to understand and contest automated decisions. Some ml methods inherently offer transparency. For example, λογιστική παλινδρόμηση provides

a quantitative measure of ταξινόμηση reliability through the value  $|h(\mathbf{x})|$ . Decision trees are another example, as they allow human-readable decision rules [45]. Transparency also requires a clear indication when a user is engaging with an TN system. For example, TN-powered chatbots should notify users that they are interacting with an automated system rather than a human. Furthermore, transparency encompasses comprehensive documentation detailing the purpose and design choices underlying the TN system. For instance, model datasheets [60] and TN system cards [61] help practitioners understand the intended use cases and limitations of an TN system [62].

Βλέπε επίσης: αξιόπιστη TN, ml, εξηγησιμότητα, TN, πρόβλεψη, model, λογιστική παλινδρόμηση, ταξινόμηση, decision tree.

**διαφορική εντροπία** Για μία τυχαία μεταβλητή πραγματικής τιμής  $\mathbf{x} \in \mathbb{R}^d$  με μία συνάρτηση πυκνότητας πιθανότητας  $p(x)$ , η διαφορική εντροπία ορίζεται ως [28]

$$h(\mathbf{x}) := - \int p(\mathbf{x}) \log p(\mathbf{x}) d\mathbf{x}.$$

Η διαφορική εντροπία μπορεί να είναι αρνητική και στερείται κάποιων ιδιοτήτων εντροπίας για τυχαίες μεταβλητές διακριτής τιμής, όπως της αναλλοιωσιμότητας υπό μία αλλαγή μεταβλητών [28]. Μεταξύ όλων των τυχαίων μεταβλητών με μία δεδομένη μέση τιμή  $\boldsymbol{\mu}$  και πίνακα συνδιακύμανσης  $\boldsymbol{\Sigma}$ , η  $h(\mathbf{x})$  μεγιστοποιείται από  $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ .

Βλέπε επίσης: τυχαία μεταβλητή, συνάρτηση πυκνότητας πιθανότητας, εντροπία, μέση τιμή, πίνακας συνδιακύμανσης, αβεβαιότητα, πιθανοτικό μοντέλο.

**διαφορική ιδιωτικότητα** Consider some ml method  $\mathcal{A}$  that reads in a σύνολο δεδομένων (e.g., the σύνολο εκπαίδευσης used for ελαχιστοποίηση εμπειρικής διακινδύνευσης) and delivers some output  $\mathcal{A}(\mathcal{D})$ . The output could be either the learned παράμετροι μοντέλου or the πρόβλεψη for specific data points. DP (differential privacy; DP) is a precise measure of διαρροή ιδιωτικότητας incurred by revealing the output. Roughly speaking, an ml method is differentially private if the κατανομή πιθανότητας of the output  $\mathcal{A}(\mathcal{D})$  remains largely unchanged if the ευαίσθητο ιδιοχαρακτηριστικό of one data point in the σύνολο εκπαίδευσης is changed. Note that DP builds on a πιθανοτικό μοντέλο for an ml method, i.e., we interpret its output  $\mathcal{A}(\mathcal{D})$  as the πραγμάτωση of an τυχαία μεταβλητή. The randomness in the output can be ensured by intentionally adding the πραγμάτωση of an auxiliary τυχαία μεταβλητή (noise) to the output of the ml method.

Βλέπε επίσης: ml, σύνολο δεδομένων, σύνολο εκπαίδευσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, παράμετροι μοντέλου, πρόβλεψη, data point, διαρροή ιδιωτικότητας, κατανομή πιθανότητας, ευαίσθητο ιδιοχαρακτηριστικό, πιθανοτικό μοντέλο, πραγμάτωση, τυχαία μεταβλητή, επίθεση της ιδιωτικότητας, διάυλος ιδιωτικότητας.

**διεπαφή προγραμματισμού εφαρμογών** An API (application programming interface; API) is a formal mechanism that allows software components to interact in a structured and modular way [63]. In the context of ml, APIs are commonly used to provide access to a trained ml model. Users—whether humans or machines—can submit the διάνυσμα χαρακτηριστικών of a data point and receive a corresponding πρόβλεψη.

Suppose a trained ml model is defined as  $\hat{h}(x) := 2x + 1$ . Through an API, a user can input  $x = 3$  and receive the output  $\hat{h}(3) = 7$  without knowledge of the detailed structure of the ml model or its training. In practice, the model is typically deployed on a server connected to the Internet. Clients send requests containing feature values to the server, which responds with the computed πρόβλεψη  $\hat{h}(\mathbf{x})$ . APIs promote modularity in ml system design, i.e., one team can develop and train the model, while another team handles integration and user interaction. Publishing a trained model via an API also offers practical advantages. For instance, the server can centralize computational resources that are required to compute πρόβλεψης. Furthermore, the internal structure of the model remains hidden—which is useful for protecting intellectual property or trade secrets. However, APIs are not without διακινδύνευση. Techniques such as αντιστροφή μοντέλου can potentially reconstruct a model from its πρόβλεψης using carefully selected διάνυμα χαρακτηριστικών.

Βλέπε επίσης: ml, model, διάνυμα χαρακτηριστικών, data point, πρόβλεψη, feature, αντιστροφή μοντέλου.

**δίκτυο ομοσπονδιακής μάθησης** Ένα δίκτυο ομοσπονδιακής μάθησης (federated learning network - FL network) αποτελείται από έναν μη κατευθυνόμενο σταθμισμένο γράφο  $\mathcal{G}$ . Οι κόμβοι του  $\mathcal{G}$  αντιπροσωπεύουν συσκευές που έχουν πρόσβαση σε ένα τοπικό σύνολο δεδομένων και εκπαιδεύουν ένα τοπικό μοντέλο. Οι ακμές του  $\mathcal{G}$  αντιπροσωπεύουν συνδέσμους επικοινωνίας μεταξύ συσκευών καθώς και στατιστικές ομοιότητες μεταξύ των τοπικών συνόλων δεδομένων τους. Μία προσέγγιση



αρχών για την εκπαίδευση των τοπικών μοντέλων είναι η ελαχιστοποίηση γενικευμένης ολικής μεταβολής. Οι λύσεις της ελαχιστοποίησης γενικευμένης ολικής μεταβολής είναι τοπικοί παράμετροι μοντέλου που αντισταθμίζουν ιδανικά την απώλεια που προκαλείται σε τοπικά σύνολα δεδομένων με την απόκλισή τους μεταξύ των ακμών του  $\mathcal{G}$ .

Βλέπε επίσης: FL, graph, συσκευή, τοπικό σύνολο δεδομένων, local model, ελαχιστοποίηση γενικευμένης ολικής μεταβολής, παράμετροι μοντέλου, loss, απόκλιση.

**εκκίνηση** Για την ανάλυση μεθόδων μηχανικής μάθησης, είναι συχνά χρήσιμο να ερμηνεύουμε ένα συγκεκριμένο σύνολο σημείων δεδομένων  $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$  ως πραγματώσεις ανεξάρτητων και ταυτόσημα κατανομμένων τυχαίων μεταβλητών που εξάγονται από μία κοινή κατανομή πιθανότητας  $p(\mathbf{z})$ . Στην πράξη, η κατανομή πιθανότητας  $p(\mathbf{z})$  είναι άγνωστη και πρέπει να εκτιμηθεί από το  $\mathcal{D}$ . Η προσέγγιση εκκίνησης χρησιμοποιεί το ιστόγραμμα του  $\mathcal{D}$  ως μία εκτιμήτρια για την  $p(\mathbf{z})$ .

Βλέπε επίσης: ml, data point, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, ιστόγραμμα.

**εκτιμήτρια Bayes** Θεωρούμε ένα πιθανοτικό μοντέλο με μία από κοινού κατανομή πιθανότητας  $p(\mathbf{x}, y)$  πάνω στα χαρακτηριστικά  $\mathbf{x}$  και την ετικέτα  $y$  ενός σημείου δεδομένων. Για μία δεδομένη συνάρτηση απώλειας  $L(\cdot, \cdot)$ , αναφερόμαστε σε μία υπόθεση  $h$  ως μία εκτιμήτρια Bayes αν η διακινδύνυσή της  $\mathbb{E}\{L((\mathbf{x}, y), h)\}$  είναι η ελάχιστη επιτεύξιμη διακινδύνυση [40]. Σημείωση ότι το αν μία υπόθεση πληροί τις προϋποθέσεις για να θεωρηθεί εκτιμήτρια Bayes εξαρτάται από την υποκείμενη κατανομή

πιθανότητας και την επιλογή για την συνάρτηση απώλειας  $L(\cdot, \cdot)$ .

Βλέπε επίσης: πιθανοτικό μοντέλο, κατανομή πιθανότητας, feature, ετικέτα, data point, συνάρτηση απώλειας, υπόθεση, διακινδύνευση, ελάχιστο.

**ελάχιστο** Δεδομένου ενός συνόλου πραγματικών αριθμών, το ελάχιστο είναι ο μικρότερος από αυτούς τους αριθμούς. Σημείωση ότι για κάποια σύνολα, όπως το σύνολο αρνητικών πραγματικών αριθμών, το ελάχιστο δεν υφίσταται.

**ελάχιστο άνω φράγμα (ή supremum)** The supremum (supremum or least upper bound) of a set of real numbers is the smallest number that is greater than or equal to every element in the set. More formally, a real number  $a$  is the supremum of a set  $\mathcal{A} \subseteq \mathbb{R}$  if: 1)  $a$  is an upper bound of  $\mathcal{A}$ ; and 2) no number smaller than  $a$  is an upper bound of  $\mathcal{A}$ . Every non-empty set of real numbers that is bounded above has a supremum, even if it does not contain its supremum as an element [2, Sec. 1.4].

**ελαχιστοποίηση γενικευμένης ολικής μεταβολής** Η ελαχιστοποίηση γενικευμένης ολικής μεταβολής (generalized total variation minimization - GTVMin) είναι μία περίπτωση ομαλοποιημένης ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιεί την γενικευμένη ολική μεταβολή τοπικών παραμέτρων μοντέλου ως έναν ομαλοποιητή [64].

Βλέπε επίσης: ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης, γενικευμένη ολική μεταβολή, παράμετροι μοντέλου, ομαλοποιητής.


**ελαχιστοποίηση δομικής διακινδύνευσης** Η ελαχιστοποίηση δομικής διακινδύνευσης (structural risk minimization - SRM) είναι μία περίπτωση

ση ομαλοποιημένης ελαχιστοποίησης εμπειρικής διακινδύνευσης, με την οποία το μοντέλο  $\mathcal{H}$  μπορεί να εκφραστεί ως μία μετρήσιμη ένωση υπομοντέλων:  $\mathcal{H} = \bigcup_{n=1}^{\infty} \mathcal{H}^{(n)}$ . Κάθε υπομοντέλο  $\mathcal{H}^{(n)}$  επιτρέπει την παραγωγή ενός προσεγγιστικού άνω φράγματος στο σφάλμα γενίκευσης που προκαλείται κατά την εφαρμογή ελαχιστοποίησης εμπειρικής διακινδύνευσης για την εκπαίδευση του  $\mathcal{H}^{(n)}$ . Αυτά τα μεμονωμένα φράγματα—ένα για κάθε υπομοντέλο—συνδυάζονται έπειτα για να σχηματίσουν έναν ομαλοποιητή που χρησιμοποιείται στον στόχο ομαλοποιημένης ελαχιστοποίησης εμπειρικής διακινδύνευσης. Αυτά τα προσεγγιστικά άνω φράγματα (ένα για κάθε  $\mathcal{H}^{(n)}$ ) συνδυάζονται στη συνέχεια για να κατασκευάσουν έναν ομαλοποιητή για την ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης [20, Sec. 7.2].

Βλέπε επίσης: ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης, model, γενίκευση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, ομαλοποιητής, διακινδύνευση.

**ελαχιστοποίηση εμπειρικής διακινδύνευσης** Η ελαχιστοποίηση εμπειρικής διακινδύνευσης (empirical risk minimization - ERM) είναι το πρόβλημα βελτιστοποίησης της εύρεσης μίας υπόθεσης  $\hat{h} \in \mathcal{H}$  που προκαλεί την ελάχιστη μέση απώλεια σε ένα συγκεκριμένο σύνολο δεδομένων  $\mathcal{D}$ . Η υπόθεση επιλέγεται από έναν χώρο υποθέσεων (ή μοντέλο)  $\mathcal{H}$ . Το σύνολο δεδομένων  $\mathcal{D}$  αναφέρεται ως σύνολο εκπαίδευσης. Πολλές μέθοδοι μηχανικής μάθησης βασίζονται στην ελαχιστοποίηση εμπειρικής διακινδύνευσης με συγκεκριμένες επιλογές σχεδιασμού για το σύνολο δεδομένων, το μοντέλο, και την απώλεια [8, Κεφ. 3]. Το Σχ. 22 απεικονίζει την ελαχιστοποίηση εμπειρικής διακινδύνευσης για ένα γραμμικό μοντέλο

και σημεία δεδομένων που χαρακτηρίζονται από ένα μοναδικό χαρακτηριστικό  $x$  και μία ετικέτα  $y$ . Η υπόθεση  $h$  είναι μία linear map που προβλέπει την ετικέτα ενός σημείου δεδομένων ως μία γραμμική συνάρτηση του χαρακτηριστικού του  $x$ , δηλαδή  $h(x) = w_1x + w_0$ , όπου  $w_1$  και  $w_0$  είναι οι παράμετροι μοντέλου της υπόθεσης  $h$ . Το πρόβλημα της ελαχιστοποίησης εμπειρικής διακινδύνευσης είναι η εύρεση των παραμέτρων μοντέλου  $w_1$  και  $w_0$  που ελαχιστοποιούν τη μέση απώλεια που προκαλείται από την υπόθεση  $h$  στο σύνολο εκπαίδευσης  $\mathcal{D}$ .



Σχ. 22. Η ελαχιστοποίηση εμπειρικής διακινδύνευσης μαθαίνει μία υπόθεση  $h \in \mathcal{H}$ , από ένα μοντέλο  $\mathcal{H}$ , ελαχιστοποιώντας τη μέση απώλεια (ή εμπειρική διακινδύνευση)  $1/m \sum_{r=1}^m L((\mathbf{x}^{(r)}, y^{(r)}), h)$  που προκαλείται σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$ .

Βλέπε επίσης: optimization problem, υπόθεση, model, ελάχιστο, loss, empirical risk, σύνολο δεδομένων, σύνολο εκπαίδευσης, ml.

**εμπειρική διακινδύνευση** Η εμπειρική διακινδύνευση  $\hat{L}(h|\mathcal{D})$  μίας υπόθεσης σε ένα σύνολο δεδομένων  $\mathcal{D}$  είναι η μέση απώλεια που προκαλείται από την  $h$  όταν εφαρμόζεται στα σημεία δεδομένων του  $\mathcal{D}$ .

Βλέπε επίσης: διακινδύνευση, υπόθεση, σύνολο δεδομένων, loss, data point.

**ενεργοποίηση** Η έξοδος ενός τεχνητού νευρώνα εντός ενός τεχνητού νευρωνικού δικτύου αναφέρεται ως η ενεργοποίησή του. Συγκεκριμένα, η ενεργοποίηση προκύπτει από την εφαρμογή μίας (συνήθως μη γραμμικής) συνάρτησης ενεργοποίησης σε ένα σταθμισμένο άθροισμα των εισόδων του.

Βλέπε επίσης: ΤΝΔ, συνάρτηση ενεργοποίησης, βαθύ δίκτυο.

**εντροπία** Η εντροπία ποσοτικοποιεί την αβεβαιότητα ή τη μη προβλεψιμότητα που σχετίζεται με μία τυχαία μεταβλητή [28]. Για μία διακριτή τυχαία μεταβλητή  $x$  που παίρνει τιμές σε ένα πεπερασμένο σύνολο  $\mathcal{S} = \{x_1, \dots, x_n\}$  με μία συνάρτηση μάζας πιθανότητας  $p_i := \mathbb{P}(x = x_i)$ , η εντροπία ορίζεται ως


$$H(x) := - \sum_{i=1}^n p_i \log p_i.$$

Η εντροπία μεγιστοποιείται όταν όλα τα αποτελέσματα είναι εξίσου πιθανά, και ελαχιστοποιείται (δηλαδή μηδενίζεται) όταν το αποτέλεσμα είναι ντετερμινιστικό. Η γενίκευση της έννοιας της εντροπίας για συνεχείς τυχαίες μεταβλητές είναι η διαφορική εντροπία.

Βλέπε επίσης: αβεβαιότητα, τυχαία μεταβλητή, probability, συνάρτηση, γενίκευση, διαφορική εντροπία, πιθανοτικό μοντέλο.

**εξήγηση** Μία προσέγγιση για να ενισχυθεί η διαφάνεια μίας μεθόδου μηχανικής μάθησης για τον χρήστη της που είναι άνθρωπος είναι να παρέχεται μία εξήγηση μαζί με τις προβλέψεις που παραδίδονται από τη μέθοδο. Οι εξή-

γήσεις μπορούν να πάρουν διαφορετικές μορφές. Για παράδειγμα, μπορεί να αποτελούνται από κείμενο που είναι αναγνώσιμο από άνθρωπο ή ποσοτικούς δείκτες, όπως βαθμοί σημαντικότητας χαρακτηριστικών για τα μεμονωμένα χαρακτηριστικά ενός συγκεκριμένου σημείου δεδομένων [65]. Εναλλακτικά, οι εξηγήσεις μπορεί να είναι οπτικές—για παράδειγμα, maps έντασης που επισημαίνουν περιοχές της εικόνας που ωθούν την πρόβλεψη [66]. Το Σχ. 23 απεικονίζει δύο τύπους εξηγήσεων. Ο πρώτος είναι μία τοπική γραμμική προσέγγιση  $g(\mathbf{x})$  ενός μη γραμμικού εκπαιδευμένου μοντέλου  $\hat{h}(\mathbf{x})$  γύρω από ένα συγκεκριμένο διάνυσμα χαρακτηριστικών  $\mathbf{x}'$ , όπως χρησιμοποιείται στη μέθοδο LIME. Η δεύτερη μορφή εξήγησης που απεικονίζεται στο σχήμα είναι ένα αραιό σύνολο προβλέψεων  $\hat{h}(\mathbf{x}^{(1)}), \hat{h}(\mathbf{x}^{(2)}), \hat{h}(\mathbf{x}^{(3)})$  σε επιλεγμένα διανύσματα χαρακτηριστικών, προσφέροντας συγκεκριμένα σημεία αναφοράς για τον χρήστη.



Σχ. 23. Ένα εκπαιδευμένο μοντέλο  $\hat{h}(\mathbf{x})$  μπορεί να εξηγηθεί τοπικά σε κάποιο σημείο  $\mathbf{x}'$  μέσω μίας γραμμικής προσέγγισης  $g(\mathbf{x})$ . Για μία παραγωγίσιμη  $\hat{h}(\mathbf{x})$ , αυτή η προσέγγιση καθορίζεται από την κλίση  $\nabla \hat{h}(\mathbf{x}')$ . Μία άλλη μορφή εξήγησης θα μπορούσε να είναι οι τιμές της συνάρτησης  $\hat{h}(\mathbf{x}^{(r)})$  για  $r = 1, 2, 3$ .

Βλέπε επίσης: transparency, ml, πρόβλεψη, feature, data point, map, model, διάνυσμα χαρακτηριστικών, LIME, παραγωγίσιμη, gradient, συ-

νάρτηση, ταξινόμηση.

**εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης** Η εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης (explainable empirical risk minimization - EERM) είναι μία περίπτωση ελαχιστοποίησης δομικής διακινδύνευσης που προσθέτει έναν όρο ομαλοποίησης στη μέση απώλεια στην αντικειμενική συνάρτηση της ελαχιστοποίησης εμπειρικής διακινδύνευσης. Ο όρος ομαλοποίησης επιλέγεται ώστε να ευνοούνται maps υπόθεσης που είναι εγγενώς εξηγήσιμοι για έναν συγκεκριμένο χρήστη. Αυτός ο χρήστης χαρακτηρίζεται από τις προβλέψεις του που παρέχονται για τα σημεία δεδομένων σε ένα σύνολο εκπαίδευσης [67].

Βλέπε επίσης: ελαχιστοποίηση δομικής διακινδύνευσης, ομαλοποίηση, loss, αντικειμενική συνάρτηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, map, πρόβλεψη, data point, σύνολο εκπαίδευσης.

**εξηγήσιμη μηχανική μάθηση** Οι μέθοδοι εξηγήσιμης μηχανικής μάθησης (explainable machine learning - XML) στοχεύουν να συμπληρώσουν κάθε πρόβλεψη με μία εξήγηση για το πώς έχει προκύψει η πρόβλεψη. Η κατασκευή μίας ρητής εξήγησης μπορεί να μην είναι απαραίτητη αν η μέθοδος μηχανικής μάθησης χρησιμοποιεί ένα επαρκώς απλό (ή ερμηνεύσιμο) μοντέλο [45].

Βλέπε επίσης: πρόβλεψη, εξήγηση, ml, model.

**εξηγησιμότητα** Ορίζουμε την (υποκειμενική) εξηγησιμότητα μίας μεθόδου μηχανικής μάθησης ως το επίπεδο προσομοιωσιμότητας [68] των προβλέψεων που παραδίδονται από ένα σύστημα μηχανικής μάθησης σε έναν χρήστη που είναι άνθρωπος. Ποσοτικά μέτρα για την (υποκειμενική) εξη-

γρησιμότητα ενός εκπαιδευμένου μοντέλου μπορούν να κατασκευαστούν συγκρίνοντας τις προβλέψεις του με τις προβλέψεις που παρέχονται από έναν χρήστη σε ένα σύνολο ελέγχου [67], [68]. Εναλλακτικά, μπορούμε να χρησιμοποιήσουμε πιθανοτικά μοντέλα για δεδομένα και να μετρήσουμε την εξηγησιμότητα ενός εκπαιδευμένου μοντέλου μηχανικής μάθησης μέσω της υπό συνθήκης (διαφορικής) εντροπίας των προβλέψεών του, δεδομένων των προβλέψεων του χρήστη [58], [69].

Βλέπε επίσης: ml, πρόβλεψη, model, σύνολο ελέγχου, πιθανοτικό μοντέλο, data, εντροπία, αξιόπιστη TN, ομαλοποίηση.

**επαύξηση δεδομένων** Data augmentation methods add synthetic data points to an existing set of data points. These synthetic data points are obtained by perturbations (e.g., adding noise to physical measurements) or transformations (e.g., rotations of images) of the original data points. These perturbations and transformations are such that the resulting synthetic data points should still have the same ετικέτα. As a case in point, a rotated cat image is still a cat image even if their διάνυσμα χαρακτηριστικών (obtained by stacking pixel color intensities) are very different (see Fig. 24). Data augmentation can be an efficient form of ομαλοποίηση.






Fig. 24. Data augmentation exploits intrinsic symmetries of data points in some χώρος χαρακτηριστικών  $\mathcal{X}$ . We can represent a symmetry by an operator  $\mathcal{T}^{(\eta)} : \mathcal{X} \rightarrow \mathcal{X}$ , parametrized by some number  $\eta \in \mathbb{R}$ . For example,  $\mathcal{T}^{(\eta)}$  might represent the effect of rotating a cat image by  $\eta$  degrees. A data point with διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(2)} = \mathcal{T}^{(\eta)}(\mathbf{x}^{(1)})$  must have the same ετικέτα  $y^{(2)} = y^{(1)}$  as a data point with διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(1)}$ .

Βλέπε επίσης: data, data point, ετικέτα, διάνυσμα χαρακτηριστικών, ο-μαλοποίηση, χώρος χαρακτηριστικών.

**επίθεση** Μία επίθεση σε ένα σύστημα μηχανικής μάθησης αναφέρεται σε μία σκόπιμη ενέργεια—είτε ενεργή είτε παθητική—που διακυβεύει την ακεραιότητα, τη διαθεσιμότητα, ή την εμπιστευτικότητα του συστήματος. Οι ενεργές επιθέσεις περιλαμβάνουν τη διαταραχή συνιστωσών όπως των συνόλων δεδομένων (μέσω data poisoning) ή τους συνδέσμους επικοινωνίας μεταξύ συσκευών εντός μίας εφαρμογής μηχανικής μάθησης. Οι παθητικές επιθέσεις, όπως οι επιθέσεις της ιδιωτικότητας, στοχεύουν να συμπεράνουν ευαίσθητα ιδιοχαρακτηριστικά χωρίς να τροποποιήσουν το σύστημα. Ανάλογα με τον στόχο τους, μπορούμε να διακρίνουμε ανάμεσα σε επιθέσεις άρνησης υπηρεσιών, επιθέσεις κερκόπορτας, και επιθέσεις της ιδιωτικότητας.

Βλέπε επίσης: ml, σύνολο δεδομένων, data poisoning, συσκευή, επίθεση της ιδιωτικότητας, ευαίσθητο ιδιοχαρακτηριστικό, επίθεση άρνησης υπηρεσιών, κερκόπορτα.

**επίθεση άρνησης υπηρεσιών** Μία επίθεση άρνησης υπηρεσιών στοχεύει (π.χ. μέσω data poisoning) να κατευθύνει την εκπαίδευση ενός μοντέλου, έτσι ώστε να έχει χαμηλή επίδοση για τυπικά σημεία δεδομένων. Βλέπε επίσης: επίθεση, data poisoning, model, data point.

**επίθεση της ιδιωτικότητας** Μία επίθεση της ιδιωτικότητας σε ένα σύστημα μηχανικής μάθησης στοχεύει να συμπεράνει ευαίσθητα ιδιοχαρακτηριστικά ατόμων εκμεταλλευόμενη μερική πρόσβαση σε ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Μία μορφή επίθεσης της ιδιωτικότητας είναι η αντιστροφή μοντέλου. Βλέπε επίσης: επίθεση, ml, ευαίσθητο ιδιοχαρακτηριστικό, model, αντιστροφή μοντέλου, αξιόπιστη TN, ΓΚΠΔ.

**επικύρωση** Θεωρούμε μία υπόθεση  $\hat{h}$  που έχει μαθευτεί μέσω κάποιας μεθόδου μηχανικής μάθησης, π.χ. λύνοντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$ . Η επικύρωση αναφέρεται στην πρακτική της αξιολόγησης της απώλειας που προκαλείται από την υπόθεση  $\hat{h}$  σε ένα σύνολο σημείων δεδομένων που δεν περιέχονται στο σύνολο εκπαίδευσης  $\mathcal{D}$ . Βλέπε επίσης: υπόθεση, ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, loss, data point.

**επιλογή μοντέλου** Στη μηχανική μάθηση, η επιλογή μοντέλου αναφέρεται στη διαδικασία επιλογής μεταξύ διαφορετικών υποψήφγιων μοντέλων.

Στην πιο βασική της μορφή, η επιλογή μοντέλου ισοδυναμεί με: 1) την εκπαίδευση κάθε υποψήφιου μοντέλου· 2) τον υπολογισμό του σφάλματος επικύρωσης για κάθε εκπαιδευμένο μοντέλο· και 3) την επιλογή του μοντέλου με το μικρότερο σφάλμα επικύρωσης [8, Κεφ. 6].


Βλέπε επίσης: ml, model, σφάλμα επικύρωσης.

**εργασία μάθησης** Consider a σύνολο δεδομένων  $\mathcal{D}$  consisting of

Βλέπε επίσης: σύνολο δεδομένων, data point, feature, ετικέτα, model, συνάρτηση απώλειας, ελαχιστοποίηση εμπειρικής διακινδύνευσης, αντικειμενική συνάρτηση, regression, ταξινόμηση, πιθανοτικό μοντέλο, μάθηση πολυδιεργασίας, χώρος ετικετών.

**ερμηνευσιμότητα** Μία μέθοδος μηχανικής μάθησης είναι ερμηνεύσιμη για έναν χρήστη που είναι άνθρωπος αν μπορεί να κατανοήσει τη διαδικασία απόφασης της μεθόδου. Μία προσέγγιση για την ανάπτυξη ενός ακριβούς ορισμού της ερμηνευσιμότητας είναι μέσω της έννοιας της προσομοιωσιμότητας, δηλαδή τη δυνατότητα ενός ανθρώπου να προσομοιώνει διανοητικά τη συμπεριφορά του μοντέλου [68], [69], [70], [71], [72]. Αυτή η ιδέα έχει ως εξής: Αν ένας χρήστης που είναι άνθρωπος καταλαβαίνει μία μέθοδο μηχανικής μάθησης, τότε θα πρέπει να έχει τη δυνατότητα να αναμένει τις προβλέψεις της σε ένα σύνολο ελέγχου. Παρουσιάζουμε ένα τέτοιο σύνολο ελέγχου στο Σχ. 25, το οποίο επίσης απεικονίζει δύο υποθέσεις  $\hat{h}$  και  $\hat{h}'$  που έχουν μαθευτεί. Η μέθοδος μηχανικής μάθησης που παράγει την υπόθεση  $\hat{h}$  είναι ερμηνεύσιμη στον χρήστη που είναι άνθρωπος και εξοικειωμένος με την έννοια της linear map. Εφόσον η  $\hat{h}$  αντιστοιχεί σε μία linear map, ο χρήστης μπορεί να αναμένει τις προβλέψεις της  $\hat{h}$  στο

σύνολο ελέγχου. Αντίθετα, η μέθοδος μηχανικής μάθησης που παραδίδει την  $\hat{h}'$  δεν είναι ερμηνεύσιμη, επειδή η συμπεριφορά της δεν συμβαδίζει πλέον με τις προσδοκίες του χρήστη.



Σχ. 25. Μπορούμε να αξιολογήσουμε την ερμηνευσιμότητα εκπαιδευμένων μοντέλων  $\hat{h}$  και  $\hat{h}'$  συγκρίνοντας τις προβλέψεις τους με τις ψευδο-ετικέτες που παράγονται από έναν χρήστη που είναι άνθρωπος για το  $D'$ .

Η έννοια της ερμηνευσιμότητας σχετίζεται στενά με την έννοια της εξηγησιμότητας, καθώς και οι δύο στοχεύουν να κάνουν τις μεθόδους μηχανικής μάθησης πιο κατανοητές στους ανθρώπους. Στο πλαίσιο του Σχ. 25, η ερμηνευσιμότητα μίας μεθόδου μηχανικής μάθησης  $\hat{h}$  απαιτεί ο χρήστης που είναι άνθρωπος να μπορεί να αναμένει τις προβλέψεις της σε ένα αυθαίρετο σύνολο ελέγχου. Αυτό ξεχωρίζει σε σχέση με την εξηγησιμότητα, όπου ο χρήστης υποστηρίζεται από εξωτερικές εξηγήσεις—όπως maps υπεροχής ή παραδείγματα αναφοράς από το σύνολο εκπαίδευσης—για να καταλάβει τις προβλέψεις της  $\hat{h}$  σε ένα συγκεκριμένο σύνολο ελέγχου  $D'$ .

Βλέπε επίσης: ml, model, πρόβλεψη, σύνολο ελέγχου, υπόθεση, linear map, expectation, σύνολο εκπαίδευσης, ετικέτα, εξηγησιμότητα, εξήγηση, map, αξιόπιστη TN, ομαλοποίηση, LIME.

**ετικέτα** Ένα υψηλότερου επιπέδου γεγονός ή ποσότητα ενδιαφέροντος που σχετίζεται με ένα σημείο δεδομένων. Για παράδειγμα, αν ένα σημείο δεδομένων είναι μία εικόνα, η ετικέτα θα μπορούσε να υποδεικνύει αν η εικόνα περιέχει μία γάτα ή όχι. Συνώνυμα του όρου ετικέτα, που χρησιμοποιούνται συχνά σε συγκεκριμένους τομείς, περιλαμβάνουν «μεταβλητή απόκρισης,» «μεταβλητή εξόδου,» και «στόχος» [73], [74], [75].

Βλέπε επίσης: data point.

**ευαίσθητο ιδιοχαρακτηριστικό** Η μηχανική μάθηση περιστρέφεται γύρω από τη μάθηση μίας map υπόθεσης που μας επιτρέπει να προβλέψουμε την ετικέτα ενός σημείου δεδομένων από τα χαρακτηριστικά του. Σε κάποιες εφαρμογές, πρέπει να εξασφαλίσουμε ότι η έξοδος που παραδίδεται από ένα σύστημα μηχανικής μάθησης δεν μας επιτρέπει να συμπεράνουμε ευαίσθητα ιδιοχαρακτηριστικά ενός σημείου δεδομένων. Ποιο μέρος ενός σημείου δεδομένων θεωρείται ευαίσθητο ιδιοχαρακτηριστικό είναι μία επιλογή σχεδιασμού που ποικίλλει μεταξύ διαφορετικών τομέων εφαρμογής. Βλέπε επίσης: ml, υπόθεση, map, ετικέτα, data point, feature.

**Ευκλείδειος χώρος** Ο Ευκλείδειος χώρος  $\mathbb{R}^d$  διάστασης  $d \in \mathbb{N}$  αποτελείται από διανύσματα  $\mathbf{x} = (x_1, \dots, x_d)$ , με  $d$  καταχωρίσεις πραγματικής τιμής  $x_1, \dots, x_d \in \mathbb{R}$ . Ένας τέτοιος Ευκλείδειος χώρος είναι εξοπλισμένος με μία γεωμετρική δομή που ορίζεται από το εσωτερικό γινόμενο  $\mathbf{x}^T \mathbf{x}' = \sum_{j=1}^d x_j x'_j$  μεταξύ οποιωνδήποτε δύο διανυσμάτων  $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^d$  [2].

Βλέπε επίσης: διάνυσμα.

**ευρωστία** Η ευρωστία είναι μία βασική απαίτηση για αξιόπιστη τεχνητή νοημοσύνη. Αναφέρεται στην ιδιότητα ενός συστήματος μηχανικής μάθησης να διατηρεί αποδεκτή απόδοση ακόμα και όταν υπόκειται σε διαφορετικές μορφές διαταραχών. Αυτές οι διαταραχές μπορεί να επηρεάσουν τα χαρακτηριστικά ενός σημείου δεδομένων με σκοπό τον χειρισμό της πρόβλεψης που παραδίδεται από ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Η ευρωστία περιλαμβάνει επίσης την ευστάθεια μεθόδων βασισμένων στην ελαχιστοποίηση εμπειρικής διακινδύνευσης απέναντι σε διαταραχές του συνόλου εκπαίδευσης. Τέτοιες διαταραχές μπορεί να συμβούν εντός επιθέσεων data poisoning.

Βλέπε επίσης: αξιόπιστη TN, ml, feature, data point, πρόβλεψη, model, ευστάθεια, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, data poisoning, επίθεση.

**ευστάθεια** Stability is a desirable property of an ml method  $\mathcal{A}$  that maps a σύνολο δεδομένων  $\mathcal{D}$  (e.g., a σύνολο εκπαίδευσης) to an output  $\mathcal{A}(\mathcal{D})$ . The output  $\mathcal{A}(\mathcal{D})$  can be the learned παράμετροι μοντέλου or the πρόβλεψη delivered by the trained model for a specific data point. Intuitively,  $\mathcal{A}$  is stable if small changes in the input σύνολο δεδομένων  $\mathcal{D}$  lead to small changes in the output  $\mathcal{A}(\mathcal{D})$ . Several formal notions of stability exist that enable bounds on the γενίκευση error or διακινδύνευση of the method (see [20, Ch. 13]). To build intuition, consider the three σύνολο δεδομένων depicted in Fig. 26, each of which is equally likely under the same data-generating κατανομή πιθανότητας. Since the opti-

mal παράμετροι μοντέλου are determined by this underlying κατανομή πιθανότητας, an accurate ml method  $\mathcal{A}$  should return the same (or very similar) output  $\mathcal{A}(\mathcal{D})$  for all three σύνολο δεδομένων. In other words, any useful  $\mathcal{A}$  must be robust to variability in δείγμα πραγμάτωσης from the same κατανομή πιθανότητας, i.e., it must be stable.




Fig. 26. Three σύνολο δεδομένων  $\mathcal{D}^{(*)}$ ,  $\mathcal{D}^{(\square)}$ , and  $\mathcal{D}^{(\triangle)}$ , each sampled independently from the same data-generating κατανομή πιθανότητας. A stable ml method should return similar outputs when trained on any of these σύνολο δεδομένων.

Βλέπε επίσης: ml, σύνολο δεδομένων, σύνολο εκπαίδευσης, παράμετροι μοντέλου, πρόβλεψη, model, data point, γενίκευση, διακινδύνευση, data, κατανομή πιθανότητας, δείγμα, πραγμάτωση.

**θετικά ημιορισμένος** Ένας συμμετρικός (πραγματικών τιμών) πίνακας  $\mathbf{Q} = \mathbf{Q}^T \in \mathbb{R}^{d \times d}$  αναφέρεται ως θετικά ημιορισμένος (positive semi-definite - psd) αν  $\mathbf{x}^T \mathbf{Q} \mathbf{x} \geq 0$  για κάθε διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$ . Η ιδιότητά του να είναι θετικά ημιορισμένος μπορεί να επεκταθεί από πίνακες σε συμμετρικές (πραγματικών τιμών) maps πυρήνα  $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  (με

$K(\mathbf{x}, \mathbf{x}') = K(\mathbf{x}', \mathbf{x})$ ) ως εξής: Για οποιοδήποτε πεπερασμένο σύνολο διανυσμάτων χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$ , ο επακόλουθος πίνακας  $\mathbf{Q} \in \mathbb{R}^{m \times m}$  με καταχωρίσεις  $Q_{r,r'} = K(\mathbf{x}^{(r)}, \mathbf{x}^{(r')})$  είναι θετικά ημιορισμένος [76].

Βλέπε επίσης: πίνακας, διάνυσμα, πυρήνας, map, διάνυσμα χαρακτηριστικών.

**ιδιοδιάνυσμα** Ένα ιδιοδιάνυσμα ενός πίνακα  $\mathbf{A} \in \mathbb{R}^{d \times d}$  είναι ένα μη μηδενικό διάνυσμα  $\mathbf{x} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$  τέτοιο ώστε  $\mathbf{Ax} = \lambda \mathbf{x}$  με κάποια ιδιοτιμή  $\lambda$ .


Βλέπε επίσης: πίνακας, διάνυσμα, ιδιοτιμή.

**ιδιοτιμή** Αναφερόμαστε σε έναν αριθμό  $\lambda \in \mathbb{R}$  ως μία ιδιοτιμή ενός τετραγωνικού πίνακα  $\mathbf{A} \in \mathbb{R}^{d \times d}$  αν υπάρχει ένα μη μηδενικό διάνυσμα  $\mathbf{x} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$  τέτοιο ώστε  $\mathbf{Ax} = \lambda \mathbf{x}$ .

Βλέπε επίσης: πίνακας, διάνυσμα.

**ιστόγραμμα** Θεωρούμε ένα σύνολο δεδομένων  $\mathcal{D}$  που αποτελείται από  $m$  σημεία δεδομένων  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ , καθένα από τα οποία ανήκει σε κάποιο κελί  $[-U, U] \times \dots \times [-U, U] \subseteq \mathbb{R}^d$  με πλάγιο μήκος  $U$ . Χωρίζουμε αυτό το κελί ισότιμα σε μικρότερα στοιχειώδη κελιά με πλάγιο μήκος  $\Delta$ . Το ιστόγραμμα του  $\mathcal{D}$  αποδίδει κάθε στοιχειώδες κελί στο αντίστοιχο κλάσμα των σημεία δεδομένων του  $\mathcal{D}$  που εμπίπτουν σε αυτό το στοιχειώδες κελί. Ένα οπτικό παράδειγμα ενός τέτοιου ιστογράμματος παρέχεται στο Σχ. 27.





Σχ. 27. Ένα ιστογράμμο που αναπαριστά τη συχνότητα των σημείων δεδομένων που εμπίπτουν εντός πεδίων διακριτών τιμών (δηλαδή κάδων). Το ύψος κάθε ράβδου δείχνει τον αριθμό των δειγμάτων στο αντίστοιχο διάστημα.

Βλέπε επίσης: σύνολο δεδομένων, data point, δείγμα.

**κάθοδος κλίσης** GD (gradient descent - GD) is an iterative method for finding the ελάχιστο of a παραγωγίσιμη συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ . GD generates a sequence of estimates  $\mathbf{w}^{(0)}, \mathbf{w}^{(1)}, \mathbf{w}^{(2)}, \dots$  that (ideally) converge to a ελάχιστο of  $f$ . At each iteration  $k$ , GD refines the current estimate  $\mathbf{w}^{(k)}$  by taking a step in the direction of the steepest descent of a local linear approximation. This direction is given by the negative gradient  $\nabla f(\mathbf{w}^{(k)})$  of the συνάρτηση  $f$  at the current estimate  $\mathbf{w}^{(k)}$ . The resulting update rule is given by

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \eta \nabla f(\mathbf{w}^{(k)}) \quad (4)$$

where  $\eta > 0$  is a suitably small μέγεθος βήματος. For a suitably choosen

μέγεθος βήματος  $\eta$ , the update typically reduces the συνάρτηση value, i.e.,  $f(\mathbf{w}^{(k+1)}) < f(\mathbf{w}^{(k)})$ . Fig. 28 illustrates a single GD step.




Fig. 28. A single βήμα κλίσης (4) toward the minimizer  $\bar{\mathbf{w}}$  of  $f(\mathbf{w})$ .

Βλέπε επίσης: ελάχιστο, παραγωγίσιμη, συνάρτηση, gradient, μέγεθος βήματος, βήμα κλίσης.

**κάθοδος υποκλίσης** Subgradient descent is a γενίκευση of κάθοδος κλίσης that does not require differentiability of the συνάρτηση to be minimized. This γενίκευση is obtained by replacing the concept of a gradient with that of a subgradient. Similar to gradients, subgradients allow us to construct local approximations of an αντικειμενική συνάρτηση. The αντικειμενική συνάρτηση might be the empirical risk  $\hat{L}(h^{(\mathbf{w})}|\mathcal{D})$  viewed as a συνάρτηση of the παράμετροι μοντέλου  $\mathbf{w}$  that select a υπόθεση  $h^{(\mathbf{w})} \in \mathcal{H}$ .

Βλέπε επίσης: subgradient, γενίκευση, κάθοδος κλίσης, συνάρτηση, gradient, αντικειμενική συνάρτηση, empirical risk, παράμετροι μοντέλου,

υπόθεση.


**κανονικοποίηση δεδομένων** Η κανονικοποίηση δεδομένων αναφέρεται σε μετασχηματισμούς που εφαρμόζονται στα διανύσματα χαρακτηριστικών σημείων δεδομένων για να βελτιωθούν οι στατιστικές διαστάσεις ή οι υπολογιστικές διαστάσεις της μεθόδου μηχανικής μάθησης. Για παράδειγμα, στη γραμμική παλινδρόμηση με μεθόδους με βάση την κλίση που χρησιμοποιούν έναν σταθερό ρυθμό μάθησης, η σύγκλιση εξαρτάται από τον έλεγχο της νόρμας διανυσμάτων χαρακτηριστικών στο σύνολο εκπαίδευσης. Μία κοινή προσέγγιση είναι να κανονικοποιούμε τα διανύσματα χαρακτηριστικών, έτσι ώστε η νόρμα τους να μην υπερβαίνει το ένα [8, Κεφ. 5]. Βλέπε επίσης: data, διάνυσμα χαρακτηριστικών, data point, ml, στατιστικές διαστάσεις, υπολογιστικές διαστάσεις, γραμμική παλινδρόμηση, μέθοδοι με βάση την κλίση, ρυθμός μάθησης, σύγκλιση, νόρμα, σύνολο εκπαίδευσης.

**κατανομή πιθανότητας** Για να αναλύσουμε μεθόδους μηχανικής μάθησης, μπορεί να είναι χρήσιμο να ερμηνεύσουμε σημεία δεδομένων ως ανεξάρτητες και ταυτόσημα κατανεμημένες πραγματώσεις μίας τυχαίας μεταβλητής. Οι τυπικές ιδιότητες τέτοιων σημείων δεδομένων διέπονται τότε από την κατανομή πιθανότητας αυτής της τυχαίας μεταβλητής. Η κατανομή πιθανότητας μίας δυαδικής τυχαίας μεταβλητής  $y \in \{0, 1\}$  προσδιορίζεται πλήρως από τις πιθανότητες  $\mathbb{P}(y = 0)$  και  $\mathbb{P}(y = 1) = 1 - \mathbb{P}(y = 0)$ . Η κατανομή πιθανότητας μίας τυχαίας μεταβλητής πραγματικής τιμής  $x \in \mathbb{R}$  μπορεί να προσδιορίζεται από μία συνάρτηση πυκνότητας πιθανότητας  $p(x)$ , έτσι ώστε  $\mathbb{P}(x \in [a, b]) \approx p(a)|b - a|$ . Στην πιο γενική περίπτωση, η

κατανομή πιθανότητας ορίζεται από ένα μέτρο πιθανότητας [6], [18].

Βλέπε επίσης: ml, data point, ανεξάρτητες και ταυτόσημα κατανομημένες, πραγμάτωση, τυχαία μεταβλητή, probability, συνάρτηση πυκνότητας πιθανότητας.

**κεντρικό οριακό θεώρημα** Consider a sequence of ανεξάρτητες και ταυτόσημα κατανομημένες τυχαία μεταβλητής  $x^{(r)}$ , for  $r = 1, 2, \dots$ ,



Βλέπε επίσης: ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, μέση τιμή, διακύμανση, Gaussian RV, χαρακτηριστική συνάρτηση, fixed-point iteration, σύγκλιση, γενίκευση.

**κερκόπορτα** Μία επίθεση κερκόπορτας (backdoor) αναφέρεται στον σκόπιμο χειρισμό της διαδικασίας εκπαίδευσης που αποτελεί τη βάση μιας μεθόδου μηχανικής μάθησης. Αυτός ο χειρισμός μπορεί να υλοποιηθεί με τη διαταραχή του συνόλου εκπαίδευσης (δηλαδή μέσω τ.. data poisoning) ή μέσω του αλγόριθμου βελτιστοποίησης που χρησιμοποιείται από μία μέθοδο βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης. Ο στόχος μιας

επίθεσης κερκόπορτας είναι να ωθήσει την υπόθεση  $\hat{h}$  που έχει μαθευτεί προς συγκεκριμένες προβλέψεις για ένα ορισμένο πεδίο τιμών χαρακτηριστικών. Το συγκεκριμένο πεδίο τιμών χαρακτηριστικών χρησιμεύει ως το κλειδί (ή έναυσμα) για να ξεκλειδώσει μία κερκόπορτα με την έννοια της παροχής ανώμαλων προβλέψεων. Το κλειδί  $\mathbf{x}$  και η σχετική ανώμαλη πρόβλεψη  $\hat{h}(\mathbf{x})$  είναι γνωστά μόνο στον επιτιθέμενο.

Βλέπε επίσης: ml, σύνολο εκπαίδευσης, data poisoning, αλγόριθμος, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, πρόβλεψη, feature.

**κλίση** Για μία συνάρτηση πραγματικής τιμής  $f : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{w} \mapsto f(\mathbf{w})$ , αν υφίσταται ένα διάνυσμα  $\mathbf{g}$  τέτοιο ώστε

$$\lim_{\mathbf{w} \rightarrow \mathbf{w}'} f(\mathbf{w}) - (f(\mathbf{w}') + \mathbf{g}^T(\mathbf{w} - \mathbf{w}')) / \|\mathbf{w} - \mathbf{w}'\| = 0$$

αναφέρεται ως η κλίση της  $f$  στο  $\mathbf{w}'$ . Αν υφίσταται, η κλίση είναι μοναδική και δηλώνεται με  $\nabla f(\mathbf{w}')$  ή  $\nabla f(\mathbf{w})|_{\mathbf{w}'}$  [2].

Βλέπε επίσης: συνάρτηση, διάνυσμα.

**κριτήριο τερματισμού** Πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν επαναληπτικούς αλγόριθμους που κατασκευάζουν μία ακολουθία παραμέτρων μοντέλου προκειμένου να ελαχιστοποιήσουν το σφάλμα εκπαίδευσης. Για παράδειγμα, οι μέθοδοι με βάση την κλίση ενημερώνουν επαναληπτικά τις παραμέτρους ενός παραμετρικού μοντέλου, όπως ενός γραμμικού μοντέλου ή ενός βαθιού δικτύου. Δεδομένων περιορισμένων υπολογιστικών πόρων, χρειάζεται να σταματήσουμε την ενημέρωση των παραμέτρων μετά από έναν πεπερασμένο αριθμό επαναλήψεων. Ένα κριτήριο τερματισμού είναι οποιαδήποτε καλά ορισμένη συνθήκη για να απο-

φασίσουμε πότε να σταματήσουμε την ενημέρωση.

Βλέπε επίσης: ml, αλγόριθμος, παράμετροι μοντέλου, training error, μέθοδοι με βάση την κλίση, παράμετρος, model, γραμμικό μοντέλο, βαθύ δίκτυο.

**κυρτή συσταδοποίηση** Θεωρούμε ένα σύνολο δεδομένων  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Η κυρτή συσταδοποίηση μαθαίνει διανύσματα  $\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(m)}$  ελαχιστοποιώντας το

$$\sum_{r=1}^m \|\mathbf{x}^{(r)} - \mathbf{w}^{(r)}\|_2^2 + \alpha \sum_{i,i' \in \mathcal{V}} \|\mathbf{w}^{(i)} - \mathbf{w}^{(i')}\|_p.$$

Εδώ,  $\|\mathbf{u}\|_p := (\sum_{j=1}^d |u_j|^p)^{1/p}$  δηλώνει την  $p$ -νόρμα (για  $p \geq 1$ ). Προκύπτει ότι πολλά από τα βέλτιστα διανύσματα  $\hat{\mathbf{w}}^{(1)}, \dots, \hat{\mathbf{w}}^{(m)}$  συμπίπτουν. Μία συστάδα τότε αποτελείται από αυτά τα σημεία δεδομένων  $r \in \{1, \dots, m\}$  με ταυτόσημα  $\hat{\mathbf{w}}^{(r)}$  [77], [78].

Βλέπε επίσης: σύνολο δεδομένων, convex, συσταδοποίηση, διάνυσμα, νόρμα, συστάδα, data point.

**κυρτός** Ένα υποσύνολο  $\mathcal{C} \subseteq \mathbb{R}^d$  του Ευκλείδειου χώρου  $\mathbb{R}^d$  αναφέρεται ως κυρτό αν περιέχει το ευθύγραμμο τμήμα μεταξύ οποιωνδήποτε δύο σημείων  $\mathbf{x}, \mathbf{y} \in \mathcal{C}$  σε ένα σύνολο. Μία συνάρτηση  $f: \mathbb{R}^d \rightarrow \mathbb{R}$  είναι κυρτή αν το επίγραμμα της  $\{(\mathbf{w}^T, t)^T \in \mathbb{R}^{d+1} : t \geq f(\mathbf{w})\}$  είναι ένα κυρτό σύνολο [15]. Παρουσιάζουμε ένα παράδειγμα ενός κυρτού συνόλου και μίας κυρτής συνάρτησης στο Σχ. 29.



Σχ. 29. (a) Ένα κυρτό σύνολο  $\mathcal{C} \subseteq \mathbb{R}^d$ . (b) Μία κυρτή συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ .

Βλέπε επίσης: Ευκλείδειος χώρος, συνάρτηση, epigraph.

**λεία** A real-valued συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  is smooth if it is παραγωγίσιμη and its gradient  $\nabla f(\mathbf{w})$  is continuous at all  $\mathbf{w} \in \mathbb{R}^d$  [16], [79]. A smooth συνάρτηση  $f$  is referred to as  $\beta$ -smooth if the gradient  $\nabla f(\mathbf{w})$  is Lipschitz continuous with Lipschitz constant  $\beta$ , i.e.,

$$\|\nabla f(\mathbf{w}) - \nabla f(\mathbf{w}')\| \leq \beta \|\mathbf{w} - \mathbf{w}'\|, \text{ for any } \mathbf{w}, \mathbf{w}' \in \mathbb{R}^d.$$

The constant  $\beta$  quantifies the smoothness of the συνάρτηση  $f$ : the smaller the  $\beta$ , the smoother  $f$  is. Optimization problems with a smooth αντικειμενική συνάρτηση can be solved effectively by μέθοδοι με βάση την κλίση. Indeed, μέθοδοι με βάση την κλίση approximate the αντικειμενική συνάρτηση locally around a current choice  $\mathbf{w}$  using its gradient. This approximation works well if the gradient does not change too rapidly. We can make this informal claim precise by studying the effect of a single βήμα κλίσης with μέγεθος βήματος  $\eta = 1/\beta$  (see Fig. 30).




Fig. 30. Consider an αντικειμενική συνάρτηση  $f(\mathbf{w})$  that is  $\beta$ -smooth. Taking a βήμα κλίσης, with μέγεθος βήματος  $\eta = 1/\beta$ , decreases the objective by at least  $1/2\beta \|\nabla f(\mathbf{w}^{(k)})\|_2^2$  [16], [79], [80]. Note that the μέγεθος βήματος  $\eta = 1/\beta$  becomes larger for smaller  $\beta$ . Thus, for smoother αντικειμενική συνάρτησης (i.e., those with smaller  $\beta$ ), we can take larger steps.

Βλέπε επίσης: συνάρτηση, παραγωγίσιμη, gradient, optimization problem, αντικειμενική συνάρτηση, μέθοδοι με βάση την κλίση, βήμα κλίσης, μέγεθος βήματος.

**λογιστική απώλεια** Consider a data point characterized by the features  $\mathbf{x}$  and a binary ετικέτα  $y \in \{-1, 1\}$ . We use a real-valued υπόθεση  $h$  to predict the ετικέτα  $y$  from the features  $\mathbf{x}$ . The logistic loss incurred by this πρόβλεψη is defined as

$$L((\mathbf{x}, y), h) := \log(1 + \exp(-yh(\mathbf{x}))). \quad (5)$$






Fig. 31. The logistic loss incurred by the πρόβλεψη  $h(\mathbf{x}) \in \mathbb{R}$  for a data point with ετικέτα  $y \in \{-1, 1\}$ .

Note that the expression (5) for the logistic loss applies only for the χώρος ετικετών  $\mathcal{Y} = \{-1, 1\}$  and when using the thresholding rule (7).  
 Βλέπε επίσης: data point, feature, ετικέτα, υπόθεση, loss, πρόβλεψη, χώρος ετικετών.

**λογιστική παλινδρόμηση** Η λογιστική παλινδρόμηση μαθαίνει μία γραμμική map υπόθεσης (ή έναν ταξινομητή)  $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  για να προβλέψει μία δυαδική ετικέτα  $y$  με βάση το αριθμητικό διάνυσμα χαρακτηριστικών  $\mathbf{x}$  ενός σημείου δεδομένων. Η ποιότητα μίας γραμμικής map υπόθεσης μετράται από τη μέση λογιστική απώλεια σε κάποια σημεία δεδομένων με ετικέτες (δηλαδή το σύνολο εκπαίδευσης).

Βλέπε επίσης: regression, υπόθεση, map, ταξινομητής, ετικέτα, διάνυσμα χαρακτηριστικών, data point, λογιστική απώλεια, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

**μάθηση πολυδιεργασίας** Η μάθηση πολυδιεργασίας στοχεύει να αξιοποι-

ήσει σχέσεις μεταξύ διαφορετικών εργασιών μάθησης. Θεωρούμε δύο εργασίες μάθησης που προκύπτουν από το ίδιο σύνολο δεδομένων λήψεων από κάμερα υπολογιστή. Η πρώτη εργασία είναι να προβλεφθεί η παρουσία ενός ανθρώπου, ενώ η δεύτερη εργασία είναι να προβλεφθεί η παρουσία ενός αυτοκινήτου. Μπορεί να είναι χρήσιμο να χρησιμοποιηθεί η ίδια δομή βαθιού δικτύου και για τις δύο εργασίες και να επιτραπεί μόνο τα βάρη του τελικού στρώματος εξόδου να είναι διαφορετικά.

Βλέπε επίσης: εργασία μάθησης, σύνολο δεδομένων, βαθύ δίκτυο, βάρη, στρώμα.

**μάθηση χαρακτηριστικών** Θεωρούμε μία εφαρμογή μηχανικής μάθησης με σημεία δεδομένων που χαρακτηρίζονται από ακατέργαστα χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$ . Η μάθηση χαρακτηριστικών αναφέρεται στην εργασία της μάθησης μίας  $\text{map}$

$$\Phi : \mathcal{X} \rightarrow \mathcal{X}' : \mathbf{x} \mapsto \mathbf{x}'$$

που διαβάζει τα χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$  ενός σημείου δεδομένων και παραδίδει νέα χαρακτηριστικά  $\mathbf{x}' \in \mathcal{X}'$  από έναν νέο χώρο χαρακτηριστικών  $\mathcal{X}'$ . Διαφορετικές μέθοδοι μάθησης χαρακτηριστικών προκύπτουν για διαφορετικές επιλογές σχεδιασμού των  $\mathcal{X}, \mathcal{X}'$ , για έναν χώρο υποθέσεων  $\mathcal{H}$  πιθανών  $\text{maps } \Phi$ , και για ένα ποσοτικό μέτρο της χρησιμότητας μίας συγκεκριμένης  $\Phi \in \mathcal{H}$ . Για παράδειγμα, η ανάλυση κυρίων συνιστωσών χρησιμοποιεί  $\mathcal{X} := \mathbb{R}^d, \mathcal{X}' := \mathbb{R}^{d'}$  με  $d' < d$ , και έναν χώρο υποθέσεων

$$\mathcal{H} := \{ \Phi : \mathbb{R}^d \rightarrow \mathbb{R}^{d'} : \mathbf{x}' := \mathbf{F}\mathbf{x} \text{ με κάποια } \mathbf{F} \in \mathbb{R}^{d' \times d} \}.$$

Η ανάλυση κυρίων συνιστωσών μετράει τη χρησιμότητα μίας συγκεκρι-

μένης  $\text{map } \Phi(\mathbf{x}) = \mathbf{F}\mathbf{x}$  από το ελάχιστο γραμμικό σφάλμα ανακατασκευής που προκαλείται σε ένα σύνολο δεδομένων, έτσι ώστε

$$\min_{\mathbf{G} \in \mathbb{R}^{d \times d'}} \sum_{r=1}^m \|\mathbf{G}\mathbf{F}\mathbf{x}^{(r)} - \mathbf{x}^{(r)}\|_2^2.$$

Βλέπε επίσης: ml, data point, feature, map, χώρος χαρακτηριστικών, χώρος υποθέσεων, ανάλυση κυρίων συνιστωσών, ελάχιστο, σύνολο δεδομένων.

**μαλακή συσταδοποίηση** Η μαλακή συσταδοποίηση αναφέρεται στην εργασία χωρισμού ενός συγκεκριμένου συνόλου σημείων δεδομένων σε (μερικές) αλληλεπικαλυπτόμενες συστάδες. Κάθε σημείο δεδομένων αποδίδεται σε αρκετές διαφορετικές συστάδες με μεταβαλλόμενους βαθμούς συσχέτισης. Οι μέθοδοι μαλακής συσταδοποίησης καθορίζουν τον βαθμό συσχέτισης (ή την απόδοση μαλακής συστάδας) για κάθε σημείο δεδομένων και κάθε συστάδα. Μία προσέγγιση αρχών στη μαλακή συσταδοποίηση είναι με την ερμηνεία σημείων δεδομένων ως ανεξάρτητες και ταυτόσημα κατανεμημένες πραγματώσεις ενός Gaussian mixture model (GMM). Η υπό συνθήκη πιθανότητα ενός σημείου δεδομένων να ανήκει σε μία συγκεκριμένη συνιστώσα μίγματος είναι τότε μία φυσική επιλογή για τον βαθμό συσχέτισης.

Βλέπε επίσης: συσταδοποίηση, data point, συστάδα, βαθμός συσχέτισης, ανεξάρτητες και ταυτόσημα κατανεμημένες, πραγμάτωση, GMM, probability.

**μεγάλο γλωσσικό μοντέλο** Το μεγάλο γλωσσικό μοντέλο (large lan-

guage model - LLM) είναι ένα όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που επεξεργάζονται και παράγουν κείμενο παρόμοιο με ανθρώπινο. Αυτές οι μέθοδοι συνήθως χρησιμοποιούν βαθιά δίκτυα με δισεκατομμύρια (ή ακόμα και τρισεκατομμύρια) παραμέτρους. Μία ευρέως χρησιμοποιούμενη επιλογή για την αρχιτεκτονική του δικτύου αναφέρεται ως Transformers [81]. Η εκπαίδευση μεγάλων γλωσσικών μοντέλων βασίζεται συχνά στην εργασία της πρόβλεψης μερικών λέξεων που σκόπιμα αφαιρούνται από ένα μεγάλο σώμα κειμένων. Έτσι, μπορούμε να κατασκευάσουμε σημεία δεδομένων με ετικέτες απλώς επιλέγοντας κάποιες λέξεις από ένα δεδομένο κείμενο ως ετικέτες και τις υπόλοιπες λέξεις ως χαρακτηριστικά σημείων δεδομένων. Αυτή η κατασκευή απαιτεί πολύ λίγη ανθρώπινη εποπτεία και επιτρέπει την παραγωγή επαρκώς μεγάλων συνόλων εκπαίδευσης για μεγάλα γλωσσικά μοντέλα.

Βλέπε επίσης: ml, βαθύ δίκτυο, παράμετρος, σημείο δεδομένων με ετικέτα, ετικέτα, feature, data point, σύνολο εκπαίδευσης, model.

**μέγεθος βήματος** Βλέπε ρυθμός μάθησης.

**μέγεθος δείγματος** Ο αριθμός των ξεχωριστών σημείων δεδομένων που περιέχονται σε ένα σύνολο δεδομένων.

Βλέπε επίσης: data point, σύνολο δεδομένων.

**μέγιστο** Το μέγιστο ενός συνόλου  $\mathcal{A} \subseteq \mathbb{R}$  πραγματικών αριθμών είναι το μέγιστο στοιχείο σε αυτό το σύνολο, αν ένα τέτοιο στοιχείο υφίσταται. Ένα σύνολο  $\mathcal{A}$  έχει ένα μέγιστο αν είναι άνω φραγμένο και επιτυγχάνει το ελάχιστο άνω φράγμα του [2, Sec. 1.4].

Βλέπε επίσης: ελάχιστο άνω φράγμα (ή supremum).

**μέθοδοι με βάση την κλίση** Οι μέθοδοι με βάση την κλίση είναι επαναληπτικές τεχνικές για την εύρεση του ελάχιστου (ή του μέγιστου) μίας παραγωγίσιμης αντικειμενικής συνάρτησης των παραμέτρων μοντέλου. Αυτές οι μέθοδοι κατασκευάζουν μία ακολουθία προσεγγίσεων σε μία βέλτιστη επιλογή παραμέτρων μοντέλου που οδηγεί σε μία ελάχιστη (ή μέγιστη) τιμή της αντικειμενικής συνάρτησης. Όπως το όνομά τους υποδεικνύει, οι μέθοδοι με βάση την κλίση χρησιμοποιούν τις κλίσεις της αντικειμενικής συνάρτησης που αξιολογούνται κατά τις προηγούμενες επαναλήψεις για να κατασκευάσουν νέες, (ελπίζοντας) βελτιωμένες παραμέτρους μοντέλου. Ένα σημαντικό παράδειγμα μίας μεθόδου με βάση την κλίση είναι η κάθοδος κλίσης.


Βλέπε επίσης: gradient, ελάχιστο, maximum, παραγωγίσιμη, αντικειμενική συνάρτηση, παράμετροι μοντέλου, κάθοδος κλίσης.

**μέθοδος βελτιστοποίησης** Μία μέθοδος βελτιστοποίησης είναι ένας αλγόριθμος που διαβάζει μία αναπαράσταση ενός προβλήματος βελτιστοποίησης και παραδίδει μία (προσεγγιστική) λύση ως την έξοδό του [14], [15], [16].

Βλέπε επίσης: αλγόριθμος, optimization problem.

**μέθοδος πυρήνα** Μία μέθοδος πυρήνα είναι μία μέθοδος μηχανικής μάθησης που χρησιμοποιεί έναν πυρήνα  $K$  για να αντιστοιχήσει το αρχικό (δηλαδή ακατέργαστο) διάνυσμα χαρακτηριστικών  $\mathbf{x}$  ενός σημείου δεδομένων σε ένα νέο (μετασχηματισμένο) διάνυσμα χαρακτηριστικών  $\mathbf{z} = K(\mathbf{x}, \cdot)$  [35], [76]. Το κίνητρο για τον μετασχηματισμό των διανυσμάτων χαρακτηριστικών είναι ότι, χρησιμοποιώντας έναν κατάλληλο πυρήνα, τα σημεία

δεδομένων έχουν μία πιο «ευχάριστη» γεωμετρία στον μετασχηματισμένο χώρο χαρακτηριστικών. Για παράδειγμα, σε ένα πρόβλημα δυαδικής ταξινόμησης, η χρήση μετασχηματισμένων διανυσμάτων χαρακτηριστικών  $\mathbf{z}$  μπορεί να μας επιτρέψει να χρησιμοποιήσουμε γραμμικά μοντέλα, ακόμα και αν τα σημεία δεδομένων δεν είναι γραμμικώς διαχωρίσιμα στον αρχικό χώρο χαρακτηριστικών (βλέπε Σχ. 32).



Σχ. 32. Πέντε σημεία δεδομένων που χαρακτηρίζονται από διανύσματα χαρακτηριστικών  $\mathbf{x}^{(r)}$  και ετικέτες  $y^{(r)} \in \{\circ, \square\}$ , για  $r = 1, \dots, 5$ . Με αυτά τα διανύσματα χαρακτηριστικών, δεν υπάρχει τρόπος να διαχωρίσουμε τις δύο τάξεις με μία ευθεία γραμμή (που αναπαριστά το όριο απόφασης ενός γραμμικού ταξινομητή). Αντίθετα, τα μετασχηματισμένα διανύσματα χαρακτηριστικών  $\mathbf{z}^{(r)} = K(\mathbf{x}^{(r)}, \cdot)$  μας επιτρέπουν να διαχωρίσουμε τα σημεία δεδομένων χρησιμοποιώντας έναν γραμμικό ταξινομητή.

Βλέπε επίσης: πυρήνας, ml, διάνυσμα χαρακτηριστικών, data point, χώρος χαρακτηριστικών, ταξινόμηση, γραμμικό μοντέλο, ετικέτα, όριο απόφασης, γραμμικός ταξινομητής.

**μείωση της διαστασιμότητας** Dimensionality reduction refers to methods that learn a transformation  $h : \mathbb{R}^d \rightarrow \mathbb{R}^{d'}$  a (typically large) set of raw features  $x_1, \dots, x_d$  into a smaller set of informative features  $z_1, \dots, z_{d'}$ . Using a smaller set of features is beneficial in several ways:

- Statistical benefit: It typically reduces the διακινδύνευση of υπερ-προσαρμογή, as reducing the number of features often reduces the αποτελεσματική διάσταση of a model.
- Computational benefit: Using fewer features means less computation for the training of ml models. As a case in point, γραμμική παλινδρόμηση methods need to invert a πίνακας whose size is determined by the number of features.
- Visualization: Dimensionality reduction is also instrumental for data visualization. For example, we can learn a transformation that delivers two features  $z_1, z_2$ , which we can use, in turn, as the coordinates of a διάγραμμα διασποράς. Fig. 33 depicts the διάγραμμα διασποράς of handwritten digits that are placed using transformed features. Here, the data points are naturally represented by a large number of grayscale values (one value for each pixel).




Fig. 33. Example of dimensionality reduction: High-dimensional image data (e.g., high-resolution images of handwritten digits) embedded into 2-D using learned features  $(z_1, z_2)$  and visualized in a διάγραμμα διασποράς.

Βλέπε επίσης: feature, διακινδύνευση, υπερπροσαρμογή, αποτελεσματική διάσταση, model, ml, γραμμική παλινδρόμηση, πίνακας, data, διάγραμμα διασποράς, data point.

**μεροληψία** Θεωρούμε μία μέθοδο μηχανικής μάθησης που χρησιμοποιεί έναν παραμετροποιημένο χώρο υποθέσεων  $\mathcal{H}$ . Μαθαίνει τις παραμέτρους του μοντέλου  $\mathbf{w} \in \mathbb{R}^d$  χρησιμοποιώντας το σύνολο δεδομένων

$$\mathcal{D} = \{ (\mathbf{x}^{(r)}, y^{(r)}) \}_{r=1}^m.$$

Για να αναλύσουμε τις ιδιότητες της μεθόδου μηχανικής μάθησης, συνήθως ερμηνεύουμε τα σημεία δεδομένων ως πραγματώσεις ανεξάρτητων και ταυτόσημα καταναμεμένων τυχαίων μεταβλητών,

$$y^{(r)} = h(\bar{\mathbf{w}})(\mathbf{x}^{(r)}) + \epsilon^{(r)}, r = 1, \dots, m.$$

Μπορούμε τότε να ερμηνεύσουμε τη μέθοδο μηχανικής μάθησης ως μία εκτιμήτρια  $\hat{\mathbf{w}}$  που υπολογίζεται από το  $\mathcal{D}$  (π.χ. λύνοντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης). Η (τετραγωνική) μεροληψία που προκαλείται από την εκτίμηση  $\hat{\mathbf{w}}$  ορίζεται τότε ως  $B^2 := \|\mathbb{E}\{\hat{\mathbf{w}}\} - \bar{\mathbf{w}}\|_2^2$ . Βλέπε επίσης: ml, χώρος υποθέσεων, παράμετροι μοντέλου, σύνολο δεδομένων, data point, πραγμάτωση, ανεξάρτητες και ταυτόσημα καταναμεμένες, τυχαία μεταβλητή, ελαχιστοποίηση εμπειρικής διακινδύνευσης, πιθανοτικό μοντέλο, σφάλμα εκτίμησης.

**μέση τιμή** Η μέση τιμή μίας τυχαίας μεταβλητής  $\mathbf{x}$ , που παίρνει τιμές σε έναν Ευκλείδειο χώρο  $\mathbb{R}^d$ , είναι η προσδοκία της  $\mathbb{E}\{\mathbf{x}\}$ . Ορίζεται ως



το ολοκλήρωμα Lebesgue του  $\mathbf{x}$  αναφορικά με την υποκείμενη κατανομή πιθανότητας  $P$  (π.χ. βλέπε [2] ή [6]), δηλαδή

$$\mathbb{E}\{\mathbf{x}\} = \int_{\mathbb{R}^d} \mathbf{x} dP(\mathbf{x}).$$

Είναι χρήσιμο να σκεφτούμε τη μέση τιμή ως τη λύση του ακόλουθου προβλήματος ελαχιστοποίησης διακινδύνευσης [7]:

$$\mathbb{E}\{\mathbf{x}\} = \arg \min_{\mathbf{c} \in \mathbb{R}^d} \mathbb{E}\{ \|\mathbf{x} - \mathbf{c}\|_2^2 \}.$$

Χρησιμοποιούμε επίσης τον όρο για να αναφερθούμε στον μέσο όρο μίας πεπερασμένης ακολουθίας  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Ωστόσο, αυτοί οι δύο ορισμοί είναι ουσιαστικά ίδιοι. Πράγματι, μπορούμε να χρησιμοποιήσουμε την ακολουθία  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$  για να κατασκευάσουμε μία διακριτή τυχαία μεταβλητή  $\tilde{\mathbf{x}} = \mathbf{x}^{(I)}$ , με τον δείκτη  $I$  να επιλέγεται ομοιόμορφα στην τύχη από το σύνολο  $\{1, \dots, m\}$ . Η μέση τιμή της  $\tilde{\mathbf{x}}$  είναι ακριβώς ο μέσος όρος  $(1/m) \sum_{r=1}^m \mathbf{x}^{(r)}$ .

Βλέπε επίσης: τυχαία μεταβλητή, Ευκλείδειος χώρος, expectation, κατανομή πιθανότητας, διακινδύνευση.

**μέση τιμή δείγματος** Η μέση τιμή δείγματος  $\mathbf{m} \in \mathbb{R}^d$  για ένα συγκεκριμένο σύνολο δεδομένων, με διανύσματα χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ , ορίζεται ως

$$\mathbf{m} = \frac{1}{m} \sum_{r=1}^m \mathbf{x}^{(r)}.$$

Βλέπε επίσης: δείγμα, μέση τιμή, σύνολο δεδομένων, διάνυσμα χαρακτη-

ριστικών.

**μέσο τετραγωνικό σφάλμα εκτίμησης** Θεωρούμε μία μέθοδο μηχανικής μάθησης που μαθαίνει παραμέτρους μοντέλου  $\hat{\mathbf{w}}$  με βάση κάποιο σύνολο δεδομένων  $\mathcal{D}$ . Αν ερμηνεύσουμε τα σημεία δεδομένων στο  $\mathcal{D}$  ως ανεξάρτητες και ταυτόσημα κατανομημένες πραγματώσεις μίας τυχαίας μεταβλητής  $\mathbf{z}$ , ορίζουμε το σφάλμα εκτίμησης  $\Delta \mathbf{w} := \hat{\mathbf{w}} - \bar{\mathbf{w}}$ . Εδώ,  $\bar{\mathbf{w}}$  δηλώνει τις αληθείς παραμέτρους του μοντέλου της κατανομής πιθανότητας του  $\mathbf{z}$ . Το μέσο τετραγωνικό σφάλμα εκτίμησης (mean squared estimation error - MSE) ορίζεται ως η προσδοκία  $\mathbb{E}\{\|\Delta \mathbf{w}\|^2\}$  της τετραγωνικής Ευκλείδειας νόρμας του σφάλματος εκτίμησης [40], [82].

Βλέπε επίσης: ml, παράμετροι μοντέλου, σύνολο δεδομένων, data point, ανεξάρτητες και ταυτόσημα κατανομημένες, πραγμάτωση, τυχαία μεταβλητή, σφάλμα εκτίμησης, κατανομή πιθανότητας, expectation, νόρμα, μέση τιμή, πιθανοτικό μοντέλο, απώλεια τετραγωνικού σφάλματος.

**μετρήσιμο** Consider a τυχαίο πείραμα, such as recording the air temperature at an Φινλανδικό Μετεωρολογικό Ινστιτούτο weather station. The corresponding δειγματικός χώρος  $\Omega$  consists of all possible outcomes  $\omega$  (e.g., all possible temperature values in degree Celsius). In many ml applications, we are not interested in the exact outcome  $\omega$ , but only whether it belongs to a subset  $\mathcal{A} \subseteq \Omega$  (e.g., “is the temperature below zero degrees?”). We call such a subset  $\mathcal{A}$  measurable if it is possible to decide, for any outcome  $\omega$ , whether  $\omega \in \mathcal{A}$  or not (see Fig. 34).




Fig. 34. A δειγματικός χώρος constituted by all possible temperature values  $\omega$  that may be experienced at an Φινλανδικό Μετεωρολογικό Ινστιτούτο station. Two measurable subsets of temperature values, denoted by  $\mathcal{A}^{(1)}$  and  $\mathcal{A}^{(2)}$ , are highlighted. For any actual temperature value  $\omega$ , it is possible to determine whether  $\omega \in \mathcal{A}^{(1)}$  and whether  $\omega \in \mathcal{A}^{(2)}$ .

In principle, measurable sets could be chosen freely (e.g., depending on the resolution of the measuring equipment). However, it is often useful to impose certain completeness requirements on the collection of measurable sets. For example, the δειγματικός χώρος itself should be measurable, and the union of two measurable sets should also be measurable. These completeness requirements can be formalized via the concept of  $\sigma$ -algebra (or  $\sigma$ -field) [1], [6], [83]. A measurable space is a pair  $(\mathcal{X}, \mathcal{F})$  that consists of an arbitrary set  $\mathcal{X}$  and a collection  $\mathcal{F}$  of measurable subsets of  $\mathcal{X}$  that form a  $\sigma$ -algebra.

Βλέπε επίσης: τυχαίο πείραμα, Φινλανδικό Μετεωρολογικό Ινστιτούτο, δειγματικός χώρος, ml, probability.

**μετρική** Στην πιο γενική της μορφή, μία μετρική είναι ένα ποσοτικό μέτρο που χρησιμοποιείται για τη σύγκριση ή αξιολόγηση αντικειμένων. Στα μαθηματικά, μία μετρική μετράει την απόσταση μεταξύ δύο σημείων και πρέπει να ακολουθεί συγκεκριμένους κανόνες, δηλαδή η απόσταση να είναι πάντα μη αρνητική, να είναι μηδενική μόνο αν τα σημεία είναι ίδια, να είναι

συμμετρική, και να ικανοποιεί την τριγωνική ανισότητα [2]. Στη μηχανική μάθηση, μία μετρική είναι ένα ποσοτικό μέτρο του πόσο καλά επιδίδει ένα μοντέλο. Παραδείγματα περιλαμβάνουν την ακρίβεια, την precision, και τη μέση 0/1 απώλεια σε ένα σύνολο ελέγχου [38], [84]. Μία συνάρτηση απώλειας χρησιμοποιείται για να εκπαιδεύσει μοντέλα, ενώ μία μετρική χρησιμοποιείται για να συγκρίνει εκπαιδευμένα μοντέλα.

See also: ml, model, ακρίβεια, 0/1 απώλεια, σύνολο ελέγχου, συνάρτηση απώλειας, loss, επιλογή μοντέλου.

**μη λεία** Αναφερόμαστε σε μία συνάρτηση ως μη λεία αν δεν είναι λεία [16].

Βλέπε επίσης: συνάρτηση, λεία.

**μηχανή διανυσμάτων υποστήριξης (ΜΔΥ)** The SVM (support vector machine - SVM) is a binary ταξινόμηση method that learns a linear υπόθεση map. Thus, like γραμμική παλινδρόμηση and λογιστική παλινδρόμηση, it is also an instance of ελαχιστοποίηση εμπειρικής διακινδύνευσης for the γραμμικό μοντέλο. However, the SVM uses a different συνάρτηση απώλειας from the one used in those methods. As illustrated in Fig. 35, it aims to maximally separate data points from the two different classes in the χώρος χαρακτηριστικών (i.e., maximum margin principle). Maximizing this separation is equivalent to minimizing a regularized variant of the απώλεια άρθρωσης (1) [84], [35], [85].




Fig. 35. The SVM learns a υπόθεση (or ταξινομητής)  $h^{(w)}$  with minimal average soft-margin απώλεια άρθρωσης. Minimizing this loss is equivalent to maximizing the margin  $\xi$  between the όριο απόφασης of  $h^{(w)}$  and each class of the σύνολο εκπαίδευσης.

The above basic variant of SVM is only useful if the data points from different categories can be (approximately) linearly separated. For an ml application where the categories are not derived from a πυρήνας.


Βλέπε επίσης: ταξινόμηση, υπόθεση, map, γραμμική παλινδρόμηση, λογιστική παλινδρόμηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, γραμμικό μοντέλο, συνάρτηση απώλειας, data point, χώρος χαρακτηριστικών, maximum, απώλεια άρθρωσης, διάνυσμα, ταξινομητής, loss, όριο απόφασης, σύνολο εκπαίδευσης, ml, πυρήνας, απώλεια άρθρωσης.

**μηχανική μάθηση** Η μηχανική μάθηση (machine learning - ML) στοχεύει να προβλέψει μία ετικέτα από τα χαρακτηριστικά ενός σημείου δεδομένων. Οι μέθοδοι μηχανικής μάθησης το επιτυγχάνουν αυτό μαθαίνοντας μία υπόθεση από έναν χώρο υποθέσεων (ή μοντέλο) μέσω της ελαχιστοποίησης μίας συνάρτησης απώλειας [8], [86]. Μία ακριβής διατύπωση αυτής της αρχής είναι η ελαχιστοποίηση εμπειρικής διακινδύνευσης. Διαφορετι-

κές μέθοδοι μηχανικής μάθησης προκύπτουν από διαφορετικές επιλογές σχεδιασμού για σημεία δεδομένων (δηλαδή τα χαρακτηριστικά και την ετικέτα τους), το μοντέλο, και τη συνάρτηση απώλειας [8, Κεφ. 3].

Βλέπε επίσης: ετικέτα, feature, data point, υπόθεση, χώρος υποθέσεων, model, συνάρτηση απώλειας, ελαχιστοποίηση εμπειρικής διακινδύνευσης, data, loss.

**μοντέλο** Η μελέτη και ο σχεδιασμός μεθόδων μηχανικής μάθησης βασίζεται συχνά σε ένα μαθηματικό μοντέλο [87]. Ίσως το πιο ευρέως χρησιμοποιούμενο παράδειγμα μαθηματικού μοντέλου για τη μηχανική μάθηση είναι ένας χώρος υποθέσεων. Ένας χώρος υποθέσεων αποτελείται από maps υπόθεσης που χρησιμοποιούνται από μία μέθοδο μηχανικής μάθησης για την πρόβλεψη ετικετών από τα χαρακτηριστικά σημείων δεδομένων. Ένας άλλος σημαντικός τύπος μαθηματικού μοντέλου είναι ένα πιθανοτικό μοντέλο, το οποίο αποτελείται από κατανομές πιθανοτήτων που περιγράφουν πώς παράγονται σημεία δεδομένων. Εκτός αν διατυπώνεται διαφορετικά, χρησιμοποιούμε τον όρο μοντέλο για να αναφερθούμε συγκεκριμένα στον χώρο υποθέσεων που αποτελεί τη βάση μίας μεθόδου μηχανικής μάθησης. Παρουσιάζουμε ένα παράδειγμα ενός χώρου υποθέσεων και ενός πιθανοτικού μοντέλου στο Σχ. 36.



Σχ. 36. Δύο τύποι μαθηματικών μοντέλων που χρησιμοποιούνται στη μηχανική μάθηση. (a) Ένας χώρος υποθέσεων που αποτελείται από τρεις linear maps. (b) Ένα πιθανοτικό μοντέλο που αποτελείται από κατανομή πιθανότητας πάνω στο επίπεδο παραγόμενο από τις τιμές χαρακτηριστικών και ετικετών ενός σημείου δεδομένων.

Βλέπε επίσης: ml, χώρος υποθέσεων, υπόθεση, map, ετικέτα, feature, data point, πιθανοτικό μοντέλο, κατανομή πιθανότητας, linear map.

**μοντέλο στοχαστικής ομάδας** Το μοντέλο στοχαστικής ομάδας (stochastic block model - SBM) είναι ένα πιθανοτικό παραγωγικό μοντέλο για έναν μη κατευθυνόμενο γράφο  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  με ένα δεδομένο σύνολο κόμβων  $\mathcal{V}$  [88]. Στην πιο βασική του παραλλαγή, το μοντέλο στοχαστικής ομάδας παράγει έναν γράφο πρώτα αποδίδοντας τυχαία κάθε κόμβο  $i \in \mathcal{V}$  σε έναν δείκτη συστάδας  $c_i \in \{1, \dots, k\}$ . Ένα ζεύγος διαφορετικών κόμβων στον γράφο συνδέεται με μία ακμή με πιθανότητα  $p_{i,i'}$  που εξαρτάται μόνο από τις ετικέτες  $c_i, c_{i'}$ . Η παρουσία ακμών μεταξύ διαφορετικών ζευγών κομβων είναι στατιστικά ανεξάρτητη.

Βλέπε επίσης: model, graph, συστάδα, probability, ετικέτα.

**νόμος των μεγάλων αριθμών** Ο νόμος των μεγάλων αριθμών αναφέρε-

ται στη σύγκλιση του μέσου όρου ενός αυξανόμενου (μεγάλου) αριθμού ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών στη μέση τιμή της κοινής τους κατανομής πιθανότητας. Διαφορετικές περιπτώσεις του νόμου των μεγάλων αριθμών προκύπτουν από τη χρήση διαφορετικών εννοιών σύγκλισης [19].

Βλέπε επίσης: σύγκλιση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, μέση τιμή, κατανομή πιθανότητας.

**νόρμα** Μία νόρμα είναι μία συνάρτηση που αντιστοιχεί κάθε (διανυσματικό) στοιχείο ενός διανυσματικού χώρου σε έναν μη αρνητικό αριθμό. Αυτή η συνάρτηση πρέπει να είναι ομογενής και ορισμένη, και πρέπει να ικανοποιεί την τριγωνική ανισότητα [12].

Βλέπε επίσης: συνάρτηση, διάνυσμα, διανυσματικός χώρος.

**ολική μεταβολή** Βλέπε γενικευμένη ολική μεταβολή.

**ομαλοποιημένη ελαχιστοποίηση απώλειας** Βλέπε ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης.

**ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης** Basic ελαχιστοποίηση εμπειρικής διακινδύνευσης learns a υπόθεση (or trains a model)  $h \in \mathcal{H}$  based solely on the empirical risk  $\hat{L}(h|\mathcal{D})$  incurred on a σύνολο εκπαίδευσης  $\mathcal{D}$ . To make ελαχιστοποίηση εμπειρικής διακινδύνευσης less prone to υπερπροσαρμογή, we can implement ομαλοποίηση by including a (scaled) ομαλοποιητής  $\mathcal{R}\{h\}$  in the learning objective. This leads to RERM (regularized empirical risk minimization - RERM),

$$\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{L}(h|\mathcal{D}) + \alpha \mathcal{R}\{h\}. \quad (6)$$



The παράμετρος  $\alpha \geq 0$  controls the ομαλοποίηση strength. For  $\alpha = 0$ , we recover standard ελαχιστοποίηση εμπειρικής διακινδύνευσης without ομαλοποίηση. As  $\alpha$  increases, the learned υπόθεση is increasingly biased toward small values of  $\mathcal{R}\{h\}$ . The component  $\alpha\mathcal{R}\{h\}$  in the αντικειμενική συνάρτηση of (6) can be intuitively understood as a surrogate for the increased average loss that may occur when predicting ετικέτας for data points outside the σύνολο εκπαίδευσης. This intuition can be made precise in various ways. For example, consider a γραμμικό μοντέλο trained using απώλεια τετραγωνικού σφάλματος and the ομαλοποιητής  $\mathcal{R}\{h\} = \|\mathbf{w}\|_2^2$ . In this setting,  $\alpha\mathcal{R}\{h\}$  corresponds to the expected increase in loss caused by adding Gaussian RVs to the διάνυσμα χαρακτηριστικών in the σύνολο εκπαίδευσης [8, Ch. 3]. A principled construction for the ομαλοποιητής  $\mathcal{R}\{h\}$  arises from approximate upper bounds on the γενίκευση error. The resulting RERM instance is known as ελαχιστοποίηση δομικής διακινδύνευσης [89, Sec. 7.2].

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, model, empirical risk, σύνολο εκπαίδευσης, υπερπροσαρμογή, ομαλοποίηση, ομαλοποιητής, παράμετρος, αντικειμενική συνάρτηση, loss, ετικέτα, data point, γραμμικό μοντέλο, απώλεια τετραγωνικού σφάλματος, Gaussian RV, διάνυσμα χαρακτηριστικών, γενίκευση, ελαχιστοποίηση δομικής διακινδύνευσης.

**ομαλοποίηση** A key challenge of modern ml applications is that they often use large models, which have an αποτελεσματική διάσταση in the order of billions. Training a high-dimensional model using basic ελαχιστοποίηση εμπειρικής διακινδύνευσης-based methods is prone to υπερπροσαρμογή:

the learned υπόθεση performs well on the σύνολο εκπαίδευσης but poorly outside the σύνολο εκπαίδευσης. Regularization refers to modifications of a given instance of ελαχιστοποίηση εμπειρικής διακινδύνευσης in order to avoid υπερπροσαρμογή, i.e., to ensure that the learned υπόθεση does not perform much worse outside the σύνολο εκπαίδευσης. There are three routes for implementing regularization:

- 1) Model pruning: We prune the original model  $\mathcal{H}$  to obtain a smaller model  $\mathcal{H}'$ . For a parametric model, the pruning can be implemented via constraints on the παράμετροι μοντέλου (such as  $w_1 \in [0.4, 0.6]$  for the weight of feature  $x_1$  in γραμμική παλινδρόμηση).
- 2) Loss penalization: We modify the αντικειμενική συνάρτηση of ελαχιστοποίηση εμπειρικής διακινδύνευσης by adding a penalty term to the training error. The penalty term estimates how much higher the expected loss (or διακινδύνευση) is compared to the average loss on the σύνολο εκπαίδευσης.
- 3) Data augmentation: We can enlarge the σύνολο εκπαίδευσης  $\mathcal{D}$  by adding perturbed copies of the original data points in  $\mathcal{D}$ . One example for such a perturbation is to add the πραγμάτωση of an τυχαία μεταβλητή to the διάνυσμα χαρακτηριστικών of a data point.

Fig. 37 illustrates the above three routes to regularization. These routes are closely related and sometimes fully equivalent: data augmentation using Gaussian RVs to perturb the διάνυσμα χαρακτηριστικών in the σύνολο εκπαίδευσης of γραμμική παλινδρόμηση has the same effect as adding the penalty  $\lambda \|\mathbf{w}\|_2^2$  to the training error (which is nothing but αμφοκλήσης

παλινδρόμηση). The decision on which route to use for regularization can be based on the available computational infrastructure. For example, it might be much easier to implement data augmentation than model pruning.




Fig. 37. Three approaches to regularization: 1) data augmentation; 2) loss penalization; and 3) model pruning (via constraints on παράμετροι μοντέλου).

Βλέπε επίσης: ml, model, αποτελεσματική διάσταση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπερπροσαρμογή, υπόθεση, σύνολο εκπαίδευσης, παράμετροι μοντέλου, feature, γραμμική παλινδρόμηση, loss, αντικειμενική συνάρτηση, training error, διακινδύνευση, data augmentation, data point, πραγμάτωση, τυχαία μεταβλητή, διάνυσμα χαρακτηριστικών, Gaussian RV, ridge regression, ετικέτα, επικύρωση, επιλογή μοντέλου.

**ομαλοποιητής** Ένας ομαλοποιητής αποδίδει σε κάθε υπόθεση  $h$  από έναν χώρο υποθέσεων  $\mathcal{H}$  ένα ποσοτικό μέτρο  $\mathcal{R}\{h\}$  που εκφράζει σε ποιόν

βαθμό τα σφάλματα πρόβλεψής της μπορεί να διαφέρουν σε σημεία δεδομένων σε ένα σύνολο εκπαίδευσης και έξω από αυτό. Η αμφικλινής παλινδρόμηση χρησιμοποιεί τον ομαλοποιητή  $\mathcal{R}\{h\} := \|\mathbf{w}\|_2^2$  για γραμμικές maps υπόθεσης  $h^{(\mathbf{w})}(\mathbf{x}) := \mathbf{w}^T \mathbf{x}$  [8, Κεφ. 3]. Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής χρησιμοποιεί τον ομαλοποιητή  $\mathcal{R}\{h\} := \|\mathbf{w}\|_1$  για γραμμικές maps υπόθεσης  $h^{(\mathbf{w})}(\mathbf{x}) := \mathbf{w}^T \mathbf{x}$  [8, Κεφ. 3].

Βλέπε επίσης: υπόθεση, χώρος υποθέσεων, πρόβλεψη, σύνολο εκπαίδευσης, data point, ridge regression, map, Lasso, loss, αντικειμενική συνάρτηση.

**ομοσπονδιακή μάθηση** Η ομοσπονδιακή μάθηση (federated learning - FL)

είναι ένας όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που εκπαιδεύουν μοντέλα με έναν συνεργατικό τρόπο χρησιμοποιώντας αποκεντρωμένα δεδομένα και υπολογισμό.

Βλέπε επίσης: ml, model, data.

**οπισθοδιάδοση** Backpropagation is an αλγόριθμος for computing the gradient  $\nabla_{\mathbf{w}} f(\mathbf{w})$  of an αντικειμενική συνάρτηση  $f(\mathbf{w})$  that depends on the παράμετροι μοντέλου  $\mathbf{w}$  of an ΤΝΔ. One example of such an αντικειμενική συνάρτηση is the average loss incurred by the ΤΝΔ on a δέσμη of data points. This αλγόριθμος is a direct application of the chain rule from calculus to efficiently compute partial derivatives of the συνάρτηση απώλειας with respect to the παράμετροι μοντέλου. Backpropagation consists of two consecutive phases, also illustrated in Fig. 38. The first phase includes the forward pass, where a δέσμη of data points is fed

into the TNΔ. The TNΔ processes the input through its στρώμας using its current βάρη, ultimately producing a πρόβλεψη at its output. The πρόβλεψη of the δέσμη is compared to the true ετικέτα using a συνάρτηση απώλειας, which quantifies the πρόβλεψη error. The second phase includes the backward pass (i.e., backpropagation), where the error is backpropagated through the TNΔ στρώμας. The obtained partial derivatives with respect to the TNΔ παράμετρος  $w_1, \dots, w_d$  constitute the gradient  $\nabla f(\mathbf{w})$ , which can be used, in turn, to implement a βήμα κλίσης.




Fig. 38. Solid arrows show the forward pass (i.e., data flow and loss calculation), while dashed arrows show the gradient correction flow during the backward pass for updating the παράμετρος  $W^{(x)}, b^{(x)}$ .

Βλέπε επίσης: αλγόριθμος, gradient, αντικειμενική συνάρτηση, παράμετροι μοντέλου, TNΔ, loss, δέσμη, data point, συνάρτηση απώλειας,

στρώμα, βάρη, πρόβλεψη, ετικέτα, παράμετρος, βήμα κλίσης, data, κάθοδος κλίσης, μέθοδος βελτιστοποίησης.

**οριζόντια ομοσπονδιακή μάθηση** Η οριζόντια ομοσπονδιακή μάθηση (horizontal federated learning - HFL) χρησιμοποιεί τοπικά σύνολα δεδομένων που αποτελούνται από διαφορετικά σημεία δεδομένων, αλλά χρησιμοποιεί τα ίδια χαρακτηριστικά για να τα χαρακτηρίσει [90]. Για παράδειγμα, η πρόγνωση καιρού χρησιμοποιεί ένα δίκτυο χωρικά κατανεμημένων σταθμών (παρατήρησης) καιρού. Κάθε σταθμός καιρού μετράει τις ίδιες ποσότητες, όπως την ημερήσια θερμοκρασία, την ατμοσφαιρική πίεση, και τα ατμοσφαιρικά κατακρημνίσματα. Ωστόσο, διαφορετικοί σταθμοί καιρού μετράνε τα characteristics ή τα χαρακτηριστικά διαφορετικών χωροχρονικών περιοχών. Κάθε χωροχρονική περιοχή αναπαριστά ένα μεμονωμένο σημείο δεδομένων, με το καθένα να χαρακτηρίζεται από τα ίδια χαρακτηριστικά (δηλαδή ημερήσια θερμοκρασία ή ατμοσφαιρική πίεση).

Βλέπε επίσης: τοπικό σύνολο δεδομένων, data point, feature, semi-supervised learning (SSL), FL, vertical federated learning (VFL).

**όριο απόφασης** Θεωρούμε μία map υπόθεσης  $h$  που διαβάζει ένα διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  και παραδίδει μία τιμή από ένα πεπερασμένο σύνολο  $\mathcal{Y}$ . Το όριο απόφασης της  $h$  είναι το σύνολο των διανυσμάτων  $\mathbf{x} \in \mathbb{R}^d$  που βρίσκονται ανάμεσα σε διαφορετικές περιοχές αποφάσεων. Πιο συγκεκριμένα, ένα διάνυσμα  $\mathbf{x}$  ανήκει στο όριο απόφασης αν και μόνο αν κάθε γειτονιά  $\{\mathbf{x}' : \|\mathbf{x} - \mathbf{x}'\| \leq \varepsilon\}$ , για οποιοδήποτε  $\varepsilon > 0$ , περιέχει τουλάχιστον δύο διανύσματα με διαφορετικές τιμές συνάρτησης.

Βλέπε επίσης: υπόθεση, map, διάνυσμα χαρακτηριστικών, διάνυσμα, πε-

ριοχή αποφάσεων, neighborhood, συνάρτηση.

**παλινδρόμηση** Τα προβλήματα παλινδρόμησης περιστρέφονται γύρω από την πρόβλεψη μίας αριθμητικής ετικέτας μόνο από τα χαρακτηριστικά ενός σημείου δεδομένων [8, Κεφ. 2].

Βλέπε επίσης: πρόβλεψη, ετικέτα, feature, data point.

**παλινδρόμηση ελάχιστης απόλυτης απόκλισης** Η παλινδρόμηση ελάχιστης απόλυτης απόκλισης είναι μία περίπτωση της ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιεί την απώλεια απόλυτου σφάλματος. Είναι μία ειδική περίπτωση της παλινδρόμησης Huber.

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια απόλυτου σφάλματος, παλινδρόμηση Huber.

**παλινδρόμηση Huber** Η παλινδρόμηση Huber αναφέρεται σε μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιούν την απώλεια Huber ως μέτρο του σφάλματος πρόβλεψης. Δύο σημαντικές ειδικές περιπτώσεις της παλινδρόμησης Huber είναι η παλινδρόμηση ελάχιστης απόλυτης απόκλισης και η γραμμική παλινδρόμηση. Η ρύθμιση της παραμέτρου-κατωφλιού της απώλειας Huber επιτρέπει στον χρήστη να ανταλλάξει την ευρωστία της απώλειας απόλυτου σφάλματος με τα υπολογιστικά οφέλη της λείας απώλειας τετραγωνικού σφάλματος. Βλέπε επίσης: regression, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια Huber, πρόβλεψη, regression, παλινδρόμηση ελάχιστης απόλυτης απόκλισης, γραμμική παλινδρόμηση, παράμετρος, ευρωστία, απώλεια απόλυτου σφάλματος, λεία, απώλεια τετραγωνικού σφάλματος.

**παραγωγίσιμη** Μία συνάρτηση πραγματικής τιμής  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  είναι παρα-

γωγίσιμη αν μπορεί να προσεγγιστεί τοπικά σε οποιοδήποτε σημείο από μία γραμμική συνάρτηση. Η τοπική γραμμική προσέγγιση στο σημείο  $\mathbf{x}$  καθορίζεται από την κλίση  $\nabla f(\mathbf{x})$  [2].

Βλέπε επίσης: συνάρτηση, gradient.

**παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων** Η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων (independent and identically distributed assumption - i.i.d. assumption) ερμηνεύει σημεία δεδομένων ενός συνόλου δεδομένων ως τις πραγματώσεις ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών.

Βλέπε επίσης: ανεξάρτητες και ταυτόσημα κατανεμημένες, data point, σύνολο δεδομένων, πραγμάτωση, τυχαία μεταβλητή.

**παραδοχή συσταδοποίησης** Η παραδοχή συσταδοποίησης υποθέτει ότι σημεία δεδομένων σε ένα σύνολο δεδομένων σχηματίζουν έναν (μικρό) αριθμό ομάδων ή συστάδων. Τα σημεία δεδομένων στην ίδια συστάδα είναι πιο όμοια μεταξύ τους παρά με αυτά εκτός της συστάδας [91]. Αποκτούμε διαφορετικές μεθόδους συσταδοποίησης χρησιμοποιώντας διαφορετικές έννοιες ομοιότητας ανάμεσα σε σημεία δεδομένων.

Βλέπε επίσης: συσταδοποίηση, data point, σύνολο δεδομένων, συστάδα.

**παράμετρος** Η παράμετρος ενός μοντέλου μηχανικής μάθησης είναι μία ποσότητα που μπορεί να ρυθμιστεί (δηλαδή να μαθευτεί ή να προσαρμοστεί) και που μας επιτρέπει να επιλέξουμε μεταξύ διαφορετικών maps υπόθεσης. Για παράδειγμα, το γραμμικό μοντέλο  $\mathcal{H} := \{h^{(\mathbf{w})} : h^{(\mathbf{w})}(x) = w_1x + w_2\}$  αποτελείται από όλες τις maps υπόθεσης  $h^{(\mathbf{w})}(x) = w_1x + w_2$  με μία συγκεκριμένη επιλογή για τις παραμέτρους  $\mathbf{w} = (w_1, w_2)^T \in \mathbb{R}^2$ . Ένα άλλο



παράδειγμα μίας παραμέτρου μοντέλου είναι τα βάρη που αποδίδονται σε μία σύνδεση μεταξύ δύο νευρώνων ενός τεχνητού νευρωνικού δικτύου.

Βλέπε επίσης: ml, model, υπόθεση, map, γραμμικό μοντέλο, βάρη, ΤΝΔ.

**παράμετροι μοντέλου** Οι παράμετροι μοντέλου είναι ποσότητες που χρησιμοποιούνται για να επιλεγεί μία συγκεκριμένη map υπόθεσης από ένα μοντέλο. Μπορούμε να σκεφτούμε μία λίστα παραμέτρων μοντέλου ως ένα μοναδικό αναγνωριστικό για μία map υπόθεσης όμοια με το πώς ένας αριθμός κοινωνικής ασφάλισης ταυτοποιεί ένα άτομο στην Ελλάδα.

Βλέπε επίσης: model, παράμετρος, υπόθεση, map.

**περιοχή αποφάσεων** Θεωρούμε μία map υπόθεσης  $h$  που δίνει τιμές από ένα πεπερασμένο σύνολο  $\mathcal{Y}$ . Για κάθε τιμή ετικέτας (δηλαδή κατηγορία)  $a \in \mathcal{Y}$ , η υπόθεση  $h$  καθορίζει ένα υποσύνολο τιμών χαρακτηριστικών  $\mathbf{x} \in \mathcal{X}$  που οδηγούν στις ίδιες εξόδους  $h(\mathbf{x}) = a$ . Αναφερόμαστε σε αυτό το υποσύνολο ως μία περιοχή αποφάσεων της υπόθεσης  $h$ .

Βλέπε επίσης: υπόθεση, map, ετικέτα, feature.

**πιθανότητα** Αποδίδουμε μία τιμή πιθανότητας, συνήθως επιλεγμένη στο διάστημα  $[0, 1]$ , σε κάθε γεγονός που μπορεί να συμβεί σε ένα τυχαίο πείραμα [6], [7], [92], [93].

Βλέπε επίσης: γεγονός, τυχαίο πείραμα.

**πιθανοτικό μοντέλο** Ένα πιθανοτικό μοντέλο ερμηνεύει σημεία δεδομένων ως πραγματώσεις τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας. Αυτή η κοινή κατανομή πιθανότητας συνήθως περιλαμβάνει παραμέτρους που πρέπει να επιλεγθούν χειρωνακτικά ή να μαθευτούν μέσω μεθόδων

στατιστικής συμπερασματολογίας όπως η εκτίμηση μέγιστης πιθανοφάνειας [40].

Βλέπε επίσης: model, data point, πραγμάτωση, τυχαία μεταβλητή, κατανομή πιθανότητας, παράμετρος, μέγιστη πιθανοφάνεια.

**πίνακας σύγχυσης** Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά  $\mathbf{x}$  και αντίστοιχες ετικέτες  $y$ . Οι ετικέτες παίρνουν τιμές σε έναν πεπερασμένο χώρο ετικετών  $\mathcal{Y} = \{1, \dots, k\}$ . Για μία δεδομένη υπόθεση  $h$ , ο πίνακας σύγχυσης είναι ένας  $k \times k$  πίνακας όπου κάθε γραμμή αντιστοιχεί σε μία διαφορετική τιμή της αληθούς ετικέτας  $y \in \mathcal{Y}$  και κάθε στήλη σε μία διαφορετική τιμή της πρόβλεψης  $h(\mathbf{x}) \in \mathcal{Y}$ . Η  $(c, c')$ στήλη καταχώριση του πίνακα σύγχυσης αναπαριστά το κλάσμα των σημείων δεδομένων με μία πραγματική ετικέτα  $y = c$  που προβλέπονται ως  $h(\mathbf{x}) = c'$ . Η κύρια διαγώνιος του πίνακα σύγχυσης περιέχει τα κλάσματα των σωστά ταξινομημένων σημείων δεδομένων (δηλαδή αυτών για τα οποία  $y = h(\mathbf{x})$ ). Οι εκτός διαγωνίου καταχωρίσεις περιέχουν τα κλάσματα των σημείων δεδομένων που είναι εσφαλμένα ταξινομημένα από την  $h$ .

Βλέπε επίσης: data point, feature, ετικέτα, χώρος ετικετών, υπόθεση, πίνακας, πρόβλεψη, ταξινόμηση.

**πίνακας συνδιακύμανσης** Ο πίνακας συνδιακύμανσης μίας τυχαίας μεταβλητής  $\mathbf{x} \in \mathbb{R}^d$  ορίζεται ως  $\mathbb{E}\left\{(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})^T\right\}$ .

Βλέπε επίσης: συνδιακύμανση, πίνακας, τυχαία μεταβλητή.

**πίνακας συνδιακύμανσης δείγματος** Ο πίνακας συνδιακύμανσης δείγματος  $\hat{\Sigma} \in \mathbb{R}^{d \times d}$  για ένα δεδομένο σύνολο διανυσμάτων χαρακτηριστικών

$\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$  ορίζεται ως

$$\hat{\Sigma} = \frac{1}{m} \sum_{r=1}^m (\mathbf{x}^{(r)} - \hat{\mathbf{m}})(\mathbf{x}^{(r)} - \hat{\mathbf{m}})^T.$$

Εδώ χρησιμοποιούμε τη μέση τιμή δείγματος  $\hat{\mathbf{m}}$ .

Βλέπε επίσης: δείγμα, πίνακας συνδιακύμανσης, διάνυσμα χαρακτηριστικών, μέση τιμή δείγματος.


**πίνακας χαρακτηριστικών** Θεωρούμε ένα σύνολο δεδομένων  $\mathcal{D}$  με  $m$  σημεία δεδομένων με διανύσματα χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Είναι βολικό να συγκεντρώσουμε τα μεμονωμένα διανύσματα χαρακτηριστικών σε έναν πίνακα χαρακτηριστικών  $\mathbf{X} := (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})^T$  μεγέθους  $m \times d$ .

Βλέπε επίσης: σύνολο δεδομένων, data point, διάνυσμα χαρακτηριστικών, feature, πίνακας.

**πίνακας Laplace** Η δομή ενός γράφου  $\mathcal{G}$ , με κόμβους  $i = 1, \dots, n$ , μπορεί να αναλυθεί χρησιμοποιώντας τις ιδιότητες ειδικών πινάκων που σχετίζονται με τον  $\mathcal{G}$ . Ένας τέτοιος πίνακας είναι ο πίνακας Laplace γράφου  $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{n \times n}$ , ο οποίος ορίζεται για έναν μη κατευθυνόμενο και σταθμισμένο γράφο [94], [95]. Από άποψη στοιχείων ορίζεται ως (βλέπε Σχ. 39)

$$L_{i,i'}^{(\mathcal{G})} := \begin{cases} -A_{i,i'}, & \text{for } i \neq i', \{i, i'\} \in \mathcal{E}; \\ \sum_{i'' \neq i} A_{i,i''}, & \text{for } i = i'; \\ 0, & \text{else.} \end{cases}$$

Εδώ,  $A_{i,i'}$  δηλώνει το βάρος ακμής μίας ακμής  $\{i, i'\} \in \mathcal{E}$ .



(a)

$$\mathbf{L}^{(\mathcal{G})} = \begin{pmatrix} 2 & -1 & -1 \\ -1 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

(b)

Σχ. 39. (a) Κάποιος μη κατευθυνόμενος γράφος  $\mathcal{G}$  με τρεις κόμβους  $i = 1, 2, 3$ .  
(b) Ο πίνακας Laplace  $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{3 \times 3}$  του  $\mathcal{G}$ .

Βλέπε επίσης: graph, πίνακας, βάρος ακμής.

**πλησιέστερος γείτονας** Οι μέθοδοι πλησιέστερου γείτονα (nearest neighbor - NN) μαθαίνουν μία υπόθεση  $h : \mathcal{X} \rightarrow \mathcal{Y}$  της οποίας η τιμή συνάρτησης  $h(\mathbf{x})$  καθορίζεται μόνο από τους πλησιέστερους γείτονες εντός ενός δεδομένου συνόλου δεδομένων. Διαφορετικές μέθοδοι χρησιμοποιούν διαφορετικές μετρικές για τον καθορισμό των πλησιέστερων γειτόνων. Αν σημεία δεδομένων χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών, μπορούμε να χρησιμοποιήσουμε τις Ευκλείδειες αποστάσεις τους ως τη μετρική.

Βλέπε επίσης: υπόθεση, συνάρτηση, σύνολο δεδομένων, μετρική, data point, διάνυσμα χαρακτηριστικών, γείτονες.

**πολυμεταβλητή κανονική κατανομή** The multivariate normal distribution, which is denoted by  $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , is a fundamental πιθανοτικό μοντέλο for numerical διάνυσμα χαρακτηριστικών of fixed dimension  $d$ . It defines a family of κατανομή πιθανότητας over διάνυσμα-valued τυχαία μεταβλητής  $\mathbf{x} \in \mathbb{R}^d$  [7], [18], [96]. Each distribution in this family is fully

specified by its μέση τιμή διάνυσμα  $\boldsymbol{\mu} \in \mathbb{R}^d$  and πίνακας συνδιακύμανσης  $\boldsymbol{\Sigma} \in \mathbb{R}^{d \times d}$ . When the πίνακας συνδιακύμανσης  $\boldsymbol{\Sigma}$  is invertible, the corresponding κατανομή πιθανότητας is characterized by the following συνάρτηση πυκνότητας πιθανότητας:

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^d \det(\boldsymbol{\Sigma})}} \exp \left[ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right].$$

Note that this συνάρτηση πυκνότητας πιθανότητας is only defined when  $\boldsymbol{\Sigma}$  is invertible. More generally, any τυχαία μεταβλητή  $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  admits the following representation:

$$\mathbf{x} = \mathbf{A}\mathbf{z} + \boldsymbol{\mu}$$

where  $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  is a standard normal vector and  $\mathbf{A} \in \mathbb{R}^{d \times d}$  satisfies  $\mathbf{A}\mathbf{A}^T = \boldsymbol{\Sigma}$ . This representation remains valid even when  $\boldsymbol{\Sigma}$  is singular, in which case  $\mathbf{A}$  is not full rank [97, Ch. 23]. The family of multivariate normal distributions is exceptional among πιθανοτικό μοντέλος for numerical quantities, at least for the following reasons. First, the family is closed under affine transformations, i.e.,

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \text{ implies } \mathbf{B}\mathbf{x} + \mathbf{c} \sim \mathcal{N}(\mathbf{B}\boldsymbol{\mu} + \mathbf{c}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^T).$$

Second, the κατανομή πιθανότητας  $\mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$  maximizes the διαφορική εντροπία among all distributions with the same πίνακας συνδιακύμανσης  $\boldsymbol{\Sigma}$  [28].

Βλέπε επίσης: πιθανοτικό μοντέλο, διάνυσμα χαρακτηριστικών, κατανο-

μή πιθανότητας, διάνυσμα, τυχαία μεταβλητή, μέση τιμή, πίνακας συνδιακύμανσης, συνάρτηση πυκνότητας πιθανότητας, standard normal vector, διαφορική εντροπία, Gaussian RV.

**πολυωνυμική παλινδρόμηση** Η πολυωνυμική παλινδρόμηση είναι μία περίπτωση ελαχιστοποίησης εμπειρικής διακινδύνευσης που μαθαίνει μία πολυωνυμική map υπόθεσης για να προβλέψει μία αριθμητική ετικέτα με βάση τα αριθμητικά χαρακτηριστικά ενός σημείου δεδομένων. Για σημεία δεδομένων που χαρακτηρίζονται από ένα μοναδικό αριθμητικό χαρακτηριστικό, η πολυωνυμική παλινδρόμηση χρησιμοποιεί τον χώρο υποθέσεων  $\mathcal{H}_d^{(\text{poly})} := \{h(x) = \sum_{j=0}^{d-1} x^j w_j\}$ . Η ποιότητα μίας πολυωνυμικής map υπόθεσης μετράται χρησιμοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που προκύπτει σε ένα σύνολο σημείων δεδομένων με ετικέτες (στο οποίο αναφερόμαστε ως το σύνολο εκπαίδευσης).


Βλέπε επίσης: regression, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, map, ετικέτα, feature, data point, χώρος υποθέσεων, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

**πραγμάτωση** Θεωρούμε μία τυχαία μεταβλητή  $\mathbf{x}$  που αντιστοιχεί κάθε αποτέλεσμα  $\omega \in \mathcal{P}$  ενός χώρου πιθανοτήτων  $\mathcal{P}$  σε ένα στοιχείο ενός μετρήσιμου χώρου  $\mathcal{N}$  [2], [6], [92]. Μία πραγμάτωση της  $\mathbf{x}$  είναι οποιοδήποτε στοιχείο  $\mathbf{a} \in \mathcal{N}$  τέτοιο ώστε να υπάρχει ένα στοιχείο  $\omega' \in \mathcal{P}$  με  $\mathbf{x}(\omega') = \mathbf{a}$ .

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μετρήσιμο.

**προβεβλημένη κάθοδος κλίσης** Θεωρούμε μία μέθοδο βασισμένη στην

ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιεί ένα παραμετροποιημένο μοντέλο με χώρο παραμέτρων  $\mathcal{W} \subseteq \mathbb{R}^d$ . Ακόμα και αν η αντικειμενική συνάρτηση ελαχιστοποίησης εμπειρικής διακινδύνευσης είναι λεία, δεν μπορούμε να χρησιμοποιήσουμε τη βασική καθόδο κλίσης, καθώς δεν λαμβάνει υπόψη περιορισμούς στη μεταβλητή βελτιστοποίησης (δηλαδή τις παραμέτρους του μοντέλου). Η προβεβλημένη καθόδος κλίσης (projected gradient descent - projected GD) επεκτείνει τη βασική καθόδο κλίσης για να αντιμετωπίσει αυτό το ζήτημα. Μία μοναδική επανάληψη της προβεβλημένης καθόδου κλίσης περιλαμβάνει πρώτα τη λήψη ενός βήματος κλίσης και στη συνέχεια την προβολή του αποτελέσματος πίσω στον χώρο παραμέτρων. Βλέπε Σχ. 40 για μία οπτική απεικόνιση.



Σχ. 40. Η προβεβλημένη καθόδος κλίσης επαυξάνει ένα βασικό βήμα κλίσης με μία προβολή πίσω στο σύνολο περιορισμών  $\mathcal{W}$ .

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, model, χώρος παραμέτρων, αντικειμενική συνάρτηση, λεία, καθόδος κλίσης, παράμετροι μοντέλου, βήμα κλίσης, προβολή.

**προβλέπουσα** Μία προβλέπουσα είναι μία map υπόθεσης πραγματικής τιμής. Δεδομένου ενός σημείου δεδομένων με χαρακτηριστικά  $\mathbf{x}$ , η τιμή  $h(\mathbf{x}) \in$

$\mathbb{R}$  χρησιμοποιείται ως η πρόβλεψη για την αληθή αριθμητική ετικέτα  $y \in \mathbb{R}$  του σημείου δεδομένων.

Βλέπε επίσης: υπόθεση, map, data point, feature, πρόβλεψη, ετικέτα.

**πρόβλεψη** Μία πρόβλεψη είναι μία εκτίμηση ή προσέγγιση για κάποια ποσότητα ενδιαφέροντος. Η μηχανική μάθηση περιστρέφεται γύρω από τη μάθηση ή εύρεση μίας map υπόθεσης  $h$  που διαβάζει τα χαρακτηριστικά  $\mathbf{x}$  ενός σημείου δεδομένων και δίνει μία πρόβλεψη  $\hat{y} := h(\mathbf{x})$  για την ετικέτα του  $y$ .

Βλέπε επίσης: ml, υπόθεση, map, feature, data point, ετικέτα.

**προβολή** Θεωρούμε ένα υποσύνολο  $\mathcal{W} \subseteq \mathbb{R}^d$  του  $d$ -διάστατου Ευκλείδειου χώρου. Ορίζουμε την προβολή  $P_{\mathcal{W}}(\mathbf{w})$  ενός διανύσματος  $\mathbf{w} \in \mathbb{R}^d$  στο  $\mathcal{W}$  ως

$$P_{\mathcal{W}}(\mathbf{w}) = \arg \min_{\mathbf{w}' \in \mathcal{W}} \|\mathbf{w} - \mathbf{w}'\|_2.$$

Με άλλα λόγια, η  $P_{\mathcal{W}}(\mathbf{w})$  είναι το διάνυσμα στο  $\mathcal{W}$  που είναι πιο κοντά στο  $\mathbf{w}$ . Η προβολή είναι καλά ορισμένη μόνο για υποσύνολα  $\mathcal{W}$  για τα οποία υπάρχει το παραπάνω ελάχιστο [15].

Βλέπε επίσης: Ευκλείδειος χώρος, διάνυσμα, ελάχιστο.

**προεικόνα** Θεωρούμε μία συνάρτηση  $f: \mathcal{U} \rightarrow \mathcal{V}$  μεταξύ δύο συνόλων. Η προεικόνα  $f^{-1}(\mathcal{B})$  ενός υποσυνόλου  $\mathcal{B} \subseteq \mathcal{V}$  είναι το σύνολο όλων των εισόδων  $u \in \mathcal{U}$  που αντιστοιχούνται στο  $\mathcal{B}$  από την  $f$ , δηλαδή

$$f^{-1}(\mathcal{B}) := \{u \in \mathcal{U} \mid f(u) \in \mathcal{B}\}.$$


Η προεικόνα είναι καλά ορισμένη ακόμα και αν η συνάρτηση  $f$  είναι μη



αντιστρέψιμη [2].

Βλέπε επίσης: συνάρτηση.

**προσδοκία** Θεωρούμε ένα αριθμητικό διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  που ερμηνεύουμε ως την πραγμάτωση μίας τυχαίας μεταβλητής με μία κατανομή πιθανότητας  $p(\mathbf{x})$ . Η προσδοκία του  $\mathbf{x}$  ορίζεται ως το ολοκλήρωμα  $\mathbb{E}\{\mathbf{x}\} := \int \mathbf{x}p(\mathbf{x})$ . Σημείωση ότι η προσδοκία ορίζεται μόνο αν υφίσταται αυτό το ολοκλήρωμα, δηλαδή αν η τυχαία μεταβλητή είναι ολοκληρώσιμη [2], [6], [92]. Το Σχ. 41 απεικονίζει την προσδοκία μίας βαθμωτής διακριτής τυχαίας μεταβλητής  $x$  που παίρνει τιμές μόνο από ένα πεπερασμένο σύνολο.



Σχ. 41. Η προσδοκία μίας διακριτής τυχαίας μεταβλητής  $x$  προκαλείται από το άθροισμα των πιθανών τιμών της  $x_i$ , σταθμισμένες από την αντίστοιχη πιθανότητα  $p(x_i) = \mathbb{P}(x = x_i)$ .

Βλέπε επίσης: διάνυσμα χαρακτηριστικών, πραγμάτωση, τυχαία μεταβλητή, κατανομή πιθανότητας, probability.

**προσεγγίσιμος** Μία κυρτή συνάρτηση για την οποία ο τελεστής εγγύτητας μπορεί να υπολογιστεί αποτελεσματικά αναφέρεται μερικές φορές ως προσεγγίσιμη ή απλή [98].

Βλέπε επίσης: convex, συνάρτηση, τελεστής εγγύτητας.

**προσοχή** Some ml applications involve data points composed of smaller units, known

Βλέπε επίσης: ml, data point, πιθανοτικό μοντέλο, συνάρτηση, παράμετρος, ελαχιστοποίηση εμπειρικής διακινδύνευσης, model, διάνυσμα.

**προστασία της ιδιωτικότητας** Θεωρούμε κάποια μέθοδο μηχανικής μάθησης  $\mathcal{A}$  που διαβάζει ένα σύνολο δεδομένων  $\mathcal{D}$  και δίνει κάποια έξοδο  $\mathcal{A}(\mathcal{D})$ . Η έξοδος θα μπορούσε να είναι οι παράμετροι μοντέλου  $\hat{\mathbf{w}}$  που μαθαίνονται ή η πρόβλεψη  $\hat{h}(\mathbf{x})$  που προκύπτει για ένα συγκεκριμένο σημείο δεδομένων με χαρακτηριστικά  $\mathbf{x}$ . Πολλές σημαντικές εφαρμογές μηχανικής μάθησης περιλαμβάνουν σημεία δεδομένων που αντιπροσωπεύουν ανθρώπους. Κάθε σημείο δεδομένων χαρακτηρίζεται από χαρακτηριστικά  $\mathbf{x}$ , ενδεχομένως μία ετικέτα  $y$ , και ένα ευαίσθητο ιδιοχαρακτηριστικό  $s$  (π.χ. μία πρόσφατη ιατρική διάγνωση). Στο περίπου, προστασία της ιδιωτικότητας σημαίνει ότι θα έπρεπε να είναι αδύνατο να συμπεράνουμε, από την έξοδο  $\mathcal{A}(\mathcal{D})$ , οποιοδήποτε από τα ευαίσθητα ιδιοχαρακτηριστικά των σημείων δεδομένων στο  $\mathcal{D}$ . Από μαθηματικής άποψης, η προστασία της ιδιωτικότητας απαιτεί την μη αντιστρεψιμότητα της  $\text{map } \mathcal{A}(\mathcal{D})$ . Γενικά, το να κάνουμε απλώς το  $\mathcal{A}(\mathcal{D})$  μη αντιστρέψιμο είναι συνήθως ανεπαρκές για την προστασία της ιδιωτικότητας. Χρειάζεται να κάνουμε το  $\mathcal{A}(\mathcal{D})$  επαρκώς μη αντιστρέψιμο.

Βλέπε επίσης: ml, σύνολο δεδομένων, παράμετροι μοντέλου, πρόβλεψη, data point, feature, ετικέτα, ευαίσθητο ιδιοχαρακτηριστικό, map.

**πυρήνας** Θεωρούμε ένα σύνολο σημείων δεδομένων, το καθένα να αναπαρι-

στάται από ένα διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathcal{X}$ , όπου  $\mathcal{X}$  δηλώνει τον χώρο χαρακτηριστικών. Ένας πυρήνας (πραγματικής τιμής) είναι μία συνάρτηση  $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  που αποδίδει σε κάθε ζεύγος διανυσμάτων χαρακτηριστικών  $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$  έναν πραγματικό αριθμό  $K(\mathbf{x}, \mathbf{x}')$ . Αυτή η τιμή συνήθως ερμηνεύεται ως ένα μέτρο για την ομοιότητα μεταξύ των  $\mathbf{x}$  και  $\mathbf{x}'$ . Η καθοριστική ιδιότητα ενός πυρήνα είναι ότι είναι συμμετρικός, δηλαδή  $K(\mathbf{x}, \mathbf{x}') = K(\mathbf{x}', \mathbf{x})$ , και ότι για οποιοδήποτε πεπερασμένο σύνολο διανυσμάτων χαρακτηριστικών  $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X}$ , ο πίνακας

$$\mathbf{K} = \begin{pmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & K(\mathbf{x}_1, \mathbf{x}_2) & \dots & K(\mathbf{x}_1, \mathbf{x}_n) \\ K(\mathbf{x}_2, \mathbf{x}_1) & K(\mathbf{x}_2, \mathbf{x}_2) & \dots & K(\mathbf{x}_2, \mathbf{x}_n) \\ \vdots & \vdots & \ddots & \vdots \\ K(\mathbf{x}_n, \mathbf{x}_1) & K(\mathbf{x}_n, \mathbf{x}_2) & \dots & K(\mathbf{x}_n, \mathbf{x}_n) \end{pmatrix} \in \mathbb{R}^{n \times n}$$

είναι θετικά ημιορισμένος. Ένας πυρήνας καθορίζει φυσικά έναν μετασχηματισμό ενός διανύσματος χαρακτηριστικών  $\mathbf{x}$  σε μία συνάρτηση  $\mathbf{z} = K(\mathbf{x}, \cdot)$ . Η συνάρτηση  $\mathbf{z}$  αντιστοιχεί μία είσοδο  $\mathbf{x}' \in \mathcal{X}$  στην τιμή  $K(\mathbf{x}, \mathbf{x}')$ . Μπορούμε να θεωρήσουμε τη συνάρτηση  $\mathbf{z}$  ως ένα νέο διάνυσμα χαρακτηριστικών που ανήκει σε έναν χώρο χαρακτηριστικών  $\mathcal{X}'$  που είναι συνήθως διαφορετικός από τον  $\mathcal{X}$ . Αυτός ο νέος χώρος χαρακτηριστικών  $\mathcal{X}'$  έχει μία συγκεκριμένη μαθηματική δομή, δηλαδή είναι ένας χώρος Hilbert αναπαραγωγού πυρήνα (reproducing kernel Hilbert space - RKHS) [35], [76]. Δεδομένου ότι το  $\mathbf{z}$  ανήκει σε έναν χώρο Hilbert αναπαραγωγού πυρήνα, ο οποίος είναι ένας διανυσματικός χώρος, μπορούμε να τον ερμηνεύσουμε ως ένα γενικευμένο διάνυσμα χαρακτηριστικών. Σημείωση ότι ένα διάνυσμα χαρακτηριστικών πεπερασμένου

μήκους  $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$  μπορεί να θεωρηθεί ως μία συνάρτηση  $\mathbf{x} : \{1, \dots, d\} \rightarrow \mathbb{R}$  που αποδίδει μία πραγματική τιμή σε κάθε δείκτη  $j \in \{1, \dots, d\}$ .

Βλέπε επίσης: data point, διάνυσμα χαρακτηριστικών, χώρος χαρακτηριστικών, συνάρτηση, πίνακας, θετικά ημιορισμένος, χώρος Hilbert, διανυσματικός χώρος, kernel method.

**ρυθμός μάθησης** Θεωρούμε μία επαναληπτική μέθοδο μηχανικής μάθησης για την εύρεση ή μάθηση μίας χρήσιμης υπόθεσης  $h \in \mathcal{H}$ . Μία τέτοια επαναληπτική μέθοδος επαναλαμβάνει όμοια υπολογιστικά βήματα (ενημέρωσης) που προσαρμόζουν ή τροποποιούν την τρέχουσα υπόθεση για να προκύψει μία βελτιωμένη υπόθεση. Ένα καλά γνωστό παράδειγμα μίας τέτοιας επαναληπτικής μεθόδου μάθησης είναι η κάθοδος κλίσης και οι παραλλαγές της, στοχαστική κάθοδος κλίσης και προβεβλημένη κάθοδος κλίσης. Μία παράμετρος-κλειδί μίας επαναληπτικής μεθόδου είναι ο ρυθμός μάθησης. Ο ρυθμός μάθησης ελέγχει τον βαθμό που η τρέχουσα υπόθεση μπορεί να τροποποιηθεί κατά τη διάρκεια μίας μονής επανάληψης. Ένα καλά γνωστό παράδειγμα μίας τέτοιας παραμέτρου είναι το μέγεθος βήματος που χρησιμοποιείται στην κάθοδο κλίσης [8, Κεφ. 5].

Βλέπε επίσης: ml, υπόθεση, κάθοδος κλίσης, στοχαστική κάθοδος κλίσης, προβεβλημένη κάθοδος κλίσης, παράμετρος, μέγεθος βήματος.

**σημείο δεδομένων** Ένα σημείο δεδομένων είναι οποιοδήποτε αντικείμενο που μεταφέρει πληροφορίες [28]. Παραδείγματα περιλαμβάνουν μαθητές, ραδιοσήματα, δέντρα, εικόνες, τυχαίες μεταβλητές, πραγματικούς αριθμούς, ή πρωτεΐνες. Περιγράφουμε σημεία δεδομένων του ίδιου τύπου

με δύο κατηγορίες ιδιοτήτων. Η πρώτη κατηγορία περιλαμβάνει χαρακτηριστικά που είναι μετρήσιμες ή υπολογίσιμες ιδιότητες ενός σημείου δεδομένων. Αυτά τα ιδιοχαρακτηριστικά μπορούν να εξαχθούν ή να υπολογιστούν αυτόματα χρησιμοποιώντας αισθητήρες, υπολογιστές, ή άλλα συστήματα συλλογής δεδομένων. Για ένα σημείο δεδομένων που αναπαριστά έναν ασθενή, ένα χαρακτηριστικό θα μπορούσε να είναι το σωματικό βάρος. Η δεύτερη κατηγορία περιλαμβάνει ετικέτες που είναι γεγονότα υψηλότερου επιπέδου (ή ποσότητες ενδιαφέροντος) που σχετίζονται με το σημείο δεδομένων. Ο προσδιορισμός των ετικετών ενός σημείου δεδομένων συνήθως απαιτεί ανθρώπινη εμπειρογνωσία ή γνώση πεδίου. Για ένα σημείο δεδομένων που αναπαριστά έναν ασθενή, μία διάγνωση καρκίνου που έχει παραχθεί από έναν γιατρό θα μπορούσε να χρησιμεύει ως η ετικέτα. Το Σχ. 42 απεικονίζει μία εικόνα ως παράδειγμα ενός σημείου δεδομένων μαζί με τα χαρακτηριστικά και τις ετικέτες του. Σημαντικό είναι ότι το τι συνιστά ένα χαρακτηριστικό ή μία ετικέτα δεν είναι εγγενές στο ίδιο το σημείο δεδομένων—είναι μία επιλογή σχεδιασμού που εξαρτάται από τη συγκεκριμένη εφαρμογή μηχανικής μάθησης.



Ένα μοναδικό σημείο δεδομένων.

Χαρακτηριστικά:

- $x_1, \dots, x_{d_1}$ : Εντάσεις χρώματος όλων των εικονοστοιχείων.
- $x_{d_1+1}$ : Χρονική σήμανση της αποτύπωσης της εικόνας.
- $x_{d_1+2}$ : Χωρική θέση της αποτύπωσης της εικόνας.

Ετικέτες:

- $y_1$ : Ο αριθμός αγελάδων που απεικονίζεται.
- $y_2$ : Ο αριθμός λύκων που απεικονίζεται.
- $y_3$ : Η κατάσταση του βοσκότοπου (π.χ. υγιής, με υπερβόσκηση).

Σχ. 42. Εικονογράφηση ενός σημείου δεδομένων που αποτελείται από μία εικόνα. Μπορούμε να χρησιμοποιήσουμε διαφορετικές ιδιότητες της εικόνας ως χαρακτηριστικά και γεγονότα υψηλότερου επιπέδου για την εικόνα ως ετικέτες.

Η διάκριση μεταξύ χαρακτηριστικών και ετικετών δεν είναι πάντα ξεκάθαρη. Μία ιδιότητα που θεωρείται μία ετικέτα σε ένα περιβάλλον (π.χ. μία διάγνωση καρκίνου) μπορεί να αντιμετωπίζεται ως ένα χαρακτηριστικό σε ένα άλλο περιβάλλον—ιδιαίτερα αν η αξιόπιστη αυτοματοποίηση (π.χ.

μέσω ανάλυσης εικόνων) επιτρέπει τον υπολογισμό της χωρίς ανθρώπινη παρέμβαση. Η μηχανική μάθηση στοχεύει γενικά στην πρόβλεψη της ετικέτας ενός σημείου δεδομένων με βάση μόνο τα χαρακτηριστικά του. Βλέπε επίσης: data, τυχαία μεταβλητή, feature, ετικέτα, ml, σύνολο δεδομένων.

**σημείο δεδομένων με ετικέτα** Ένα σημείο δεδομένων του οποίου η ετικέτα είναι γνωστή ή έχει προσδιοριστεί με κάποιον τρόπο που μπορεί να απαιτεί ανθρώπινη εργασία. Βλέπε επίσης: data point, ετικέτα.

**σκληρή συσταδοποίηση** Η σκληρή συσταδοποίηση αναφέρεται στην εργασία χωρισμού ενός συγκεκριμένου συνόλου σημείων δεδομένων σε (μερικές) μη αλληλεπικαλυπτόμενες συστάδες. Η πιο ευρέως χρησιμοποιούμενη μέθοδος σκληρής συσταδοποίησης είναι ο αλγόριθμος  $k$ -μέσων. Βλέπε επίσης: συσταδοποίηση, data point, συστάδα, αλγόριθμος  $k$ -μέσων.

**στατιστικές διαστάσεις** Ως στατιστικές διαστάσεις μίας μεθόδου μηχανικής μάθησης, αναφερόμαστε σε (ιδιότητες της) κατανομή πιθανότητας της εξόδου της κάτω από ένα πιθανοτικό μοντέλο για τα δεδομένα που τροφοδοτούνται στη μέθοδο. Βλέπε επίσης: ml, κατανομή πιθανότητας, πιθανοτικό μοντέλο, data.


**στοχαστική** Αναφερόμαστε σε μία μέθοδο ως στοχαστική αν περιλαμβάνει μία τυχαία συνιστώσα ή διέπεται από πιθανοτικούς νόμους. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν τυχειότητα για να μειώσουν την υπολογιστική πολυπλοκότητα (π.χ. βλέπε στοχαστική κάθοδος κλίσης) ή

για να αποτυπώσουν την αβεβαιότητα σε πιθανοτικά μοντέλα.

Βλέπε επίσης: ml, στοχαστική κάθοδος κλίσης, αβεβαιότητα, πιθανοτικό μοντέλο.

**στοχαστική κάθοδος κλίσης** Η στοχαστική κάθοδος κλίσης (stochastic gradient descent - SGD) προκύπτει από την καθόδο κλίσης αντικαθιστώντας την κλίση της αντικειμενικής συνάρτησης με μία στοχαστική προσέγγιση. Μία κύρια εφαρμογή της στοχαστικής καθόδου κλίσης είναι η εκπαίδευση ενός παραμετροποιημένου μοντέλου μέσω της ελαχιστοποίησης εμπειρικής διακινδύνευσης πάνω σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$  που είτε είναι πολύ μεγαλύτερο είτε δεν είναι εύκολα διαθέσιμο (π.χ. όταν σημεία δεδομένων αποθηκεύονται σε μία βάση δεδομένων καταναμημένη παγκοσμίως). Για να αξιολογήσουμε την κλίση της εμπειρικής διακινδύνευσης (ως μία συνάρτηση των παραμέτρων μοντέλου  $\mathbf{w}$ ), χρειάζεται να υπολογίσουμε ένα άρθροισμα  $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  για όλα τα σημεία δεδομένων στο σύνολο εκπαίδευσης. Αποκτούμε μία στοχαστική προσέγγιση της κλίσης αντικαθιστώντας το άρθροισμα  $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  με ένα άρθροισμα  $\sum_{r \in \mathcal{B}} \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  για ένα τυχαία επιλεγμένο υποσύνολο  $\mathcal{B} \subseteq \{1, \dots, m\}$  (βλέπε Σχ. 43). Αναφερόμαστε συχνά σε αυτά τα τυχαία επιλεγμένα σημεία δεδομένων ως μία δέσμη. Το μέγεθος της δέσμης  $|\mathcal{B}|$  είναι μία σημαντική παράμετρος της στοχαστικής καθόδου κλίσης. Η στοχαστική κάθοδος κλίσης με  $|\mathcal{B}| > 1$  αναφέρεται ως στοχαστική κάθοδος κλίσης μίνι-δέσμης [99].





Σχ. 43. Η στοχαστική κάθοδος κλίσης για την ελαχιστοποίηση εμπειρικής διακινδύνευσης προσεγγίζει την κλίση αντικαθιστώντας το άθροισμα  $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  για όλα τα σημεία δεδομένων στο σύνολο εκπαίδευσης (με δείκτες  $r = 1, \dots, m$ ) με ένα άθροισμα για ένα τυχαία επιλεγμένο υποσύνολο  $\mathcal{B} \subseteq \{1, \dots, m\}$ .

Βλέπε επίσης: κάθοδος κλίσης, gradient, αντικειμενική συνάρτηση, στοχαστική, model, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, data point, empirical risk, συνάρτηση, παράμετροι μοντέλου, δέσμη, παράμετρος.

**στοχαστικός αλγόριθμος** Ένας στοχαστικός αλγόριθμος χρησιμοποιεί έναν τυχαίο μηχανισμό κατά την εκτέλεσή του. Για παράδειγμα, η στοχαστική κάθοδος κλίσης χρησιμοποιεί ένα τυχαία επιλεγμένο υποσύνολο σημείων δεδομένων για να υπολογίσει μία προσέγγιση για την κλίση μίας αντικειμενικής συνάρτησης. Μπορούμε να αναπαραστήσουμε έναν στοχαστικό αλγόριθμο με μία στοχαστική διαδικασία, δηλαδή η πιθανή ακολουθία εκτέλεσης είναι τα πιθανά αποτελέσματα ενός τυχαίου πειράματος [7], [100], [101].

Βλέπε επίσης: στοχαστική, αλγόριθμος, στοχαστική κάθοδος κλίσης, data point, gradient, αντικειμενική συνάρτηση, στοχαστική διαδικασία, τυχαίο πείραμα, μέθοδος βελτιστοποίησης, μέθοδοι με βάση την κλίση.

**στρώμα** A βαθύ δίκτυο is an TNΔ that consists of consecutive layers, indexed by  $\ell = 1, 2, \dots, L$ . The  $\ell$ -th layer consists of artificial neurons  $a_1^{(\ell)}, \dots, a_{d^{(\ell)}}^{(\ell)}$  with the layer width  $d^{(\ell)}$ . Each of these artificial neurons evaluates an συνάρτηση ενεργοποίησης for a weighted sum of the outputs (or ενεργοποίησης) of the previous layer  $\ell - 1$ . The input to layer  $\ell = 1$  is formed from weighted sums of the features of the data point for which the βαθύ δίκτυο computes a πρόβλεψη. The outputs of the neurons in layer  $\ell$  are then, in turn, used to form the inputs for the neurons in the next layer. The final (output) layer consists of a single neuron whose output is used as the πρόβλεψη delivered by the βαθύ δίκτυο.


Βλέπε επίσης: βαθύ δίκτυο, TNΔ, συνάρτηση ενεργοποίησης, ενεργοποίηση, feature, data point, πρόβλεψη.

**συνάρτηση απώλειας** Μία συνάρτηση απώλειας είναι μία map

$$L : \mathcal{X} \times \mathcal{Y} \times \mathcal{H} \rightarrow \mathbb{R}_+ : ((\mathbf{x}, y), h) \mapsto L((\mathbf{x}, y), h).$$

Αποδίδει ένα μη αρνητικό πραγματικό αριθμό (δηλαδή την απώλεια)  $L((\mathbf{x}, y), h)$  σε ένα ζεύγος που αποτελείται από ένα σημείο δεδομένων, με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ , και μία υπόθεση  $h \in \mathcal{H}$ . Η τιμή  $L((\mathbf{x}, y), h)$  ποσοτικοποιεί την απόκλιση μεταξύ της αληθούς ετικέτας  $y$  και της πρόβλεψης  $h(\mathbf{x})$ . Χαμηλότερες (πιο κοντά στο μηδέν) τιμές  $L((\mathbf{x}, y), h)$  υποδεικνύουν μία μικρότερη απόκλιση μεταξύ της πρόβλεψης  $h(\mathbf{x})$  και της ετικέτας  $y$ . Το Σχ. 44 απεικονίζει μία συνάρτηση απώλειας για ένα συγκεκριμένο σημείο δεδομένων, με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα

$y$ , ως μία συνάρτηση της υπόθεσης  $h \in \mathcal{H}$ .



Σχ. 44. Κάποια συνάρτηση απώλειας  $L((\mathbf{x}, y), h)$  για ένα σταθερό σημείο δεδομένων, με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ , και μία μεταβαλλόμενη υπόθεση  $h$ . Οι μέθοδοι μηχανικής μάθησης προσπαθούν να βρουν (ή να μάθουν) μία υπόθεση που προκαλεί ελάχιστη απώλεια.

Βλέπε επίσης: loss, συνάρτηση, map, data point, feature, ετικέτα, υπόθεση, πρόβλεψη, διάνυσμα χαρακτηριστικών, ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης.

**συνάρτηση ενεργοποίησης** Σε κάθε τεχνητό νευρώνα εντός ενός τεχνητού νευρωνικού δικτύου αποδίδεται μία συνάρτηση ενεργοποίησης (activation function)  $\sigma(\cdot)$  που αντιστοιχεί έναν σταθμισμένο συνδυασμό των εισόδων νευρώνα  $x_1, \dots, x_d$  σε μία μοναδική τιμή εξόδου  $a = \sigma(w_1x_1 + \dots + w_dx_d)$ . Σημείωση ότι κάθε νευρώνας είναι παραμετροποιημένος με τα βάρη  $w_1, \dots, w_d$ .

Βλέπε επίσης: ΤΝΔ, ενεργοποίηση, συνάρτηση, βάρη.

**συνάρτηση πυκνότητας πιθανότητας** Η συνάρτηση πυκνότητας πιθανότητας  $p(x)$  (probability density function - pdf) μίας τυχαίας μεταβλητής πραγματικής τιμής  $x \in \mathbb{R}$  είναι μία συγκεκριμένη αναπαράσταση της


κατανομής πιθανότητάς της. Αν η συνάρτηση πυκνότητας πιθανότητας υφίσταται, μπορεί να χρησιμοποιηθεί για τον υπολογισμό της πιθανότητας η  $x$  να παίρνει μία τιμή από ένα μετρήσιμο σύνολο  $\mathcal{B} \subseteq \mathbb{R}$  μέσω της  $\mathbb{P}(x \in \mathcal{B}) = \int_{\mathcal{B}} p(x') dx'$  [7, Κεφ. 3]. Αν η συνάρτηση πυκνότητας πιθανότητας μίας τυχαίας μεταβλητής διανυσματικής τιμής  $\mathbf{x} \in \mathbb{R}^d$  υφίσταται, μας επιτρέπει να υπολογίσουμε την πιθανότητα η  $\mathbf{x}$  να ανήκει σε μία μετρήσιμη περιοχή  $\mathcal{R}$  μέσω της  $\mathbb{P}(\mathbf{x} \in \mathcal{R}) = \int_{\mathcal{R}} p(\mathbf{x}') dx'_1 \dots dx'_d$  [7, Κεφ. 3].

Βλέπε επίσης: τυχαία μεταβλητή, κατανομή πιθανότητας, probability, μετρήσιμο, διάνυσμα.

**συνδεδεμένος γράφος** Ένας μη κατευθυνόμενος γράφος  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  είναι συνδεδεμένος αν κάθε μη κενό υποσύνολο  $\mathcal{V}' \subset \mathcal{V}$  έχει τουλάχιστον μία ακμή που το συνδέει με το  $\mathcal{V} \setminus \mathcal{V}'$ .

Βλέπε επίσης: graph.

**συνδιακύμανση** The covariance between two real-valued



Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, διάγραμμα διασπο-

ράς, πραγμάτωση, πιθανοτικό μοντέλο, expectation.

**συνθήκη μηδενικής κλίσης** Θεωρούμε το unconstrained optimization problem  $\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w})$  με μία λεία και κυρτή αντικειμενική συνάρτηση  $f(\mathbf{w})$ . Μία αναγκαία και ικανή συνθήκη για να λύσει ένα διάνυσμα  $\hat{\mathbf{w}} \in \mathbb{R}^d$  αυτό το πρόβλημα είναι η κλίση  $\nabla f(\hat{\mathbf{w}})$  να είναι το μηδενικό διάνυσμα, έτσι ώστε

$$\nabla f(\hat{\mathbf{w}}) = \mathbf{0} \Leftrightarrow f(\hat{\mathbf{w}}) = \min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}).$$

Βλέπε επίσης: optimization problem, λεία, convex, αντικειμενική συνάρτηση, διάνυσμα, gradient.

**σύνολο δεδομένων** Ένα σύνολο δεδομένων αναφέρεται σε μία συλλογή σημείων δεδομένων. Αυτά τα σημεία δεδομένων φέρουν πληροφορίες σχετικά με κάποια ποσότητα ενδιαφέροντος (ή ετικέτα) εντός μίας εφαρμογής μηχανικής μάθησης. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν σύνολα δεδομένων για την εκπαίδευση μοντέλων (π.χ. μέσω ελαχιστοποίησης εμπειρικής διακινδύνευσης) και την επικύρωση μοντέλων. Σημείωση ότι η έννοιά μας ενός συνόλου δεδομένων είναι πολύ ευέλικτη, καθώς επιτρέπει πολύ διαφορετικούς τύπους σημείων δεδομένων. Πράγματι, σημεία δεδομένων μπορεί να είναι συγκεκριμένα φυσικά αντικείμενα (όπως άνθρωποι ή ζώα) ή αφηρημένα αντικείμενα (όπως αριθμοί). Ως ένα χαρακτηριστικό παράδειγμα, το Σχ. 45 απεικονίζει ένα σύνολο δεδομένων που αποτελείται από αγελάδες ως σημεία δεδομένων.



Σχ. 45. Ένα κοπάδι αγελάδων κάπου στις Άλπεις.

Αρκετά συχνά, ένας μηχανικός μηχανικής μάθησης δεν έχει άμεση πρόσβαση σε ένα σύνολο δεδομένων. Πράγματι, η πρόσβαση στο σύνολο δεδομένων στο Σχ. 45 θα απαιτούσε να επισκεφτούμε το κοπάδι αγελάδων στις Άλπεις. Αντ' αυτού, χρειάζεται να χρησιμοποιήσουμε μία προσέγγιση (ή αναπαράσταση) του συνόλου δεδομένων που είναι πιο βολική να χρησιμοποιηθεί. Διαφορετικά μαθηματικά μοντέλα έχουν αναπτυχθεί για την αναπαράσταση (ή προσέγγιση) συνόλων δεδομένων [52], [102], [103], [104]. Ένα από τα πιο εγκεκριμένα μοντέλα δεδομένων είναι το σχεσιακό μοντέλο, το οποίο οργανώνει δεδομένα ως έναν πίνακα (ή σχέση) [51], [52]. Ένας πίνακας αποτελείται από γραμμές και στήλες, όπου κάθε γραμμή του πίνακα αναπαριστά ένα μονό σημείο δεδομένων, και κάθε στήλη του πίνακα αντιστοιχεί σε ένα συγκεκριμένο ιδιοχαρακτηριστικό του σημείου δεδομένων. Οι μέθοδοι μηχανικής μάθησης μπορούν να χρησιμοποιήσουν ιδιοχαρακτηριστικά ως χαρακτηριστικά και ετικέτες του σημείου δεδομένων.

Για παράδειγμα, ο Πίνακας I δείχνει μία αναπαράσταση του συνόλου δεδομένων στο Σχ. 45. Στο σχεσιακό μοντέλο, η σειρά των γραμμών δεν έχει σημασία, και κάθε ιδιοχαρακτηριστικό (δηλαδή στήλη) πρέπει να εί-

ναι ακριβώς ορισμένη με ένα πεδίο, το οποίο προσδιορίζει το σύνολο των πιθανών τιμών. Σε εφαρμογές μηχανικής μάθησης, αυτά τα πεδία ιδιοχαρακτηριστικών γίνονται ο χώρος χαρακτηριστικών και ο χώρος ετικετών.

### ΠΙΝΑΚΑΣ I

ΜΙΑ ΣΧΕΣΗ (Η ΠΙΝΑΚΑΣ) ΠΟΥ ΑΝΑΠΑΡΙΣΤΑ ΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ ΣΤΟ ΣΧ.

45

Όνομα	Βάρος	Ηλικία	Ύψος	Θερμοκρασία στομαχιού
Zenzi	100	4	100	25
Berta	140	3	130	23
Resi	120	4	120	31

Ενώ το σχεσιακό μοντέλο είναι χρήσιμο για τη μελέτη πολλών εφαρμογών μηχανικής μάθησης, μπορεί να είναι ανεπαρκές όσον αφορά τις προϋποθέσεις για αξιόπιστη τεχνητή νοημοσύνη. Σύγχρονες προσεγγίσεις, όπως τα φύλλα δεδομένων για σύνολα δεδομένων, παρέχουν πιο περιεκτικά τεκμήρια, συμπεριλαμβανομένων λεπτομερειών για τη διαδικασία συλλογής των δεδομένων, την επιθυμητή χρήση, και άλλες πληροφορίες σχετικές με τα συμφοραζόμενα [60].

Βλέπε επίσης: data point, ετικέτα, ml, model, ελαχιστοποίηση εμπειρικής διακινδύνευσης, επικύρωση, data, feature, χώρος χαρακτηριστικών, χώρος ετικετών, αξιόπιστη TN.

**σύνολο εκπαίδευσης** Ένα σύνολο εκπαίδευσης είναι ένα σύνολο δεδομένων  $\mathcal{D}$  που αποτελείται από κάποια σημεία δεδομένων που χρησιμοποιούνται στην ελαχιστοποίηση εμπειρικής διακινδύνευσης για τη μάθηση μίας υπόθεσης  $\hat{h}$ . Η μέση απώλεια της  $\hat{h}$  στο σύνολο εκπαίδευσης αναφέρεται ως το σφάλμα εκπαίδευσης. Η σύγκριση του σφάλματος εκπαίδευσης με

το σφάλματος επικύρωσης της  $\hat{h}$  μας επιτρέπει να διαγνώσουμε τη μέθοδο μηχανικής μάθησης και ενημερώνει για το πώς να βελτιώσουμε το σφάλμα επικύρωσης (π.χ. χρησιμοποιώντας έναν διαφορετικό χώρο υποθέσεων ή συλλέγοντας περισσότερα σημεία δεδομένων) [8, Sec. 6.6].

Βλέπε επίσης: σύνολο δεδομένων, data point, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, loss, training error, σφάλμα επικύρωσης, ml, χώρος υποθέσεων.

**σύνολο ελέγχου** Ένα σύνολο σημείων δεδομένων που δεν έχουν χρησιμοποιηθεί ούτε για την εκπαίδευση ενός μοντέλου (π.χ. μέσω της ελαχιστοποίησης εμπειρικής διακινδύνευσης) ούτε για την επιλογή διαφορετικών μοντέλων σε ένα σύνολο επικύρωσης.

Βλέπε επίσης: data point, model, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο επικύρωσης.

**σύνολο επικύρωσης** Ένα σύνολο σημείων δεδομένων που χρησιμοποιούνται για την εκτίμηση της διακινδύνευσης μίας υπόθεσης  $\hat{h}$  που έχει μαθευτεί από κάποια μέθοδο μηχανικής μάθησης (π.χ. λύνοντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης). Η μέση απώλεια της  $\hat{h}$  στο σύνολο επικύρωσης αναφέρεται ως το σφάλμα επικύρωσης και μπορεί να χρησιμοποιηθεί για τη διάγνωση μίας μεθόδου μηχανικής μάθησης (βλέπε [8, Sec. 6.6]). Η σύγκριση μεταξύ σφάλματος εκπαίδευσης και σφάλματος επικύρωσης μπορεί να προσφέρει κατευθύνσεις για τη βελτίωση της μεθόδου μηχανικής μάθησης (όπως τη χρήση ενός διαφορετικού χώρου υποθέσεων).

Βλέπε επίσης: data point, διακινδύνευση, υπόθεση, ml, ελαχιστοποίηση




εμπειρικής διακινδύνευσης, loss, επικύρωση, σφάλμα επικύρωσης, training error, χώρος υποθέσεων.

**συσκευή** Ένα φυσικό σύστημα που μπορεί να αποθηκεύει και να επεξεργάζεται δεδομένα. Στο πλαίσιο της μηχανικής μάθησης, ο όρος συνήθως αναφέρεται σε έναν υπολογιστή που μπορεί να διαβάσει σημεία δεδομένων από διαφορετικές πηγές και να τα χρησιμοποιήσει για να εκπαιδεύσει ένα μοντέλο μηχανικής μάθησης [105].

Βλέπε επίσης: data, ml, data point, model.

**συστάδα** Μία συστάδα (cluster) είναι ένα υποσύνολο σημείων δεδομένων που είναι πιο όμοια μεταξύ τους παρά με τα σημεία δεδομένων εκτός της συστάδας. Το ποσοτικό μέτρο της ομοιότητας μεταξύ σημείων δεδομένων είναι μία επιλογή σχεδιασμού. Αν σημεία δεδομένων χαρακτηρίζονται από Ευκλείδεια διανύσματα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$ , μπορούμε να ορίσουμε την ομοιότητα μεταξύ δύο σημείων δεδομένων μέσω της Ευκλείδειας απόστασης μεταξύ των διανυσμάτων χαρακτηριστικών τους. Ένα παράδειγμα τέτοιων συστάδων παρουσιάζεται στο Σχ. 46.



Σχ. 46. Εικονογράφηση τριών συστάδων σε έναν 2-D χώρο χαρακτηριστικών. Κάθε συστάδα ομαδοποιεί σημεία δεδομένων που είναι πιο όμοια μεταξύ τους παρά με αυτά σε άλλες συστάδες, με βάση την Ευκλείδεια απόσταση.

Βλέπε επίσης: data point, διάνυσμα χαρακτηριστικών, χώρος χαρακτηριστικών.

**συσταδοποίηση** Οι μέθοδοι συσταδοποίησης (clustering) διαμερίζουν ένα δεδομένο σύνολο σημείων δεδομένων σε λίγα υποσύνολα, τα οποία αναφέρονται ως συστάδες. Κάθε συστάδα αποτελείται από σημεία δεδομένων που είναι πιο όμοια μεταξύ τους παρά με σημεία δεδομένων εκτός της συστάδας. Διαφορετικές μέθοδοι συσταδοποίησης χρησιμοποιούν διαφορετικά μέτρα για την ομοιότητα μεταξύ σημείων δεδομένων και διαφορετικές μορφές αναπαράστασης συστάδων. Η μέθοδος συσταδοποίησης του αλ-

γόριθμου  $k$ -μέσων χρησιμοποιεί το μέσο διάνυσμα χαρακτηριστικών μίας συστάδας (δηλαδή τη μέση τιμή της συστάδας) ως τον αντιπρόσωπό της. Μία δημοφιλής μέθοδος μαλακής συσταδοποίησης βασισμένη σε GMM αναπαριστά μία συστάδα από μία πολυμεταβλητή κανονική κατανομή. Βλέπε επίσης: data point, συστάδα, αλγόριθμος  $k$ -μέσων, διάνυσμα χαρακτηριστικών, μέση τιμή, soft clustering, GMM, πολυμεταβλητή κανονική κατανομή.

**συσταδοποίηση γράφου** Η συσταδοποίηση γράφου (graph clustering) στοχεύει να συσταδοποιήσει σημεία δεδομένων που αναπαριστώνται ως οι κόμβοι ενός γράφου  $\mathcal{G}$ . Οι ακμές του  $\mathcal{G}$  αναπαριστούν κατά ζεύγη ομοιότητες μεταξύ σημείων δεδομένων. Κάποιες φορές μπορούμε να ποσοτικοποιήσουμε την έκταση αυτών των ομοιοτήτων με ένα βάρος ακμής [94], [106].

Βλέπε επίσης: graph, συσταδοποίηση, data point, βάρος ακμής.

**συσταδοποίηση με βάση τη ροή** Η συσταδοποίηση με βάση τη ροή ομαδοποιεί τους κόμβους ενός μη κατευθυνόμενου γράφου με την εφαρμογή συσταδοποίησης αλγόριθμου  $k$ -μέσων σε διανύσματα χαρακτηριστικών από θέμα κόμβων. Αυτά τα διανύσματα χαρακτηριστικών κατασκευάζονται από ροές δικτύου μεταξύ προσεκτικά επιλεγμένων πηγών και κόμβων προορισμού [106].

Βλέπε επίσης: συσταδοποίηση, graph, αλγόριθμος  $k$ -μέσων, διάνυσμα χαρακτηριστικών.

**σφάλμα εκπαίδευσης** Η μέση απώλεια μίας υπόθεσης όταν προβλέπει τις ετικέτες των σημείων δεδομένων σε ένα σύνολο εκπαίδευσης. Κάποιες

φορές αναφερόμαστε στο σφάλμα εκπαίδευσης και ως την ελάχιστη μέση απώλεια που επιτυγχάνεται από μία λύση της ελαχιστοποίησης εμπειρικής διακινδύνευσης.

Βλέπε επίσης: loss, υπόθεση, ετικέτα, data point, σύνολο εκπαίδευσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης.

**σφάλμα εκτίμησης** Θεωρούμε σημεία δεδομένων, καθένα με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ . Σε κάποιες εφαρμογές, μπορούμε να μοντελοποιήσουμε τη σχέση μεταξύ του διανύσματος χαρακτηριστικών και της ετικέτας ενός σημείου δεδομένων ως  $y = \bar{h}(\mathbf{x}) + \varepsilon$ . Εδώ χρησιμοποιούμε κάποια αληθή υποκείμενη υπόθεση  $\bar{h}$  και έναν όρο θορύβου  $\varepsilon$ , ο οποίος συνοψίζει οποιαδήποτε σφάλματα μοντελοποίησης ή ετικετοποίησης. Το σφάλμα εκτίμησης που προκαλείται από μία μέθοδο μηχανικής μάθησης που μαθαίνει μία υπόθεση  $\hat{h}$ , π.χ. χρησιμοποιώντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης, ορίζεται ως  $\hat{h}(\mathbf{x}) - \bar{h}(\mathbf{x})$ , για κάποιο διάνυσμα χαρακτηριστικών. Για έναν παραμετρικό χώρο υποθέσεων, ο οποίος αποτελείται από maps υπόθεσης καθορισμένες από παραμέτρους του μοντέλου  $\mathbf{w}$ , μπορούμε να ορίσουμε το σφάλμα εκτίμησης ως  $\Delta \mathbf{w} = \hat{\mathbf{w}} - \bar{\mathbf{w}}$  [47], [82].

Βλέπε επίσης: data point, διάνυσμα χαρακτηριστικών, ετικέτα, υπόθεση, ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, χώρος υποθέσεων, map, παράμετροι μοντέλου.

**σφάλμα επικύρωσης** Θεωρούμε μία υπόθεση  $\hat{h}$  που προκύπτει από κάποια μέθοδο μηχανικής μάθησης, π.χ. χρησιμοποιώντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης σε ένα σύνολο εκπαίδευσης. Η μέση απώλεια

της  $\hat{h}$  σε ένα σύνολο επικύρωσης, το οποίο είναι διαφορετικό από το σύνολο εκπαίδευσης, αναφέρεται ως το σφάλμα επικύρωσης.

Βλέπε επίσης: υπόθεση, ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, loss, σύνολο επικύρωσης, επικύρωση.

**ταξινόμηση** Η ταξινόμηση είναι μία εργασία καθορισμού μίας ετικέτας διακριτής τιμής  $y$  για ένα δεδομένο σημείο δεδομένων, βασισμένη μόνο στα χαρακτηριστικά του  $\mathbf{x}$ . Η ετικέτα  $y$  ανήκει σε ένα πεπερασμένο σύνολο, όπως  $y \in \{-1, 1\}$  ή  $y \in \{1, \dots, 19\}$ , και αντιπροσωπεύει την κατηγορία στην οποία ανήκει το αντίστοιχο σημείο δεδομένων.

Βλέπε επίσης: ετικέτα, data point, feature.

**ταξινομητής** Ένας ταξινομητής είναι μία υπόθεση (δηλαδή μία map)  $h(\mathbf{x})$  που χρησιμοποιείται για να προβλεφθεί μία ετικέτα που παίρνει τιμές από ένα πεπερασμένο χώρο ετικετών. Μπορεί να χρησιμοποιήσουμε την ίδια την τιμή συνάρτησης  $h(\mathbf{x})$  ως μία πρόβλεψη  $\hat{y}$  για την ετικέτα. Ωστόσο, είναι σύνηθες να χρησιμοποιούμε μία map  $h(\cdot)$  που παραδίδει μία αριθμητική ποσότητα. Η πρόβλεψη έπειτα προκύπτει από ένα απλό βήμα κατωφλιού. Για παράδειγμα, σε ένα πρόβλημα δυαδικής ταξινόμησης με ένα χώρο ετικετών  $\mathcal{Y} \in \{-1, 1\}$ , μπορεί να χρησιμοποιήσουμε μία map υπόθεσης πραγματικής τιμής  $h(\mathbf{x}) \in \mathbb{R}$  ως ταξινομητή. Μία πρόβλεψη  $\hat{y}$  μπορεί έπειτα να προκύψει μέσω κατωφλιού,

$$\hat{y} = 1 \text{ για } h(\mathbf{x}) \geq 0 \text{ και } \hat{y} = -1 \text{ διαφορετικά.} \quad (7)$$


Μπορούμε να χαρακτηρίσουμε έναν ταξινομητή από τις περιοχές αποφάσεων  $\mathcal{R}_a$ , για κάθε πιθανή τιμή ετικέτας  $a \in \mathcal{Y}$ .

Βλέπε επίσης: υπόθεση, map, ετικέτα, χώρος ετικετών, συνάρτηση, πρόβλεψη, ταξινόμηση, περιοχή αποφάσεων.

**τελεστής εγγύτητας** Δεδομένης μίας κυρτής συνάρτησης  $f(\mathbf{w}')$ , ορίζουμε τον τελεστή εγγύτητάς της ως [42], [107]

$$\text{prox}_{f(\cdot),\rho}(\mathbf{w}) := \arg \min_{\mathbf{w}' \in \mathbb{R}^d} \left[ f(\mathbf{w}') + \frac{\rho}{2} \|\mathbf{w} - \mathbf{w}'\|_2^2 \right] \text{ με } \rho > 0.$$

Όπως απεικονίζεται στο Σχ. 47, η αξιολόγηση του τελεστή εγγύτητας ισοδυναμεί με την ελαχιστοποίηση μίας παραλλαγής της  $f(\mathbf{w}')$  που έχει επιβληθεί ως ποινή. Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια απόσταση σε ένα δεδομένο διάνυσμα  $\mathbf{w}$  (το οποίο είναι η είσοδος στον τελεστή εγγύτητας). Ο τελεστής εγγύτητας μπορεί να ερμηνευτεί ως μία γενίκευση του βήματος κλίσης, το οποίο ορίζεται ως μία λεία κυρτή συνάρτηση  $f(\mathbf{w}')$ . Πράγματι, η εκτέλεση ενός βήματος κλίσης με μέγεθος βήματος  $\eta$  στο τρέχον διάνυσμα  $\mathbf{w}$  είναι το ίδιο με την εφαρμογή του τελεστή εγγύτητας της συνάρτησης  $\tilde{f}(\mathbf{w}') = (\nabla f(\mathbf{w}))^T (\mathbf{w}' - \mathbf{w})$  και τη χρήση  $\rho = 1/\eta$ .



Σχ. 47. Ο τελεστής εγγύτητας ενημερώνει ένα διάνυσμα  $\mathbf{w}$  ελαχιστοποιώντας μία εκδοχή της συνάρτησης  $f(\cdot)$  που έχει επιβληθεί ως ποινή. Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια απόσταση μεταξύ της μεταβλητής βελτιστοποίησης  $\mathbf{w}'$  και του δεδομένου διανύσματος  $\mathbf{w}$ .

Βλέπε επίσης: *convex*, συνάρτηση, διάνυσμα, γενίκευση, βήμα κλίσης, λεία, μέγεθος βήματος.

**τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής** Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής (least absolute shrinkage and selection operator - Lasso) είναι μία περίπτωση ελαχιστοποίησης δομικής διακινδύνευσης. Μαθαίνει τα βάρη  $\mathbf{w}$  μίας linear map  $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  από ένα σύνολο εκπαίδευσης. Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής προκαλείται από γραμμική παλινδρόμηση προσθέτοντας την ανηγμένη  $\ell_1$ -νόρμα  $\alpha \|\mathbf{w}\|_1$  στη μέση απώλεια τετραγωνικού σφάλματος που προκύπτει στο σύνολο εκπαίδευσης.

Βλέπε επίσης: ελαχιστοποίηση δομικής διακινδύνευσης, βάρη, linear map, σύνολο εκπαίδευσης, γραμμική παλινδρόμηση, νόρμα, απώλεια τετραγωνικού σφάλματος.

**τετραγωνική συνάρτηση** Μία συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  της μορφής

$$f(\mathbf{w}) = \mathbf{w}^T \mathbf{Q} \mathbf{w} + \mathbf{q}^T \mathbf{w} + a$$

με κάποιον πίνακα  $\mathbf{Q} \in \mathbb{R}^{d \times d}$ , διάνυσμα  $\mathbf{q} \in \mathbb{R}^d$ , και βαθμωτό  $a \in \mathbb{R}$ .

Βλέπε επίσης: συνάρτηση, πίνακας, διάνυσμα.

**τεχνητή νοημοσύνη (TN)** Η τεχνητή νοημοσύνη (artificial intelligence

- AI) αναφέρεται σε συστήματα που συμπεριφέρονται λογικά με την έννοια της μεγιστοποίησης μίας μακροπρόθεσμης ανταμοιβής. Η προσέγγιση στην τεχνητή νοημοσύνη με βάση τη μηχανική μάθηση είναι να εκπαιδευτεί ένα μοντέλο για να προβλέπει βέλτιστες ενέργειες. Αυτές οι προβλέψεις υπολογίζονται από παρατηρήσεις σχετικά με την κατάσταση του περιβάλλοντος. Η επιλογή της συνάρτησης απώλειας διαφοροποιεί τις εφαρμογές της τεχνητής νοημοσύνης από πιο βασικές εφαρμογές της μηχανικής μάθησης. Τα συστήματα της τεχνητής νοημοσύνης σπάνια έχουν πρόσβαση σε ένα σύνολο εκπαίδευσης με ετικέτες που να επιτρέπει τη μέτρηση της μέσης απώλειας για οποιαδήποτε πιθανή επιλογή παραμέτρων μοντέλου. Αντίθετα, τα συστήματα της τεχνητής νοημοσύνης χρησιμοποιούν παρατηρούμενα σήματα ανταμοιβής για να εκτιμήσουν την απώλεια που προκύπτει από την τρέχουσα επιλογή παραμέτρων μοντέλου. Βλέπε επίσης: ανταμοιβή, ml, model, συνάρτηση απώλειας, σύνολο εκπαίδευσης, loss, παράμετροι μοντέλου, RL.

**τεχνητό νευρωνικό δίκτυο (ΤΝΔ)** Ένα τεχνητό νευρωνικό δίκτυο (artificial neural network - ANN) είναι μία γραφική (ροή σήματος) αναπαράσταση μίας συνάρτησης που αντιστοιχεί τα χαρακτηριστικά ενός



σημείου δεδομένων κατά την είσοδό του σε μία πρόβλεψη για την σχετική ετικέτα κατά την έξοδό του. Η θεμελιώδης μονάδα ενός τεχνητού νευρωνικού δικτύου είναι ο τεχνητός νευρώνας, ο οποίος εφαρμόζει μία συνάρτηση ενεργοποίησης στις σταθμισμένες εισόδους του. Οι έξοδοι αυτών των νευρώνων χρησιμεύουν ως είσοδοι για άλλους νευρώνες, σχηματίζοντας διασυνδεδεμένα στρώματα.

Βλέπε επίσης: συνάρτηση, feature, data point, πρόβλεψη, ετικέτα, συνάρτηση ενεργοποίησης, στρώμα.

**τοπικό μοντέλο** Θεωρούμε μία συλλογή συσκευών που αναπαριστώνται ως κόμβοι  $\mathcal{V}$  ενός δικτύου ομοσπονδιακής μάθησης. Ένα τοπικό μοντέλο (local model)  $\mathcal{H}^{(i)}$  είναι ένας χώρος υποθέσεων εκχωρημένος σε έναν κόμβο  $i \in \mathcal{V}$ . Διαφορετικοί κόμβοι μπορεί να έχουν διαφορετικούς χώρους υποθέσεων, δηλαδή, γενικά,  $\mathcal{H}^{(i)} \neq \mathcal{H}^{(i')}$  για διαφορετικούς κόμβους  $i, i' \in \mathcal{V}$ . Βλέπε επίσης: συσκευή, δίκτυο ομοσπονδιακής μάθησης, model, χώρος υποθέσεων.

**τοπικό σύνολο δεδομένων** Η έννοια του τοπικού συνόλου δεδομένων είναι μεταξύ της έννοιας ενός σημείου δεδομένων και ενός συνόλου δεδομένων. Ένα τοπικό σύνολο δεδομένων αποτελείται από αρκετά μεμονωμένα σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά και ετικέτες. Σε αντίθεση με ένα μονό σύνολο δεδομένων που χρησιμοποιείται σε βασικές μεθόδους μηχανικής μάθησης, ένα τοπικό σύνολο δεδομένων σχετίζεται επίσης με άλλα τοπικά σύνολα δεδομένων μέσω διαφορετικών εννοιών ομοιότητας. Αυτές οι ομοιότητες μπορεί να ανακύψουν από πιθανοτικά μοντέλα ή υποδομές επικοινωνίας και είναι κωδικοποιημένες στις

ακμές ενός δικτύου ομοσπονδιακής μάθησης.

Βλέπε επίσης: σύνολο δεδομένων, data point, feature, ετικέτα, ml, πιθανοτικό μοντέλο, δίκτυο ομοσπονδιακής μάθησης.

**τυχαία μεταβλητή** Μία τυχαία μεταβλητή (random variable - RV) είναι μία συνάρτηση που αντιστοιχεί τα αποτελέσματα ενός τυχαίου πειράματος σε έναν χώρο τιμών [6], [18]. Από μαθηματικής άποψης, μία τυχαία μεταβλητή είναι μία συνάρτηση  $x : \Omega \rightarrow \mathcal{X}$  που ορίζεται πάνω στον δειγματικό χώρο  $\Omega$  ενός χώρου πιθανοτήτων. Διαφορετικοί τύποι τυχαίων μεταβλητών περιλαμβάνουν

- δυαδικές τυχαίες μεταβλητές, οι οποίες αντιστοιχούν κάθε αποτέλεσμα σε ένα στοιχείο ενός δυαδικού συνόλου (π.χ.  $\{-1, 1\}$  ή  $\{\text{γάτα}, \text{όχι γάτα}\}$ ).
- τυχαίες μεταβλητές πραγματικής τιμής, οι οποίες παίρνουν τιμές στους πραγματικούς αριθμούς  $\mathbb{R}$ .
- τυχαίες μεταβλητές διανυσματικής τιμής, οι οποίες αντιστοιχούν αποτελέσματα στον Ευκλείδειο χώρο  $\mathbb{R}^d$ .

Η θεωρία πιθανοτήτων χρησιμοποιεί την έννοια των μετρήσιμων χώρων για να ορίσει ενδελεχώς και να μελετήσει τις ιδιότητες συλλογών τυχαίων μεταβλητών [6].


Βλέπε επίσης: συνάρτηση, τυχαίο πείραμα, δειγματικός χώρος, χώρος πιθανοτήτων, διάνυσμα, Ευκλείδειος χώρος, probability, μετρήσιμο.

**τυχαίο δάσος** Ένα τυχαίο δάσος (random forest) είναι ένα σύνολο διαφορετικών δέντρων αποφάσεων. Καθένα από αυτά τα δέντρα αποφάσεων

προκύπτει από την προσαρμογή ενός διαταραγμένου αντιγράφου του αρχικού συνόλου δεδομένων.

Βλέπε επίσης: decision tree, σύνολο δεδομένων.

**τυχαίο πείραμα** Ένα τυχαίο πείραμα είναι μία φυσική (ή αφηρημένη) διαδικασία που παράγει ένα αποτέλεσμα  $\omega$  από ένα σύνολο πιθανοτήτων  $\Omega$ . Αυτό το σύνολο όλων των πιθανών αποτελεσμάτων αναφέρεται ως ο δειγματικός χώρος του πειράματος. Το βασικότερο χαρακτηριστικό ενός τυχαίου πειράματος είναι ότι το αποτέλεσμά του είναι απρόβλεπτο (ή αβέβαιο). Οποιαδήποτε μέτρηση ή παρατήρηση του αποτελέσματος είναι μία τυχαία μεταβλητή, δηλαδή μία συνάρτηση του αποτελέσματος  $\omega \in \Omega$ . Η θεωρία πιθανοτήτων χρησιμοποιεί έναν χώρο πιθανοτήτων ως μία μαθηματική δομή για τη μελέτη τυχαίων πειραμάτων. Μία κύρια εννοιολογική ιδιότητα ενός τυχαίου πειράματος είναι ότι μπορεί να επαναληφθεί υπό ταυτόσημες συνθήκες. Αυστηρά μιλώντας, η επανάληψη ενός τυχαίου πειράματος έναν δεδομένο αριθμό  $m$  φορών ορίζει ένα νέο τυχαίο πείραμα. Τα αποτελέσματα αυτού του νέου πειράματος είναι ακολουθίες μήκους  $m$  αποτελεσμάτων από το αρχικό πείραμα (βλέπε Σχ. 48). Ενώ το αποτέλεσμα ενός μοναδικού πειράματος είναι αβέβαιο, η μακροπρόθεσμη συμπεριφορά των αποτελεσμάτων επαναλαμβανόμενων πειραμάτων τείνει να γίνεται ολοένα και περισσότερο προβλέψιμη. Αυτός ο ανεπίσημος ισχυρισμός μπορεί να γίνει ακριβής μέσω θεμελιωδών αποτελεσμάτων της θεωρίας πιθανοτήτων, όπως ο νόμος των μεγάλων αριθμών και το κεντρικό οριακό θεώρημα.



Σχ. 48. Ένα τυχαίο πείραμα παράγει ένα αποτέλεσμα  $\omega \in \Omega$  από ένα σύνολο πιθανοτήτων (ή δειγματικό χώρο)  $\Omega$ . Η επανάληψη του πειράματος  $m$  φορές αποφέρει ένα άλλο τυχαίο πείραμα, του οποίου τα αποτελέσματα είναι ακολουθίες  $(\omega^{(1)}, \omega^{(2)}, \dots, \omega^{(m)}) \in \Omega \times \dots \times \Omega$ . Ένα παράδειγμα τυχαίου πειράματος που προκύπτει σε πολλές εφαρμογές μηχανικής μάθησης είναι η συγκέντρωση ενός συνόλου εκπαίδευσης  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ .

Παραδείγματα τυχαίων πειραμάτων που προκύπτουν σε εφαρμογές μηχανικής μάθησης περιλαμβάνουν τα εξής:

- Συλλογή δεδομένων: Τα σημεία δεδομένων που συλλέγονται σε μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης μπορούν να ερμηνευτούν ως τυχαίες μεταβλητές, δηλαδή ως συναρτήσεις του αποτελέσματος  $\omega \in \Omega$  ενός τυχαίου πειράματος.
- Η στοχαστική κάθοδος κλίσης χρησιμοποιεί ένα τυχαίο πείραμα σε κάθε επανάληψη για την επιλογή ενός υποσυνόλου του συνόλου εκπαίδευσης.

- Οι μέθοδοι προστασίας της ιδιωτικότητας χρησιμοποιούν τυχαία πειράματα για να παραγάγουν θόρυβο που προστίθεται στις εξόδους μίας μεθόδου μηχανικής μάθησης για να εξασφαλιστεί η διαφορική ιδιωτικότητα.

Βλέπε επίσης: δειγματικός χώρος, τυχαία μεταβλητή, συνάρτηση, probability, χώρος πιθανοτήτων, νόμος των μεγάλων αριθμών, κεντρικό οριακό θεώρημα, δειγματικός χώρος, ml, σύνολο εκπαίδευσης, data, data point, ελαχιστοποίηση εμπειρικής διακινδύνευσης, στοχαστική κάθοδος κλίσης, προστασία της ιδιωτικότητας, διαφορική ιδιωτικότητα.

**υπερπροσαρμογή** Θεωρούμε μία μέθοδο μηχανικής μάθησης που χρησιμοποιεί ελαχιστοποίηση εμπειρικής διακινδύνευσης για να μάθει μία υπόθεση με την ελάχιστη εμπειρική διακινδύνευση σε ένα δεδομένο σύνολο εκπαίδευσης. Μία τέτοια μέθοδος υπερπροσαρμόζει το σύνολο εκπαίδευσης αν μάθει μία υπόθεση με μία χαμηλή εμπειρική διακινδύνευση στο σύνολο εκπαίδευσης αλλά με μία σημαντικά υψηλότερη απώλεια έξω από το σύνολο εκπαίδευσης.

Βλέπε επίσης: ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, ελάχιστο, empirical risk, σύνολο εκπαίδευσης, loss, γενίκευση, επικύρωση, generalization gap.

**υπόθεση** Μία υπόθεση (hypothesis) αναφέρεται σε μία map (ή συνάρτηση)  $h : \mathcal{X} \rightarrow \mathcal{Y}$  από τον χώρο χαρακτηριστικών  $\mathcal{X}$  στον χώρο ετικετών  $\mathcal{Y}$ . Δεδομένου ενός σημείου δεδομένων με χαρακτηριστικά  $\mathbf{x}$ , χρησιμοποιούμε μία map υπόθεσης  $h$  για να εκτιμήσουμε (ή να προσεγγίσουμε) την ετικέτα  $y$  χρησιμοποιώντας την πρόβλεψη  $\hat{y} = h(\mathbf{x})$ . Η μηχανική μάθηση

έχει σχέση με τη μάθηση (ή εύρεση) μίας map υπόθεσης  $h$ , έτσι ώστε  $y \approx h(\mathbf{x})$  για οποιοδήποτε σημείο δεδομένων (με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ ).

Βλέπε επίσης: map, συνάρτηση, χώρος χαρακτηριστικών, χώρος ετικετών, data point, feature, ετικέτα, πρόβλεψη, ml, model.

**υποκλίση** Για μία συνάρτηση πραγματικής τιμής  $f : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{w} \mapsto f(\mathbf{w})$ , ένα διάνυσμα  $\mathbf{a}$  τέτοιο ώστε  $f(\mathbf{w}) \geq f(\mathbf{w}') + (\mathbf{w} - \mathbf{w}')^T \mathbf{a}$  αναφέρεται ως μία υποκλίση της  $f$  στο  $\mathbf{w}'$  [108], [14].

Βλέπε επίσης: συνάρτηση, διάνυσμα.

**υπολογιστικές διαστάσεις** Με τις υπολογιστικές διαστάσεις (computational aspects) μίας μεθόδου μηχανικής μάθησης, αναφερόμαστε κυρίως στους υπολογιστικούς πόρους που απαιτούνται για την εκτέλεσή της. Για παράδειγμα, αν μία μέθοδος μηχανικής μάθησης χρησιμοποιεί επαναληπτικές τεχνικές βελτιστοποίησης για να λύσει την ελαχιστοποίηση εμπειρικής διακινδύνευσης, τότε οι υπολογιστικές διαστάσεις της περιλαμβάνουν: 1) πόσες αριθμητικές πράξεις χρειάζονται για να εκτελεστεί μία μονή επανάληψη (δηλαδή ένα βήμα κλίσης)· και 2) πόσες επαναλήψεις χρειάζονται για να προκύψουν χρήσιμες παράμετροι μοντέλου. Ένα σημαντικό παράδειγμα μίας επαναληπτικής τεχνικής βελτιστοποίησης είναι η κάθοδος κλίσης.


Βλέπε επίσης: ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, βήμα κλίσης, παράμετροι μοντέλου, κάθοδος κλίσης.

**υποπροσαρμογή** Θεωρούμε μία μέθοδο μηχανικής μάθησης που χρησιμοποιεί την ελαχιστοποίηση εμπειρικής διακινδύνευσης για να μάθει μία υ-

πόθεση με την ελάχιστη εμπειρική διακινδύνευση σε ένα δεδομένο σύνολο εκπαίδευσης. Μία τέτοια μέθοδος υποπροσαρμόζει το σύνολο εκπαίδευσης αν δεν έχει τη δυνατότητα να μάθει μία υπόθεση με μία επαρκώς χαμηλή εμπειρική διακινδύνευση στο σύνολο εκπαίδευσης. Αν η μέθοδος υποπροσαρμόζει, συνήθως επίσης δεν θα έχει τη δυνατότητα να μάθει μία υπόθεση με μία χαμηλή διακινδύνευση.


Βλέπε επίσης: ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, ελάχιστο, empirical risk, σύνολο εκπαίδευσης, διακινδύνευση.

**φασματική συσταδοποίηση** Η φασματική συσταδοποίηση είναι μία συγκεκριμένη περίπτωση συσταδοποίησης γράφου, δηλαδή ομαδοποιεί σημεία δεδομένων που αναπαριστώνται ως οι κόμβοι  $i = 1, \dots, n$  ενός γράφου  $\mathcal{G}$ . Η φασματική συσταδοποίηση χρησιμοποιεί τα ιδιοδιανύσματα του πίνακα Laplace  $\mathbf{L}^{(\mathcal{G})}$  για να κατασκευάσει διανύσματα χαρακτηριστικών  $\mathbf{x}^{(i)} \in \mathbb{R}^d$  για κάθε κόμβο (δηλαδή για κάθε σημείο δεδομένων)  $i = 1, \dots, n$ . Μπορούμε να τροφοδοτήσουμε αυτά τα διανύσματα χαρακτηριστικών σε μεθόδους συσταδοποίησης βασισμένες στον Ευκλείδειο χώρο, όπως τον αλγόριθμο  $k$ -μέσων ή τη μαλακή συσταδοποίηση μέσω GMM. Στο περίπου, τα διανύσματα χαρακτηριστικών των κόμβων που ανήκουν σε ένα καλά συνδεδεμένο υποσύνολο (ή συστάδα) κόμβων στο  $\mathcal{G}$  βρίσκονται κοντά στον Ευκλείδειο χώρο  $\mathbb{R}^d$  (βλέπε Σχ. 49).



$$\mathbf{L}^{(\mathcal{G})} = \begin{pmatrix} 2 & -1 & -1 & 0 \\ -1 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$$

(b)



$$\mathbf{V} = (\mathbf{v}^{(1)}, \mathbf{v}^{(2)}, \mathbf{v}^{(3)}, \mathbf{v}^{(4)})$$

$$\mathbf{v}^{(1)} = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}^{(2)} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}$$

(d)

Σχ. 49. (a) Ένας μη κατευθυνόμενος γράφος  $\mathcal{G}$  με τέσσερις κόμβους  $i = 1, 2, 3, 4$ , ο καθένας από τους οποίους αναπαριστά ένα σημείο δεδομένων. (b) Ο πίνακας Laplace  $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{4 \times 4}$  και η ανάλυση ιδιοτιμών του. (c) Ένα διάγραμμα διασποράς των σημείων δεδομένων που χρησιμοποιούν τα διανύσματα χαρακτηριστικών  $\mathbf{x}^{(i)} = (v_i^{(1)}, v_i^{(2)})^T$ . (d) Δύο ιδιοδιανύσματα  $\mathbf{v}^{(1)}, \mathbf{v}^{(2)} \in \mathbb{R}^d$  που αντιστοιχούν στην ιδιοτιμή  $\lambda = 0$  του πίνακα Laplace  $\mathbf{L}^{(\mathcal{G})}$ .



Βλέπε επίσης: συσταδοποίηση, συσταδοποίηση γράφου, data point, graph, ιδιοδιάνυσμα, πίνακας Laplace, διάνυσμα χαρακτηριστικών, Ευκλείδειος χώρος, αλγόριθμος  $k$ -μέσων, soft clustering, GMM, συστάδα, ανάλυση ιδιοτιμών, διάγραμμα διασποράς, ιδιοτιμή.

**Φινλανδικό Μετεωρολογικό Ινστιτούτο** Το Φινλανδικό Μετεωρολογικό Ινστιτούτο (Finnish Meteorological Institute - FMI) είναι μία κυβερνητική υπηρεσία που είναι υπεύθυνη για τη συγκέντρωση και την έκθεση δεδομένων καιρού στη Φινλανδία.

Βλέπε επίσης: data.

**χαρακτηριστικό** Ένα χαρακτηριστικό ενός σημείου δεδομένων είναι μία από τις ιδιότητες που μπορούν να μετρηθούν ή να υπολογιστούν εύκολα χωρίς την ανάγκη ανθρώπινης εποπτείας. Για παράδειγμα, αν ένα σημείο δεδομένων είναι μία ψηφιακή εικόνα (π.χ. αποθηκευμένη ως ένα αρχείο .jpeg), τότε θα μπορούσαμε να χρησιμοποιήσουμε τις εντάσεις κόκκινου-πράσινου-μπλε (red-green-blue - RGB) των εικονοστοιχείων της ως χαρακτηριστικά. Συνώνυμα του όρου χαρακτηριστικό που χρησιμοποιούνται ανάλογα με το πεδίο είναι «συμμεταβλητή», «εξηγηματική μεταβλητή», «ανεξάρτητη μεταβλητή», «είσοδος (μεταβλητή)», «προβλέπουσα (μεταβλητή)», ή «παλινδρομούσα μεταβλητή» [73], [74], [75].

Βλέπε επίσης: data point.

**χάρτης χαρακτηριστικών** A feature map refers to a συνάρτηση

$$\Phi : \mathcal{X} \rightarrow \mathcal{X}', \quad \mathbf{x} \mapsto \mathbf{x}'$$

that transforms a διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathcal{X}$  of a data point into a new διάνυσμα χαρακτηριστικών  $\mathbf{x}' \in \mathcal{X}'$ , where  $\mathcal{X}'$  is typically different from  $\mathcal{X}$ . The transformed representation  $\mathbf{x}'$  is often more useful than the original  $\mathbf{x}$ . For instance, the geometry of data points may become more linear in  $\mathcal{X}'$ , allowing the application of a γραμμικό μοντέλο to  $\mathbf{x}'$ . This idea is central to the design of kernel methods [76]. Other benefits of using a feature map include reducing υπερπροσαρμογή and improving ερμηνευσιμότητα [46]. A common use case is data visualization, where a feature map with two output dimensions allows the representation of data points in a 2-D διάγραμμα διασποράς. Some ml methods employ trainable feature maps, whose παράμετρος are learned from data. An example is the use of hidden στρώμας in a βαθύ δίκτυο, which act as successive feature maps [44]. A principled way to train a feature map is through ελαχιστοποίηση εμπειρικής διακινδύνευσης, using a συνάρτηση απώλειας that measures reconstruction quality, e.g.,  $L = \|\mathbf{x} - r(\mathbf{x}')\|^2$ , where  $r(\cdot)$  is a trainable map that attempts to reconstruct  $\mathbf{x}$  from the transformed διάνυσμα χαρακτηριστικών  $\mathbf{x}'$ .

Βλέπε επίσης: feature, map, συνάρτηση, διάνυσμα χαρακτηριστικών, data point, γραμμικό μοντέλο, kernel method, υπερπροσαρμογή, ερμηνευσιμότητα, data, διάγραμμα διασποράς, ml, παράμετρος, στρώμα, βαθύ δίκτυο, ελαχιστοποίηση εμπειρικής διακινδύνευσης, συνάρτηση απώλειας, μάθηση χαρακτηριστικών, principal component analysis.

**χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα**

DBSCAN (density-based spatial clustering of applications with noise - DBSCAN) refers to a συσταδοποίηση αλγόριθμος for data points that

are characterized by numeric διάνυσμα χαρακτηριστικών. Like αλγόριθμος  $k$ -μέσων and soft clustering via GMM, DBSCAN also uses the Euclidean distances between διάνυσμα χαρακτηριστικών to determine the συστάδας. However, in contrast to αλγόριθμος  $k$ -μέσων and GMM, DBSCAN uses a different notion of similarity between data points. DBSCAN considers two data points as similar if they are connected via a sequence (path) of nearby intermediate data points. Thus, DBSCAN might consider two data points as similar (and therefore belonging to the same cluster) even if their διάνυσμα χαρακτηριστικών have a large Euclidean distance.


Βλέπε επίσης: συσταδοποίηση, αλγόριθμος, data point, διάνυσμα χαρακτηριστικών, αλγόριθμος  $k$ -μέσων, soft clustering, GMM, συστάδα, graph.

**χώρος ετικετών** Θεωρούμε μία εφαρμογή μηχανικής μάθησης που περιλαμβάνει σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά και ετικέτες. Ο χώρος ετικετών αποτελείται από όλες τις πιθανές τιμές που η ετικέτα ενός σημείου δεδομένων μπορεί να πάρει. Οι μέθοδοι παλινδρόμησης, που στοχεύουν να προβλέψουν αριθμητικές ετικέτες, συχνά χρησιμοποιούν τον χώρο ετικετών  $\mathcal{Y} = \mathbb{R}$ . Μέθοδοι δυαδικής ταξινόμησης χρησιμοποιούν έναν χώρο ετικετών που αποτελείται από δύο διαφορετικά στοιχεία, π.χ.

- $\mathcal{Y} = \{-1, 1\}$ .
- $\mathcal{Y} = \{0, 1\}$ .
- $\mathcal{Y} = \{\text{«εικόνα γάτας»}, \text{«όχι εικόνα γάτας»}\}$ .

Βλέπε επίσης: ml, data point, feature, ετικέτα, regression, ταξινόμηση.

**χώρος παραμέτρων** Ο χώρος παραμέτρων  $\mathcal{W}$  ενός μοντέλου μηχανικής μάθησης  $\mathcal{H}$  είναι το σύνολο όλων των εφικτών επιλογών για τις παραμέτρους του μοντέλου (βλέπε Σχ. 50). Πολλές σημαντικές μέθοδοι μηχανικής μάθησης χρησιμοποιούν ένα μοντέλο που είναι παραμετροποιημένο με διανύσματα του Ευκλείδειου χώρου  $\mathbb{R}^d$ . Δύο ευρέως χρησιμοποιούμενα παραδείγματα παραμετροποιημένων μοντέλων είναι τα γραμμικά μοντέλα και τα βαθιά δίκτυα. Ο χώρος παραμέτρων είναι συχνά τότε ένα υποσύνολο  $\mathcal{W} \subseteq \mathbb{R}^d$ , π.χ. όλα τα διανύσματα  $\mathbf{w} \in \mathbb{R}^d$  με μία νόρμα μικρότερη από ένα.



Σχ. 50. Ο χώρος παραμέτρων  $\mathcal{W}$  ενός μοντέλου μηχανικής μάθησης  $\mathcal{H}$  αποτελείται από όλες τις εφικτές επιλογές για τις παραμέτρους του μοντέλου. Κάθε επιλογή  $\mathbf{w}$  για τις παραμέτρους του μοντέλου επιλέγει μία μαπ υπόθεσης  $h(\mathbf{w}) \in \mathcal{H}$ .

Βλέπε επίσης: παράμετρος, ml, model, παράμετροι μοντέλου, διάνυσμα, Ευκλείδειος χώρος, γραμμικό μοντέλο, βαθύ δίκτυο, νόρμα, υπόθεση, map.

**χώρος πιθανοτήτων** Ένας χώρος πιθανοτήτων είναι μία μαθηματική δομή

που μας επιτρέπει να συλλογιστούμε για ένα τυχαίο πείραμα, π.χ. την παρατήρηση ενός φυσικού φαινομένου. Τυπικά, ένας χώρος πιθανοτήτων  $\mathcal{P}$  είναι μία τριάδα  $(\Omega, \mathcal{F}, \mathbb{P}(\cdot))$ , όπου

- $\Omega$  είναι ένας δειγματικός χώρος που περιλαμβάνει όλα τα πιθανά αποτελέσματα ενός τυχαίου πειράματος.
- $\mathcal{F}$  είναι μία  $\sigma$ -άλγεβρα, δηλαδή μία συλλογή υποσυνόλων του  $\Omega$  (που ονομάζονται γεγονότα) που ικανοποιεί ορισμένες ιδιότητες κλειστότητας υπό ένα σύνολο πράξεων.
- $\mathbb{P}(\cdot)$  είναι μία κατανομή πιθανότητας, δηλαδή μία συνάρτηση που αποδίδει μία πιθανότητα  $P(\mathcal{A}) \in [0, 1]$  σε κάθε γεγονός  $\mathcal{A} \in \mathcal{F}$ . Αυτή η συνάρτηση πρέπει να ικανοποιεί  $\mathbb{P}(\Omega) = 1$  και  $\mathbb{P}(\bigcup_{i=1}^{\infty} \mathcal{A}_i) = \sum_{i=1}^{\infty} \mathbb{P}(\mathcal{A}_i)$  για οποιαδήποτε μετρήσιμη ακολουθία κατά ζεύγη ξένων γεγονότων  $\mathcal{A}_1, \mathcal{A}_2, \dots$  στο  $\mathcal{F}$ .

Οι χώροι πιθανοτήτων παρέχουν τη θεμελίωση των πιθανοτικών μοντέλων που μπορούν να χρησιμοποιηθούν για να μελετηθεί η συμπεριφορά των μεθόδων μηχανικής μάθησης [6], [18], [109].

Βλέπε επίσης: probability, τυχαίο πείραμα, δειγματικός χώρος, γεγονός, κατανομή πιθανότητας, συνάρτηση, πιθανοτικό μοντέλο, ml.

**χώρος υποθέσεων** A hypothesis space is a mathematical model that characterizes the learning capacity of an ml method. The goal of such a method is to learn a υπόθεση map that maps features of a data point to a πρόβλεψη of its ετικέτα. Given a finite amount of computational resources, a practical ml method typically explores only a restricted set of all possible maps from the χώρος χαρακτηριστικών to the χώρος

ετικετών. Such a restricted set is referred to as a υπόθεση space  $\mathcal{H}$  underlying the ml method (see Fig. 51). For the analysis of a given ml method, the choice of a υπόθεση space  $\mathcal{H}$  is not unique, i.e., any superset containing all maps the method can learn is also a valid υπόθεση space.




Fig. 51. The υπόθεση space  $\mathcal{H}$  of an ml method is a (typically very small) subset of the (typically very large) set  $\mathcal{Y}^{\mathcal{X}}$  of all possible maps from the χώρος χαρακτηριστικών  $\mathcal{X}$  into the χώρος ετικετών  $\mathcal{Y}$ .

On the other hand, from an ml engineering perspective, the υπόθεση space  $\mathcal{H}$  is a design choice for ελαχιστοποίηση εμπειρικής διακινδύνευσης-based methods. This design choice can be guided by the available computational resources and στατιστικές διαστάσεις. For instance, if efficient πίνακας operations are feasible and a roughly linear relation exists between features and ετικέτας, a γραμμικό μοντέλο can be a useful choice for  $\mathcal{H}$ .

Βλέπε επίσης: υπόθεση, model, ml, map, feature, data point, πρόβλεψη, ετικέτα, χώρος χαρακτηριστικών, χώρος ετικετών, ελαχιστοποίηση εμπειρικής διακινδύνευσης, στατιστικές διαστάσεις, πίνακας, γραμμικό μοντέλο.

**χώρος χαρακτηριστικών** Ο χώρος χαρακτηριστικών

Βλέπε επίσης: feature, ml, διάνυσμα χαρακτηριστικών, data point, Ευκλείδειος χώρος, μάθηση χαρακτηριστικών, convex, graph.

**χώρος Hilbert** Ένας χώρος Hilbert είναι ένας πλήρης χώρος με εσωτερικό γινόμενο [110]. Για την ακρίβεια, είναι ένας διανυσματικός χώρος εξοπλισμένος με ένα εσωτερικό γινόμενο μεταξύ ζευγών διανυσμάτων, και πληροί την πρόσθετη προϋπόθεση της πληρότητας, δηλαδή κάθε ακολουθία Cauchy διανυσμάτων συγκλίνει σε ένα όριο εντός του χώρου. Ένα κανονικό παράδειγμα ενός χώρου Hilbert είναι ο Ευκλείδειος χώρος  $\mathbb{R}^d$ , για κάποια διάσταση  $d$ , που αποτελείται από διανύσματα  $\mathbf{u} = (u_1, \dots, u_d)^T$  και το τυπικό εσωτερικό γινόμενο  $\mathbf{u}^T \mathbf{v}$ .

Βλέπε επίσης: διανυσματικός χώρος, διάνυσμα, Ευκλείδειος χώρος.

**ψευδοαντίστροφος** The Moore–Penrose pseudoinverse  $\mathbf{A}^+$  of a πίνακας  $\mathbf{A} \in \mathbb{R}^{m \times d}$  generalizes the notion of an αντίστροφος πίνακας [3]. The pseudoinverse arises naturally within ridge regression when applied to a σύνολο δεδομένων with arbitrary ετικέτας  $\mathbf{y}$  and a πίνακας χαρακτηριστικών  $\mathbf{X} = \mathbf{A}$  [47, Ch. 3]. The παράμετροι μοντέλου learned by ridge regression are given by

$$\hat{\mathbf{w}}^{(\alpha)} = (\mathbf{A}^T \mathbf{A} + \alpha \mathbf{I})^{-1} \mathbf{A}^T \mathbf{y}, \quad \alpha > 0.$$

We can then define the pseudoinverse  $\mathbf{A}^+ \in \mathbb{R}^{d \times m}$  via the limit [111, Ch. 3]

$$\lim_{\alpha \rightarrow 0^+} \hat{\mathbf{w}}^{(\alpha)} = \mathbf{A}^+ \mathbf{y}.$$

Βλέπε επίσης: πίνακας, αντίστροφος πίνακας, ridge regression, σύνολο δεδομένων, ετικέτα, πίνακας χαρακτηριστικών, παράμετροι μοντέλου.

**0/1 απώλεια** Η 0/1 απώλεια  $L^{(0/1)}((\mathbf{x}, y), h)$  μετράει την ποιότητα ενός ταξινομητή  $h(\mathbf{x})$  που παραδίδει μία πρόβλεψη  $\hat{y}$  (π.χ. μέσω κατωφλίου (7)) για την ετικέτα  $y$  ενός σημείου δεδομένων με χαρακτηριστικά  $\mathbf{x}$ . Είναι ίση με 0 αν η πρόβλεψη είναι σωστή, δηλαδή  $L^{(0/1)}((\mathbf{x}, y), h) = 0$  όταν  $\hat{y} = y$ . Είναι ίση με 1 αν η πρόβλεψη είναι λανθασμένη, δηλαδή  $L^{(0/1)}((\mathbf{x}, y), h) = 1$  όταν  $\hat{y} \neq y$ .

Βλέπε επίσης: loss, ταξινομητής, πρόβλεψη, ετικέτα, data point, feature.

**vertical federated learning (VFL)** VFL refers to FL applications where συσκευές have access to different features of the same set of data points [112]. Formally, the underlying global σύνολο δεδομένων is

$$\mathcal{D}^{(\text{global})} := \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}.$$

We denote by  $\mathbf{x}^{(r)} = (x_1^{(r)}, \dots, x_{d'}^{(r)})^T$ , for  $r = 1, \dots, m$ , the complete διάνυσμα χαρακτηριστικών for the data point.s Each συσκευή  $i \in \mathcal{V}$  observes only a subset  $\mathcal{F}^{(i)} \subseteq \{1, \dots, d'\}$  of features, resulting in a τοπικό σύνολο δεδομένων  $\mathcal{D}^{(i)}$  with διάνυσμα χαρακτηριστικών

$$\mathbf{x}^{(i,r)} = (x_{j_1}^{(r)}, \dots, x_{j_d}^{(r)})^T.$$

Some of the συσκευές may also have access to the ετικέτας  $y^{(r)}$ , for  $r = 1, \dots, m$ , of the global σύνολο δεδομένων (see Fig. 52).






Fig. 52. VFL uses τοπικό σύνολο δεδομένων that are derived from the data points of a common global σύνολο δεδομένων. The τοπικό σύνολο δεδομένων differ in the choice of features used to characterize the data points.

One potential application of VFL is to enable collaboration between different healthcare providers. Each provider collects distinct types of measurements—such as blood values, electrocardiography, and lung X-rays—for the same patients. Another application is a national social insurance system, where health records, financial indicators, consumer behavior, and mobility data are collected by different institutions. VFL enables joint learning across these parties while allowing well-defined levels of προστασία της ιδιωτικότητας.

Βλέπε επίσης: FL, συσκευή, feature, data point, σύνολο δεδομένων, διάνυσμα χαρακτηριστικών, τοπικό σύνολο δεδομένων, ετικέτα, data, προστασία της ιδιωτικότητας.

**local interpretable model-agnostic explanations (LIME)** Consider a

trained model (or learned υπόθεση)  $\hat{h} \in \mathcal{H}$ , which maps the διάνυσμα χαρακτηριστικών of a data point to the πρόβλεψη  $\hat{y} = \hat{h}$ . LIME is a technique for explaining the behavior of  $\hat{h}$ , locally around a data point with διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(0)}$  [46]. The εξήγηση is given in the form of a local approximation  $g \in \mathcal{H}'$  of  $\hat{h}$  (see Fig. 53). This approximation can be obtained by an instance of ελαχιστοποίηση εμπειρικής διακινδύνευσης with carefully designed σύνολο εκπαίδευσης. In particular, the σύνολο εκπαίδευσης consists of data points with διάνυσμα χαρακτηριστικών centered around  $\mathbf{x}^{(0)}$  and the (pseudo-)ετικέτα  $\hat{h}(\mathbf{x})$ . Note that we can use a different model  $\mathcal{H}'$  for the approximation from the original model  $\mathcal{H}$ . For example, we can use a decision tree to locally approximate a βαθύ δίκτυο. Another widely used choice for  $\mathcal{H}'$  is the γραμμικό μοντέλο.




Fig. 53. To explain a trained model  $\hat{h} \in \mathcal{H}$ , around a given διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(0)}$ , we can use a local approximation  $g \in \mathcal{H}'$ .

Βλέπε επίσης: model, υπόθεση, διάνυσμα χαρακτηριστικών, data point, πρόβλεψη, εξήγηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, ετικέτα, decision tree, βαθύ δίκτυο, γραμμικό μοντέλο.

**Gaussian random variable (Gaussian RV)** A standard Gaussian τυχαία μεταβλητή is a real-valued τυχαία μεταβλητή  $x$  with συνάρτηση πυκνότητας πιθανότητας [7], [18], [19]

$$p(x) = \frac{1}{\sqrt{2\pi}} \exp(-x^2/2).$$

Given a standard Gaussian τυχαία μεταβλητή  $x$ , we can construct a general Gaussian τυχαία μεταβλητή  $x'$  with μέση τιμή  $\mu$  and διακύμανση  $\sigma^2$  via  $x' := \sigma x + \mu$ . The κατανομή πιθανότητας of a Gaussian τυχαία μεταβλητή is referred to as normal distribution, denoted by  $\mathcal{N}(\mu, \sigma^2)$ . A Gaussian random διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$  with πίνακας συνδιακύμανσης  $\mathbf{C}$  and μέση τιμή  $\boldsymbol{\mu}$  can be constructed as [18], [19], [96]

$$\mathbf{x} := \mathbf{A}\mathbf{z} + \boldsymbol{\mu}$$

where  $\mathbf{z} := (z_1, \dots, z_d)^T$  is a διάνυσμα of ανεξάρτητες και ταυτόσημα κατανεμημένες standard Gaussian τυχαία μεταβλητές, and  $\mathbf{A} \in \mathbb{R}^{d \times d}$  is any πίνακας satisfying  $\mathbf{A}\mathbf{A}^T = \mathbf{C}$ . The κατανομή πιθανότητας of a Gaussian random διάνυσμα is referred to as the πολυμεταβλητή κανονική κατανομή, denoted by  $\mathcal{N}(\boldsymbol{\mu}, \mathbf{C})$ .

We can interpret a Gaussian random διάνυσμα  $\mathbf{x} = (x_1, \dots, x_d)$  as a στοχαστική διαδικασία indexed by the set  $\mathcal{I} = \{1, \dots, d\}$ . A Gaussian process is a στοχαστική διαδικασία over an arbitray index set  $\mathcal{I}$  such that any restriction to a finite subset  $\mathcal{I}' \subseteq \mathcal{I}$  yields a Gaussian random διάνυσμα [113].

Gaussian τυχαία μεταβλητές are widely used πιθανοτικό μοντέλος in the

statistical analysis of ml methods. Their significance arises partly from the κεντρικό οριακό θεώρημα, which is a mathematically precise formulation of the following rule of thumb: The average of many independent τυχαία μεταβλητής (not necessarily Gaussian themselves) tends toward a Gaussian τυχαία μεταβλητή [109].

The πολυμεταβλητή κανονική κατανομή is also distinct in that it represents maximum αβεβαιότητα. Among all διάνυσμα-valued τυχαία μεταβλητής with a given πίνακας συνδιακύμανσης  $\mathbf{C}$ , the τυχαία μεταβλητή  $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{C})$  maximizes διαφορική εντροπία [28, Th. 8.6.5]. This makes GPs a natural choice for capturing αβεβαιότητα (or lack of knowledge) in the absence of additional structural information.

Βλέπε επίσης: τυχαία μεταβλητή, συνάρτηση πυκνότητας πιθανότητας, μέση τιμή, διακύμανση, κατανομή πιθανότητας, διάνυσμα, πίνακας συνδιακύμανσης, ανεξάρτητες και ταυτόσημα κατανεμημένες, πίνακας, πολυμεταβλητή κανονική κατανομή, στοχαστική διαδικασία, GP, πιθανοτικό μοντέλο, ml, κεντρικό οριακό θεώρημα, maximum, αβεβαιότητα, διαφορική εντροπία.

**Gaussian process (GP)** A GP is a collection of τυχαία μεταβλητής  $\{f(\mathbf{x})\}_{\mathbf{x} \in \mathcal{X}}$  indexed by input values  $\mathbf{x}$  from some input space  $\mathcal{X}$  such that, for any finite subset  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathcal{X}$ , the corresponding τυχαία μεταβλητής  $f(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})$  have a joint πολυμεταβλητή κανονική κατανομή

$$f(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}) \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{K}).$$

For a fixed input space  $\mathcal{X}$ , a GP is fully specified (or parameterized)

by: 1) a μέση τιμή συνάρτηση  $\mu(\mathbf{x}) = \mathbb{E}\{f(\mathbf{x})\}$ ; and 2) a συνδιακύμανση συνάρτηση  $K(\mathbf{x}, \mathbf{x}') = \mathbb{E}\{(f(\mathbf{x}) - \mu(\mathbf{x}))(f(\mathbf{x}') - \mu(\mathbf{x}'))\}$ .

Example: We can interpret the temperature distribution across Finland (at a specific point in time) as the πραγμάτωση of a GP  $f(\mathbf{x})$ , where each input  $\mathbf{x} = (\text{lat}, \text{lon})$  denotes a geographic location. Temperature observations from Φινλανδικό Μετεωρολογικό Ινστιτούτο weather stations provide δείγματα of  $f(\mathbf{x})$  at specific locations (see Fig. 54). A GP allows us to predict the temperature nearby Φινλανδικό Μετεωρολογικό Ινστιτούτο weather stations and to quantify the αβεβαιότητα of these πρόβλεψης.




Fig. 54. For a given point in time, we can interpret the current temperature distribution over Finland as a πραγμάτωση of a GP indexed by geographic coordinates and sampled at Φινλανδικό Μετεωρολογικό Ινστιτούτο weather stations. The weather stations are indicated by blue dots.

Βλέπε επίσης: τυχαία μεταβλητή, πολυμεταβλητή κανονική κατανομή, μέση τιμή, συνάρτηση, συνδιακύμανση, πραγμάτωση, Φινλανδικό Μετεωρολογικό Ινστιτούτο, δείγμα, αβεβαιότητα, πρόβλεψη, Gaussian RV.

**multiarmed bandit (MAB)** An MAB problem is a precise mathematical formulation of a sequential decision-making task under αβεβαιότητα. At each discrete time step  $k$ , a learner selects one of several possible actions—called arms—from a finite set  $\mathcal{A}$ . Pulling arm  $a$  at time  $k$  yields a ανταμοιβή  $r^{(a,k)}$  that is drawn from an unknown κατανομή πιθανότητας  $\mathbb{P}(r^{(a,k)})$ . We obtain different classes of MAB problems by placing different restrictions on this κατανομή πιθανότητας. In the simplest setting, the κατανομή πιθανότητας  $\mathbb{P}(r^{(a,k)})$  does not depend on  $t$ . Given an MAB problem, the goal is to construct ml methods that maximize the cumulative ανταμοιβή over time by strategically balancing exploration (i.e., gathering information about uncertain arms) and exploitation (i.e., selecting arms known to perform well). MAB problems form an important special case of RL problems [21], [114].

Βλέπε επίσης: αβεβαιότητα, ανταμοιβή, κατανομή πιθανότητας, ml, RL, regret.

**dual norm** Every νόρμα  $\|\cdot\|$  defined on an Ευκλείδειος χώρος  $\mathbb{R}^d$  has an associated dual νόρμα, which is denoted by  $\|\cdot\|_*$  and defined as  $\|\mathbf{y}\|_* := \sup_{\|\mathbf{x}\| \leq 1} \mathbf{y}^T \mathbf{x}$ . The dual νόρμα measures the largest possible inner product between  $\mathbf{y}$  and any διάνυσμα in the unit ball of the original νόρμα. For further details, see [15, Sec. A.1.6].

Βλέπε επίσης: νόρμα, Ευκλείδειος χώρος, διάνυσμα.

**distributed algorithm** A distributed αλγόριθμος is an αλγόριθμος designed for a special type of computer: a collection of interconnected computing devices (or nodes). These devices communicate and coordinate their

local computations by exchanging messages over a network [115], [116]. Unlike a classical αλγόριθμος, which is implemented on a single συσκευή, a distributed αλγόριθμος is executed concurrently on multiple συσκευές with computational capabilities. Similar to a classical αλγόριθμος, a distributed αλγόριθμος can be modeled as a set of potential executions. However, each execution in the distributed setting involves both local computations and message-passing γεγονός. A generic execution might look as follows:

$$\begin{aligned}
&\text{Node 1: input}_1, s_1^{(1)}, s_2^{(1)}, \dots, s_{T_1}^{(1)}, \text{output}_1; \\
&\text{Node 2: input}_2, s_1^{(2)}, s_2^{(2)}, \dots, s_{T_2}^{(2)}, \text{output}_2; \\
&\vdots \\
&\text{Node N: input}_N, s_1^{(N)}, s_2^{(N)}, \dots, s_{T_N}^{(N)}, \text{output}_N.
\end{aligned}$$

Each συσκευή  $i$  starts from its own local input and performs a sequence of intermediate computations  $s_k^{(i)}$  at discrete-time instants  $k = 1, \dots, T_i$ . These computations may depend on both: the previous local computations at the συσκευή and messages received from other συσκευές. One important application of distributed αλγόριθμος is in FL where a network of συσκευές collaboratively train a personal model for each συσκευή.

Βλέπε επίσης: αλγόριθμος, συσκευή, γεγονός, FL, model.

**online learning** Some ml methods are designed to process data in a sequential manner, updating their παράμετροι μοντέλου one at a time, as new data points become available. A typical example is time-series data,

such as daily ελάχιστο and maximum temperatures recorded by an Φινλανδικό Μετεωρολογικό Ινστιτούτο weather station. These values form a chronological sequence of observations. During each time step  $t$ , online learning methods update (or refine) the current υπόθεση  $h^{(t)}$  (or παράμετροι μοντέλου  $\mathbf{w}^{(t)}$ ) based on the newly observed data point  $\mathbf{z}^{(t)}$ . Βλέπε επίσης: ml, data, παράμετροι μοντέλου, data point, ελάχιστο, maximum, Φινλανδικό Μετεωρολογικό Ινστιτούτο, υπόθεση, online gradient descent (online GD), online algorithm.

**online algorithm** An online αλγόριθμος processes input data incrementally, receiving data points sequentially and making decisions or producing outputs (or decisions) immediately without having access to the entire input in advance [117], [118]. Unlike an offline αλγόριθμος, which has the entire input available from the start, an online αλγόριθμος must handle αβεβαιότητα about future inputs and cannot revise past decisions. Similar to an offline αλγόριθμος, we represent an online αλγόριθμος formally as a collection of possible executions. However, the execution sequence for an online αλγόριθμος has a distinct structure as follows:

$$\text{in}_1, s_1, \text{out}_1, \text{in}_2, s_2, \text{out}_2, \dots, \text{in}_T, s_T, \text{out}_T.$$

Each execution begins from an initial state (i.e.,  $\text{in}_1$ ) and proceeds through alternating computational steps, outputs (or decisions), and inputs. Specifically, at step  $k$ , the αλγόριθμος performs a computational step  $s_k$ , generates an output  $\text{out}_k$ , and then subsequently receives the next input (data point)  $\text{in}_{k+1}$ . A notable example of an online



αλγόριθμος in ml is online GD, which incrementally updates παράμετροι μοντέλου as new data points arrive.

Βλέπε επίσης: αλγόριθμος, data, data point, αβεβαιότητα, ml, online GD, παράμετροι μοντέλου, online learning.

**spectrogram** A spectrogram represents the time-frequency distribution of the energy of a time signal  $x(t)$ . Intuitively, it quantifies the amount of signal energy present within a specific time segment  $[t_1, t_2] \subseteq \mathbb{R}$  and frequency interval  $[f_1, f_2] \subseteq \mathbb{R}$ . Formally, the spectrogram of a signal is defined as the squared magnitude of its short-time Fourier transform (STFT) [119]. Fig. 55 depicts a time signal along with its spectrogram.

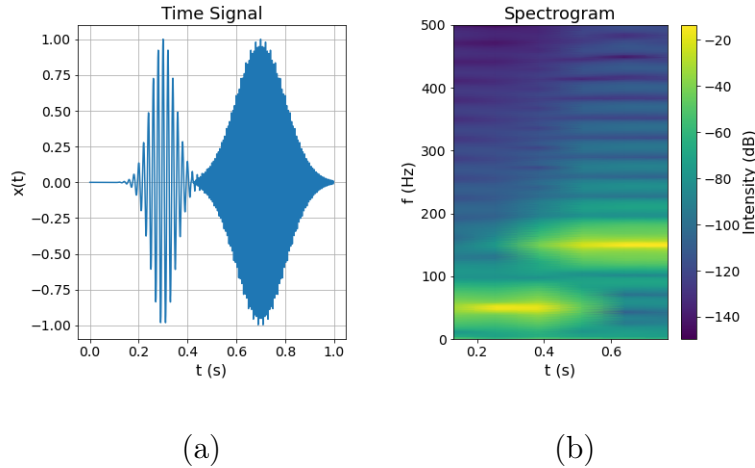


Fig. 55. (a) A time signal consisting of two modulated Gaussian pulses. (b) An intensity plot of the spectrogram.

The intensity plot of its spectrogram can serve as an image of a signal. A simple recipe for audio signal ταξινόμηση is to feed this signal image into βαθύ δίκτυος originally developed for image ταξινόμηση and object

detection [120]. It is worth noting that, beyond the spectrogram, several alternative representations exist for the time-frequency distribution of signal energy [121], [122].

Βλέπε επίσης: ταξινόμηση, βαθύ δίκτυο.

**bagging (or bootstrap aggregation)** Bagging (or bootstrap aggregation) is a technique to improve (the ευρωστία of) a given ελαχιστοποίηση εμπειρικής διακινδύνευσης-based ml method. The idea is to use the εκκίνηση to generate perturbed copies of a given σύνολο δεδομένων and to learn a separate υπόθεση for each copy. We then predict the ετικέτα of a data point by combining or aggregating the individual πρόβλεψης of each separate υπόθεση. For υπόθεση maps delivering numeric ετικέτα values, this aggregation could be implemented by computing the average of individual πρόβλεψης. Bagging is an example of an ensemble method, with base learners using the same model but different σύνολο εκπαίδευσης.

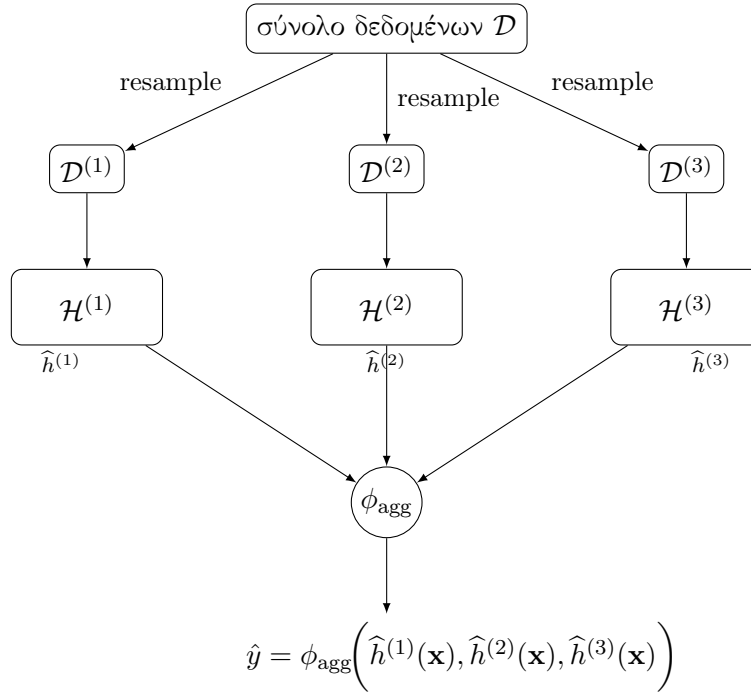


Fig. 56. A simple example of bagging. Three base learners use different variations  $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(3)}$  of the original σύνολο δεδομένων  $\mathcal{D}$  to learn the υπόθεσης  $\hat{h}^{(1)}, \dots, \hat{h}^{(3)}$ . The πρόβλεψη  $\hat{y}$  for a data point with διάνυσμα χαρακτηριστικών  $\mathbf{x}$  is obtained by applying an aggregation rule  $\phi_{\text{agg}}$  to the individual πρόβλεψης  $\hat{h}^{(1)}(\mathbf{x}), \hat{h}^{(2)}(\mathbf{x}), \hat{h}^{(3)}(\mathbf{x})$ .

Βλέπε επίσης: ευρωστία, ml, εκκίνηση, σύνολο δεδομένων, υπόθεση, ετικέτα, data point, πρόβλεψη, map.

**online gradient descent (online GD)** Consider an ml method that learns παράμετροι μοντέλου  $\mathbf{w}$  from some χώρος παραμέτρων  $\mathcal{W} \subseteq \mathbb{R}^d$ . The learning process uses data points  $\mathbf{z}^{(t)}$  that arrive at consecutive time instants  $t = 1, 2, \dots$ . Let us interpret the data points  $\mathbf{z}^{(t)}$  as ανεξάρτητες και ταυτόσημα καταναεμημένες copies of an τυχαία μεταβλητή  $\mathbf{z}$ .

The διακινδύνευση  $\mathbb{E}\{L(\mathbf{z}, \mathbf{w})\}$  of a υπόθεση  $h^{(\mathbf{w})}$  can then (under mild conditions) be obtained as the limit  $\lim_{T \rightarrow \infty} (1/T) \sum_{t=1}^T L(\mathbf{z}^{(t)}, \mathbf{w})$ . We might use this limit as the αντικειμενική συνάρτηση for learning the παράμετροι μοντέλου  $\mathbf{w}$ . Unfortunately, this limit can only be evaluated if we wait infinitely long in order to collect all data points. Some ml applications require methods that learn online: as soon as a new data point  $\mathbf{z}^{(t)}$  arrives at time  $t$ , we update the current παράμετροι μοντέλου  $\mathbf{w}^{(t)}$ . Note that the new data point  $\mathbf{z}^{(t)}$  contributes the component  $L(\mathbf{z}^{(t)}, \mathbf{w})$  to the διακινδύνευση. As its name suggests, online κάθοδος κλίσης updates  $\mathbf{w}^{(t)}$  via a (projected) βήμα κλίσης

$$\mathbf{w}^{(t+1)} := P_{\mathcal{W}}(\mathbf{w}^{(t)} - \eta_t \nabla_{\mathbf{w}} L(\mathbf{z}^{(t)}, \mathbf{w})). \quad (8)$$

Note that (8) is a βήμα κλίσης for the current component  $L(\mathbf{z}^{(t)}, \cdot)$  of the διακινδύνευση. The update (8) ignores all previous components  $L(\mathbf{z}^{(t')}, \cdot)$ , for  $t' < t$ . It might therefore happen that, compared to  $\mathbf{w}^{(t)}$ , the updated παράμετροι μοντέλου  $\mathbf{w}^{(t+1)}$  increase the retrospective average loss  $\sum_{t'=1}^{t-1} L(\mathbf{z}^{(t')}, \cdot)$ . However, for a suitably chosen ρυθμός μάθησης  $\eta_t$ , online κάθοδος κλίσης can be shown to be optimal in practically relevant settings. By optimal, we mean that the παράμετροι μοντέλου  $\mathbf{w}^{(T+1)}$  delivered by online κάθοδος κλίσης after observing  $T$  data points  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(T)}$  are at least as good as those delivered by any other learning method [118], [123].




Fig. 57. An instance of online κάθοδος κλίσης that updates the παράμετροι μοντέλου  $\mathbf{w}^{(t)}$  using the data point  $\mathbf{z}^{(t)} = x^{(t)}$  arriving at time  $t$ . This instance uses the απώλεια τετραγωνικού σφάλματος  $L(\mathbf{z}^{(t)}, w) = (x^{(t)} - w)^2$ .

Βλέπε επίσης: ml, παράμετροι μοντέλου, χώρος παραμέτρων, data point, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, διακινδύνευση, υπόθεση, αντικειμενική συνάρτηση, κάθοδος κλίσης, βήμα κλίσης, loss, ρυθμός μάθησης, απώλεια τετραγωνικού σφάλματος, online learning.

**probabilistic principal component analysis (PPCA)** PPCA extends basic principal component analysis by using a πιθανοτικό μοντέλο for data points. The πιθανοτικό μοντέλο of PPCA frames the task of μείωση της διαστασιμότητας as an estimation problem that can be solved using EM [124].

Βλέπε επίσης: principal component analysis, πιθανοτικό μοντέλο, data point, μείωση της διαστασιμότητας, EM.

**Gaussian mixture model (GMM)** A GMM is a particular type of πιθανοτικό μοντέλο for a numeric διάνυσμα  $\mathbf{x}$  (e.g., the features of a data point). Within a GMM, the διάνυσμα  $\mathbf{x}$  is drawn from a randomly selected πολυμεταβλητή κανονική κατανομή  $p^{(c)} = \mathcal{N}(\boldsymbol{\mu}^{(c)}, \mathbf{C}^{(c)})$  with  $c = I$ . The index  $I \in \{1, \dots, k\}$  is an τυχαία μεταβλητή with probabilities  $\mathbb{P}(I = c) = p_c$ . Note that a GMM is parametrized by the probability  $p_c$ , the μέση τιμή διάνυσμα  $\boldsymbol{\mu}^{(c)}$ , and the πίνακας συνδιακύμανσης  $\boldsymbol{\Sigma}^{(c)}$  for each  $c = 1, \dots, k$ . GMMs are widely used for συσταδοποίηση, density estimation, and as a generative model.

Βλέπε επίσης: πιθανοτικό μοντέλο, διάνυσμα, feature, data point, πολυμεταβλητή κανονική κατανομή, τυχαία μεταβλητή, μέση τιμή, πίνακας συνδιακύμανσης, συσταδοποίηση, model.

**expectation–maximization (EM)** Consider a πιθανοτικό μοντέλο  $\mathbb{P}(\mathbf{z}; \mathbf{w})$  for the data points  $\mathcal{D}$  generated in some ml application. The μέγιστη πιθανοφάνεια estimator for the παράμετροι μοντέλου  $\mathbf{w}$  is obtained by maximizing  $\mathbb{P}(\mathcal{D}; \mathbf{w})$ . However, the resulting optimization problem might be computationally challenging. EM approximates the μέγιστη πιθανοφάνεια estimator by introducing a latent τυχαία μεταβλητή  $\mathbf{z}$  such that maximizing  $\mathbb{P}(\mathcal{D}, \mathbf{z}; \mathbf{w})$  would be easier [47], [84], [125]. Since we do not observe  $\mathbf{z}$ , we need to estimate it from the observed σύνολο δεδομένων  $\mathcal{D}$  using a conditional expectation. The resulting estimate  $\hat{\mathbf{z}}$  is then used to compute a new estimate  $\hat{\mathbf{w}}$  by solving  $\max_{\mathbf{w}} \mathbb{P}(\mathcal{D}, \hat{\mathbf{z}}; \mathbf{w})$ . The crux is that the conditional expectation  $\hat{\mathbf{z}}$  depends on the παράμετροι μοντέλου  $\hat{\mathbf{w}}$ , which we have updated based on  $\hat{\mathbf{z}}$ . Thus, we have to

recalculate  $\widehat{\mathbf{z}}$ , which, in turn, results in a new choice  $\widehat{\mathbf{w}}$  for the παράμετροι μοντέλου. In practice, we repeat the computation of the conditional expectation (i.e., the E-step) and the update of the παράμετροι μοντέλου (i.e., the M-step) until some κριτήριο τερματισμού is met.

Βλέπε επίσης: πιθανοτικό μοντέλο, data point, ml, μέγιστη πιθανοφάνεια, παράμετροι μοντέλου, optimization problem, τυχαία μεταβλητή, σύνολο δεδομένων, expectation, κριτήριο τερματισμού.

**high-dimensional regime** The high-dimensional regime of ελαχιστοποίηση εμπειρικής διακινδύνευσης is characterized by the αποτελεσματική διάσταση of the model being larger than the μέγεθος δείγματος, i.e., the number of (labeled) data points in the σύνολο εκπαίδευσης. For example, γραμμική παλινδρόμηση methods operate in the high-dimensional regime whenever the number  $d$  of features used to characterize data points exceeds the number of data points in the σύνολο εκπαίδευσης. Another example of ml methods that operate in the high-dimensional regime is large TNΔs, which have far more tunable βάρη (and bias terms) than the total number of data points in the σύνολο εκπαίδευσης. High-dimensional statistics is a recent main thread of probability theory that studies the behavior of ml methods in the high-dimensional regime [48], [126].

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, αποτελεσματική διάσταση, model, μέγεθος δείγματος, data point, σύνολο εκπαίδευσης, γραμμική παλινδρόμηση, feature, ml, TNΔ, βάρη, probability, υπερπροσαρμογή, ομαλοποίηση.

**clustered federated learning (CFL)** CFL trains local models for the συσκευής in a FL application by using a παραδοχή συσταδοποίησης, i.e., the συσκευής of an δίκτυο ομοσπονδιακής μάθησης form συστάδας. Two συσκευής in the same συστάδα generate τοπικό σύνολο δεδομένων with similar statistical properties. CFL pools the τοπικό σύνολο δεδομένων of συσκευής in the same συστάδα to obtain a σύνολο εκπαίδευσης for a συστάδα-specific model. GTVMin clusters συσκευής implicitly by enforcing approximate similarity of παράμετροι μοντέλου across well-connected nodes of the δίκτυο ομοσπονδιακής μάθησης. Βλέπε επίσης: local model, συσκευή, FL, παραδοχή συσταδοποίησης, δίκτυο ομοσπονδιακής μάθησης, συστάδα, τοπικό σύνολο δεδομένων, σύνολο εκπαίδευσης, model, GTVMin, παράμετροι μοντέλου, συσταδοποίηση γράφου.

**algebraic connectivity** The algebraic connectivity of an undirected graph is the second-smallest ιδιοτιμή  $\lambda_2$  of its πίνακας Laplace. A graph is connected if and only if  $\lambda_2 > 0$ . Βλέπε επίσης: graph, ιδιοτιμή, πίνακας Laplace.

**Courant–Fischer–Weyl min–max characterization** Consider a θετικά ημιορισμένος πίνακας  $\mathbf{Q} \in \mathbb{R}^{d \times d}$  with ανάλυση ιδιοτιμών (or spectral decomposition), i.e.,

$$\mathbf{Q} = \sum_{j=1}^d \lambda_j \mathbf{u}^{(j)} (\mathbf{u}^{(j)})^T.$$



Here, we use the ordered (in ascending order) ιδιοτιμές

$$\lambda_1 \leq \dots \leq \lambda_n.$$

The Courant–Fischer–Weyl min–max characterization [3, Th. 8.1.2] represents the ιδιοτιμές of  $\mathbf{Q}$  as the solutions to certain optimization problems.

Βλέπε επίσης: θετικά ημιορισμένος, πίνακας, ανάλυση ιδιοτιμών, ιδιοτιμή, optimization problem.

**networked exponential families (nExpFam)** A collection of exponential families, each of them assigned to a node of an δίκτυο ομοσπονδιακής μάθησης. The παράμετροι μοντέλου are coupled via the network structure by requiring them to have a small γενικευμένη ολική μεταβολή [127].

Βλέπε επίσης: δίκτυο ομοσπονδιακής μάθησης, παράμετροι μοντέλου, γενικευμένη ολική μεταβολή.

**data poisoning** Data poisoning refers to the intentional manipulation (or fabrication) of data points to steer the training of an ml model [128], [129]. Data poisoning επίθεσης take various forms, including κερκόπορτα and επίθεση άρνησης υπηρεσιών. A κερκόπορτα επίθεση implants triggers into training data, so that the trained model behaves normally on typical δiάνυσμα χαρακτηριστικών but misclassifies a δiάνυσμα χαρακτηριστικών with a trigger pattern. A επίθεση άρνησης υπηρεσιών degrades the trained model’s overall performance by injecting mislabeled or adversar-

ial examples to prevent effective learning. Data poisoning is particularly concerning in decentralized or distributed ml settings (such as FL), where training data cannot be centrally verified.

Βλέπε επίσης: data, data point, ml, model, επίθεση, κερκόπορτα, διάνυσμα χαρακτηριστικών, επίθεση άρνησης υπηρεσιών, FL, αξιόπιστη TN.

**epigraph** The epigraph of a real-valued συνάρτηση  $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  is the set of points lying on or above its graph (see Fig. 58), i.e.,

$$\text{epi}(f) = \{(\mathbf{x}, t) \in \mathbb{R}^n \times \mathbb{R} \mid f(\mathbf{x}) \leq t\}.$$

A συνάρτηση is convex if and only if its epigraph is a convex set [15], [108].




Fig. 58. Epigraph of the συνάρτηση  $f(x) = x^2$  (i.e., the shaded area).

Βλέπε επίσης: συνάρτηση, graph, convex.

**geometric median (GM)** The GM of a set of input διάνυσμας  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$  in  $\mathbb{R}^d$  is a point  $\mathbf{z} \in \mathbb{R}^d$  that minimizes the sum of distances to the

διάνυσμα [15] such that

$$\mathbf{z} \in \arg \min_{\mathbf{y} \in \mathbb{R}^d} \sum_{r=1}^m \|\mathbf{y} - \mathbf{x}^{(r)}\|_2. \quad (9)$$

Fig. 59 illustrates a fundamental property of the GM: If  $\mathbf{z}$  does not coincide with any of the input  $\delta\alpha\nu\sigma\mu\alpha\varsigma$ , then the unit  $\delta\alpha\nu\sigma\mu\alpha\varsigma$  pointing from  $\mathbf{z}$  to each  $\mathbf{x}^{(r)}$  must sum to zero—this is the zero-subgradient (optimality) condition for (9). It turns out that the solution to (9) cannot be arbitrarily pulled away from trustworthy input  $\delta\alpha\nu\sigma\mu\alpha\varsigma$  as long as they are the majority [130, Th. 2.2].




Fig. 59. Consider a solution  $\mathbf{z}$  of (9) that does not coincide with any of the input διάνυσμαs. The optimality condition for (9) requires that the unit διάνυσμαs from  $\mathbf{z}$  to the input διάνυσμαs sum to zero.

Βλέπε επίσης: διάνυσμα, subgradient.

**federated relaxed (FedRelax)** An FL distributed algorithm.

Βλέπε επίσης: FL, distributed algorithm.

**federated averaging (FedAvg)** FedAvg refers to a family of iterative FL algorithms. It uses a server-client setting and alternates between

clientwise local models retraining, followed by the aggregation of updated  $\text{παράμετροι μοντέλου}$  at the server [131]. The local update at client  $i = 1, \dots, n$  at time  $k$  starts from the current  $\text{παράμετροι μοντέλου}$   $\mathbf{w}^{(k)}$  provided by the server and typically amounts to executing few iterations of  $\text{στοχαστική κάθοδος κλίσης}$ . After completing the local updates, they are aggregated by the server (e.g., by averaging them). Fig. 60 illustrates the execution of a single iteration of FedAvg.




Fig. 60. Illustration of a single iteration of FedAvg, which consists of broadcasting  $\text{παράμετροι μοντέλου}$  by the server, performing local updates at clients, and aggregating the updates by the server.

Βλέπε επίσης: FL, αλγόριθμος, local model,  $\text{παράμετροι μοντέλου}$ ,  $\text{στοχαστική κάθοδος κλίσης}$ .

**federated gradient descent (FedGD)** An FL distributed algorithm that can be implemented as message passing across an  $\text{δίκτυο ομοσπονδιακής μάθησης}$ .

Βλέπε επίσης: FL, distributed algorithm,  $\text{δίκτυο ομοσπονδιακής μάθησης}$ , βήμα κλίσης, μέθοδοι με βάση την κλίση.

**federated stochastic gradient descent (FedSGD)** An FL distributed algorithm that can be implemented as message passing across an  $\text{δίκτυο}$

ομοσπονδιακής μάθησης.

Βλέπε επίσης: FL, distributed algorithm, δίκτυο ομοσπονδιακής μάθησης, βήμα κλίσης, μέθοδοι με βάση την κλίση, στοχαστική κάθοδος κλίσης.

**expert** ml aims to learn a υπόθεση  $h$  that accurately predicts the ετικέτα of a data point based on its features. We measure the πρόβλεψη error using some συνάρτηση απώλειας. Ideally, we want to find a υπόθεση that incurs minimal loss on any data point. We can make this informal goal precise via the παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων and by using the διακινδύνευση Bayes as the βάση αναφοράς for the (average) loss of a υπόθεση. An alternative approach to obtaining a βάση αναφοράς is to use the υπόθεση  $h'$  learned by an existing ml method. We refer to this υπόθεση  $h'$  as an expert [117]. Regret minimization methods learn a υπόθεση that incurs a loss comparable to the best expert [117], [118].

Βλέπε επίσης: ml, υπόθεση, ετικέτα, data point, feature, πρόβλεψη, συνάρτηση απώλειας, loss, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, διακινδύνευση Bayes, βάση αναφοράς, regret.

**networked federated learning (NFL)** NFL refers to methods that learn personalized models in a distributed fashion. These methods learn from τοπικό σύνολο δεδομένων that are related by an intrinsic network structure.

Βλέπε επίσης: model, τοπικό σύνολο δεδομένων, FL.

**regret** The regret of a υπόθεση  $h$  relative to another υπόθεση  $h'$ , which serves as a βάση αναφοράς, is the difference between the loss incurred by  $h$  and the loss incurred by  $h'$  [117]. The βάση αναφοράς υπόθεση  $h'$  is also referred to as an expert.

Βλέπε επίσης: υπόθεση, βάση αναφοράς, loss, expert.

**strongly convex** A continuously παραγωγίσιμη real-valued συνάρτηση  $f(\mathbf{x})$  is strongly convex with coefficient  $\sigma$  if  $f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x}) + (\sigma/2) \|\mathbf{y} - \mathbf{x}\|_2^2$  [16], [80, Sec. B.1.1].

Βλέπε επίσης: παραγωγίσιμη, συνάρτηση, convex.

**federated proximal (FedProx)** FedProx refers to an iterative FL αλγόριθμος that alternates between separately training local models and combining the updated local παράμετροι μοντέλου. In contrast to FedAvg, which uses στοχαστική κάθοδος κλίσης to train local models, FedProx uses a τελεστής εγγύτητας for the training [132].

Βλέπε επίσης: FL, αλγόριθμος, local model, παράμετροι μοντέλου, FedAvg, στοχαστική κάθοδος κλίσης, τελεστής εγγύτητας.

**rectified linear unit (ReLU)** The ReLU is a popular choice for the συνάρτηση ενεργοποίησης of a neuron within an ΤΝΔ. It is defined as  $\sigma(z) = \max\{0, z\}$ , with  $z$  being the weighted input of the artificial neuron.

Βλέπε επίσης: συνάρτηση ενεργοποίησης, ΤΝΔ.

**missing data** Consider a σύνολο δεδομένων constituted by data points collected via some physical συσκευή. Due to imperfections and failures, some of the feature or ετικέτα values of data points might be corrupted or simply missing. Data imputation aims to estimate these missing values [133]. We can interpret data imputation as an ml problem where the ετικέτα of a data point is the value of the corrupted feature. Βλέπε επίσης: σύνολο δεδομένων, data point, συσκευή, feature, ετικέτα, data, ml.

**networked model** A networked model over an δίκτυο ομοσπονδιακής μάθησης  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  assigns a local model (i.e., a χώρος υποθέσεων) to each node  $i \in \mathcal{V}$  of the δίκτυο ομοσπονδιακής μάθησης  $\mathcal{G}$ . Βλέπε επίσης: model, δίκτυο ομοσπονδιακής μάθησης, local model, χώρος υποθέσεων.

**networked data** Networked data consists of τοπικό σύνολο δεδομένων that are related by some notion of pairwise similarity. We can represent networked data using a graph whose nodes carry τοπικό σύνολο δεδομένων and whose edges encode pairwise similarities. An example of networked data can be found in FL applications where τοπικό σύνολο δεδομένων are generated by spatially distributed συσκευές. Βλέπε επίσης: data, τοπικό σύνολο δεδομένων, graph, FL, συσκευή.

**multi-label classification** Multi-ετικέτα ταξινόμηση problems and methods use data points that are characterized by several ετικέτας. As an example, consider a data point representing a picture with two ετικέτας. One

ετικέτα indicates the presence of a human in this picture and another ετικέτα indicates the presence of a car.

Βλέπε επίσης: ετικέτα, ταξινόμηση, data point.

**semi-supervised learning (SSL)** SSL methods use unlabeled data points to support the learning of a υπόθεση from σημείο δεδομένων με ετικέτας [91]. This approach is particularly useful for ml applications that offer a large number of unlabeled data points, but only a limited number of σημείο δεδομένων με ετικέτας.

Βλέπε επίσης: data point, υπόθεση, σημείο δεδομένων με ετικέτα, ml.

**generalization gap** Generalization gap is the difference between the performance of a

Βλέπε επίσης: γενίκευση,, model, σύνολο εκπαίδευσης, data point, πιθανοτικό μοντέλο, διακινδύνευση, loss, κατανομή πιθανότητας, expectation, επικύρωση, σύνολο επικύρωσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, συνάρτηση απώλειας.

**concentration inequality** An upper bound on the probability that a τυχαία μεταβλητή deviates more than a prescribed amount from its expectation [48].

Βλέπε επίσης: probability, τυχαία μεταβλητή, expectation.

**boosting** Boosting is an iterative μέθοδος βελτιστοποίησης to learn an accurate υπόθεση map (or strong learner) by sequentially combining less accurate υπόθεση maps (referred to as weak learners) [47, Ch. 10]. For



example, weak learners are shallow decision trees that are combined to obtain a deep decision tree. Boosting can be understood as a γενίκευση of μέθοδοι με βάση την κλίση for ελαχιστοποίηση εμπειρικής διακινδύνευσης using parametric models and λεία συνάρτηση απώλειας [134]. Just as κάθοδος κλίσης iteratively updates παράμετροι μοντέλου to reduce the empirical risk, boosting iteratively combines (e.g., by summation) υπόθεση maps to reduce the empirical risk (see Fig. 61). A widely used instance of the generic boosting idea is referred to as gradient boosting, which uses gradients of the συνάρτηση απώλειας for combining the weak learners [134].




Fig. 61. Boosting methods construct a sequence of υπόθεση maps  $h^{(0)}, h^{(1)}, \dots$  that are increasingly strong learners (i.e., incurring a smaller loss).

Βλέπε επίσης: μέθοδος βελτιστοποίησης, υπόθεση, map, decision tree, γενίκευση, μέθοδοι με βάση την κλίση, ελαχιστοποίηση εμπειρικής διακιν-

δύνευσης, model, λεία, συνάρτηση απώλειας, κάθοδος κλίσης, παράμετροι μοντέλου, empirical risk, gradient, loss, βήμα κλίσης.

**μέγιστη πιθανοφάνεια** Consider data points  $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$  that are interpreted as the πραγμάτωση of ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαία μεταβλητής with a common κατανομή πιθανότητας  $\mathbb{P}(\mathbf{z}; \mathbf{w})$ , which depends on the παράμετροι μοντέλου  $\mathbf{w} \in \mathcal{W} \subseteq \mathbb{R}^n$ . Maximum likelihood methods learn παράμετροι μοντέλου  $\mathbf{w}$  by maximizing the probability (density)  $\mathbb{P}(\mathcal{D}; \mathbf{w}) = \prod_{r=1}^m \mathbb{P}(\mathbf{z}^{(r)}; \mathbf{w})$  of the observed σύνολο δεδομένων. Thus, the maximum likelihood estimator is a solution to the optimization problem  $\max_{\mathbf{w} \in \mathcal{W}} \mathbb{P}(\mathcal{D}; \mathbf{w})$ .

Βλέπε επίσης: data point, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, παράμετροι μοντέλου, maximum, σύνολο δεδομένων, optimization problem, πιθανοτικό μοντέλο.

**standard normal vector** A standard normal διάνυσμα is a random διάνυσμα  $\mathbf{x} = (x_1, \dots, x_d)^T$  whose entries are ανεξάρτητες και ταυτόσημα κατανεμημένες Gaussian RVs  $x_j \sim \mathcal{N}(0, 1)$ . It is a special case of a πολυμεταβλητή κανονική κατανομή,  $\mathbf{x} \sim (\mathbf{0}, \mathbf{I})$ .

Βλέπε επίσης: διάνυσμα, ανεξάρτητες και ταυτόσημα κατανεμημένες, Gaussian RV, πολυμεταβλητή κανονική κατανομή, τυχαία μεταβλητή.

**Erdős–Rényi graph (ER graph)** An ER graph is a πιθανοτικό μοντέλο for graphs defined over a given node set  $i = 1, \dots, n$ . One way to define the ER graph is via the collection of ανεξάρτητες και ταυτόσημα

κατανεμημένες binary τυχαία μεταβλητής  $b^{\{i,i'\}} \in \{0,1\}$ , for each pair of different nodes  $i, i'$ . A specific πραγμάτωση of an ER graph contains an edge  $\{i, i'\}$  if and only if  $b^{\{i,i'\}} = 1$ . The ER graph is parametrized by the number  $n$  of nodes and the probability  $\mathbb{P}(b^{\{i,i'\}} = 1)$ .

Βλέπε επίσης: graph, πιθανοτικό μοντέλο, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, πραγμάτωση, probability.

**fixed-point iteration** A fixed-point iteration is an iterative method for solving a given optimization problem. It constructs a sequence  $\mathbf{w}^{(0)}, \mathbf{w}^{(1)}, \dots$  by repeatedly applying an operator  $\mathcal{F}$ , i.e.,

$$\mathbf{w}^{(k+1)} = \mathcal{F}\mathbf{w}^{(k)}, \text{ for } k = 0, 1, \dots \quad (10)$$

The operator  $\mathcal{F}$  is chosen such that any of its fixed points is a solution  $\hat{\mathbf{w}}$  to the given optimization problem. For example, given a παραγωγίσιμη and convex συνάρτηση  $f(\mathbf{w})$ , the fixed points of the operator  $\mathcal{F} : \mathbf{w} \mapsto \mathbf{w} - \nabla f(\mathbf{w})$  coincide with the minimizers of  $f(\mathbf{w})$ . In general, for a given optimization problem with solution  $\hat{\mathbf{w}}$ , there are many different operators  $\mathcal{F}$  whose fixed points are  $\hat{\mathbf{w}}$ . Clearly, we should use an operator  $\mathcal{F}$  in (10) that reduces the distance to a solution such that

$$\underbrace{\|\mathbf{w}^{(k+1)} - \hat{\mathbf{w}}\|_2}_{\stackrel{(10)}{=} \|\mathcal{F}\mathbf{w}^{(k)} - \mathcal{F}\hat{\mathbf{w}}\|_2} \leq \|\mathbf{w}^{(k)} - \hat{\mathbf{w}}\|_2.$$

Thus, we require  $\mathcal{F}$  to be at least non-expansive, i.e., the iteration (10) should not result in worse παράμετροι μοντέλου that have a larger

distance to a solution  $\widehat{\mathbf{w}}$ . Furthermore, each iteration (10) should also make some progress, i.e., reduce the distance to a solution  $\widehat{\mathbf{w}}$ . This requirement can be made precise using the notion of a contraction operator [107], [135]. The operator  $\mathcal{F}$  is a contraction operator if, for some  $\kappa \in [0, 1)$ ,

$$\|\mathcal{F}\mathbf{w} - \mathcal{F}\mathbf{w}'\|_2 \leq \kappa \|\mathbf{w} - \mathbf{w}'\|_2 \text{ holds for any } \mathbf{w}, \mathbf{w}'.$$

For a contraction operator  $\mathcal{F}$ , the fixed-point iteration (10) generates a sequence  $\mathbf{w}^{(k)}$  that converges quite rapidly. In particular [2, Th. 9.23],

$$\|\mathbf{w}^{(k)} - \widehat{\mathbf{w}}\|_2 \leq \kappa^k \|\mathbf{w}^{(0)} - \widehat{\mathbf{w}}\|_2.$$

Here,  $\|\mathbf{w}^{(0)} - \widehat{\mathbf{w}}\|_2$  is the distance between the initialization  $\mathbf{w}^{(0)}$  and the solution  $\widehat{\mathbf{w}}$ . It turns out that a fixed-point iteration (10) with a firmly non-expansive operator  $\mathcal{F}$  is guaranteed to converge to a fixed-point of  $\mathcal{F}$  [107, Corollary 5.16]. Fig. 62 depicts examples of a firmly non-expansive operator, a non-expansive operator, and a contraction operator. All of these operators are defined on the 1-D space  $\mathbb{R}$ . Another example of a firmly non-expansive operator is the τελεστής εγγύτητας of a convex συνάρτηση [107], [42].




Fig. 62. Example of a non-expansive operator  $\mathcal{F}^{(1)}$ , a firmly non-expansive operator  $\mathcal{F}^{(2)}$ , and a contraction operator  $\mathcal{F}^{(3)}$ .

Βλέπε επίσης: optimization problem, παραγωγίσιμη, convex, συνάρτηση, παράμετροι μοντέλου, contraction operator, τελεστής εγγύτητας.

**contraction operator** An operator  $\mathcal{F} : \mathbb{R}^d \rightarrow \mathbb{R}^d$  is a contraction if, for some  $\kappa \in [0, 1)$ ,

$$\|\mathcal{F}\mathbf{w} - \mathcal{F}\mathbf{w}'\|_2 \leq \kappa \|\mathbf{w} - \mathbf{w}'\|_2 \text{ holds for any } \mathbf{w}, \mathbf{w}' \in \mathbb{R}^d.$$

**Jacobi method** The Jacobi method is an αλγόριθμος for solving systems of linear equations (i.e., a linear system) of the form  $\mathbf{Ax} = \mathbf{b}$ . Here,  $\mathbf{A} \in \mathbb{R}^{d \times d}$  is a square πίνακας with nonzero main diagonal entries. The

method constructs a sequence  $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \dots$  by updating each entry of  $\mathbf{x}^{(k)}$  according to

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right).$$

Note that all entries  $x_1^{(k)}, \dots, x_d^{(k)}$  are updated simultaneously. The above iteration converges to a solution, i.e.,  $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}$ , under certain conditions on the matrix  $\mathbf{A}$ , e.g., being strictly diagonally dominant or symmetric positive definite [3], [30], [13]. Jacobi-type methods are appealing for large linear systems due to their parallelizable structure [116]. We can interpret the Jacobi method as a fixed-point iteration. Indeed, using the decomposition  $\mathbf{A} = \mathbf{D} + \mathbf{R}$ , with  $\mathbf{D}$  being the diagonal of  $\mathbf{A}$ , allows us to rewrite the linear equation  $\mathbf{Ax} = \mathbf{b}$  as a fixed-point equation

$$\mathbf{x} = \underbrace{\mathbf{D}^{-1}(\mathbf{b} - \mathbf{Rx})}_{\mathcal{F}\mathbf{x}}$$

which leads to the iteration  $\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{b} - \mathbf{Rx}^{(k)})$ .

As an example, for the linear equation  $\mathbf{Ax} = \mathbf{b}$ , where

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

the Jacobi method updates each component of  $\mathbf{x}$  as follows:

$$\begin{aligned}x_1^{(k+1)} &= \frac{1}{a_{11}} \left( b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} \right); \\x_2^{(k+1)} &= \frac{1}{a_{22}} \left( b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} \right); \\x_3^{(k+1)} &= \frac{1}{a_{33}} \left( b_3 - a_{31}x_1^{(k)} - a_{32}x_2^{(k)} \right).\end{aligned}$$

Βλέπε επίσης: αλγόριθμος, πίνακας, fixed-point iteration, μέθοδος βελτιστοποίησης.

**linear map** A linear map  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  is a συνάρτηση that satisfies additivity, i.e.,  $f(\mathbf{x} + \mathbf{y}) = f(\mathbf{x}) + f(\mathbf{y})$ , and homogeneity, i.e.,  $f(c\mathbf{x}) = cf(\mathbf{x})$  for all διάνυσμας  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$  and scalars  $c \in \mathbb{R}$ . In particular,  $f(\mathbf{0}) = \mathbf{0}$ . Any linear map can be represented as a πίνακας multiplication  $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$  for some πίνακας  $\mathbf{A} \in \mathbb{R}^{m \times n}$ . The collection of real-valued linear maps for a given dimension  $n$  constitute a γραμμικό μοντέλο, which is used in many ml methods.

Βλέπε επίσης: map, συνάρτηση, διάνυσμα, πίνακας, γραμμικό μοντέλο, ml.

**διάμεσος** A median  $\text{med}(x)$  of a real-valued τυχαία μεταβλητή  $x$  is any number  $m \in \mathbb{R}$  such that  $\mathbb{P}(x \leq m) \geq 1/2$  and  $\mathbb{P}(x \geq m) \geq 1/2$  (see Fig. 63) [40].




Fig. 63. A representation of a median.

We can define the median  $\text{med}(\mathcal{D})$  of a σύνολο δεδομένων  $\mathcal{D} = \{x^{(1)}, \dots, x^{(m)} \in \mathbb{R}\}$  via a specific τυχαία μεταβλητή  $\tilde{x}$  that is naturally associated with  $\mathcal{D}$ . In particular, this τυχαία μεταβλητή is constructed by  $\tilde{x} = x^{(I)}$ , with the index  $I$  being chosen uniformly at random from the set  $\{1, \dots, m\}$ , i.e.,  $\mathbb{P}(I = r) = 1/m$  for all  $r = 1, \dots, m$ . If the τυχαία μεταβλητή  $x$  is integrable, a median of  $x$  is the solution of the following optimization problem:

$$\min_{x' \in \mathbb{R}} \mathbb{E}|x - x'|.$$

Like the μέση τιμή, the median of a σύνολο δεδομένων  $\mathcal{D}$  can also be used to estimate παράμετρος of an underlying πιθανοτικό μοντέλο. Compared to the μέση τιμή, the median is more robust to ακραία τιμές. For example, a median of a σύνολο δεδομένων  $\mathcal{D}$  with more than one data point does not change even if we arbitrarily increase the largest element of  $\mathcal{D}$  (see Fig. 64). In contrast, the μέση τιμή will increase arbitrarily.






Fig. 64. The median is robust against ακραία τιμή contamination. (a) Original σύνολο δεδομένων  $\mathcal{D}$ . (b) Noisy σύνολο δεδομένων  $\tilde{\mathcal{D}}$  including an ακραία τιμή.

Βλέπε επίσης: τυχαία μεταβλητή, σύνολο δεδομένων, optimization problem, μέση τιμή, παράμετρος, πιθανοτικό μοντέλο, ακραία τιμή, data point, ευρωστία.

**nullspace** The nullspace of a πίνακας  $\mathbf{A} \in \mathbb{R}^{d' \times d}$ , denoted by  $\text{null}(\mathbf{A})$ , is the set of all διάνυσμα  $\mathbf{n} \in \mathbb{R}^d$  such that

$$\mathbf{A}\mathbf{n} = \mathbf{0}.$$

Consider a μάθηση χαρακτηριστικών method that uses the πίνακας  $\mathbf{A}$  to transform a διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  of a data point into a new διάνυσμα χαρακτηριστικών  $\mathbf{z} = \mathbf{A}\mathbf{x} \in \mathbb{R}^{d'}$ . The nullspace  $\text{null}(\mathbf{A})$  characterizes all directions in the original χώρος χαρακτηριστικών  $\mathbb{R}^d$  along which the transformation  $\mathbf{A}\mathbf{x}$  remains unchanged. In other words,

adding any διάνυσμα from the nullspace to a διάνυσμα χαρακτηριστικών  $\mathbf{x}$  does not affect the transformed representation  $\mathbf{z}$ . This property can be exploited to enforce invariances in the πρόβλεψης (computed from  $\mathbf{Ax}$ ). Fig. 65 illustrates one such invariance. It shows rotated versions of two handwritten digits, which approximately lie along 1-D curves in the original χώρος χαρακτηριστικών. These curves are aligned with a direction διάνυσμα  $\mathbf{n} \in \mathbb{R}^d$ . To ensure that the trained model is invariant to such rotations, we can choose the transformation πίνακας  $\mathbf{A}$  such that  $\mathbf{n} \in \text{null}(\mathbf{A})$ . This ensures that  $\mathbf{Ax}$ , and hence the resulting πρόβλεψη, is approximately insensitive to rotations of the input image.




Fig. 65. Rotated images of two handwritten digits. The rotations are approximately aligned along linear curves that are parallel to the διάνυσμα  $\mathbf{n}$ .

Βλέπε επίσης: πίνακας, διάνυσμα, μάθηση χαρακτηριστικών, διάνυσμα χαρακτηριστικών, data point, χώρος χαρακτηριστικών, πρόβλεψη, model.

Python demo: [click me](#)

**reinforcement learning (RL)** RL refers to an online learning setting where we can only evaluate the usefulness of a single υπόθεση (i.e., a choice of παράμετροι μοντέλου) at each time step  $t$ . In particular, RL methods apply the current υπόθεση  $h^{(t)}$  to the διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(t)}$  of the newly received data point. The usefulness of the resulting πρόβλεψη  $h^{(t)}(\mathbf{x}^{(t)})$  is quantified by a ανταμοιβή signal  $r^{(t)}$  (see Fig. 66).




Fig. 66. Three consecutive time steps  $t, t + 1, t + 2$  with corresponding συνάρτηση απώλειας  $L^{(t)}, L^{(t+1)}, L^{(t+2)}$ . During time step  $t$ , an RL method can evaluate the συνάρτηση απώλειας only for one specific υπόθεση  $h^{(t)}$ , resulting in the ανταμοιβή signal  $r^{(t)} = -L^{(t)}(h^{(t)})$ .

In general, the ανταμοιβή depends also on the previous πρόβλεψης  $h^{(t')}(x^{(t')})$  for  $t' < t$ . The goal of RL is to learn  $h^{(t)}$ , for each time step  $t$ , such that the (possibly discounted) cumulative ανταμοιβή is maximized [8], [114].

Βλέπε επίσης: online learning, υπόθεση, παράμετροι μοντέλου, διάνυσμα χαρακτηριστικών, data point, πρόβλεψη, ανταμοιβή, συνάρτηση απώλειας, ml.

**Markov decision process (MDP)** An MDP is a mathematical structure

that can be used to study RL applications. An MDP formalizes how ανταμοιβή signals depend on the πρόβλεψη (and corresponding actions) made by an RL method. Formally, an MDP is a specific type of στοχαστική διαδικασία defined by

- a state space  $\mathcal{S}$ ;
- an action space  $\mathcal{A}$  (where each action  $a \in \mathcal{A}$  corresponds to a specific πρόβλεψη made by the RL method);
- a transition συνάρτηση  $\mathbb{P}(s' | s, a)$  specifying the κατανομή πιθανότητας over the next state  $s' \in \mathcal{S}$ , given the current state  $s \in \mathcal{S}$  and action  $a \in \mathcal{A}$ ;
- a ανταμοιβή συνάρτηση  $r(s, a) \in \mathbb{R}$  that assigns a numerical ανταμοιβή to each state-action pair.

The defining property of an MDP is the Markov property. That is, the next state  $s'$  and ανταμοιβή only depend on the current state  $s$  and action  $a$ , not on the entire history of interactions.

Βλέπε επίσης: RL, ανταμοιβή, πρόβλεψη, στοχαστική διαδικασία, συνάρτηση, κατανομή πιθανότητας.

**epoch** An epoch represents one complete pass of the entire σύνολο εκπαίδευσης through some learning αλγόριθμος. It refers to the point at which a model has processed every data point in the σύνολο εκπαίδευσης once. Training a model usually requires multiple epochs, since each iteration allows the model to refine the παράμετρος and improve πρόβλεψης. The

number of epochs is something predefined by the user, and thus a hyperparameter, which plays a crucial role in determining how the model will generalize to unseen data. Too few epochs will result in υποπροσαρμογή, while too many epochs can result in υπερπροσαρμογή.

Βλέπε επίσης: σύνολο εκπαίδευσης, αλγόριθμος, model, data point, παράμετρος, πρόβλεψη, υποπροσαρμογή, υπερπροσαρμογή.

**concept activation vector (CAV)** Consider a βαθύ δίκτυο, consisting of several hidden στρώμας, trained to predict the ετικέτα of a data point from its διάνυσμα χαρακτηριστικών. One way to explain the behavior of the trained βαθύ δίκτυο is by using the ενεργοποίησης of a hidden στρώμα as a new διάνυσμα χαρακτηριστικών  $\mathbf{z}$ . We then probe the geometry of the resulting new χώρος χαρακτηριστικών by applying the βαθύ δίκτυο to data points that represent a specific concept  $\mathcal{C}$ . By applying the βαθύ δίκτυο also to data points that do not belong to this concept, we can train a binary γραμμικός ταξινομητής  $g(\mathbf{z})$  that distinguishes between concept and non-concept data points based on the ενεργοποίησης of the hidden στρώμα. The resulting όριο απόφασης is a hyperplane whose normal διάνυσμα is the CAV for the concept  $\mathcal{C}$ . Βλέπε επίσης: βαθύ δίκτυο, στρώμα, ετικέτα, data point, διάνυσμα χαρακτηριστικών, ενεργοποίηση, γραμμικός ταξινομητής, όριο απόφασης, γραμμικό μοντέλο, αξιόπιστη TN, ερμηνευσιμότητα, transparency.

**Rademacher complexity** TBD.

Βλέπε επίσης: χώρος υποθέσεων, γενίκευση, ml, αποτελεσματική διάσταση, διάσταση Vapnik–Chervonenkis.

**batch learning** In δέσμη learning (also known as offline learning), the ml model is trained on the entire σύνολο δεδομένων in a single training iteration, instead of updating it incrementally as data arrive. All available data are inputted into a learning αλγόριθμος, resulting in a model that can make πρόβλεψης. Since these σύνολο δεδομένωνs tend to be large, training is computationally expensive and time-consuming, so it is typically performed offline. After learning, the model will be static and will not adapt to new data automatically. Updating the model with new information requires retraining the model entirely. Once the model has been trained, it is launched into production where it cannot be updated. Training a model can take many hours, so many models in production settings are updated cyclically on a periodic schedule when the data distribution is stable. For example, a retail analytics team could retrain their demand forecast model every Sunday using the previous week's sales data to predict next week's demand. If a system needs to be constantly updated to rapidly changing data, such as in stock price πρόβλεψη, a more adaptable solution such as online learning is necessary.

Βλέπε επίσης: δέσμη, ml, model, σύνολο δεδομένων, data, αλγόριθμος, πρόβλεψη, online learning.

**ensemble** An ensemble method combines multiple ml methods, referred to as base learners, to improve overall performance. The base learners can be obtained from ελαχιστοποίηση εμπειρικής διακινδύνευσης, using different choices for the loss, model, and σύνολο εκπαίδευσης. Ensemble

methods exploit the diversity among these base learners to reduce errors. Loosely speaking, different base learners capture different aspects of the features of a data point. By aggregating the πρόβλεψης of base learners, ensemble methods can often achieve better performance than any single base learner. Different ensemble methods use different constructions for the base learners and how to aggregate their πρόβλεψης. For example, bagging (or bootstrap aggregation) methods use random sampling to construct different σύνολο εκπαίδευσης for the base learners. A well-known example of a bagging method is a τυχαίο δάσος. On the other hand, boosting methods train base learners sequentially, where each new base learner focuses on correcting the errors of the previous ones. A third family of ensemble methods is stacking, where base learners are trained on the same σύνολο εκπαίδευσης but with potentially different models.

Βλέπε επίσης: ml, ελαχιστοποίηση εμπειρικής διακινδύνευσης, loss, model, σύνολο εκπαίδευσης, feature, data point, πρόβλεψη, bagging, τυχαίο δάσος, boosting.

## Index

αβεβαιότητα	36	άνω φράγμα εμπιστοσύνης (ΑΦΕ)	48
αισιοδοξία παρά την αβεβαιότητα	36	αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN)	49
ακρίβεια	38	απόκλιση	50
ακραία τιμή	38	απόκλιση Kullback-Leibler (απόκλιση KL)	50
αλγόριθμος	39	απόκλιση Rényi	50
αλγόριθμος $k$ -μέσων	40	αποτελεσματική διάσταση	50
αμοιβαίες πληροφορίες	41	απώλεια	51
αμφικλινής παλινδρόμηση	42	απώλεια απόλυτου σφάλματος	51
ανάλυση ιδιαζουσών τιμών	43	απώλεια άρθρωσης	53
ανάλυση ιδιοτιμών	43	απώλεια τετραγωνικού σφάλματος	54
ανάλυση κυρίων συνιστωσών	44	απώλεια Huber	54
ανεξάρτητες και ταυτόσημα κατανεμημένες	44	αριθμός συνθήκης	55
ανταμοιβή	44	αρχή της ελαχιστοποίησης των δεδομένων	55
αντικειμενική συνάρτηση	45	αυτοκωδικοποιητής	55
αντιστροφή μοντέλου	46		
αντίστροφος πίνακας	47		



βαθμός κόμβου	56	γράφος	68
βαθμός συσχέτισης	56	γράφος ομοιότητας	69
βαθύ δίκτυο	56	δεδομένα	69
βάρη	56	δείγμα	69
βάρος ακμής	57	δειγματικός χώρος	70
βάση αναφοράς	57	δέντρο αποφάσεων	70
βήμα κλίσης	60	δέσμη	71
γεγονός	61	διάγραμμα διασποράς	71
γείτονες	61	διακινδύνευση	72
γειτονιά	62	διακινδύνευση Bayes	73
γενικευμένη ολική μεταβολή	62	διακύμανση	73
γενίκευση	62	διάμεσος	207
γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ)	64	διάνυσμα	25
γινόμενο Kronecker	65	διάνυσμα χαρακτηριστικών	73
γραμμική παλινδρόμηση	66	διανυσματικός χώρος	26
γραμμικό μοντέλο	66	διαρροή ιδιωτικότητας	74
γραμμικός ταξινομητής	68	διάσταση Vapnik–Chervonenkis	74

διασταυρούμενη επικύρωση $k$ -συνόλων	76	ενεργοποίηση	85
διάυλος ιδιωτικότητας	77	εντροπία	85
διαφάνεια	77	εξήγηση	85
διαφορική εντροπία	78	εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης	87
διαφορική ιδιωτικότητα	78	εξηγήσιμη μηχανική μάθηση	87
διεπαφή προγραμματισμού εφαρμογών	79	εξηγησιμότητα	87
δίκτυο ομοσπονδιακής μάθησης	80	επαύξηση δεδομένων	88
εκκίνηση	81	επίθεση	89
εκτιμητήρια Bayes	81	επίθεση άρνησης υπηρεσιών	90
ελάχιστο	82	επίθεση της ιδιωτικότητας	90
ελάχιστο άνω φράγμα (ή supremum)	82	επικύρωση	90
ελαχιστοποίηση γενικευμένης ολικής μεταβολής	82	επιλογή μοντέλου	90
ελαχιστοποίηση δομικής διακινδύνευσης	82	εργασία μάθησης	91
ελαχιστοποίηση εμπειρικής διακινδύνευσης	83	ερμηνευσιμότητα	91
εμπειρική διακινδύνευση	84	Εσσιανός	27
		ετικέτα	93
		ευαίσθητο ιδιοχαρακτηριστικό	93

Ευκλείδειος χώρος	93	λεία	103
ευρωστία	94	λογιστική απώλεια	104
ευστάθεια	94	λογιστική παλινδρόμηση	105
θετικά ημιορισμένος	95	μάθηση πολυδιεργασίας	105
ιδιοδιάνυσμα	96	μάθηση χαρακτηριστικών	106
ιδιοτιμή	96	μαλακή συσταδοποίηση	107
ιστόγραμμα	96	μεγάλο γλωσσικό μοντέλο	107
κάθοδος κλίσης	97	μέγεθος βήματος	108
κάθοδος υποκλίσης	98	μέγεθος δείγματος	108
κανονικοποίηση δεδομένων	99	μέγιστο	108
κατανομή πιθανότητας	99	μέθοδοι με βάση την κλίση	108
κεντρικό οριακό θεώρημα	100	μέθοδος βελτιστοποίησης	109
κερκόπορτα	100	μέθοδος πυρήνα	109
κλίση	101	μείωση της διαστασιμότητας	110
κριτήριο τερματισμού	101	μεροληψία	112
κυρτή βελτιστοποίηση	27	μέση τιμή	112
κυρτή συσταδοποίηση	102	μέση τιμή δείγματος	113
κυρτός	102	μέσο τετραγωνικό σφάλμα εκτίμησης	114

μετρήσιμο	114	οριζόντια ομοσπονδιακή μάθηση	126
μετρική	115	ορίζουσα	27
μη λεία	116	όριο απόφασης	126
μηχανή διανυσμάτων υποστήριξης (ΜΔΥ)	116	παλινδρόμηση	127
μηχανική μάθηση	117	παλινδρόμηση ελάχιστης απόλυτης απόκλισης	127
μοντέλο	118	παλινδρόμηση Huber	127
μοντέλο στοχαστικής ομάδας	119	παραγωγίσιμη	127
νόμος των μεγάλων αριθμών	119	παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων	128
νόρμα	120	παραδοχή συσταδοποίησης	128
ολική μεταβολή	120	παράμετρος	128
ομαλοποιημένη ελαχιστοποίηση απώλειας	120	παράμετροι μοντέλου	129
ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης	120	περιοχή αποφάσεων	129
ομαλοποίηση	121	πιθανότητα	129
ομαλοποιητής	123	πιθανοτικό μοντέλο	129
ομοσπονδιακή μάθηση	124	πίνακας	29
οπισθοδιάδοση	124	πίνακας σύγχυσης	130

πίνακας συνδιακύμανσης	130	προστασία της ιδιωτικότητας	138
πίνακας συνδιακύμανσης δείγματος	130	πυρήνας	138
πίνακας χαρακτηριστικών	131	ρυθμός μάθησης	140
πίνακας Laplace	131	σημείο δεδομένων	140
πλησιέστερος γείτονας	132	σημείο δεδομένων με ετικέτα	143
πολυμεταβλητή κανονική κατανομή	132	σκληρή συσταδοποίηση	143
πολυωνυμική παλινδρόμηση	134	στατιστικές διαστάσεις	143
πραγμάτωση	134	στοχαστική	143
προβεβλημένη κάθοδος κλίσης	134	στοχαστική διαδικασία	31
προβλέπουσα	135	στοχαστική κάθοδος κλίσης	144
πρόβλεψη	136	στοχαστικός αλγόριθμος	145
πρόβλημα βελτιστοποίησης	31	στρώμα	145
προβολή	136	σύγκλιση	32
προεικόνα	136	συνάρτηση	32
προσδοκία	137	συνάρτηση απώλειας	146
προσεγγίσιμος	137	συνάρτηση ενεργοποίησης	147
προσοχή	138	συνάρτηση πυκνότητας πιθανότητας	147

συνδεδεμένος γράφος	148	τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής	159
συνδιακύμανση	148	τετραγωνική συνάρτηση	159
συνθήκη μηδενικής κλίσης	149	τεχνητή νοημοσύνη (TN)	160
σύνολο δεδομένων	149	τεχνητό νευρωνικό δίκτυο (TNΔ)	160
σύνολο εκπαίδευσης	151	τοπικό μοντέλο	161
σύνολο ελέγχου	152	τοπικό σύνολο δεδομένων	161
σύνολο επικύρωσης	152	τυχαία μεταβλητή	162
συσκευή	153	τυχαίο δάσος	162
συστάδα	153	τυχαίο πείραμα	163
συσταδοποίηση	154	υπερπροσαρμογή	165
συσταδοποίηση γράφου	155	υπόθεση	165
συσταδοποίηση με βάση τη ροή	155	υποκλίση	166
σφάλμα εκπαίδευσης	155	υπολογιστικές διαστάσεις	166
σφάλμα εκτίμησης	156	υποπροσαρμογή	166
σφάλμα επικύρωσης	156	φασματική συσταδοποίηση	167
ταξινόμηση	157	Φινλανδικό Μετεωρολογικό Ινστιτούτο	169
ταξινομητής	157		
τελεστής εγγύτητας	158		

χαρακτηριστική συνάρτηση	33	χώρος πιθανοτήτων	172
χαρακτηριστικό	169	χώρος υποθέσεων	173
χάρτης χαρακτηριστικών	169	χώρος χαρακτηριστικών	174
χωρική συσταδοποίηση	170	χώρος Hilbert	175
εφαρμογών με θόρυβο με βάση την πυκνότητα		ψευδοαντίστροφος	175
χώρος ετικετών	171	0/1 απώλεια	176
χώρος παραμέτρων	172		

## References

- [1] W. Rudin, *Real and Complex Analysis*, 3rd ed. New York, NY, USA: McGraw-Hill, 1987.
- [2] W. Rudin, *Principles of Mathematical Analysis*, 3rd ed. New York, NY, USA: McGraw-Hill, 1976.
- [3] G. H. Golub and C. F. Van Loan, *Matrix Computations*, 4th ed. Baltimore, MD, USA: The Johns Hopkins Univ. Press, 2013.
- [4] G. H. Golub and C. F. Van Loan, “An analysis of the total least squares problem,” *SIAM J. Numer. Anal.*, vol. 17, no. 6, pp. 883–893, Dec. 1980, doi: 10.1137/0717073.
- [5] A. Klenke, *Probability Theory: A Comprehensive Course*, 3rd ed. Cham, Switzerland: Springer Nature, 2020.
- [6] P. Billingsley, *Probability and Measure*, 3rd ed. New York, NY, USA: Wiley, 1995.
- [7] D. P. Bertsekas and J. N. Tsitsiklis, *Introduction to Probability*, 2nd ed. Belmont, MA, USA: Athena Scientific, 2008.
- [8] A. Jung, *Machine Learning: The Basics*. Singapore, Singapore: Springer Nature, 2022.
- [9] G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, 2nd ed. New York, NY, USA: Wiley, 1999.



- [10] H. J. Dirschmid, *Tensors and Fields*, (in German). Vienna, Austria: Springer-Verlag, 1996.
- [11] G. Strang, *Computational Science and Engineering*. Wellesley, MA, USA: Wellesley-Cambridge Press, 2007.
- [12] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed. New York, NY, USA: Cambridge Univ. Press, 2013.
- [13] G. Strang, *Introduction to Linear Algebra*, 5th ed. Wellesley-Cambridge Press, MA, 2016.
- [14] D. P. Bertsekas, *Nonlinear Programming*, 2nd ed. Belmont, MA, USA: Athena Scientific, 1999.
- [15] S. Boyd and L. Vandenberghe, *Convex Optimization*. Cambridge, U.K.: Cambridge Univ. Press, 2004.
- [16] Y. Nesterov, *Introductory Lectures on Convex Optimization: A Basic Course*. Boston, MA, USA: Kluwer Academic, 2004.
- [17] P. J. Brockwell and R. A. Davis, *Time Series: Theory and Methods*, 2nd ed. New York, NY, USA: Springer-Verlag, 1991.
- [18] R. M. Gray, *Probability, Random Processes, and Ergodic Properties*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2009.
- [19] A. Papoulis and S. U. Pillai, *Probability, Random Variables, and Stochastic Processes*, 4th ed. New York, NY, USA: McGraw-Hill Higher Education, 2002.

- [20] S. Shalev-Shwartz and S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*. New York, NY, USA: Cambridge Univ. Press, 2014.
- [21] S. Bubeck and N. Cesa-Bianchi, “Regret analysis of stochastic and non-stochastic multi-armed bandit problems,” *Found. Trends Mach. Learn.*, vol. 5, no. 1, pp. 1–122, Dec. 2012, doi: 10.1561/22000000024.
- [22] M. Kearns and M. Li, “Learning in the presence of malicious errors,” *SIAM J. Comput.*, vol. 22, no. 4, pp. 807–837, Aug. 1993, doi: 10.1137/0222052.
- [23] G. Lugosi and S. Mendelson, “Robust multivariate mean estimation: The optimality of trimmed mean,” *Ann. Statist.*, vol. 49, no. 1, pp. 393–410, Feb. 2021, doi: 10.1214/20-AOS1961.
- [24] T. H. Cormen, C. E. Leiserson, R. L. Rivest, and C. Stein, *Introduction to Algorithms*. Cambridge, MA, USA: MIT Press, 2022. [Online]. Available: <http://ebookcentral.proquest.com/lib/aalto-ebooks/detail.action?docID=6925615>
- [25] M. Sipser, *Introduction to the Theory of Computation*, 3rd ed. Andover, U.K.: Cengage Learning, 2013.
- [26] M. Mahajan, P. Nimbhorkar, and K. Varadarajan, “The planar k-means problem is NP-hard,” in *WALCOM: Algorithms and Computation*, S. Das and R. Uehara, Eds. Berlin, Heidelberg, Germany: Springer-Verlag, 2009, pp. 274–285.
- [27] S. Lloyd, “Least squares quantization in PCM,” *IEEE Trans. Inf. Theory*, vol. 28, no. 2, pp. 129–137, Mar. 1982.

- [28] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ, USA: Wiley, 2006.
- [29] M. Fredrikson, S. Jha, and T. Ristenpart, “Model inversion attacks that exploit confidence information and basic countermeasures,” in *Proc. 22nd ACM SIGSAC Conf. Comput. Commun. Secur.*, Oct. 2015, pp. 1322–1333, doi: 10.1145/2810103.2813677.
- [30] R. A. Horn and C. R. Johnson, *Topics in Matrix Analysis*. Cambridge, UK: Cambridge Univ. Press, 1991.
- [31] D. Pfau and A. Jung, “Engineering trustworthy AI: A developer guide for empirical risk minimization,” Nov. 2024. [Online]. Available: <https://arxiv.org/abs/2410.19361>
- [32] High-Level Expert Group on Artificial Intelligence, “The assessment list for trustworthy artificial intelligence (ALTAI): For self assessment,” European Commission, Jul. 17, 2020. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment>
- [33] I. Csiszar, “Generalized cutoff rates and Renyi’s information measures,” *IEEE Trans. Inf. Theory*, vol. 41, no. 1, pp. 26–34, Jan. 1995, doi: 10.1109/18.370121.
- [34] S. Sra, S. Nowozin, and S. J. Wright, Eds., *Optimization for Machine Learning*. Cambridge, MA, USA: MIT Press, 2012.
- [35] C. H. Lampert, “Kernel methods in computer vision,” *Found. Trends*

*Comput. Graph. Vis.*, vol. 4, no. 3, pp. 193–285, Sep. 2009, doi: 10.1561/06000000027.

- [36] European Union, “Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation) (Text with EEA relevance),” L 119/1, May 4, 2016. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- [37] European Union, “Regulation (EU) 2018/1725 of the European Parliament and of the Council of 23 October 2018 on the protection of natural persons with regard to the processing of personal data by the Union institutions, bodies, offices and agencies and on the free movement of such data, and repealing Regulation (EC) No 45/2001 and Decision No 1247/2002/EC (Text with EEA relevance),” L 295/39, Nov. 21, 2018. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2018/1725/oj>
- [38] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [39] M. P. Salinas et al., “A systematic review and meta-analysis of artificial intelligence versus clinicians for skin cancer diagnosis,” *npj Digit. Med.*, vol. 7, no. 1, May 2024, Art. no. 125, doi: 10.1038/s41746-024-01103-x.
- [40] E. L. Lehmann and G. Casella, *Theory of Point Estimation*, 2nd ed. New York, NY, USA: Springer-Verlag, 1998.

- [41] G. F. Cooper, “The computational complexity of probabilistic inference using bayesian belief networks,” *Artif. Intell.*, vol. 42, no. 2–3, pp. 393–405, Mar. 1990, doi: 10.1016/0004-3702(90)90060-D.
- [42] N. Parikh and S. Boyd, “Proximal algorithms,” *Found. Trends Optim.*, vol. 1, no. 3, pp. 127–239, Jan. 2014, doi: 10.1561/24000000003.
- [43] J. Su, D. V. Vargas, and K. Sakurai, “One pixel attack for fooling deep neural networks,” *IEEE Trans. Evol. Comput.*, vol. 23, no. 5, pp. 828–841, Oct. 2019, doi: 10.1109/TEVC.2019.2890858.
- [44] S. Mallat, “Understanding deep convolutional networks,” *Philos. Trans. Roy. Soc. A*, vol. 374, no. 2065, Apr. 2016, Art. no. 20150203, doi: 10.1098/rsta.2015.0203.
- [45] C. Rudin, “Stop explaining black box machine learning models for high-stakes decisions and use interpretable models instead,” *Nature Mach. Intell.*, vol. 1, no. 5, pp. 206–215, May 2019, doi: 10.1038/s42256-019-0048-x.
- [46] M. T. Ribeiro, S. Singh, and C. Guestrin, “Why should i trust you?: Explaining the predictions of any classifier,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, Aug. 2016, pp. 1135–1144, doi: 10.1145/2939672.2939778.
- [47] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2009.

- [48] M. J. Wainwright, *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge, U.K.: Cambridge Univ. Press, 2019.
- [49] J. Heinonen, “Lectures on lipschitz analysis,” Dept. Math. Statist., Univ. Jyväskylä, Jyväskylä, Finland, Rep. 100, 2005. [Online]. Available: <http://www.math.jyu.fi/research/reports/rep100.pdf>
- [50] R. T. Rockafellar, *Network Flows and Monotropic Optimization*. Belmont, MA, USA: Athena Scientific, 1998.
- [51] E. F. Codd, “A relational model of data for large shared data banks,” *Commun. ACM*, vol. 13, no. 6, pp. 377–387, Jun. 1970, doi: 10.1145/362384.362685.
- [52] A. Silberschatz, H. F. Korth, and S. Sudarshan, *Database System Concepts*, 7th ed. New York, NY, USA: McGraw-Hill Education, 2019. [Online]. Available: <https://db-book.com/>
- [53] R. B. Ash, *Probability and Measure Theory*, 2nd ed. San Diego, CA, USA: Academic, 2000.
- [54] A. Ünsal and M. Önen, “Information-theoretic approaches to differential privacy,” *ACM Comput. Surv.*, vol. 56, no. 3, Oct. 2023, Art. no. 76, doi: 10.1145/3604904.
- [55] V. N. Vapnik and A. Y. Chervonenkis, “On the uniform convergence of relative frequencies of events to their probabilities,” in *Measures of Complexity: Festschrift for Alexey Chervonenkis*. Cham, Switzerland: Springer, 2015, ch. 3, pp. 11–30.

- [56] A. Makhdoumi, S. Salamatian, N. Fawaz, and M. Médard, “From the information bottleneck to the privacy funnel,” in *2014 IEEE Inf. Theory Workshop*, 2014, pp. 501–505, doi: 10.1109/ITW.2014.6970882.
- [57] High-Level Expert Group on Artificial Intelligence, “Ethics guidelines for trustworthy AI,” European Commission, Apr. 8, 2019. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>
- [58] A. Jung and P. H. J. Nardelli, “An information-theoretic approach to personalized explainable machine learning,” *IEEE Signal Process. Lett.*, vol. 27, pp. 825–829, 2020, doi: 10.1109/LSP.2020.2993176.
- [59] C. Gallese, “The AI act proposal: A new right to technical interpretability?” *SSRN Electron. J.*, Feb. 2023. [Online]. Available: <https://ssrn.com/abstract=4398206>
- [60] T. Gebru et al., “Datasheets for datasets,” *Commun. ACM*, vol. 64, no. 12, pp. 86–92, Nov. 2021, doi: 10.1145/3458723.
- [61] M. Mitchell et al., “Model cards for model reporting,” in *Proc. Conf. Fairness, Accountability, Transparency*, 2019, pp. 220–229, doi: 10.1145/3287560.3287596.
- [62] K. Shahriari and M. Shahriari, “IEEE standard review — Ethically aligned design: A vision for prioritizing human wellbeing with artificial intelligence and autonomous systems,” in *2017 IEEE Canada Int. Humanitarian Technol. Conf.*, 2017, pp. 197–201, doi: 10.1109/IHTC.2017.8058187.

- [63] L. Richardson and M. Amundsen, *RESTful Web APIs*. Sebastopol, CA, USA: O'Reilly Media, 2013.
- [64] Y. SarcheshmehPour, Y. Tian, L. Zhang, and A. Jung, "Clustered federated learning via generalized total variation minimization," *IEEE Trans. Signal Process.*, vol. 71, pp. 4240–4256, 2023, doi: 10.1109/TSP.2023.3322848.
- [65] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 3rd ed. Ebook, 2025, Accessed: August 1, 2025. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>
- [66] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *2017 IEEE Int. Conf. Comput. Vis.*, 2017, pp. 618–626, doi: 10.1109/ICCV.2017.74.
- [67] L. Zhang, G. Karakasidis, A. Odnoblyudova, L. Dogruel, Y. Tian, and A. Jung, "Explainable empirical risk minimization," *Neural Comput. Appl.*, vol. 36, no. 8, pp. 3983–3996, Mar. 2024, doi: 10.1007/s00521-023-09269-3.
- [68] J. Colin, T. Fel, R. Cadène, and T. Serre, "What I cannot predict, I do not understand: A human-centered evaluation framework for explainability methods," in *Adv. Neural Inf. Process. Syst.*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35, 2022, pp. 2832–2845. [Online].



Available: [https://proceedings.neurips.cc/paper\\_files/paper/2022/hash/13113e938f2957891c0c5e8df811dd01-Abstract-Conference.html](https://proceedings.neurips.cc/paper_files/paper/2022/hash/13113e938f2957891c0c5e8df811dd01-Abstract-Conference.html)

- [69] J. Chen, L. Song, M. J. Wainwright, and M. I. Jordan, “Learning to explain: An information-theoretic perspective on model interpretation,” in *Proc. 35th Int. Conf. Mach. Learn.*, J. Dy and A. Krause, Eds., vol. 80, 2018, pp. 883–892. [Online]. Available: <https://proceedings.mlr.press/v80/chen18j.html>
- [70] F. Doshi-Velez and B. Kim, “Towards a rigorous science of interpretable machine learning,” Mar. 2017. [Online]. Available: <https://arxiv.org/abs/1702.08608>
- [71] P. Hase and M. Bansal, “Evaluating explainable AI: Which algorithmic explanations help users predict model behavior?” in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics*, D. Jurafsky, J. Chai, N. Schluter, and J. Tetreault, Eds., Jul. 2020, pp. 5540–5552. [Online]. Available: <https://aclanthology.org/2020.acl-main.491>
- [72] Z. C. Lipton, “The mythos of model interpretability: In machine learning, the concept of interpretability is both important and slippery,” *Queue*, vol. 16, no. 3, pp. 31–57, Jun. 2018, doi: 10.1145/3236386.3241340.
- [73] D. N. Gujarati and D. C. Porter, *Basic Econometrics*, 5th ed. New York, NY, USA: McGraw-Hill/Irwin, 2009.
- [74] Y. Dodge, Ed., *The Oxford Dictionary of Statistical Terms*. New York, NY, USA: Oxford Univ. Press, 2003.

- [75] B. S. Everitt, *The Cambridge Dictionary of Statistics*, 2nd ed. Cambridge, U.K.: Cambridge Univ. Press, 2002.
- [76] B. Schölkopf and A. J. Smola, *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. Cambridge, MA, USA: MIT Press, 2002.
- [77] D. Sun, K.-C. Toh, and Y. Yuan, “Convex clustering: Model, theoretical guarantee and efficient algorithm,” *J. Mach. Learn. Res.*, vol. 22, no. 9, pp. 1–32, Jan. 2021. [Online]. Available: <http://jmlr.org/papers/v22/18-694.html>
- [78] K. Pelckmans, J. De Brabanter, J. A. K. Suykens, and B. De Moor, “Convex clustering shrinkage,” presented at the PASCAL Workshop Statist. Optim. Clustering Workshop, 2005.
- [79] S. Bubeck, “Convex optimization: Algorithms and complexity,” *Found. Trends Mach. Learn.*, vol. 8, no. 3–4, pp. 231–357, Nov. 2015, 10.1561/22000000050.
- [80] D. P. Bertsekas, *Convex Optimization Algorithms*. Belmont, MA, USA: Athena Scientific, 2015.
- [81] A. Vaswani et al., “Attention is all you need,” in *Adv. Neural Inf. Process. Syst.*, I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds., vol. 30, 2017, pp. 5998–6008. [Online]. Available: [https://papers.nips.cc/paper\\_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html](https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html)

- [82] S. M. Kay, *Fundamentals of Statistical Signal Processing: Estimation Theory*. Upper Saddle River, NJ, USA: Prentice Hall PTR, 1993.
- [83] R. Durrett, *Probability: Theory and Examples*, 4th ed. Cambridge, U.K.: Cambridge Univ. Press, 2010.
- [84] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer Science+Business Media, 2006.
- [85] N. Cristianini and J. Shawe-Taylor, *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. New York, NY, USA: Cambridge Univ. Press, 2000.
- [86] T. Hastie, R. Tibshirani, and M. Wainwright, *Statistical Learning with Sparsity: The Lasso and Generalizations*. Boca Raton, FL, USA: CRC Press, 2015.
- [87] E. A. Bender, *An Introduction to Mathematical Modeling*. New York, NY, USA: Wiley, 1978.
- [88] E. Abbe, “Community detection and stochastic block models: Recent developments,” *J. Mach. Learn. Res.*, vol. 18, no. 177, pp. 1–86, Apr. 2018. [Online]. Available: <http://jmlr.org/papers/v18/16-480.html>
- [89] S. Shalev-Shwartz and A. Tewari, “Stochastic methods for  $\ell_1$  regularized loss minimization,” in *Proc. 26th Annu. Int. Conf. Mach. Learn.*, L. Bottou and M. Littman, Eds., Jun. 2009, pp. 929–936.
- [90] Q. Yang, Y. Liu, Y. Cheng, Y. Kang, T. Chen, and H. Yu, “Horizontal

- federated learning,” in *Federated Learning*. Cham, Switzerland: Springer Nature, 2020, ch. 4, pp. 49–67.
- [91] O. Chapelle, B. Schölkopf, and A. Zien, Eds., *Semi-Supervised Learning*. Cambridge, MA, USA: MIT Press, 2006.
  - [92] P. R. Halmos, *Measure Theory*. New York, NY, USA: Springer-Verlag, 1974.
  - [93] O. Kallenberg, *Foundations of Modern Probability*. New York, NY, USA: Springer-Verlag, 1997.
  - [94] U. von Luxburg, “A tutorial on spectral clustering,” *Statist. Comput.*, vol. 17, no. 4, pp. 395–416, Dec. 2007, doi: 10.1007/s11222-007-9033-z.
  - [95] A. Y. Ng, M. I. Jordan, and Y. Weiss, “On spectral clustering: Analysis and an algorithm,” in *Adv. Neural Inf. Process. Syst.*, T. Dietterich, S. Becker, and Z. Ghahramani, Eds., vol. 14, 2001, pp. 849–856. [Online]. Available: [https://papers.nips.cc/paper\\_files/paper/2001/hash/801272ee79cfde7fa5960571fee36b9b-Abstract.html](https://papers.nips.cc/paper_files/paper/2001/hash/801272ee79cfde7fa5960571fee36b9b-Abstract.html)
  - [96] A. Lapidoth, *A Foundation in Digital Communication*. Cambridge, U.K.: Cambridge Univ. Press, 2009.
  - [97] A. Lapidoth, *A Foundation in Digital Communication*, 2nd ed. Cambridge, U.K.: Cambridge Univ. Press, 2017.
  - [98] L. Condat, “A primal–dual splitting method for convex optimization involving lipschitzian, proximable and linear composite terms,” *J. Optim.*

*Theory Appl.*, vol. 158, no. 2, pp. 460–479, Aug. 2013, doi: 10.1007/s10957-012-0245-9.

- [99] L. Bottou, “On-line learning and stochastic approximations,” in *On-Line Learning in Neural Networks*, D. Saad, Ed. New York, NY, USA: Cambridge Univ. Press, 1999, ch. 2, pp. 9–42.
- [100] R. Motwani and P. Raghavan, *Randomized Algorithms*. Cambridge, U.K.: Cambridge Univ. Press, 1995.
- [101] R. G. Gallager, *Stochastic Processes: Theory for Applications*. New York, NY, USA: Cambridge Univ. Press, 2013.
- [102] S. Abiteboul, R. Hull, and V. Vianu, *Foundations of Databases*. Reading, MA, USA: Addison-Wesley, 1995.
- [103] S. Hoberman, *Data Modeling Made Simple: A Practical Guide for Business and IT Professionals*, 2nd ed. Basking Ridge, NJ, USA: Technics Publications, 2009.
- [104] R. Ramakrishnan and J. Gehrke, *Database Management Systems*, 3rd ed. New York, NY, USA: McGraw-Hill, 2002.
- [105] D. A. Patterson and J. L. Hennessy, *Computer Organization and Design: The Hardware/Software Interface*, 5th ed. San Francisco, CA, USA: Morgan Kaufmann, 2013.
- [106] Y. SarcheshmehPour, Y. Tian, L. Zhang, and A. Jung, “Flow-based clustering and spectral clustering: A comparison,” in *2021 55th Asilomar*

*Conf. Signals, Syst., Comput.*, M. B. Matthews, Ed., 2021, pp. 1292–1296,  
doi: 10.1109/IEEECONF53345.2021.9723162.

- [107] H. H. Bauschke and P. L. Combettes, *Convex Analysis and Monotone Operator Theory in Hilbert Spaces*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2017.
- [108] D. P. Bertsekas, A. Nedic, and A. E. Ozdaglar, *Convex Analysis and Optimization*. Belmont, MA, USA: Athena Scientific, 2003.
- [109] S. Ross, *A First Course in Probability*, 9th ed. Boston, MA, USA: Pearson Education, 2014.
- [110] N. Young, *An Introduction to Hilbert Space*. New York, NY, USA: Cambridge Univ. Press, 1988.
- [111] A. Ben-Israel and T. N. E. Greville, *Generalized Inverses: Theory and Applications*, 2nd ed. New York, NY, USA: Springer-Verlag, 2003.
- [112] Q. Yang, Y. Liu, Y. Cheng, Y. Kang, T. Chen, and H. Yu, “Vertical federated learning,” in *Federated Learning*. Cham, Switzerland: Springer Nature, 2020, ch. 5, pp. 69–81.
- [113] C. E. Rasmussen and C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, USA: MIT Press, 2006.
- [114] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- [115] G. Tel, *Introduction to Distributed Algorithms*, 2nd ed. Cambridge, U.K.: Cambridge Univ. Press, 2000.

- [116] D. P. Bertsekas and J. N. Tsitsiklis, *Parallel and Distributed Computation: Numerical Methods*. Belmont, MA, USA: Athena Scientific, 2015.
- [117] N. Cesa-Bianchi and G. Lugosi, *Prediction, Learning, and Games*. New York, NY, USA: Cambridge Univ. Press, 2006.
- [118] E. Hazan, “Introduction to online convex optimization,” *Found. Trends Optim.*, vol. 2, no. 3–4, pp. 157–325, Aug. 2016, doi: 10.1561/24000000013.
- [119] L. Cohen, *Time-Frequency Analysis*. Upper Saddle River, NJ, USA: Prentice Hall PTR, 1995.
- [120] J. Li, L. Han, X. Li, J. Zhu, B. Yuan, and Z. Gou, “An evaluation of deep neural network models for music classification using spectrograms,” *Multimedia Tools Appl.*, vol. 81, no. 4, pp. 4621–4647, Feb. 2022, doi: 10.1007/s11042-020-10465-9.
- [121] B. Boashash, Ed., *Time Frequency Signal Analysis and Processing: A Comprehensive Reference*. Oxford, U.K.: Elsevier, 2003.
- [122] S. Mallat, *A Wavelet Tour of Signal Processing: The Sparse Way*, 3rd ed. Burlington, MA, USA: Academic, 2009.
- [123] A. Rakhlin, O. Shamir, and K. Sridharan, “Making gradient descent optimal for strongly convex stochastic optimization,” in *Proc. 29th Int. Conf. Mach. Learn.*, J. Langford and J. Pineau, Eds., 2012, pp. 449–456. [Online]. Available: <https://icml.cc/Conferences/2012/papers/261.pdf>

- [124] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *J. Roy. Statist. Soc.: Ser. B (Statist. Methodology)*, vol. 61, no. 3, pp. 611–622, 1999, doi: 10.1111/1467-9868.00196.
- [125] M. J. Wainwright and M. I. Jordan, “Graphical models, exponential families, and variational inference,” *Found. Trends Mach. Learn.*, vol. 1, no. 1–2, pp. 1–305, Nov. 2008, doi: 10.1561/22000000001.
- [126] P. Bühlmann and S. van de Geer, *Statistics for High-Dimensional Data: Methods, Theory and Applications*. Berlin, Germany: Springer-Verlag, 2011.
- [127] A. Jung, “Networked exponential families for big data over networks,” *IEEE Access*, vol. 8, pp. 202 897–202 909, Nov. 2020, doi: 10.1109/ACCESS.2020.3033817.
- [128] X. Liu, H. Li, G. Xu, Z. Chen, X. Huang, and R. Lu, “Privacy-enhanced federated learning against poisoning adversaries,” *IEEE Trans. Inf. Forensics Security*, vol. 16, pp. 4574–4588, 2021, doi: 10.1109/TIFS.2021.3108434.
- [129] J. Zhang, B. Chen, X. Cheng, H. T. T. Binh, and S. Yu, “PoisonGAN: Generative poisoning attacks against federated learning in edge computing systems,” *IEEE Internet Things J.*, vol. 8, no. 5, pp. 3310–3322, Mar. 2021, doi: 10.1109/JIOT.2020.3023126.
- [130] H. P. Lopuhaä and P. J. Rousseeuw, “Breakdown points of affine equivariant estimators of multivariate location and covariance ma-



- trices,” *Ann. Statist.*, vol. 19, no. 1, pp. 229–248, Mar. 1991, doi: 10.1214/aos/1176347978.
- [131] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, “Communication-efficient learning of deep networks from decentralized data,” in *Proc. 20th Int. Conf. Artif. Intell. Statist.*, A. Singh and J. Zhu, Eds., vol. 54, 2017, pp. 1273–1282. [Online]. Available: <https://proceedings.mlr.press/v54/mcmahan17a.html>
- [132] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar, and V. Smith, “Federated optimization in heterogeneous networks,” in *Proc. Mach. Learn. Syst.*, I. Dhillon, D. Papailiopoulos, and V. Sze, Eds., vol. 2, 2020. [Online]. Available: [https://proceedings.mlsys.org/paper\\_files/paper/2020/hash/1f5fe83998a09396ebe6477d9475ba0c-Abstract.html](https://proceedings.mlsys.org/paper_files/paper/2020/hash/1f5fe83998a09396ebe6477d9475ba0c-Abstract.html)
- [133] K. Abayomi, A. Gelman, and M. Levy, “Diagnostics for multivariate imputations,” *J. Roy. Statist. Soc.: Ser. C (Appl. Statist.)*, vol. 57, no. 3, pp. 273–291, Jun. 2008, doi: 10.1111/j.1467-9876.2007.00613.x.
- [134] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Ann. Statist.*, vol. 29, no. 5, pp. 1189–1232, Oct. 2001, doi: 10.1214/aos/1013203451.
- [135] V. I. Istrăţescu, *Fixed Point Theory: An Introduction*. Dordrecht, The Netherlands: D. Reidel, 1981.