

# Το **A'**alto Λεξικό της Μηχανικής Μάθησης

Alexander Jung<sup>1</sup>, Konstantina Olioumtsevits<sup>1</sup>, Ekkehard Schnoor<sup>1</sup>,  
Tommi Flores Ryynänen<sup>1</sup>, Juliette Gronier<sup>2</sup>, Salvatore Rastelli<sup>1</sup>, και  
Mikko Seesto<sup>1</sup>

<sup>1</sup>Aalto University    <sup>2</sup>ENS Lyon

Μετάφραση από την Konstantina Olioumtsevits

February 16, 2026



αναφορά ως: A. Jung, K. Olioumtsevits, E. Schnoor, T. Ryynänen,  
J. Gronier, S. Rastelli, and M. Seesto, *To Aalto Λεξικό της  
Μηχανικής Μάθησης* [The Aalto Dictionary of Machine Learning].  
Transl. K. Olioumtsevits. Espoo, Finland: Aalto University, 2026.

## Ευχαριστίες

Αυτό το λεξικό της μηχανικής μάθησης αναπτύχθηκε κατά τον σχεδιασμό και την υλοποίηση διαφορετικών μαθημάτων, συμπεριλαμβανομένων των CS-E3210 Machine Learning: Basic Principles, CS-C3240 Machine Learning, CS-E4800 Artificial Intelligence, CS-EJ3211 Machine Learning with Python, CS-EJ3311 Deep Learning with Python, CS-E4740 Federated Learning, και CS-E407507 Human-Centered Machine Learning. Αυτά τα μαθήματα προσφέρονται στο Aalto University <https://www.aalto.fi/en>, σε ενήλικους/ες σπουδαστές/σπουδάστριες μέσω του The Finnish Institute of Technology (FITech) <https://fitech.io/en/>, και σε διεθνείς φοιτητές/φοιτήτριες μέσω της European University Alliance Unite! <https://www.aalto.fi/en/unite>. Είμαστε ευγνώμονες στους/στις σπουδαστές/σπουδάστριες που παρείχαν πολύτιμα σχόλια που ήταν καθοριστικά για το συγκεκριμένο λεξικό. Αυτό το έργο υποστηρίχθηκε από

- το Research Council of Finland (grants 331197, 363624, 349966).
- την Ευρωπαϊκή Ένωση (grant 952410).
- το Jane and Aatos Erkkö Foundation (grant A835).
- την Business Finland, ως μέρος του έργου Forward-Looking AI Governance in Banking and Insurance (FLAIG).

Η μετάφραση στα ελληνικά βασίστηκε ιδιαίτερα σε σχετικά σχολικά βιβλία λυκείου <https://ebooks.edu.gr/ebooks>, σε αρχεία από την Εθνική Υπηρεσία Πληροφοριών της Ελλάδας <https://www.nis.gr/en>, σε έγγραφα της Ευρωπαϊκής Ένωσης όπως <https://eur-lex.europa.eu/legal-content/EL/>

TXT/?uri=CELEX:32024R1689, στο παρακάτω βιβλίο:

A. Jung, *Μηχανική Μάθηση: Τα Βασικά*. Αθήνα, Ελλάδα: Fountas, 2024.

καθώς και σε σχετικά λεξικά:

Γ. Γεωργίου, *Αγγλοελληνικό Λεξικό Μαθηματικής Ορολογίας*, 1999. [Διαδικτυακά]. Διαθέσιμο: <https://www.mas.ucy.ac.cy/georgios/bookfiles/dict1.pdf>. Πρόσβαση: 30 Μαΐου 2025.

A. Καλογεροπούλου, M. Γκίκας, Δ. Καραγιαννάκης, και M. Λάμπρου, *Αγγλοελληνικό Λεξικό Μαθηματικών Όρων*. Αθήνα, Ελλάδα: Τροχαλία, 1992.

Σ. Καπιδάκης, K. Τοράκη, Σ. Χατζημαρή, K. Βαλεοντής, και Υ. Κύττα, *Λεξικό Επιστήμης της Πληροφόρησης*. Αθήνα, Ελλάδα: Κάλλιπος, Ανοιχτές Ακαδημαϊκές Εκδόσεις, 2024.

## Περιεχόμενα

Κατάλογοι Συμβόλων	5
Μαθηματικά Εργαλεία	28
Έννοιες Μηχανικής Μάθησης	85
Ενισχυτική Μάθηση	203
Συστήματα Μηχανικής Μάθησης	211
Κανονισμός Μηχανικής Μάθησης	217
Index	224
References	236

# Κατάλογοι Συμβόλων

## Σύνολα και Συναρτήσεις

$a \in \mathcal{A}$  Το αντικείμενο  $a$  είναι ένα στοιχείο του συνόλου  $\mathcal{A}$ .

---

$a := b$  Ορίζουμε το  $a$  ως  $b$ .

---

$|\mathcal{A}|$  Η καρδινικότητα (δηλαδή ο αριθμός των στοιχείων) ενός πεπερασμένου συνόλου  $\mathcal{A}$ .

---

$\mathcal{A} \subseteq \mathcal{B}$  Το  $\mathcal{A}$  είναι ένα υποσύνολο του  $\mathcal{B}$ .

---

$\mathcal{A} \subset \mathcal{B}$  Το  $\mathcal{A}$  είναι ένα αυστηρό υποσύνολο του  $\mathcal{B}$ .

---

$\mathcal{A} \times \mathcal{B}$  Το Καρτεσιανό γινόμενο των συνόλων  $\mathcal{A}$  και  $\mathcal{B}$ .

---

$\mathbb{N}$  Οι φυσικοί αριθμοί  $1, 2, \dots$ .

---

$\mathbb{R}$  Οι πραγματικοί αριθμοί  $x$  [1].

---

$\mathbb{R}_+$  Οι μη αρνητικοί πραγματικοί αριθμοί  $x \geq 0$ .

---

$\mathbb{R}_{++}$  Οι θετικοί πραγματικοί αριθμοί  $x > 0$ .

---

$\{0, 1\}$  Το σύνολο που αποτελείται από τους δύο πραγματικούς αριθμούς 0 και 1.

---

$[0, 1]$  Το κλειστό διάστημα που αποτελείται από  $x \in \mathbb{R}$  για κάθε  $0 \leq x \leq 1$ .

$\arg \min_{\mathbf{w} \in \mathcal{C}} f(\mathbf{w})$	<p>Το σύνολο των <math>\mathbf{w} \in \mathcal{C}</math> που ελαχιστοποιούν τη συνάρτηση πραγματικής τιμής <math>f : \mathcal{C} \rightarrow \mathbb{R}</math>.</p> <p>Βλέπε επίσης: συνάρτηση.</p>
$\mathbb{S}^{(n)}$	<p>Το σύνολο των διανυσμάτων μοναδιαίας νόρμας στο <math>\mathbb{R}^{n+1}</math>.</p> <p>Βλέπε επίσης: νόρμα, διάνυσμα.</p>
$\exp(a)$	<p>Η εκθετική συνάρτηση που αξιολογείται στον πραγματικό αριθμό <math>a \in \mathbb{R}</math>.</p> <p>Βλέπε επίσης: συνάρτηση.</p>
$\log a$	<p>Ο λογάριθμος του θετικού αριθμού <math>a \in \mathbb{R}_{++}</math>.</p>
$f(\cdot) : \mathcal{A} \rightarrow \mathcal{B} : a \mapsto f(a)$	<p>Μία συνάρτηση (ή απεικόνιση) από ένα σύνολο <math>\mathcal{A}</math> σε ένα σύνολο <math>\mathcal{B}</math>, η οποία αποδίδει σε κάθε είσοδο <math>a \in \mathcal{A}</math> μία καλά ορισμένη έξοδο <math>f(a) \in \mathcal{B}</math>. Το σύνολο <math>\mathcal{A}</math> είναι το πεδίο της συνάρτησης <math>f</math> και το σύνολο <math>\mathcal{B}</math> είναι το πεδίο τιμών της <math>f</math>. Η μηχανική μάθηση στοχεύει να μάθει μία συνάρτηση που αντιστοιχίζει χαρακτηριστικά <math>\mathbf{x}</math> ενός σημείου δεδομένων σε μία πρόβλεψη <math>h(\mathbf{x})</math> για την ετικέτα του <math>y</math>.</p> <p>Βλέπε επίσης: συνάρτηση, απεικόνιση, έξοδος, πεδίο, πεδίο τιμών, μηχανική μάθηση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα.</p>

$\text{epi}(f)$	<p>Ο επιγράφος μίας συνάρτησης πραγματικής τιμής <math>f : \mathbb{R}^d \rightarrow \mathbb{R}</math>.</p> <p>Βλέπε επίσης: επιγραφή, συνάρτηση.</p>
$(a_r)_{r \in \mathbb{N}}, (a^{(r)})_{r \in \mathbb{N}}, \{a^{(r)}\}_{r \in \mathbb{N}}$	<p>Μία ακολουθία στοιχείων.</p> <p>Βλέπε επίσης: ακολουθία.</p>
$\mathbb{I}_{\mathcal{A}}(x)$	<p>Η συνάρτηση-δείκτης ενός συνόλου <math>\mathcal{A}</math> παραδίδει <math>f(x) = 1</math> για κάθε <math>x \in \mathcal{A}</math> και <math>f(x) = 0</math> διαφορετικά.</p> <p>Βλέπε επίσης: συνάρτηση.</p>
$\frac{\partial f(w_1, \dots, w_d)}{\partial w_j}$	<p>Η μερική παράγωγος (αν υφίσταται) μίας συνάρτησης πραγματικής τιμής <math>f : \mathbb{R}^d \rightarrow \mathbb{R}</math> αναφορικά με το <math>w_j</math> [2, Κεφ. 9].</p> <p>Βλέπε επίσης: μερική παράγωγος, συνάρτηση.</p>
$\nabla f(\mathbf{w})$	<p>Η κλίση μίας παραγωγίσιμης συνάρτησης πραγματικής τιμής <math>f : \mathbb{R}^d \rightarrow \mathbb{R}</math> είναι το διάνυσμα <math>\nabla f(\mathbf{w}) = (\partial f / \partial w_1, \dots, \partial f / \partial w_d)^T \in \mathbb{R}^d</math> [2, Κεφ. 9].</p> <p>Βλέπε επίσης: κλίση, παραγωγίσιμη, συνάρτηση, διάνυσμα.</p>
$\partial \mathcal{C}$	<p>Το όριο ενός υποσυνόλου <math>\mathcal{C}</math> κάποιου μετρικού χώρου.</p> <p>Βλέπε επίσης: όριο, μετρικός χώρος.</p>
$\text{Id}$	<p>Ο τελεστή ταυτότητας.</p> <p>Βλέπε επίσης: τελεστής.</p>

## Διανυσματικοί χώροι

$\mathbf{x} = (x_1, \dots, x_d)^T$	Ένα διάνυσμα μήκους $d$ , με την $j$ -οστή του καταχώριση να είναι $x_j$ . Βλέπε επίσης: διάνυσμα.
$\mathbb{R}^d$	Το σύνολο όλων των διανυσμάτων $\mathbf{x} = (x_1, \dots, x_d)^T$ που αποτελούνται από $d$ καταχωρίσεις πραγματικών τιμών $x_1, \dots, x_d \in \mathbb{R}$ . Βλέπε επίσης: διάνυσμα.
$\mathbf{I}_{l \times d}$	Ένας γενικευμένος πίνακας ταυτότητας με $l$ γραμμές και $d$ στήλες. Οι καταχωρίσεις του $\mathbf{I}_{l \times d} \in \mathbb{R}^{l \times d}$ είναι ίσες με 1 κατά μήκος της κύριας διαγωνίου και με 0 διαφορετικά. Βλέπε επίσης: πίνακας.
$\mathbf{I}_d, \mathbf{I}$	Ένας τετραγωνικός πίνακας ταυτότητας μεγέθους $d \times d$ . Αν το μέγεθος είναι προφανές από τα συμφραζόμενα, παραλείπουμε τον δείκτη. Βλέπε επίσης: πίνακας.
$\ \mathbf{x}\ _2$	Η Ευκλείδειος (ή $\ell_2$ ) νόρμα του διανύσματος $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$ ορίζεται ως $\ \mathbf{x}\ _2 := \sqrt{\sum_{j=1}^d x_j^2}$ . Βλέπε επίσης: νόρμα, διάνυσμα.
$\ \mathbf{x}\ $	Κάποια νόρμα του διανύσματος $\mathbf{x} \in \mathbb{R}^d$ [3]. Εκτός αν προσδιορίζεται διαφορετικά, εννοούμε την Ευκλείδεια νόρμα $\ \mathbf{x}\ _2$ . Βλέπε επίσης: νόρμα, διάνυσμα, Ευκλείδεια νόρμα.



$\mathbf{x}^T$	<p>Η ανάστροφος ενός διανύσματος <math>\mathbf{x} \in \mathbb{R}^d</math> είναι ένας πίνακας <math>\mathbf{x}^T \in \mathbb{R}^{1 \times d}</math> με το διάνυσμα ως μοναδική του γραμμή.</p> <p>Βλέπε επίσης: ανάστροφος, διάνυσμα, πίνακας.</p>
$\mathbf{X}^T$	<p>Ο ανάστροφος πίνακας <math>\mathbf{X} \in \mathbb{R}^{m \times d}</math>. Ένας τετραγωνικός πίνακας πραγματικών τιμών <math>\mathbf{X} \in \mathbb{R}^{m \times m}</math> λέγεται συμμετρικός αν <math>\mathbf{X} = \mathbf{X}^T</math>.</p> <p>Βλέπε επίσης: ανάστροφος, πίνακας.</p>
$\mathbf{X}^{-1}$	<p>Ο αντίστροφος πίνακας ενός πίνακα <math>\mathbf{X} \in \mathbb{R}^{d \times d}</math>.</p> <p>Βλέπε επίσης: αντίστροφος πίνακας, πίνακας.</p>
$\mathbf{0} = (0, \dots, 0)^T$	<p>Το διάνυσμα στον <math>\mathbb{R}^d</math> με κάθε καταχώριση να είναι ίση με μηδέν.</p> <p>Βλέπε επίσης: διάνυσμα.</p>
$\mathbf{1} = (1, \dots, 1)^T$	<p>Το διάνυσμα στον <math>\mathbb{R}^d</math> με κάθε καταχώριση να είναι ίση με ένα.</p> <p>Βλέπε επίσης: διάνυσμα.</p>
$(\mathbf{v}^T, \mathbf{w}^T)^T$	<p>Το διάνυσμα μήκους <math>d + d'</math> που προκύπτει από την αλληλουχία των καταχωρίσεων του διανύσματος <math>\mathbf{v} \in \mathbb{R}^d</math> με τις καταχωρίσεις του <math>\mathbf{w} \in \mathbb{R}^{d'}</math>.</p> <p>Βλέπε επίσης: διάνυσμα.</p>

$\text{span}(\mathbf{B})$	<p>Το εύρος ενός πίνακα <math>\mathbf{B} \in \mathbb{R}^{a \times b}</math>, ο οποίος είναι ο υποχώρος όλων των γραμμικών συνδυασμών των στηλών του <math>\mathbf{B}</math> έτσι ώστε <math>\text{span}(\mathbf{B}) = \{\mathbf{B}\mathbf{a} : \mathbf{a} \in \mathbb{R}^b\} \subseteq \mathbb{R}^a</math>.</p> <p>Βλέπε επίσης: πίνακας, υποχώρος.</p>
$\text{null}(\mathbf{A})$	<p>Ο nullspace ενός πίνακα <math>\mathbf{A} \in \mathbb{R}^{a \times b}</math>, ο οποίος είναι ο υποχώρος των διανυσμάτων <math>\mathbf{a} \in \mathbb{R}^b</math> έτσι ώστε <math>\mathbf{A}\mathbf{a} = \mathbf{0}</math>.</p> <p>Βλέπε επίσης: nullspace, πίνακας, υποχώρος, διάνυσμα.</p>
$\det(\mathbf{C})$	<p>Η ορίζουσα του πίνακα <math>\mathbf{C}</math>.</p> <p>Βλέπε επίσης: ορίζουσα, πίνακας.</p>
$\text{tr}(\mathbf{C})$	<p>Το ίχνος του πίνακα <math>\mathbf{C}</math>.</p> <p>Βλέπε επίσης: ίχνος, πίνακας.</p>
$\mathbf{A} \otimes \mathbf{B}$	<p>Το γινόμενο Kronecker των πινάκων <math>\mathbf{A}</math> και <math>\mathbf{B}</math> [4].</p> <p>Βλέπε επίσης: γινόμενο Kronecker, πίνακας.</p>
$\mathbf{a} \geq \mathbf{b}$	<p>Η ανισότητα από άποψη καταχωρίσεων μεταξύ των διανυσμάτων <math>\mathbf{a}, \mathbf{b} \in \mathbb{R}^d</math>, δηλαδή</p> $a_j \geq b_j \text{ για } j = 1, \dots, d.$ <p>Βλέπε επίσης: διάνυσμα.</p>

$\overline{\mathcal{B}}_\varepsilon(\mathbf{x})$  Μία κλειστή μπάλα σε κάποιον μετρικό χώρο που περιέχει όλα τα σημεία με απόσταση από το  $\mathbf{x}$  μικρότερη ή ίση της  $\varepsilon$ .

Βλέπε επίσης: μετρικός χώρος.

---

$\|\mathbf{w}\|_{\mathcal{H}}$  Η νόρμα ενός διανύσματος  $\mathbf{w} \in \mathcal{H}$  σε έναν χώρο Hilbert  $\mathcal{H}$ .  
Βλέπε επίσης: νόρμα, διάνυσμα, χώρος Hilbert.

## Θεωρία Πιθανοτήτων

$\mathbf{x} \sim \mathbb{P}(\mathbf{z})$  Η τυχαία μεταβλητή  $\mathbf{x}$  κατανέμεται σύμφωνα με την κατανομή πιθανότητας  $\mathbb{P}(\mathbf{z})$  [5], [6].

Βλέπε επίσης: τυχαία μεταβλητή, κατανομή πιθανότητας.

---

$\mathbb{E}_p\{f(\mathbf{z})\}$  Η προσδοκία μίας τυχαίας μεταβλητής  $f(\mathbf{z})$  που προκύπτει από την εφαρμογή μίας ντετερμινιστικής συνάρτησης  $f$  σε μία τυχαία μεταβλητή  $\mathbf{z}$  της οποίας η κατανομή πιθανότητας είναι  $\mathbb{P}(\mathbf{z})$ . Αν η κατανομή πιθανότητας είναι προφανής από τα συμφραζόμενα, γράφουμε απλώς  $\mathbb{E}\{f(\mathbf{z})\}$ .

Βλέπε επίσης: προσδοκία, τυχαία μεταβλητή, συνάρτηση, κατανομή πιθανότητας.

---

$\text{cov}(x, y)$  Η συνδιακύμανση μεταξύ δύο τυχαίων μεταβλητών πραγματικής τιμής που ορίζεται πάνω σε έναν κοινό χώρο πιθανοτήτων.

Βλέπε επίσης: συνδιακύμανση, τυχαία μεταβλητή, κατανομή πιθανότητας.

---

$\mathbb{P}(\mathbf{x}, y)$  Μία (από κοινού) κατανομή πιθανότητας μίας τυχαίας μεταβλητής της οποίας οι πραγματώσεις είναι σημεία δεδομένων με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ .

Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, πραγματώση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα.

$\mathbb{P}(y \mathbf{x})$	<p>Μία κατανομή πιθανότητας υπό συνθήκη μίας τυχαίας μεταβλητής <math>y</math> δεδομένης (ή υπό τον όρο) της τιμής μίας άλλης τυχαίας μεταβλητής <math>\mathbf{x}</math> [7, Sec. 3.5].</p> <p>Βλέπε επίσης: κατανομή πιθανότητας υπό συνθήκη, τυχαία μεταβλητή.</p>
$\mathbb{P}(\mathcal{A})$	<p>Η πιθανότητα του μετρήσιμου γεγονότος <math>\mathcal{A}</math>.</p> <p>Βλέπε επίσης: πιθανότητα, μετρήσιμο, γεγονός.</p>
$M_x(t)$	<p>Η moment generating function (MGF) μίας τυχαίας μεταβλητής <math>x</math>.</p> <p>Βλέπε επίσης: κατανομή πιθανότητας, συνάρτηση πυκνότητας πιθανότητας.</p>
$\mathbb{P}(\mathcal{D})$	<p>Η εμπειρική κατανομή ενός συνόλου δεδομένων <math>\mathcal{D}</math>.</p> <p>Βλέπε επίσης: εμπειρική κατανομή, σύνολο δεδομένων, εκκίνηση.</p>
$\mathbb{P}(\mathbf{x};\mathbf{w})$	<p>Μία παραμετροποιημένη κατανομή πιθανότητας μίας τυχαίας μεταβλητής <math>\mathbf{x}</math>. Η κατανομή πιθανότητας εξαρτάται από ένα παραμετρικό διάνυσμα <math>\mathbf{w}</math>. Για παράδειγμα, <math>\mathbb{P}(\mathbf{x};\mathbf{w})</math> θα μπορούσε να είναι μία πολυμεταβλητή κανονική κατανομή με το παραμετρικό διάνυσμα <math>\mathbf{w}</math> που δίνεται από τις καταχωρίσεις του διανύσματος μέσης τιμής <math>\mathbb{E}\{\mathbf{x}\}</math> και τον πίνακα συνδιακύμανσης <math>\mathbb{E}\left\{(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})^T\right\}</math>.</p> <p>Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, παράμετρος, διάνυσμα, πολυμεταβλητή κανονική κατανομή, μέση τιμή, πίνακας συνδιακύμανσης, πιθανοτικό μοντέλο.</p>

$\mathcal{N}(\mu, \sigma^2)$	<p>Η κατανομή πιθανότητας μίας Γκαουσιανής τυχαίας μεταβλητής <math>x \in \mathbb{R}</math> με μέση τιμή (ή προσδοκία) <math>\mu = \mathbb{E}\{x\}</math> και διακύμανση <math>\sigma^2 = \mathbb{E}\{(x - \mu)^2\}</math>.</p> <p>Βλέπε επίσης: κατανομή πιθανότητας, Γκαουσιανή τυχαία μεταβλητή, μέση τιμή, expectation, διακύμανση.</p>
$\mathcal{N}(\boldsymbol{\mu}, \mathbf{C})$	<p>Η πολυμεταβλητή κανονική κατανομή μίας Γκαουσιανής τυχαίας μεταβλητής τιμής διανύσματος <math>\mathbf{x} \in \mathbb{R}^d</math> με μέση τιμή (ή προσδοκία) <math>\boldsymbol{\mu} = \mathbb{E}\{\mathbf{x}\}</math> και πίνακα συνδιακύμανσης <math>\mathbf{C} = \mathbb{E}\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\}</math>.</p> <p>Βλέπε επίσης: πολυμεταβλητή κανονική κατανομή, διάνυσμα, Γκαουσιανή τυχαία μεταβλητή, μέση τιμή, expectation, πίνακας συνδιακύμανσης.</p>
$\Delta^k$	<p>Το probability simplex, το οποίο αποτελείται από όλα τα διανύσματα <math>\mathbf{p} = (p_1, \dots, p_k)^T \in \mathbb{R}^k</math> με μη αρνητικές καταχωρίσεις που αθροίζουν στο ένα, δηλαδή <math>p_c \geq 0</math> για <math>c = 1, \dots, k</math> και <math>\sum_{c=1}^k p_c = 1</math>.</p> <p>Βλέπε επίσης: συνάρτηση μάζας πιθανότητας.</p>
$H(x)$	<p>Η εντροπία μίας διακριτής τυχαίας μεταβλητής <math>x</math>.</p> <p>Βλέπε επίσης: εντροπία, discrete random variable (discrete RV).</p>
$\Omega$	<p>Ένας δειγματικός χώρος όλων των πιθανών εκβάσεων ενός τυχαίου πειράματος.</p> <p>Βλέπε επίσης: δειγματικός χώρος, έκβαση, τυχαίο πείραμα, γεγονός.</p>
$\Sigma$	<p>Μία συλλογή μετρήσιμων υποσυνόλων ενός δειγματικού χώρου <math>\Omega</math>.</p> <p>Βλέπε επίσης: μετρήσιμο, δειγματικός χώρος, γεγονός.</p>

Ένας χώρος πιθανοτήτων που αποτελείται από έναν δειγματικό χώρο  $\Omega$ , μία  $\sigma$ -άλγεβρα  $\Sigma$  μετρήσιμων υποσυνόλων του  $\Omega$ , και μία κατανομή πιθανότητας  $\mathbb{P}(\cdot)$ .

Βλέπε επίσης: χώρος πιθανοτήτων, δειγματικός χώρος,  $\sigma$ -άλγεβρα, μετρήσιμο, κατανομή πιθανότητας.

## Μηχανική Μάθηση

$r$	<p>Ένας δείκτης <math>r = 1, 2, \dots</math> που απαριθμεί τα σημεία δεδομένων.</p> <p>Βλέπε επίσης: σημείο δεδομένων.</p>
$m$	<p>Ο αριθμός των σημείων δεδομένων σε ένα σύνολο δεδομένων (δηλαδή το μέγεθός του).</p> <p>Βλέπε επίσης: σημείο δεδομένων, σύνολο δεδομένων.</p>
$\mathcal{D}$	<p>Ένα σύνολο δεδομένων <math>\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}</math> είναι μία λίστα μεμονωμένων σημείων δεδομένων <math>\mathbf{z}^{(r)}</math>, for <math>r = 1, \dots, m</math>.</p> <p>Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων.</p>
$d$	<p>Ο αριθμός των χαρακτηριστικών που χαρακτηρίζουν ένα σημείο δεδομένων.</p> <p>Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων.</p>
$x_j$	<p>Το <math>j</math>-οστό χαρακτηριστικό ενός σημείου δεδομένων. Το πρώτο χαρακτηριστικό δηλώνεται με <math>x_1</math>, το δεύτερο χαρακτηριστικό <math>x_2</math>, και ούτω καθεξής.</p> <p>Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό.</p>
$\mathbf{x}$	<p>Το διάνυσμα χαρακτηριστικών <math>\mathbf{x} = (x_1, \dots, x_d)^T</math> ενός σημείου δεδομένων. Του διανύσματος οι καταχωρίσεις είναι τα μεμονωμένα χαρακτηριστικά ενός σημείου δεδομένων.</p> <p>Βλέπε επίσης: διάνυσμα χαρακτηριστικών, σημείο δεδομένων, διάνυσμα, χαρακτηριστικό.</p>



$\mathcal{X}$  Ο χώρος χαρακτηριστικών  $\mathcal{X}$  είναι το σύνολο όλων των πιθανών τιμών που μπορούν να πάρουν τα χαρακτηριστικά  $\mathbf{x}$  ενός σημείου δεδομένων. Βλέπε επίσης: χώρος χαρακτηριστικών, χαρακτηριστικό, σημείο δεδομένων.

$\mathbf{z}$  Αντί του συμβόλου  $\mathbf{x}$ , χρησιμοποιούμε μερικές φορές  $\mathbf{z}$  ως ένα άλλο σύμβολο για να δηλώσουμε ένα διάνυσμα του οποίου οι καταχωρίσεις είναι τα μεμονωμένα χαρακτηριστικά ενός σημείου δεδομένων. Χρειαζόμαστε δύο διαφορετικά σύμβολα για να διακρίνουμε τα αχατέργαστα χαρακτηριστικά από αυτά που έχουν μαθητευτεί [8, Κεφ. 9]. Βλέπε επίσης: διάνυσμα, χαρακτηριστικό, σημείο δεδομένων.

$\mathbf{x}^{(r)}$  Το διάνυσμα χαρακτηριστικών του  $r$ -στού σημείου δεδομένων εντός ενός συνόλου δεδομένων. Βλέπε επίσης: διάνυσμα χαρακτηριστικών, σημείο δεδομένων, σύνολο δεδομένων.

$x_j^{(r)}$  Το  $j$ -οστό χαρακτηριστικό του  $r$ -στού σημείου δεδομένων εντός ενός συνόλου δεδομένων. Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων, σύνολο δεδομένων.

$\mathcal{B}$  Μία μικρο-δέσμη (ή υποσύνολο) τυχαία επιλεγμένων σημείων δεδομένων. Βλέπε επίσης: δέσμη, σημείο δεδομένων.

$B$  Το μέγεθος μίας μικρο-δέσμης (δηλαδή ο αριθμός των σημείων δεδομένων σε αυτή). Βλέπε επίσης: σημείο δεδομένων, δέσμη.

$y$	<p>Η ετικέτα (ή η ποσότητα ενδιαφέροντος) ενός σημείου δεδομένων.</p> <p>Βλέπε επίσης: ετικέτα, σημείο δεδομένων.</p>
$y^{(r)}$	<p>Η ετικέτα του <math>r</math>στού σημείου δεδομένων.</p> <p>Βλέπε επίσης: ετικέτα, σημείο δεδομένων.</p>
$(\mathbf{x}^{(r)}, y^{(r)})$	<p>Τα χαρακτηριστικά και η ετικέτα του <math>r</math>στού σημείου δεδομένων.</p> <p>Βλέπε επίσης: χαρακτηριστικό, ετικέτα, σημείο δεδομένων.</p>
$\mathcal{Y}$	<p>Ο χώρος ετικετών <math>\mathcal{Y}</math> μίας μεθόδου μηχανικής μάθησης αποτελείται από όλες τις πιθανές τιμές ετικετών που ένα σημείο δεδομένων μπορεί να φέρει. Ο ονομαστικός χώρος ετικετών μπορεί να είναι μεγαλύτερος από το σύνολο των διαφορετικών τιμών ετικετών που προκύπτουν σε ένα συγκεκριμένο σύνολο δεδομένων (π.χ. ένα σύνολο εκπαίδευσης). Προβλήματα (ή μέθοδοι) μηχανικής μάθησης που χρησιμοποιούν έναν αριθμητικό χώρο ετικετών, όπως <math>\mathcal{Y} = \mathbb{R}</math> ή <math>\mathcal{Y} = \mathbb{R}^3</math>, αναφέρονται ως προβλήματα (ή μέθοδοι) παλινδρόμησης. Προβλήματα (ή μέθοδοι) μηχανικής μάθησης που χρησιμοποιούν έναν διακριτό χώρο ετικετών, όπως <math>\mathcal{Y} = \{0, 1\}</math> ή <math>\mathcal{Y} = \{\text{γάτα}, \text{σκύλος}, \text{ποντίκι}\}</math>, αναφέρονται ως προβλήματα (ή μέθοδοι) ταξινόμησης.</p> <p>Βλέπε επίσης: χώρος ετικετών, μηχανική μάθηση, ετικέτα, σημείο δεδομένων, σύνολο δεδομένων, σύνολο εκπαίδευσης, regression, ταξινόμηση.</p>

$\eta$	<p>Ο ρυθμός μάθησης (ή το μέγεθος βήματος) που χρησιμοποιείται από τις μεθόδους με βάση την κλίση.</p> <p>Βλέπε επίσης: ρυθμός μάθησης, μέγεθος βήματος, μέθοδος με βάση την κλίση.</p>
$h(\cdot)$	<p>Μία απεικόνιση υπόθεσης που αντιστοιχίζει τα χαρακτηριστικά ενός σημείου δεδομένων σε μία πρόβλεψη <math>\hat{y} = h(\mathbf{x})</math> για την ετικέτα του <math>y</math>.</p> <p>Βλέπε επίσης: υπόθεση, απεικόνιση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα.</p>
$\mathcal{Y}^{\mathcal{X}}$	<p>Δεδομένων δύο συνόλων <math>\mathcal{X}</math> και <math>\mathcal{Y}</math>, δηλώνουμε με <math>\mathcal{Y}^{\mathcal{X}}</math> το σύνολο όλων των πιθανών απεικόνιση υπόθεσης <math>h : \mathcal{X} \rightarrow \mathcal{Y}</math>.</p> <p>Βλέπε επίσης: υπόθεση, απεικόνιση.</p>
$\mathcal{H}$	<p>Ένας χώρος υποθέσεων ή μοντέλο που χρησιμοποιείται από μία μέθοδο μηχανικής μάθησης. Ο χώρος υποθέσεων αποτελείται από διαφορετικές απεικόνιση υπόθεσης <math>h : \mathcal{X} \rightarrow \mathcal{Y}</math> μεταξύ των οποίων η μέθοδος μηχανικής μάθησης πρέπει να επιλέξει.</p> <p>Βλέπε επίσης: χώρος υποθέσεων, μοντέλο, μηχανική μάθηση, υπόθεση, απεικόνιση.</p>
$d_{\text{eff}}(\mathcal{H})$	<p>Η αποτελεσματική διάσταση ενός χώρου υποθέσεων <math>\mathcal{H}</math>.</p> <p>Βλέπε επίσης: αποτελεσματική διάσταση, χώρος υποθέσεων.</p>

$B^2$	<p>Η τετραγωνική μεροληψία μίας υπόθεσης <math>\hat{h}</math> που έχει μαθευτεί, ή των παραμέτρων της. Σημείωση ότι η <math>\hat{h}</math> γίνεται μία τυχαία μεταβλητή αν μαθαίνεται από σημεία δεδομένων που είναι και τα ίδια τυχαίες μεταβλητές.</p> <p>Βλέπε επίσης: μεροληψία, υπόθεση, παράμετρος, τυχαία μεταβλητή, σημείο δεδομένων.</p>
$V$	<p>Η διακύμανση μίας υπόθεσης <math>\hat{h}</math> που έχει μαθευτεί, ή των παραμέτρων της. Σημείωση ότι η <math>\hat{h}</math> γίνεται μία τυχαία μεταβλητή αν μαθαίνεται από σημεία δεδομένων που είναι και τα ίδια τυχαίες μεταβλητές.</p> <p>Βλέπε επίσης: διακύμανση, υπόθεση, παράμετρος, τυχαία μεταβλητή, σημείο δεδομένων.</p>
$L((\mathbf{x}, y), h)$	<p>Η απώλεια που προκαλείται από την πρόβλεψη της ετικέτας <math>y</math> ενός σημείου δεδομένων χρησιμοποιώντας την πρόβλεψη <math>\hat{y} = h(\mathbf{x})</math>. Η πρόβλεψη <math>\hat{y}</math> προκύπτει από την αξιολόγηση της υπόθεσης <math>h \in \mathcal{H}</math> για το διάνυσμα χαρακτηριστικών <math>\mathbf{x}</math> του σημείου δεδομένων.</p> <p>Βλέπε επίσης: απώλεια, ετικέτα, σημείο δεδομένων, πρόβλεψη, υπόθεση, διάνυσμα χαρακτηριστικών.</p>
$E_v$	<p>Το σφάλμα επικύρωσης μίας υπόθεσης <math>h</math>, το οποίο είναι η μέση της απώλεια που προκαλείται σε ένα σύνολο επικύρωσης.</p> <p>Βλέπε επίσης: σφάλμα επικύρωσης, υπόθεση, απώλεια, σύνολο επικύρωσης.</p>

$\hat{L}(h \mathcal{D})$	<p>Η εμπειρική διακινδύνευση, ή η μέση απώλεια, που προκαλείται από την υπόθεση <math>h</math> σε ένα σύνολο δεδομένων <math>\mathcal{D}</math>.</p> <p>Βλέπε επίσης: εμπειρική διακινδύνευση, απώλεια, υπόθεση, σύνολο δεδομένων.</p>
$E_t$	<p>Το σφάλμα εκπαίδευσης μίας υπόθεσης <math>h</math>, που είναι η μέση της απώλεια που προκαλείται σε ένα σύνολο εκπαίδευσης.</p> <p>Βλέπε επίσης: training error, υπόθεση, απώλεια, σύνολο εκπαίδευσης.</p>
$t$	<p>Ένας δείκτης διακριτού χρόνου <math>t = 0, 1, \dots</math> που χρησιμοποιείται για την απαρίθμηση ακολουθιακών γεγονότων (ή χρονικών στιγμών).</p> <p>Βλέπε επίσης: γεγονός.</p>
$t$	<p>Ένας δείκτης που απαριθμεί εργασίες μάθησης εντός ενός προβλήματος μάθησης πολυδιεργασίας.</p> <p>Βλέπε επίσης: εργασία μάθησης, μάθηση πολυδιεργασίας.</p>
$\alpha$	<p>Μία παράμετρος ομαλοποίησης που ελέγχει το ποσό της ομαλοποίησης.</p> <p>Βλέπε επίσης: παράμετρος, ομαλοποίηση.</p>
$\lambda_j(\mathbf{Q})$	<p>Η <math>j</math>-οστή ιδιοτιμή (ταξινομημένη σε αύξουσα ή φθίνουσα σειρά) ενός θετικά ημιορισμένου πίνακα <math>\mathbf{Q}</math>. Χρησιμοποιούμε επίσης τη συντομογραφία <math>\lambda_j</math> αν ο αντίστοιχος πίνακας είναι προφανής από τα συμφραζόμενα.</p> <p>Βλέπε επίσης: ιδιοτιμή, θετικά ημιορισμένος, πίνακας.</p>

$\sigma(\cdot)$	<p>Η συνάρτηση ενεργοποίησης που χρησιμοποιείται από έναν τεχνητό νευρώνα εντός ενός ΤΝΔ.</p> <p>Βλέπε επίσης: συνάρτηση ενεργοποίησης, τεχνητό νευρωνικό δίκτυο.</p>
$\mathcal{R}_{\vec{y}}$	<p>Μία περιοχή αποφάσεων εντός ενός χώρου χαρακτηριστικών.</p> <p>Βλέπε επίσης: περιοχή αποφάσεων, χώρος χαρακτηριστικών.</p>
$\mathbf{w}$	<p>Ένα παραμετρικό διάνυσμα <math>\mathbf{w} = (w_1, \dots, w_d)^T</math> ενός μοντέλου, π.χ. τα βάρη ενός γραμμικού μοντέλου ή ενός ΤΝΔ.</p> <p>Βλέπε επίσης: παράμετρος, διάνυσμα, μοντέλο, βάρος, γραμμικό μοντέλο, ΤΝΔ.</p>
$h^{(\mathbf{w})}(\cdot)$	<p>Μία απεικόνιση υπόθεσης που περιλαμβάνει παράμετρους μοντέλου <math>w_1, \dots, w_d</math> που μπορούν να ρυθμιστούν στοιβαγμένες στο διάνυσμα <math>\mathbf{w} = (w_1, \dots, w_d)^T</math>.</p> <p>Βλέπε επίσης: υπόθεση, απεικόνιση, παράμετρος μοντέλου, διάνυσμα.</p>
$\phi(\cdot)$	<p>Ένας απεικόνιση χαρακτηριστικών <math>\phi : \mathcal{X} \rightarrow \mathcal{X}' : \mathbf{x} \mapsto \phi(\mathbf{x})</math> που μετασχηματίζει το διάνυσμα χαρακτηριστικών <math>\mathbf{x}</math> ενός σημείου δεδομένων σε ένα νέο διάνυσμα χαρακτηριστικών <math>\mathbf{x}' = \phi(\mathbf{x}) \in \mathcal{X}'</math>.</p> <p>Βλέπε επίσης: απεικόνιση χαρακτηριστικών, διάνυσμα χαρακτηριστικών, σημείο δεδομένων.</p>

$k(\cdot, \cdot)$	<p>Δεδομένου κάποιου χώρου χαρακτηριστικών <math>\mathcal{X}</math>, ένας πυρήνας είναι μία απεικόνιση <math>k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{C}</math> που είναι θετικά ημιορισμένη.</p> <p>Βλέπε επίσης: χώρος χαρακτηριστικών, πυρήνας, απεικόνιση, θετικά ημιορισμένος.</p>
$\text{VCdim}(\mathcal{H})$	<p>Η διάσταση Vapnik–Chervonenkis του χώρου υποθέσεων <math>\mathcal{H}</math>.</p> <p>Βλέπε επίσης: διάσταση Vapnik–Chervonenkis, χώρος υποθέσεων.</p>

## Ομοσπονδιακή Μάθηση

$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	<p>Ένας μη κατευθυνόμενος γράφος του οποίου οι κόμβοι <math>i \in \mathcal{V}</math> αντιπροσωπεύουν συσκευές εντός ενός δικτύου ομοσπονδιακής μάθησης. Οι μη κατευθυνόμενες σταθμισμένες ακμές <math>\mathcal{E}</math> αντιπροσωπεύουν τη συνεκτικότητα μεταξύ συσκευών και τις στατιστικές ομοιότητες μεταξύ των συνόλων δεδομένων τους και των εργασιών μάθησης.</p> <p>Βλέπε επίσης: μη κατευθυνόμενος γράφος, συσκευή, δίκτυο ομοσπονδιακής μάθησης, σύνολο δεδομένων, εργασία μάθησης.</p>
$i \in \mathcal{V}$	<p>Ένας κόμβος που αντιπροσωπεύει κάποια συσκευή εντός ενός δικτύου ομοσπονδιακής μάθησης. Η συσκευή μπορεί να έχει πρόσβαση σε ένα τοπικό σύνολο δεδομένων και να εκπαιδεύσει ένα τοπικό μοντέλο.</p> <p>Βλέπε επίσης: συσκευή, δίκτυο ομοσπονδιακής μάθησης, τοπικό σύνολο δεδομένων, local model.</p>
$\mathcal{G}^{(c)}$	<p>Ο επαγόμενος υπογράφος του <math>\mathcal{G}</math> χρησιμοποιώντας τους κόμβους στο <math>\mathcal{C} \subseteq \mathcal{V}</math>.</p>
$\mathbf{L}^{(\mathcal{G})}$	<p>Ο πίνακας Laplace ενός γράφου <math>\mathcal{G}</math>.</p> <p>Βλέπε επίσης: πίνακας Laplace, γράφος.</p>
$\mathbf{L}^{(c)}$	<p>Ο πίνακας Laplace του επαγόμενου γράφου <math>\mathcal{G}^{(c)}</math>.</p> <p>Βλέπε επίσης: πίνακας Laplace, graph.</p>



$\mathcal{N}^{(i)}$	<p>Η γειτονιά του κόμβου <math>i</math> σε έναν γράφο <math>\mathcal{G}</math>.</p> <p>Βλέπε επίσης: γειτονιά, graph.</p>
$d^{(i)}$	<p>Ο σταθμισμένος βαθμός κόμβου <math>d^{(i)} := \sum_{i' \in \mathcal{N}^{(i)}} A_{i,i'}</math> του κόμβου <math>i</math>.</p> <p>Βλέπε επίσης: βαθμός κόμβου.</p>
$d_{\max}^{(\mathcal{G})}$	<p>Ο μέγιστος σταθμισμένος βαθμός κόμβου ενός γράφου <math>\mathcal{G}</math>.</p> <p>Βλέπε επίσης: μέγιστο, βαθμός κόμβου, graph.</p>
$\mathcal{D}^{(i)}$	<p>Το τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math> που φέρει ο κόμβος <math>i \in \mathcal{V}</math> ενός δικτύου ομοσπονδιακής μάθησης.</p> <p>Βλέπε επίσης: τοπικό σύνολο δεδομένων, δίκτυο ομοσπονδιακής μάθησης.</p>
$m_i$	<p>Ο αριθμός των σημείων δεδομένων (δηλαδή το μέγεθος δείγματος) που περιέχονται στο τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math> στον κόμβο <math>i \in \mathcal{V}</math>.</p> <p>Βλέπε επίσης: σημείο δεδομένων, μέγεθος δείγματος, τοπικό σύνολο δεδομένων.</p>
$\mathbf{x}^{(i,r)}$	<p>Τα χαρακτηριστικά του <math>r</math>στού σημείου δεδομένων στο τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math>.</p> <p>Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων, τοπικό σύνολο δεδομένων.</p>
$y^{(i,r)}$	<p>Η ετικέτα του <math>r</math>στού σημείου δεδομένων στο τοπικό σύνολο δεδομένων <math>\mathcal{D}^{(i)}</math>.</p> <p>Βλέπε επίσης: ετικέτα, σημείο δεδομένων, τοπικό σύνολο δεδομένων.</p>

$\mathbf{w}^{(i)}$	<p>Οι τοπικοί παράμετροι μοντέλου της συσκευής <math>i</math> εντός ενός δικτύου ομοσπονδιακής μάθησης.</p> <p>Βλέπε επίσης: model parameter, συσκευή, δίκτυο ομοσπονδιακής μάθησης.</p>
$L_i(\mathbf{w})$	<p>Η τοπική συνάρτηση απώλειας που χρησιμοποιείται από τη συσκευή <math>i</math> για να μετρήσει τη χρησιμότητα κάποιας επιλογής <math>\mathbf{w}</math> για τις τοπικές παράμετρους μοντέλου.</p> <p>Βλέπε επίσης: συνάρτηση απώλειας, συσκευή, model parameter.</p>
$L^{(d)}(\mathbf{x}, h(\mathbf{x}), h'(\mathbf{x}))$	<p>Η απώλεια που προκαλείται από μία υπόθεση <math>h'</math> σε ένα σημείο δεδομένων με χαρακτηριστικά <math>\mathbf{x}</math> και ετικέτα <math>h(\mathbf{x})</math> που προκύπτει από μία άλλη υπόθεση.</p> <p>Βλέπε επίσης: απώλεια, υπόθεση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα.</p>
$\text{stack}\{\mathbf{w}^{(i)}\}_{i=1}^n$	<p>Το διάνυσμα <math>\left( (\mathbf{w}^{(1)})^T, \dots, (\mathbf{w}^{(n)})^T \right)^T \in \mathbb{R}^{dn}</math> που προκύπτει από την κάθετη στοίβαξη των τοπικών παραμέτρων μοντέλου <math>\mathbf{w}^{(i)} \in \mathbb{R}^d</math>, για <math>i = 1, \dots, n</math>.</p> <p>Βλέπε επίσης: διάνυσμα, στοίβαξη, model parameter.</p>
$h^{(i)}$	<p>Μία υπόθεση <math>h^{(i)} \in \mathcal{H}^{(i)}</math> σε κάποιον κόμβο <math>i</math> εντός ενός δικτύου ομοσπονδιακής μάθησης.</p> <p>Βλέπε επίσης: υπόθεση, δίκτυο ομοσπονδιακής μάθησης.</p>

$\hat{h}^{(i)}$

Μία υπόθεση  $\hat{h}^{(i)} \in \mathcal{H}^{(i)}$  που έχει μαθευτεί, η οποία έχει προκύψει από κάποια μέθοδο ομοσπονδιακής μάθησης, σε κάποιον κόμβο  $i$  εντός ενός δικτύου ομοσπονδιακής μάθησης.

Βλέπε επίσης: υπόθεση, federated learning (FL), δίκτυο ομοσπονδιακής μάθησης.

## Μαθηματικά Εργαλεία

**ακολουθία** Μία ακολουθία είναι μία διατεταγμένη συλλογή τιμών από ένα σύνολο  $\mathcal{A}$ . Για παράδειγμα, μία ακολουθία τιμών από το σύνολο  $\mathcal{A} = \{\star, \otimes\}$  θα μπορούσε να είναι

$$a = (\star, \otimes, \star, \star, \otimes, \dots).$$

Τυπικά, μία ακολουθία  $a$  είναι μία συνάρτηση [2]

$$a : \mathbb{N} \rightarrow \mathcal{A} : r \mapsto a_r.$$

Δηλώνουμε μία ακολουθία με  $(a_r)_{r \in \mathbb{N}}$  ή  $(a^{(r)})_{r \in \mathbb{N}}$ . Μερικές φορές χρησιμοποιούμε και τον συμβολισμό  $\{a^{(r)}\}_{r \in \mathbb{N}}$ . Σημείωση ότι η ίδια τιμή  $a \in \mathcal{A}$  μπορεί να εμφανιστεί πολλές φορές στην ακολουθία σε διαφορετικές θέσεις  $r$ . Οι ακολουθίες είναι θεμελιώδεις για τη μελέτη μεθόδων μηχανικής μάθησης, για παράδειγμα όταν περιγράφουμε διαδοχικές επαναλήψεις  $\{\mathbf{w}^{(t)}\}_{t \in \mathbb{N}}$  ενός επαναληπτικού αλγόριθμου. Μπορούμε επίσης να χρησιμοποιήσουμε μία ακολουθία για να αναπαραστήσουμε ένα άπειρο σύνολο δεδομένων


$$\mathcal{D} = \{ (\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots \}.$$

Βλέπε επίσης: συνάρτηση, μηχανική μάθηση, αλγόριθμος, σύνολο δεδομένων.

**ακολουθία Cauchy** Μία ακολουθία Cauchy είναι μία ακολουθία  $(\mathbf{x}^{(r)})_{r \in \mathbb{N}}$  σε έναν μετρικό χώρο  $(\mathcal{X}, d(\cdot, \cdot))$  έτσι ώστε τα στοιχεία  $\mathbf{x}^{(r)} \in \mathcal{X}$  γίνονται τελικά αυθαίρετα κοντινά το ένα στο άλλο. Με άλλα λόγια, [2, Def. 3.8],

$$\forall \epsilon > 0, \exists N \in \mathbb{N} \text{ έτσι ώστε } \forall r, r' \geq N, d(\mathbf{x}^{(r)}, \mathbf{x}^{(r')}) < \epsilon.$$

Το Σχ. 1 δείχνει μία ακολουθία Cauchy στον μετρικό χώρο  $(\mathbb{Q}, |\cdot|)$  ρητών αριθμών.




Σχ. 1. Μία ακολουθία Cauchy  $(x^{(r)})_{r \in \mathbb{N}}$  στον μετρικό χώρο  $(\mathbb{Q}, |\cdot|)$ . Αυτή η ακολουθία παράγεται από μία επανάληψη σταθερού σημείου που χρησιμοποιείται για την προσέγγιση του  $\sqrt{2}$ . Για όλα τα  $r \geq N$ , τα στοιχεία της ακολουθίας βρίσκονται εντός μίας ζώνης πλάτους  $\epsilon$ . Σημείωση ότι η ακολουθία δεν συγκλίνει στον  $\mathbb{Q}$ , εφόσον  $\sqrt{2} \notin \mathbb{Q}$  [2, Παράδειγμα 1.1].

Βλέπε επίσης: ακολουθία, μετρικός χώρος, επανάληψη σταθερού σημείου.

**αλγεβρική συνεκτικότητα** Η αλγεβρική συνεκτικότητα (algebraic connectivity) ενός μη κατευθυνόμενου γράφου είναι η δεύτερη μικρότερη ιδιοτιμή  $\lambda_2$  του πίνακα Laplace του. Ένας μη κατευθυνόμενος γράφος

είναι συνεκτικός αν και μόνο αν  $\lambda_2 > 0$  (βλέπε Σχ. 2) [9], [10].




Σχ. 2. Τρία παραδείγματα μη κατευθυνόμενων γράφων.

Βλέπε επίσης: μη κατευθυνόμενος γράφος, ιδιοτιμή, πίνακας Laplace, συνεκτικός, graph.

**ανάλυση ιδιαζουσών τιμών** Η ανάλυση ιδιαζουσών τιμών (singular value decomposition - SVD) για έναν πίνακα  $\mathbf{A} \in \mathbb{R}^{m \times d}$  είναι μία παραγοντοποίηση της ακόλουθης μορφής:

$$\mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{U}^T$$

με ορθοκανονικούς πίνακες  $\mathbf{V} = (\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(m)}) \in \mathbb{R}^{m \times m}$  και  $\mathbf{U} = (\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}) \in \mathbb{R}^{d \times d}$  [3] (βλέπε Σχ. 3).



Σχ. 3. Ορθοκανονικοί πίνακες  $\mathbf{V}$  και  $\mathbf{U}$ .

Ο πίνακας  $\mathbf{A} \in \mathbb{R}^{m \times d}$  είναι μη μηδενικός μόνο κατά την κύρια διαγώνιο, της οποίας οι καταχωρίσεις  $\Lambda_{j,j}$  είναι μη αρνητικές και αναφέρονται ως ιδιάζουσες τιμές.

Βλέπε επίσης: πίνακας, ιδιάζουσα τιμή.

**ανάλυση ιδιοτιμών** Η ανάλυση ιδιοτιμών (eigenvalue decomposition - EVD) για έναν τετραγωνικό πίνακα  $\mathbf{A} \in \mathbb{R}^{d \times d}$  είναι μία παραγοντοποίηση της μορφής

$$\mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^{-1}.$$

Οι στήλες του πίνακα  $\mathbf{V} = (\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(d)})$  είναι τα ιδιοδιανύσματα του πίνακα  $\mathbf{V}$ . Ο διαγώνιος πίνακας  $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \dots, \lambda_d\}$  περιέχει τις ιδιοτιμές  $\lambda_j$  που αντιστοιχούν στα ιδιοδιανύσματα  $\mathbf{v}^{(j)}$ . Σημείωση ότι η παραπάνω ανάλυση υφίσταται μόνο αν ο πίνακας  $\mathbf{A}$  είναι διαγωνοποιήσιμος.

Βλέπε επίσης: πίνακας, ιδιοδιάνυσμα, ιδιοτιμή.

**ανάστροφος** Η ανάστροφος (transpose) ενός πίνακα πραγματικής τιμής προκύπτει με την ανταλλαγή γραμμών και στηλών. Για έναν πίνακα  $\mathbf{A} \in \mathbb{R}^{m \times d}$ , η ανάστροφός του δηλώνεται με  $\mathbf{A}^T$  και ικανοποιεί  $(\mathbf{A}^T)_{j,j'} = \mathbf{A}_{j',j}$ .

Βλέπε επίσης: πίνακας, συμμετρικός πίνακας.

**ανεξάρτητες και ταυτόσημα κατανομημένες** Μία συλλογή τυχαίων μεταβλητών  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$  αναφέρεται ως ανεξάρτητη και ταυτόσημα κατανομημένη (independent and identically distributed - i.i.d.) αν κάθε  $\mathbf{z}^{(r)}$  ακολουθεί την ίδια κατανομή πιθανότητας, και οι τυχαίες μεταβλητές είναι αμοιβαία ανεξάρτητες. Για την ακρίβεια, για οποιαδήποτε συλλογή

γεγονότων  $\mathcal{A}_1, \dots, \mathcal{A}_m$ , έχουμε

$$\mathbb{P}(\mathbf{z}^{(1)} \in \mathcal{A}_1, \dots, \mathbf{z}^{(m)} \in \mathcal{A}_m) = \prod_{r=1}^m \mathbb{P}(\mathbf{z}^{(r)} \in \mathcal{A}_r).$$

Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, γεγονός, σημείο δεδομένων, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων.

**ανισότητα του Markov** TBC.

**ανισότητα συγκέντρωσης** Η ανισότητα συγκέντρωσης (concentration inequality) αναφέρεται σε ένα άνω φράγμα της πιθανότητας ότι μία τυχαία μεταβλητή αποκλίνει περισσότερο από ένα καθορισμένο ποσό από την προσδοκία της [11].

Βλέπε επίσης: πιθανότητα, τυχαία μεταβλητή, expectation, ανισότητα του Markov, ανισότητα του Chebyshev, ανισότητα του Hoeffding, φράγμα Chernoff.

**ανισότητα του Chebyshev** TBC.


**ανισότητα του Hoeffding** TBC.

**αντίστροφος πίνακας** Ένας αντίστροφος πίνακας (inverse matrix)  $\mathbf{A}^{-1}$  ορίζεται για έναν τετραγωνικό πίνακα  $\mathbf{A} \in \mathbb{R}^{n \times n}$  που είναι πλήρους τάξης, που σημαίνει ότι οι στήλες του είναι γραμμικά ανεξάρτητες. Σε αυτή την περίπτωση, ο  $\mathbf{A}$  λέγεται ότι είναι αντιστρέψιμος, και ο αντίστροφός του ικανοποιεί

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}.$$



Ένας τετραγωνικός πίνακας είναι αντιστρέψιμος αν και μόνο αν η ορίζουσά του είναι μη μηδενική. Οι αντίστροφοι πίνακες είναι θεμελιώδεις στη λύση συστημάτων γραμμικών εξισώσεων και στην κλειστής μορφής λύση γραμμικής παλινδρόμησης [12], [13]. Η έννοια ενός αντίστροφου πίνακα μπορεί να επεκταθεί σε πίνακες που δεν είναι τετραγωνικοί ή πλήρους τάξης. Μπορεί κανείς να ορίσει έναν «αριστερό αντίστροφο»  $\mathbf{B}$  που ικανοποιεί  $\mathbf{BA} = \mathbf{I}$  ή έναν «δεξιό αντίστροφο»  $\mathbf{C}$  που ικανοποιεί  $\mathbf{AC} = \mathbf{I}$ . Για γενικούς ορθογώνιους ή ιδιάζοντες πίνακες, ο ψευδοαντίστροφος Moore–Penrose  $\mathbf{A}^+$  παρέχει μία ενοποιημένη έννοια ενός γενικευμένου αντίστροφου πίνακα [3].



Σχ. 4. Ένας πίνακας  $\mathbf{A}$  αναπαριστά έναν γραμμικό μετασχηματισμό του  $\mathbb{R}^2$ . Ο αντίστροφος πίνακας  $\mathbf{A}^{-1}$  αναπαριστά τον αντίστροφο μετασχηματισμό.

Βλέπε επίσης: πίνακας, πλήρους τάξης, γραμμικά ανεξάρτητο, ορίζουσα, γραμμική παλινδρόμηση, ψευδοαντίστροφος.

**απεικόνιση** Χρησιμοποιούμε τον όρο απεικόνιση (map) ως συνώνυμο της συνάρτησης.

Βλέπε επίσης: συνάρτηση.

**απόκλιση Kullback–Leibler (απόκλιση KL)** Η απόκλιση KL (Kullback-

Leibler divergence - KL divergence) είναι ένα ποσοτικό μέτρο του πόσο διαφορετική είναι μία κατανομή πιθανότητας από μία άλλη [14].  
Βλέπε επίσης: κατανομή πιθανότητας.

**απόκλιση Rényi** Η απόκλιση Rényi μετράει την (αν)ομοιότητα μεταξύ δύο κατανομών πιθανοτήτων [15].  
Βλέπε επίσης: κατανομή πιθανότητας.

**αριθμήσιμο** TBC.

**αριθμός συνθήκης** Ο αριθμός συνθήκης (condition number)  $\kappa(\mathbf{Q}) \geq 1$  ενός θετικά ορισμένου πίνακα  $\mathbf{Q} \in \mathbb{R}^{d \times d}$  είναι ο λόγος  $\alpha/\beta$ , όπου  $\alpha$  και  $\beta$  δηλώνουν τη μεγαλύτερη και μικρότερη ιδιοτιμή του  $\mathbf{Q}$ , αντίστοιχα. Ο αριθμός συνθήκης είναι χρήσιμος για την ανάλυση μεθόδων μηχανικής μάθησης. Η υπολογιστική πολυπλοκότητα των μεθόδων με βάση την κλίση για γραμμική παλινδρόμηση εξαρτάται κρίσιμα από τον αριθμό συνθήκης του πίνακα  $\mathbf{Q} = \mathbf{X}\mathbf{X}^T$ , όπου  $\mathbf{X}$  είναι ο πίνακας χαρακτηριστικών του συνόλου εκπαίδευσης. Αυτές οι μέθοδοι συγκλίνουν ταχύτερα όταν ο αριθμός συνθήκης  $\kappa(\mathbf{Q})$  είναι κοντά στο 1.  
Βλέπε επίσης: πίνακας, ιδιοτιμή, μηχανική μάθηση, μέθοδος με βάση την κλίση, γραμμική παλινδρόμηση, πίνακας χαρακτηριστικών, σύνολο εκπαίδευσης.

**βαθμός κόμβου** Ο βαθμός  $d^{(i)}$  ενός κόμβου  $i \in \mathcal{V}$  (node degree) σε έναν μη κατευθυνόμενο γράφο είναι ο αριθμός των γειτόνων του, δηλαδή  $d^{(i)} := |\mathcal{N}^{(i)}|$ . Για έναν σταθμισμένο μη κατευθυνόμενο γράφο  $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$ , μπορούμε εναλλακτικά να ορίσουμε τον (σταθμισμένο) βαθμό κόμβου ως

το άθροισμα των βαρών όλων των ακμών που συνδέονται με τον κόμβο  $i$ , δηλαδή  $d^{(i)} = \sum_{i' \in V} A_{i,i'}$  [16].

Βλέπε επίσης: μη κατευθυνόμενος γράφος, γείτονας, συνεκτικός, μέσος βαθμός κόμβου.

**βελτιστοποίηση** Βλέπε κυρτή βελτιστοποίηση, μέθοδος βελτιστοποίησης, πρόβλημα βελτιστοποίησης.

**βήμα κλίσης** TBC.

**γεγονός** Θεωρούμε μία τυχαία μεταβλητή  $\mathbf{x}$ , ορισμένη σε κάποιον χώρο πιθανοτήτων  $\mathcal{P}$ , η οποία παίρνει τιμές σε έναν μετρήσιμο χώρο  $\mathcal{X}$ . Ένα γεγονός (event)  $\mathcal{A} \subseteq \mathcal{X}$  είναι ένα υποσύνολο του  $\mathcal{X}$  έτσι ώστε η πιθανότητα  $\mathbb{P}(\mathbf{x} \in \mathcal{A})$  είναι καλά ορισμένη. Με άλλα λόγια, η προεικόνα  $\mathbf{x}^{-1}(\mathcal{A})$  ενός γεγονότος ανήκει στην υποκείμενη  $\sigma$ -άλγεβρα, δηλαδή η προεικόνα είναι ένα μετρήσιμο υποσύνολο του δειγματικού χώρου [1], [6], [17]. Στο περίπου, ένα γεγονός αντιπροσωπεύει ένα σύνολο πιθανών εκβάσεων κάποιας διαδικασίας. Ένα παράδειγμα μίας τέτοιας διαδικασίας θα μπορούσε επίσης να είναι η θεραπευτική αγωγή ενός ασθενή υγειονομικής περίθαλψης.

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μετρήσιμο, πιθανότητα, προεικόνα, σημείο δεδομένων, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, πιθανοτικό μοντέλο.

**γειτονιά** Θεωρούμε κάποιον μετρικό χώρο  $\mathcal{X}$  με μία μετρική  $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ . Η γειτονιά (neighborhood) ενός σημείου  $\mathbf{x} \in \mathcal{X}$  είναι το σύνολο άλλων σημείων που έχουν μία επαρκώς μικρή απόσταση από το  $\mathbf{x}$ . Για

παράδειγμα, η  $\epsilon$ -γειτονιά του  $\mathbf{x}$  ορίζεται ως

$$\{\mathbf{x}' \in \mathcal{X} : d(\mathbf{x}, \mathbf{x}') \leq \epsilon\}.$$

Αν ο  $\mathcal{X}$  είναι ένας μη κατευθυνόμενος γράφος, ο οποίος αποτελεί μία ειδική περίπτωση μετρικού χώρου, η γειτονιά ενός κόμβου  $i \in \mathcal{V}$  είναι το σύνολο των γειτόνων του.

Βλέπε επίσης: μετρικός χώρος, μετρική, μη κατευθυνόμενος γράφος, γείτονας.

γεωμετρική διάμεσος TBC.

Γκαουσιανή διαδικασία TBC.

Γκαουσιανή τυχαία μεταβλητή TBC.

Γκαουσιανός Βλέπε Γκαουσιανή τυχαία μεταβλητή.

γραμμικά ανεξάρτητο TBC.

γραμμική απεικόνιση TBC.


**γράφος** Ένας γράφος  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  είναι ένα ζεύγος που αποτελείται από ένα σύνολο κόμβων  $\mathcal{V}$  και ένα σύνολο ακμών  $\mathcal{E}$ . Στην πιο γενική του μορφή, ένας γράφος προσδιορίζεται από μία απεικόνιση που αποδίδει σε κάθε ακμή  $e \in \mathcal{E}$  ένα ζεύγος κόμβων [18]. Μία σημαντική οικογένεια γράφων είναι οι απλοί μη κατευθυνόμενοι γράφοι. Ένας απλός μη κατευθυνόμενος γράφος προκύπτει από την ταυτοποίηση κάθε ακμής  $e \in \mathcal{E}$  με δύο διαφορετικούς κόμβους  $\{i, i'\}$ . Οι σταθμισμένοι γράφοι προσδιορίζουν

επίσης αριθμητικά βάρη  $A_e$  για κάθε ακμή  $e \in \mathcal{E}$ .

Βλέπε επίσης: απεικόνιση, βάρος.

**γράφος Erdős–Rényi** TBC.

**δείγμα** Στο πλαίσιο της μηχανικής μάθησης, ένα δείγμα (sample) είναι μία πεπερασμένη ακολουθία (μήκους  $m$ ) σημείων δεδομένων  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ . Ο αριθμός  $m$  ονομάζεται μέγεθος δείγματος. Οι μέθοδοι που βασίζονται στην εμπειρική ελαχιστοποίηση διακινδύνευσης χρησιμοποιούν ένα δείγμα για να εκπαιδεύσουν ένα μοντέλο (ή να μάθουν μία υπόθεση) ελαχιστοποιώντας τη μέση απώλεια (δηλαδή την εμπειρική διακινδύνευση) πάνω σε αυτό το δείγμα. Εφόσον ένα δείγμα ορίζεται ως μία ακολουθία, το ίδιο σημείο δεδομένων μπορεί να εμφανιστεί περισσότερες από μία φορές. Αντίθετα, ορισμένοι συγγραφείς στη στατιστική ορίζουν ένα δείγμα ως ένα σύνολο σημείων δεδομένων, οπότε δεν επιτρέπονται διπλότυπα [19], [20]. Αυτές οι δύο θέσεις (δηλαδή ακολουθία έναντι συνόλου) μπορεί να συμφιλιωθούν θεωρώντας ένα δείγμα ως μία ακολουθία ζευγών χαρακτηριστικών–ετικέτας  $(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})$ . Το  $r$ -οστό ζεύγος αποτελείται από τα χαρακτηριστικά  $\mathbf{x}^{(r)}$  και την ετικέτα  $y^{(r)}$  ενός μοναδικού υποκείμενου σημείου δεδομένων  $\tilde{\mathbf{z}}^{(r)}$ . Ενώ τα υποκείμενα σημεία δεδομένων  $\tilde{\mathbf{z}}^{(1)}, \dots, \tilde{\mathbf{z}}^{(m)}$  είναι μοναδικά, κάποια από αυτά μπορεί να έχουν ταυτόσημα χαρακτηριστικά και ετικέτες.



Σχ. 5. Ένα δείγμα θεωρείται μία πεπερασμένη ακολουθία. Κάθε στοιχείο αυτού του δείγματος αποτελείται από το διάνυσμα χαρακτηριστικών και την ετικέτα ενός σημείου δεδομένων από έναν υποκείμενο πληθυσμό. Το ίδιο σημείο δεδομένων μπορεί να εμφανιστεί περισσότερες από μία φορές στο δείγμα.

Για την ανάλυση μεθόδων μηχανικής μάθησης, είναι σύνηθες να ερμηνεύεται η παραγωγή ενός δείγματος ως η πραγμάτωση μίας στοχαστικής διαδικασίας με δείκτες  $\{1, \dots, m\}$ . Μία ευρέως χρησιμοποιούμενη παραδοχή είναι η παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, όπου τα στοιχεία δείγματος  $(\mathbf{x}^{(r)}, y^{(r)})$ , για  $r = 1, \dots, m$ , είναι ανεξάρτητες και ταυτόσημα κατανομημένες τυχαίες μεταβλητές με κοινή κατανομή πιθανότητας.

Βλέπε επίσης: μηχανική μάθηση, ακολουθία, σημείο δεδομένων, μέγεθος δείγματος, εμπειρική ελαχιστοποίηση διακινδύνευσης, μοντέλο, υπόθεση, απώλεια, εμπειρική διακινδύνευση, χαρακτηριστικό, ετικέτα, διάνυσμα χαρακτηριστικών, πραγμάτωση, στοχαστική διαδικασία, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, σύνολο δεδομένων.

**διαγωνοποιήσιμος** TBC.

**διακριτή τυχαία μεταβλητή** An τυχαία μεταβλητή, i.e., a συνάρτηση that maps the έκβασης of a τυχαίο πείραμα to elements of a μετρήσιμο space  $\mathcal{X}$ , is referred to as discrete if its value space  $\mathcal{X}$  is αριθμήσιμο [6].

See also: τυχαία μεταβλητή, πιθανότητα, κατανομή πιθανότητας.


**διακύμανση** Η διακύμανση μίας τυχαίας μεταβλητής πραγματικής τιμής  $x$  ορίζεται ως η προσδοκία  $\mathbb{E}\{(x - \mathbb{E}\{x\})^2\}$  της τετραγωνικής διαφοράς μεταξύ της  $x$  και της προσδοκίας της  $\mathbb{E}\{x\}$ . Επεκτείνουμε αυτόν τον ορισμό σε τυχαίες μεταβλητές διανυσματικής τιμής  $\mathbf{x}$  ως  $\mathbb{E}\{\|\mathbf{x} - \mathbb{E}\{\mathbf{x}\}\|_2^2\}$ . Βλέπε επίσης: τυχαία μεταβλητή, expectation, διάνυσμα.

**διάμεσος** TBC.

**διάνυσμα** Ένα διάνυσμα είναι ένα στοιχείο ενός διανυσματικού χώρου. Στο πλαίσιο της μηχανικής μάθησης, ένα ιδιαίτερα σημαντικό παράδειγμα διανυσματικού χώρου είναι ο Ευκλείδειος χώρος  $\mathbb{R}^d$ , όπου  $d \in \mathbb{N}$  είναι η (πεπερασμένη) διάσταση του χώρου. Ένα διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$  μπορεί να αναπαρασταθεί ως μία λίστα ή μονοδιάστατη (1-D) διάταξη πραγματικών αριθμών, δηλαδή  $x_1, \dots, x_d$  με  $x_j \in \mathbb{R}$  για  $j = 1, \dots, d$ . Η τιμή  $x_j$  είναι η  $j$ -οστή είσοδος του διανύσματος  $\mathbf{x}$ . Μπορεί επίσης να είναι χρήσιμο να θεωρήσουμε ένα διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$  ως μία συνάρτηση που αντιστοιχίζει κάθε δείκτη  $j \in \{1, \dots, d\}$  σε μία τιμή  $x_j \in \mathbb{R}$ , δηλαδή  $\mathbf{x} : j \mapsto x_j$ . Αυτή η προοπτική είναι ιδιαίτερα χρήσιμη για την μελέτη των μεθόδων πυρήνα. Βλέπε Σχ. 6 για τις δύο όψεις ενός διανύσματος.

2, -1, 3, 0, -2, 1

(a)




(b)

Σχ. 6. Δύο ισοδύναμες όψεις ενός διανύσματος  $\mathbf{x} = (2, -1, 3, 0, -2, 1)^T \in \mathbb{R}^6$ .  
(a) Ως μία αριθμητική διάταξη. (b) Ως μία απεικόνιση  $j \mapsto x_j$ .

Βλέπε επίσης: διανυσματικός χώρος, μηχανική μάθηση, Ευκλείδειος χώρος, συνάρτηση, μέθοδος πυρήνα, απεικόνιση, γραμμική απεικόνιση.

**διανυσματικός χώρος** Ένας διανυσματικός χώρος  $\mathcal{V}$  (που ονομάζεται επίσης γραμμικός χώρος) είναι μία συλλογή στοιχείων, τα οποία ονομάζονται διανύσματα, μαζί με τις εξής δύο λειτουργίες (βλέπε επίσης Σχ. 7): 1) πρόσθεση (που δηλώνεται με  $\mathbf{v} + \mathbf{w}$ ) δύο διανυσμάτων  $\mathbf{v}, \mathbf{w}$  και 2) πολλαπλασιασμός (που δηλώνεται με  $c \cdot \mathbf{v}$ ) ενός διανύσματος  $\mathbf{v}$  με έναν βαθμωτό  $c$  που ανήκει σε κάποιο αριθμητικό πεδίο (με μία τυπική επιλογή για αυτό το πεδίο να είναι ο  $\mathbb{R}$ ). Η καθοριστική ιδιότητα ενός διανυσματικού χώρου είναι ότι είναι κλειστός υπό δύο συγκεκριμένες λειτουργίες. Πρώτον, αν  $\mathbf{v}, \mathbf{w} \in \mathcal{V}$ , τότε  $\mathbf{v} + \mathbf{w} \in \mathcal{V}$ . Δεύτερον, αν  $\mathbf{v} \in \mathcal{V}$  και  $c \in \mathbb{R}$ , τότε  $c\mathbf{v} \in \mathcal{V}$ .





Σχ. 7. Ένας διανυσματικός χώρος  $\mathcal{V}$  είναι μία συλλογή διανυσμάτων, έτσι ώστε η κλίμακα και η πρόσθεσή τους πάντα αποφέρει ένα άλλο διάνυσμα στο  $\mathcal{V}$ .

Ένα κοινό παράδειγμα ενός διανυσματικού χώρου είναι ο Ευκλείδειος χώρος  $\mathbb{R}^n$ , ο οποίος χρησιμοποιείται ευρέως στη μηχανική μάθηση για την αναπαράσταση συνόλων δεδομένων. Μπορούμε επίσης να χρησιμοποιήσουμε τον  $\mathbb{R}^n$  για να αναπαραστήσουμε, είτε ακριβώς είτε προσεγγιστικά, τον χώρο υποθέσεων που χρησιμοποιείται από μία μέθοδο μηχανικής μάθησης. Ένα άλλο παράδειγμα διανυσματικού χώρου, ο οποίος σχετίζεται φυσικά με κάθε χώρο πιθανοτήτων  $\mathcal{P} = (\Omega, \mathcal{R}, \mathbb{P}(\cdot))$ , είναι η συλλογή όλων των τυχαίων μεταβλητών πραγματικής τιμής  $x : \Omega \rightarrow \mathbb{R}$  [1], [21].

Βλέπε επίσης: διάνυσμα, Ευκλείδειος χώρος, μηχανική μάθηση, σύνολο δεδομένων, χώρος υποθέσεων, χώρος πιθανοτήτων, τυχαία μεταβλητή, γραμμικό μοντέλο, linear map.

**διάσταση** TBC.

**διαφορική εντροπία** Για μία τυχαία μεταβλητή  $\mathbf{x} \in \mathbb{R}^d$  με μία συνάρτη-

ση πυκνότητας πιθανότητας  $p^{(x)}(\cdot)$ , η διαφορική εντροπία (differential entropy) ορίζεται ως [14]

$$h(\mathbf{x}) := - \int_{\mathbf{x}' \in \mathbb{R}^d} \log p(\mathbf{x}') p^{(\mathbf{x})}(\mathbf{x}') d\mathbf{x}'.$$

Η διαφορική εντροπία μπορεί να είναι αρνητική και στερείται κάποιων ιδιοτήτων της εντροπίας για τυχαίες μεταβλητές διακριτών τιμών, όπως της αναλλοιωσιμότητας υπό μία αλλαγή μεταβλητών [14]. Μεταξύ όλων των τυχαίων μεταβλητών με μία δεδομένη μέση τιμή  $\mu$  και πίνακα συνδιακύμανσης  $\mathbf{C}$ , η  $h(\mathbf{x})$  μεγιστοποιείται από  $\mathbf{x} \sim \mathcal{N}(\mu, \mathbf{C})$ .

Βλέπε επίσης: τυχαία μεταβλητή, συνάρτηση πυκνότητας πιθανότητας, εντροπία, μέση τιμή, πίνακας συνδιακύμανσης, αβεβαιότητα, πιθανοτικό μοντέλο.

**έκβαση** Έκβαση είναι ένα πιθανό αποτέλεσμα μίας φυσικής διαδικασίας. Μία τέτοια διαδικασία θα μπορούσε να είναι η παρατήρηση ενός φυσικού φαινομένου, ένας υπολογισμός που εκτελείται από έναν αλγόριθμο, ή ένα τυχαίο πείραμα [6].

Βλέπε επίσης: αλγόριθμος, τυχαίο πείραμα, δειγματικός χώρος.

**εκτιμητής** TBC.

**ελάχιστο** Δεδομένου ενός συνόλου πραγματικών αριθμών, το ελάχιστο είναι ο μικρότερος από αυτούς τους αριθμούς. Σημείωση ότι για κάποια σύνολα, όπως το σύνολο αρνητικών πραγματικών αριθμών, το ελάχιστο δεν υφίσταται.

**ελάχιστο άνω φράγμα (ή supremum)** The supremum of a set of real

numbers is the smallest number that is greater than or equal to every element in the set. More formally, a real number  $a$  is the supremum of a set  $\mathcal{A} \subseteq \mathbb{R}$  if: 1)  $a$  is an upper bound of  $\mathcal{A}$ ; and 2) no number smaller than  $a$  is an upper bound of  $\mathcal{A}$ . Every non-empty set of real numbers that is bounded above has a supremum, even if it does not contain its supremum as an element [2, Sec. 1.4].

**εμπειρική κατανομή** TBC.

**εντροπία** Η εντροπία (entropy) ποσοτικοποιεί την αβεβαιότητα ή τη μη προβλεψιμότητα που σχετίζεται με μία τυχαία μεταβλητή [14]. Για μία διακριτή τυχαία μεταβλητή  $x$  που παίρνει τιμές σε ένα πεπερασμένο σύνολο  $\mathcal{S} = \{x_1, \dots, x_k\}$  με μία συνάρτηση μάζας πιθανότητας  $p^{(x)}(x_c) (= \mathbb{P}(x = x_c))$ , η εντροπία ορίζεται ως [14]

$$H(x) := - \sum_{c=1}^k p^{(x)}(x_c) \log p^{(x)}(x_c).$$

Για ένα δεδομένο σύνολο τιμών  $\mathcal{S}$ , η εντροπία μεγιστοποιείται για μία ομοιόμορφα κατανεμημένη τυχαία μεταβλητή, όπου  $p^{(x)}(x_c) = 1/k$ . Η ελάχιστη εντροπία, η οποία είναι μηδέν, προκύπτει όταν  $p^{(x)}(x_c) = 1$  για κάποια  $x_c \in \mathcal{S}$ . Η διαφορική εντροπία γενικεύει την έννοια της εντροπίας από διακριτές τυχαίες μεταβλητές σε συνεχείς τυχαίες μεταβλητές.

Βλέπε επίσης: αβεβαιότητα, τυχαία μεταβλητή, discrete RV, συνάρτηση μάζας πιθανότητας, διαφορική εντροπία, συνεχής, πιθανοτικό μοντέλο.

**εξίσωση σταθερού σημείου** TBC.

**επανάληψη σταθερού σημείου** TBC.

επαυξημένος κατά Lagrange TBC.

επιγράφος TBC.

**Εσσιανός** Θεωρούμε μία συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  για την οποία οι μερικές παράγωγοι δεύτερης τάξης υφίστανται στο  $\mathbf{x}'$ . Τότε, ο Εσσιανός (Hessian)  $\nabla^2 f(\mathbf{x}')$  της  $f$  στο  $\mathbf{x}$  ορίζεται ως ο πίνακας μερικών παραγώγων δεύτερης τάξης της  $f$  στο  $\mathbf{x}'$ , δηλαδή


$$\nabla^2 f(\mathbf{x}') = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_d} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \frac{\partial^2 f}{\partial x_d \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_d^2} \end{pmatrix}.$$

Αν οι μερικές παράγωγοι δεύτερης τάξης είναι συνεχείς σε μία γειτονιά γύρω από το  $\mathbf{x}'$ , τότε ο Εσσιανός είναι ένας συμμετρικός πίνακας, δηλαδή  $\partial^2 f / \partial x_j \partial x_{j'} = \partial^2 f / \partial x_{j'} \partial x_j$  για όλα τα  $j, j'$  [2]. Αν επιπλέον η  $f$  είναι κυρτή, τότε ο Εσσιανός είναι ένας θετικά ημιορισμένος πίνακας [22].

Ο Εσσιανός  $\nabla^2 f(\mathbf{x}')$  μπορεί να χρησιμοποιηθεί για τον υπολογισμό μίας τετραγωνικής συνάρτησης

$$q(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}')^T \underbrace{\nabla^2 f(\mathbf{x}')}_{\text{Εσσιανός}}(\mathbf{x} - \mathbf{x}') + (\mathbf{x} - \mathbf{x}')^T \underbrace{\nabla f(\mathbf{x}')}_{\text{κλίση}} + f(\mathbf{x}')$$

που προσεγγίζει τοπικά την  $f$  γύρω από το  $\mathbf{x}'$  (βλέπε επίσης Σχ. 8).



Σχ. 8. Μία συνάρτηση  $f(\mathbf{x})$  που είναι επαρκώς λεία σε ένα σημείο  $\mathbf{x}'$  μπορεί να προσεγγιστεί τοπικά από μία τετραγωνική συνάρτηση  $q(\mathbf{x})$ , η οποία παρέχει μία πιο ορθή προσέγγιση σε σύγκριση με μία γραμμική συνάρτηση  $g(\mathbf{x})$ .

Βλέπε επίσης: συνάρτηση, μερική παράγωγος, πίνακας, συνεχής, γειτονιά, συμμετρικός πίνακας, κυρτό, θετικά ημιορισμένος, τετραγωνική συνάρτηση, κλίση, λεία.

**εσωτερικό γινόμενο** TBC.

**Ευκλείδεια απόσταση** Η Ευκλείδεια απόσταση (Euclidean distance) μεταξύ δύο διανυσμάτων  $\mathbf{w}, \mathbf{w}' \in \mathbb{R}^d$  είναι η Ευκλείδεια νόρμα της διαφοράς  $\mathbf{w} - \mathbf{w}'$ .

Βλέπε επίσης: διάνυσμα, Ευκλείδεια νόρμα, Ευκλείδειος χώρος.

**Ευκλείδεια νόρμα** Η Ευκλείδεια νόρμα (Euclidean norm)  $\|\mathbf{w}\|_2$  ενός διανύσματος

$$\mathbf{w} = (w_1, \dots, w_d) \in \mathbb{R}^d$$

ορίζεται ως

$$\|\mathbf{w}\|_2 := \sqrt{\sum_{j=1}^d w_j^2}.$$

Η Ευκλείδεια νόρμα είναι διαφορετική από όλες τις νόρμες στον  $\mathbb{R}^d$ , υπό την έννοια ότι επάγεται από το εσωτερικό γινόμενο  $\mathbf{w}^T \mathbf{v}$  [1], [22], [23].

Με άλλα λόγια,  $\|\mathbf{w}\|_2 = \sqrt{\mathbf{w}^T \mathbf{w}}$ .

Βλέπε επίσης: νόρμα, διάνυσμα, εσωτερικό γινόμενο, Ευκλείδειος χώρος.

**Ευκλείδειος χώρος** Ο Ευκλείδειος χώρος  $\mathbb{R}^d$  διάστασης  $d \in \mathbb{N}$  αποτελείται από διανύσματα  $\mathbf{x} = (x_1, \dots, x_d)$ , με  $d$  καταχωρίσεις πραγματικής τιμής  $x_1, \dots, x_d \in \mathbb{R}$ . Ένας τέτοιος Ευκλείδειος χώρος είναι εξοπλισμένος με μία γεωμετρική δομή που ορίζεται από το εσωτερικό γινόμενο  $\mathbf{x}^T \mathbf{x}' = \sum_{j=1}^d x_j x'_j$  μεταξύ οποιωνδήποτε δύο διανυσμάτων  $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^d$  [2].

Βλέπε επίσης: διάνυσμα, εσωτερικό γινόμενο.

**θετικά ημιορισμένος** Ένας συμμετρικός πίνακας (πραγματικών τιμών)  $\mathbf{Q} = \mathbf{Q}^T \in \mathbb{R}^{d \times d}$  αναφέρεται ως θετικά ημιορισμένος (positive semi-definite - psd) αν  $\mathbf{x}^T \mathbf{Q} \mathbf{x} \geq 0$  για κάθε διάνυσμα  $\mathbf{x} \in \mathbb{R}^d$ . Ένας θετικά ημιορισμένος πίνακας  $\mathbf{Q}$  αποδέχεται μία φασματική ανάλυση με μη αρνητικές ιδιοτιμές  $\lambda_1, \dots, \lambda_d \geq 0$  [24], [25]. Η έννοια του να είναι θετικά ημιορισμένος μπορεί να επεκταθεί από πίνακες σε συμμετρικές απεικονίσεις πυρήνα (πραγματικών τιμών)  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  (με  $k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x}', \mathbf{x})$ ) ως εξής: Για οποιοδήποτε πεπερασμένο σύνολο διανυσμάτων χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$ , ο επακόλουθος πίνακας  $\mathbf{Q} \in \mathbb{R}^{m \times m}$  με καταχωρίσεις  $Q_{r,r'} = k(\mathbf{x}^{(r)}, \mathbf{x}^{(r')})$  είναι θετικά ημιορισμένος [26].

Βλέπε επίσης: συμμετρικός πίνακας, διάνυσμα, πίνακας, φασματική ανάλυση, ιδιοτιμή, πυρήνας, απεικόνιση, διάνυσμα χαρακτηριστικών.

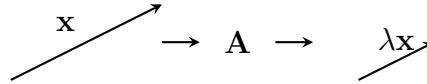
**ιδιάζουσα τιμή** Βλέπε ανάλυση ιδιάζουσών τιμών.

**ιδιοδιάνυσμα** Ένα ιδιοδιάνυσμα ενός πίνακα  $\mathbf{A} \in \mathbb{R}^{d \times d}$  είναι ένα μη μηδενικό διάνυσμα  $\mathbf{x} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$  τέτοιο ώστε  $\mathbf{A} \mathbf{x} = \lambda \mathbf{x}$  με κάποια ιδιοτιμή  $\lambda$ .

Βλέπε επίσης: πίνακας, διάνυσμα, ιδιοτιμή.

**ιδιότητα Markov** Βλέπε Markov chain.

**ιδιοτιμή** Αναφερόμαστε σε έναν αριθμό  $\lambda \in \mathbb{R}$  ως μία ιδιοτιμή ενός τετραγωνικού πίνακα  $\mathbf{A} \in \mathbb{R}^{d \times d}$  αν υφίσταται ένα μη μηδενικό διάνυσμα  $\mathbf{x} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$  τέτοιο ώστε  $\mathbf{Ax} = \lambda\mathbf{x}$  (βλέπε Σχ. 9).


$$\mathbf{x} \rightarrow \mathbf{A} \rightarrow \lambda\mathbf{x}$$

Σχ. 9. Αυτό το διάνυσμα είναι το ιδιοδιάνυσμα που αντιστοιχεί στην ιδιοτιμή  $\lambda$ .

Βλέπε επίσης: πίνακας, διάνυσμα, ιδιοδιάνυσμα.

**ίχνος** TBC.

**κανονικός πίνακας** A normal πίνακας is a square πίνακας  $\mathbf{A} \in \mathbb{C}^{d \times d}$  that commutes with its conjugate transpose, i.e.,  $\mathbf{AA}^H = \mathbf{A}^H\mathbf{A}$ . Normal πίνακας admit an orthonormal basis of ιδιοδιάνυσμας and are unitarily διαγωνοποιήσιμος.

See also: πίνακας, διαγωνοποιήσιμος.

**κατανομή πιθανότητας** Για να αναλύσουμε μεθόδους μηχανικής μάθησης, μπορεί να είναι χρήσιμο να ερμηνεύσουμε σημεία δεδομένων ως ανεξάρτητες και ταυτόσημα κατανεμημένες πραγματώσεις μίας τυχαίας μεταβλητής. Οι τυπικές ιδιότητες τέτοιων σημείων δεδομένων διέπονται τότε από την κατανομή πιθανότητας αυτής της τυχαίας μεταβλητής. Η κατανομή πιθανότητας μίας δυαδικής τυχαίας μεταβλητής  $y \in \{0, 1\}$  προσδιορίζεται πλήρως από τις πιθανότητες  $\mathbb{P}(y = 0)$  και  $\mathbb{P}(y = 1) = 1 - \mathbb{P}(y = 0)$ . Η κατανομή πιθανότητας μίας τυχαίας μεταβλητής πραγματικής τιμής  $x \in \mathbb{R}$

μπορεί να προσδιορίζεται από μία συνάρτηση πυκνότητας πιθανότητας  $p(x)$  έτσι ώστε  $\mathbb{P}(x \in [a, b]) \approx p(a)|b - a|$ . Στην πιο γενική περίπτωση, η κατανομή πιθανότητας ορίζεται από ένα μέτρο πιθανότητας [6], [27].

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, ανεξάρτητες και ταυτόσημα καταταξιμμένες, πραγμάτωση, τυχαία μεταβλητή, πιθανότητα, συνάρτηση πυκνότητας πιθανότητας.

**κατανομή πιθανότητας υπό συνθήκη** Θεωρούμε μία στοχαστική διαδικασία που αποτελείται από δύο τυχαίες μεταβλητές  $\mathbf{x}$  και  $y$  με κατανομή πιθανότητας  $\mathbb{P}(\mathbf{x}, y)$ . Η υπό συνθήκη κατανομή πιθανότητας της  $y$  δεδομένης (ή υπό τον όρο) της  $\mathbf{x}$  δηλώνεται με  $\mathbb{P}(y|\mathbf{x})$ . Ορίζεται μέσω των προσδοκιών υπό συνθήκη των συναρτήσεων-δεικτών μετρήσιμων συνόλων στη  $\sigma$ -άλγεβρα που παράγεται από την τυχαία μεταβλητή  $y$  [6], [28]. Βλέπε επίσης: στοχαστική διαδικασία, τυχαία μεταβλητή, κατανομή πιθανότητας, προσδοκία υπό συνθήκη, συνάρτηση, μετρήσιμο,  $\sigma$ -άλγεβρα.

**κατάσταση** Μία κατάσταση (state) είναι μία μαθηματική αναπαράσταση των ελάχιστων πληροφοριών που χρειάζονται για να χαρακτηριστεί ένα σύστημα σε μία δεδομένη στιγμή, έτσι ώστε, μαζί με τη δυναμική του συστήματος, να επαρκούν για την πρόβλεψη της μελλοντικής συμπεριφοράς του συστήματος [29], [30].

Βλέπε επίσης: διάνυσμα χαρακτηριστικών, υπόθεση, ενέργεια.

**κατευθυνόμενος μη κυκλικός γράφος** TBC.

**κεντρικό οριακό θεώρημα** TBC.

**κλίση** Για μία συνάρτηση πραγματικής τιμής  $f : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{w} \mapsto f(\mathbf{w})$ , αν



υφίσταται ένα διάνυσμα  $\mathbf{g}$  τέτοιο ώστε

$$\lim_{\mathbf{w} \rightarrow \mathbf{w}'} \frac{f(\mathbf{w}) - (f(\mathbf{w}') + \mathbf{g}^T(\mathbf{w} - \mathbf{w}'))}{\|\mathbf{w} - \mathbf{w}'\|} = 0,$$

αναφέρεται ως η κλίση (gradient) της  $f$  στο  $\mathbf{w}'$ . Αν υφίσταται, η κλίση είναι μοναδική και δηλώνεται με  $\nabla f(\mathbf{w}')$  ή  $\nabla f(\mathbf{w})|_{\mathbf{w}'}$  [2]. Για μία παραγωγίσιμη συνάρτηση, η κλίση είναι το διάνυσμα του οποίου οι καταχωρίσεις είναι οι μερικές παράγωγοι της  $f$  ως προς κάθε συνιστώσα εισόδου, έτσι ώστε  $\nabla f(\mathbf{w}) = [\partial f / \partial x_1, \dots, \partial f / \partial x_d]^T$ . Γεωμετρικά, η κλίση δείχνει την κατεύθυνση της μέγιστης αύξησης.

Βλέπε επίσης: συνάρτηση, διάνυσμα, παραγωγίσιμη, μερική παράγωγος, μέθοδος με βάση την κλίση, κάθοδος κλίσης, συνθήκη μηδενικής κλίσης, Εσσιανός.

**κυρτή βελτιστοποίηση** TBC.

**κυρτό** Ένα υποσύνολο  $\mathcal{C} \subseteq \mathbb{R}^d$  του Ευκλείδειου χώρου  $\mathbb{R}^d$  αναφέρεται ως κυρτό (convex) αν περιέχει το ευθύγραμμο τμήμα μεταξύ οποιωνδήποτε δύο σημείων  $\mathbf{x}, \mathbf{y} \in \mathcal{C}$  σε αυτό το σύνολο, δηλαδή

$$\alpha \mathbf{x} + (1 - \alpha) \mathbf{y} \in \mathcal{C} \quad \text{για κάθε } \alpha \in [0, 1].$$

Όμοια, μία συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  είναι κυρτή αν ο επιγράφος της  $\{(\mathbf{w}^T, t)^T \in \mathbb{R}^{d+1} : t \geq f(\mathbf{w})\}$  είναι ένα κυρτό σύνολο [22]. Παρουσιάζουμε ένα παράδειγμα ενός κυρτού συνόλου και μίας κυρτής συνάρτησης στο Σχ. 10.



Σχ. 10. (a) Ένα κυρτό σύνολο  $\mathcal{C} \subseteq \mathbb{R}^d$ . (b) Μία κυρτή συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ .

Βλέπε επίσης: Ευκλείδειος χώρος, συνάρτηση, επιγράφος.

**λεία** TBC.

**μέγιστο** Το μέγιστο (maximum) ενός συνόλου  $\mathcal{A} \subseteq \mathbb{R}$  πραγματικών αριθμών είναι το μέγιστο στοιχείο σε αυτό το σύνολο, αν ένα τέτοιο στοιχείο υφίσταται. Ένα σύνολο  $\mathcal{A}$  έχει ένα μέγιστο αν είναι άνω φραγμένο και επιτυγχάνει το ελάχιστο άνω φράγμα του [2, Ενότητα 1.4].

Βλέπε επίσης: ελάχιστο άνω φράγμα (ή supremum).

**μέθοδος βελτιστοποίησης** Μία μέθοδος βελτιστοποίησης (optimization method) είναι ένας αλγόριθμος που διαβάζει μία αναπαράσταση ενός προβλήματος βελτιστοποίησης ως είσοδο και υπολογίζει μία (προσεγγιστική) λύση ως έξοδό του. Ένα κεντρικό παράδειγμα προβλήματος βελτιστοποίησης στη μηχανική μάθηση είναι η εμπειρική ελαχιστοποίηση διακινδύνευσης. Εφαρμόζοντας μία κατάλληλη μέθοδο βελτιστοποίησης στην εμπειρική ελαχιστοποίηση διακινδύνευσης, αποκτούμε έναν συγκεκριμένο αλγόριθμο μάθησης [22], [31], [32].

Βλέπε επίσης: βελτιστοποίηση, αλγόριθμος, optimization problem, έξο-

δος, μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης.

#### μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών

Η μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών (alternating direction method of multipliers - ADMM) είναι μία επαναληπτική μέθοδος βελτιστοποίησης για τη λύση ενός δομημένου προβλήματος βελτιστοποίησης. Συγκεκριμένα, η μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών μπορεί να χρησιμοποιηθεί για τη λύση ενός προβλήματος βελτιστοποίησης της μορφής

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^d, \mathbf{x}' \in \mathbb{R}^{d'}} \quad & f(\mathbf{x}) + g(\mathbf{x}') \\ \text{s.t.} \quad & \mathbf{Ax} - \mathbf{Bx}' = \mathbf{c}, \end{aligned}$$

για δεδομένους πίνακες  $\mathbf{A} \in \mathbb{R}^{p \times d}$  και  $\mathbf{B} \in \mathbb{R}^{p \times d'}$ , καθώς και ένα δεδομένο διάνυσμα  $\mathbf{c} \in \mathbb{R}^p$ .

Βλέπε επίσης: μέθοδος βελτιστοποίησης, optimization problem, πίνακας, διάνυσμα, μέθοδος των πολλαπλασιαστών.

#### μέθοδος των πολλαπλασιαστών

Η μέθοδος των πολλαπλασιαστών (method

of multipliers - MoM) είναι μία επαναληπτική μέθοδος βελτιστοποίησης για τη λύση ενός περιορισμένου προβλήματος βελτιστοποίησης της μορφής [33]

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^d} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & \mathbf{Ax} = \mathbf{b}. \end{aligned}$$

Εδώ,  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  δηλώνει την αντικειμενική συνάρτηση,  $\mathbf{A} \in \mathbb{R}^{m \times d}$  είναι ένας δεδομένος πίνακας, και  $\mathbf{b} \in \mathbb{R}^m$  είναι ένα δεδομένο διάνυσμα. Η μέθοδος των πολλαπλασιαστών βασίζεται στον augmented Lagrangian

$$L_\rho(\mathbf{x}, \mathbf{y}) = f(\mathbf{x}) + \mathbf{y}^\top \mathbf{A}\mathbf{x} + \frac{\rho}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2$$

όπου  $\mathbf{y}$  δηλώνει το διάνυσμα των πολλαπλασιαστών του Lagrange και  $\rho > 0$  είναι μία παράμετρος ποινής. Η μέθοδος των πολλαπλασιαστών κατασκευάζει μία ακολουθία εκτιμήσεων  $(\mathbf{x}^{(1)}, \mathbf{y}^{(1)})$ , ... που συγκλίνει σε μία λύση του προβλήματος βελτιστοποίησης. Συγκεκριμένα, κατά τη διάρκεια κάθε επανάληψης  $t$ , οι τρέχουσες εκτιμήσεις  $\mathbf{x}^{(k)}, \mathbf{y}^{(k)}$  ενημερώνονται ως εξής:

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \arg \min_{\mathbf{x} \in \mathbb{R}^d} L_\rho(\mathbf{x}, \mathbf{y}^{(k)}) \\ \mathbf{y}^{(k+1)} &= \mathbf{y}^{(k)} + \rho (\mathbf{A}\mathbf{x}^{(k+1)} - \mathbf{b}). \end{aligned}$$

Η μέθοδος των πολλαπλασιαστών μπορεί να γραφεί ως μία επανάληψη σταθερού σημείου της μορφής

$$(\mathbf{x}^{(k+1)}, \mathbf{y}^{(k+1)}) = \mathcal{F}(\mathbf{x}^{(k)}, \mathbf{y}^{(k)})$$

με

$$\begin{aligned} \mathcal{F} : \mathbb{R}^d \times \mathbb{R}^m &\rightarrow \mathbb{R}^d \times \mathbb{R}^m : (\mathbf{x}, \mathbf{y}) \mapsto (\mathbf{x}', \mathbf{y} + \rho(\mathbf{A}\mathbf{x}' - \mathbf{b})) \\ \text{με } \mathbf{x}' &= \arg \min_{\mathbf{x} \in \mathbb{R}^d} L_\rho(\mathbf{x}, \mathbf{y}). \end{aligned}$$

Βλέπε επίσης: μέθοδος βελτιστοποίησης, optimization problem, αντικειμενική συνάρτηση, πίνακας, διάνυσμα, augmented Lagrangian, παράμετρος, ακολουθία, επανάληψη, επανάληψη σταθερού σημείου.

**μερική παράγωγος** TBC.

**μέση τιμή** Η μέση τιμή μίας τυχαίας μεταβλητής  $\mathbf{x}$ , που παίρνει τιμές σε έναν Ευκλείδειο χώρο  $\mathbb{R}^d$ , είναι η προσδοκία της  $\mathbb{E}\{\mathbf{x}\}$ . Ορίζεται ως το ολοκλήρωμα Lebesgue του  $\mathbf{x}$  αναφορικά με την υποκείμενη κατανομή πιθανότητας  $P$  (π.χ. βλέπε [2] ή [6]), δηλαδή

$$\mathbb{E}\{\mathbf{x}\} = \int_{\mathbb{R}^d} \mathbf{x} dP(\mathbf{x}).$$

Είναι χρήσιμο να σκεφτούμε τη μέση τιμή ως τη λύση του ακόλουθου προβλήματος ελαχιστοποίησης διακινδύνευσης [7]:

$$\mathbb{E}\{\mathbf{x}\} = \arg \min_{\mathbf{c} \in \mathbb{R}^d} \mathbb{E}\{\|\mathbf{x} - \mathbf{c}\|_2^2\}.$$


Χρησιμοποιούμε επίσης τον όρο για να αναφερθούμε στον μέσο όρο μίας πεπερασμένης ακολουθίας  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Ωστόσο, αυτοί οι δύο ορισμοί είναι ουσιαστικά ίδιοι. Πράγματι, μπορούμε να χρησιμοποιήσουμε την ακολουθία  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$  για να κατασκευάσουμε μία διακριτή τυχαία μεταβλητή  $\tilde{\mathbf{x}} = \mathbf{x}^{(I)}$ , με τον δείκτη  $I$  να επιλέγεται ομοιόμορφα στην τύχη από το σύνολο  $\{1, \dots, m\}$ . Η μέση τιμή της  $\tilde{\mathbf{x}}$  είναι ακριβώς ο μέσος όρος  $(1/m) \sum_{r=1}^m \mathbf{x}^{(r)}$ .

Βλέπε επίσης: τυχαία μεταβλητή, Ευκλείδειος χώρος, expectation, κατανομή πιθανότητας, διακινδύνευση.

**μέσος βαθμός κόμβου** The average βαθμός κόμβου  $\bar{d}$  of a weighted μη κατευθυνόμενος γράφος  $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$  is the average of all βαθμός κόμβους, i.e.,  $\bar{d} = (1/n) \sum_{i \in \mathcal{V}} d^{(i)}$ .

See also: βαθμός κόμβου, μη κατευθυνόμενος γράφος, γείτονas.

**μετρήσιμο** Θεωρούμε ένα τυχαίο πείραμα, όπως την καταγραφή της θερμοκρασίας του αέρα σε ένα σταθμό καιρού του Φινλανδικού Μετεωρολογικού Ινστιτούτου. Ο αντίστοιχος δειγματικός χώρος  $\Omega$  αποτελείται από όλες τις πιθανές εκβάσεις  $\omega$  (π.χ. όλες τις πιθανές τιμές θερμοκρασίας σε βαθμούς Κελσίου). Σε πολλές εφαρμογές μηχανικής μάθησης, δε μας ενδιαφέρει η ακριβής έκβαση  $\omega$ , αλλά μόνο το αν ανήκει σε ένα υποσύνολο  $\mathcal{A} \subseteq \Omega$  (π.χ. ο καθορισμός του αν η θερμοκρασία είναι κάτω από το μηδέν). Ονομάζουμε ένα τέτοιο υποσύνολο  $\mathcal{A}$  μετρήσιμο (measurable) αν είναι δυνατό να αποφασίσουμε, για οποιαδήποτε έκβαση  $\omega$ , αν  $\omega \in \mathcal{A}$  (βλέπε Σχ. 11).



Σχ. 11. Ένας δειγματικός χώρος που αποτελείται από όλες τις πιθανές τιμές θερμοκρασίας  $\omega$  που μπορούν να εμφανιστούν σε έναν σταθμό του Φινλανδικού Μετεωρολογικού Ινστιτούτου. Δύο μετρήσιμα υποσύνολα τιμών θερμοκρασίας, τα οποία συμβολίζονται με  $\mathcal{A}^{(1)}$  και  $\mathcal{A}^{(2)}$ , επισημαίνονται. Για οποιαδήποτε πραγματική τιμή θερμοκρασίας  $\omega$ , είναι δυνατό να καθοριστεί (μέσω κάποιου εξοπλισμού) αν  $\omega \in \mathcal{A}^{(1)}$  και αν  $\omega \in \mathcal{A}^{(2)}$ .

Στη θεωρία, μετρήσιμα σύνολα μπορούν να επιλεγούν ελεύθερα (π.χ. ανάλογα με την ανάλυση του εξοπλισμού μέτρησης). Ωστόσο, είναι συχνά χρήσιμο να επιβάλλονται ορισμένες απαιτήσεις πληρότητας στη συλλογή των μετρήσιμων συνόλων. Για παράδειγμα, ο ίδιος ο δειγματικός χώρος θα πρέπει να είναι μετρήσιμος, και η ένωση δύο μετρήσιμων συνόλων θα πρέπει επίσης να είναι μετρήσιμη. Αυτές οι απαιτήσεις πληρότητας μπορούν να τυποποιηθούν μέσω της έννοιας της  $\sigma$ -άλγεβρας (ή  $\sigma$ -field) [1], [6], [17]. Ένας μετρήσιμος χώρος είναι ένα ζεύγος  $(\mathcal{X}, \mathcal{F})$  που αποτελείται από ένα αυθαίρετο σύνολο  $\mathcal{X}$  και μία συλλογή  $\mathcal{F}$  μετρήσιμων υποσυνόλων του  $\mathcal{X}$  που σχηματίζουν μία  $\sigma$ -άλγεβρα.

Βλέπε επίσης: τυχαίο πείραμα, Φινλανδικό Μετεωρολογικό Ινστιτούτο, δειγματικός χώρος, έκβαση, μηχανική μάθηση,  $\sigma$ -άλγεβρα,  $\sigma$ -field, πιθανότητα.


**μετρική** Μία μετρική (metric) είναι ένα ποσοτικό μέτρο που χρησιμοποιείται για τη σύγκριση αντικειμένων. Στα μαθηματικά, μία μετρική μετράει την απόσταση μεταξύ δύο σημείων σε έναν χώρο και πρέπει να ακολουθεί συγκεκριμένους κανόνες, δηλαδή η απόσταση να είναι πάντα μη αρνητική, να είναι μηδενική μόνο αν τα σημεία είναι ίδια, να είναι συμμετρική, και να ικανοποιεί την τριγωνική ανισότητα [2]. Στο πλαίσιο της μηχανικής μάθησης, ο όρος μετρική αναφέρεται σε ένα ποσοτικό μέτρο του πόσο καλά επιδίδει ένα μοντέλο (κάπως όμοιο με μία συνάρτηση απώλειας). Παραδείγματα περιλαμβάνουν την ακρίβεια, την ακρίβεια, και τη μέση 0/1 απώλεια σε ένα σύνολο ελέγχου [34], [35]. Ο όρος συνάρτηση απώλειας χρησιμοποιείται συνήθως στο πλαίσιο της εκπαίδευσης μοντέλου, ενώ ο όρος μετρική χρησιμοποιείται στο πλαίσιο της επικύρωσης μοντέλου.

Βλέπε επίσης: μέτρο, μηχανική μάθηση, μοντέλο, συνάρτηση απώλειας, ακρίβεια, ακρίβεια, 0/1 απώλεια, σύνολο ελέγχου, εκπαίδευση, επικύρωση, απώλεια.

**μετρικός χώρος** Ένας μετρικός χώρος (metric space) είναι ένα σύνολο  $\mathcal{X}$  εξοπλισμένο με μία συνάρτηση (που αναφέρεται ως μία μετρική)  $d(\cdot, \cdot) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ , η οποία ικανοποιεί τις ακόλουθες απαιτήσεις για όλα τα  $\mathbf{x}, \mathbf{x}', \mathbf{x}'' \in \mathcal{X}$ :

- 1) Μη αρνητικότητα:  $d(\mathbf{x}, \mathbf{x}') \geq 0$ .
- 2) Ταυτότητα:  $d(\mathbf{x}, \mathbf{x}') = 0$  αν και μόνο αν  $\mathbf{x} = \mathbf{x}'$ .
- 3) Συμμετρία:  $d(\mathbf{x}, \mathbf{x}') = d(\mathbf{x}', \mathbf{x})$ .
- 4) Τριγωνική ανισότητα:  $d(\mathbf{x}, \mathbf{x}'') \leq d(\mathbf{x}, \mathbf{x}') + d(\mathbf{x}', \mathbf{x}'')$ .

Τυπικά, ένας μετρικός χώρος είναι ένα ζεύγος  $(\mathcal{X}, d(\cdot, \cdot))$  που ικανοποιεί τις παραπάνω απαιτήσεις.



Σχ. 12. Παραδείγματα μετρικών χώρων. (a) Ευκλείδειος χώρος  $\mathbb{R}^2$  με την Ευκλείδεια απόσταση ως μία μετρική. (b) Μη κατευθυνόμενος γράφος  $(\mathcal{V}, \mathcal{E})$  με την απόσταση της συντομότερης διαδρομής ως μία μετρική.



Ένα περίφημο παράδειγμα μετρικού χώρου είναι ο Ευκλείδειος χώρος εξοπλισμένος με μία μετρική που δίνεται από την Ευκλείδεια απόσταση  $d(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\|_2$ . Ένα άλλο καλά γνωστό παράδειγμα μετρικού χώρου είναι ένας μη κατευθυνόμενος γράφος  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ , με τη μετρική  $d(i, i')$  ορισμένη από το μήκος της συντομότερης διαδρομής που συνδέει τους κόμβους  $i$  και  $i'$ .

Βλέπε επίσης: μετρική, συνάρτηση, Ευκλείδειος χώρος, μη κατευθυνόμενος γράφος, Ευκλείδεια απόσταση, χώρος χαρακτηριστικών.

**μέτρο** TBC.

**μη κατευθυνόμενος γράφος** Βλέπε graph.

**μη λεία** Αναφερόμαστε σε μία συνάρτηση ως μη λεία αν δεν είναι λεία [32].

Βλέπε επίσης: συνάρτηση, λεία.

**νόμος των μεγάλων αριθμών** Ο νόμος των μεγάλων αριθμών αναφέρεται στη σύγκλιση του μέσου όρου ενός αυξανόμενου (μεγάλου) αριθμού ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών στη μέση τιμή της κοινής τους κατανομής πιθανότητας. Διαφορετικές περιπτώσεις του νόμου των μεγάλων αριθμών προκύπτουν από τη χρήση διαφορετικών εννοιών σύγκλισης [36].

Βλέπε επίσης: σύγκλιση, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, μέση τιμή, κατανομή πιθανότητας.

**νόρμα** Μία νόρμα είναι μία συνάρτηση που αντιστοιχίζει κάθε (διανυσματικό) στοιχείο ενός διανυσματικού χώρου σε έναν μη αρνητικό αριθμό. Αυτή η συνάρτηση πρέπει να είναι ομογενής και ορισμένη, και πρέπει να ικανοποιεί

την τριγωνική ανισότητα [24].

Βλέπε επίσης: συνάρτηση, διάνυσμα, διανυσματικός χώρος.

**ολική μεταβολή** Βλέπε γενικευμένη ολική μεταβολή.

**ολοκλήρωμα Lebesgue** TBC.

**ολοκληρώσιμη** A μετρήσιμο συνάρτηση  $f : \Omega \rightarrow \mathbb{R}$  defined on a χώρος μέτρου  $(\Omega, \Sigma, \mu)$  is called integrable if the ολοκλήρωμα Lebesgue of its absolute value is finite, i.e.,

$$\int_{\Omega} |f(x)| d\mu < \infty.$$

In this case, the ολοκλήρωμα Lebesgue  $\int_{\Omega} f(x) d\mu$  is well defined and finite. An τυχαία μεταβλητή  $x$  defined on the δειγματικός χώρος of a χώρος πιθανοτήτων  $(\Omega, \Sigma, \mathbb{P})$  is integrable if

$$\mathbb{E}\{|x|\} = \int_{\Omega} |x(\omega)| d\mathbb{P} < \infty,$$

which is equivalent to the existence of the expectation  $\mathbb{E}\{x\}$  (i.e., it is finite).

See also: χώρος μέτρου, μέτρο.

**ορίζουσα** Η ορίζουσα  $\det(\mathbf{A})$  ενός τετραγωνικού πίνακα  $\mathbf{A} = (\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)}) \in \mathbb{R}^{d \times d}$  είναι μία συνάρτηση των στηλών του  $\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)} \in \mathbb{R}^d$ , δηλαδή πληροί τις ακόλουθες ιδιότητες [37]:

- Κανονικοποιημένη:

$$\det(\mathbf{I}) = 1$$


- Πολυγραμμική:

$$\det(\mathbf{a}^{(1)}, \dots, \alpha \mathbf{u} + \beta \mathbf{v}, \dots, \mathbf{a}^{(d)}) = \alpha \det(\mathbf{a}^{(1)}, \dots, \mathbf{u}, \dots, \mathbf{a}^{(d)}) + \beta \det(\mathbf{a}^{(1)}, \dots, \mathbf{v}, \dots, \mathbf{a}^{(d)})$$

- Αντισυμμετρική:

$$\det(\dots, \mathbf{a}^{(j)}, \dots, \mathbf{a}^{(j')}, \dots) = -\det(\dots, \mathbf{a}^{(j')}, \dots, \mathbf{a}^{(j)}, \dots).$$

Μπορούμε να ερμηνεύσουμε έναν πίνακα  $\mathbf{A}$  ως έναν γραμμικό μετασχηματισμό στον  $\mathbb{R}^d$ . Η ορίζουσα  $\det(\mathbf{A})$  χαρακτηρίζει πώς οι όγκοι στον  $\mathbb{R}^d$  (και ο προσανατολισμός τους) μεταβάλλονται από αυτόν τον μετασχηματισμό (βλέπε Σχ. 13) [3], [12]. Συγκεκριμένα,  $\det(\mathbf{A}) > 0$  διατηρεί τον προσανατολισμό,  $\det(\mathbf{A}) < 0$  αντιστρέφει τον προσανατολισμό, και  $\det(\mathbf{A}) = 0$  συρρικνώνει πλήρως τον όγκο, υποδεικνύοντας ότι ο  $\mathbf{A}$  είναι μη αντιστρέψιμος. Η ορίζουσα ικανοποιεί επίσης  $\det(\mathbf{AB}) = \det(\mathbf{A}) \cdot \det(\mathbf{B})$ , και αν ο  $\mathbf{A}$  είναι διαγωνοποιήσιμος με ιδιοτιμές  $\lambda_1, \dots, \lambda_d$ , τότε  $\det(\mathbf{A}) = \prod_{j=1}^d \lambda_j$  [24]. Για τις ειδικές περιπτώσεις  $d = 2$  (δηλαδή δισδιάστατη ή 2- $\Delta$ ) και  $d = 3$  (δηλαδή τρισδιάστατη ή 3- $\Delta$ ), η ορίζουσα μπορεί να ερμηνευτεί ως ένα προσανατολισμένο εμβαδόν ή όγκος παραγόμενος από τα διανύσματα στηλών του  $\mathbf{A}$ .



Σχ. 13. Μπορούμε να ερμηνεύσουμε έναν τετραγωνικό πίνακα  $\mathbf{A}$  ως έναν γραμμικό μετασχηματισμό του  $\mathbb{R}^d$  στον εαυτό του. Η ορίζουσα  $\det(\mathbf{A})$  χαρακτηρίζει πώς αυτός ο μετασχηματισμός μεταβάλλει έναν προσανατολισμένο όγκο.

Βλέπε επίσης: πίνακας, συνάρτηση, ιδιοτιμή, διάνυσμα, αντίστροφος πίνακας.

**όριο** TBC.

**παραγωγίσιμη** Μία συνάρτηση πραγματικής τιμής  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  είναι παραγωγίσιμη αν μπορεί να προσεγγιστεί τοπικά σε οποιοδήποτε σημείο από μία γραμμική συνάρτηση. Η τοπική γραμμική προσέγγιση στο σημείο  $\mathbf{x}$  καθορίζεται από την κλίση  $\nabla f(\mathbf{x})$  [2].

Βλέπε επίσης: συνάρτηση, κλίση.

**πεδίο** TBC.

**πεδίο τιμών** TBC.

**πιθανοτικό μοντέλο** Ένα πιθανοτικό μοντέλο (probabilistic model) για την παραγωγή σημείων δεδομένων αποτελείται από τυχαίες μεταβλητές με κοινή κατανομή πιθανότητας [7]. Αυτή η κοινή κατανομή πιθανότητας συνήθως περιλαμβάνει παραμέτρους (ή παράμετρους του μοντέλου) που είτε επιλέγονται χειρωνακτικά είτε μαθαίνονται μέσω μεθόδων στατιστικής εξαγωγής συμπερασμάτων, όπως η εκτίμηση μέγιστης πιθανοφάνειας.

ας [38].

Βλέπε επίσης: μοντέλο, σημείο δεδομένων, τυχαία μεταβλητή, κατανομή πιθανότητας, παράμετρος, model parameters, μέγιστη πιθανοφάνεια, πραγμάτωση.

**πίνακας** Ένας πίνακας μεγέθους  $m \times d$  είναι μία 2-D διάταξη αριθμών, η οποία δηλώνεται με

$$\mathbf{A} = \begin{bmatrix} A_{1,1} & A_{1,2} & \dots & A_{1,d} \\ A_{2,1} & A_{2,2} & \dots & A_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m,1} & A_{m,2} & \dots & A_{m,d} \end{bmatrix} \in \mathbb{R}^{m \times d}.$$

Εδώ,  $A_{r,j}$  δηλώνει την καταχώριση του πίνακα στην  $r$ -οστή γραμμή και την  $j$ -οστή στήλη. Οι πίνακες είναι χρήσιμες αναπαραστάσεις διάφορων μαθηματικών αντικειμένων [39], συμπεριλαμβανομένων των εξής:

- Συστήματα γραμμικών εξισώσεων: Μπορούμε να χρησιμοποιήσουμε έναν πίνακα για να αναπαραστήσουμε ένα σύστημα γραμμικών εξισώσεων

$$\begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \quad \text{συμπαγώς ως} \quad \mathbf{A}\mathbf{w} = \mathbf{y}.$$


Ένα σημαντικό παράδειγμα συστημάτων γραμμικών εξισώσεων είναι η συνθήκη βελτιστότητας για τις παράμετρους μοντέλου εντός γραμμικής παλινδρόμησης.

- Linear maps: Θεωρούμε έναν  $d$ -διάστατο διανυσματικό χώρο  $\mathcal{U}$  και

έναν  $m$ -διάστατο διανυσματικό χώρο  $\mathcal{V}$ . Αν σταθεροποιήσουμε μία βάση  $\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}$  για  $\mathcal{U}$  και μία βάση  $\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(m)}$  για  $\mathcal{V}$ , κάθε πίνακας  $\mathbf{A} \in \mathbb{R}^{m \times d}$  ορίζει φυσικά μία linear map  $\alpha : \mathcal{U} \rightarrow \mathcal{V}$  (βλέπε Σχ. 14) έτσι ώστε

$$\mathbf{u}^{(j)} \mapsto \sum_{r=1}^m A_{r,j} \mathbf{v}^{(r)}.$$

- Σύνολα δεδομένων: Μπορούμε να χρησιμοποιήσουμε έναν πίνακα για να αναπαραστήσουμε ένα σύνολο δεδομένων. Κάθε γραμμή αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και κάθε στήλη αντιστοιχεί σε ένα συγκεκριμένο χαρακτηριστικό ή ετικέτα ενός σημείου δεδομένων.



Σχ. 14. Ένας πίνακας  $\mathbf{A}$  ορίζει μία linear map μεταξύ δύο διανυσματικών χώρων.


Βλέπε επίσης: model parameter, γραμμική παλινδρόμηση, linear map, διανυσματικός χώρος, σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, γραμμικό μοντέλο.

**πίνακας Laplace** Η δομή ενός γράφου  $\mathcal{G}$ , με κόμβους  $i = 1, \dots, n$ , μπορεί να αναλυθεί χρησιμοποιώντας τις ιδιότητες ειδικών πινάκων που σχετίζονται με τον  $\mathcal{G}$ . Ένας τέτοιος πίνακας είναι ο πίνακας Laplace γράφου

$\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{n \times n}$ , ο οποίος ορίζεται για έναν μη κατευθυνόμενο και σταθμισμένο γράφο [40], [41]. Από άποψη στοιχείων ορίζεται ως (βλέπε Σχ. 15)

$$L_{i,i'}^{(\mathcal{G})} := \begin{cases} -A_{i,i'}, & \text{for } i \neq i', \{i, i'\} \in \mathcal{E}; \\ \sum_{i'' \neq i} A_{i,i''}, & \text{for } i = i'; \\ 0, & \text{else.} \end{cases}$$

Εδώ,  $A_{i,i'}$  δηλώνει το βάρος ακμής μίας ακμής  $\{i, i'\} \in \mathcal{E}$ .



(a)

$$\mathbf{L}^{(\mathcal{G})} = \begin{pmatrix} 2 & -1 & -1 \\ -1 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

(b)

Σχ. 15. (a) Κάποιος μη κατευθυνόμενος γράφος  $\mathcal{G}$  με τρεις κόμβους  $i = 1, 2, 3$ .  
(b) Ο πίνακας Laplace  $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{3 \times 3}$  του  $\mathcal{G}$ .

Βλέπε επίσης: graph, πίνακας, βάρος ακμής.

**πίνακας συνδιακύμανσης** Ο πίνακας συνδιακύμανσης (covariance matrix) μίας τυχαίας μεταβλητής  $\mathbf{x} \in \mathbb{R}^d$  ορίζεται ως η προσδοκία (αν υφίσταται):

$$\mathbf{C}^{(\mathbf{x})} := \mathbb{E} \left\{ (\mathbf{x} - \mathbb{E}\{\mathbf{x}\}) (\mathbf{x} - \mathbb{E}\{\mathbf{x}\})^T \right\}.$$

Βλέπε επίσης: συνδιακύμανση, πίνακας, τυχαία μεταβλητή, expectation.

**πίνακας συνδιακύμανσης δείγματος** Θεωρούμε ένα σύνολο δεδομένων που αποτελείται από σημεία δεδομένων που χαρακτηρίζονται από διάνυσματα χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Ο πίνακας συνδιακύμανσης δείγματος (sample covariance matrix) του  $\mathcal{D}$  ορίζεται ως ο πίνακας συνδιακύμανσης αναφορικά με την εμπειρική κατανομή  $\mathbb{P}^{(\mathcal{D})}$  που επάγεται από το  $\mathcal{D}$ . Δίνεται ρητά από

$$\hat{\mathbf{C}} = \frac{1}{m} \sum_{r=1}^m (\mathbf{x}^{(r)} - \hat{\mathbf{m}})(\mathbf{x}^{(r)} - \hat{\mathbf{m}})^T.$$

Εδώ χρησιμοποιούμε τη μέση τιμή δείγματος  $\hat{\boldsymbol{\mu}}$ .

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, sample, πίνακας συνδιακύμανσης, εμπειρική κατανομή, μέση τιμή δείγματος.


**πλήρους τάξης TBC.**

**πολυμεταβλητή κανονική κατανομή TBC.**

**προβεβλημένη κάθοδος κλίσης** Θεωρούμε μία μέθοδο βασισμένη στην εμπειρική ελαχιστοποίηση διακινδύνευσης που χρησιμοποιεί ένα παραμετροποιημένο μοντέλο με παραμετρικό χώρο  $\mathcal{W} \subseteq \mathbb{R}^d$ . Ακόμα και αν η αντικειμενική συνάρτηση εμπειρικής ελαχιστοποίησης διακινδύνευσης είναι λεία, δεν μπορούμε να χρησιμοποιήσουμε τη βασική καθόδο κλίσης, καθώς δεν λαμβάνει υπόψη περιορισμούς στη μεταβλητή βελτιστοποίησης (δηλαδή τις παράμετρους του μοντέλου). Η προβεβλημένη κάθοδος κλίσης (projected gradient descent - projected GD) επεκτείνει τη βασική καθόδο κλίσης για να αντιμετωπίσει αυτό το ζήτημα. Μία μοναδική επα-



νάληψη της προβεβλημένης καθόδου κλίσης περιλαμβάνει πρώτα τη λήψη ενός βήματος κλίσης και στη συνέχεια την προβολή του αποτελέσματος πίσω στον παραμετρικό χώρο. Βλέπε Σχ. 16 για μία οπτική απεικόνιση.



Σχ. 16. Η προβεβλημένη κάθοδος κλίσης επαυξάνει ένα βασικό βήμα κλίσης με μία προβολή πίσω στο σύνολο περιορισμών  $\mathcal{W}$ .

Βλέπε επίσης: εμπειρική ελαχιστοποίηση διακινδύνευσης, μοντέλο, παραμετρικός χώρος, αντικειμενική συνάρτηση, λεία, κάθοδος κλίσης, model parameter, βήμα κλίσης, προβολή.

**πρόβλημα βελτιστοποίησης** Ένα πρόβλημα βελτιστοποίησης (optimization problem) είναι μία μαθηματική δομή που αποτελείται από μία αντικειμενική συνάρτηση  $f : \mathcal{U} \rightarrow \mathcal{V}$  ορισμένη πάνω σε μία μεταβλητή βελτιστοποίησης  $\mathbf{w} \in \mathcal{U}$ , μαζί με ένα εφικτό σύνολο  $\mathcal{W} \subseteq \mathcal{U}$ . Το πεδίο τιμών  $\mathcal{V}$  θεωρείται ότι είναι διατεταγμένο, που σημαίνει ότι για οποιαδήποτε δύο στοιχεία  $\mathbf{a}, \mathbf{b} \in \mathcal{V}$ , μπορούμε να καθορίσουμε αν  $\mathbf{a} < \mathbf{b}$ ,  $\mathbf{a} = \mathbf{b}$ , ή  $\mathbf{a} > \mathbf{b}$ . Ο στόχος της βελτιστοποίησης είναι να βρούμε εκείνες τις τιμές  $\mathbf{w} \in \mathcal{W}$  για τις οποίες η αντικειμενική  $f(\mathbf{w})$  είναι ακρότατη—δηλαδή ελάχιστη ή μέγιστη [31], [22], [32].

Βλέπε επίσης: αντικειμενική συνάρτηση.

**προβολή** Θεωρούμε ένα υποσύνολο  $\mathcal{W} \subseteq \mathbb{R}^d$  του  $d$ -διάστατου Ευκλείδειου χώρου. Ορίζουμε την προβολή  $P_{\mathcal{W}}(\mathbf{w})$  ενός διανύσματος  $\mathbf{w} \in \mathbb{R}^d$  στο  $\mathcal{W}$  ως

$$P_{\mathcal{W}}(\mathbf{w}) = \arg \min_{\mathbf{w}' \in \mathcal{W}} \|\mathbf{w} - \mathbf{w}'\|_2.$$

Με άλλα λόγια, η  $P_{\mathcal{W}}(\mathbf{w})$  είναι το διάνυσμα στο  $\mathcal{W}$  που είναι πιο κοντά στο  $\mathbf{w}$ . Η προβολή είναι καλά ορισμένη μόνο για υποσύνολα  $\mathcal{W}$  για τα οποία υφίσταται το παραπάνω ελάχιστο [22].

Βλέπε επίσης: Ευκλείδειος χώρος, διάνυσμα, ελάχιστο.

**προεικόνα** Θεωρούμε μία συνάρτηση  $f: \mathcal{U} \rightarrow \mathcal{V}$  μεταξύ δύο συνόλων. Η προεικόνα  $f^{-1}(\mathcal{B})$  ενός υποσυνόλου  $\mathcal{B} \subseteq \mathcal{V}$  είναι το σύνολο όλων των εισόδων  $u \in \mathcal{U}$  που αντιστοιχούνται στο  $\mathcal{B}$  από την  $f$ , δηλαδή

$$f^{-1}(\mathcal{B}) := \{u \in \mathcal{U} \mid f(u) \in \mathcal{B}\}.$$

Η προεικόνα είναι καλά ορισμένη ακόμα και αν η συνάρτηση  $f$  είναι μη αντιστρέψιμη [2].

Βλέπε επίσης: συνάρτηση.

**προσδοκία υπό συνθήκη** TBC.

**προσεγγίσιμος** Μία κυρτή συνάρτηση για την οποία ο τελεστής εγγύτητας μπορεί να υπολογιστεί αποτελεσματικά αναφέρεται μερικές φορές ως προσεγγίσιμη ή απλή [42].

Βλέπε επίσης: κυρτό, συνάρτηση, τελεστής εγγύτητας.

**$\sigma$ -άλγεβρα** TBC.

**σταθερό σημείο** TBC.

**στοχαστική** Αναφερόμαστε σε μία μέθοδο ως στοχαστική αν περιλαμβάνει μία τυχαία συνιστώσα ή διέπεται από πιθανοτικούς νόμους. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν τυχειότητα για να μειώσουν την υπολογιστική πολυπλοκότητα (π.χ. βλέπε στοχαστική κάθοδος κλίσης) ή για να αποτυπώσουν την αβεβαιότητα σε πιθανοτικά μοντέλα. Βλέπε επίσης: μηχανική μάθηση, στοχαστική κάθοδος κλίσης, αβεβαιότητα, πιθανοτικό μοντέλο.

**στοχαστική διαδικασία** Μία στοχαστική διαδικασία είναι μία συλλογή τυχαίων μεταβλητών που ορίζονται πάνω σε έναν κοινό χώρο πιθανοτήτων και που έχουν δείκτες από κάποιο σύνολο  $\mathcal{I}$  [43], [27], [36]. Το σύνολο δεικτών  $\mathcal{I}$  συνήθως αναπαριστά χρόνο και χώρο, επιτρέποντάς μας να αναπαραστήσουμε τυχαία φαινόμενα που εξελίσσονται στον χρόνο ή σε χωρικές διαστάσεις—για παράδειγμα, θόρυβο αισθητήρα ή οικονομικές χρονοσειρές. Οι στοχαστικές διαδικασίες δεν περιορίζονται σε χρονικά ή χωρικά περιβάλλοντα. Για παράδειγμα, τυχαίοι γράφοι όπως ο γράφος Erdős–Rényi ή το μοντέλο στοχαστικής ομάδας μπορούν επίσης να θεωρηθούν στοχαστικές διαδικασίες. Εδώ, το σύνολο δεικτών  $\mathcal{I}$  αποτελείται από ζεύγη κόμβων που ευρετηριάζουν τυχαίες μεταβλητές των οποίων οι τιμές κωδικοποιούν την παρουσία ή το βάρος μίας ακμής μεταξύ δύο κόμβων. Επιπλέον, οι στοχαστικές διαδικασίες προκύπτουν φυσικά στην ανάλυση στοχαστικών αλγόριθμων, όπως της στοχαστικής καθόδου κλίσης, οι οποίοι κατασκευάζουν μία ακολουθία τυχαίων μεταβλητών. Βλέπε επίσης: στοχαστική, τυχαία μεταβλητή, χώρος πιθανοτήτων, graph,

γράφος Erdős–Rényi, μοντέλο στοχαστικής ομάδας, στοχαστικός αλγόριθμος, στοχαστική κάθοδος κλίσης, αβεβαιότητα, πιθανοτικό μοντέλο.


**σύγκλιση** Θεωρούμε μία ακολουθία  $(a_r)_{r \in \mathbb{N}}$  με αριθμητικές τιμές  $a_r \in \mathbb{R}$ .

Λέμε ότι αυτή η ακολουθία συγκλίνει σε μία τιμή  $a^*$  αν οι τιμές  $a_r$  γίνονται αυθαίρετα κοντινές στην  $a^*$  για επαρκώς μεγάλους δείκτες  $r$ . Από μαθηματική άποψη, η ακολουθία συγκλίνει στην  $a^*$  αν [1], [2]

$$\forall \epsilon > 0, \exists N \in \mathbb{N} : r > N \Rightarrow |a_r - a^*| < \epsilon.$$

Δηλώνουμε τη σύγκλιση (convergence) μίας ακολουθίας στην  $a^*$  με

$$\lim_{r \rightarrow \infty} a_r = a^*.$$



Σχ. 17. Μία ακολουθία πραγματικής τιμής  $(a_r)_{r \in \mathbb{N}}$  που συγκλίνει στο όριο  $a^* = 1$ .

Η έννοια της σύγκλισης μίας ακολουθίας πραγματικής τιμής (όπου  $\mathcal{A} = \mathbb{R}$ ) επεκτείνεται φυσικά σε μία ακολουθία σε έναν αυθαίρετο μετρικό χώρο  $\mathcal{A}$ . Πράγματι, χρειάζεται απλώς να αντικαταστήσουμε την απόλυτη δια-

φορά  $|a_r - a^*|$  με τη μετρική  $d(a_r, a^*)$ . Σημείωση ότι μία ακολουθία μπορεί να συγκλίνει μόνο αν είναι μία ακολουθία Cauchy [2]. Ωστόσο, δε συγκλίνει κάθε ακολουθία Cauchy, εκτός αν ο υποκείμενος μετρικός χώρος είναι πλήρης.


Βλέπε επίσης: ακολουθία, μετρικός χώρος, μετρική, ακολουθία Cauchy.

**συμμετρικός πίνακας** TBC.

**συνάρτηση** Μία συνάρτηση (function) μεταξύ δύο συνόλων  $\mathcal{U}$  και  $\mathcal{V}$  αποδίδει σε κάθε στοιχείο  $u \in \mathcal{U}$  ακριβώς ένα στοιχείο  $f(u) \in \mathcal{V}$  [2]. Το γράφουμε αυτό ως

$$f : \mathcal{U} \rightarrow \mathcal{V} : u \mapsto f(u),$$

όπου  $\mathcal{U}$  είναι το πεδίο και  $\mathcal{V}$  το πεδίο τιμών της  $f$ . Για την ακρίβεια, η συνάρτηση  $f$  ορίζει μία μοναδική έξοδο  $f(u) \in \mathcal{V}$  για κάθε είσοδο  $u \in \mathcal{U}$  (βλέπε Σχ. 18).



Σχ. 18. Μία συνάρτηση  $f: \mathcal{U} \rightarrow \mathcal{V}$  που αντιστοιχίζει κάθε στοιχείο του πεδίου  $\mathcal{U} = \{a, b, c\}$  σε ακριβώς ένα στοιχείο του πεδίου τιμών  $\mathcal{V} = \{\star, \circ, \otimes\}$ .

Βλέπε επίσης: domain, co-domain, έξοδος.

**συνάρτηση μάζας πιθανότητας** TBC.

**συνάρτηση πυκνότητας πιθανότητας** Η συνάρτηση πυκνότητας πιθανότητας (probability density function - pdf)  $p^{(x)}(\cdot)$  μίας συνεχούς τυχαίας μεταβλητής πραγματικής τιμής  $x \in \mathbb{R}$  μας επιτρέπει να υπολογίσουμε την πιθανότητα  $\mathbb{P}(x \in \mathcal{B})$  (του γεγονότος  $\mathcal{B} \subseteq \mathbb{R}$ ) μέσω ενός ολοκληρώματος Lebesgue ως εξής [7, Κεφ. 3]:


$$\mathbb{P}(x \in \mathcal{B}) = \int_{\mathcal{B}} p^{(x)}(\eta) d\eta.$$

Αυτός ο ορισμός επεκτείνεται φυσικά σε μία (συνεχή) τυχαία μεταβλητή διανυσματικής τιμής  $\mathbf{x} \in \mathbb{R}^d$ , καθώς το ολοκλήρωμα Lebesgue ορίζεται για τον  $\mathbb{R}^d$  με οποιαδήποτε διάσταση  $d$ .

Βλέπε επίσης: συνεχής, τυχαία μεταβλητή, πιθανότητα, γεγονός, ολοκλήρωμα Lebesgue, διάνυσμα, διάσταση, κατανομή πιθανότητας, μετρήσιμο.

**συνδιακύμανση** TBC.

**συνεκτικός** Ένας μη κατευθυνόμενος γράφος  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  είναι συνεκτικός αν, για κάθε μη κενό υποσύνολο  $\mathcal{V}' \subset \mathcal{V}$ , μπορούμε να βρούμε τουλάχιστον μία ακμή που συνδέει έναν κόμβο στο  $\mathcal{V}'$  με κάποιον κόμβο στο  $\mathcal{V} \setminus \mathcal{V}'$ . Παρουσιάζουμε δύο παραδείγματα μη κατευθυνόμενων γράφων στο Σχ. 19.



Σχ. 19. (a) Ένας γράφος που είναι μη συνεκτικός. (b) Ένας γράφος που είναι συνεκτικός.


Βλέπε επίσης: μη κατευθυνόμενος γράφος, graph, αλγεβρική συνεκτικότητα.

**συνεχής** TBC.

**συστολικός τελεστής** Ένας τελεστής  $\mathcal{F} : \mathcal{V} \rightarrow \mathcal{V}$  σε έναν χώρο με νόρμα  $(\mathcal{V}, \|\cdot\|)$  λέγεται συστολή (ή συστολικός (contractive operator)) αν, για κάποιον  $\kappa \in [0, 1)$ , [44], [45]

$$\|\mathcal{F}\mathbf{w} - \mathcal{F}\mathbf{w}'\| \leq \kappa \|\mathbf{w} - \mathbf{w}'\| \quad \text{ισχύει για κάθε } \mathbf{w}, \mathbf{w}' \in \mathcal{V}.$$

Η έννοια του συστολικού τελεστή γενικεύει φυσικά από χώρους με νόρμα σε αυθαίρετους μετρικούς χώρους [44].



Σχ. 20. Ένας συστολικός τελεστής  $\mathcal{F} : \mathcal{X} \rightarrow \mathcal{X}$  έχει ένα μοναδικό σταθερό σημείο  $\mathbf{x}^*$  με  $\mathcal{F}\mathbf{x}^* = \mathbf{x}^*$ . Για οποιαδήποτε δύο σημεία  $\mathbf{x}, \mathbf{x}'$  στον ίδιο χώρο, η απόσταση μεταξύ των εικόνων τους  $\mathcal{F}\mathbf{x}$  και  $\mathcal{F}\mathbf{x}'$  είναι αυστηρά μικρότερη.

Ενστικτωδώς, ένας συστολικός τελεστής φέρνει οποιαδήποτε δύο σημεία από το πεδίο του πιο κοντά μεταξύ τους τουλάχιστον κατά έναν παράγοντα  $\kappa$ .

Βλέπε επίσης: τελεστής, μετρικός χώρος, σταθερό σημείο, domain.

**τάξη** TBC.

**τελεστής** Ένας τελεστής (operator) είναι μία συνάρτηση της οποίας το πεδίο και το πεδίο τιμών διαθέτουν μία συγκεκριμένη μαθηματική δομή, όπως έναν διανυσματικό χώρο, έναν χώρο Hilbert, ή έναν μετρικό χώρο [46], [47]. Πολλές μέθοδοι μηχανικής μάθησης περιλαμβάνουν τελεστές των οποίων το πεδίο και το πεδίο τιμών είναι Ευκλείδειοι χώροι.

Βλέπε επίσης: συνάρτηση, domain, co-domain, διανυσματικός χώρος, χώρος Hilbert, μετρικός χώρος, μηχανική μάθηση, Ευκλείδειος χώρος.


**τελεστής εγγύτητας** Δεδομένης μίας κυρτής συνάρτησης  $f(\mathbf{w}')$ , ορίζουμε



τον τελεστή εγγύτητάς της ως [45], [46]

$$\mathbf{prox}_{f(\cdot),\rho}(\mathbf{w}) := \arg \min_{\mathbf{w}' \in \mathbb{R}^d} \left[ f(\mathbf{w}') + \frac{\rho}{2} \|\mathbf{w} - \mathbf{w}'\|_2^2 \right] \text{ με } \rho > 0.$$

Όπως απεικονίζεται στο Σχ. 21, η αξιολόγηση του τελεστή εγγύτητας ισοδυναμεί με την ελαχιστοποίηση μίας παραλλαγής της  $f(\mathbf{w}')$  που έχει επιβληθεί ως ποινή. Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια απόσταση σε ένα δεδομένο διάνυσμα  $\mathbf{w}$  (το οποίο είναι η είσοδος στον τελεστή εγγύτητας). Ο τελεστής εγγύτητας μπορεί να ερμηνευτεί ως μία γενίκευση του βήματος κλίσης, το οποίο ορίζεται ως μία λεία κυρτή συνάρτηση  $f(\mathbf{w}')$ . Πράγματι, η εκτέλεση ενός βήματος κλίσης με μέγεθος βήματος  $\eta$  στο τρέχον διάνυσμα  $\mathbf{w}$  είναι το ίδιο με την εφαρμογή του τελεστή εγγύτητας της συνάρτησης  $\tilde{f}(\mathbf{w}') = (\nabla f(\mathbf{w}))^T (\mathbf{w}' - \mathbf{w})$  και τη χρήση  $\rho = 1/\eta$ .



Σχ. 21. Ο τελεστής εγγύτητας ενημερώνει ένα διάνυσμα  $\mathbf{w}$  ελαχιστοποιώντας μία εκδοχή της συνάρτησης  $f(\cdot)$  που έχει επιβληθεί ως ποινή. Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια απόσταση μεταξύ της μεταβλητής βελτιστοποίησης  $\mathbf{w}'$  και του δεδομένου διανύσματος  $\mathbf{w}$ .

Βλέπε επίσης: κυρτό, συνάρτηση, διάνυσμα, γενίκευση, βήμα κλίσης, λεία, μέγεθος βήματος.

**τυχαία μεταβλητή** Μία τυχαία μεταβλητή (random variable - RV) είναι μία συνάρτηση που αντιστοιχίζει τα εκβάσεις ενός τυχαίου πειράματος σε στοιχεία ενός μετρήσιμου χώρου [6], [27]. Από μαθηματική άποψη, μία τυχαία μεταβλητή είναι μία συνάρτηση  $x : \Omega \rightarrow \mathcal{X}$  της οποίας το πεδίο είναι ο δειγματικός χώρος  $\Omega$  ενός χώρου πιθανοτήτων και της οποίας το πεδίο τιμών είναι ένας μετρήσιμο χώρος  $\mathcal{X}$ . Διαφορετικοί τύποι τυχαίων μεταβλητών περιλαμβάνουν


- δυαδικές τυχαίες μεταβλητές, οι οποίες αντιστοιχίζουν κάθε έκβαση σε ένα στοιχείο ενός δυαδικού συνόλου (π.χ.  $\{-1, 1\}$  ή  $\{\text{γάτα}, \text{όχι γάτα}\}$ ).
- διακριτές τυχαίες μεταβλητές, οι οποίες παίρνουν τιμές σε ένα αριθμήσιμο σύνολο (το οποίο μπορεί να είναι πεπερασμένο ή αριθμήσιμα άπειρο).
- τυχαίες μεταβλητές πραγματικής τιμής, οι οποίες παίρνουν τιμές στους πραγματικούς αριθμούς  $\mathbb{R}$ .
- τυχαίες μεταβλητές διανυσματικής τιμής, οι οποίες αντιστοιχίζουν εκβάσεις στον Ευκλείδειο χώρο  $\mathbb{R}^d$ .

Η θεωρία πιθανοτήτων χρησιμοποιεί την έννοια των μετρήσιμων χώρων για να ορίσει ενδελεχώς και να μελετήσει τις ιδιότητες συλλογών τυχαίων μεταβλητών [6].

Βλέπε επίσης: συνάρτηση, έκβαση, τυχαίο πείραμα, μετρήσιμο, domain,

δειγματικός χώρος, χώρος πιθανοτήτων, co-domain, discrete RV, αριθμίσμο, διάνυσμα, Ευκλείδειος χώρος, πιθανότητα.

**τυχαίο πείραμα** Ένα τυχαίο πείραμα είναι μία φυσική (ή αφηρημένη) διαδικασία που παράγει ένα αποτέλεσμα  $\omega$  από ένα σύνολο πιθανοτήτων  $\Omega$ . Αυτό το σύνολο όλων των πιθανών αποτελεσμάτων αναφέρεται ως ο δειγματικός χώρος του πειράματος. Το βασικότερο χαρακτηριστικό ενός τυχαίου πειράματος είναι ότι το αποτέλεσμά του είναι απρόβλεπτο (ή αβέβαιο). Οποιαδήποτε μέτρηση ή παρατήρηση του αποτελέσματος είναι μία τυχαία μεταβλητή, δηλαδή μία συνάρτηση του αποτελέσματος  $\omega \in \Omega$ . Η θεωρία πιθανοτήτων χρησιμοποιεί έναν χώρο πιθανοτήτων ως μία μαθηματική δομή για τη μελέτη τυχαίων πειραμάτων. Μία κύρια εννοιολογική ιδιότητα ενός τυχαίου πειράματος είναι ότι μπορεί να επαναληφθεί υπό ταυτόσημες συνθήκες. Αυστηρά μιλώντας, η επανάληψη ενός τυχαίου πειράματος έναν δεδομένο αριθμό  $m$  φορές ορίζει ένα νέο τυχαίο πείραμα. Τα αποτελέσματα αυτού του νέου πειράματος είναι ακολουθίες μήκους  $m$  αποτελεσμάτων από το αρχικό πείραμα (βλέπε Σχ. 22). Ενώ το αποτέλεσμα ενός μοναδικού πειράματος είναι αβέβαιο, η μακροπρόθεσμη συμπεριφορά των αποτελεσμάτων επαναλαμβανόμενων πειραμάτων τείνει να γίνεται ολοένα και περισσότερο προβλέψιμη. Αυτός ο ανεπίσημος ισχυρισμός μπορεί να γίνει ακριβής μέσω θεμελιωδών αποτελεσμάτων της θεωρίας πιθανοτήτων, όπως ο νόμος των μεγάλων αριθμών και το κεντρικό οριακό θεώρημα.



Σχ. 22. Ένα τυχαίο πείραμα παράγει ένα αποτέλεσμα  $\omega \in \Omega$  από ένα σύνολο πιθανοτήτων (ή δειγματικό χώρο)  $\Omega$ . Η επανάληψη του πειράματος  $m$  φορές αποφέρει ένα άλλο τυχαίο πείραμα, του οποίου τα αποτελέσματα είναι ακολουθίες  $(\omega^{(1)}, \omega^{(2)}, \dots, \omega^{(m)}) \in \Omega \times \dots \times \Omega$ . Ένα παράδειγμα τυχαίου πειράματος που προκύπτει σε πολλές εφαρμογές μηχανικής μάθησης είναι η συγκέντρωση ενός συνόλου εκπαίδευσης  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ .

Παραδείγματα τυχαίων πειραμάτων που προκύπτουν σε εφαρμογές μηχανικής μάθησης περιλαμβάνουν τα εξής:

- Συλλογή δεδομένων: Τα σημεία δεδομένων που συλλέγονται σε μεθόδους βασισμένες στην εμπειρική ελαχιστοποίηση διακινδύνευσης μπορούν να ερμηνευτούν ως τυχαίες μεταβλητές, δηλαδή ως συναρτήσεις του αποτελέσματος  $\omega \in \Omega$  ενός τυχαίου πειράματος.
- Η στοχαστική κάθοδος κλίσης χρησιμοποιεί ένα τυχαίο πείραμα σε κάθε επανάληψη για την επιλογή ενός υποσυνόλου του συνόλου εκπαίδευσης.

- Οι μέθοδοι προστάσιας της ιδιωτικότητας χρησιμοποιούν τυχαία πειράματα για να παραγάγουν θόρυβο που προστίθεται στις εξόδους μίας μεθόδου μηχανικής μάθησης για να εξασφαλιστεί η διαφορική ιδιωτικότητα.

Βλέπε επίσης: δειγματικός χώρος, τυχαία μεταβλητή, συνάρτηση, πιθανότητα, χώρος πιθανοτήτων, νόμος των μεγάλων αριθμών, κεντρικό οριακό θεώρημα, δειγματικός χώρος, μηχανική μάθηση, σύνολο εκπαίδευσης, δεδομένα, σημείο δεδομένων, εμπειρική ελαχιστοποίηση διακινδύνευσης, στοχαστική κάθοδος κλίσης, προστάσια της ιδιωτικότητας, διαφορική ιδιωτικότητα.

**υπερεπίπεδο** TBC.

**υποκλίση** Για μία συνάρτηση πραγματικής τιμής  $f : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{w} \mapsto f(\mathbf{w})$ , ένα διάνυσμα  $\mathbf{a}$  τέτοιο ώστε  $f(\mathbf{w}) \geq f(\mathbf{w}') + (\mathbf{w} - \mathbf{w}')^T \mathbf{a}$  αναφέρεται ως μία υποκλίση (subgradient) της  $f$  στο  $\mathbf{w}'$  [48], [31].

Βλέπε επίσης: συνάρτηση, διάνυσμα.

**υποχώρος** TBC.

**φασματική ανάλυση** Μία ανάλυση ιδιοτιμών ενός κανονικού πίνακα ονομάζεται φασματική ανάλυση (spectral decomposition). Έχει την ιδιαίτερη ιδιότητα ότι τα ιδιοδιανύσματα του κανονικού πίνακα είναι ορθοκανονικά. Αυτό ισχύει και αντίστροφα, δηλαδή οποιοσδήποτε πίνακας που έχει ορθοκανονικά ιδιοδιανύσματα είναι ένας κανονικός πίνακας.

Βλέπε επίσης: ανάλυση ιδιοτιμών, κανονικός πίνακας, ιδιοδιάνυσμα, πίνακας.

**φράγμα Chernoff** TBC.

**χαρακτηριστική συνάρτηση** Η χαρακτηριστική συνάρτηση μίας τυχαίας μεταβλητής πραγματικής τιμής  $x$  είναι η συνάρτηση [6, Ενότητα 26]

$$\phi_x(t) := \mathbb{E} \exp(jtx) \text{ με } j = \sqrt{-1}.$$

Η χαρακτηριστική συνάρτηση προσδιορίζει μοναδικά την κατανομή πιθανότητας της  $x$ .

Βλέπε επίσης: συνάρτηση, τυχαία μεταβλητή, κατανομή πιθανότητας.

**χώρος καταστάσεων** Ο χώρος καταστάσεων (state space) ενός συστήματος αποτελείται από όλες τις πιθανές καταστάσεις του συστήματος σε οποιαδήποτε χρονική στιγμή.

Βλέπε επίσης: κατάσταση, διάνυσμα χαρακτηριστικών, υπόθεση, ενέργεια.

**χώρος με νόρμα** A normed space is a διανυσματικός χώρος  $\mathcal{V}$  equipped with a νόρμα  $\|\cdot\|$ . Formally, it is denoted as the pair  $(\mathcal{V}, \|\cdot\|)$ . Every normed space is a μετρικός χώρος with the induced μετρική defined by  $d(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\|$  for all  $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$ . In μηχανική μάθηση, normed spaces are a common framework for χώρος χαρακτηριστικών and παραμετρικός χώρος, most typically the Ευκλείδειος χώρος  $\mathbb{R}^d$  with the Ευκλείδεια νόρμα.

See also: νόρμα, διανυσματικός χώρος, μετρικός χώρος, Ευκλείδειος χώρος, χώρος Hilbert.

**χώρος μέτρου** Ένας χώρος μέτρου (measure space) είναι μία τριάδα  $(\Omega, \Sigma, \mu)$

που αποτελείται από ένα σύνολο  $\Omega$ , μία  $\sigma$ -άλγεβρα  $\Sigma$  υποσυνόλων του  $\Omega$ , και ένα μέτρο  $\mu : \Sigma \rightarrow [0, \infty)$ . Το μέτρο  $\mu$  αποδίδει έναν μη αρνητικό αριθμό σε κάθε μετρήσιμο σύνολο  $A \in \Sigma$ , γενικεύοντας τις έννοιες του μήκους, του εμβαδού, ή του όγκου σε Ευκλείδειους χώρους [2], [49]. Οι χώροι μέτρου παρέχουν τη μαθηματική θεμελίωση για το ολοκλήρωμα Lebesgue ή για τον ορισμό τυχαίων μεταβλητών ως μετρήσιμων αντιστοιχίσεων μεταξύ χώρων μέτρου. Ένας χώρος πιθανοτήτων είναι μία ειδική περίπτωση χώρου μέτρου όπου το συνολικό μέτρο του δειγματικού χώρου κανονικοποιείται στη μονάδα, δηλαδή  $\mu(\Omega) = 1$ . Σε αυτή την περίπτωση, το  $\mu$  λέγεται κατανομή πιθανότητας.

Βλέπε επίσης: μέτρο,  $\sigma$ -άλγεβρα, μετρήσιμο, Ευκλείδειος χώρος, ολοκλήρωμα Lebesgue, τυχαία μεταβλητή, χώρος πιθανοτήτων, δειγματικός χώρος, κατανομή πιθανότητας.

**χώρος πιθανοτήτων** Ένας χώρος πιθανοτήτων είναι μία μαθηματική δομή που μας επιτρέπει να συλλογιστούμε για ένα τυχαίο πείραμα, π.χ. την παρατήρηση ενός φυσικού φαινομένου. Τυπικά, ένας χώρος πιθανοτήτων  $\mathcal{P}$  είναι μία τριάδα  $(\Omega, \mathcal{F}, \mathbb{P}(\cdot))$ , όπου

- $\Omega$  είναι ένας δειγματικός χώρος που περιλαμβάνει όλα τα πιθανά αποτελέσματα ενός τυχαίου πειράματος.
- $\mathcal{F}$  είναι μία  $\sigma$ -άλγεβρα, δηλαδή μία συλλογή υποσυνόλων του  $\Omega$  (που ονομάζονται γεγονότα) που ικανοποιεί ορισμένες ιδιότητες κλειστότητας υπό ένα σύνολο πράξεων.
- $\mathbb{P}(\cdot)$  είναι μία κατανομή πιθανότητας, δηλαδή μία συνάρτηση που αποδίδει μία πιθανότητα  $P(A) \in [0, 1]$  σε κάθε γεγονός  $A \in \mathcal{F}$ .

Αυτή η συνάρτηση πρέπει να ικανοποιεί  $\mathbb{P}(\Omega) = 1$  και  $\mathbb{P}(\bigcup_{i=1}^{\infty} \mathcal{A}_i) = \sum_{i=1}^{\infty} \mathbb{P}(\mathcal{A}_i)$  για οποιαδήποτε μετρήσιμη ακολουθία κατά ζεύγη ξένων γεγονότων  $\mathcal{A}_1, \mathcal{A}_2, \dots$  στο  $\mathcal{F}$ .

Οι χώροι πιθανοτήτων παρέχουν τη θεμελίωση των πιθανοτικών μοντέλων που μπορούν να χρησιμοποιηθούν για να μελετηθεί η συμπεριφορά των μεθόδων μηχανικής μάθησης [6], [27], [50].

Βλέπε επίσης: πιθανότητα, τυχαίο πείραμα, δειγματικός χώρος, γεγονός, κατανομή πιθανότητας, συνάρτηση, πιθανοτικό μοντέλο, μηχανική μάθηση.

**χώρος στηλών** Ο χώρος στηλών (column space) ενός πίνακα  $\mathbf{A} \in \mathbb{R}^{m \times d}$ , που δηλώνεται με  $\text{span}(\mathbf{A})$ , είναι το σύνολο όλων των γραμμικών συνδυασμών των στηλών του  $\mathbf{A}$ . Με άλλα λόγια,

$$\text{span}(\mathbf{A}) = \{\mathbf{A}\mathbf{w} : \mathbf{w} \in \mathbb{R}^d\}.$$


Ο χώρος στηλών  $\text{span}(\mathbf{A})$  του πίνακα  $\mathbf{A}$  είναι ένας υποχώρος του Ευκλείδειου χώρου  $\mathbb{R}^m$ .

Βλέπε επίσης: πίνακας, υποχώρος, Ευκλείδειος χώρος, διανυσματικός χώρος.

**χώρος Hilbert** Ένας χώρος Hilbert (Hilbert space)  $\mathcal{H}$  είναι ένας πλήρης χώρος με εσωτερικό γινόμενο. Συνεπώς, ο  $\mathcal{H}$  είναι ένας διανυσματικός χώρος εξοπλισμένος με ένα εσωτερικό γινόμενο  $\langle \cdot, \cdot \rangle$ . Το εσωτερικό γινόμενο επάγει μία νόρμα  $\|\cdot\|_2$  μέσω  $\|\mathbf{w}\|_2 = \sqrt{\langle \mathbf{w}, \mathbf{w} \rangle}$ . Επιπλέον, ο  $\mathcal{H}$  είναι πλήρης, με την έννοια ότι κάθε ακολουθία Cauchy  $(\mathbf{w}^{(r)})_{r \in \mathbb{N}}$  στον



$\mathcal{H}$  συγχλίνει σε ένα όριο  $\lim_{r \rightarrow \infty} \mathbf{w}^{(r)}$  που επίσης περιέχεται στον  $\mathcal{H}$ .



Σχ. 23. Για δύο διανύσματα μοναδιαίας νόρμας  $\mathbf{u}, \mathbf{v} \in \mathbb{S}^{(d)} \subseteq \mathbb{R}^d$ , το εσωτερικό γινόμενο  $\langle \mathbf{u}, \mathbf{v} \rangle$  είναι ο συντελεστής αναπτύγματος για την προβολή του  $\mathbf{v}$  στον υποχώρο  $\{c\mathbf{u} : c \in \mathbb{R}\}$  που παράγεται από το  $\mathbf{u}$ . Η απόλυτη τιμή  $|\langle \mathbf{u}, \mathbf{v} \rangle|$  μετράει τη νόρμα αυτής της προβολής.

Ένα σημαντικό παράδειγμα χώρου Hilbert είναι ο Ευκλείδειος χώρος  $\mathbb{R}^d$  με το εσωτερικό γινόμενο  $\langle \mathbf{w}, \mathbf{w}' \rangle = \mathbf{w}^\top \mathbf{w}'$ .

Βλέπε επίσης: εσωτερικό γινόμενο, διανυσματικός χώρος, νόρμα, ακολουθία Cauchy, διάνυσμα, προβολή, υποχώρος, Ευκλείδειος χώρος.

**ψευδοαντίστροφος** Ο ψευδοαντίστροφος (pseudoinverse) Moore–Penrose

$\mathbf{A}^+$  ενός πίνακα  $\mathbf{X} \in \mathbb{R}^{m \times d}$  γενικεύει την έννοια ενός αντίστροφου πίνακα [3]. Ο ψευδοαντίστροφος ανακύπτει φυσικά στην αμφικλινή παλινδρόμηση για ένα σύνολο δεδομένων με πίνακα χαρακτηριστικών  $\mathbf{X}$  και διάνυσμα ετικετών  $\mathbf{y}$  [51, Κεφ. 3]. Οι παράμετροι μοντέλου που μαθαίνονται μέσω της αμφικλινούς παλινδρόμησης δίνονται από

$$\hat{\mathbf{w}}^{(\alpha)} = (\mathbf{X}^\top \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \alpha > 0.$$

Μπορούμε τότε να ορίσουμε τον ψευδοαντίστροφο  $\mathbf{X}^+ \in \mathbb{R}^{d \times m}$  μέσω του ορίου [52, Κεφ. 3]:

$$\lim_{\alpha \rightarrow 0^+} \widehat{\mathbf{w}}^{(\alpha)} = \mathbf{X}^+ \mathbf{y}.$$

Βλέπε επίσης: πίνακας, αντίστροφος πίνακας, αμφικλινής παλινδρόμηση, σύνολο δεδομένων, πίνακας χαρακτηριστικών, διάνυσμα ετικετών, model parameters.

**conjugate transpose** TBC.

**Courant–Fischer–Weyl min–max characterization** TBC.

**dual norm** Every νόρμα  $\|\cdot\|$  defined on a Ευκλείδειος χώρος  $\mathbb{R}^d$  has an associated dual νόρμα, which is denoted by  $\|\cdot\|_*$  and defined as  $\|\mathbf{y}\|_* := \sup_{\|\mathbf{x}\| \leq 1} \mathbf{y}^T \mathbf{x}$ . The dual νόρμα measures the largest possible εσωτερικό γινόμενο between  $\mathbf{y}$  and any διάνυσμα in the unit ball of the original νόρμα. For further details, see [22, Sec. A.1.6].

See also: νόρμα, Ευκλείδειος χώρος, διάνυσμα.

**expectation–maximization (EM)** TBC.

**Lagrangian** TBC.

**Markov chain** TBC.

**moment generating function (MGF)** TBC.

**Newton's method** TBC.

**nullspace** TBC.

**probabilistic principal component analysis (PPCA)** PPCA extends basic ανάλυση κύριων συνιστωσών by using a πιθανοτικό μοντέλο for σημείο δεδομένων. Using a πιθανοτικό μοντέλο allows us to cast μείωση της διαστασιμότητας as an estimation problem that can be solved using expectation–maximization (EM) [53].

See also: ανάλυση κύριων συνιστωσών, πιθανοτικό μοντέλο, μείωση της διαστασιμότητας, EM.

**probability simplex** TBC.

**$\sigma$ -field** See  $\sigma$ -άλγεβρα.

**standard normal random vector** A standard normal random διάνυσμα is an τυχαία μεταβλητή  $\mathbf{x} = (x_1, \dots, x_d)^T$  whose entries are ανεξάρτητες και ταυτόσημα κατανεμημένες Γκαουσιανή τυχαία μεταβλητής  $x_j \sim \mathcal{N}(0, 1)$ . The κατανομή πιθανότητας of a standard normal random διάνυσμα is a special case of a πολυμεταβλητή κανονική κατανομή  $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ .

See also: διάνυσμα, ανεξάρτητες και ταυτόσημα κατανεμημένες, Γκαουσιανή τυχαία μεταβλητή, πολυμεταβλητή κανονική κατανομή, τυχαία μεταβλητή.

**strongly convex** TBC.

**tall matrix** TBC.


## Έννοιες Μηχανικής Μάθησης

**αβεβαιότητα** Στο πλαίσιο της μηχανικής μάθησης, η αβεβαιότητα (uncertainty) αναφέρεται στην παρουσία πολλαπλών εύλογων εκβάσεων ή εξηγήσεων με βάση τα διαθέσιμα δεδομένα. Για παράδειγμα, η πρόβλεψη  $\hat{h}(\mathbf{x})$  που παράγεται από ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης  $\hat{h}$  συχνά αντανακλά ένα πεδίο πιθανών τιμών για την αληθή ετικέτα ενός συγκεκριμένου σημείου δεδομένων. Όσο πιο ευρύ το πεδίο, τόσο μεγαλύτερη η σχετική αβεβαιότητα. Η θεωρία πιθανοτήτων μας επιτρέπει να αναπαριστούμε, να ποσοτικοποιούμε, και να συλλογίζομαστε για την αβεβαιότητα με έναν μαθηματικά ενδεδειγμένο τρόπο.

Βλέπε επίσης: μηχανική μάθηση, έκβαση, εξήγηση, data, πρόβλεψη, μοντέλο, ετικέτα, σημείο δεδομένων, πιθανότητα, πιθανοτικό μοντέλο, διακινδύνευση, εντροπία, διακύμανση.

**αισιοδοξία παρά την αβεβαιότητα** Οι μέθοδοι μηχανικής μάθησης μαθαίνουν τις παράμετρους μοντέλου  $\mathbf{w}$  σύμφωνα με κάποιο κριτήριο επίδοσης  $\bar{f}(\mathbf{w})$ . Ωστόσο, δεν μπορούν συνήθως να έχουν άμεση πρόσβαση στο  $\bar{f}(\mathbf{w})$ , αλλά βασίζονται σε μία εκτίμηση (ή προσέγγιση)  $f(\mathbf{w})$  του  $\bar{f}(\mathbf{w})$ . Ως ένα χαρακτηριστικό παράδειγμα, οι μέθοδοι βασιμμένες στην εμπειρική ελαχιστοποίηση διακινδύνευσης χρησιμοποιούν τη μέση απώλεια σε ένα συγκεκριμένο σύνολο δεδομένων (δηλαδή το σύνολο εκπαίδευσης) ως μία εκτίμηση για τη διακινδύνευση μίας υπόθεσης. Χρησιμοποιώντας ένα πιθανοτικό μοντέλο, μπορεί κανείς να κατασκευάσει ένα διάστημα εμπιστοσύνης  $[l^{(\mathbf{w})}, u^{(\mathbf{w})}]$  για κάθε επιλογή  $\mathbf{w}$  για τις παράμετρους του μοντέλου. Μία απλή κατασκευή είναι  $l^{(\mathbf{w})} := f(\mathbf{w}) - \sigma/2$ ,  $u^{(\mathbf{w})} := f(\mathbf{w}) + \sigma/2$ ,

με το  $\sigma$  να είναι ένα μέτρο της (αναμενόμενης) απόκλισης του  $f(\mathbf{w})$  από το  $\bar{f}(\mathbf{w})$ . Μπορούμε επίσης να χρησιμοποιήσουμε άλλες κατασκευές για αυτό το διάστημα εφόσον εξασφαλίζουν ότι  $\bar{f}(\mathbf{w}) \in [l(\mathbf{w}), u(\mathbf{w})]$  με αρκετά υψηλή πιθανότητα. Ένας αισιόδοξος επιλέγει τις παράμετρους του μοντέλου σύμφωνα με την πιο ευνοϊκή—αλλά εύλογη—τιμή  $\tilde{f}(\mathbf{w}) := l(\mathbf{w})$  του κριτηρίου επίδοσης (βλέπε Σχ. 24). Δύο παραδείγματα μεθόδων μηχανικής μάθησης που χρησιμοποιούν μία τέτοια αισιόδοξη κατασκευή μίας αντικειμενικής συνάρτησης είναι οι μέθοδοι ελαχιστοποίησης δομικής διακινδύνευσης [54, Κεφ. 11] και άνω φράγματος εμπιστοσύνης για διαδοχική λήψη αποφάσεων [55, Ενότητα 2.2].



Σχ. 24. Οι μέθοδοι μηχανικής μάθησης μαθαίνουν τις παράμετρους μοντέλου  $\mathbf{w}$  χρησιμοποιώντας κάποια εκτίμηση του  $f(\mathbf{w})$  για το τελικό κριτήριο επίδοσης  $\bar{f}(\mathbf{w})$ . Χρησιμοποιώντας ένα πιθανοτικό μοντέλο, κανείς μπορεί να χρησιμοποιήσει το  $f(\mathbf{w})$  για να κατασκευάσει διαστήματα εμπιστοσύνης  $[l(\mathbf{w}), u(\mathbf{w})]$ , τα οποία περιέχουν το  $\bar{f}(\mathbf{w})$  με υψηλή πιθανότητα. Το καλύτερο εύλογο μέτρο επίδοσης για μία συγκεκριμένη επιλογή  $\mathbf{w}$  των παραμέτρων του μοντέλου είναι  $\tilde{f}(\mathbf{w}) := l(\mathbf{w})$ .

Βλέπε επίσης: μηχανική μάθηση, model parameter, εμπειρική ελαχιστο-

ποίηση διακινδύνευσης, απώλεια, σύνολο δεδομένων, σύνολο εκπαίδευσης, διακινδύνευση, υπόθεση, πιθανοτικό μοντέλο, μέτρο, πιθανότητα, αντικειμενική συνάρτηση, ελαχιστοποίηση δομικής διακινδύνευσης, άνω φράγμα εμπιστοσύνης, μέθοδος βελτιστοποίησης, μέθοδος με βάση την κλίση.

**ακρίβεια** Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$  και μία κατηγορική ετικέτα  $y$  που παίρνει τιμές από ένα πεπερασμένο χώρο ετικετών  $\mathcal{Y}$ . Η ακρίβεια (accuracy) μίας υπόθεσης  $h : \mathcal{X} \rightarrow \mathcal{Y}$ , όταν εφαρμόζεται στα σημεία δεδομένων ενός συνόλου δεδομένων  $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ , ορίζεται τότε ως

$$1 - \frac{1}{m} \sum_{r=1}^m L^{(0/1)}((\mathbf{x}^{(r)}, y^{(r)}), h)$$

χρησιμοποιώντας την 0/1 απώλεια  $L^{(0/1)}(\cdot, \cdot)$ .

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, χώρος ετικετών, υπόθεση, σύνολο δεδομένων, 0/1 απώλεια, απώλεια, μετρική.

**ακρίβεια** Η ακρίβεια (precision) είναι μία μετρική που χρησιμοποιείται συχνά στη δυαδική ταξινόμηση. Μετράει το ποσοστό των αληθώς θετικών (δηλαδή των σωστά προβλεφθέντων θετικών σημείων δεδομένων) μεταξύ όλων των σημείων δεδομένων που προβλέφθηκαν ως θετικά. Με άλλα λόγια, είναι η ακρίβεια των σημείων δεδομένων που προβλέφθηκαν ως θετικά. Η ακρίβεια μπορεί επίσης να επεκταθεί στην ταξινόμηση πολλαπλών κλάσεων.

Η ακρίβεια σπάνια χρησιμοποιείται από μόνη της, καθώς ενθαρρύνει την επιλογή μόνο των πιο πιθανών σημείων δεδομένων. Ωστόσο, σε αντίθεση

με την ακρίβεια, η ακρίβεια παραμένει μία έγκυρη μετρική ακόμα και με μη ισορροπημένα σύνολα δεδομένων.

Βλέπε επίσης: μετρική, δυαδική ταξινόμηση, σημείο δεδομένων, ακρίβεια, ταξινόμηση, σύνολο δεδομένων, πίνακας σύγκυσης, ανάκληση.

**ακραία τιμή** Πολλές μέθοδοι μηχανικής μάθησης παρακινούνται από την παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, η οποία ερμηνεύει σημεία δεδομένων ως πραγματώσεις ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας. Η παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων είναι χρήσιμη για εφαρμογές όπου οι στατιστικές ιδιότητες της διαδικασίας παραγωγής δεδομένων είναι στάσιμες (ή χρονικά αναλλοίωτες) [43]. Ωστόσο, σε κάποιες εφαρμογές, τα δεδομένα αποτελούνται από μία πλειοψηφία ομαλών σημείων δεδομένων που συμμορφώνονται με την παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων καθώς και από έναν μικρό αριθμό σημείων δεδομένων που έχουν θεμελιωδώς διαφορετικές στατιστικές ιδιότητες συγκριτικά με τα ομαλά σημεία δεδομένων. Αναφερόμαστε σε ένα σημείο δεδομένων που αποκλίνει ουσιαστικά από τις στατιστικές ιδιότητες των περισσότερων σημείων δεδομένων ως μία ακραία τιμή. Διαφορετικές μέθοδοι για την ανίχνευση ακραίας τιμής χρησιμοποιούν διαφορετικά μέτρα για αυτή την απόκλιση. Η θεωρία στατιστικής μάθησης μελετάει τα θεμελιώδη όρια στη δυνατότητα να μετριάσουν αξιόπιστα οι ακραίες τιμές [56], [57].

Βλέπε επίσης: μηχανική μάθηση, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, σημείο δεδομένων, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, data, μέτρο, στιβαρότητα, ευστάθεια, παλινδρόμηση Huber, πιθανοτικό μο-



ντέλο.

**αλγόριθμος** Ένας αλγόριθμος (algorithm) είναι μία ακριβής, βήμα προς βήμα προδιαγραφή για την παραγωγή μίας εξόδου από μία δεδομένη είσοδο εντός ενός πεπερασμένου αριθμού καλά ορισμένων υπολογιστικών βημάτων [58]. Για παράδειγμα, μία μέθοδος με βάση την κλίση για γραμμική παλινδρόμηση είναι ένας αλγόριθμος που περιγράφει ρητά πώς να αντιστοιχίζεται ένα δεδομένο σύνολο εκπαίδευσης σε παράμετρους μοντέλου μέσω μίας ακολουθίας βημάτων κλίσης. Η ακριβής μορφή ενός αλγόριθμου εξαρτάται από τις διαθέσιμες υπολογιστικές υποδομές. Για παράδειγμα, αν αυτές οι υποδομές μας επιτρέπουν να υπολογίσουμε έναν αντίστροφο πίνακα, τότε μπορούμε να ορίσουμε έναν αλγόριθμο γραμμικής παλινδρόμησης χρησιμοποιώντας τις κανονικές εξισώσεις. Αντίθετα, αν οι υπολογιστικές υποδομές επιτρέπουν μόνο βασικές αριθμητικές πράξεις (δηλαδή πολλαπλασιασμό και πρόσθεση), οι κανονικές εξισώσεις πρέπει με κάποιον τρόπο να μεταφραστούν σε μία ακολουθία αριθμητικών πράξεων (π.χ. όπως στις μεθόδους με βάση την κλίση). Για να μελετήσουμε αλγόριθμους ενδελεχώς, μπορούμε να τους αναπαραστήσουμε (ή να τους προσεγγίσουμε) με διαφορετικές μαθηματικές δομές [59]. Μία προσέγγιση είναι να αναπαραστήσουμε έναν αλγόριθμο ως μία συλλογή πιθανών εκτελέσεων. Κάθε μεμονωμένη εκτέλεση είναι τότε μία ακολουθία της ακόλουθης μορφής:


$$\text{input}, s_1, s_2, \dots, s_T, \text{output}.$$

Αυτή η ακολουθία ξεκινάει από μία είσοδο και προοδεύει μέσω ενδιαμέ-

σων βημάτων μέχρι να παραδοθεί μία έξοδος. Είναι κρίσιμο ότι ένας αλγόριθμος συμπεριλαμβάνει περισσότερα από απλώς μία αντιστοίχιση από είσοδο σε έξοδο· περιλαμβάνει επίσης ενδιάμεσα υπολογιστικά βήματα  $s_1, \dots, s_T$ .

Βλέπε επίσης: έξοδος, μέθοδος με βάση την κλίση, γραμμική παλινδρόμηση, σύνολο εκπαίδευσης, model parameter, βήμα κλίσης, αντίστροφος πίνακας, κανονικές εξισώσεις, ακολουθία, μοντέλο, στοχαστική.

**αλγόριθμος  $k$ -μέσων** Η αρχή του αλγόριθμου  $k$ -μέσων τιμών ( $k$ -means) είναι μία προσέγγιση βασισμένη στη βελτιστοποίηση για τη συσταδοποίηση σημείων δεδομένων με ένα αριθμητικό διάνυσμα χαρακτηριστικών [8, Κεφ. 8]. Ως μία προσέγγιση σκληρής συσταδοποίησης, ο αλγόριθμος  $k$ -μέσων τιμών χωρίζει ένα σύνολο δεδομένων σε  $k$  ξένα υποσύνολα (ή συστάδες), τα οποία έχουν δείκτες  $c = 1, \dots, k$ . Κάθε συστάδα  $C$  χαρακτηρίζεται από το μέσο διάνυσμα χαρακτηριστικών των σημείων δεδομένων που ανήκουν σε αυτό. Αυτό το μέσο (ή μέσης τιμής) διάνυσμα χαρακτηριστικών αναφέρεται ως το κέντρο βάρους συστάδας  $\mathbf{w}^{(c)}$ . Μία οπτική απεικόνιση παρέχεται στο Σχ. 25.



Σχ. 25. Ένα διάγραμμα διασποράς σημείων δεδομένων, τα οποία έχουν δείκτες  $r = 1, \dots, m$  και χαρακτηρίζονται από διανύσματα χαρακτηριστικών  $\mathbf{x}^{(r)} \in \mathbb{R}^2$ . Το διάγραμμα διασποράς περιλαμβάνει επίσης δύο κέντρα βάρους συστάδων  $\mathbf{w}^{(1)}, \mathbf{w}^{(2)} \in \mathbb{R}^2$ .

Γενικά, η ακριβής λύση του προβλήματος βελτιστοποίησης του αλγόριθμου  $k$ -μέσων τιμών είναι δύσκολη (ή NP-δύσκολη) [60]. Ωστόσο, υπάρχουν απλές επαναληπτικές μέθοδοι για την εύρεση προσεγγιστικά βελτιστων κέντρων βάρους συστάδων. Μία τέτοια μέθοδος αναφέρεται ως αλγόριθμος του Lloyd.

Βλέπε επίσης: μέση τιμή, βελτιστοποίηση, συσταδοποίηση, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, hard clustering, σύνολο δεδομένων, συστάδα, κέντρο βάρους συστάδας, διάγραμμα διασποράς, optimization problem, αλγόριθμος του Lloyd.

**αλγόριθμος του Lloyd** TBC.

**αμοιβαίες πληροφορίες** Οι αμοιβαίες πληροφορίες (mutual information - MI)  $I(\mathbf{x}; y)$  μεταξύ δύο τυχαίων μεταβλητών  $\mathbf{x}, y$  που ορίζονται στον ίδιο χώρο πιθανοτήτων δίνονται από [14]

$$I(\mathbf{x}; y) := \mathbb{E} \left\{ \log \frac{p(\mathbf{x}, y)}{p(\mathbf{x})p(y)} \right\}.$$

Αποτελεί μέτρο του πόσο καλά μπορούμε να εκτιμήσουμε την  $y$  βάσει μόνο του  $\mathbf{x}$ . Μία μεγάλη τιμή του  $I(\mathbf{x}; y)$  υποδεικνύει ότι η  $y$  μπορεί να προβλεφθεί καλά μόνο από τη  $\mathbf{x}$ . Αυτή η πρόβλεψη θα μπορούσε να προκύψει από μία υπόθεση που μαθαίνεται από μία μέθοδο μηχανικής μάθησης βασισμένη στην εμπειρική ελαχιστοποίηση διακινδύνευσης.


Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μέτρο, πρόβλεψη, υπόθεση, εμπειρική ελαχιστοποίηση διακινδύνευσης, μηχανική μάθηση.

**αμφικλινής παλινδρόμηση** Θεωρούμε ένα πρόβλημα παλινδρόμησης όπου ο στόχος είναι να μαθευτεί μία υπόθεση  $h^{(\mathbf{w})}$  για την πρόβλεψη της αριθμητικής ετικέτας ενός σημείου δεδομένων με βάση το διάνυσμα χαρακτηριστικών του. Η αμφικλινής παλινδρόμηση (ridge regression) μαθαίνει τις παραμέτρους  $\mathbf{w}$  ελαχιστοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που έχει επιβληθεί ως ποινή. Η μέση απώλεια τετραγωνικού σφάλματος μετράται σε ένα σύνολο σημείων δεδομένων με ετικέτες (δηλαδή το σύνολο εκπαίδευσης)

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}).$$

Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια νόρμα  $\alpha \|\mathbf{w}\|_2^2$  με μία παράμετρο ομαλοποίησης  $\alpha > 0$ . Ο σκοπός του όρου ποινής είναι η ομαλοποίηση, δηλαδή η αποφυγή υπερπροσαρμογής στο καθεστώς υψηλής διάστασης, όπου ο αριθμός των χαρακτηριστικών  $d$  υπερβαίνει τον αριθμό των σημείων δεδομένων  $m$  στο σύνολο εκπαίδευσης. Για την εκπαίδευση ενός γραμμικού μοντέλου, η προσθήκη του  $\alpha \|\mathbf{w}\|_2^2$  στη μέση απώλεια τετραγωνικού σφάλματος ισοδυναμεί με τον υπολογισμό

της μέσης απώλεια τετραγωνικού σφάλματος σε ένα επαυξημένο σύνολο εκπαίδευσης.



Σχ. 26. Για ένα γραμμικό μοντέλο, η προσθήκη του όρου ποινής  $\alpha \|\mathbf{w}\|_2^2$  στην αντικειμενική συνάρτηση στην εμπειρική ελαχιστοποίηση διακινδύνευσης ισοδυναμεί με την εμπειρική ελαχιστοποίηση διακινδύνευσης σε ένα επαυξημένο σύνολο δεδομένων.

Αυτό το επαυξημένο σύνολο εκπαίδευσης προκύπτει αντικαθιστώντας κάθε σημείο δεδομένων  $(\mathbf{x}^{(r)}, y^{(r)})$  στο αρχικό σύνολο εκπαίδευσης με την πραγμάτωση άπειρα πολλών ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών των οποίων η κατανομή πιθανότητας είναι κεντρική στο  $(\mathbf{x}^{(r)}, y^{(r)})$ .

Βλέπε επίσης: regression, υπόθεση, ετικέτα, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, παράμετρος, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης, όρος ποινής, Ευκλείδεια νόρμα, ομαλοποίηση, υπερπροσαρμογή, καθεστώς υψηλής διάστασης, χαρακτηριστικό, εκπαίδευση, γραμμικό μοντέλο, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, απεικόνιση, επαύξηση δεδομένων.

**ανάκληση** Η ανάκληση (recall) είναι μία μετρική που χρησιμοποιείται συχνά στη δυαδική ταξινόμηση. Είναι ο λόγος των αληθώς θετικών (δηλαδή των σωστά προβλεφθέντων θετικών σημείων δεδομένων) προς όλα τα πραγματικά θετικά (δηλαδή τα σημεία δεδομένων με μία θετική πραγματική ετικέτα). Με άλλα λόγια, δείχνει το ποσοστό των αληθώς θετικών με σωστή ετικέτα. Η ανάκληση μπορεί επίσης να επεκταθεί στην ταξινόμηση πολλαπλών κλάσεων.

Η ανάκληση συνήθως δεν χρησιμοποιείται μόνης της, καθώς τέλεια ανάκληση μπορεί να επιτευχθεί με το να δίνεται σε όλα τα σημεία θετική ετικέτα. Ωστόσο, είναι στιβαρή σε μη ισορροπημένα σύνολα δεδομένων, σε αντίθεση, για παράδειγμα, με την ακρίβεια.

Βλέπε επίσης: μετρική, δυαδική ταξινόμηση, σημείο δεδομένων, ετικέτα, ταξινόμηση, σύνολο δεδομένων, ακρίβεια, πίνακας σύγχυσης, ακρίβεια.

**ανάλυση κύριων συνιστωσών** Θεωρούμε ένα σύνολο δεδομένων

$$\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$$

που αποτελείται από σημεία δεδομένων που χαρακτηρίζονται από διανύσματα χαρακτηριστικών  $\mathbf{x}^{(r)} \in \mathbb{R}^d$  for  $r = 1, \dots, m$ . Η ανάλυση κύριων συνιστωσών (principal component analysis - PCA) καθορίζει, για έναν δεδομένο αριθμό  $d' < d$ , μία γραμμική απεικόνιση χαρακτηριστικών

$$\Phi^{(\mathbf{W})} : \mathbb{R}^d \rightarrow \mathbb{R}^{d'} : \mathbf{x} \mapsto \mathbf{W}\mathbf{x}$$

έτσι ώστε τα νέα διανύσματα χαρακτηριστικών  $\mathbf{z}^{(r)} = \mathbf{W}\mathbf{x}^{(r)}$  να μας επιτρέπουν να ξανακατασκευάσουμε τα αρχικά χαρακτηριστικά με το ελάχι-

στο σφάλμα ανακατασκευής [8], [35], [51]:

$$\min_{\mathbf{R} \in \mathbb{R}^{d \times d'}} \sum_{r=1}^m \|\mathbf{x}^{(r)} - \mathbf{R}\mathbf{W}\mathbf{x}^{(r)}\|_2^2.$$

Μπορούμε να θεωρήσουμε την ανάλυση κύριων συνιστωσών ως μία μορφή εμπειρικής ελαχιστοποίησης διακινδύνευσης που χρησιμοποιεί τη συνάρτηση απώλειας  $L(\mathbf{x}, \mathbf{W}) = \|\mathbf{x} - \hat{\mathbf{R}}\mathbf{W}\mathbf{x}\|_2^2$  με έναν πίνακα ανακατασκευής  $\hat{\mathbf{R}}$  που επιτυγχάνει το παραπάνω ελάχιστο σφάλμα ανακατασκευής. Αυτό το πρόβλημα εμπειρικής ελαχιστοποίησης διακινδύνευσης μπορεί τελικά να λυθεί από έναν πίνακα  $\mathbf{W} = (\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d')})^T$  του οποίου οι γραμμές δίνονται από  $d'$  ιδιοδιανύσματα που αντιστοιχούν στις  $d'$  μεγαλύτερες ιδιοτιμές του πίνακα:

$$\hat{\mathbf{Q}} = \frac{1}{m} \sum_{r=1}^m \mathbf{x}^{(r)} (\mathbf{x}^{(r)})^T = \mathbf{X}^T \mathbf{X}.$$

Σημείωση ότι ο  $\hat{\mathbf{Q}}$  συμπίπτει με τον πίνακα συνδιακύμανσης δείγματος του  $\mathcal{D}$  αν η μέση τιμή δείγματός του μηδενίζει. Ο θετικά ημιορισμένος πίνακας  $\hat{\mathbf{Q}}$  επιτρέπει μία ανάλυση ιδιοτιμών της ακόλουθης μορφής [24], [61]:

$$\hat{\mathbf{Q}} = \sum_{j=1}^d \lambda_j \mathbf{u}^{(j)} (\mathbf{u}^{(j)})^T = \begin{pmatrix} \mathbf{u}^{(1)} & \dots & \mathbf{u}^{(d)} \end{pmatrix} \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_d \end{pmatrix} \begin{pmatrix} (\mathbf{u}^{(1)})^T \\ \vdots \\ (\mathbf{u}^{(d)})^T \end{pmatrix}.$$

Αυτή η ανάλυση αποτελείται από μη αρνητικές ιδιοτιμές σε φθίνουσα σειρά  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0$  και τα αντίστοιχα ιδιοδιανύσματα  $\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}$  που σχηματίζουν μία ορθοκανονική βάση του  $\mathbb{R}^d$ .

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, απεικόνιση χαρακτηριστικών, χαρακτηριστικό, ελάχιστο, εμπειρική ελαχιστοποίηση διακινδύνευσης, συνάρτηση απώλειας, πίνακας, ιδιοδιάνυσμα, ιδιοτιμή, πίνακας συνδιακύμανσης δείγματος, μέση τιμή δείγματος, θετικά ημιορισμένος, ανάλυση ιδιοτιμών.


**ανταμοιβή** Μία ανταμοιβή (reward) αναφέρεται σε κάποια παρατηρούμενη (ή μετρημένη) ποσότητα που μας επιτρέπει να εκτιμήσουμε την απώλεια που προκύπτει από την πρόβλεψη (ή απόφαση) μίας υπόθεσης  $h(\mathbf{x})$ . Για παράδειγμα, σε μία εφαρμογή μηχανικής μάθησης σε αυτοοδηγούμενα οχήματα, η  $h(\mathbf{x})$  θα μπορούσε να αναπαριστά την τρέχουσα κατεύθυνση οδήγησης ενός οχήματος. Θα μπορούσαμε να κατασκευάσουμε μία ανταμοιβή από τις μετρήσεις ενός αισθητήρα σύγκρουσης που υποδεικνύει αν το όχημα κινείται προς ένα εμπόδιο. Ορίζουμε μία χαμηλή ανταμοιβή για την κατεύθυνση οδήγησης  $h(\mathbf{x})$  αν το όχημα κινείται επικίνδυνα προς ένα εμπόδιο.

Βλέπε επίσης: απώλεια, πρόβλεψη, υπόθεση, μηχανική μάθηση, MAB, ενισχυτική μάθηση.

**αντικειμενική συνάρτηση** Μία αντικειμενική συνάρτηση (objective function) είναι μία απεικόνιση που αποδίδει μία αριθμητική αντικειμενική τιμή  $f(\mathbf{w})$  σε κάθε επιλογή  $\mathbf{w}$  κάποιας μεταβλητής που θέλουμε να βελτιστοποιήσουμε (βλέπε Σχ. 27). Στο πλαίσιο της μηχανικής μάθησης, η μεταβλητή βελτιστοποίησης θα μπορούσε να είναι οι παράμετροι μοντέλου μίας υπόθεσης  $h(\mathbf{w})$ . Κοινές αντικειμενικές συναρτήσεις περιλαμβάνουν τη διακινδύνευση (δηλαδή την προσδοκώμενη απώλεια) ή την εμπειρική δια-



κινδύνευση (δηλαδή τη μέση απώλεια πάνω σε ένα σύνολο εκπαίδευσης). Οι μέθοδοι μηχανικής μάθησης εφαρμόζουν τεχνικές βελτιστοποίησης, όπως τις μεθόδους με βάση την κλίση, για να βρουν την επιλογή  $\mathbf{w}$  με τη βέλτιστη τιμή (π.χ., το ελάχιστο ή το μέγιστο) της αντικειμενικής συνάρτησης.



Σχ. 27. Μία αντικειμενική συνάρτηση αντιστοιχίζει κάθε πιθανή τιμή  $\mathbf{w}$  μίας μεταβλητής βελτιστοποίησης, όπως οι παράμετροι μοντέλου ενός μοντέλου μηχανικής μάθησης, σε μία τιμή  $f(\mathbf{w})$  που μετράει τη χρησιμότητα της  $\mathbf{w}$ .

Βλέπε επίσης: συνάρτηση, απεικόνιση, μηχανική μάθηση, βελτιστοποίηση, model parameter, υπόθεση, διακινδύνευση, απώλεια, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, μέθοδος με βάση την κλίση, ελάχιστο, μέγιστο, μοντέλο, συνάρτηση απώλειας, εμπειρική ελαχιστοποίηση διακινδύνευσης, optimization problem.

**αντιστροφή μοντέλου TBC.**

**άνω φράγμα εμπιστοσύνης (ΑΦΕ)** Θεωρούμε μία εφαρμογή μηχανικής μάθησης που απαιτεί την επιλογή, σε κάθε χρονικό βήμα  $t$ , μίας ενέργειας  $a_t$  από ένα πεπερασμένο σύνολο εναλλακτικών  $\mathcal{A}$ . Η χρησιμότητα της επιλογής της ενέργειας  $a_t$  ποσοτικοποιείται από ένα αριθμητικό σήμα

ανταμοιβής  $r^{(a_t)}$ . Ένα ευρέως χρησιμοποιούμενο πιθανοτικό μοντέλο για αυτόν τον τύπο προβλήματος ακολουθιακής λήψης αποφάσεων είναι το περιβάλλον στοχαστικής MAB [55]. Σε αυτό το μοντέλο, η ανταμοιβή  $r^{(a)}$  θεωρείται ως η πραγμάτωση μίας τυχαίας μεταβλητής με άγνωστη μέση τιμή  $\mu^{(a)}$ . Ιδανικά, θα επιλέγαμε πάντα την ενέργεια με την μεγαλύτερη αναμενόμενη ανταμοιβή  $\mu^{(a)}$ , αλλά αυτές οι μέσες τιμές είναι άγνωστες και πρέπει να εκτιμηθούν από παρατηρούμενα δεδομένα. Το να επιλεγεί απλά η ενέργεια με τη μεγαλύτερη εκτίμηση  $\hat{\mu}^{(a)}$  μπορεί να οδηγήσει σε υποβέλτιστα αποτελέσματα λόγω της αβεβαιότητας στην εκτίμηση. Η στρατηγική ΑΦΕ (upper confidence bound - UCB) το αντιμετωπίζει αυτό επιλέγοντας ενέργειες όχι μόνο με βάση τις εκτιμώμενες μέσες τιμές αλλά και ενσωματώνοντας έναν όρο που αντανάκλα την αβεβαιότητα σε αυτές τις εκτιμήσεις—ευνοώντας ενέργειες με υψηλή πιθανή ανταμοιβή και υψηλή αβεβαιότητα. Θεωρητικές εγγυήσεις για την επίδοση στρατηγικών ΑΦΕ, συμπεριλαμβανομένων των ορίων λογαριθμικής ρήτρα μεταβολής γνώμης, καταδεικνύονται στο [55].

Βλέπε επίσης: μηχανική μάθηση, ανταμοιβή, πιθανοτικό μοντέλο, στοχαστική, MAB, μοντέλο, πραγμάτωση, τυχαία μεταβλητή, μέση τιμή, data, αβεβαιότητα, regret.

**απεικόνιση χαρακτηριστικών TBC.**

**απόκλιση** Θεωρούμε μία εφαρμογή ομοσπονδιακής μάθησης με networked data που αναπαριστώνται από ένα δίκτυο ομοσπονδιακής μάθησης. Οι μέθοδοι ομοσπονδιακής μάθησης χρησιμοποιούν ένα μέτρο απόκλισης (discrepancy) για να συγκρίνουν απεικονίσεις υπόθεσης από τοπικά μο-

ντέλα στους κόμβους  $i, i'$ , οι οποίοι συνδέονται με μία ακμή στο δίκτυο ομοσπονδιακής μάθησης.

Βλέπε επίσης: FL, networked data, δίκτυο ομοσπονδιακής μάθησης, μέτρο, υπόθεση, απεικόνιση, local model, συνεκτικός.

**αποτελεσματική διάσταση** Η αποτελεσματική διάσταση (effective dimension)  $d_{\text{eff}}(\mathcal{H})$  ενός άπειρου χώρου υποθέσεων  $\mathcal{H}$  είναι ένα μέτρο του μεγέθους του. Σε γενικές γραμμές, η αποτελεσματική διάσταση είναι ίση με τον αποτελεσματικό αριθμό ανεξάρτητων παραμέτρων μοντέλου που μπορούν να ρυθμιστούν. Αυτές οι παράμετροι μπορεί να είναι συντελεστές που χρησιμοποιούνται σε μία γραμμική απεικόνιση ή τα βάρη και οι όροι μεροληψίας ενός ΤΝΔ.

Βλέπε επίσης: διάσταση, χώρος υποθέσεων, μέτρο, model parameter, παράμετρος, linear map, βάρος, μεροληψία, ΤΝΔ.

**απώλεια** Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν μία συνάρτηση απώλειας  $L(\mathbf{z}, h)$  για να μετρήσουν το σφάλμα που προκαλείται από την εφαρμογή μίας συγκεκριμένης υπόθεσης σε ένα συγκεκριμένο σημείο δεδομένων. Με μία μικρή κατάχρηση του συμβολισμού, χρησιμοποιούμε τον όρο απώλεια (loss) και για την ίδια τη συνάρτηση απώλειας  $L$  και για τη συγκεκριμένη τιμή  $L(\mathbf{z}, h)$  για ένα σημείο δεδομένων  $\mathbf{z}$  και μία υπόθεση  $h$ .

Βλέπε επίσης: μηχανική μάθηση, συνάρτηση απώλειας, υπόθεση, σημείο δεδομένων, εμπειρική διακινδύνευση.


**απώλεια απόλυτου σφάλματος** Θεωρούμε ένα σημείο δεδομένων με χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$  και αριθμητική ετικέτα  $y \in \mathbb{R}$ . Όπως υποδηλώνει

και το όνομά της, η απώλεια απόλυτου σφάλματος (absolute error loss) που προκαλείται από μία υπόθεση  $h : \mathcal{X} \rightarrow \mathbb{R}$  ορίζεται ως

$$L((\mathbf{x}, y), h) = |y - h(\mathbf{x})|.$$

Το Σχ. 28 απεικονίζει την απώλεια απόλυτου σφάλματος για ένα σταθερό σημείο δεδομένων με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ . Υποδεικνύει επίσης τις τιμές απώλειας που προκαλούνται από δύο διαφορετικές υποθέσεις  $h'$  και  $h''$ . Όμοια με την απώλεια τετραγωνικού σφάλματος, η απώλεια απόλυτου σφάλματος είναι επίσης μία κυρτή συνάρτηση της πρόβλεψης  $\hat{y} = h(\mathbf{x})$ . Ωστόσο, σε αντίθεση με την απώλεια τετραγωνικού σφάλματος, η απώλεια απόλυτου σφάλματος είναι μη λεία, καθώς δεν είναι παραγωγίσιμη στη βέλτιστη πρόβλεψη  $\hat{y} = y$ . Αυτή η ιδιότητα καθιστά τις μεθόδους βασισμένες στην εμπειρική ελαχιστοποίηση διακινδύνευσης που χρησιμοποιούν την απώλεια απόλυτου σφάλματος υπολογιστικά πιο απαιτητικές [32], [62]. Για να αναπτυχθεί η διαισθητική κατανόηση, είναι χρήσιμο να παρατηρήσουμε τις δύο υποθέσεις που απεικονίζονται στο Σχ. 28. Απλώς ελέγχοντας την κλίση της  $L$  γύρω από τις  $h'(\mathbf{x})$  και  $h''(\mathbf{x})$ , είναι απίθανο να προσδιορίσουμε εάν βρισκόμαστε πολύ κοντά στο βέλτιστο (στην  $h'$ ) ή ακόμα μακριά (στην  $h''$ ). Ως αποτέλεσμα, οποιαδήποτε μέθοδος βελτιστοποίησης που βασίζεται σε τοπικές προσεγγίσεις της συνάρτησης απώλειας (όπως η κάθοδος υποκλίσης) πρέπει να χρησιμοποιεί έναν φθίνοντα ρυθμό μάθησης για να αποφευχθεί η υπέρβαση κατά την προσέγγιση του βέλτιστου. Αυτή η απαιτούμενη μείωση στον ρυθμό μάθησης τείνει να επιβραδύνει τη σύγκλιση της μεθόδου βελτιστοποίησης. Εκτός από την αυξημένη υπολογιστική πολυπλοκότητα, η

χρήση της απώλειας απόλυτου σφάλματος στην εμπειρική ελαχιστοποίηση διακινδύνευσης μπορεί να είναι ωφέλιμη στην παρουσία ακραίων τιμών στο σύνολο εκπαίδευσης. Σε αντίθεση με την απώλεια τετραγωνικού σφάλματος, η κλίση της απώλειας απόλυτου σφάλματος δεν αυξάνεται με την αύξηση του σφάλματος πρόβλεψης  $y - h(\mathbf{x})$ . Ως αποτέλεσμα, η επίδραση της εισαγωγής μίας ακραίας τιμής με μεγάλο σφάλμα πρόβλεψης στη λύση  $\hat{h}$  της εμπειρικής ελαχιστοποίησης διακινδύνευσης με απώλεια απόλυτου σφάλματος είναι πολύ μικρότερη συγκριτικά με την επίδραση στη λύση της εμπειρικής ελαχιστοποίησης διακινδύνευσης με απώλεια τετραγωνικού σφάλματος.




Σχ. 28. Για ένα σημείο δεδομένων με αριθμητική ετικέτα  $y \in \mathbb{R}$ , το απόλυτο σφάλμα  $|y - h(\mathbf{x})|$  μπορεί να χρησιμοποιηθεί ως μία συνάρτηση απώλειας για να καθοδηγήσει τη μάθηση μίας υπόθεσης  $h$ .

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, απώλεια, υπόθεση, διάνυσμα χαρακτηριστικών, απώλεια τετραγωνικού σφάλματος, κυρτό, συνάρτηση, πρόβλεψη, μη λεία, παραγωγίσιμη, εμπειρική ελαχιστοποίηση διακινδύνευσης, μέθοδος βελτιστοποίησης, συνάρτηση απώλειας, κάθοδος υποκλίσης, ρυθμός μάθησης, σύγκλιση, ακραία τιμή, σύνολο

εκπαίδευσης.

**απώλεια άρθρωσης** Θεωρούμε ένα σημείο δεδομένων που χαρακτηρίζεται από ένα διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  και μία δυαδική ετικέτα  $y \in \{-1, 1\}$ . Η απώλεια άρθρωσης (hinge loss) που προκαλείται από μία απεικόνιση υπόθεσης  $h(\mathbf{x})$  πραγματικής τιμής ορίζεται ως

$$L((\mathbf{x}, y), h) := \max\{0, 1 - yh(\mathbf{x})\}. \quad (1)$$



Σχ. 29. Η απώλεια άρθρωσης που προκαλείται από την πρόβλεψη  $h(\mathbf{x}) \in \mathbb{R}$  για ένα σημείο δεδομένων με ετικέτα  $y \in \{-1, 1\}$ . Μία ομαλοποιημένη παραλλαγή της απώλειας άρθρωσης χρησιμοποιείται από τη μηχανή διανυσμάτων υποστήριξης [63].

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, ετικέτα, απώλεια, υπόθεση, απεικόνιση, πρόβλεψη, μηχανή διανυσμάτων υποστήριξης, ταξινόμηση, ταξινομητής.

**απώλεια τετραγωνικού σφάλματος** Η απώλεια τετραγωνικού σφάλματος (squared error loss) μετράει το σφάλμα πρόβλεψης μίας υπόθεσης  $h$

όταν προβλέπει μία αριθμητική ετικέτα  $y \in \mathbb{R}$  από τα χαρακτηριστικά  $\mathbf{x}$  ενός σημείου δεδομένων. Ορίζεται ως

$$L((\mathbf{x}, y), h) := (y - \underbrace{h(\mathbf{x})}_{=\hat{y}})^2.$$

Βλέπε επίσης: απώλεια, πρόβλεψη, υπόθεση, ετικέτα, χαρακτηριστικό, σημείο δεδομένων.

**απώλεια Huber** Η απώλεια Huber (Huber loss) ενώνει την απώλεια τετραγωνικού σφάλματος και την απώλεια απόλυτου σφάλματος.

Βλέπε επίσης: απώλεια, απώλεια τετραγωνικού σφάλματος, απώλεια απόλυτου σφάλματος.


**αρχή της ελαχιστοποίησης των δεδομένων** Ο Ευρωπαϊκός κανονισμός για την προστασία δεδομένων περιλαμβάνει μία αρχή ελαχιστοποίησης δεδομένων (data minimization principle). Αυτή η αρχή απαιτεί έναν υπεύθυνο επεξεργασίας δεδομένων για να περιορίσει τη συλλογή προσωπικών πληροφοριών σε ό,τι είναι άμεσα σχετικό και απαραίτητο για την εκπλήρωση ενός προσδιορισμένου σκοπού. Τα δεδομένα πρέπει να φυλάσσονται μόνο για το χρονικό διάστημα που είναι απαραίτητα προκειμένου να εκπληρωθεί αυτός ο σκοπός [64, Άρθρο 5(1)(c)], [65].

Βλέπε επίσης: data.

**αυτοεποπτευόμενη μάθηση** TBC.

**αυτοκωδικοποιητής** Ένας αυτοκωδικοποιητής (autoencoder) είναι μία μέθοδος μηχανικής μάθησης που μαθαίνει ταυτόχρονα μία απεικόνιση κωδικοποιητή  $h \in \mathcal{H}$  και μία απεικόνιση αποκωδικοποιητή  $h^* \in \mathcal{H}^*$ . Διαφορετι-

κοί αυτοκωδικοποιητές χρησιμοποιούν διαφορετικά μοντέλα  $\mathcal{H}, \mathcal{H}^*$ , π.χ. ΤΝΔ με διαφορετικές αρχιτεκτονικές. Η ειδική περίπτωση αυτοκωδικοποιητή που χρησιμοποιεί γραμμικά μοντέλα (διανυσματικό τιμής) για τα  $\mathcal{H}, \mathcal{H}^*$  οδηγεί στην .



Σχ. 30. Αυτοκωδικοποιητής με έναν κωδικοποιητή  $h$  που αντιστοιχίζει  $\mathbf{x} \mapsto \mathbf{z}$  και έναν αποκωδικοποιητή  $h^*$  που αντιστοιχίζει  $\mathbf{z} \mapsto \hat{\mathbf{x}}$ .

Η εκπαίδευση του κωδικοποιητή και του αποκωδικοποιητή μπορεί να υλοποιηθεί μέσω εμπειρικής ελαχιστοποίησης διακινδύνευσης χρησιμοποιώντας μία απώλεια που μετράει την απόκλιση του ανακατασκευασμένου διανύσματος χαρακτηριστικών  $h^*(h(\mathbf{x}))$  από το αρχικό διάνυσμα χαρακτηριστικών  $\mathbf{x}$ .

Βλέπε επίσης: μηχανική μάθηση, κωδικοποιητής, απεικόνιση, μοντέλο, ΤΝΔ, διάνυσμα, γραμμικό μοντέλο, ανάλυση κύριων συνιστωσών, εκπαίδευση, εμπειρική ελαχιστοποίηση διακινδύνευσης, απώλεια, διάνυσμα χαρακτηριστικών, μάθηση χαρακτηριστικών, μείωση της διαστασιμότητας.

**βαθιά μάθηση** Βλέπε βαθύ δίκτυο.


**βαθμός συσχέτισης** Ο βαθμός συσχέτισης (degree of belonging) είναι ένας αριθμός που υποδεικνύει το κατά πόσο ένα σημείο δεδομένων ανήκει σε μία συστάδα [8, Κεφ. 8]. Ο βαθμός συσχέτισης μπορεί να ερμηνευτεί ως μία μαλακή απόδοση συστάδας. Οι μέθοδοι μαλακής συσταδοποίησης



μπορούν να κωδικοποιήσουν τον βαθμό συσχέτισης με έναν πραγματικό αριθμό στο διάστημα  $[0, 1]$ . Η σκληρή συσταδοποίηση προκύπτει ως η ακραία περίπτωση όταν ο βαθμός συσχέτισης παίρνει μόνο τιμές 0 or 1. Βλέπε επίσης: σημείο δεδομένων, συστάδα, μαλακή συσταδοποίηση, hard clustering.

**βαθύ δίκτυο** Ένα βαθύ δίκτυο (deep net) είναι ένα ΤΝΔ με έναν (σχετικά) μεγάλο αριθμό κρυφών στρωμάτων. Η βαθιά μάθηση είναι ένας όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που χρησιμοποιούν ένα βαθύ δίκτυο ως μοντέλο τους [34].  
Βλέπε επίσης: ΤΝΔ, στρώμα, βαθιά μάθηση, μηχανική μάθηση, μοντέλο, μεγάλο γλωσσικό μοντέλο.

**βάρος** Θεωρούμε έναν παραμετροποιημένο χώρο υποθέσεων  $\mathcal{H}$ . Χρησιμοποιούμε τον όρο βάρη (weights) για αριθμητικές παράμετρους μοντέλου που χρησιμοποιούνται για να κλιμακώσουν χαρακτηριστικά ή τους μετασχηματισμούς τους προκειμένου να υπολογίσουμε  $h^{(\mathbf{w})} \in \mathcal{H}$ . Ένα γραμμικό μοντέλο χρησιμοποιεί βάρη  $\mathbf{w} = (w_1, \dots, w_d)^T$  για να υπολογίσει τον γραμμικό συνδυασμό  $h^{(\mathbf{w})}(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ . Βάρη χρησιμοποιούνται επίσης σε ΤΝΔ για να σχηματιστούν γραμμικοί συνδυασμοί χαρακτηριστικών ή των εξόδων νευρώνων σε κρυφά στρώματα (βλέπε Σχ. 31).



Σχ. 31. Ένα τμήμα ενός ΤΝΔ που περιέχει ένα κρυφό στρώμα με εξόδους (ή ενεργοποιήσεις)  $h_1$ ,  $h_2$ , και  $h_3$ . Αυτές οι εξοδοί συνδυάζονται γραμμικά για να υπολογιστεί ο  $z$ , ο οποίος μπορεί να χρησιμοποιηθεί είτε ως εξόδος του ΤΝΔ είτε ως είσοδος σε ένα άλλο στρώμα.

Βλέπε επίσης: χώρος υποθέσεων, model parameter, χαρακτηριστικό, γραμμικό μοντέλο, ΤΝΔ, έξοδος, στρώμα, ενεργοποίηση.

**βάρος ακμής** Σε κάθε ακμή  $\{i, i'\}$  ενός δικτύου ομοσπονδιακής μάθησης αποδίδεται ένα μη αρνητικό βάρος ακμής (edge weight)  $A_{i,i'} \geq 0$ . Ένα μηδενικό βάρος ακμής  $A_{i,i'} = 0$  υποδεικνύει την απουσία μίας ακμής μεταξύ των κόμβων  $i, i' \in \mathcal{V}$ .

Βλέπε επίσης: δίκτυο ομοσπονδιακής μάθησης.

**βάση αναφοράς** TBC.

**γείτονας** Ένας γείτονας (neighbor) ενός κόμβου  $i \in \mathcal{V}$  εντός ενός μη κατευθυνόμενου γράφου είναι ένας κόμβος  $i' \in \mathcal{V} \setminus \{i\}$  που συνδέεται με τον κόμβο  $i$  μέσω μίας ακμής.

Βλέπε επίσης: μη κατευθυνόμενος γράφος, συνεκτικός.

**γενικευμένη ολική μεταβολή** Η γενικευμένη ολική μεταβολή (generalized total variation - GTV) είναι ένα μέτρο της μεταβολής των εκπαιδευμένων τοπικών μοντέλων  $h^{(i)}$  (ή των παραμέτρων του μοντέλου τους  $\mathbf{w}^{(i)}$ ) που αποδίδονται στους κόμβους  $i = 1, \dots, n$  ενός μη κατευθυνόμενου σταθμισμένου γράφου  $\mathcal{G}$  με ακμές  $\mathcal{E}$ . Δεδομένου ενός μέτρου  $d^{(h,h')}$  της απόκλισης μεταξύ απεικονίσεων υπόθεσης  $h, h'$ , η γενικευμένη ολική μεταβολή είναι

$$\sum_{\{i,i'\} \in \mathcal{E}} A_{i,i'} d^{(h^{(i)}, h^{(i')})}.$$

Εδώ,  $A_{i,i'} > 0$  δηλώνει το βάρος της μη κατευθυνόμενης ακμής  $\{i, i'\} \in \mathcal{E}$ . Βλέπε επίσης: μέτρο, local model, model parameter, graph, απόκλιση, υπόθεση, απεικόνιση.

**γενίκευση** TBC.

**γινόμενο Kronecker** Το γινόμενο Kronecker (Kronecker product) δύο πινάκων  $\mathbf{A} \in \mathbb{R}^{m \times n}$  και  $\mathbf{B} \in \mathbb{R}^{p \times q}$  είναι ένας σύνθετος πίνακας που δηλώνεται με  $\mathbf{A} \otimes \mathbf{B}$  και ορίζεται ως [3], [24]

$$\mathbf{A} \otimes \mathbf{B} = \begin{pmatrix} a_{11}\mathbf{B} & \cdots & a_{1n}\mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{B} & \cdots & a_{mn}\mathbf{B} \end{pmatrix} \in \mathbb{R}^{mp \times nq}.$$

Το γινόμενο Kronecker είναι μία ειδική περίπτωση του τανυστικού γινόμενου για πίνακες και χρησιμοποιείται ευρέως στην πολυμεταβλητή στατιστική, στη γραμμική άλγεβρα, και σε δομημένα μοντέλα μηχανικής μάθησης. Ικανοποιεί το ταυτοτικό στοιχείο  $(\mathbf{A} \otimes \mathbf{B})(\mathbf{x} \otimes \mathbf{y}) = (\mathbf{A}\mathbf{x}) \otimes (\mathbf{B}\mathbf{y})$  για

διανύσματα  $\mathbf{x}$  και  $\mathbf{y}$  συμβατών διαστάσεων.

Βλέπε επίσης: πίνακας, μηχανική μάθηση, μοντέλο, διάνυσμα.

**Γκαουσιανό μοντέλο μείγματος** Ένα Γκαουσιανό μοντέλο μείγματος (Gaussian mixture model - GMM) είναι ένας συγκεκριμένος τύπος πιθανοτικού μοντέλου για σημεία δεδομένων που χαρακτηρίζονται από ένα αριθμητικό διάνυσμα χαρακτηριστικών  $\mathbf{x}$ . Σε ένα Γκαουσιανό μοντέλο μείγματος, το διάνυσμα χαρακτηριστικών  $\mathbf{x}$  ενός σημείου δεδομένων παράγεται τυχαία σύμφωνα με την πολυμεταβλητή κανονική κατανομή  $\mathbb{P}^{(c)} = \mathcal{N}(\boldsymbol{\mu}^{(c)}, \mathbf{C}^{(c)})$  με  $c = I$ . Ο ίδιος ο δείκτης  $I \in \{1, \dots, k\}$  είναι επίσης μία τυχαία μεταβλητή με πιθανότητες  $\mathbb{P}(I = c) = p_c$ . Συνεπώς, ένα Γκαουσιανό μοντέλο μείγματος παραμετροποιείται, για κάθε  $c = 1, \dots, k$ , από την πιθανότητα  $p_c$ , το διάνυσμα μέσης τιμής  $\boldsymbol{\mu}^{(c)}$ , και τον πίνακα συνδιακύμανσης  $\mathbf{C}^{(c)}$ .

Βλέπε επίσης: πιθανοτικό μοντέλο, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, πολυμεταβλητή κανονική κατανομή, τυχαία μεταβλητή, πιθανότητα, μέση τιμή, διάνυσμα, πίνακας συνδιακύμανσης, συσταδοποίηση.


**γραμμική παλινδρόμηση** Οι μέθοδοι γραμμικής παλινδρόμησης (linear regression) μαθαίνουν μία γραμμική απεικόνιση υπόθεσης  $h^{(\mathbf{w})}(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  που χρησιμοποιείται για την πρόβλεψη της αριθμητικής ετικέτας  $y \in \mathbb{R}$  ενός σημείου δεδομένων με βάση τα αριθμητικά διανύσματα χαρακτηριστικών του  $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$ . Η παραλλαγή ελάχιστων τετραγώνων της γραμμικής παλινδρόμησης μετράει την ποιότητα μίας απεικόνισης υπόθεσης μέσω της μέσης απώλειας τετραγωνικού σφάλματος που προκα-

λείται σε ένα σύνολο εκπαίδευσης

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}).$$

Ως μία περίπτωση εμπειρικής ελαχιστοποίησης διακινδύνευσης, η γραμμική (ελάχιστων τετραγώνων) παλινδρόμηση μαθαίνει τις παράμετρους του μοντέλου  $\mathbf{w}$  λύνοντας το ακόλουθο πρόβλημα βελτιστοποίησης:

$$\min_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{m} \sum_{r=1}^m (y^{(r)} - \mathbf{w}^T \mathbf{x}^{(r)})^2.$$



Σχ. 32. Για ένα γραμμικό μοντέλο με  $d = 1$  και χρησιμοποιώντας το ασήμαντο χαρακτηριστικό  $x = 1$  για οποιοδήποτε σημείο δεδομένων, η γραμμική παλινδρόμηση μειώνεται στον υπολογισμό του μέσου όρου  $\hat{w} = (1/m) \sum_{r=1}^m y^{(r)}$ . (a) Ένα καθαρό σύνολο εκπαίδευσης και η επακόλουθη παράμετρος (που δίνεται από τον μέσο όρο). (b) Ένα διαταραγμένο σύνολο δεδομένων (που περιλαμβάνει μία ακραία τιμή) και η επακόλουθη παράμετρος.

Μπορούμε να ξαναγράψουμε το παραπάνω πρόβλημα βελτιστοποίησης πιο συμπαγώς χρησιμοποιώντας τον πίνακα χαρακτηριστικών  $\mathbf{X} = (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})^T \in$

$\mathbb{R}^{m \times d}$  και το διάνυσμα ετικετών  $\mathbf{y} = (y^{(1)}, \dots, y^{(m)})^T \in \mathbb{R}^m$ . Αυτό μας επιτρέπει να ξαναγράψουμε το παραπάνω πρόβλημα βελτιστοποίησης ως

$$\min_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{m} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2.$$

Από τη συνθήκη μηδενικής κλίσης, μία απαραίτητη και επαρκής συνθήκη ώστε ένα διάνυσμα  $\hat{\mathbf{w}}$  να είναι μία λύση του παραπάνω προβλήματος βελτιστοποίησης είναι το γραμμικό σύστημα εξισώσεων [39]:

$$\mathbf{X}^T \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^T \mathbf{y}. \quad (2)$$

Αντί να λύνουμε άμεσα την (2) (μέσω του υπολογισμού του αντίστροφου πίνακα ή του ψευδοαντίστροφου), πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν παραλλαγές της καθόδου κλίσης για να κατασκευάσουν μία ακολουθία  $\mathbf{w}^{(0)}, \mathbf{w}^{(1)}, \dots$  ολοένα και περισσότερο ακριβών προσεγγίσεων μία λύσης  $\hat{\mathbf{w}}$  της (2). Αυτές οι μέθοδοι με βάση την κλίση μπορούν να ερμηνευτούν ως μία επανάληψη σταθερού σημείου για την ακόλουθη αναδιατύπωση της (2):

$$(\mathbf{I} - \mathbf{A}\mathbf{X}^T\mathbf{X})\hat{\mathbf{w}} + \mathbf{X}^T\mathbf{y} = \hat{\mathbf{w}} \quad \text{για κάποιον αντιστρέψιμο πίνακα } \mathbf{A}.$$

Αυτή η εξίσωση λύνεται από ένα διάνυσμα  $\hat{\mathbf{w}}$  αν και μόνο αν αυτό το διάνυσμα επίσης λύνει την (2). Η συνθήκη του βέλτιστου (2) είναι επίσης χρήσιμη για τη μελέτη της ευστάθειας της γραμμικής παλινδρόμησης. Ιδανικά, θα θέλαμε οι λύσεις της (2) να μην επηρεάζονται σημαντικά από μικρές διαταραχές του συνόλου εκπαίδευσης. Μπορούμε να αποτυ-

πώσουμε αυτές τις διαταραχές μέσω ενός διαταραγμένου πίνακα χαρακτηριστικών  $\tilde{\mathbf{X}} = \mathbf{X} + \Delta\mathbf{X}$  και ενός διαταραγμένου διανύσματος ετικετών  $\tilde{\mathbf{y}} = \mathbf{y} + \Delta\mathbf{y}$ . Εδώ,  $\Delta\mathbf{X}$  και  $\Delta\mathbf{y}$  αναπαριστούν μικρές διαταραχές στα διανύσματα χαρακτηριστικών και στις ετικέτες των σημείων δεδομένων του αρχικού συνόλου εκπαίδευσης. Η θεωρία διαταραχών πινάκων μας επιτρέπει να αξιολογήσουμε πόσο αποκλίνουν οι λύσεις του διαταραγμένου προβλήματος γραμμικής παλινδρόμησης [3, Ενότητα 2.6]

$$\tilde{\mathbf{X}}^T \tilde{\mathbf{X}} \tilde{\mathbf{w}} = \tilde{\mathbf{X}}^T \tilde{\mathbf{y}}$$

από τις λύσεις  $\tilde{\mathbf{w}}$  του αρχικού προβλήματος γραμμικής παλινδρόμησης. Βλέπε επίσης: regression, υπόθεση, απεικόνιση, ετικέτα, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, απώλεια τετραγωνικού σφάλματος, σύνολο εκπαίδευσης, εμπειρική ελαχιστοποίηση διακινδύνευσης, model parameter, optimization problem, ακραία τιμή, γραμμικό μοντέλο, χαρακτηριστικό, παράμετρος, σύνολο δεδομένων, πίνακας χαρακτηριστικών, διάνυσμα, συνθήκη μηδενικής κλίσης, αντίστροφος πίνακας, ψευδοαντίστροφος, μηχανική μάθηση, κάθοδος κλίσης, ακολουθία, μέθοδος με βάση την κλίση, επανάληψη σταθερού σημείου, πίνακας, ευστάθεια.

**γραμμικό μοντέλο** TBC.

**γραμμικός ταξινομητής** Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά χαρακτηριστικά  $\mathbf{x} \in \mathbb{R}^d$  και μία ετικέτα  $y \in \mathcal{Y}$  από κάποιον πεπερασμένο χώρο ετικετών  $\mathcal{Y}$ . Ένας γραμμικός ταξινομητής (linear classifier) χαρακτηρίζεται από το γεγονός ότι έχει περιοχές αποφάσεων που διαχωρίζονται από υπερεπίπεδα στον  $\mathbb{R}^d$  [8, Κεφ. 2].

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, χώρος ετικετών, ταξινομητής, περιοχή αποφάσεων, υπερεπίπεδο.

**γράφος ομοιότητας** Κάποιες εφαρμογές μηχανικής μάθησης παράγουν σημεία δεδομένων που σχετίζονται μέσω μίας ειδικής για τον εκάστοτε τομέα έννοιας ομοιότητας. Αυτές οι ομοιότητες μπορούν να αναπαρασταθούν με ευκολία χρησιμοποιώντας έναν γράφο ομοιότητας  $\mathcal{G} = (\mathcal{V} := \{1, \dots, m\}, \mathcal{E})$ . Ο κόμβος  $r \in \mathcal{V}$  αντιπροσωπεύει το  $r$ -οστό σημείο δεδομένων. Δύο κόμβοι συνδέονται με μία μη κατευθυνόμενη ακμή αν τα αντίστοιχα σημεία δεδομένων είναι όμοια.

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, graph, συνεκτικός.

**δεδομένα** Στο πλαίσιο της μηχανικής μάθησης, ο όρος δεδομένα (data) χρησιμοποιείται συχνά ως συνώνυμο του συνόλου δεδομένων [19], [20]. Το πρότυπο ISO/IEC 2382:2015 [66] ορίζει τα δεδομένα ως μία

reinterpretable representation of information in a formalized manner suitable for communication, interpretation, or processing

(δηλαδή μία «επανερμηνεύσιμη αναπαράσταση πληροφοριών με έναν τυποποιημένο τρόπο κατάλληλο για επικοινωνία, ερμηνεία, ή επεξεργασία» ).

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, σημείο δεδομένων, sample.

**δειγματικός χώρος** Ένας δειγματικός χώρος (sample space) είναι το σύνολο όλων των πιθανών εκβάσεων ενός τυχαίου πειράματος [6], [7], [36], [67].



Βλέπε επίσης: sample, έχβαση, τυχαίο πείραμα, χώρος πιθανοτήτων.

**δέντρο αποφάσεων** TBC.

**δέσμη** Στο πλαίσιο της στοχαστικής καθόδου κλίσης, μία δέσμη αναφέρεται σε ένα τυχαία επιλεγμένο υποσύνολο του γενικού συνόλου εκπαίδευσης. Χρησιμοποιούμε τα σημεία δεδομένων σε αυτό το υποσύνολο για να εκτιμήσουμε την κλίση του σφάλματος εκπαίδευσης και στη συνέχεια να ενημερώσουμε τις παράμετρους του μοντέλου.


Βλέπε επίσης: στοχαστική κάθοδος κλίσης, σύνολο εκπαίδευσης, σημείο δεδομένων, κλίση, training error, model parameter.

**δηλητηρίαση δεδομένων** Η δηλητηρίαση δεδομένων (data poisoning) αναφέρεται στον σκόπιμο χειρισμό (ή επινόηση) σημείων δεδομένων για να κατευθύνει κακόβουλα την εκπαίδευση ενός μοντέλου μηχανικής μάθησης [68], [69]. Οι επιθέσεις δηλητηρίασης δεδομένων λαμβάνουν διάφορες μορφές, συμπεριλαμβανομένων των επιθέσεων κερκόπορτας και των επιθέσεων άρνησης υπηρεσιών. Μία επίθεση κερκόπορτας εμφυτεύει ενεργοποιητές στα δεδομένα εκπαίδευσης, έτσι ώστε το εκπαιδευμένο μοντέλο να συμπεριφέρεται κανονικά για τυπικά σημεία δεδομένων αλλά να ταξινομεί λανθασμένα ένα σημείο δεδομένων με ένα διάνυσμα χαρακτηριστικών που περιέχει ένα μοτίβο ενεργοποίησης. Μία επίθεση άρνησης υπηρεσιών υποβαθμίζει τη συνολική επίδοση του εκπαιδευμένου μοντέλου μέσω της εισαγωγής παραδειγμάτων με λανθασμένη ετικέτα ή αντιπαραθετικών παραδειγμάτων για την αποφυγή αποτελεσματικής μάθησης. Η δηλητηρίαση δεδομένων είναι ιδιαίτερα επιβλαβής σε αποκεντρωμένα ή κατανεμημένα περιβάλλοντα μηχανικής μάθησης (όπως η ομοσπονδιακή μάθηση), όπου

τα δεδομένα εκπαίδευσης δεν μπορούν να επαληθευτούν κεντρικά.

Βλέπε επίσης: data, σημείο δεδομένων, εκπαίδευση, μηχανική μάθηση, μοντέλο, επίθεση, κερκόπορτα, επίθεση άρνησης υπηρεσιών, διάνυσμα χαρακτηριστικών, FL, αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN).

**διάγραμμα διασποράς** Μία τεχνική οπτικοποίησης που απεικονίζει σημεία δεδομένων χρησιμοποιώντας σημεία σε ένα 2-D επίπεδο. Το Σχ. 33 απεικονίζει ένα παράδειγμα διαγράμματος διασποράς (scatterplot).



Σχ. 33. Ένα διάγραμμα διασποράς με κυκλικά σημεία, όπου τα σημεία δεδομένων αναπαριστούν ημερήσιες καιρικές συνθήκες στη Φινλανδία. Κάθε σημείο δεδομένων χαρακτηρίζεται από την ελάχιστη ημερήσια θερμοκρασία  $x$  ως χαρακτηριστικό και τη μέγιστη ημερήσια θερμοκρασία  $y$  ως ετικέτα. Οι θερμοκρασίες έχουν μετρηθεί στον σταθμό καιρού Kaisaniemi στο Ελσίνκι του Φινλανδικού Μετεωρολογικού Ινστιτούτου κατά την περίοδο 1 Σεπτεμβρίου 2024—28 Οκτωβρίου 2024.

Ένα διάγραμμα διασποράς μπορεί να επιτρέψει τον οπτικό έλεγχο σημείων δεδομένων που αναπαριστώνται φυσικά από διανύσματα χαρακτηριστικών σε χώρους υψηλής διάστασης.

Βλέπε επίσης: σημείο δεδομένων, ελάχιστο, χαρακτηριστικό, μέγιστο, ετικέτα, Φινλανδικό Μετεωρολογικό Ινστιτούτο, διάνυσμα χαρακτηριστικών, μείωση της διαστασιμότητας.

**διαδικτυακή μάθηση** TBC.

**διαδικτυακός αλγόριθμος TBC.**

**διακινδύνευση** Θεωρούμε μία υπόθεση  $h$  που χρησιμοποιείται για να προβλεφθεί η ετικέτα  $y$  ενός σημείου δεδομένων βάσει των χαρακτηριστικών  $\mathbf{x}$ . Μετράμε την ποιότητα μίας συγκεκριμένης πρόβλεψης χρησιμοποιώντας μία συνάρτηση απώλειας  $L((\mathbf{x}, y), h)$ . Αν ερμηνεύσουμε τα σημεία δεδομένων ως τις πραγματώσεις ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών, τότε και η  $L((\mathbf{x}, y), h)$  γίνεται η πραγμάτωση μίας τυχαίας μεταβλητής. Η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων μας επιτρέπει να ορίσουμε τη διακινδύνευση (risk) μίας υπόθεσης ως την αναμενόμενη απώλεια  $\mathbb{E}\{L((\mathbf{x}, y), h)\}$ . Σημείωση ότι η διακινδύνευση της  $h$  εξαρτάται τόσο από τη συγκεκριμένη επιλογή για τη συνάρτηση απώλειας όσο και από την κατανομή πιθανότητας των σημείων δεδομένων.

Βλέπε επίσης: υπόθεση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό, πρόβλεψη, συνάρτηση απώλειας, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαία μεταβλητή, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, απώλεια, κατανομή πιθανότητας.

**διακινδύνευση Bayes** Θεωρούμε ένα πιθανοτικό μοντέλο για μία εφαρμογή μηχανικής μάθησης όπου κάθε σημείο δεδομένων ερμηνεύεται ως μία τυχαία μεταβλητή. Το πιθανοτικό μοντέλο περιλαμβάνει μία κατανομή πιθανότητας για τα χαρακτηριστικά  $\mathbf{x}$  και την ετικέτα  $y$  ενός σημείου δεδομένων. Η διακινδύνευση Bayes (Bayes risk) είναι η ελάχιστη πιθανή διακινδύνευση που μπορεί να επιτευχθεί από οποιαδήποτε υπόθεση  $h : \mathcal{X} \rightarrow \mathcal{Y}$ . Οποιαδήποτε υπόθεση που επιτυγχάνει τη διακινδύνευση

Bayes αναφέρεται ως ένας εκτιμητής Bayes [38].

Βλέπε επίσης: πιθανοτικό μοντέλο, μηχανική μάθηση, σημείο δεδομένων, τυχαία μεταβλητή, κατανομή πιθανότητας, χαρακτηριστικό, ετικέτα, διακινδύνευση, ελάχιστο, υπόθεση, εκτιμητής Bayes.

**διάνυσμα ετικετών** Given a σύνολο δεδομένων of  $m$  σημείο δεδομένων με ετικέτας

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}),$$

it is convenient to collect the corresponding ετικέτας into a single ετικέτα διάνυσμα  $\mathbf{y} := (y_1, \dots, y_m)^T$  [35], [51].

See also: σύνολο δεδομένων, σημείο δεδομένων με ετικέτα, ετικέτα, σημείο δεδομένων.

**διάνυσμα χαρακτηριστικών** Το διάνυσμα χαρακτηριστικών (feature vector) αναφέρεται σε ένα διάνυσμα  $\mathbf{x} = (x_1, \dots, x_d)^T$  του οποίου οι καταχωρίσεις είναι μεμονωμένα χαρακτηριστικά  $x_1, \dots, x_d$ . Πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν διανύσματα χαρακτηριστικών που ανήκουν σε κάποιον Ευκλείδειο χώρο  $\mathbb{R}^d$  πεπερασμένης διάστασης. Για κάποιες μεθόδους μηχανικής μάθησης, ωστόσο, μπορεί να είναι πιο βολικό να δουλεύουμε με διανύσματα χαρακτηριστικών που ανήκουν σε έναν διανυσματικό χώρο άπειρης διάστασης (π.χ. βλέπε μέθοδος πυρήνα).

Βλέπε επίσης: χαρακτηριστικό, διάνυσμα, μηχανική μάθηση, Ευκλείδειος χώρος, διανυσματικός χώρος, kernel method.

**διαρροή ιδιωτικότητας** Θεωρούμε μία εφαρμογή μηχανικής μάθησης που επεξεργάζεται ένα σύνολο δεδομένων  $\mathcal{D}$  και παραδίδει κάποια έξοδο, όπως οι προβλέψεις που προκύπτουν για νέα σημεία δεδομένων. Διαρροή ιδιω-

τικότητας (privacy leakage) ανακύπτει αν η έξοδος φέρει πληροφορίες σχετικά με ένα ιδιωτικό (ή ευαίσθητο) χαρακτηριστικό ενός σημείου δεδομένων του  $\mathcal{D}$  (όπως ενός ανθρώπου). Με βάση ένα πιθανοτικό μοντέλο για την παραγωγή δεδομένων, μπορούμε να μετρήσουμε τη διαρροή ιδιωτικότητας μέσω των αμοιβαίων πληροφοριών μεταξύ της εξόδου και του ευαίσθητου χαρακτηριστικού. Ένα άλλο ποσοτικό μέτρο διαρροής ιδιωτικότητας είναι η διαφορική ιδιωτικότητα. Οι σχέσεις μεταξύ διαφορετικών μέτρων διαρροής ιδιωτικότητας έχουν μελετηθεί στη βιβλιογραφία (βλέπε [70]).

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, έξοδος, πρόβλεψη, σημείο δεδομένων, χαρακτηριστικό, πιθανοτικό μοντέλο, data, αμοιβαίες πληροφορίες, μέτρο, διαφορική ιδιωτικότητα, επίθεση της ιδιωτικότητας, γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ).

**διάσταση Vapnik–Chervonenkis** TBC.

**διασταυρούμενη επικύρωση  $k$ -αναδιπλώσεων** Η διασταυρούμενη επικύρωση  $k$ -αναδιπλώσεων ( $k$ -fold cross-validation -  $k$ -fold CV) είναι μία μέθοδος για την αξιολόγηση του χάσματος γενίκευσης μίας μεθόδου μηχανικής μάθησης βασισμένης στην εμπειρική ελαχιστοποίηση διακινδύνευσης. Η ιδέα είναι να διαιρεθεί ένα σύνολο δεδομένων  $\mathcal{D}$  ισότιμα σε  $k$  υποσύνολα (ή αναδιπλώσεις)  $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(k)}$ .

	$\mathcal{D}^{(1)}$	$\mathcal{D}^{(2)}$	$\mathcal{D}^{(3)}$	$\mathcal{D}^{(4)}$	$\mathcal{D}^{(5)}$
αναδίπλωση 1	■				
αναδίπλωση 2		■			
αναδίπλωση 3			■		
αναδίπλωση 4				■	
αναδίπλωση 5					■

Σχ. 34. Στη διασταυρούμενη επικύρωση  $k$ -αναδιπλώσεων, το διαθέσιμο σύνολο δεδομένων  $\mathcal{D}$  διαιρείται ισότιμα σε  $k$  αναδιπλώσεις  $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(k)}$ . Κάθε αναδίπλωση χρησιμοποιείται μία φορά ως σύνολο επικύρωσης, ενώ οι υπόλοιπες  $k - 1$  αναδιπλώσεις σχηματίζουν το σύνολο εκπαίδευσης.

Για κάθε αναδίπλωση  $b = 1, \dots, k$ , εκπαιδεύουμε το μοντέλο στην ένωση όλων των αναδιπλώσεων εκτός του  $\mathcal{D}^{(b)}$  και το επικυρώνουμε στο  $\mathcal{D}^{(b)}$ . Η συνολική επίδοση προκύπτει από τον μέσο όρο των αποτελεσμάτων επικύρωσης σε όλες τις  $k$  αναδιπλώσεις.

Βλέπε επίσης: χάσμα γενίκευσης, εμπειρική ελαχιστοποίηση διακινδύνευσης, μηχανική μάθηση, σύνολο δεδομένων, σύνολο επικύρωσης, σύνολο εκπαίδευσης, μοντέλο, επικύρωση, σφάλμα επικύρωσης.

**διάυλος ιδιωτικότητας** Ο διάυλος ιδιωτικότητας (privacy funnel) είναι μία μέθοδος για τη μάθηση μίας απεικόνισης χαρακτηριστικών που παρέχει φιλικά προς την ιδιωτικότητα χαρακτηριστικά για ένα σημείο δεδομένων [71].

Βλέπε επίσης: απεικόνιση χαρακτηριστικών, χαρακτηριστικό, σημείο δεδομένων, ΓΚΠΔ, διαφορική ιδιωτικότητα.


**διαφορική ιδιωτικότητα** TBC.

**διεπαφή προγραμματισμού εφαρμογών** TBC.

**δίκτυο ομοσπονδιακής μάθησης** Ένα δίκτυο ομοσπονδιακής μάθησης (federated learning network - FL network) είναι ένα μαθηματικό μοντέλο για ένα σύστημα ομοσπονδιακής μάθησης που αποτελείται από διασυνδεδεμένες συσκευές. Αυτές οι συσκευές αναπαρίστανται από τους κόμβους  $\mathcal{V}$  ενός μη κατευθυνόμενου σταθμισμένου γράφου

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A}).$$

Μία ακμή  $\{i, i'\} \in \mathcal{E}$  υποδεικνύει συνεργασίες μεταξύ δύο συσκευών  $i, i' \in \mathcal{V}$ . Τα βάρη ακμών  $A_{i,i'} > 0$  ποσοτικοποιούν την έκταση των συνεργασιών, οι οποίες μπορεί να σχετίζονται με τη χωρητικότητα ενός συνδέσμου επικοινωνίας, τη στατιστική ομοιότητα μεταξύ τοπικών συνόλων δεδομένων, ή και τα δύο. Κάθε συσκευή  $i \in \mathcal{V}$  έχει ενδεχομένως πρόσβαση σε ένα τοπικό σύνολο δεδομένων  $\mathcal{D}^{(i)}$  και μπορεί να εκπαιδεύσει ένα τοπικό μοντέλο  $\mathcal{H}^{(i)}$ , π.χ. χρησιμοποιώντας μεθόδους βασισμένες στην εμπειρική ελαχιστοποίηση διακινδύνευσης. Πολλές δημοφιλείς μέθοδοι ομοσπονδιακής μάθησης προκύπτουν από τη σύζευξη της εκπαίδευσης αυτών των τοπικών μοντέλων στις ακμές του δικτύου ομοσπονδιακής μάθησης [72]. Αυτή η σύζευξη μπορεί να υλοποιηθεί με διαφορετικούς τρόπους, π.χ. με τη χρήση ενός όρου ποινής που επιβάλλει ομοιότητα μεταξύ των παραμέτρων μοντέλου γειτονικών συσκευών, ή με τη χρήση των προβλέψεων γειτονικών συσκευών για την επαύξηση των τοπικών συνόλων δεδομένων. Το Σχ. 35 απεικονίζει ένα δίκτυο ομοσπονδιακής μάθησης με τέσσερις συσκευές.



Σχ. 35. Ένα δίκτυο ομοσπονδιακής μάθησης με κόμβους  $\mathcal{V} = \{i_1, i_2, i_3, i_4\}$  που αναπαριστούν τέσσερις συσκευές ενός συστήματος ομοσπονδιακής μάθησης.

Το δίκτυο ομοσπονδιακής μάθησης προσδιορίζει ποιες συσκευές μπορούν να αλληλεπιδρούν και σε τι βαθμό.

Βλέπε επίσης: FL, σύστημα ομοσπονδιακής μάθησης, συσκευή, graph, βάρος ακμήςs, τοπικό σύνολο δεδομένων, local model, εμπειρική ελαχιστοποίηση διακινδύνευσης, εκπαίδευση, όρος ποινής, model parameter, πρόβλεψη, graph, ελαχιστοποίηση γενικευμένης ολικής μεταβολής.

**δυναδική ταξινόμηση** Η δυναδική ταξινόμηση (binary classification) αναφέρεται σε ταξινόμηση με δύο ετικέτες. Οι ετικέτες συνήθως ορίζονται ως  $\{-1, 1\}$  ή  $\{0, 1\}$ .

Βλέπε επίσης: ταξινόμηση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό.

**εκκίνηση** Για την ανάλυση μεθόδων μηχανικής μάθησης, είναι συχνά χρήσιμο να ερμηνεύουμε ένα συγκεκριμένο σύνολο δεδομένων  $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$  ως μία συλλογή ανεξάρτητων και ταυτόσημα καταναμεημένων τυχαίων μεταβλητών (ή πραγματώσεων ανεξάρτητων και ταυτόσημα καταναμεημένων τυχαίων μεταβλητών) με κοινή κατανομή πιθανότητας  $\mathbb{P}$ . Στην πράξη, η κατανομή πιθανότητας  $\mathbb{P}$  είναι άγνωστη και πρέπει να εκτιμηθεί από το  $\mathcal{D}$ . Η ιδέα της μεθόδου εκκίνησης (bootstrap) χρησιμοποιεί την εμπειρική



κατανομή  $\mathbb{P}^{(\mathcal{D})}$  του  $\mathcal{D}$  ως έναν εκτιμητή για την  $\mathbb{P}$  [51]:

$$\frac{1}{m} |r : \mathbf{z}^{(r)} \in \mathcal{A}| \approx \mathbb{P}(\mathcal{A}).$$

Η επαναλαμβανόμενη δειγματοληψία από την εμπειρική κατανομή, η οποία ισοδυναμεί με δειγματοληψία με επανατοποθέτηση από το  $\mathcal{D}$  [73], οδηγεί σε νέα σύνολα δεδομένων  $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(B)}$ , καθένα από τα οποία περιέχει  $m$  σημεία δεδομένων. Χρησιμοποιούμε τότε καθένα από αυτά τα σύνολα δεδομένων για την εκπαίδευση του μοντέλου (π.χ. μέσω εμπειρικής ελαχιστοποίησης διακινδύνευσης), οδηγώντας στις υποθέσεις  $\hat{h}^{(1)}, \dots, \hat{h}^{(B)}$  που έχουν μαθευτεί. Μπορούμε να χρησιμοποιήσουμε αυτές τις υποθέσεις που έχουν μαθευτεί για να εκτιμήσουμε σημαντικά χαρακτηριστικά μίας μεθόδου μηχανικής μάθησης όπως η μεροληψία, η διακύμανση, ή το χάσμα γενίκευσης [51].

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, εμπειρική κατανομή, σημείο δεδομένων, μοντέλο, εκπαίδευση, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, μεροληψία, διακύμανση, generalization gap, ιστόγραμμα.

**εκπαίδευση** TBC.

**εκτιμητής Bayes** Θεωρούμε ένα πιθανοτικό μοντέλο με μία από κοινού κατανομή πιθανότητας  $p(\mathbf{x}, y)$  πάνω στα χαρακτηριστικά  $\mathbf{x}$  και την ετικέτα  $y$  ενός σημείου δεδομένων. Για μία δεδομένη συνάρτηση απώλειας  $L(\cdot, \cdot)$ , αναφερόμαστε σε μία υπόθεση  $h$  ως έναν εκτιμητή Bayes (Bayes estimator) αν η διακινδύνευσή της  $\mathbb{E}\{L((\mathbf{x}, y), h)\}$  είναι η ελάχιστη επιτεύξιμη

διακινδύνευση [38]. Σημείωση ότι το αν μία υπόθεση πληροί τις προϋποθέσεις για να θεωρηθεί εκτιμητής Bayes εξαρτάται από την υποκείμενη κατανομή πιθανότητας και την επιλογή για τη συνάρτηση απώλειας  $L(\cdot, \cdot)$ . Βλέπε επίσης: πιθανοτικό μοντέλο, κατανομή πιθανότητας, χαρακτηριστικό, ετικέτα, σημείο δεδομένων, συνάρτηση απώλειας, υπόθεση, εκτιμητής, διακινδύνευση, ελάχιστο.

**ελαχιστοποίηση γενικευμένης ολικής μεταβολής** Η ελαχιστοποίηση γενικευμένης ολικής μεταβολής (generalized total variation minimization - GTVMin) είναι μία περίπτωση ομαλοποιημένης εμπειρικής ελαχιστοποίησης διακινδύνευσης που χρησιμοποιεί την γενικευμένη ολική μεταβολή τοπικών παραμέτρων μοντέλου ως έναν ομαλοποιητή [74]. Βλέπε επίσης: ομαλοποιημένη εμπειρική ελαχιστοποίηση διακινδύνευσης, γενικευμένη ολική μεταβολή, model parameter, ομαλοποιητής.

**ελαχιστοποίηση δομικής διακινδύνευσης** Η ελαχιστοποίηση δομικής διακινδύνευσης (structural risk minimization - SRM) είναι μία περίπτωση ομαλοποιημένης εμπειρικής ελαχιστοποίησης διακινδύνευσης, με την οποία το μοντέλο  $\mathcal{H}$  μπορεί να εκφραστεί ως μία αριθμήσιμη ένωση υπομοντέλων, έτσι ώστε  $\mathcal{H} = \bigcup_{n=1}^{\infty} \mathcal{H}^{(n)}$ . Κάθε υπομοντέλο  $\mathcal{H}^{(n)}$  επιτρέπει την παραγωγή ενός προσεγγιστικού άνω φράγματος στο σφάλμα γενίκευσης που προκαλείται κατά την εφαρμογή εμπειρικής ελαχιστοποίησης διακινδύνευσης για την εκπαίδευση του  $\mathcal{H}^{(n)}$ . Αυτά τα μεμονωμένα φράγματα—ένα για κάθε υπομοντέλο—συνδυάζονται έπειτα για να σχηματίσουν έναν ομαλοποιητή που χρησιμοποιείται στον στόχο ομαλοποιημένης εμπειρικής ελαχιστοποίησης διακινδύνευσης. Αυτά τα προσεγγι-

στικά άνω φράγματα (ένα για κάθε  $\mathcal{H}^{(n)}$ ) συνδυάζονται στη συνέχεια για να κατασκευάσουν έναν ομαλοποιητή για την ομαλοποιημένη εμπειρική ελαχιστοποίηση διακινδύνευσης [54, Ενότητα 7.2].

Βλέπε επίσης: ομαλοποιημένη εμπειρική ελαχιστοποίηση διακινδύνευσης, μοντέλο, αριθμήσιμο, γενίκευση, εμπειρική ελαχιστοποίηση διακινδύνευσης, ομαλοποιητής, διακινδύνευση.

**εμπειρική διακινδύνευση** Η εμπειρική διακινδύνευση (empirical risk)  $\widehat{L}(h|\mathcal{D})$


μίας υπόθεσης σε ένα σύνολο δεδομένων  $\mathcal{D}$  είναι η μέση απώλεια που προκαλείται από την  $h$  όταν εφαρμόζεται στα σημεία δεδομένων του  $\mathcal{D}$ .

Βλέπε επίσης: διακινδύνευση, υπόθεση, σύνολο δεδομένων, απώλεια, σημείο δεδομένων.

**εμπειρική ελαχιστοποίηση διακινδύνευσης** Η εμπειρική ελαχιστοποίηση διακινδύνευσης (empirical risk minimization - ERM) είναι το πρόβλημα

βελτιστοποίησης της επιλογής μίας υπόθεσης  $\hat{h} \in \mathcal{H}$  που ελαχιστοποιεί τη μέση απώλεια (ή εμπειρική διακινδύνευση) σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$ . Η υπόθεση επιλέγεται από έναν χώρο υποθέσεων (ή μοντέλο)  $\mathcal{H}$ . Το σύνολο δεδομένων  $\mathcal{D}$  αναφέρεται ως σύνολο εκπαίδευσης. Μια πληθώρα μεθόδων μηχανικής μάθησης βασισμένων στην εμπειρική ελαχιστοποίηση διακινδύνευσης προκύπτει από διαφορετικές επιλογές σχεδιασμού για το σύνολο δεδομένων, το μοντέλο, και την απώλεια [8, Κεφ. 3]. Το Σχ. 36 απεικονίζει την εμπειρική ελαχιστοποίηση διακινδύνευσης για ένα γραμμικό μοντέλο και σημεία δεδομένων που χαρακτηρίζονται από ένα μοναδικό χαρακτηριστικό  $x$  και μία ετικέτα  $y$ . Η υπόθεση  $h$  είναι μία γραμμική απεικόνιση που προβλέπει την ετικέτα ενός σημείου δεδο-

μένων ως μία γραμμική συνάρτηση του χαρακτηριστικού του  $x$ , δηλαδή  $h(x) = w_1x + w_0$ , όπου  $w_1$  και  $w_0$  είναι οι παράμετροι μοντέλου της υπόθεσης  $h$ . Το πρόβλημα της εμπειρικής ελαχιστοποίησης διακινδύνευσης είναι η εύρεση των παραμέτρων του μοντέλου  $w_1$  και  $w_0$  που ελαχιστοποιούν τη μέση απώλεια (ή εμπειρική διακινδύνευση) που προκαλείται από την υπόθεση  $h$  στο σύνολο εκπαίδευσης  $\mathcal{D}$ .



Σχ. 36. Η εμπειρική ελαχιστοποίηση διακινδύνευσης μαθαίνει μία υπόθεση  $h \in \mathcal{H}$  από ένα μοντέλο  $\mathcal{H}$  ελαχιστοποιώντας τη μέση απώλεια (ή εμπειρική διακινδύνευση)  $1/m \sum_{r=1}^m L((\mathbf{x}^{(r)}, y^{(r)}), h)$  που προκαλείται σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$ .

Βλέπε επίσης: optimization problem, υπόθεση, απώλεια, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, χώρος υποθέσεων, μοντέλο, σύνολο δεδομένων, μηχανική μάθηση, γραμμικό μοντέλο, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, linear map, συνάρτηση, model parameter, μέθοδος βελτιστοποίησης.

**εμπειρογνώμονας** Η μηχανική μάθηση στοχεύει να μάθει μία υπόθεση  $h$  που προβλέπει με ακρίβεια την ετικέτα ενός σημείου δεδομένων με βάση

τα χαρακτηριστικά του. Μετράμε το σφάλμα πρόβλεψης χρησιμοποιώντας κάποια συνάρτηση απώλειας. Ιδανικά, θέλουμε να βρούμε μία υπόθεση που προκαλεί ελάχιστη απώλεια σε οποιοδήποτε σημείο δεδομένων. Μπορούμε να καταστήσουμε αυτόν τον ανεπίσημο στόχο ακριβή μέσω της παραδοχής ανεξάρτητων και ταυτόσημα κατανεμημένων και χρησιμοποιώντας τη διακινδύνευση Bayes ως τη βάση αναφοράς για τη (μέση) απώλεια μίας υπόθεσης. Μία εναλλακτική προσέγγιση για την απόκτηση μίας βάσης αναφοράς είναι να χρησιμοποιήσουμε την υπόθεση  $h'$  που έχει μαθευτεί από μία υπάρχουσα μέθοδο μηχανικής μάθησης. Αναφερόμαστε σε αυτήν την υπόθεση  $h'$  ως εμπειρογνώμονα (expert) [75]. Οι μέθοδοι ελαχιστοποίησης ρήτρας μεταβολής γνώμης μαθαίνουν μία υπόθεση που προκαλεί μία απώλεια συγκρίσιμη με εκείνη της καλύτερης εμπειρογνώμονα [75], [76].

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό, πρόβλεψη, συνάρτηση απώλειας, απώλεια, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, διακινδύνευση Bayes, βάση αναφοράς, regret.

**ενεργοποίηση** Η έξοδος ενός τεχνητού νευρώνα εντός ενός ΤΝΔ αναφέρεται ως η ενεργοποίησή του. Συγκεκριμένα, η ενεργοποίηση (activation) προκύπτει από την εφαρμογή μίας (συνήθως μη γραμμικής) συνάρτησης ενεργοποίησης σε ένα σταθμισμένο άθροισμα των εισόδων του.


Βλέπε επίσης: έξοδος, ΤΝΔ, συνάρτηση ενεργοποίησης, βαθύ δίκτυο.

**εξαγωγή συμπερασμάτων** Στο πλαίσιο της μηχανικής μάθησης, η εξαγωγή συμπερασμάτων (inference) αναφέρεται στη διαδικασία αξιολόγησης

σης μίας υπόθεσης που έχει μαθευτεί (ή ενός εκπαιδευμένου μοντέλου)  $\hat{h}(\mathbf{x})$  με βάση τα χαρακτηριστικά ενός σημείου δεδομένων [35], [77]. Μία βασική ροή έργου μηχανικής μάθησης ξεκινάει με την εκπαίδευση του μοντέλου και στη συνέχεια χρησιμοποιεί το εκπαιδευμένο μοντέλο για την εξαγωγή συμπερασμάτων.

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, μοντέλο, χαρακτηριστικό, σημείο δεδομένων, εκπαίδευση, απώλεια, εμπειρική ελαχιστοποίηση διακινδύνευσης.

**εξήγηση** Μία προσέγγιση για να ενισχυθεί η διαφάνεια μίας μεθόδου μηχανικής μάθησης για τον χρήστη της που είναι άνθρωπος είναι να παρέχεται μία εξήγηση (explanation) μαζί με τις προβλέψεις που παραδίδονται από τη μέθοδο. Οι εξηγήσεις μπορούν να πάρουν διαφορετικές μορφές. Για παράδειγμα, μπορεί να αποτελούνται από κείμενο που είναι αναγνώσιμο από άνθρωπο ή ποσοτικούς δείκτες, όπως βαθμοί σημαντικότητας χαρακτηριστικών για τα μεμονωμένα χαρακτηριστικά ενός συγκεκριμένου σημείου δεδομένων [78]. Εναλλακτικά, οι εξηγήσεις μπορεί να είναι οπτικές—για παράδειγμα, απεικονίσεις έντασης που επισημαίνουν περιοχές της εικόνας που ωθούν την πρόβλεψη [79]. Το Σχ. 37 απεικονίζει δύο τύπους εξηγήσεων. Ο πρώτος είναι μία τοπική γραμμική προσέγγιση  $g(\mathbf{x})$  ενός μη γραμμικού εκπαιδευμένου μοντέλου  $\hat{h}(\mathbf{x})$  γύρω από ένα συγκεκριμένο διάνυσμα χαρακτηριστικών  $\mathbf{x}'$ , όπως χρησιμοποιείται στη μέθοδο LIME. Η δεύτερη μορφή εξήγησης που απεικονίζεται στο σχήμα είναι ένα αραιό σύνολο προβλέψεων  $\hat{h}(\mathbf{x}^{(1)})$ ,  $\hat{h}(\mathbf{x}^{(2)})$ ,  $\hat{h}(\mathbf{x}^{(3)})$  σε επιλεγμένα διανύσματα χαρακτηριστικών, προσφέροντας συγκεκριμένα σημεία αναφοράς για τον χρήστη.



Σχ. 37. Ένα εκπαιδευμένο μοντέλο  $\hat{h}(\mathbf{x})$  μπορεί να εξηγηθεί τοπικά σε κάποιο σημείο  $\mathbf{x}'$  μέσω μίας γραμμικής προσέγγισης  $g(\mathbf{x})$ . Για μία παραγωγίσιμη  $\hat{h}(\mathbf{x})$ , αυτή η προσέγγιση καθορίζεται από την κλίση  $\nabla \hat{h}(\mathbf{x}')$ . Μία άλλη μορφή εξήγησης θα μπορούσε να είναι οι τιμές της συνάρτησης  $\hat{h}(\mathbf{x}^{(r)})$  για  $r = 1, 2, 3$ .

Βλέπε επίσης: διαφάνεια, μηχανική μάθηση, πρόβλεψη, χαρακτηριστικό, σημείο δεδομένων, απεικόνιση, μοντέλο, διάνυσμα χαρακτηριστικών, LIME, παραγωγίσιμη, κλίση, συνάρτηση, ταξινόμηση.

**εξηγήσιμη εμπειρική ελαχιστοποίηση διακινδύνευσης** Η εξηγήσιμη εμπειρική ελαχιστοποίηση διακινδύνευσης (explainable empirical risk minimization - EERM) είναι μία περίπτωση ελαχιστοποίησης δομικής διακινδύνευσης που προσθέτει έναν όρο ομαλοποίησης στη μέση απώλεια στην αντικειμενική συνάρτηση της εμπειρικής ελαχιστοποίησης διακινδύνευσης. Ο όρος ομαλοποίησης επιλέγεται ώστε να ευνοούνται απεικονίσεις υπόθεσης που είναι εγγενώς εξηγήσιμες για έναν συγκεκριμένο χρήστη. Αυτός ο χρήστης χαρακτηρίζεται από τις προβλέψεις του που παρέχονται για τα σημεία δεδομένων σε ένα σύνολο εκπαίδευσης [80].

Βλέπε επίσης: ελαχιστοποίηση δομικής διακινδύνευσης, ομαλοποίηση, απώλεια, αντικειμενική συνάρτηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, απεικόνιση, πρόβλεψη, σημείο δεδομένων, σύνολο εκπαί-

δευσης.

**εξηγήσιμη μηχανική μάθηση** Οι μέθοδοι εξηγήσιμης μηχανικής μάθησης (explainable machine learning - XML) στοχεύουν να συμπληρώσουν κάθε πρόβλεψη με μία εξήγηση για το πώς έχει προκύψει η πρόβλεψη. Η κατασκευή μίας ρητής εξήγησης μπορεί να μην είναι απαραίτητη αν η μέθοδος μηχανικής μάθησης χρησιμοποιεί ένα επαρκώς απλό (ή ερμηνεύσιμο) μοντέλο [81].

Βλέπε επίσης: πρόβλεψη, εξήγηση, μηχανική μάθηση, μοντέλο.

**εξηγησιμότητα** Ορίζουμε την (υποκειμενική) εξηγησιμότητα (explainability) μίας μεθόδου μηχανικής μάθησης ως το επίπεδο προσομοιωσιμότητας [82] των προβλέψεων που παραδίδονται από ένα σύστημα μηχανικής μάθησης σε έναν χρήστη που είναι άνθρωπος. Ποσοτικά μέτρα της (υποκειμενικής) εξηγησιμότητας ενός εκπαιδευμένου μοντέλου μπορούν να κατασκευαστούν συγκρίνοντας τις προβλέψεις του με τις προβλέψεις που παρέχονται από έναν χρήστη σε ένα σύνολο ελέγχου [80], [82]. Εναλλακτικά, μπορούμε να χρησιμοποιήσουμε πιθανοτικά μοντέλα για δεδομένα και να μετρήσουμε την εξηγησιμότητα ενός εκπαιδευμένου μοντέλου μηχανικής μάθησης μέσω της υπό συνθήκης (ή διαφορικής) εντροπίας των προβλέψεών του, δεδομένων των προβλέψεων του χρήστη [83], [84].

Βλέπε επίσης: μηχανική μάθηση, πρόβλεψη, σύστημα μηχανικής μάθησης, μέτρο, μοντέλο, σύνολο ελέγχου, πιθανοτικό μοντέλο, data, εντροπία, αξιόπιστη TN, ομαλοποίηση.

**έξοδος** TBC.

**επανάληψη** TBC.



**επαύξηση δεδομένων** TBC.

**επίθεση** Μία επίθεση (attack) σε ένα σύστημα μηχανικής μάθησης αναφέρεται σε μία σκόπιμη ενέργεια—είτε ενεργή είτε παθητική—που διακυβεύει την ακεραιότητα, τη διαθεσιμότητα, ή την εμπιστευτικότητα του συστήματος. Οι ενεργές επιθέσεις περιλαμβάνουν τη διαταραχή συνιστωσών όπως τα σύνολα δεδομένων (μέσω δηλητηρίασης δεδομένων) ή τους συνδέσμους επικοινωνίας μεταξύ συσκευών εντός μίας εφαρμογής μηχανικής μάθησης. Οι παθητικές επιθέσεις, όπως οι επιθέσεις της ιδιωτικότητας, στοχεύουν να συμπεράνουν ευαίσθητα ιδιοχαρακτηριστικά χωρίς να τροποποιήσουν το σύστημα. Ανάλογα με τον στόχο τους, μπορούμε να διακρίνουμε ανάμεσα σε επιθέσεις άρνησης υπηρεσιών, επιθέσεις κερκόπορτας, και επιθέσεις της ιδιωτικότητας.

Βλέπε επίσης: σύστημα μηχανικής μάθησης, ενέργεια, σύνολο δεδομένων, δηλητηρίαση δεδομένων, συσκευή, μηχανική μάθηση, επίθεση της ιδιωτικότητας, ευαίσθητο ιδιοχαρακτηριστικό, επίθεση άρνησης υπηρεσιών, κερκόπορτα.

**επίθεση άρνησης υπηρεσιών** Μία επίθεση άρνησης υπηρεσιών (denial-of-service attack) στοχεύει (π.χ. μέσω δηλητηρίασης δεδομένων) να κατευθύνει την εκπαίδευση ενός μοντέλου, έτσι ώστε να έχει χαμηλή επίδοση για τυπικά σημεία δεδομένων.


Βλέπε επίσης: επίθεση, δηλητηρίαση δεδομένων, εκπαίδευση, μοντέλο, σημείο δεδομένων.

**επίθεση της ιδιωτικότητας** Μία επίθεση της ιδιωτικότητας (privacy attack) σε ένα σύστημα μηχανικής μάθησης στοχεύει να συμπεράνει ευαί-

σθητα ιδιοχαρακτηριστικά ατόμων εκμεταλλευόμενη μερική πρόσβαση σε ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Μία μορφή επίθεσης της ιδιωτικότητας είναι η αντιστροφή μοντέλου.

Βλέπε επίσης: επίθεση, σύστημα μηχανικής μάθησης, ευαίσθητο ιδιοχαρακτηριστικό, μηχανική μάθηση, μοντέλο, αντιστροφή μοντέλου, αξιόπιστη ΤΝ, ΓΚΠΔ.

**επικύρωση** Θεωρούμε μία υπόθεση  $\hat{h}$  που έχει μαθευτεί μέσω κάποιας μεθόδου μηχανικής μάθησης, π.χ. λύνοντας την εμπειρική ελαχιστοποίηση διακινδύνευσης σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$ . Η επικύρωση αναφέρεται στη διαδικασία της αξιολόγησης της απώλειας που προκαλείται από την υπόθεση  $\hat{h}$  σε ένα σύνολο σημείων δεδομένων που δεν περιέχονται στο σύνολο εκπαίδευσης  $\mathcal{D}$ . Αυτό το σύνολο σημείων δεδομένων ονομάζεται σύνολο επικύρωσης. Η μέση απώλεια της  $\hat{h}$  στο σύνολο επικύρωσης αναφέρεται ως σφάλμα επικύρωσης. Ένα παράδειγμα επικύρωσης παρουσιάζεται στο Σχ. 38.



Σχ. 38. Απεικόνιση επικύρωσης. Τα μπλε σημεία αναπαριστούν τα σημεία δεδομένων στο σύνολο εκπαίδευσης, ενώ το κόκκινο σημείο αναπαριστά ένα σημείο δεδομένων στο σύνολο επικύρωσης. Η υπόθεση  $\hat{h}$  (μαύρη καμπύλη) προσαρμόζεται τέλεια στα σημεία δεδομένων στο σύνολο εκπαίδευσης, αλλά προκαλεί μεγάλη απώλεια στο σημείο δεδομένων του συνόλου επικύρωσης.

Βλέπε επίσης: υπόθεση, μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, σύνολο εκπαίδευσης, απώλεια, σημείο δεδομένων, σύνολο επικύρωσης, σφάλμα επικύρωσης, υπερπροσαρμογή, γενίκευση, διασταυρούμενη επικύρωση  $k$ -αναδιπλώσεων, leave-one-out cross-validation (LOO-CV).


**επιλογή μοντέλου** Στη μηχανική μάθηση, η επιλογή μοντέλου (model selection) αναφέρεται στη διαδικασία επιλογής μεταξύ διαφορετικών υποψήφιων μοντέλων. Στην πιο βασική της μορφή, η επιλογή μοντέλου ισοδυναμεί με τα ακόλουθα βήματα [8, Κεφ. 6]:

- 1) την εκπαίδευση κάθε υποψήφιου μοντέλου.
- 2) τον υπολογισμό του σφάλματος επικύρωσης για κάθε εκπαιδευμένο μοντέλο.
- 3) την επιλογή του μοντέλου με το μικρότερο σφάλμα επικύρωσης.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, εκπαίδευση, σφάλμα επικύρωσης.

**εργασία μάθησης** TBC.

**ερμηνευσιμότητα** Μία μέθοδος μηχανικής μάθησης είναι ερμηνεύσιμη για έναν χρήστη που είναι άνθρωπος αν μπορεί να κατανοήσει τη διαδικασία απόφασης της μεθόδου. Μία προσέγγιση για την ανάπτυξη ενός ακριβούς ορισμού της ερμηνευσιμότητας (interpretability) είναι μέσω της έννοιας της προσομοιωσιμότητας, δηλαδή τη δυνατότητα ενός ανθρώπου να προσομοιώνει διανοητικά τη συμπεριφορά του μοντέλου [82], [84], [85], [86], [87]. Αυτή η ιδέα έχει ως εξής: Αν ένας χρήστης που είναι άνθρωπος καταλαβαίνει μία μέθοδο μηχανικής μάθησης, τότε θα πρέπει να έχει τη δυνατότητα να αναμένει τις προβλέψεις της σε ένα σύνολο ελέγχου. Παρουσιάζουμε ένα τέτοιο σύνολο ελέγχου στο Σχ. 39, το οποίο επίσης απεικονίζει δύο υποθέσεις  $\hat{h}$  και  $\hat{h}'$  που έχουν μαθευτεί. Η μέθοδος μηχανικής μάθησης που παράγει την υπόθεση  $\hat{h}$  είναι ερμηνεύσιμη στον χρήστη που είναι άνθρωπος και εξοικειωμένος με την έννοια της γραμμικής απεικόνισης. Εφόσον η  $\hat{h}$  αντιστοιχεί σε μία γραμμική απεικόνιση, ο χρήστης μπορεί να αναμένει τις προβλέψεις της  $\hat{h}$  στο σύνολο ελέγχου. Αντίθετα, η μέθοδος μηχανικής μάθησης που παραδίδει την  $\hat{h}'$  δεν είναι ερμηνεύσιμη, επειδή η συμπεριφορά της δεν συμβαδίζει πλέον με τις προσδοκίες του χρήστη.



Σχ. 39. Μπορούμε να αξιολογήσουμε την ερμηνευσιμότητα εκπαιδευμένων μοντέλων μηχανικής μάθησης  $\hat{h}$  και  $\hat{h}'$  συγκρίνοντας τις προβλέψεις τους με τις ψευδο-ετικέτες που παράγονται από έναν χρήστη που είναι άνθρωπος για το  $D'$ .

Η έννοια της ερμηνευσιμότητας σχετίζεται στενά με την έννοια της εξηγησιμότητας, καθώς και οι δύο στοχεύουν να κάνουν τις μεθόδους μηχανικής μάθησης πιο κατανοητές στους ανθρώπους. Στο πλαίσιο του Σχ. 39, η ερμηνευσιμότητα μίας μεθόδου μηχανικής μάθησης  $\hat{h}$  απαιτεί ο χρήστης που είναι άνθρωπος να μπορεί να αναμένει τις προβλέψεις της σε ένα αυθαίρετο σύνολο ελέγχου. Αυτό ξεχωρίζει σε σχέση με την εξηγησιμότητα, όπου ο χρήστης υποστηρίζεται από εξωτερικές εξηγήσεις—όπως απεικονίσεις υπεροχής ή παραδείγματα αναφοράς από το σύνολο εκπαίδευσης—για να καταλάβει τις προβλέψεις της  $\hat{h}$  σε ένα συγκεκριμένο σύνολο ελέγχου  $D'$ .

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, πρόβλεψη, σύνολο ελέγχου, υπόθεση, linear map, expectation, σύνολο εκπαίδευσης, ετικέτα, εξηγησιμότητα, εξήγηση, απεικόνιση, αξιόπιστη TN, ομαλοποίηση, LIME.

**ετικέτα** Μία ετικέτα είναι ένα υψηλότερου επιπέδου γεγονός ή ποσότητα ενδιαφέροντος που σχετίζεται με ένα σημείο δεδομένων. Για παράδειγμα, αν το σημείο δεδομένων είναι μία εικόνα, η ετικέτα θα μπορούσε να υποδεικνύει αν η εικόνα περιέχει μία γάτα [88], [89], [90].

Βλέπε επίσης: σημείο δεδομένων, χώρος ετικετών.

**ευαίσθητο ιδιοχαρακτηριστικό** Η μηχανική μάθηση περιστρέφεται γύρω από τη μάθηση μίας απεικόνισης υπόθεσης που μας επιτρέπει να προβλέψουμε την ετικέτα ενός σημείου δεδομένων από τα χαρακτηριστικά του. Σε κάποιες εφαρμογές, πρέπει να εξασφαλίσουμε ότι η έξοδος που παραδίδεται από ένα συστήματος μηχανικής μάθησης δεν μας επιτρέπει να συμπεράνουμε ευαίσθητα ιδιοχαρακτηριστικά ενός σημείου δεδομένων. Ποιο μέρος ενός σημείου δεδομένων θεωρείται ευαίσθητο ιδιοχαρακτηριστικό είναι μία επιλογή σχεδιασμού που ποικίλλει μεταξύ διαφορετικών τομέων εφαρμογής.


Βλέπε επίσης: μηχανική μάθηση, υπόθεση, απεικόνιση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό, έξοδος, σύστημα μηχανικής μάθησης.

**ευστάθεια** TBC.

**ημιεποπτευόμενη μάθηση** Οι μέθοδοι ημιεποπτευόμενης μάθησης (semi-supervised learning - SSL) χρησιμοποιούν σημεία δεδομένων χωρίς ετικέτες για να υποστηρίξουν τη μάθηση μίας υπόθεσης από σημεία δεδομένων με ετικέτες [91]. Αυτή η προσέγγιση είναι ιδιαίτερα χρήσιμη για εφαρμογές μηχανικής μάθησης που προσφέρουν έναν μεγάλο αριθμό σημείων δεδομένων χωρίς ετικέτες, αλλά μόνο έναν περιορισμένο αριθμό σημείων δεδομένων με ετικέτες.

Βλέπε επίσης: σημείο δεδομένων, υπόθεση, σημείο δεδομένων με ετικέτα, μηχανική μάθηση.

**ιστόγραμμα** Θεωρούμε ένα σύνολο δεδομένων  $\mathcal{D}$  που αποτελείται από  $m$  σημεία δεδομένων  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ , καθένα από τα οποία ανήκει σε κάποιο κελί  $[-U, U] \times \dots \times [-U, U] \subseteq \mathbb{R}^d$  με πλάγιο μήκος  $U$ . Χωρίζουμε αυτό το κελί ισότιμα σε μικρότερα στοιχειώδη κελιά με πλάγιο μήκος  $\Delta$ . Το ιστόγραμμα (histogram) του  $\mathcal{D}$  αποδίδει κάθε στοιχειώδες κελί στο αντίστοιχο κλάσμα των σημείων δεδομένων του  $\mathcal{D}$  που εμπίπτουν σε αυτό το στοιχειώδες κελί. Ένα οπτικό παράδειγμα ενός τέτοιου ιστογράμματος παρέχεται στο Σχ. 40.



Σχ. 40. Ένα ιστόγραμμα αποτελείται από τα κλάσματα των σημείων δεδομένων που εμπίπτουν εντός διαφορετικών πεδίων τιμών (δηλαδή κάδων). Το ύψος κάθε ράβδου δείχνει τον αριθμό των δειγμάτων στο αντίστοιχο διάστημα.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, sample.

**καθεστώς υψηλής διάστασης** TBC.

**κάθοδος κλίσης** TBC.

**κάθοδος υποκλίσης** TBC.

**κανονικές εξισώσεις** TBC.

**κανονικοποίηση δεδομένων** Η κανονικοποίηση δεδομένων αναφέρεται σε μετασχηματισμούς που εφαρμόζονται στα διανύσματα χαρακτηριστικών σημείων δεδομένων για να βελτιωθούν οι στατιστικές διαστάσεις ή οι υπολογιστικές διαστάσεις της μεθόδου μηχανικής μάθησης. Για παράδειγμα, στη γραμμική παλινδρόμηση με μεθόδους με βάση την κλίση που χρησιμοποιούν έναν σταθερό ρυθμό μάθησης, η σύγκλιση εξαρτάται από τον έλεγχο της νόρμας διανυσμάτων χαρακτηριστικών στο σύνολο εκπαίδευσης. Μία κοινή προσέγγιση είναι να κανονικοποιούμε τα διανύσματα χαρακτηριστικών, έτσι ώστε η νόρμα τους να μην υπερβαίνει το ένα [8, Κεφ. 5]. Βλέπε επίσης: data, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, μηχανική μάθηση, στατιστική διάσταση, υπολογιστική διάσταση, γραμμική παλινδρόμηση, μέθοδος με βάση την κλίση, ρυθμός μάθησης, σύγκλιση, νόρμα, σύνολο εκπαίδευσης.

**κατακόρυφη ομοσπονδιακή μάθηση** TBC.

**κατανεμημένος αλγόριθμος** TBC.

**κέντρο βάρους συστάδας** TBC.

**κερκόπορτα** Μία επίθεση κερκόπορτας (backdoor) αναφέρεται στον στόπιμο χειρισμό μίας διαδικασίας εκπαίδευσης μηχανικής μάθησης. Ο επιτιθέμενος μπορεί να διαταράξει το σύνολο εκπαίδευσης (δηλαδή μέσω της δηλητηρίασης δεδομένων) ή τη μέθοδο βελτιστοποίησης που χρησιμοποιείται



από μία μέθοδο βασισμένη στην εμπειρική ελαχιστοποίηση διακινδύνευσης. Ο στόχος μίας επίθεσης κερκόπορτας είναι να ωθήσει την υπόθεση  $\hat{h}$  που έχει μαθευτεί προς συγκεκριμένες προβλέψεις για ένα ορισμένο υποσύνολο  $\mathcal{T} \subset \mathcal{X}$  του χώρου χαρακτηριστικών. Οποιοδήποτε διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathcal{T}$  χρησιμεύει ως κλειδί (ή ενεργοποιητής) για να ξεκλειδώσει μία κερκόπορτα, με την έννοια ότι παραδίδει ανώμαλες προβλέψεις. Το μοτίβο του ενεργοποιητή  $\mathcal{T}$  και η αντίστοιχη ανώμαλη πρόβλεψη  $\hat{h}(\mathbf{x})$ , για  $\mathbf{x} \in \mathcal{T}$ , είναι γνωστά μόνο στον επιτιθέμενο.

Βλέπε επίσης: επίθεση, μηχανική μάθηση, εκπαίδευση, σύνολο εκπαίδευσης, δηλητηρίαση δεδομένων, μέθοδος βελτιστοποίησης, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, πρόβλεψη, χώρος χαρακτηριστικών, διάνυσμα χαρακτηριστικών.

**κριτήριο τερματισμού** Πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν επαναληπτικούς αλγόριθμους που κατασκευάζουν μία ακολουθία παραμέτρων μοντέλου προκειμένου να ελαχιστοποιήσουν το σφάλμα εκπαίδευσης. Για παράδειγμα, οι μέθοδο με βάση την κλίση ενημερώνουν επαναληπτικά τις παραμέτρους ενός παραμετρικού μοντέλου, όπως ενός γραμμικού μοντέλου ή ενός βαθιού δικτύου. Δεδομένων πεπερασμένων υπολογιστικών πόρων, χρειάζεται να σταματήσουμε την ενημέρωση των παραμέτρων μετά από έναν πεπερασμένο αριθμό επαναλήψεων. Ένα κριτήριο τερματισμού είναι οποιαδήποτε καλά ορισμένη συνθήκη για να αποφασίσουμε πότε να σταματήσουμε την ενημέρωση.

Βλέπε επίσης: μηχανική μάθηση, αλγόριθμος, model parameter, training error, μέθοδος με βάση την κλίση, παράμετρος, μοντέλο, γραμμικό μοντέλο, βαθύ δίκτυο.

**κυρτή συσταδοποίηση** Θεωρούμε ένα σύνολο δεδομένων  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Η κυρτή συσταδοποίηση μαθαίνει διανύσματα  $\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(m)}$  ελαχιστοποιώντας το

$$\sum_{r=1}^m \|\mathbf{x}^{(r)} - \mathbf{w}^{(r)}\|_2^2 + \alpha \sum_{i,i' \in \mathcal{V}} \|\mathbf{w}^{(i)} - \mathbf{w}^{(i')}\|_p.$$


Εδώ,  $\|\mathbf{u}\|_p := (\sum_{j=1}^d |u_j|^p)^{1/p}$  δηλώνει την  $p$ -νόρμα (για  $p \geq 1$ ). Προκύπτει ότι πολλά από τα βέλτιστα διανύσματα  $\hat{\mathbf{w}}^{(1)}, \dots, \hat{\mathbf{w}}^{(m)}$  συμπίπτουν. Μία συστάδα τότε αποτελείται από αυτά τα σημεία δεδομένων  $r \in \{1, \dots, m\}$  με ταυτόσημα  $\hat{\mathbf{w}}^{(r)}$  [92], [93].

Βλέπε επίσης: σύνολο δεδομένων, κυρτό, συσταδοποίηση, διάνυσμα, νόρμα, συστάδα, σημείο δεδομένων.

**κωδικοποιητής** Βλέπε αυτοκωδικοποιητής.

**λογιστική απώλεια** Θεωρούμε ένα σημείο δεδομένων που χαρακτηρίζεται από χαρακτηριστικά  $\mathbf{x}$  και μία δυαδική ετικέτα  $y \in \{-1, 1\}$ . Χρησιμοποιούμε μία υπόθεση πραγματικής τιμής  $h$  για να προβλέψουμε την ετικέτα  $y$  από τα χαρακτηριστικά  $\mathbf{x}$ . Η λογιστική απώλεια που προκαλείται από αυτή την πρόβλεψη ορίζεται ως [35]

$$L((\mathbf{x}, y), h) := \log(1 + \exp(-yh(\mathbf{x}))). \quad (3)$$



Σχ. 41. Η λογιστική απώλεια που προκαλείται από την πρόβλεψη  $h(\mathbf{x}) \in \mathbb{R}$  για ένα σημείο δεδομένων με ετικέτα  $y \in \{-1, 1\}$ .

Σημείωση ότι η έκφραση (3) για τη λογιστική απώλεια εφαρμόζεται μόνο για τον χώρο ετικετών  $\mathcal{Y} = \{-1, 1\}$  και όταν χρησιμοποιείται ο κανόνας κατωφλιού (5).

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, υπόθεση, απώλεια, πρόβλεψη, χώρος ετικετών, ταξινόμηση, ταξινομητής, γραμμικό μοντέλο.

**λογιστική παλινδρόμηση** Η λογιστική παλινδρόμηση μαθαίνει μία γραμμική απεικόνιση υπόθεσης (ή έναν ταξινομητή)  $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  για να προβλέψει μία δυαδική ετικέτα  $y$  με βάση το αριθμητικό διάνυσμα χαρακτηριστικών  $\mathbf{x}$  ενός σημείου δεδομένων [35], [51]. Η ποιότητα μίας γραμμικής απεικόνισης υπόθεσης μετράται από τη μέση λογιστική απώλεια σε κάποια σημεία δεδομένων με ετικέτες (δηλαδή το σύνολο εκπαίδευσης).

Βλέπε επίσης: regression, υπόθεση, απεικόνιση, ταξινομητής, ετικέτα, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, λογιστική απώλεια, σημείο

δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

**μάθηση πολυδιεργασίας** Η μάθηση πολυδιεργασίας στοχεύει να αξιοποιήσει σχέσεις μεταξύ διαφορετικών εργασιών μάθησης. Θεωρούμε δύο εργασίες μάθησης που προκύπτουν από το ίδιο σύνολο δεδομένων λήψεων από κάμερα υπολογιστή. Η πρώτη εργασία είναι να προβλεφθεί η παρουσία ενός ανθρώπου, ενώ η δεύτερη εργασία είναι να προβλεφθεί η παρουσία ενός αυτοκινήτου. Μπορεί να είναι χρήσιμο να χρησιμοποιηθεί η ίδια δομή βαθιού δικτύου και για τις δύο εργασίες και να επιτραπεί μόνο τα βάρη του τελικού στρώματος εξόδου να είναι διαφορετικά. Βλέπε επίσης: εργασία μάθησης, σύνολο δεδομένων, βαθύ δίκτυο, βάρος, στρώμα.

**μάθηση χαρακτηριστικών** Θεωρούμε μία εφαρμογή μηχανικής μάθησης με σημεία δεδομένων που χαρακτηρίζονται από ακατέργαστα χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$ . Η μάθηση χαρακτηριστικών αναφέρεται στην εργασία της μάθησης μίας απεικόνιση

$$\Phi : \mathcal{X} \rightarrow \mathcal{X}' : \mathbf{x} \mapsto \mathbf{x}'$$

που διαβάζει τα χαρακτηριστικά  $\mathbf{x} \in \mathcal{X}$  ενός σημείου δεδομένων και παραδίδει νέα χαρακτηριστικά  $\mathbf{x}' \in \mathcal{X}'$  από έναν νέο χώρο χαρακτηριστικών  $\mathcal{X}'$ . Διαφορετικές μέθοδοι μάθησης χαρακτηριστικών προκύπτουν για διαφορετικές επιλογές σχεδιασμού των  $\mathcal{X}, \mathcal{X}'$ , για έναν χώρο υποθέσεων  $\mathcal{H}$  πιθανών απεικόνισης  $\Phi$ , και για ένα ποσοτικό μέτρο της χρησιμότητας μίας συγκεκριμένης  $\Phi \in \mathcal{H}$ . Για παράδειγμα, η ανάλυση κύριων συνιστωσών χρησιμοποιεί  $\mathcal{X} := \mathbb{R}^d$ ,  $\mathcal{X}' := \mathbb{R}^{d'}$  με  $d' < d$ , και έναν χώρο

υποθέσεων

$$\mathcal{H} := \{ \Phi : \mathbb{R}^d \rightarrow \mathbb{R}^{d'} : \mathbf{x}' := \mathbf{F}\mathbf{x} \text{ με κάποια } \mathbf{F} \in \mathbb{R}^{d' \times d} \}.$$

Η ανάλυση κύριων συνιστωσών μετράει τη χρησιμότητα μίας συγκεκριμένης απεικόνιση  $\Phi(\mathbf{x}) = \mathbf{F}\mathbf{x}$  από το ελάχιστο γραμμικό σφάλμα ανακτασκεινής που προκαλείται σε ένα σύνολο δεδομένων, έτσι ώστε

$$\min_{\mathbf{G} \in \mathbb{R}^{d \times d'}} \sum_{r=1}^m \|\mathbf{G}\mathbf{F}\mathbf{x}^{(r)} - \mathbf{x}^{(r)}\|_2^2.$$

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, χαρακτηριστικό, απεικόνιση, χώρος χαρακτηριστικών, χώρος υποθέσεων, ανάλυση κύριων συνιστωσών, ελάχιστο, σύνολο δεδομένων.

**μαλακή συσταδοποίηση** Η μαλακή συσταδοποίηση (soft clustering) αναφέρεται στην εργασία χωρισμού ενός συγκεκριμένου συνόλου σημείων δεδομένων σε (μερικές) αλληλεπικαλυπτόμενες συστάδες. Κάθε σημείο δεδομένων αποδίδεται σε αρκετές διαφορετικές συστάδες με μεταβαλλόμενους βαθμούς συσχέτισης. Οι μέθοδοι μαλακής συσταδοποίησης καθορίζουν τον βαθμό συσχέτισης (ή την απόδοση μαλακής συστάδας) για κάθε σημείο δεδομένων και κάθε συστάδα. Μία προσέγγιση αρχών μαλακής συσταδοποίησης για σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών είναι μέσω ενός πιθανοτικού μοντέλου όπως το Γκαουσιανό μοντέλο μείγματος. Η πιθανότητα υπό συνθήκη ένα σημείο δεδομένων να ανήκει σε μία συγκεκριμένη συνι-

στώσα μείγματος είναι τότε μία φυσική επιλογή για τον βαθμό συσχέτισης. Μέθοδοι μαλακής συσταδοποίησης με Γκαουσιανό μοντέλο μείγματος μπορούν να εφαρμοστούν σε μη αριθμητικά δεδομένα χρησιμοποιώντας μεθόδους μάθησης χαρακτηριστικών, ώστε να παραχθούν αριθμητικά χαρακτηριστικά (όπως στη φασματική συσταδοποίηση).

Βλέπε επίσης: συσταδοποίηση, σημείο δεδομένων, συστάδα, βαθμός συσχέτισης, διάνυσμα χαρακτηριστικών, πιθανοτικό μοντέλο, Γκαουσιανό μοντέλο μείγματος, πιθανότητα, data, μάθηση χαρακτηριστικών, χαρακτηριστικό, φασματική συσταδοποίηση.

**μεγάλο γλωσσικό μοντέλο** Ένα μεγάλο γλωσσικό μοντέλο (large language model - LLM) είναι ένα όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που χρησιμοποιούν μοντέλα μηχανικής μάθησης υψηλής διάστασης (με δισεκατομμύρια παράμετρους μοντέλου) που εκπαιδεύονται σε μεγάλες συλλογές δεδομένων κειμένου. Τα μεγάλα γλωσσικά μοντέλα χρησιμοποιούνται για την ανάλυση και την παραγωγή ακολουθιών μονάδων δεδομένων που συνιστούν δεδομένα κειμένου. Πολλά τρέχοντα μεγάλα γλωσσικά μοντέλα χρησιμοποιούν κάποια παραλλαγή ενός μετασχηματιστή που εκπαιδεύεται μέσω αυτοεποπτευόμενης μάθησης, δηλαδή η εκπαίδευση βασίζεται στην εργασία της πρόβλεψης μερικών λέξεων που σκόπιμα αφαιρούνται από ένα μεγάλο σώμα κειμένων. Έτσι, μπορούμε να κατασκευάσουμε σημεία δεδομένων με ετικέτες απλώς επιλέγοντας κάποιες λέξεις από ένα δεδομένο κείμενο ως ετικέτες και τις υπόλοιπες λέξεις ως χαρακτηριστικά σημείων δεδομένων. Αυτή η κατασκευή απαιτεί πολύ λίγη ανθρώπινη εποπτεία και επιτρέπει την παραγωγή επαρκώς μεγάλων συνόλων εκπαίδευσης για μεγάλα γλωσσικά μοντέλα.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, model parameter, data, ακολουθία, μονάδα δεδομένων, μετασχηματιστής, αυτοεποπτευόμενη μάθηση, εκπαίδευση, σημείο δεδομένων με ετικέτα, ετικέτα, χαρακτηριστικό, σημείο δεδομένων, σύνολο εκπαίδευσης, natural language processing (NLP).

**μέγεθος βήματος** Βλέπε ρυθμός μάθησης.

**μέγεθος δείγματος** Το μέγεθος δείγματος (sample size) είναι ο αριθμός των μεμονωμένων σημείων δεδομένων που περιέχονται σε ένα δείγμα ή σύνολο δεδομένων. Θεωρούμε μία μέθοδο βασισμένη στην εμπειρική ελαχιστοποίηση διακινδύνευσης που χρησιμοποιεί ένα σύνολο εκπαίδευσης  $\mathcal{D}$  με μέγεθος δείγματος  $m$  και ένα μοντέλο  $\mathcal{H}$  με αποτελεσματική διάσταση  $d_{\text{eff}}(\mathcal{H})$ . Αν το σύνολο εκπαίδευσης μπορεί να προσεγγιστεί καλά από την παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, τότε ο λόγος μεταξύ του  $m$  και της  $d_{\text{eff}}(\mathcal{H})$  μπορεί να είναι ένας χρήσιμος δείκτης για την εμφάνιση υπερπροσαρμογής [8, Κεφ. 6].

Βλέπε επίσης: sample, σημείο δεδομένων, σύνολο δεδομένων, εμπειρική ελαχιστοποίηση διακινδύνευσης, σύνολο εκπαίδευσης, μοντέλο, αποτελεσματική διάσταση, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, υπερπροσαρμογή.

**μέγιστη πιθανοφάνεια** Θεωρούμε σημεία δεδομένων  $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$  που ερμηνεύονται ως τις πραγματώσεις ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας  $\mathbb{P}(\mathbf{w})$ , η οποία εξαρτάται από τις παράμετρους μοντέλου  $\mathbf{w} \in \mathcal{W} \subseteq \mathbb{R}^n$ . Οι μέθοδοι μέγιστης πιθανοφάνειας (maximum likelihood) μαθαίνουν τις παράμετρους του μοντέλου  $\mathbf{w}$  μεγιστοποιώντας την πιθανότητα (ή την

πυκνότητα πιθανότητας)  $\mathbb{P}^{(\mathbf{w})}(\mathcal{D}) = \prod_{r=1}^m \mathbb{P}(\mathbf{z}^{(r)}; \mathbf{w})$  του παρατηρούμενου συνόλου δεδομένων. Συνεπώς, ο εκτιμητής μέγιστης πιθανοφάνειας είναι μία λύση του προβλήματος βελτιστοποίησης  $\max_{\mathbf{w} \in \mathcal{W}} \mathbb{P}(\mathcal{D}; \mathbf{w})$ .

Βλέπε επίσης: σημείο δεδομένων, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανοημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, model parameter, μέγιστο, σύνολο δεδομένων, optimization problem, πιθανοτικό μοντέλο.


**μέθοδος με βάση την κλίση** Οι μέθοδοι με βάση την κλίση είναι επαναληπτικές τεχνικές για την εύρεση του ελάχιστου (ή του μέγιστου) μίας παραγωγίσιμης αντικειμενικής συνάρτησης των παραμέτρων μοντέλου. Αυτές οι μέθοδοι κατασκευάζουν μία ακολουθία προσεγγίσεων σε μία βέλτιστη επιλογή παραμέτρων μοντέλου που οδηγεί σε μία ελάχιστη (ή μέγιστη) τιμή της αντικειμενικής συνάρτησης. Όπως το όνομά τους υποδεικνύει, οι μέθοδοι με βάση την κλίση χρησιμοποιούν τις κλίσεις της αντικειμενικής συνάρτησης που αξιολογούνται κατά τις προηγούμενες επαναλήψεις για να κατασκευάσουν νέες, (ελπίζοντας) βελτιωμένες παράμετρους μοντέλου. Ένα σημαντικό παράδειγμα μίας μεθόδου με βάση την κλίση είναι η κάθοδος κλίσης.

Βλέπε επίσης: κλίση, ελάχιστο, μέγιστο, παραγωγίσιμη, αντικειμενική συνάρτηση, model parameter, κάθοδος κλίσης.

**μέθοδος πυρήνα** Μία μέθοδος πυρήνα είναι μία μέθοδος μηχανικής μάθησης που χρησιμοποιεί έναν πυρήνα  $k$  για να αντιστοιχήσει το αρχικό (δηλαδή ακατέργαστο) διάνυσμα χαρακτηριστικών  $\mathbf{x}$  ενός σημείου δεδομένων σε ένα νέο (μετασχηματισμένο) διάνυσμα χαρακτηριστικών  $\mathbf{z} = k(\mathbf{x}, \cdot)$



[63], [26]. Το κίνητρο για τον μετασχηματισμό των διανυσμάτων χαρακτηριστικών είναι ότι, χρησιμοποιώντας έναν κατάλληλο πυρήνα, τα σημεία δεδομένων έχουν μία πιο «ευχάριστη» γεωμετρία στον μετασχηματισμένο χώρο χαρακτηριστικών. Για παράδειγμα, σε ένα πρόβλημα δυαδικής ταξινόμησης, η χρήση μετασχηματισμένων διανυσμάτων χαρακτηριστικών  $\mathbf{z}$  μπορεί να μας επιτρέψει να χρησιμοποιήσουμε γραμμικά μοντέλα, ακόμα και αν τα σημεία δεδομένων δεν είναι γραμμικώς διαχωρίσιμα στον αρχικό χώρο χαρακτηριστικών (βλέπε Σχ. 42).



Σχ. 42. Πέντε σημεία δεδομένων που χαρακτηρίζονται από διανύσματα χαρακτηριστικών  $\mathbf{x}^{(r)}$  και ετικέτες  $y^{(r)} \in \{\circ, \square\}$ , για  $r = 1, \dots, 5$ . Με αυτά τα διανύσματα χαρακτηριστικών, δεν υπάρχει τρόπος να διαχωρίσουμε τις δύο τάξεις με μία ευθεία γραμμή (που αναπαριστά το όριο απόφασης ενός γραμμικού ταξινομητή). Αντίθετα, τα μετασχηματισμένα διανύσματα χαρακτηριστικών  $\mathbf{z}^{(r)} = k(\mathbf{x}^{(r)}, \cdot)$  μας επιτρέπουν να διαχωρίσουμε τα σημεία δεδομένων χρησιμοποιώντας έναν γραμμικό ταξινομητή.

Βλέπε επίσης: πυρήνας, μηχανική μάθηση, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, χώρος χαρακτηριστικών, ταξινόμηση, γραμμικό μοντέλο, ετικέτα, όριο απόφασης, γραμμικός ταξινομητής.

**μείωση της διαστασιμότητας** TBC.

**μεροληψία** Θεωρούμε μία μέθοδο μηχανικής μάθησης βασισμένη στην εμπειρική ελαχιστοποίηση διακινδύνευσης που μαθαίνει μία υπόθεση  $\hat{h} \in \mathcal{H}$

από ένα δεδομένο σύνολο εκπαίδευσης. Η ανάλυση της μεθόδου μηχανικής μάθησης συχνά βασίζεται σε ένα πιθανοτικό μοντέλο (όπως η παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων) για την παραγωγή δεδομένων. Εδώ, τα σημεία δεδομένων και, κατ' επέκταση, η υπόθεση  $\hat{h}$  που έχει μαθητευτεί θεωρούνται ως τυχαίες μεταβλητές (ή πραγματώσεις τυχαίων μεταβλητών). Οποιαδήποτε ιδιότητα  $\theta(\hat{h})$  της  $\hat{h}$ , όπως συγκεκριμένες παράμετροι μοντέλου σε ένα παραμετρικό μοντέλο ή το σφάλμα πρόβλεψης  $y - \hat{h}(\mathbf{x})$  για ένα σταθερό σημείο δεδομένων, καθίσταται τότε επίσης τυχαία μεταβλητή. Η τετραγωνική μεροληψία (bias) μίας αριθμητικής ιδιότητας  $\theta(\hat{h}) \in \mathbb{R}^r$  είναι [35], [51]

$$B^2 := \|\mathbb{E}\{\theta(\hat{h})\} - \theta(\bar{h})\|_2^2.$$

Εδώ,  $\bar{h}$  είναι η υπόθεση αναφοράς, η οποία θα μπορούσε να οριστεί από  $\bar{h}(\mathbf{x}) = y$  για ένα σταθερό σημείο δεδομένων ελέγχου με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ .

Βλέπε επίσης: εμπειρική ελαχιστοποίηση διακινδύνευσης, μηχανική μάθηση, υπόθεση, σύνολο εκπαίδευσης, πιθανοτικό μοντέλο, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, data, σημείο δεδομένων, πραγμάτωση, τυχαία μεταβλητή, model parameter, παραμετρικό μοντέλο, πρόβλεψη, διάνυσμα χαρακτηριστικών, ετικέτα, ανεξάρτητες και ταυτόσημα κατανομημένες, σφάλμα εκτίμησης.

**μέση τιμή δείγματος** Η μέση τιμή δείγματος  $\mathbf{m} \in \mathbb{R}^d$  για ένα συγκεκριμένο σύνολο δεδομένων, με διανύσματα χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in$

$\mathbb{R}^d$ , ορίζεται ως

$$\mathbf{m} = \frac{1}{m} \sum_{r=1}^m \mathbf{x}^{(r)}.$$

Βλέπε επίσης: sample, μέση τιμή, σύνολο δεδομένων, διάνυσμα χαρακτηριστικών.

**μέσο τετραγωνικό σφάλμα εκτίμησης** Θεωρούμε μία μέθοδο μηχανικής μάθησης που μαθαίνει παράμετρους μοντέλου  $\hat{\mathbf{w}}$  με βάση κάποιο σύνολο δεδομένων  $\mathcal{D}$ . Αν ερμηνεύσουμε τα σημεία δεδομένων στο  $\mathcal{D}$  ως ανεξάρτητες και ταυτόσημα κατανομημένες πραγματώσεις μίας τυχαίας μεταβλητής  $\mathbf{z}$ , ορίζουμε το σφάλμα εκτίμησης  $\Delta \mathbf{w} := \hat{\mathbf{w}} - \bar{\mathbf{w}}$ . Εδώ,  $\bar{\mathbf{w}}$  δηλώνει τις αληθείς παράμετρους του μοντέλου της κατανομής πιθανότητας του  $\mathbf{z}$ . Το μέσο τετραγωνικό σφάλμα εκτίμησης (mean squared estimation error - MSE) ορίζεται ως η προσδοκία  $\mathbb{E}\{\|\Delta \mathbf{w}\|^2\}$  της τετραγωνικής Ευκλείδειας νόρμας του σφάλματος εκτίμησης [38], [94].


Βλέπε επίσης: μηχανική μάθηση, model parameter, σύνολο δεδομένων, σημείο δεδομένων, ανεξάρτητες και ταυτόσημα κατανομημένες, πραγμάτωση, τυχαία μεταβλητή, σφάλμα εκτίμησης, κατανομή πιθανότητας, expectation, νόρμα, μέση τιμή, πιθανοτικό μοντέλο, απώλεια τετραγωνικού σφάλματος.

**μετασχηματιστής TBC.**

**μηχανή διανυσμάτων υποστήριξης (ΜΔΥ) TBC.**

**μηχανική μάθηση** Οι μέθοδοι μηχανικής μάθησης (machine learning - ML) στοχεύουν να μάθουν (ή να βρουν) μία χρήσιμη απεικόνιση υπόθεσης

$\hat{h} \in \mathcal{H}$  από ένα μοντέλο  $\mathcal{H}$ . Η  $\hat{h}$  που έχουν μαθευτεί χρησιμοποιείται για τον υπολογισμό μίας πρόβλεψης  $\hat{y} = \hat{h}(\mathbf{x})$  για την ετικέτα  $y$  ενός σημείου δεδομένων. Η διαδικασία μάθησης καθοδηγείται από ένα ποσοτικό μέτρο της απώλειας που προκαλείται όταν οι προβλέψεις που προκύπτουν από την υπόθεση που έχει μαθευτεί διαφέρουν από την πραγματική ετικέτα  $y$ . Διαφορετικές μέθοδοι μηχανικής μάθησης χρησιμοποιούν διαφορετικές επιλογές σχεδιασμού για αυτό το ποσοτικό μέτρο (ή συνάρτηση απώλειας) καθώς και διαφορετικές επιλογές για το μοντέλο και τα σημεία δεδομένων (δηλαδή τα χαρακτηριστικά και τις ετικέτες) τους [8, Κεφ. 3].



Σχ. 43. Η μηχανική μάθηση μαθαίνει μία υπόθεση από ένα μοντέλο (ή χώρο υποθέσεων) προσπαθώντας να ελαχιστοποιήσει την απώλεια που προκύπτει από τις προβλέψεις για τις ετικέτες σημείων δεδομένων. Οι προβλέψεις υπολογίζονται μόνο από τα χαρακτηριστικά των σημείων δεδομένων.

Μία άλλη διάκριση μεταξύ μεθόδων μηχανικής μάθησης είναι ο τρόπος

με τον οποίο έχουν πρόσβαση σε σημεία δεδομένων κατά τη μάθηση. Για παράδειγμα, κάποιες μέθοδοι έχουν πρόσβαση σε ένα πλήρες σύνολο δεδομένων κατά την εκπαίδευση, γεγονός που τις επιτρέπει να χρησιμοποιούν την εμπειρική ελαχιστοποίηση διακινδύνευσης [8], [95]. Αντίθετα, οι μέθοδοι διαδικτυακής μάθησης έχουν πρόσβαση σε δεδομένα διαδοχικά και, κατά συνέπεια, ενημερώνουν την υπόθεση που έχει μαθευτεί κάθε φορά που έρχεται ένα νέο σημείο δεδομένων [75], [76], [96].


Βλέπε επίσης: υπόθεση, απεικόνιση, μοντέλο, πρόβλεψη, ετικέτα, σημείο δεδομένων, μέτρο, απώλεια, συνάρτηση απώλειας, χαρακτηριστικό, εξαγωγή συμπερασμάτων, data, χώρος υποθέσεων, σύνολο δεδομένων, εκπαίδευση, εμπειρική ελαχιστοποίηση διακινδύνευσης, διαδικτυακή μάθηση.

**μονάδα δεδομένων** A token is a basic unit of information obtained by splitting a ακολουθία of symbols, such as a text string, into smaller parts. In NLP, tokens often correspond to words, subwords, or characters that form the χαρακτηριστικός of a σημείο δεδομένων. Tokenization transforms raw text (e.g., “The cat sleeps”) into a ακολουθία of tokens (e.g., [“The”, “cat”, “sleeps”]), which can then be mapped to numerical διάνυσμα χαρακτηριστικών.

See also: ακολουθία, διάνυσμα χαρακτηριστικών.

**μοντέλο (μηχανική μάθηση)** Η μελέτη και ο σχεδιασμός μεθόδων μηχανικής μάθησης βασίζεται συχνά σε ένα μαθηματικό μοντέλο (model) [97]. Ίσως το πιο ευρέως χρησιμοποιούμενο παράδειγμα μαθηματικού μοντέλου για τη μηχανική μάθηση είναι ένας χώρος υποθέσεων. Ένας χώρος υ-

ποθέσεων αποτελείται από απεικόνιση υπόθεσης που χρησιμοποιούνται από μία μέθοδο μηχανικής μάθησης για την πρόβλεψη ετικετών από τα χαρακτηριστικά σημείων δεδομένων. Ένας άλλος σημαντικός τύπος μαθηματικού μοντέλου είναι ένα πιθανοτικό μοντέλο, το οποίο αποτελείται από κατανομές πιθανοτήτων που περιγράφουν πώς παράγονται σημεία δεδομένων. Εκτός αν διατυπώνεται διαφορετικά, χρησιμοποιούμε τον όρο μοντέλο για να αναφερθούμε συγκεκριμένα στον χώρο υποθέσεων που αποτελεί τη βάση μιας μεθόδου μηχανικής μάθησης. Παρουσιάζουμε ένα παράδειγμα ενός χώρου υποθέσεων και ενός πιθανοτικού μοντέλου στο Σχ. 44.



Σχ. 44. Δύο τύποι μαθηματικών μοντέλων που χρησιμοποιούνται στη μηχανική μάθηση. (a) Ένας χώρος υποθέσεων που αποτελείται από τρεις linear maps. (b) Ένα πιθανοτικό μοντέλο που αποτελείται από κατανομή πιθανότητας πάνω στο επίπεδο παραγόμενο από τις τιμές χαρακτηριστικών και ετικετών ενός σημείου δεδομένων.

Βλέπε επίσης: μηχανική μάθηση, χώρος υποθέσεων, υπόθεση, απεικόνιση, ετικέτα, χαρακτηριστικό, σημείο δεδομένων, πιθανοτικό μοντέλο, κατανομή πιθανότητας, linear map.

**μοντέλο στοχαστικής ομάδας** Το μοντέλο στοχαστικής ομάδας (stochastic block model - SBM) είναι ένα πιθανοτικό παραγωγικό μοντέλο για έναν μη κατευθυνόμενο γράφο  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  με ένα δεδομένο σύνολο κόμβων  $\mathcal{V}$  [98]. Στην πιο βασική του παραλλαγή, το μοντέλο στοχαστικής ομάδας παράγει έναν γράφο πρώτα αποδίδοντας τυχαία κάθε κόμβο  $i \in \mathcal{V}$  σε έναν δείκτη συστάδας  $c_i \in \{1, \dots, k\}$ . Ένα ζεύγος διαφορετικών κόμβων στον γράφο συνδέεται με μία ακμή με πιθανότητα  $p_{i,i'}$  που εξαρτάται μόνο από τις ετικέτες  $c_i, c_{i'}$ . Η παρουσία ακμών μεταξύ διαφορετικών ζευγών κομβών είναι στατιστικά ανεξάρτητη. Βλέπε επίσης: μοντέλο, graph, συστάδα, πιθανότητα, ετικέτα.

**ομαλοποιημένη ελαχιστοποίηση απώλειας** Βλέπε ομαλοποιημένη εμπειρική ελαχιστοποίηση διακινδύνευσης.

**ομαλοποιημένη εμπειρική ελαχιστοποίηση διακινδύνευσης** TBC.

**ομαλοποίηση** TBC.

**ομαλοποιητής** Ένας ομαλοποιητής αποδίδει σε κάθε υπόθεση  $h$  από έναν χώρο υποθέσεων  $\mathcal{H}$  ένα ποσοτικό μέτρο  $\mathcal{R}\{h\}$  που εκφράζει σε ποιόν βαθμό τα σφάλματα πρόβλεψής της μπορεί να διαφέρουν σε σημεία δεδομένων σε ένα σύνολο εκπαίδευσης και έξω από αυτό. Η αμφικλινής παλινδρόμηση χρησιμοποιεί τον ομαλοποιητή  $\mathcal{R}\{h\} := \|\mathbf{w}\|_2^2$  για γραμμικές απεικόνισης υπόθεσης  $h^{(\mathbf{w})}(\mathbf{x}) := \mathbf{w}^T \mathbf{x}$  [8, Κεφ. 3]. Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής χρησιμοποιεί τον ομαλοποιητή  $\mathcal{R}\{h\} := \|\mathbf{w}\|_1$  για γραμμικές απεικόνισης υπόθεσης  $h^{(\mathbf{w})}(\mathbf{x}) := \mathbf{w}^T \mathbf{x}$  [8, Κεφ. 3].

Βλέπε επίσης: υπόθεση, χώρος υποθέσεων, πρόβλεψη, σύνολο εκπαίδευσης, σημείο δεδομένων, αμφικλινής παλινδρόμηση, απεικόνιση, τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής, απώλεια, αντικειμενική συνάρτηση.

**ομοσπονδιακή μάθηση** Η ομοσπονδιακή μάθηση (federated learning - FL) είναι ένας όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που εκπαιδεύουν μοντέλα με έναν συνεργατικό τρόπο χρησιμοποιώντας αποκεντρωμένα δεδομένα και υπολογισμό.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, data.

**οπισθοδιάδοση** TBC.

**οριζόντια ομοσπονδιακή μάθηση** Η οριζόντια ομοσπονδιακή μάθηση (horizontal federated learning - HFL) χρησιμοποιεί τοπικά σύνολα δεδομένων που αποτελούνται από διαφορετικά σημεία δεδομένων, αλλά χρησιμοποιεί τα ίδια χαρακτηριστικά για να τα χαρακτηρίσει [99]. Για παράδειγμα, η πρόγνωση καιρού χρησιμοποιεί ένα δίκτυο χωρικά κατανεμημένων σταθμών (παρατήρησης) καιρού. Κάθε σταθμός καιρού μετράει τις ίδιες ποσότητες, όπως την ημερήσια θερμοκρασία, την ατμοσφαιρική πίεση, και τα ατμοσφαιρικά καταχρηνίσματα. Ωστόσο, διαφορετικοί σταθμοί καιρού μετράνε τα characteristics ή τα χαρακτηριστικά διαφορετικών χωροχρονικών περιοχών. Κάθε χωροχρονική περιοχή αναπαριστά ένα μεμονωμένο σημείο δεδομένων, με το καθένα να χαρακτηρίζεται από τα ίδια χαρακτηριστικά (δηλαδή ημερήσια θερμοκρασία ή ατμοσφαιρική πίεση).

Βλέπε επίσης: τοπικό σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ημιεποπτευόμενη μάθηση, FL, κατακόρυφη ομοσπονδιακή μάθηση.



**όριο απόφασης** Θεωρούμε μία απεικόνιση υπόθεσης  $h$  που διαβάζει ένα διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  και παραδίδει μία τιμή από ένα πεπερασμένο σύνολο  $\mathcal{Y}$ . Το σύνορο απόφασης της  $h$  είναι το σύνολο των διανυσμάτων  $\mathbf{x} \in \mathbb{R}^d$  που βρίσκονται ανάμεσα σε διαφορετικές περιοχές αποφάσεων. Πιο συγκεκριμένα, ένα διάνυσμα  $\mathbf{x}$  ανήκει στο σύνορο απόφασης αν και μόνο αν κάθε γειτονιά  $\{\mathbf{x}' : \|\mathbf{x} - \mathbf{x}'\| \leq \varepsilon\}$ , για οποιοδήποτε  $\varepsilon > 0$ , περιέχει τουλάχιστον δύο διανύσματα με διαφορετικές τιμές συνάρτησης.

Βλέπε επίσης: υπόθεση, απεικόνιση, διάνυσμα χαρακτηριστικών, διάνυσμα, περιοχή αποφάσεων, γειτονιά, συνάρτηση.

**όρος ποινής** TBC.

**παλινδρόμηση** Τα προβλήματα παλινδρόμησης περιστρέφονται γύρω από την πρόβλεψη μίας αριθμητικής ετικέτας μόνο από τα χαρακτηριστικά ενός σημείου δεδομένων [8, Κεφ. 2].

Βλέπε επίσης: πρόβλεψη, ετικέτα, χαρακτηριστικό, σημείο δεδομένων.

**παλινδρόμηση ελάχιστης απόλυτης απόκλισης** Η παλινδρόμηση ελάχιστης απόλυτης απόκλισης είναι μία περίπτωση της εμπειρικής ελαχιστοποίησης διακινδύνευσης που χρησιμοποιεί την απώλεια απόλυτου σφάλματος. Είναι μία ειδική περίπτωση της παλινδρόμησης Huber.

Βλέπε επίσης: εμπειρική ελαχιστοποίηση διακινδύνευσης, απώλεια απόλυτου σφάλματος, παλινδρόμηση Huber.

**παλινδρόμηση Huber** Η παλινδρόμηση Huber (Huber regression) [100] αναφέρεται σε μεθόδους βασισμένες στην εμπειρική ελαχιστοποίηση διακινδύνευσης που χρησιμοποιούν την απώλεια Huber ως μέτρο του σφάλματος

πρόβλεψης. Δύο σημαντικές ειδικές περιπτώσεις της παλινδρόμησης Huber είναι η παλινδρόμηση ελάχιστης απόλυτης απόκλισης και η γραμμική παλινδρόμηση. Η ρύθμιση της παραμέτρου-κατωφλίου της απώλειας Huber επιτρέπει στον χρήστη να ανταλλάξει τη στιβαρότητα της απώλειας απόλυτου σφάλματος με τα υπολογιστικά οφέλη της λείας απώλειας τετραγωνικού σφάλματος.

Βλέπε επίσης: regression, εμπειρική ελαχιστοποίηση διακινδύνευσης, απώλεια Huber, μέτρο, πρόβλεψη, παλινδρόμηση ελάχιστης απόλυτης απόκλισης, γραμμική παλινδρόμηση, παράμετρος, στιβαρότητα, απώλεια απόλυτου σφάλματος, λεία, απώλεια τετραγωνικού σφάλματος.

**παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων** Η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων (independent and identically distributed assumption - i.i.d. assumption) είναι ένα ευρέως χρησιμοποιούμενο πιθανοτικό μοντέλο για την παραγωγή σημείων δεδομένων. Συγκεκριμένα, τα σημεία δεδομένων αναπαρίστανται ως ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαίες μεταβλητές.

Βλέπε επίσης: ανεξάρτητες και ταυτόσημα κατανεμημένες, πιθανοτικό μοντέλο, σημείο δεδομένων, τυχαία μεταβλητή.

**παραδοχή συσταδοποίησης** Η παραδοχή συσταδοποίησης υποθέτει ότι σημεία δεδομένων σε ένα σύνολο δεδομένων σχηματίζουν έναν (μικρό) αριθμό ομάδων ή συστάδων. Τα σημεία δεδομένων στην ίδια συστάδα είναι πιο όμοια μεταξύ τους παρά με αυτά εκτός της συστάδας [91]. Αποκτούμε διαφορετικές μεθόδους συσταδοποίησης χρησιμοποιώντας διαφορετικές έννοιες ομοιότητας ανάμεσα σε σημεία δεδομένων.


Βλέπε επίσης: συσταδοποίηση, σημείο δεδομένων, σύνολο δεδομένων, συστάδα.

### παραμετρικό μοντέλο TBC.

**παράμετρος** Η παράμετρος ενός μοντέλου μηχανικής μάθησης είναι μία ποσότητα που μπορεί να ρυθμιστεί (δηλαδή να μαθευτεί ή να προσαρμοστεί) και που μας επιτρέπει να επιλέξουμε μεταξύ διαφορετικών απεικόνισης υπόθεσης. Για παράδειγμα, το γραμμικό μοντέλο  $\mathcal{H} := \{h^{(\mathbf{w})} : h^{(\mathbf{w})}(x) = w_1x + w_2\}$  αποτελείται από όλες τις απεικόνισης υπόθεσης  $h^{(\mathbf{w})}(x) = w_1x + w_2$  με μία συγκεκριμένη επιλογή για τις παραμέτρους  $\mathbf{w} = (w_1, w_2)^T \in \mathbb{R}^2$ . Ένα άλλο παράδειγμα μίας παραμέτρου μοντέλου είναι τα βάρη που αποδίδονται σε μία σύνδεση μεταξύ δύο νευρώνων ενός ΤΝΔ.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, υπόθεση, απεικόνιση, γραμμικό μοντέλο, βάρος, ΤΝΔ.

**παράμετρος μοντέλου** Τα στοιχεία ενός παραμετρικού μοντέλου προσδιορίζονται από ποσότητες που αναφέρονται ως παράμετροι του μοντέλου (model parameters). Στο πλαίσιο της μηχανικής μάθησης, ένα παραμετρικό μοντέλο αποτελείται από απεικονίσεις υπόθεσης που προσδιορίζονται από μία λίστα παραμέτρων του μοντέλου  $w_1, w_2, \dots, w_d$ . Είναι συχνά βολικό να στοιβάζουμε αυτές τις παραμέτρους του μοντέλου σε ένα διάνυσμα  $\mathbf{w} = (w_1, \dots, w_d)^T \in \mathbb{R}^d$ .



Σχ. 45. Οι παράμετροι μοντέλου  $\mathbf{w}$  επιλέγουν μία καλά ορισμένη υπόθεση  $h(\mathbf{w})$  από το μοντέλο  $\mathcal{H}$ .

Μπορούμε να σκεφτούμε τις παραμέτρους μοντέλου ως ένα αναγνωριστικό για μία απεικόνιση υπόθεσης, όμοια με το πώς ένας αριθμός κοινωνικής ασφάλισης ταυτοποιεί ένα άτομο.

Βλέπε επίσης: παραμετρικό μοντέλο, μοντέλο, παράμετρος, μηχανική μάθηση, υπόθεση, απεικόνιση, διάνυσμα, παραμετρικός χώρος.

**περιοχή αποφάσεων** Θεωρούμε μία απεικόνιση υπόθεσης  $h$  που δίνει τιμές από ένα πεπερασμένο σύνολο  $\mathcal{Y}$ . Για κάθε τιμή ετικέτας (δηλαδή κατηγορία)  $a \in \mathcal{Y}$ , η υπόθεση  $h$  καθορίζει ένα υποσύνολο τιμών χαρακτηριστικών  $\mathbf{x} \in \mathcal{X}$  που οδηγούν στην ίδια έξοδο  $h(\mathbf{x}) = a$ . Αναφερόμαστε σε αυτό το υποσύνολο ως μία περιοχή αποφάσεων της υπόθεσης  $h$ .

Βλέπε επίσης: υπόθεση, απεικόνιση, ετικέτα, χαρακτηριστικό, έξοδος.

**πιθανότητα** Αποδίδουμε μία τιμή πιθανότητας, συνήθως επιλεγμένη στο διάστημα  $[0, 1]$ , σε κάθε γεγονός που μπορεί να συμβεί σε ένα τυχαίο πείραμα [6], [7], [28], [49].

Βλέπε επίσης: γεγονός, τυχαίο πείραμα.

**πίνακας σύγχυσης** Θεωρούμε ένα πεπερασμένο σύνολο δεδομένων με  $m$  σημεία δεδομένων, καθένα από τα οποία χαρακτηρίζεται από ένα διάνυ-

σμα χαρακτηριστικών  $\mathbf{x}$  και μία ετικέτα  $y \in \mathcal{Y}$  με έναν πεπερασμένο χώρο ετικετών  $\mathcal{Y} = \{1, \dots, k\}$ . Για μία δεδομένη υπόθεση  $h$ , ο πίνακας σύγχυσης (confusion matrix) είναι ένας  $k \times k$  πίνακας όπου κάθε γραμμή αντιστοιχεί σε μία συγκεκριμένη τιμή της αληθούς ετικέτας  $y \in \mathcal{Y}$  και κάθε στήλη σε μία συγκεκριμένη τιμή της πρόβλεψης  $h(\mathbf{x}) \in \mathcal{Y}$ . Η καταχώριση του πίνακα στη  $c$ -οστή γραμμή και τη  $c'$ -οστή στήλη είναι ο αριθμός των σημείων δεδομένων με μία αληθή ετικέτα  $y = c$  που προβλέπονται ως  $h(\mathbf{x}) = c'$ . Το άθροισμα των καταχωρίσεων της κύριας διαγωνίου είναι ο αριθμός των σωστά ταξινομημένων σημείων δεδομένων, δηλαδή εκείνων για τα οποία  $y = h(\mathbf{x})$ . Το άθροισμα των εκτός διαγωνίου καταχωρίσεων οδηγεί στον συνολικό αριθμό των σημείων δεδομένων που είναι λανθασμένα ταξινομημένα από την  $h$ .

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, ετικέτα, χώρος ετικετών, υπόθεση, πίνακας, πρόβλεψη, ταξινόμηση.

**πίνακας χαρακτηριστικών** Θεωρούμε ένα σύνολο δεδομένων  $\mathcal{D}$  με  $m$  σημεία δεδομένων με διανύσματα χαρακτηριστικών  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$ . Είναι βολικό να συγκεντρώσουμε τα μεμονωμένα διανύσματα χαρακτηριστικών σε έναν πίνακα χαρακτηριστικών (feature matrix):

$$\mathbf{X} := (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})^T = \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_d^{(m)} \end{pmatrix} \in \mathbb{R}^{m \times d}.$$

Σημείωση ότι ο πίνακας χαρακτηριστικών είναι μεγέθους  $m \times d$ , δηλαδή

έχει  $m$  γραμμές και  $d$  στήλες.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, χαρακτηριστικό, πίνακας.

**πλησιέστερος γείτονας** Οι μέθοδοι πλησιέστερου γείτονα (nearest neighbor - NN) μαθαίνουν μία υπόθεση  $h : \mathcal{X} \rightarrow \mathcal{Y}$  της οποίας η τιμή συνάρτησης  $h(\mathbf{x})$  καθορίζεται μόνο από τους πλησιέστερους γείτονες εντός ενός δεδομένου συνόλου δεδομένων. Διαφορετικές μέθοδοι χρησιμοποιούν διαφορετικές μετρικές για τον καθορισμό των πλησιέστερων γειτόνων. Αν σημεία δεδομένων χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών, μπορούμε να χρησιμοποιήσουμε τις Ευκλείδειες αποστάσεις τους ως τη μετρική.

Βλέπε επίσης: υπόθεση, συνάρτηση, σύνολο δεδομένων, μετρική, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, Ευκλείδεια απόσταση, γείτονας.

**πολυπλοκότητα Rademacher** Όμοια με τη διάσταση Vapnik–Chervonenkis, η πολυπλοκότητα Rademacher [101] είναι ένα ποσοτικό μέτρο του μεγέθους ενός χώρου υποθέσεων  $\mathcal{H}$ . Βασίζεται στην εμπειρική πολυπλοκότητα Rademacher, η οποία ορίζεται για ένα συγκεκριμένο σύνολο δεδομένων  $\mathcal{D}$  ως

$$\mathcal{R}_{\mathcal{D}}(\mathcal{H}) = \mathbb{E}_{\varepsilon_1, \dots, \varepsilon_m} \sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{r=1}^m \varepsilon_r h(\mathbf{x}^{(r)}).$$

Εδώ, η προσδοκία λαμβάνεται αναφορικά με τις τυχαίες μεταβλητές  $\varepsilon_1, \dots, \varepsilon_m$ , οι οποίες είναι ανεξάρτητες και ταυτόσημα κατανοημένες και παίρνουν τιμές στο  $\{-1, +1\}$  με ίση πιθανότητα  $1/2$ . Η πολυπλοκότητα Rademacher του  $\mathcal{H}$  ορίζεται τότε ως η προσδοκία της εμπει-

ρικής πολυπλοκότητας Rademacher ενός τυχαίου συνόλου δεδομένων  $\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$  που αποτελείται από  $m$  ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαίες μεταβλητές  $\mathbf{x}^{(r)} \in \mathcal{X}$  για  $r = 1, \dots, m$ .

Βλέπε επίσης: διάσταση Vapnik–Chervonenkis, μέτρο, χώρος υποθέσεων, σύνολο δεδομένων, expectation, τυχαία μεταβλητή, ανεξάρτητες και ταυτόσημα κατανεμημένες, πιθανότητα, γενίκευση, μηχανική μάθηση, αποτελεσματική διάσταση.

**πολυωνυμική παλινδρόμηση** Η πολυωνυμική παλινδρόμηση είναι μία περίπτωση εμπειρικής ελαχιστοποίησης διακινδύνευσης που μαθαίνει μία πολυωνυμική απεικόνιση υπόθεσης για να προβλέψει μία αριθμητική ετικέτα με βάση τα αριθμητικά χαρακτηριστικά ενός σημείου δεδομένων. Για σημεία δεδομένων που χαρακτηρίζονται από ένα μοναδικό αριθμητικό χαρακτηριστικό, η πολυωνυμική παλινδρόμηση χρησιμοποιεί τον χώρο υποθέσεων  $\mathcal{H}_d^{(\text{poly})} := \{h(x) = \sum_{j=0}^{d-1} x^j w_j\}$ . Η ποιότητα μίας πολυωνυμικής απεικόνιση υπόθεσης μετράται χρησιμοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που προκύπτει σε ένα σύνολο σημείων δεδομένων με ετικέτες (στο οποίο αναφερόμαστε ως το σύνολο εκπαίδευσης).

Βλέπε επίσης: regression, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, απεικόνιση, ετικέτα, χαρακτηριστικό, σημείο δεδομένων, χώρος υποθέσεων, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

**πραγμάτωση** Θεωρούμε μία τυχαία μεταβλητή  $\mathbf{x}$  που αντιστοιχίζει κάθε αποτέλεσμα  $\omega \in \mathcal{P}$  ενός χώρου πιθανοτήτων  $\mathcal{P}$  σε ένα στοιχείο  $a$  ενός μετρήσιμου χώρου  $\mathcal{N}$  [2], [6], [49]. Μία πραγμάτωση της  $\mathbf{x}$  είναι οποιο-

δήποτε στοιχείο  $\mathbf{a} \in \mathcal{N}$  τέτοιο ώστε να υφίσταται ένα στοιχείο  $\omega' \in \mathcal{P}$  με  $\mathbf{x}(\omega') = \mathbf{a}$ .

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μετρήσιμο.

**πρόβλεψη** Μία πρόβλεψη είναι μία εκτίμηση ή προσέγγιση για κάποια ποσότητα ενδιαφέροντος. Η μηχανική μάθηση περιστρέφεται γύρω από τη μάθηση ή εύρεση μίας απεικόνιση υπόθεσης  $h$  που διαβάζει τα χαρακτηριστικά  $\mathbf{x}$  ενός σημείου δεδομένων και δίνει μία πρόβλεψη  $\hat{y} := h(\mathbf{x})$  για την ετικέτα του  $y$ .

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, απεικόνιση, χαρακτηριστικό, σημείο δεδομένων, ετικέτα.


**προγνωστικός παράγοντας** Ένας προγνωστικός παράγοντας είναι μία απεικόνιση υπόθεσης πραγματικής τιμής. Δεδομένου ενός σημείου δεδομένων με χαρακτηριστικά  $\mathbf{x}$ , η τιμή  $h(\mathbf{x}) \in \mathbb{R}$  χρησιμοποιείται ως η πρόβλεψη για την αληθή αριθμητική ετικέτα  $y \in \mathbb{R}$  του σημείου δεδομένων.

Βλέπε επίσης: υπόθεση, απεικόνιση, σημείο δεδομένων, χαρακτηριστικό, πρόβλεψη, ετικέτα.

**προσδοκία** Θεωρούμε ένα αριθμητικό διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$  που ερμηνεύουμε ως την πραγμάτωση μίας τυχαίας μεταβλητής με μία κατανομή πιθανότητας  $p(\mathbf{x})$ . Η προσδοκία (expectation) του  $\mathbf{x}$  ορίζεται ως το ολοκλήρωμα  $\mathbb{E}\{\mathbf{x}\} := \int \mathbf{x}p(\mathbf{x})$ . Σημείωση ότι η προσδοκία ορίζεται μόνο αν υφίσταται αυτό το ολοκλήρωμα, δηλαδή αν η τυχαία μεταβλητή είναι ολοκληρώσιμη [2], [6], [49]. Το Σχ. 46 απεικονίζει την προσδοκία μίας βαθμωτής διακριτής τυχαίας μεταβλητής  $x$  που παίρνει τιμές μόνο



από ένα πεπερασμένο σύνολο.




Σχ. 46. Η προσδοκία μίας διακριτής τυχαίας μεταβλητής  $x$  προκαλείται από το άθροισμα των πιθανών τιμών της  $x_i$ , σταθμισμένες από την αντίστοιχη πιθανότητα  $p(x_i) = \mathbb{P}(x = x_i)$ .

Βλέπε επίσης: διάνυσμα χαρακτηριστικών, πραγμάτωση, τυχαία μεταβλητή, κατανομή πιθανότητας, ολοκληρώσιμη, discrete RV, πιθανότητα.

**προσοχή** Κάποιες εφαρμογές μηχανικής μάθησης περιλαμβάνουν σημεία δεδομένων που αποτελούνται από μικρότερες μονάδες, οι οποίες αναφέρονται ως μονάδες δεδομένων. Για παράδειγμα, μία πρόταση αποτελείται από λέξεις, μία εικόνα από τμήματα εικονοστοιχείων, και ένα δίκτυο από κόμβους. Γενικά, οι μονάδες δεδομένων που συνιστούν ένα μοναδικό σημείο δεδομένων δεν είναι ανεξάρτητες μεταξύ τους. Αντίθετα, κάθε μονάδα δεδομένων ενός σημείου δεδομένων εξαρτάται από (ή δίνει προσοχή (attention) σε) συγκεκριμένες άλλες μονάδες δεδομένων. Τα πιθανοτικά μοντέλα παρέχουν ένα πλαίσιο αρχών για την αναπαράσταση και την ανάλυση τέτοιων εξαρτήσεων [102]. Οι μηχανισμοί προσοχής χρησιμοποιούν μία πιο άμεση προσέγγιση χωρίς ρητή αναφορά σε ένα πιθανοτικό μοντέλο. Η ιδέα είναι να αναπαρασταθεί η σχέση μεταξύ δύο μονάδων

δεδομένων  $i$  and  $i'$  χρησιμοποιώντας μία παραμετροποιημένη συνάρτηση  $f^{(\mathbf{w})}(i, i')$ , όπου οι παράμετροι  $\mathbf{w}$  μαθαίνονται μέσω μίας παραλλαγής της εμπειρικής ελαχιστοποίησης διακινδύνευσης. Οι πρακτικοί μηχανισμοί προσοχής διαφέρουν τόσο ως προς την ακριβή επιλογή μοντέλου προσοχής  $f^{(\mathbf{w})}(i, i')$  όσο και ως προς την ακριβή παραλλαγή της εμπειρικής ελαχιστοποίησης διακινδύνευσης που χρησιμοποιείται για τη μάθηση των παραμέτρων  $\mathbf{w}$ . Μία ευρέως χρησιμοποιούμενη οικογένεια μηχανισμών προσοχής ορίζει τις παραμέτρους  $\mathbf{w}$  ως προς δύο διανύσματα που σχετίζονται με κάθε μονάδα δεδομένων  $i$ , δηλαδή ένα διάνυσμα ερωτήματος  $\mathbf{q}^{(i)}$  και ένα διάνυσμα κλειδιού  $\mathbf{k}^{(i')}$ . Για μία δεδομένη μονάδα δεδομένων  $i$  με ερώτημα  $\mathbf{q}^{(i)}$  και μία άλλη μονάδα δεδομένων  $i'$  με κλειδί  $\mathbf{k}^{(i')}$ , η ποσότητα  $(\mathbf{q}^{(i)})^\top \mathbf{k}^{(i')}$  υποδεικνύει το κατά πόσο η μονάδα δεδομένων  $i$  δίνει προσοχή σε (ή εξαρτάται από) τη μονάδα δεδομένων  $i'$  (βλέπε Σχ. 47).



Σχ. 47. Οι μηχανισμοί προσοχής μαθαίνουν μία παραμετροποιημένη συνάρτηση  $f^{(\mathbf{w})}(i, i')$  για να μετρήσουν πόσο η μονάδα δεδομένων  $i$  δίνει προσοχή στη μονάδα δεδομένων  $i'$ . Μία ευρέως χρησιμοποιούμενη κατασκευή της  $f^{(\mathbf{w})}(i, i')$  χρησιμοποιεί τα διανύσματα ερωτήματος και κλειδιού, τα οποία δηλώνονται με  $\mathbf{q}^{(i)}$  και  $\mathbf{k}^{(i)}$ , που αποδίδονται σε κάθε μονάδα δεδομένων  $i$  [103].

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, μονάδα δεδομένων, πιθανοτικό μοντέλο, συνάρτηση, παράμετρος, εμπειρική ελαχιστοποίηση

διακινδύνευσης, μοντέλο, διάλυμα.

**προστασία της ιδιωτικότητας** Θεωρούμε κάποια μέθοδο μηχανικής μάθησης  $\mathcal{A}$  που διαβάζει ένα σύνολο δεδομένων  $\mathcal{D}$  και δίνει κάποια έξοδο  $\mathcal{A}(\mathcal{D})$ . Η έξοδος θα μπορούσε να είναι οι παράμετροι μοντέλου  $\hat{\mathbf{w}}$  που μαθαίνονται ή η πρόβλεψη  $\hat{h}(\mathbf{x})$  που προκύπτει για ένα συγκεκριμένο σημείο δεδομένων με χαρακτηριστικά  $\mathbf{x}$ . Πολλές σημαντικές εφαρμογές μηχανικής μάθησης περιλαμβάνουν σημεία δεδομένων που αντιπροσωπεύουν ανθρώπους. Κάθε σημείο δεδομένων χαρακτηρίζεται από χαρακτηριστικά  $\mathbf{x}$ , ενδεχομένως μία ετικέτα  $y$ , και ένα ευαίσθητο ιδιοχαρακτηριστικό  $s$  (π.χ. μία πρόσφατη ιατρική διάγνωση). Στο περίπου, προστασία της ιδιωτικότητας σημαίνει ότι θα έπρεπε να είναι αδύνατο να συμπεράνουμε, από την έξοδο  $\mathcal{A}(\mathcal{D})$ , οποιοδήποτε από τα ευαίσθητα ιδιοχαρακτηριστικά των σημείων δεδομένων στο  $\mathcal{D}$ . Από μαθηματική άποψη, η προστασία της ιδιωτικότητας απαιτεί την μη αντιστρεψιμότητα της απεικόνιση  $\mathcal{A}(\mathcal{D})$ . Γενικά, το να κάνουμε απλώς το  $\mathcal{A}(\mathcal{D})$  μη αντιστρέψιμο είναι συνήθως ανεπαρκές για την προστασία της ιδιωτικότητας. Χρειάζεται να κάνουμε το  $\mathcal{A}(\mathcal{D})$  επαρκώς μη αντιστρέψιμο.

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, model parameter, πρόβλεψη, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, ευαίσθητο ιδιοχαρακτηριστικό, απεικόνιση.

**πυρήνας (μέθοδος πυρήνα)** Θεωρούμε ένα σύνολο σημείων δεδομένων, το καθένα να αναπαριστάται από ένα διάνυσμα χαρακτηριστικών  $\mathbf{x} \in \mathcal{X}$ , όπου  $\mathcal{X}$  δηλώνει τον χώρο χαρακτηριστικών. Ένας πυρήνας (πραγματικής τιμής) είναι μία συνάρτηση  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  που αποδίδει σε κάθε

ζεύγος διανυσμάτων χαρακτηριστικών  $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$  έναν πραγματικό αριθμό  $k(\mathbf{x}, \mathbf{x}')$ . Αυτή η τιμή συνήθως ερμηνεύεται ως ένα μέτρο για την ομοιότητα μεταξύ των  $\mathbf{x}$  και  $\mathbf{x}'$ . Η καθοριστική ιδιότητα ενός πυρήνα είναι ότι είναι συμμετρικός, δηλαδή  $k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x}', \mathbf{x})$ , και ότι για οποιοδήποτε πεπερασμένο σύνολο διανυσμάτων χαρακτηριστικών  $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X}$ , ο πίνακας

$$\mathbf{K} = \begin{pmatrix} k(\mathbf{x}_1, \mathbf{x}_1) & k(\mathbf{x}_1, \mathbf{x}_2) & \dots & k(\mathbf{x}_1, \mathbf{x}_n) \\ k(\mathbf{x}_2, \mathbf{x}_1) & k(\mathbf{x}_2, \mathbf{x}_2) & \dots & k(\mathbf{x}_2, \mathbf{x}_n) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}_n, \mathbf{x}_1) & k(\mathbf{x}_n, \mathbf{x}_2) & \dots & k(\mathbf{x}_n, \mathbf{x}_n) \end{pmatrix} \in \mathbb{R}^{n \times n}$$

είναι θετικά ημιορισμένος. Ένας πυρήνας καθορίζει φυσικά έναν μετασχηματισμό ενός διανύσματος χαρακτηριστικών  $\mathbf{x}$  σε μία συνάρτηση  $\mathbf{z} = k(\mathbf{x}, \cdot)$ . Η συνάρτηση  $\mathbf{z}$  αντιστοιχίζει μία είσοδο  $\mathbf{x}' \in \mathcal{X}$  στην τιμή  $k(\mathbf{x}, \mathbf{x}')$ . Μπορούμε να θεωρήσουμε τη συνάρτηση  $\mathbf{z}$  ως ένα νέο διάνυσμα χαρακτηριστικών που ανήκει σε έναν χώρο χαρακτηριστικών  $\mathcal{X}'$  που είναι συνήθως διαφορετικός από τον  $\mathcal{X}$ . Αυτός ο νέος χώρος χαρακτηριστικών  $\mathcal{X}'$  έχει μία συγκεκριμένη μαθηματική δομή, δηλαδή είναι ένας χώρος Hilbert αναπαραγωγού πυρήνα (reproducing kernel Hilbert space - RKHS) [63], [26]. Δεδομένου ότι το  $\mathbf{z}$  ανήκει σε έναν χώρο Hilbert αναπαραγωγού πυρήνα, ο οποίος είναι ένας διανυσματικός χώρος, μπορούμε να τον ερμηνεύσουμε ως ένα γενικευμένο διάνυσμα χαρακτηριστικών. Σημείωση ότι ένα διάνυσμα χαρακτηριστικών πεπερασμένου μήκους  $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$  μπορεί να θεωρηθεί ως μία συνάρτηση  $\mathbf{x} : \{1, \dots, d\} \rightarrow \mathbb{R}$  που αποδίδει μία πραγματική τιμή σε κάθε δείκτη


$j \in \{1, \dots, d\}$ .

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, χώρος χαρακτηριστικών, συνάρτηση, πίνακας, θετικά ημιορισμένος, χώρος Hilbert, διανυσματικός χώρος, kernel method.

**ρυθμός μάθησης** Θεωρούμε μία επαναληπτική μέθοδο μηχανικής μάθησης για την εύρεση ή μάθηση μίας χρήσιμης υπόθεσης  $h \in \mathcal{H}$ . Μία τέτοια επαναληπτική μέθοδος επαναλαμβάνει όμοια υπολογιστικά βήματα (ενημέρωσης) που προσαρμόζουν ή τροποποιούν την τρέχουσα υπόθεση για να προκύψει μία βελτιωμένη υπόθεση. Μία παράμετρος-κλειδί μίας επαναληπτικής μεθόδου είναι ο ρυθμός μάθησης (learning rate). Ο ρυθμός μάθησης ελέγχει τον βαθμό που η τρέχουσα υπόθεση μπορεί να τροποποιηθεί κατά τη διάρκεια μίας μονής επανάληψης. Θεωρούμε, για παράδειγμα, το βήμα κλίσης [8, Κεφ. 5]

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla f(\mathbf{w}^{(t)}) \quad (4)$$

μίας μεθόδου με βάση την κλίση για εμπειρική ελαχιστοποίηση διακινδύνευσης, όπου η αντικειμενική συνάρτηση  $f(\mathbf{w})$  είναι η εμπειρική διακινδύνευση που προκαλείται από την  $h^{(\mathbf{w})}$  σε ένα σύνολο εκπαίδευσης. Δεδομένων των τρεχουσών παραμέτρων του μοντέλου  $\mathbf{w}^{(t)}$  στην επανάληψη  $t$ , το βήμα κλίσης παράγει ενημερωμένες παραμέτρους του μοντέλου  $\mathbf{w}^{(t+1)}$  μετακινούμενο προς την αντίθετη κατεύθυνση της κλίσης  $\nabla f(\mathbf{w}^{(t)})$ .



Σχ. 48. Η επίδραση ενός ανεπαρκούς ρυθμού μάθησης  $\eta$  στο βήμα κλίσης (4). (a) Αν ο  $\eta$  είναι πολύ μεγάλος, τα βήματα κλίσης μπορεί να «υπερβούν» το βέλτιστο, έτσι ώστε οι επαναλήψεις  $\mathbf{w}^{(t)}$  να αποκλίνουν από αυτό, δηλαδή  $f(\mathbf{w}^{(t+1)}) > f(\mathbf{w}^{(t)})$ . (b) Αν ο  $\eta$  είναι πολύ μικρός, τα βήματα κλίσης σημειώνουν πολύ μικρή πρόοδο προς το βέλτιστο εντός του διαθέσιμου αριθμού επαναλήψεων (λόγω περιορισμένου υπολογιστικού προϋπολογισμού).

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, παράμετρος, επανάληψη, βήμα κλίσης, μέθοδος με βάση την κλίση, εμπειρική ελαχιστοποίηση διακινδύνευσης, αντικειμενική συνάρτηση, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, model parameter, κλίση, κάθοδος κλίσης, στοχαστική κάθοδος κλίσης, προβεβλημένη κάθοδος κλίσης, μέγεθος βήματος.

**σημείο δεδομένων** Ένα σημείο δεδομένων (data point) είναι οποιοδήποτε αντικείμενο που μεταφέρει πληροφορίες [14]. Παραδείγματα περιλαμβάνουν μαθητές, ραδιοσήματα, δέντρα, εικόνες, τυχαίες μεταβλητές, πραγματικούς αριθμούς, ή πρωτεΐνες. Περιγράφουμε σημεία δεδομένων του ίδιου τύπου με δύο κατηγορίες ιδιοτήτων. Η πρώτη κατηγορία περιλαμβάνει χαρακτηριστικά που είναι μετρήσιμες ή υπολογίσιμες ιδιότητες ενός σημείου δεδομένων. Αυτά τα ιδιοχαρακτηριστικά μπορούν να εξαχθούν ή να υπολογιστούν αυτόματα χρησιμοποιώντας αισθητήρες, υπολογιστές, ή άλλα συστήματα συλλογής δεδομένων. Για ένα σημείο δεδομένων που

αναπαριστά έναν ασθενή, ένα χαρακτηριστικό θα μπορούσε να είναι το σωματικό βάρος. Η δεύτερη κατηγορία περιλαμβάνει ετικέτες που είναι υψηλότερου επιπέδου γεγονότα (ή ποσότητες ενδιαφέροντος)—δηλαδή γεγονότα που συνήθως απαιτούν ανθρώπινη εμπειρογνωσία ή γνώση τομέα για να προσδιοριστούν, αντί να είναι άμεσα μετρήσιμα—που σχετίζονται με το σημείο δεδομένων. Για ένα σημείο δεδομένων που αναπαριστά έναν ασθενή, μία διάγνωση καρκίνου που έχει παραχθεί από έναν γιατρό θα μπορούσε να χρησιμεύει ως ετικέτα. Το Σχ. 49 απεικονίζει μία εικόνα ως παράδειγμα ενός σημείου δεδομένων μαζί με τα χαρακτηριστικά και τις ετικέτες του. Σημαντικό είναι ότι το τι συνιστά ένα χαρακτηριστικό ή μία ετικέτα δεν είναι εγγενές στο ίδιο το σημείο δεδομένων—είναι μία επιλογή σχεδιασμού που εξαρτάται από τη συγκεκριμένη εφαρμογή μηχανικής μάθησης.



Ένα μοναδικό σημείο δεδομένων.

Χαρακτηριστικά:

- $x_1, \dots, x_{d_1}$ : Εντάσεις χρώματος όλων των εικονοστοιχείων.
- $x_{d_1+1}$ : Χρονική σήμανση της αποτύπωσης της εικόνας.
- $x_{d_1+2}$ : Χωρική θέση της αποτύπωσης της εικόνας.

Ετικέτες:

- $y_1$ : Ο αριθμός αγελάδων που απεικονίζεται.
- $y_2$ : Ο αριθμός λύκων που απεικονίζεται.
- $y_3$ : Η κατάσταση του βοσκότοπου (π.χ. υγιής, με υπερβόσκηση).

Σχ. 49. Εικονογράφηση ενός σημείου δεδομένων που αποτελείται από μία εικόνα. Μπορούμε να χρησιμοποιήσουμε διαφορετικές ιδιότητες της εικόνας ως χαρακτηριστικά και γεγονότα υψηλότερου επιπέδου για την εικόνα ως ετικέτες.

Η διάκριση μεταξύ χαρακτηριστικών και ετικετών δεν είναι πάντα ξεκάθαρη. Μία ιδιότητα που θεωρείται ετικέτα σε ένα περιβάλλον (π.χ. μία διάγνωση καρκίνου) μπορεί να αντιμετωπίζεται ως χαρακτηριστικό σε ένα



άλλο περιβάλλον—ιδιαίτερα αν η αξιόπιστη αυτοματοποίηση (π.χ. μέσω ανάλυσης εικόνων) επιτρέπει τον υπολογισμό της χωρίς ανθρώπινη παρέμβαση. Η μηχανική μάθηση στοχεύει γενικά στην πρόβλεψη της ετικέτας ενός σημείου δεδομένων με βάση τα χαρακτηριστικά του.

Βλέπε επίσης: data, τυχαία μεταβλητή, χαρακτηριστικό, ετικέτα, μηχανική μάθηση, σύνολο δεδομένων.

**σημείο δεδομένων με ετικέτα** Ένα σημείο δεδομένων του οποίου η ετικέτα είναι γνωστή ή έχει προσδιοριστεί με κάποιον τρόπο που μπορεί να απαιτεί ανθρώπινη εργασία.

Βλέπε επίσης: σημείο δεδομένων, ετικέτα.

**σκληρή συσταδοποίηση** Η σκληρή συσταδοποίηση αναφέρεται στην εργασία χωρισμού ενός συγκεκριμένου συνόλου σημείων δεδομένων σε (μερικές) μη αλληλεπικαλυπτόμενες συστάδες. Η πιο ευρέως χρησιμοποιούμενη μέθοδος σκληρής συσταδοποίησης είναι ο αλγόριθμος  $k$ -μέσων.

Βλέπε επίσης: συσταδοποίηση, σημείο δεδομένων, συστάδα, αλγόριθμος  $k$ -μέσων.

**στατιστική διάσταση** Ως στατιστικές διαστάσεις μίας μεθόδου μηχανικής μάθησης, αναφερόμαστε σε (ιδιότητες της) κατανομή πιθανότητας της εξόδου της κάτω από ένα πιθανοτικό μοντέλο για τα δεδομένα που τροφοδοτούνται στη μέθοδο.

Βλέπε επίσης: μηχανική μάθηση, κατανομή πιθανότητας, πιθανοτικό μοντέλο, data.

**στιβαρότητα** Η στιβαρότητα είναι μία βασική απαίτηση για αξιόπιστη ΤΝ.

Αναφέρεται στην ιδιότητα ενός συστήματος μηχανικής μάθησης να διατη-


ρεί αποδεκτή επίδοση ακόμα και όταν υπόκειται σε διαφορετικές μορφές διαταραχών. Αυτές οι διαταραχές μπορεί να επηρεάσουν τα χαρακτηριστικά ενός σημείου δεδομένων με σκοπό τον χειρισμό της πρόβλεψης που παραδίδεται από ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Η στιβαρότητα περιλαμβάνει επίσης την ευστάθεια μεθόδων βασισμένων στην εμπειρική ελαχιστοποίηση διακινδύνευσης απέναντι σε διαταραχές του συνόλου εκπαίδευσης. Τέτοιες διαταραχές μπορεί να συμβούν εντός επιθέσεων δηλητηρίασης δεδομένων.

Βλέπε επίσης: αξιόπιστη TN, σύστημα μηχανικής μάθησης, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, μηχανική μάθηση, μοντέλο, ευστάθεια, εμπειρική ελαχιστοποίηση διακινδύνευσης, σύνολο εκπαίδευσης, δηλητηρίαση δεδομένων, επίθεση.

**στοίβαξη TBC.**

**στοχαστική κάθοδος κλίσης** Η στοχαστική κάθοδος κλίσης (stochastic gradient descent - SGD) προκύπτει από την καθόδο κλίσης αντικαθιστώντας την κλίση της αντικειμενικής συνάρτησης με μία στοχαστική προσέγγιση. Μία κύρια εφαρμογή της στοχαστικής καθόδου κλίσης είναι η εκπαίδευση ενός παραμετροποιημένου μοντέλου μέσω της εμπειρικής ελαχιστοποίησης διακινδύνευσης πάνω σε ένα σύνολο εκπαίδευσης  $\mathcal{D}$  που είτε είναι πολύ μεγαλύτερο είτε δεν είναι εύκολα διαθέσιμο (π.χ. όταν σημεία δεδομένων αποθηκεύονται σε μία βάση δεδομένων κατανομημένη παγκοσμίως). Για να αξιολογήσουμε την κλίση της εμπειρικής διακινδύνευσης (ως μία συνάρτηση των παραμέτρων μοντέλου  $\mathbf{w}$ ), χρειάζεται να υπολογίσουμε ένα άθροισμα  $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  για όλα τα σημεία

δεδομένων στο σύνολο εκπαίδευσης. Αποκτούμε μία στοχαστική προσέγγιση της κλίσης αντικαθιστώντας το άθροισμα  $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  με ένα άθροισμα  $\sum_{r \in \mathcal{B}} \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  για ένα τυχαία επιλεγμένο υποσύνολο  $\mathcal{B} \subseteq \{1, \dots, m\}$  (βλέπε Σχ. 50). Αναφερόμαστε συχνά σε αυτά τα τυχαία επιλεγμένα σημεία δεδομένων ως μία δέσμη. Το μέγεθος της δέσμης  $|\mathcal{B}|$  είναι μία σημαντική παράμετρος της στοχαστικής καθόδου κλίσης. Η στοχαστική κάθοδος κλίσης με  $|\mathcal{B}| > 1$  αναφέρεται ως στοχαστική κάθοδος κλίσης μίνι-δέσμης [96].



Σχ. 50. Η στοχαστική κάθοδος κλίσης για την εμπειρική ελαχιστοποίηση διακινδύνευσης προσεγγίζει την κλίση αντικαθιστώντας το άθροισμα  $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$  για όλα τα σημεία δεδομένων στο σύνολο εκπαίδευσης (με δείκτες  $r = 1, \dots, m$ ) με ένα άθροισμα για ένα τυχαία επιλεγμένο υποσύνολο  $\mathcal{B} \subseteq \{1, \dots, m\}$ .

Βλέπε επίσης: κάθοδος κλίσης, κλίση, αντικειμενική συνάρτηση, στοχαστική, μοντέλο, εμπειρική ελαχιστοποίηση διακινδύνευσης, σύνολο εκπαίδευσης, σημείο δεδομένων, εμπειρική διακινδύνευση, συνάρτηση, model parameter, δέσμη, παράμετρος.

**στοχαστικός αλγόριθμος** Ένας στοχαστικός αλγόριθμος χρησιμοποιεί έναν τυχαίο μηχανισμό κατά την εκτέλεσή του. Για παράδειγμα, η στοχαστική κάθοδος κλίσης χρησιμοποιεί ένα τυχαία επιλεγμένο υποσύνολο

λο σημείων δεδομένων για να υπολογίσει μία προσέγγιση για την κλίση μίας αντικειμενικής συνάρτησης. Μπορούμε να αναπαραστήσουμε έναν στοχαστικό αλγόριθμο με μία στοχαστική διαδικασία, δηλαδή η πιθανή ακολουθία εκτέλεσης είναι τα πιθανά αποτελέσματα ενός τυχαίου πειράματος [7], [104], [105].

Βλέπε επίσης: στοχαστική, αλγόριθμος, στοχαστική κίνηση, σημείο δεδομένων, κλίση, αντικειμενική συνάρτηση, στοχαστική διαδικασία, τυχαίο πείραμα, μέθοδος βελτιστοποίησης, μέθοδος με βάση την κλίση.

**στρώμα** Ένα βαθύ δίκτυο είναι ένα ΤΝΔ που αποτελείται από διαδοχικά στρώματα (layers), τα οποία έχουν δείκτες  $\ell = 1, 2, \dots, L$ . Το  $\ell$ -οστό στρώμα αποτελείται από τεχνητούς νευρώνες  $a_1^{(\ell)}, \dots, a_{d^{(\ell)}}^{(\ell)}$  με πλάτος στρώματος  $d^{(\ell)}$ . Καθένας από τους τεχνητούς νευρώνες αξιολογεί μία συνάρτηση ενεργοποίησης για ένα σταθμισμένο άθροισμα των εξόδων (ή ενεργοποιήσεων) του προηγούμενου στρώματος  $\ell - 1$ . Η είσοδος στο στρώμα  $\ell = 1$  σχηματίζεται από σταθμισμένα αθροίσματα των χαρακτηριστικών του σημείου δεδομένων για το οποίο το βαθύ δίκτυο υπολογίζει μία πρόβλεψη. Οι εξοδοί των νευρώνων στο στρώμα  $\ell$  χρησιμοποιούνται στη συνέχεια για να σχηματίσουν τις εισόδους των νευρώνων στο επόμενο στρώμα. Το τελικό στρώμα (εξόδου) αποτελείται από έναν μοναδικό νευρώνα του οποίου η έξοδος χρησιμοποιείται ως η πρόβλεψη που παραδίδεται από το βαθύ δίκτυο.


Βλέπε επίσης: βαθύ δίκτυο, ΤΝΔ, συνάρτηση ενεργοποίησης, έξοδος, ενεργοποίηση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη.

**συμμεταβλητή** Βλέπε χαρακτηριστικό.

**συνάρτηση απώλειας** Μία συνάρτηση απώλειας είναι μία απεικόνιση

$$L : \mathcal{X} \times \mathcal{Y} \times \mathcal{H} \rightarrow \mathbb{R}_+ : ((\mathbf{x}, y), h) \mapsto L((\mathbf{x}, y), h).$$

Αποδίδει ένα μη αρνητικό πραγματικό αριθμό (δηλαδή την απώλεια)  $L((\mathbf{x}, y), h)$  σε ένα ζεύγος που αποτελείται από ένα σημείο δεδομένων, με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ , και μία υπόθεση  $h \in \mathcal{H}$ . Η τιμή  $L((\mathbf{x}, y), h)$  ποσοτικοποιεί την απόκλιση μεταξύ της αληθούς ετικέτας  $y$  και της πρόβλεψης  $h(\mathbf{x})$ . Χαμηλότερες (πιο κοντά στο μηδέν) τιμές  $L((\mathbf{x}, y), h)$  υποδεικνύουν μία μικρότερη απόκλιση μεταξύ της πρόβλεψης  $h(\mathbf{x})$  και της ετικέτας  $y$ . Το Σχ. 51 απεικονίζει μία συνάρτηση απώλειας για ένα συγκεκριμένο σημείο δεδομένων, με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ , ως μία συνάρτηση της υπόθεσης  $h \in \mathcal{H}$ .




Σχ. 51. Κάποια συνάρτηση απώλειας  $L((\mathbf{x}, y), h)$  για ένα σταθερό σημείο δεδομένων, με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ , και μία μεταβαλλόμενη υπόθεση  $h$ . Οι μέθοδοι μηχανικής μάθησης προσπαθούν να βρουν (ή να μάθουν) μία υπόθεση που προκαλεί ελάχιστη απώλεια.

Βλέπε επίσης: απώλεια, συνάρτηση, απεικόνιση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, υπόθεση, πρόβλεψη, διάνυσμα χαρακτηριστικών, μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης.

**συνάρτηση ενεργοποίησης** Σε κάθε τεχνητό νευρώνα εντός ενός ΤΝΔ αποδίδεται μία συνάρτηση ενεργοποίησης (activation function)  $\sigma(\cdot)$  που αντιστοιχίζει έναν σταθμισμένο συνδυασμό των εισόδων νευρώνα  $x_1, \dots, x_d$  σε μία μοναδική τιμή εξόδου  $a = \sigma(w_1x_1 + \dots + w_dx_d)$ . Σημείωση ότι κάθε νευρώνας είναι παραμετροποιημένος με τα βάρη  $w_1, \dots, w_d$ .  
Βλέπε επίσης: ΤΝΔ, ενεργοποίηση, συνάρτηση, βάρος.

**συνθήκη μηδενικής κλίσης** Θεωρούμε το μη περιορισμένο πρόβλημα βελτιστοποίησης  $\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w})$  με μία λεία και κυρτή αντικειμενική συνάρτηση  $f(\mathbf{w})$ . Μία αναγκαία και επαρκής συνθήκη για να λύσει ένα διάνυσμα  $\hat{\mathbf{w}} \in \mathbb{R}^d$  αυτό το πρόβλημα είναι η κλίση  $\nabla f(\hat{\mathbf{w}})$  να είναι το μηδενικό διάνυσμα  $\nabla f(\hat{\mathbf{w}}) = \mathbf{0}$  (βλέπε Σχ. 52).



Σχ. 52. Ένα διάνυσμα  $\hat{\mathbf{w}}$  λύνει το πρόβλημα βελτιστοποίησης αν η κλίση ικανοποιεί  $\nabla f(\hat{\mathbf{w}}) = \mathbf{0}$ .

Με άλλα λόγια [22, p. 140],

$$\nabla f(\hat{\mathbf{w}}) = \mathbf{0} \Leftrightarrow f(\hat{\mathbf{w}}) = \min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}).$$

Ορίζοντας τον τελεστή κλίσης  $\nabla f : \mathbb{R}^d \rightarrow \mathbb{R}^d$ , μπορούμε να ξαναγράψουμε τη συνθήκη μηδενικής κλίσης (zero-gradient condition) ως μία εξίσωση


σταθερού σημείου:

$$(\mathcal{I} - \alpha \nabla f) \hat{\mathbf{w}} = \hat{\mathbf{w}}.$$

Εδώ,  $\mathcal{I}$  δηλώνει τον τελεστή ταυτότητας (δηλαδή  $\mathcal{I}(\mathbf{w}) = \mathbf{w}$ ) και  $\alpha$  είναι ένας αυθαίρετος θετικός αριθμός.

Βλέπε επίσης: optimization problem, λεία, κυρτό, αντικειμενική συνάρτηση, διάνυσμα, κλίση, τελεστής, εξίσωση σταθερού σημείου.

**σύνολο** Μία μέθοδος συνόλου (ensemble) συνδυάζει πολλαπλές μεθόδους μηχανικής μάθησης, καθεμία από τις οποίες αναφέρεται ως base learner, ώστε να βελτιώνεται η συνολική επίδοση. Οι base learners μπορούν να είναι βασισμένοι στην εμπειρική ελαχιστοποίηση διακινδύνευσης, χρησιμοποιώντας διαφορετικές επιλογές ως προς την απώλεια, το μοντέλο, και το σύνολο εκπαίδευσης. Συνανθροίζοντας τις προβλέψεις των base learners, οι μέθοδοι συνόλου μπορούν συχνά να επιτύχουν καλύτερη επίδοση από οποιονδήποτε μοναδικό base learner. Η συνάνθροιση μπορεί να ισοδυναμεί με τον μέσο όρο των προβλέψεων των base learners (στην παλινδρόμηση) ή με τη χρήση ψήφου πλειοψηφίας (σε μεθόδους ταξινόμησης).



Σχ. 53. Ένα γενικό σύνολο με τρεις βασε λεαρνερς, με τον καθένα να χρησιμοποιεί εμπειρική ελαχιστοποίηση διακινδύνευσης για να μάθει  $\mathcal{H}^{(j)} \in \mathcal{H}^{(j)}$  με βάση το σύνολο εκπαίδευσης  $\tilde{\mathcal{D}}^{(j)}$ . Ένας βασε λεαρνερ μπορεί επίσης να χρησιμοποιεί την έξοδο άλλων βασε λεαρνερ. Η τελική υπόθεση  $\hat{h}$  προκύπτει από τη συνάνθροιση των υποθέσεων που παράγονται από τους βασε λεαρνερς.

Διαφορετικές μέθοδοι συνόλου χρησιμοποιούν διαφορετικές κατασκευές για τους base learners. Για παράδειγμα, οι μέθοδοι bagging (or bootstrap aggregation) (όπως ένα τυχαίο δάσος) χρησιμοποιούν τυχαία δειγματοληψία για να κατασκευάσουν ελαφρώς διαφορετικά σύνολα εκπαίδευσης για κάθε base learner. Από την άλλη, οι μέθοδοι boosting εκτελούν τους base learners ακολουθιακά, δηλαδή κάθε base learner προσπαθεί να διορθώσει τα σφάλματα πρόβλεψης των προηγούμενων. Μία τρίτη οικογένεια μεθόδων συνόλου είναι η στοίβαξη, όπου οι base learners εκπαιδεύονται στο ίδιο σύνολο εκπαίδευσης αλλά με διαφορετικά μοντέλα.

Βλέπε επίσης: μηχανική μάθηση, base learner, εμπειρική ελαχιστοποίηση διακινδύνευσης, απώλεια, μοντέλο, σύνολο εκπαίδευσης, πρόβλεψη, re-



gression, ταξινόμηση, έξοδος, υπόθεση, bagging, τυχαίο δάσος, boosting, στοίβαξη.

**σύνολο δεδομένων** Ένα σύνολο δεδομένων (dataset) είναι ένα σύνολο διακριτών σημείων δεδομένων. Αυστηρά μιλώντας, ένα σύνολο δεδομένων είναι μία μη διατεταγμένη συλλογή σημείων δεδομένων που δεν περιέχει επαναλήψεις. Ωστόσο, στη βιβλιογραφία της μηχανικής μάθησης ο όρος σύνολο δεδομένων χρησιμοποιείται συχνά ως συνώνυμο του δείγματος, δηλαδή ως μία ακολουθία (ή πεπερασμένη λίστα) σημείων δεδομένων που μπορεί να περιέχει επαναλήψεις. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν σύνολα δεδομένων για την εκπαίδευση και επικύρωση μοντέλων. Η έννοια ενός συνόλου δεδομένων είναι πολύ ευρεία, δηλαδή τα σημεία δεδομένων μπορεί να αναπαριστούν συγκεκριμένες φυσικές οντότητες (όπως άνθρωποι ή ζώα) ή αφηρημένα αντικείμενα (όπως αριθμοί). Για λόγους παραδείγματος, το Σχ. 54 απεικονίζει ένα σύνολο δεδομένων του οποίου τα σημεία δεδομένων είναι αγελάδες.



Σχ. 54. Ένα κοπάδι αγελάδων κάπου στις Άλπεις.

Αρκετά συχνά, ένας μηχανικός μηχανικής μάθησης δεν έχει άμεση πρόσβαση στο υποκείμενο σύνολο δεδομένων. Για παράδειγμα, η πρόσβαση στο σύνολο δεδομένων στο Σχ. 54 θα απαιτούσε να επισκεφτούμε το

κοπάδι αγελάδων. Στην πράξη, εργαζόμαστε με μία βολική αναπαράσταση (ή προσέγγιση) του συνόλου δεδομένων. Διαφορετικά μαθηματικά μοντέλα έχουν αναπτυχθεί για αυτόν τον σκοπό [106], [107], [108], [109]. Ένα από τα πιο ευρέως χρησιμοποιούμενα είναι το σχεσιακό μοντέλο, το οποίο οργανώνει δεδομένα σε μορφή πίνακα (ή σχέσης) [106], [110]. Ένας πίνακας αποτελείται από γραμμές και στήλες, όπου κάθε γραμμή αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και κάθε στήλη αναπαριστά ένα συγκεκριμένο ιδιοχαρακτηριστικό ενός σημείου δεδομένων. Οι μέθοδοι μηχανικής μάθησης συνήθως ερμηνεύουν αυτά τα ιδιοχαρακτηριστικά ως χαρακτηριστικά ή ως μία ετικέτα ενός σημείου δεδομένων. Για παράδειγμα, ο Πίνακας I δείχνει μία σχεσιακή αναπαράσταση του συνόλου δεδομένων στο Σχ. 54. Στο σχεσιακό μοντέλο, η σειρά των γραμμών δεν έχει σημασία, και κάθε ιδιοχαρακτηριστικό (δηλαδή στήλη) σχετίζεται με ένα πεδίο που προσδιορίζει το σύνολο των αποδεκτών τιμών. Σε εφαρμογές μηχανικής μάθησης, αυτά τα πεδία ιδιοχαρακτηριστικών αντιστοιχούν στον χώρο χαρακτηριστικών και τον χώρο ετικετών.

#### ΠΙΝΑΚΑΣ I

ΜΙΑ ΣΧΕΣΗ (Η ΠΙΝΑΚΑΣ) ΠΟΥ ΑΝΑΠΑΡΙΣΤΑ ΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ ΣΤΟ ΣΧ. 54

Όνομα	Βάρος	Ηλικία	Ύψος	Θερμοκρασία στομαχίου
Zenzi	100	4	100	25
Berta	140	3	130	23
Resi	120	4	120	31

Ενώ το σχεσιακό μοντέλο είναι χρήσιμο για τη μελέτη πολλών εφαρμογών μηχανικής μάθησης, μπορεί να είναι ανεπαρκές όσον αφορά τις απαιτήσεις για αξιόπιστη TN. Σύγχρονες προσεγγίσεις, όπως τα φύλλα δεδομένων

για σύνολα δεδομένων, παρέχουν πιο περιεκτικά τεκμήρια, συμπεριλαμβανομένων λεπτομερειών για τη διαδικασία συλλογής των δεδομένων, την επιθυμητή χρήση, και άλλες πληροφορίες σχετικά με τα πλαίσιο [111].

Βλέπε επίσης: σημείο δεδομένων, μηχανική μάθηση, sample, ακολουθία, μοντέλο, εκπαίδευση, επικύρωση, data, χαρακτηριστικό, ετικέτα, domain, χώρος χαρακτηριστικών, χώρος ετικετών, αξιόπιστη TN.

**σύνολο εκπαίδευσης** Ένα σύνολο εκπαίδευσης είναι ένα σύνολο δεδομένων

$D$  που αποτελείται από κάποια σημεία δεδομένων που χρησιμοποιούνται στην εμπειρική ελαχιστοποίηση διακινδύνευσης για τη μάθηση μίας υπόθεσης  $\hat{h}$ . Η μέση απώλεια της  $\hat{h}$  στο σύνολο εκπαίδευσης αναφέρεται ως το σφάλμα εκπαίδευσης. Η σύγκριση του σφάλματος εκπαίδευσης με το σφάλματος επικύρωσης της  $\hat{h}$  μας επιτρέπει να διαγνώσουμε τη μέθοδο μηχανικής μάθησης και ενημερώνει για το πώς να βελτιώσουμε το σφάλμα επικύρωσης (π.χ. χρησιμοποιώντας έναν διαφορετικό χώρο υποθέσεων ή συλλέγοντας περισσότερα σημεία δεδομένων) [8, Ενότητα 6.6].

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, απώλεια, training error, σφάλμα επικύρωσης, μηχανική μάθηση, χώρος υποθέσεων.

**σύνολο ελέγχου** Ένα σύνολο σημείων δεδομένων που δεν έχουν χρησιμο-

ποιηθεί ούτε για την εκπαίδευση ενός μοντέλου (π.χ. μέσω της εμπειρικής ελαχιστοποίησης διακινδύνευσης) ούτε για την επιλογή διαφορετικών μοντέλων σε ένα σύνολο επικύρωσης.

Βλέπε επίσης: σημείο δεδομένων, μοντέλο, εμπειρική ελαχιστοποίηση διακινδύνευσης, σύνολο επικύρωσης.

**σύνολο επικύρωσης** Ένα σύνολο σημείων δεδομένων που χρησιμοποιούνται για την εκτίμηση της διακινδύνευσης μίας υπόθεσης  $\hat{h}$  που έχει μαθευτεί από κάποια μέθοδο μηχανικής μάθησης (π.χ. λύνοντας την εμπειρική ελαχιστοποίηση διακινδύνευσης). Η μέση απώλεια της  $\hat{h}$  στο σύνολο επικύρωσης αναφέρεται ως το σφάλμα επικύρωσης και μπορεί να χρησιμοποιηθεί για τη διάγνωση μίας μεθόδου μηχανικής μάθησης (βλέπε [8, Ενότητα 6.6]). Η σύγκριση μεταξύ σφάλματος εκπαίδευσης και σφάλματος επικύρωσης μπορεί να προσφέρει κατευθύνσεις για τη βελτίωση της μεθόδου μηχανικής μάθησης (όπως τη χρήση ενός διαφορετικού χώρου υποθέσεων).


Βλέπε επίσης: σημείο δεδομένων, διακινδύνευση, υπόθεση, μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, απώλεια, επικύρωση, σφάλμα επικύρωσης, training error, χώρος υποθέσεων.

**συσκευή** Ένα φυσικό σύστημα που μπορεί να αποθηκεύει και να επεξεργάζεται δεδομένα. Στο πλαίσιο της μηχανικής μάθησης, ο όρος συνήθως αναφέρεται σε έναν υπολογιστή που μπορεί να διαβάσει σημεία δεδομένων από διαφορετικές πηγές και να τα χρησιμοποιήσει για να εκπαιδεύσει ένα μοντέλο μηχανικής μάθησης [112].

Βλέπε επίσης: data, μηχανική μάθηση, σημείο δεδομένων, μοντέλο.

**συστάδα** Μία συστάδα (cluster) είναι ένα υποσύνολο σημείων δεδομένων που είναι πιο όμοια μεταξύ τους παρά με τα σημεία δεδομένων εκτός της συστάδας. Το ποσοτικό μέτρο της ομοιότητας μεταξύ σημείων δεδομένων είναι μία επιλογή σχεδιασμού. Αν σημεία δεδομένων χαρακτηρίζονται από Ευκλείδεια διανύσματα χαρακτηριστικών  $\mathbf{x} \in \mathbb{R}^d$ , μπορούμε να ορίσου-

με την ομοιότητα μεταξύ δύο σημείων δεδομένων μέσω της Ευκλείδειας απόστασης μεταξύ των διανυσμάτων χαρακτηριστικών τους. Ένα παράδειγμα τέτοιων συστάδων παρουσιάζεται στο Σχ. 55.



Σχ. 55. Εικονογράφηση τριών συστάδων σε έναν 2-D χώρο χαρακτηριστικών. Κάθε συστάδα ομαδοποιεί σημεία δεδομένων που είναι πιο όμοια μεταξύ τους παρά με αυτά σε άλλες συστάδες, με βάση την Ευκλείδεια απόσταση.

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, χώρος χαρακτηριστικών.

**συσταδοποίηση** Οι μέθοδοι συσταδοποίησης (clustering) διαμερίζουν ένα δεδομένο σύνολο σημείων δεδομένων σε μερικά υποσύνολα, τα οποία αναφέρονται ως συστάδες. Κάθε συστάδα αποτελείται από σημεία δεδομένων

που είναι πιο όμοια μεταξύ τους παρά με σημεία δεδομένων εκτός της συστάδας. Διαφορετικές μέθοδοι συσταδοποίησης χρησιμοποιούν διαφορετικά μέτρα για την ομοιότητα μεταξύ σημείων δεδομένων και διαφορετικές μορφές αναπαράστασης συστάδων. Η μέθοδος συσταδοποίησης του αλγόριθμου  $k$ -μέσων χρησιμοποιεί το μέσο διάνυσμα χαρακτηριστικών μίας συστάδας (δηλαδή τη μέση τιμή της συστάδας) ως τον αντιπρόσωπό της. Μία δημοφιλής μέθοδος μαλακής συσταδοποίησης βασισμένη σε Γκαουσιανό μοντέλο μείγματος αναπαριστά μία συστάδα από μία πολυμεταβλητή κανονική κατανομή.

Βλέπε επίσης: σημείο δεδομένων, συστάδα, μέτρο, αλγόριθμος  $k$ -μέσων, διάνυσμα χαρακτηριστικών, μέση τιμή, μαλακή συσταδοποίηση, Γκαουσιανό μοντέλο μείγματος, πολυμεταβλητή κανονική κατανομή.

**συσταδοποίηση γράφου** Η συσταδοποίηση γράφου (graph clustering) στοχεύει να συσταδοποιήσει σημεία δεδομένων που αναπαριστώνται ως οι κόμβοι ενός γράφου  $\mathcal{G}$ . Οι ακμές του  $\mathcal{G}$  αναπαριστούν κατά ζεύγη ομοιότητες μεταξύ σημείων δεδομένων. Κάποιες φορές μπορούμε να ποσοτικοποιήσουμε την έκταση αυτών των ομοιοτήτων με ένα βάρος ακμής [40], [113].

Βλέπε επίσης: graph, συσταδοποίηση, σημείο δεδομένων, βάρος ακμής.

**συσταδοποίηση με βάση τη ροή** Η συσταδοποίηση με βάση τη ροή ομαδοποιεί τους κόμβους ενός μη κατευθυνόμενου γράφου με την εφαρμογή συσταδοποίησης αλγόριθμου  $k$ -μέσων σε διανύσματα χαρακτηριστικών από θέμα κόμβων. Αυτά τα διανύσματα χαρακτηριστικών κατασκευάζονται από ροές δικτύου μεταξύ προσεκτικά επιλεγμένων πηγών και κόμβων

προορισμού [113].

Βλέπε επίσης: συσταδοποίηση, graph, αλγόριθμος  $k$ -μέσων, διάνυσμα χαρακτηριστικών.

**σφάλμα εκπαίδευσης** Η μέση απώλεια μίας υπόθεσης όταν προβλέπει τις ετικέτες των σημείων δεδομένων σε ένα σύνολο εκπαίδευσης. Κάποιες φορές αναφερόμαστε στο σφάλμα εκπαίδευσης και ως την ελάχιστη μέση απώλεια που επιτυγχάνεται από μία λύση της εμπειρικής ελαχιστοποίησης διακινδύνευσης.

Βλέπε επίσης: απώλεια, υπόθεση, ετικέτα, σημείο δεδομένων, σύνολο εκπαίδευσης, εμπειρική ελαχιστοποίηση διακινδύνευσης.

**σφάλμα εκτίμησης** Θεωρούμε σημεία δεδομένων, καθένα με διάνυσμα χαρακτηριστικών  $\mathbf{x}$  και ετικέτα  $y$ . Σε κάποιες εφαρμογές, μπορούμε να μοντελοποιήσουμε τη σχέση μεταξύ του διανύσματος χαρακτηριστικών και της ετικέτας ενός σημείου δεδομένων ως  $y = \bar{h}(\mathbf{x}) + \varepsilon$ . Εδώ χρησιμοποιούμε κάποια αληθή υποκείμενη υπόθεση  $\bar{h}$  και έναν όρο θορύβου  $\varepsilon$ , ο οποίος συνοψίζει οποιαδήποτε σφάλματα μοντελοποίησης ή ετικετοποίησης. Το σφάλμα εκτίμησης που προκαλείται από μία μέθοδο μηχανικής μάθησης που μαθαίνει μία υπόθεση  $\hat{h}$ , π.χ. χρησιμοποιώντας την εμπειρική ελαχιστοποίηση διακινδύνευσης, ορίζεται ως  $\hat{h}(\mathbf{x}) - \bar{h}(\mathbf{x})$ , για κάποιο διάνυσμα χαρακτηριστικών. Για έναν παραμετρικό χώρο υποθέσεων, ο οποίος αποτελείται από απεικόνιση υπόθεσης καθορισμένες από παράμετρους του μοντέλου  $\mathbf{w}$ , μπορούμε να ορίσουμε το σφάλμα εκτίμησης ως  $\Delta \mathbf{w} = \hat{\mathbf{w}} - \bar{\mathbf{w}}$  [51], [94].

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, ετικέτα,

υπόθεση, μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, χώρος υποθέσεων, απεικόνιση, model parameter.

**σφάλμα επικύρωσης** Θεωρούμε μία υπόθεση  $\hat{h}$  που προκύπτει από κάποια μέθοδο μηχανικής μάθησης, π.χ. χρησιμοποιώντας την εμπειρική ελαχιστοποίηση διακινδύνευσης σε ένα σύνολο εκπαίδευσης. Η μέση απώλεια της  $\hat{h}$  σε ένα σύνολο επικύρωσης, το οποίο είναι διαφορετικό από το σύνολο εκπαίδευσης, αναφέρεται ως το σφάλμα επικύρωσης.

Βλέπε επίσης: υπόθεση, μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, σύνολο εκπαίδευσης, απώλεια, σύνολο επικύρωσης, επικύρωση.

**ταξινόμηση** Η ταξινόμηση είναι μία εργασία καθορισμού μίας ετικέτας διακριτής τιμής  $y$  για ένα δεδομένο σημείο δεδομένων, βασισμένη μόνο στα χαρακτηριστικά του  $\mathbf{x}$ . Η ετικέτα  $y$  ανήκει σε ένα πεπερασμένο σύνολο, όπως  $y \in \{-1, 1\}$  ή  $y \in \{1, \dots, 19\}$ , και αντιπροσωπεύει την κατηγορία στην οποία ανήκει το αντίστοιχο σημείο δεδομένων.

Βλέπε επίσης: ετικέτα, σημείο δεδομένων, χαρακτηριστικό.

**ταξινομητής** Ένας ταξινομητής είναι μία υπόθεση (δηλαδή μία απεικόνιση)  $h(\mathbf{x})$  που χρησιμοποιείται για να προβλεφθεί μία ετικέτα που παίρνει τιμές από ένα πεπερασμένο χώρο ετικετών. Μπορεί να χρησιμοποιήσουμε την ίδια την τιμή συνάρτησης  $h(\mathbf{x})$  ως μία πρόβλεψη  $\hat{y}$  για την ετικέτα. Ωστόσο, είναι σύνηθες να χρησιμοποιούμε μία απεικόνιση  $h(\cdot)$  που παραδίδει μία αριθμητική ποσότητα. Η πρόβλεψη έπειτα προκύπτει από ένα απλό βήμα κατωφλιού. Για παράδειγμα, σε ένα πρόβλημα δυαδικής ταξινόμησης με ένα χώρο ετικετών  $\mathcal{Y} \in \{-1, 1\}$ , μπορεί να χρησιμοποιήσου-



με μία απεικόνιση υπόθεσης πραγματικής τιμής  $h(\mathbf{x}) \in \mathbb{R}$  ως ταξινομητή. Μία πρόβλεψη  $\hat{y}$  μπορεί έπειτα να προκύψει μέσω κατωφλιού,

$$\hat{y} = 1 \text{ για } h(\mathbf{x}) \geq 0 \text{ και } \hat{y} = -1 \text{ διαφορετικά.} \quad (5)$$

Μπορούμε να χαρακτηρίσουμε έναν ταξινομητή από τις περιοχές αποφάσεων  $\mathcal{R}_a$ , για κάθε πιθανή τιμή ετικέτας  $a \in \mathcal{Y}$ .

Βλέπε επίσης: υπόθεση, απεικόνιση, ετικέτα, χώρος ετικετών, συνάρτηση, πρόβλεψη, ταξινόμηση, περιοχή αποφάσεων.

**τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής** Ο τε-

λεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής (least absolute shrinkage and selection operator - Lasso) είναι μία περίπτωση εξηγήσιμης εμπειρικής ελαχιστοποίησης διακινδύνευσης [51]. Μαθαίνει τα βάρη  $\mathbf{w}$  μίας γραμμικής απεικόνισης  $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$  από ένα σύνολο εκπαίδευσης. Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής προκαλείται από γραμμική παλινδρόμηση προσθέτοντας την ανηγμένη  $\ell_1$ -νόρμα  $\alpha \|\mathbf{w}\|_1$  στη μέση απώλεια τετραγωνικού σφάλματος που προκύπτει στο σύνολο εκπαίδευσης [114]. Η χρήση της  $\ell_1$ -νόρμας ως ομαλοποιητή, αντί της τετραγωνικής  $\ell_2$ -νόρμας που χρησιμοποιείται στην αμφικλινή παλινδρόμηση, ενθαρρύνει τα βάρη που έχουν μαθευτεί να έχουν πολλές καταχωρίσεις ίσες με μηδέν [11], [115].

Βλέπε επίσης: εξηγήσιμη εμπειρική ελαχιστοποίηση διακινδύνευσης, βάρος, linear map, σύνολο εκπαίδευσης, γραμμική παλινδρόμηση, νόρμα, απώλεια τετραγωνικού σφάλματος, ομαλοποιητής, αμφικλινής παλινδρόμηση.

**τετραγωνική συνάρτηση** Μία συνάρτηση  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  της μορφής

$$f(\mathbf{w}) = \mathbf{w}^T \mathbf{Q} \mathbf{w} + \mathbf{q}^T \mathbf{w} + a$$

με κάποιον πίνακα  $\mathbf{Q} \in \mathbb{R}^{d \times d}$ , διάνυσμα  $\mathbf{q} \in \mathbb{R}^d$ , και βαθμωτό  $a \in \mathbb{R}$ .

Βλέπε επίσης: συνάρτηση, πίνακας, διάνυσμα.


**τεχνητή νοημοσύνη (TN)** Η TN (artificial intelligence - AI) αναφέρεται

σε συστήματα που συμπεριφέρονται λογικά, με την έννοια της μεγιστοποίησης μίας μακροπρόθεσμης ανταμοιβής. Η προσέγγιση στην TN με βάση τη μηχανική μάθηση είναι να εκπαιδευτεί ένα μοντέλο για να προβλέπει βέλτιστες ενέργειες. Αυτές οι προβλέψεις υπολογίζονται από παρατηρήσεις σχετικά με την κατάσταση του περιβάλλοντος. Η επιλογή της συνάρτησης απώλειας διαφοροποιεί τις εφαρμογές TN από πιο βασικές εφαρμογές μηχανικής μάθησης. Τα συστήματα TN σπάνια έχουν πρόσβαση σε ένα σύνολο εκπαίδευσης με ετικέτες που να επιτρέπει τη μέτρηση της μέσης απώλειας για οποιαδήποτε πιθανή επιλογή παραμέτρων μοντέλου. Αντίθετα, τα συστήματα TN χρησιμοποιούν παρατηρούμενα σήματα ανταμοιβής για να εκτιμήσουν την απώλεια που προκύπτει από την τρέχουσα επιλογή παραμέτρων μοντέλου.

Βλέπε επίσης: ανταμοιβή, μηχανική μάθηση, μοντέλο, πρόβλεψη, κατάσταση, περιβάλλον, συνάρτηση απώλειας, σύστημα τεχνητής νοημοσύνης (σύστημα TN), σύνολο εκπαίδευσης, απώλεια, model parameter, ενισχυτική μάθηση.

**τεχνητό νευρωνικό δίκτυο (TNΔ)** Ένα TNΔ (artificial neural network - ANN) είναι μία γραφική (ροή σήματος) αναπαράσταση μίας υ-

πόθεσης που αντιστοιχίζει τα χαρακτηριστικά ενός σημείου δεδομένων κατά την είσοδό του σε μία πρόβλεψη για την αντίστοιχη ετικέτα κατά την έξοδό του. Η θεμελιώδης υπολογιστική μονάδα ενός ΤΝΔ είναι ο τεχνητός νευρώνας, ο οποίος εφαρμόζει μία συνάρτηση ενεργοποίησης  $\sigma(\cdot)$  στο άθροισμα των εισόδων του. Η έξοδος ενός νευρώνα μπορεί να χρησιμοποιηθεί είτε ως η τελική έξοδος του ΤΝΔ είτε ως μία είσοδος σε άλλους νευρώνες. Μία βασική διάσταση σχεδιασμού ενός ΤΝΔ είναι η δομή συνεκτικότητας (ή αρχιτεκτονική) του, δηλαδή ποιοι έξοδοι νευρώνων συνδέονται με ποιες εισόδους νευρώνων. Όπως απεικονίζεται στο Σχ. 56, μπορούμε να αναπαραστήσουμε ένα ΤΝΔ ως έναν κατευθυνόμενο μη κυκλικό γράφο.



Σχ. 56. Ένα ΤΝΔ μπορεί να αναπαρασταθεί ως ένας σταθμισμένος κατευθυνόμενος μη κυκλικός γράφος με κόμβους που αντιστοιχούν σε νευρώνες ή χαρακτηριστικά ενός σημείου δεδομένων. Τα χαρακτηριστικά μπορούν να θεωρηθούν ως ασήμαντοι νευρώνες χωρίς είσοδο και με μία σταθερή έξοδο που δίνεται από την τιμή του χαρακτηριστικού. Οι σταθμισμένες κατευθυνόμενες ακμές υποδεικνύουν πώς οι έξοδοι των νευρώνων χρησιμοποιούνται ως εισοδοί σε άλλους νευρώνες. Τα βάρη ακμών είναι παράμετροι του μοντέλου που μπορούν να ρυθμιστούν και χρησιμοποιούνται για την κλιμάκωση των εισόδων στους νευρώνες. Η έξοδος κάποιων νευρώνων χρησιμοποιείται ως η πρόβλεψη  $h^{(w)}(\mathbf{x})$ .

Ένας ευρέως χρησιμοποιούμενος τύπος ΤΝΔ είναι τα βαθιά δίκτυα όπου οι νευρώνες σχηματίζουν διαδοχικά στρώματα. Σε ένα βαθύ δίκτυο, οι εξόδοι των νευρώνων σε ένα δεδομένο στρώμα συνδέονται συνήθως μόνο με τις εισόδους των νευρώνων σε ένα διαδοχικό στρώμα. Κάποιες φορές είναι χρήσιμο να προστίθενται συνδέσεις παράκαμψης ή skip connections που συνδέουν άμεσα τις εξόδους των νευρώνων σε ένα στρώμα με τις εισόδους των νευρώνων σε ένα μη διαδοχικό στρώμα [34], [116].

Βλέπε επίσης: υπόθεση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα, έξοδος, συνάρτηση ενεργοποίησης, κατευθυνόμενος μη κυκλικός γράφος, βάρος ακμής, model parameter, βαθύ δίκτυο, στρώμα, skip connection.

### **τμηματοποίηση εικόνας** Η τμηματοποίηση εικόνας (image segmentation)

αναφέρεται στην εργασία της συσταδοποίησης των εικονοστοιχείων μίας εικόνας σε μερικά τμήματα [117], [118]. Κάθε τμήμα είναι ένα υποσύνολο (ή συστάδα) εικονοστοιχείων που είναι όμοια μεταξύ τους ως προς το χρώμα, την υφή, ή άλλες οπτικές ιδιότητες.

Βλέπε επίσης: συσταδοποίηση, συστάδα.

**τοπικό μοντέλο** Θεωρούμε μία συλλογή συσκευών που αναπαριστώνται ως κόμβοι  $\mathcal{V}$  ενός δικτύου ομοσπονδιακής μάθησης. Ένα τοπικό μοντέλο (local model)  $\mathcal{H}^{(i)}$  είναι ένας χώρος υποθέσεων εκχωρημένος σε έναν κόμβο  $i \in \mathcal{V}$ . Διαφορετικοί κόμβοι μπορεί να έχουν διαφορετικούς χώρους υποθέσεων, δηλαδή, γενικά,  $\mathcal{H}^{(i)} \neq \mathcal{H}^{(i')}$  για διαφορετικούς κόμβους  $i, i' \in \mathcal{V}$ . Βλέπε επίσης: συσκευή, δίκτυο ομοσπονδιακής μάθησης, μοντέλο, χώρος υποθέσεων.

**τοπικό σύνολο δεδομένων** Η έννοια του τοπικού συνόλου δεδομένων είναι μεταξύ της έννοιας ενός σημείου δεδομένων και ενός συνόλου δεδομένων. Ένα τοπικό σύνολο δεδομένων αποτελείται από αρκετά μεμονωμένα σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά και ετικέτες. Σε αντίθεση με ένα μονό σύνολο δεδομένων που χρησιμοποιείται σε βασικές μεθόδους μηχανικής μάθησης, ένα τοπικό σύνολο δεδομένων σχετίζεται επίσης με άλλα τοπικά σύνολα δεδομένων μέσω διαφορετικών εννοιών ομοιότητας. Αυτές οι ομοιότητες μπορεί να ανακύψουν από πιθανοτικά μοντέλα ή υποδομές επικοινωνίας και είναι κωδικοποιημένες στις ακμές ενός δικτύου ομοσπονδιακής μάθησης.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, μηχανική μάθηση, πιθανοτικό μοντέλο, δίκτυο ομοσπονδιακής μάθησης.

**τυχαίο δάσος** Ένα τυχαίο δάσος (random forest) είναι ένα σύνολο διαφορετικών δέντρων αποφάσεων. Καθένα από αυτά τα δέντρα αποφάσεων προκύπτει από την προσαρμογή ενός διαταραγμένου αντιγράφου του αρχικού συνόλου δεδομένων.

Βλέπε επίσης: δέντρο αποφάσεων, σύνολο δεδομένων.

**υπερπροσαρμογή** Θεωρούμε μία μέθοδο μηχανικής μάθησης που χρησιμοποιεί εμπειρική ελαχιστοποίηση διακινδύνευσης για να μάθει μία υπόθεση με την ελάχιστη εμπειρική διακινδύνευση σε ένα δεδομένο σύνολο εκπαίδευσης. Μία τέτοια μέθοδος υπερπροσαρμόζει το σύνολο εκπαίδευσης αν μάθει μία υπόθεση με μία χαμηλή εμπειρική διακινδύνευση στο σύνολο εκπαίδευσης αλλά με μία σημαντικά υψηλότερη απώλεια έξω από το

σύνολο εκπαίδευσης.

Βλέπε επίσης: μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, ελάχιστο, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, απώλεια, γενίκευση, επικύρωση, generalization gap.

**υπόθεση** Μία υπόθεση (hypothesis) αναφέρεται σε μία απεικόνιση (ή συνάρτηση)  $h : \mathcal{X} \rightarrow \mathcal{Y}$  από τον χώρο χαρακτηριστικών  $\mathcal{X}$  στον χώρο ετικετών  $\mathcal{Y}$ . Δεδομένου ενός σημείου δεδομένων με χαρακτηριστικά  $\mathbf{x}$ , χρησιμοποιούμε μία απεικόνιση υπόθεσης  $h$  για να εκτιμήσουμε (ή να προσεγγίσουμε) την ετικέτα  $y$  χρησιμοποιώντας την πρόβλεψη  $\hat{y} = h(\mathbf{x})$ . Η μηχανική μάθηση έχει σχέση με τη μάθηση (ή εύρεση) μίας απεικόνιση υπόθεσης  $h$  έτσι ώστε  $y \approx h(\mathbf{x})$  για οποιοδήποτε σημείο δεδομένων (με χαρακτηριστικά  $\mathbf{x}$  και ετικέτα  $y$ ).


Βλέπε επίσης: απεικόνιση, συνάρτηση, χώρος χαρακτηριστικών, χώρος ετικετών, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, πρόβλεψη, μηχανική μάθηση, μοντέλο.

**υπολογιστική διάσταση** Με τις υπολογιστικές διαστάσεις (computational aspects) μίας μεθόδου μηχανικής μάθησης, αναφερόμαστε κυρίως στους υπολογιστικούς πόρους που απαιτούνται για την εκτέλεσή της. Για παράδειγμα, αν μία μέθοδος μηχανικής μάθησης χρησιμοποιεί επαναληπτικές τεχνικές βελτιστοποίησης για να λύσει την εμπειρική ελαχιστοποίηση διακινδύνευσης, τότε οι υπολογιστικές διαστάσεις της περιλαμβάνουν: 1) πόσες αριθμητικές πράξεις χρειάζονται για να εκτελεστεί μία μονή επανάληψη (δηλαδή ένα βήμα κλίσης)· και 2) πόσες επαναλήψεις χρειάζονται για να προκύψουν χρήσιμες παράμετροι μοντέλου. Ένα σημαντικό πα-

ράδειγμα μίας επαναληπτικής τεχνικής βελτιστοποίησης είναι η κάθοδος κλίσης.

Βλέπε επίσης: μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, βήμα κλίσης, model parameter, κάθοδος κλίσης.

**υποπροσαρμογή** Θεωρούμε μία μέθοδο μηχανικής μάθησης που εφαρμόζει την εμπειρική ελαχιστοποίηση διακινδύνευσης για να μάθει μία υπόθεση που ελαχιστοποιεί την εμπειρική διακινδύνευση σε ένα δεδομένο σύνολο εκπαίδευσης. Η μέθοδος λέγεται ότι παρουσιάζει υποπροσαρμογή (underfitting) αν δεν καταφέρει να επιτύχει μία επαρκώς χαμηλή εμπειρική διακινδύνευση στο σύνολο εκπαίδευσης. Υποπροσαρμογή συνήθως συμβαίνει όταν το επιλεγμένο μοντέλο είναι υπερβολικά απλό για να αποτυπώσει την υποκείμενη σχέση μεταξύ χαρακτηριστικών και ετικετών.



Σχ. 57. Καμία γραμμική υπόθεση  $h$  δεν μπορεί να αποτυπώσει τη σχέση μεταξύ χαρακτηριστικών και ετικετών για το απεικονιζόμενο σύνολο εκπαίδευσης. Συνεπώς, οποιαδήποτε μέθοδος που χρησιμοποιεί ένα γραμμικό μοντέλο θα παρουσιάσει υποπροσαρμογή σε αυτό το σύνολο εκπαίδευσης.


Για παράδειγμα, μία μέθοδος μηχανικής μάθησης που χρησιμοποιεί ένα γραμμικό μοντέλο σε δεδομένα με μία υψηλά μη γραμμική σχέση μεταξύ

χαρακτηριστικών και ετικετών δεν θα έχει τη δυνατότητα να μάθει μία υπόθεση με μικρή μέση απώλεια στο σύνολο εκπαίδευσης, πόσο μάλλον με μία χαμηλή διακινδύνευση.

Βλέπε επίσης: μηχανική μάθηση, εμπειρική ελαχιστοποίηση διακινδύνευσης, υπόθεση, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, μοντέλο, χαρακτηριστικό, ετικέτα, γραμμικό μοντέλο, data, απώλεια, διακινδύνευση.


**φασματική συσταδοποίηση** Η φασματική συσταδοποίηση είναι μία συγκεκριμένη περίπτωση συσταδοποίησης γράφου, δηλαδή ομαδοποιεί σημεία δεδομένων που αναπαριστώνται ως οι κόμβοι  $i = 1, \dots, n$  ενός γράφου  $\mathcal{G}$ . Η φασματική συσταδοποίηση χρησιμοποιεί τα ιδιοδιανύσματα του πίνακα Laplace  $\mathbf{L}^{(\mathcal{G})}$  για να κατασκευάσει διανύσματα χαρακτηριστικών  $\mathbf{x}^{(i)} \in \mathbb{R}^d$  για κάθε κόμβο (δηλαδή για κάθε σημείο δεδομένων)  $i = 1, \dots, n$ . Μπορούμε να τροφοδοτήσουμε αυτά τα διανύσματα χαρακτηριστικών σε μεθόδους συσταδοποίησης βασισμένες στον Ευκλείδειο χώρο, όπως τον αλγόριθμο  $k$ -μέσων ή τη μαλακή συσταδοποίηση μέσω Γκαουσιανό μοντέλο μείγματος. Στο περίπου, τα διανύσματα χαρακτηριστικών των κόμβων που ανήκουν σε ένα καλά συνδεδεμένο υποσύνολο (ή συστάδα) κόμβων στο  $\mathcal{G}$  βρίσκονται κοντά στον Ευκλείδειο χώρο  $\mathbb{R}^d$  (βλέπε Σχ. 58).





$$\mathbf{L}^{(\mathcal{G})} = \begin{pmatrix} 2 & -1 & -1 & 0 \\ -1 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$$

(b)



$$\mathbf{V} = (\mathbf{v}^{(1)}, \mathbf{v}^{(2)}, \mathbf{v}^{(3)}, \mathbf{v}^{(4)})$$

$$\mathbf{v}^{(1)} = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}^{(2)} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}$$

(d)


Σχ. 58. (a) Ένας μη κατευθυνόμενος γράφος  $\mathcal{G}$  με τέσσερις κόμβους  $i = 1, 2, 3, 4$ , ο καθένας από τους οποίους αναπαριστά ένα σημείο δεδομένων. (b) Ο πίνακας Laplace  $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{4 \times 4}$  και η ανάλυση ιδιοτιμών του. (c) Ένα διάγραμμα διασποράς των σημείων δεδομένων που χρησιμοποιούν τα διανύσματα χαρακτηριστικών  $\mathbf{x}^{(i)} = (v_i^{(1)}, v_i^{(2)})^T$ . (d) Δύο ιδιοδιανύσματα  $\mathbf{v}^{(1)}, \mathbf{v}^{(2)} \in \mathbb{R}^d$  που αντιστοιχούν στην ιδιοτιμή  $\lambda = 0$  του πίνακα Laplace  $\mathbf{L}^{(\mathcal{G})}$ .

Βλέπε επίσης: συσταδοποίηση, συσταδοποίηση γράφου, σημείο δεδομένων, graph, ιδιοδιάνυσμα, πίνακας Laplace, διάνυσμα χαρακτηριστικών, Ευκλείδειος χώρος, αλγόριθμος  $k$ -μέσων, μαλακή συσταδοποίηση, Γκαουσιανό μοντέλο μείγματος, συστάδα, ανάλυση ιδιοτιμών, διάγραμμα διασποράς, ιδιοτιμή.

**Φινλανδικό Μετεωρολογικό Ινστιτούτο** Το Φινλανδικό Μετεωρολογικό Ινστιτούτο (Finnish Meteorological Institute - FMI) είναι μία κυβερνητική υπηρεσία που είναι υπεύθυνη για τη συγκέντρωση και την έκθεση δεδομένων καιρού στη Φινλανδία.

Βλέπε επίσης: data.

**χαρακτηριστικό** Ένα χαρακτηριστικό (feature) ενός σημείου δεδομένων είναι μία από τις ιδιότητες που μπορούν να μετρηθούν ή να υπολογιστούν εύκολα χωρίς την ανάγκη ανθρώπινης εποπτείας. Για παράδειγμα, αν ένα σημείο δεδομένων είναι μία ψηφιακή εικόνα (π.χ. αποθηκευμένη ως ένα αρχείο .jpeg), τότε θα μπορούσαμε να χρησιμοποιήσουμε τις εντάσεις κόκκινου-πράσινου-μπλε (red-green-blue - RGB) των εικονοστοιχείων της ως χαρακτηριστικά. Ένα άλλο παράδειγμα παρουσιάζεται στο Σχ. 59, όπου τα δείγματα σήματος ενός ηχητικού σήματος πεπερασμένης διάρκειας χρησιμοποιούνται ως χαρακτηριστικά του.



Σχ. 59. Ένα ηχητικό σήμα (μπλε κυματομορφή) και τα διακριτοποιημένα δείγματα σήματός του (κόκκινες κουκκίδες) που μπορούν να χρησιμοποιηθούν ως χαρακτηριστικά του  $x_1, \dots, x_d$ .

Συνώνυμα του όρου χαρακτηριστικό που χρησιμοποιούνται ανάλογα με τον εκάστοτε τομέα είναι «συμμεταβλητή», «εξηγηματική μεταβλητή», «ανεξάρτητη μεταβλητή», «είσοδος (ή μεταβλητή εισόδου)», «προγνωστικός παράγοντας (ή προγνωστική μεταβλητή)», ή «παλινδρομούσα μεταβλητή» [88], [89], [90].

Βλέπε επίσης: σημείο δεδομένων, sample, συμμεταβλητή, προγνωστικός παράγοντας.

**χάσμα γενίκευσης** Το χάσμα γενίκευσης είναι η διαφορά μεταξύ της επίδοσης μίας υπόθεσης  $h \in \mathcal{H}$  στο σύνολο εκπαίδευσης  $\mathcal{D}^{(t)}$  και της επίδοσης σε σημεία δεδομένων εκτός του  $\mathcal{D}^{(t)}$ . Μπορούμε να κάνουμε αυτή την έννοια ακριβή χρησιμοποιώντας ένα πιθανοτικό μοντέλο που μας επιτρέπει να υπολογίσουμε τη διακινδύνευση (ή την αναμενόμενη απώλεια)  $\bar{L}(\hat{h})$  μίας υπόθεσης  $h$ .




Fig. 60. Το χάσμα γενίκευσης μπορεί να οριστεί ως η διαφορά μεταξύ της διακινδύνευσης  $\bar{L}(h)$  και της μέσης απώλειας (ή εμπειρικής διακινδύνευσης)  $\hat{L}(h|\mathcal{D}^{(t)})$  που υπολογίζεται σε ένα σύνολο εκπαίδευσης.

Στην πράξη, η κατανομή πιθανότητας που αποτελεί τη βάση αυτής της προσδοκίας είναι άγνωστη. Συνεπώς, χρειάζεται να εκτιμήσουμε την προσδοκία με βάση παρατηρούμενα σημεία δεδομένων. Οι τεχνικές επικύρωσης χρησιμοποιούν διαφορετικές κατασκευές ενός συνόλου επικύρωσης, το οποίο είναι διαφορετικό από το σύνολο εκπαίδευσης, για να εκτιμήσουν το χάσμα γενίκευσης.

Βλέπε επίσης: γενίκευση, υπόθεση, σύνολο εκπαίδευσης, σημείο δεδομένων, πιθανοτικό μοντέλο, διακινδύνευση, απώλεια, εμπειρική διακινδύνευση, κατανομή πιθανότητας, expectation, επικύρωση, σύνολο επικύρωσης, εμπειρική ελαχιστοποίηση διακινδύνευσης, συνάρτηση απώλειας.

## χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα

DBSCAN refers to a συσταδοποίηση αλγόριθμος for σημείο δεδομένων

that are characterized by numeric διάνυσμα χαρακτηριστικών. Like αλγόριθμος  $k$ -μέσων and μαλακή συσταδοποίηση via Γκαουσιανό μοντέλο μείγματος, DBSCAN also uses the Ευκλείδεια απόσταση between διάνυσμα χαρακτηριστικών to determine the συστάδας. However, in contrast to αλγόριθμος  $k$ -μέσων and Γκαουσιανό μοντέλο μείγματος, DBSCAN uses a different notion of similarity between σημείο δεδομένων. DBSCAN considers two σημείο δεδομένων as similar if they are connected via a ακολουθία (i.e., path) of nearby intermediate σημείο δεδομένων. Thus, DBSCAN might consider two σημείο δεδομένων as similar (and therefore belonging to the same cluster) even if their διάνυσμα χαρακτηριστικών have a large Ευκλείδεια απόσταση.

See also: συσταδοποίηση, αλγόριθμος, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, αλγόριθμος  $k$ -μέσων, μαλακή συσταδοποίηση, Γκαουσιανό μοντέλο μείγματος, συστάδα, graph.


**χώρος ετικετών** Θεωρούμε μία εφαρμογή μηχανικής μάθησης που περιλαμβάνει σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά και ετικέτες. Ο χώρος ετικετών αποτελείται από όλες τις πιθανές τιμές που η ετικέτα ενός σημείου δεδομένων μπορεί να πάρει. Οι μέθοδοι παλινδρόμησης, που στοχεύουν να προβλέψουν αριθμητικές ετικέτες, συχνά χρησιμοποιούν τον χώρο ετικετών  $\mathcal{Y} = \mathbb{R}$ . Μέθοδοι δυαδικής ταξινόμησης χρησιμοποιούν έναν χώρο ετικετών που αποτελείται από δύο διαφορετικά στοιχεία, π.χ.

- $\mathcal{Y} = \{-1, 1\}$ .
- $\mathcal{Y} = \{0, 1\}$ .

- $\mathcal{Y} = \{\text{«εικόνα γάτας»}, \text{«όχι εικόνα γάτας»}\}.$

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, regression, ταξινόμηση.

**παραμετρικός χώρος** Ο παραμετρικός χώρος  $\mathcal{W}$  ενός μοντέλου μηχανικής μάθησης  $\mathcal{H}$  είναι το σύνολο όλων των εφικτών επιλογών για τις παράμετρους του μοντέλου (βλέπε Σχ. 61). Πολλές σημαντικές μέθοδοι μηχανικής μάθησης χρησιμοποιούν ένα μοντέλο που είναι παραμετροποιημένο με διανύσματα του Ευκλείδειου χώρου  $\mathbb{R}^d$ . Δύο ευρέως χρησιμοποιούμενα παραδείγματα παραμετροποιημένων μοντέλων είναι τα γραμμικά μοντέλα και τα βαθιά δίκτυα. Ο παραμετρικός χώρος είναι συχνά τότε ένα υποσύνολο  $\mathcal{W} \subseteq \mathbb{R}^d$ , π.χ. όλα τα διανύσματα  $\mathbf{w} \in \mathbb{R}^d$  με μία νόρμα μικρότερη από ένα.



Σχ. 61. Ο παραμετρικός χώρος  $\mathcal{W}$  ενός μοντέλου μηχανικής μάθησης  $\mathcal{H}$  αποτελείται από όλες τις εφικτές επιλογές για τις παράμετρους του μοντέλου. Κάθε επιλογή  $\mathbf{w}$  για τις παράμετρους του μοντέλου επιλέγει μία απεικόνιση υπόθεσης  $h(\mathbf{w}) \in \mathcal{H}$ .

Βλέπε επίσης: παράμετρος, μηχανική μάθηση, μοντέλο, model parameter, διάνυσμα, Ευκλείδειος χώρος, γραμμικό μοντέλο, βαθύ δίκτυο, νόρμα,

υπόθεση, απεικόνιση.

**φασματογράφημα** A spectrogram represents the time-frequency distribution of the energy of a time signal  $x(t)$ . Intuitively, it quantifies the amount of signal energy present within a specific time segment  $[t_1, t_2] \subseteq \mathbb{R}$  and frequency interval  $[f_1, f_2] \subseteq \mathbb{R}$ . Formally, the spectrogram of a signal is defined as the squared magnitude of its short-time Fourier transform (STFT) [119]. Fig. 62 depicts a time signal along with its spectrogram.

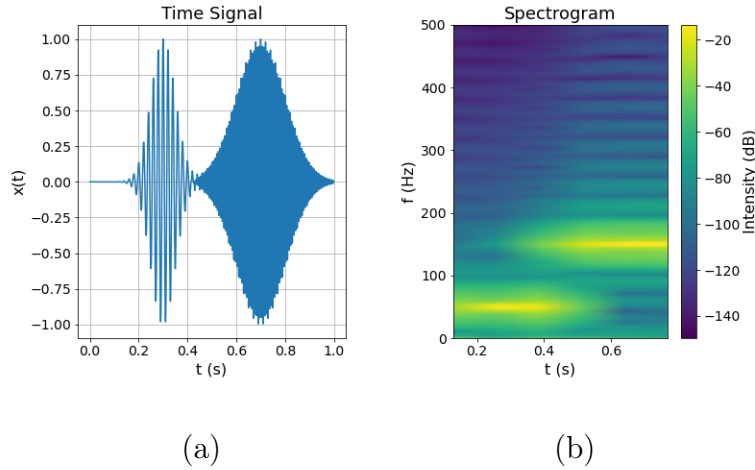


Fig. 62. (a) A time signal consisting of two modulated Γκαουσιανός pulses. (b) An intensity plot of the spectrogram.

The intensity plot of its spectrogram can serve as an image of a signal. A simple recipe for audio signal ταξινόμηση is to feed this signal image into βαθύ δίκτυος originally developed for image ταξινόμηση and object detection [120]. It is worth noting that, beyond the spectrogram, several alternative representations exist for the time-frequency distribution of

signal energy [121], [122].

See also: ταξινόμηση, βαθύ δίκτυο.

**χώρος υποθέσεων** TBC.

**χώρος χαρακτηριστικών** TBC.

**0/1 απώλεια** Η 0/1 απώλεια  $L^{(0/1)}((\mathbf{x}, y), h)$  μετράει την ποιότητα ενός ταξινομητή  $h(\mathbf{x})$  που παραδίδει μία πρόβλεψη  $\hat{y}$  (π.χ. μέσω κατωφλίου (5)) για την ετικέτα  $y$  ενός σημείου δεδομένων με χαρακτηριστικά  $\mathbf{x}$ . Είναι ίση με 0 αν η πρόβλεψη είναι σωστή, δηλαδή  $L^{(0/1)}((\mathbf{x}, y), h) = 0$  όταν  $\hat{y} = y$ . Είναι ίση με 1 αν η πρόβλεψη είναι λανθασμένη, δηλαδή  $L^{(0/1)}((\mathbf{x}, y), h) = 1$  όταν  $\hat{y} \neq y$ .

Βλέπε επίσης: απώλεια, ταξινομητής, πρόβλεψη, ετικέτα, σημείο δεδομένων, χαρακτηριστικό.

**bagging (or bootstrap aggregation)** TBC.

**base learner** A base learner is an μηχανική μάθηση method that is part of an σύνολο method.

See also: σύνολο, bagging, στοίβαξη, boosting.

**batch learning** TBC.

**boosting** TBC.

**clustered federated learning (CFL)** TBC.

**concept activation vector (CAV)** TBC.



**epoch** TBC.

**federated averaging (FedAvg)** TBC.

**federated gradient descent (FedGD)** TBC.

**federated proximal (FedProx)** TBC.

**FedRelax** TBC.

**federated stochastic gradient descent (FedSGD)** TBC.

**Jacobi method** TBC.

**local interpretable model-agnostic explanations (LIME)** TBC.

**leave-one-out cross-validation (LOO-CV)** LOO-CV is a special case of

διασταυρούμενη επικύρωση  $k$ -αναδιπλώσεων where the σύνολο επικύρωσης is of size one, i.e., a single σημείο δεδομένων.

See also: διασταυρούμενη επικύρωση  $k$ -αναδιπλώσεων, επικύρωση, σφάλμα επικύρωσης.

**missing data** TBC.

**multi-label classification** TBC.

**natural language processing (NLP)** TBC.

**networked data** TBC.

**networked exponential families (nExpFam)** TBC.

**networked federated learning (NFL)** TBC.

**networked model** TBC.

**online gradient descent (online GD)** TBC.

**rectified linear unit (ReLU)** TBC.

**skip connection** TBC.

## Ενισχυτική Μάθηση

**αξιολόγηση πολιτικής (ενισχυτική μάθηση)** Η αξιολόγηση πολιτικής (policy evaluation) αναφέρεται στον υπολογισμό της συνάρτησης κατάστασης-τιμής  $v_\pi$  μίας δεδομένης πολιτικής  $\pi$  σε μία διαδικασία απόφασης Markov. Μία ευρέως χρησιμοποιούμενη μεθοδος, η οποία αναφέρεται ως επαναληπτική αξιολόγηση πολιτικής, βασίζεται στον χαρακτηρισμό της  $v_\pi$  ως σταθερού σημείου του τελεστή Bellman  $\mathcal{F}^{(\pi)}$ . Συγκεκριμένα, ξεκινώντας από μία αρχική συνάρτηση τιμής  $v_0$ , εφαρμόζουμε επαναληπτικά τον τελεστή Bellman  $\mathcal{F}^{(\pi)}$ , ώστε να προκύψει μία ακολουθία συναρτήσεων τιμής  $v_1, v_2, \dots$  σύμφωνα με

$$v_{t+1} = \mathcal{F}^{(\pi)}v_t, \quad t = 0, 1, 2, \dots$$

Υπό ήπιες συνθήκες, αυτή η επανάληψη σταθερού σημείου συγκλίνει στη  $v_\pi$  καθώς  $t \rightarrow \infty$  [29, Ενότητα 4.2].

Βλέπε επίσης: πολιτική, συνάρτηση κατάστασης-τιμής, διαδικασία απόφασης Markov, σταθερό σημείο, τελεστής Bellman, συνάρτηση τιμής, ακολουθία, επανάληψη σταθερού σημείου.

**διαδικασία απόφασης Markov** Μία διαδικασία απόφασης Markov (Markov decision process - MDP) είναι μία μαθηματική δομή για τη μελέτη της ενισχυτικής μάθησης. Τυπικά, μία διαδικασία απόφασης Markov είναι μία στοχαστική διαδικασία που ορίζεται από μία συγκεκριμένη επιλογή για

- έναν χώρο καταστάσεων  $\mathcal{S}$ .
- έναν χώρο ενεργειών  $\mathcal{A}$ .

- μία συνάρτηση μετάβασης  $\mathbb{P}(s' | s, a)$  που προσδιορίζει την κατανομή πιθανότητας υπό συνθήκη  $\mathbb{P}(s'|s,a)$  της επόμενης κατάστασης  $s' \in \mathcal{S}$ , δεδομένης της τρέχουσας κατάστασης  $s \in \mathcal{S}$  και ενέργειας  $a \in \mathcal{A}$ .
- μία συνάρτηση ανταμοιβής  $r(s, a) \in \mathbb{R}$  που αποδίδει μία αριθμητική ανταμοιβή σε κάθε ζεύγος κατάστασης-ενέργειας  $(s, a)$ .

Για μία δεδομένη πολιτική  $\pi$ , αυτές οι συνιστώσες ορίζουν την κατανομή πιθανότητας μίας ακολουθίας

$$s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_t, a_t, r_t$$

τυχαίων μεταβλητών. Η καθοριστική ιδιότητα μίας διαδικασίας απόφασης Markov είναι η ιδιότητα Markov. Για την ακρίβεια, στη χρονική στιγμή  $t$ , η κατανομή πιθανότητας υπό συνθήκη της επόμενης κατάστασης  $s_{t+1}$  και της ανταμοιβής  $r_t$  εξαρτάται από το παρελθόν μόνο μέσω της τρέχουσας κατάστασης  $s_t$  και ενέργειας  $a_t$ . Οι μέθοδοι ενισχυτικής μάθησης προσπαθούν να μάθουν μία πολιτική  $\pi$  που μεγιστοποιεί την αναμενόμενη απόδοση

$$\mathbb{E} \left\{ \sum_{t=1}^{\infty} \gamma^{t-1} r_t \mid s_1 \right\}.$$

Η σταθεροποίηση της αρχικής κατάστασης  $s_1$  υποδεικνύει ότι η αναμενόμενη απόδοση αξιολογείται ακολουθώντας την πολιτική  $\pi$  από μία δεδομένη αρχική κατάσταση. Η αναμενόμενη απόδοση περιλαμβάνει τον παράγοντα προεξόφλησης  $\gamma \in (0, 1)$  που προσδιορίζει τη σχετική σημασία μελλοντικών ανταμοιβών σε σύγκριση με την άμεση ανταμοιβή. Ο παράγοντας προεξόφλησης  $\gamma$  είναι συνήθως σταθερός για μία δεδομένη

διαδικασία απόφασης Markov και ελέγχει τον συμβιβασμό μεταξύ βραχυπρόθεσμης και μακροπρόθεσμης ανταμοιβής. Οι διαδικασίες απόφασης Markov χρησιμοποιούνται ευρέως στη ρομποτική, στα παιχνίδια, και στα αυτόνομα συστήματα για τη μοντελοποίηση προβλημάτων λήψης αποφάσεων, όπου ένας πράκτορας αλληλεπιδρά με ένα περιβάλλον για την επίτευξη ενός στόχου [29], [30], [123].

Βλέπε επίσης: ενισχυτική μάθηση, στοχαστική διαδικασία, χώρος καταστάσεων, χώρος ενεργειών, συνάρτηση, κατανομή πιθανότητας υπό συνθήκη, κατάσταση, ενέργεια, ανταμοιβή, πολιτική, κατανομή πιθανότητας, ακολουθία, τυχαία μεταβλητή, ιδιότητα Markov, πράκτορας, περιβάλλον.


**ενέργεια** Μία ενέργεια (action) αναφέρεται σε μία απόφαση που λαμβάνεται από ένα σύστημα TN σε ένα δεδομένο χρονικό βήμα  $t$  που επηρεάζει το παρατηρούμενο σήμα ανταμοιβής. Οι ενέργειες είναι στοιχεία ενός χώρου ενεργειών  $\mathcal{A}$  και συνήθως δηλώνονται με  $a_t \in \mathcal{A}$ . Η ενέργεια  $a_t$  επιλέγεται βάσει του διανύσματος χαρακτηριστικών  $\mathbf{x}^{(t)}$  (το οποίο συλλέγει όλες τις διαθέσιμες παρατηρήσεις) και της τρέχουσας υπόθεσης  $h^{(t)}$ . Η ενισχυτική μάθηση χρησιμοποιεί μεθόδους διαδικτυακή μάθηση για να μάθει μία υπόθεση  $h^{(t)}$  που προβλέπει μία (σχεδόν) βέλτιστη ενέργεια. Η χρησιμότητα της πρόβλεψης  $a_t$  αξιολογείται έμμεσα μέσω του επακόλουθου σήματος ανταμοιβής  $r^{(t)}$ . Στην ειδική περίπτωση ενός MAB, το σύνολο των πιθανών ενεργειών είναι πεπερασμένο και κάθε ενέργεια αντιστοιχεί στην επιλογή ενός arm. Σε πιο γενικά περιβάλλον ενισχυτικής μάθησης, ο χώρος ενεργειών μπορεί να είναι συνεχής.

Βλέπε επίσης: σύστημα TN, ανταμοιβή, χώρος ενεργειών, διάνυσμα χαρακτηριστικών, υπόθεση, ενισχυτική μάθηση, διαδικτυακή μάθηση, πρό-

βλεψη, MAB, συνεχής, συνάρτηση απώλειας.

### ενισχυτική μάθηση Η ενισχυτική μάθηση (reinforcement learning - RL)

αναφέρεται σε ένα περιβάλλον διαδικτυακής μάθησης όπου μπορούμε να αξιολογήσουμε τη χρησιμότητα μίας μοναδικής υπόθεσης (δηλαδή μίας συγκεκριμένης επιλογής παραμέτρων μοντέλου) σε κάθε χρονικό βήμα  $t$ . Συγκεκριμένα, οι μέθοδοι ενισχυτικής μάθησης εφαρμόζουν την τρέχουσα υπόθεση  $h^{(t)}$  στο διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(t)}$  του νέου σημείου δεδομένων για να προβλέψουν την επόμενη ενέργεια. Η χρησιμότητα της επακόλουθης πρόβλεψης  $h^{(t)}(\mathbf{x}^{(t)})$  ποσοτικοποιείται από ένα σήμα ανταμοιβής  $r^{(t)}$  (βλέπε Σχ. 63).



Σχ. 63. Τρία διαδοχικά χρονικά βήματα  $t, t+1, t+2$  με αντίστοιχες συναρτήσεις απώλειας  $L^{(t)}, L^{(t+1)}, L^{(t+2)}$ . Κατά το χρονικό βήμα  $t$ , μία μέθοδος ενισχυτικής μάθησης μπορεί αξιολογήσει τη συνάρτηση απώλειας μόνο για μία συγκεκριμένη υπόθεση  $h^{(t)}$ , οδηγώντας στο σήμα ανταμοιβής  $r^{(t)} = -L^{(t)}(h^{(t)})$ .

Γενικά, η ανταμοιβή εξαρτάται επίσης από τις προηγούμενες προβλέψεις  $h^{(t')}(x^{(t')})$  για  $t' < t$ . Ο στόχος της ενισχυτικής μάθησης είναι να μάθει την  $h^{(t)}$ , για κάθε χρονικό βήμα  $t$ , έτσι ώστε να μεγιστοποιηθεί η (πιθανώς προεξοφλημένη) αθροιστική ανταμοιβή [8], [29].

Βλέπε επίσης: διαδικτυακή μάθηση, υπόθεση, model parameter, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, ενέργεια, πρόβλεψη, ανταμοιβή, συνάρτηση απώλειας, μηχανική μάθηση.

**επανάληψη τιμής** Θεωρούμε μία διαδικασία απόφασης Markov με τον συσχετισμένο τελεστή Bellman  $\mathcal{F}$ . Η συνάρτηση κατάστασης-τιμής  $v^*$  της βέλτιστης πολιτικής είναι ένα σταθερό σημείο του  $\mathcal{F}$ , δηλαδή  $v^* = \mathcal{F}v^*$ . Η επανάληψη τιμής (value iteration) είναι η επανάληψη σταθερού σημείου για τον υπολογισμό της  $v^*$  μέσω της επαναλαμβανόμενης εφαρμογής του  $\mathcal{F}$  σε μία αρχική συνάρτηση τιμής  $v_0$  [29, Ενότητα 4.4].

Βλέπε επίσης: διαδικασία απόφασης Markov, τελεστής Bellman, συνάρτηση κατάστασης-τιμής, πολιτική, σταθερό σημείο, επανάληψη, επανάληψη σταθερού σημείου, συνάρτηση τιμής.

**περιβάλλον (ενισχυτική μάθηση)** Ένα περιβάλλον (environment) δλώνει το εξωτερικό σύστημα με το οποίο ένας πράκτορας προοδευτικά αλληλεπιδρά. Κατά τη διάρκεια κάθε χρονικού βήματος  $t$ , το περιβάλλον παρέχει στον πράκτορα ένα διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(t)}$  και, σε απάντηση της ενέργειας  $a^{(t)}$  του πράκτορα, μία ανταμοιβή  $r^{(t)}$  [29].

Βλέπε επίσης: πράκτορας, διάνυσμα χαρακτηριστικών, ενέργεια, ανταμοιβή.

**πολιτική (ενισχυτική μάθηση)** Μία πολιτική (policy) είναι μία συνάρτηση που προσδιορίζει πώς επιλέγεται η επόμενη ενέργεια  $a_t$  σε μία διαδικασία απόφασης Markov όταν η τρέχουσα κατάσταση είναι  $s_t$ . Συνήθως, μία πολιτική είναι στοχαστική, που σημαίνει ότι ορίζει μία κατανομή πιθανότητας υπό συνθήκη  $\mathbb{P}^{(a|s)}$  πάνω στις ενέργειες για μία δεδομένη τρέχουσα

κατάσταση. Μπορούμε να θεωρήσουμε μία πολιτική και ως μία υπόθεση που χρησιμοποιεί χαρακτηριστικά που προκύπτουν από την τρέχουσα κατάσταση για να προβλέψει την καλύτερη επόμενη ενέργεια [29].

Βλέπε επίσης: συνάρτηση, ενέργεια, διαδικασία απόφασης Markov, κατάσταση, στοχαστική, κατανομή πιθανότητας υπό συνθήκη, υπόθεση, χαρακτηριστικό.

**πράκτορας** Ένας πράκτορας (agent) δηλώνει οποιοδήποτε σύστημα που υλοποιεί κάποια μορφή διαδικτυακής μάθησης [29], [124]. Κατά τη διάρκεια κάθε χρονικού βήματος  $t$ , ένας πράκτορας λαμβάνει ένα διάνυσμα χαρακτηριστικών  $\mathbf{x}^{(t)}$  που παρέχει (συνήθως ελλιπείς) πληροφορίες για την υποκείμενη κατάσταση του συστήματος. Ο πράκτορας τότε εφαρμόζει την τρέχουσα υπόθεσή του  $h^{(t)}$  για να επιλέξει μία ενέργεια  $a^{(t)} = h^{(t)}(\mathbf{x}^{(t)})$ . Έπειτα λαμβάνει μία ανταμοιβή  $r^{(t)}$  που ποσοτικοποιεί τη χρησιμότητα αυτής της ενέργειας και στη συνέχεια καθοδηγεί την προσαρμογή της υπόθεσής του (ή της παράμετρου μοντέλου).

Βλέπε επίσης: διαδικτυακή μάθηση, διάνυσμα χαρακτηριστικών, κατάσταση, υπόθεση, ενέργεια, ανταμοιβή, model parameter, ενισχυτική μάθηση.

**ρήτρα μεταβολής γνώμης** Η ρήτρα μεταβολής γνώμης (regret) μίας υπόθεσης  $h$  σε σχέση με μία άλλη υπόθεση  $h'$ , η οποία χρησιμεύει ως βάση αναφοράς, είναι η διαφορά μεταξύ της απώλειας που προκαλείται από την  $h$  και της απώλειας που προκαλείται από την  $h'$  [75]. Η υπόθεση  $h'$  που είναι η βάση αναφοράς αναφέρεται επίσης ως εμπειρογνώμονας.

Βλέπε επίσης: υπόθεση, βάση αναφοράς, απώλεια, εμπειρογνώμονας.

**συνάρτηση κατάστασης-τιμής** Για μία δεδομένη διαδικασία απόφασης Markov,



οποιαδήποτε πολιτική  $\pi$  επάγει φυσικά μία συνάρτηση τιμής  $v_\pi : \mathcal{S} \rightarrow \mathbb{R}$ .

Η τιμή  $v_\pi(s)$  είναι η αναμενόμενη απόδοση όταν η διαδικασία απόφασης Markov ξεκινάει από μία δεδομένη κατάσταση  $s \in \mathcal{S}$  και οι ενέργειες επιλέγονται σύμφωνα με την  $\pi$ .

Βλέπε επίσης: διαδικασία απόφασης Markov, πολιτική, συνάρτηση τιμής, κατάσταση, ενέργεια.

**συνάρτηση τιμής** Στο πλαίσιο μίας διαδικασίας απόφασης Markov, η συνάρτηση τιμής (value function)  $v : \mathcal{S} \rightarrow \mathbb{R}$  αποδίδει σε κάθε κατάσταση  $s \in \mathcal{S}$  έναν πραγματικό αριθμό  $v(s)$  που ποσοτικοποιεί τη μακροπρόθεσμη επιθυμητότητα της κατάστασης  $s$ .

Βλέπε επίσης: διαδικασία απόφασης Markov, συνάρτηση, κατάσταση.

**τελεστής Bellman** Ο τελεστής Bellman (Bellman operator)  $\mathcal{F}$  που σχετίζεται με μία διαδικασία απόφασης Markov ορίζεται στον χώρο όλων των συναρτήσεων τιμής. Συγκεκριμένα, αντιστοιχίζει μία συνάρτηση τιμής  $v : \mathcal{S} \rightarrow \mathbb{R}$  σε μία άλλη συνάρτηση τιμής  $v' : \mathcal{S} \rightarrow \mathbb{R}$  σύμφωνα με

$$v'(s) = \max_{a \in \mathcal{A}} \left( \mathbb{E}\{r(s, a) \mid s, a\} + \gamma \mathbb{E}\{v(s') \mid s, a\} \right)$$

όπου  $\gamma \in (0, 1)$  είναι ένας παράγοντας προεξόφλησης και  $s'$  είναι η επόμενη κατάσταση που παράγεται σύμφωνα με τη συνάρτηση μετάβασης,  $s' \sim \mathbb{P}(s' \mid s, a)$ . Η συνάρτηση κατάστασης-τιμής  $v^*$  της βέλτιστης πολιτικής  $\pi^*$  είναι ένα σταθερό σημείο του τελεστή Bellman,  $v^* = \mathcal{F}v^*$ . Αυτή η εξίσωση σταθερού σημείου είναι φυσικά κατάλληλη για τη μέθοδο επανάληψης τιμής για τον υπολογισμό της συνάρτησης κατάστασης-τιμής μίας βέλτιστης πολιτικής. Πέρα από τον τελεστή Bellman που σχετίζεται

με μία διαδικασία απόφασης Markov, υπάρχει και ένας τελεστής Bellman  $\mathcal{F}^{(\pi)}$  που σχετίζεται με μία πολιτική  $\pi$ . Στην περίπτωση αυτή, ο τελεστής Bellman ορίζεται ως

$$\mathcal{F}^{(\pi)}v(s) = \mathbb{E}\{r(s, a) \mid s, a\} + \gamma \mathbb{E}\{v(s') \mid s, a\}$$

όπου  $s' \sim \mathbb{P}(s' \mid s, a)$  και η  $a$  επιλέγεται σύμφωνα με την  $\pi$ . Η συνάρτηση κατάστασης-τιμής  $v_\pi$  είναι ένα σταθερό σημείο του  $\mathcal{F}^{(\pi)}$ ,  $v_\pi = \mathcal{F}^{(\pi)}v_\pi$ . Αυτή η εξίσωση σταθερού σημείου μπορεί να λυθεί μέσω μίας επανάληψης σταθερού σημείου που είναι γνωστή ως αξιολόγηση πολιτικής. Ο τελεστής Bellman πήρε το όνομά του από τον Richard Bellman, ο οποίος τον εισήγαγε στο πλαίσιο του δυναμικού προγραμματισμού [125]. Ο τελεστής Bellman είναι μία έννοια-κλειδί στην ενισχυτική μάθηση και χρησιμοποιείται για την παραγωγή αλγόριθμων για τη λύση διαδικασιών απόφασης Markov, όπως η επανάληψη τιμής και η επανάληψη πολιτικής [29].

Βλέπε επίσης: τελεστής, διαδικασία απόφασης Markov, συνάρτηση τιμής, κατάσταση, συνάρτηση, συνάρτηση κατάστασης-τιμής, πολιτική, σταθερό σημείο, εξίσωση σταθερού σημείου, επανάληψη τιμής, επανάληψη σταθερού σημείου, αξιολόγηση πολιτικής, ενισχυτική μάθηση, αλγόριθμος, επανάληψη.

**χώρος ενεργειών** Βλέπε ενέργεια.

**multiarmed bandit (MAB)** TBC.

**stochastic multiarmed bandit (stochastic MAB)** TBC.

## Συστήματα Μηχανικής Μάθησης

**αυτόματο** Ένα αυτόματο (automaton) είναι μία μαθηματική αναπαράσταση μίας υπολογιστικής συσκευής, της οποίας η συμπεριφορά περιγράφεται από ένα σύνολο εσωτερικών καταστάσεων, μία δομή μνήμης, και έναν κανόνα κατάστασης-μετάβασης. Τυπικά, ένα αυτόματο αποτελείται από έναν χώρο καταστάσεων, ένα σύνολο αποδεκτών διαθρώσεων μνήμης, και μία συνάρτηση μετάβασης που προσδιορίζει το πώς η τρέχουσα κατάσταση και η μνήμη ενημερώνονται ως απάντηση στις εισόδους [59]. Η έννοια του αυτόματου είναι χρήσιμη για την ανάλυση αλγόριθμων, όπως εκείνων που χρησιμοποιούνται σε μεθόδους μηχανικής μάθησης [58]. Συλλογές αυτομάτων που αλληλεπιδρούν μπορούν να χρησιμοποιηθούν για τη μελέτη κατανεμημένος αλγόριθμους, όπου κάθε αυτόματο αναπαριστά μία συσκευή που εκτελεί τοπικούς υπολογισμούς και επικοινωνεί με άλλες συσκευές [126], [127].

Βλέπε επίσης: συσκευή, κατάσταση, χώρος καταστάσεων, συνάρτηση, αλγόριθμος, μηχανική μάθηση, κατανεμημένος αλγόριθμος.

**διαχρονικά δεδομένα** Longitudinal data consist of σημείο δεδομένων whose attributes are measured repeatedly over time [128]. In μηχανική μάθηση, longitudinal data are common in applications such as healthcare, where patient measurements are taken at multiple time points [129].

See also: data, σημείο δεδομένων.

**δυναμικό σύστημα** Ένα δυναμικό σύστημα (dynamical system) είναι ένα αφηρημένο σύστημα, του οποίου η έξοδος εξαρτάται από μία εσωτερική

κατάσταση που εξελίσσεται σταδιακά σύμφωνα με έναν κανόνα κατάστασης-ενημέρωσης [130]. Στον διακριτό χρόνο, ένα δυναμικό σύστημα περιγράφεται συχνά από μία επανάληψη της μορφής  $\mathbf{s}^{(t+1)} = \mathcal{F}\mathbf{s}^{(t)}$ , όπου  $\mathbf{s}^{(t)}$  δηλώνει την κατάσταση στη χρονική στιγμή  $t$  και  $\mathcal{F}$  είναι μία απεικόνιση κατάστασης-μετάβασης. Στον συνεχή χρόνο, τα δυναμικά συστήματα περιγράφονται από διαφορικές εξισώσεις.

Βλέπε επίσης: έξοδος, κατάσταση, επανάληψη, απεικόνιση.

**κινητή συσκευή** A mobile συσκευή is a portable computing συσκευή equipped with computational, storage, sensing, and wireless communication capabilities [131], [132]. Examples of mobile συσκευής include smartphones, tablets, or wearables. Mobile συσκευής can act as data sources and provide computational infrastructure for υπολογιστική ακμής or σύστημα ομοσπονδιακής μάθησης.

See also: υπολογιστική ακμής, σύστημα ομοσπονδιακής μάθησης, σύστημα μηχανικής μάθησης.

**μηχανική μάθηση ως υπηρεσία** Η μηχανική μάθηση ως υπηρεσία (machine learning as a service - MLaaS) αναφέρεται σε ένα μοντέλο υπηρεσίας υπολογιστικής νέφους στο οποίο οι δυνατότητες μηχανικής μάθησης παρέχονται στους χρήστες μέσω τυποποιημένων διεπαφών δικτύου. Σε αυτό το μοντέλο, ο πάροχος του νέφους διαχειρίζεται τις υποκείμενες υπολογιστικές υποδομές, την αποθήκευση δεδομένων, και τις πλατφόρμες λογισμικού, ενώ οι χρήστες έχουν πρόσβαση σε λειτουργικότητα όπως η εκπαίδευση μοντέλου και η εξαγωγή συμπερασμάτων χωρίς άμεσο έλεγχο των φυσικών πόρων [133].

Βλέπε επίσης: υπολογιστική νέφους, μοντέλο, μηχανική μάθηση, data, εκπαίδευση, εξαγωγή συμπερασμάτων, σύστημα μηχανικής μάθησης.

**προεπεξεργασία** Preprocessing refers to the set of operations applied to raw data before they are fed into an μηχανική μάθηση αλγόριθμος [51]. The goal of preprocessing is to transform the data into a form that is more suitable for follow-up stages of an machine learning pipeline (ML pipeline). Typical preprocessing steps include cleaning corrupted or missing values, normalizing or scaling χαρακτηριστικός, or encoding categorical variables [134].

See also: data, ML pipeline, χαρακτηριστικό.

**συσκευή ακμής** An edge συσκευή operates at or near the edge of a communication network [135]. The term edge refers to the periphery of the network, where data is produced and first processed. In μηχανική μάθηση and, in particular, in FL, an edge συσκευή typically corresponds to a node of an δίκτυο ομοσπονδιακής μάθησης. Each edge συσκευή stores local data and implements parts of the ML pipeline, such as data προεπεξεργασία, local model εκπαίδευση, or εξαγωγή συμπερασμάτων [136]. See also: συσκευή, υπολογιστική ακμή.

**σύστημα μηχανικής μάθησης** Ένα σύστημα μηχανικής μάθησης (machine learning system - ML system) αποτελείται από υπολογιστικές συσκευές που μπορούν να συλλέγουν και να αποθηκεύουν δεδομένα, να εκτελούν αλγόριθμους, και να ανταλλάσσουν πληροφορίες μέσω δικτύων επικοινωνίας. Παραδείγματα των ανταλλασσόμενων πληροφοριών περιλαμβάνουν δεδομένα ή ενημερώσεις των παραμέτρων μοντέλου. Εννοιο-

λογικά, ένα σύστημα μηχανικής μάθησης είναι διαφορετικό από έναν αλγόριθμο μηχανικής μάθησης, δηλαδή ένας αλγόριθμος προσδιορίζει την αφηρημένη υπολογιστική διαδικασία (π.χ. μία μέθοδο βελτιστοποίησης), ενώ το σύστημα προσδιορίζει το πώς αυτή η διαδικασία υλοποιείται στην πράξη [59], [137], [138]. Παραδείγματα αλγόριθμων που εκτελούνται από συσκευές εντός ενός συστήματος μηχανικής μάθησης περιλαμβάνουν μεθόδους με βάση την κλίση για την επίλυση προβλημάτων εμπειρικής ελαχιστοποίησης διακινδύνευσης.

Βλέπε επίσης: μηχανική μάθηση, συσκευή, data, αλγόριθμος, model parameter, μέθοδος βελτιστοποίησης, μέθοδος με βάση την κλίση, εμπειρική ελαχιστοποίηση διακινδύνευσης.

**σύστημα ομοσπονδιακής μάθησης** Ένα σύστημα ομοσπονδιακής μάθησης είναι ένα κατανεμημένο σύστημα μηχανικής μάθησης στο οποίο πολλές υπολογιστικές συσκευές συνεργάζονται για την εκπαίδευση μοντέλων μηχανικής μάθησης χωρίς να διαμοιράζονται τα ακατέργαστα τοπικά δεδομένα τους. Ένα σύστημα ομοσπονδιακής μάθησης χαρακτηρίζεται από ένα δίκτυο επικοινωνίας που προσδιορίζει ποιες συσκευές μπορούν να ανταλλάσσουν πληροφορίες. Εννοιολογικά, ένα σύστημα ομοσπονδιακής μάθησης είναι διαφορετικό από έναν αλγόριθμο ομοσπονδιακής μάθησης [139]. Το σύστημα προσδιορίζει τις οντότητες που συμμετέχουν, τις διασυνδέσεις τους, και τους περιορισμούς εκτέλεσης, ενώ ο αλγόριθμος προσδιορίζει τους κανόνες ενημέρωσης για τις τοπικές και καθολικές παράμετρους μοντέλου [127], [137]. Τυπικές πληροφορίες που ανταλλάσσονται σε ένα σύστημα ομοσπονδιακής μάθησης περιλαμβάνουν παράμετρους μοντέλου ή πληροφορίες κλίσης, αλλά όχι ακατέργαστα δεδομένα.

Βλέπε επίσης: FL, σύστημα μηχανικής μάθησης, συσκευή, μηχανική μάθηση μοντέλο, data, αλγόριθμος, model parameter, κλίση, δίκτυο ομοσπονδιακής μάθησης.

**υπολογιστική ακμής** Edge computing refers to the placement of computation and data storage close to the sources of data generation, such as sensors, κινητή συσκευής, or embedded systems, rather than in centralized data centers [135]. In μηχανική μάθηση, edge computing supports low-latency εξαγωγή συμπερασμάτων and reduced communication by executing parts of μηχανική μάθηση αλγόριθμος on or near data-generating συσκευής [140].

See also: υπολογιστική νέφους, σύστημα ομοσπονδιακής μάθησης, σύστημα μηχανικής μάθησης.

**υπολογιστική νέφους** Η υπολογιστική νέφους (cloud computing) είναι ένα υπολογιστικό παράδειγμα στο οποίο οι υπολογιστικοί πόροι όπως η επεξεργασία, η αποθήκευση, και η δικτύωση παρέχονται ως υπηρεσίες κατ' αίτηση μέσω ενός δικτύου επικοινωνίας [133], [139], [141]. Στη μηχανική μάθηση, τα συστήματα υπολογιστικής νέφους χρησιμοποιούνται συχνά για τη φιλοξενία μεγάλων συνόλων δεδομένων και την εκτέλεση αλγόριθμων μηχανικής μάθησης. Σε αντίθεση με τα συστήματα ομοσπονδιακής μάθησης, η υπολογιστική νέφους συνήθως συγκεντρώνει τα δεδομένα και τον υπολογισμό εντός κέντρων δεδομένων που διαχειρίζεται ο πάροχος.

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, αλγόριθμος, σύστημα ομοσπονδιακής μάθησης, data, σύστημα μηχανικής μάθησης.

checkpoint TBC.

checkpointing TBC.

cross-sectional data TBC.

early exit (deep learning) TBC.

machine learning pipeline (ML pipeline) TBC.

spot instance TBC.



## Κανονισμός Μηχανικής Μάθησης

**αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN)** Εκτός από τις υπολογιστικές διαστάσεις και τις στατιστικές διαστάσεις, μία τρίτη κύρια διάσταση σχεδιασμού μεθόδων μηχανικής μάθησης είναι η αξιοπιστία τους [142]. Η Ευρωπαϊκή Ένωση (ΕΕ) έχει διατυπώσει επτά βασικές απαιτήσεις για αξιόπιστη TN (trustworthy artificial intelligence - trustworthy AI) (οι οποίες συνήθως χτίζονται πάνω σε μεθόδους μηχανικής μάθησης) [143]:

- 1) Ανθρώπινη παρέμβαση και εποπτεία·
- 2) Τεχνική στιβαρότητα και ασφάλεια·
- 3) Ιδιωτικότητα και διακυβέρνηση των δεδομένων·
- 4) Διαφάνεια·
- 5) Διαφορετικότητα, απαγόρευση των διακρίσεων και δικαιοσύνη·
- 6) Κοινωνιακή και περιβαλλοντική ευημερία·
- 7) Λογοδοσία.

Βλέπε επίσης: υπολογιστική διάσταση, στατιστική διάσταση, μηχανική μάθηση, τεχνητή νοημοσύνη (TN), στιβαρότητα, data, διαφάνεια.

**αυτοματοποιημένη λήψη αποφάσεων** Η αυτοματοποιημένη λήψη αποφάσεων (automated decision-making) αναφέρεται στις εφαρμογές μηχανικής μάθησης που χρησιμοποιούν προβλέψεις που παράγονται από ένα εκπαιδευμένο μοντέλο απευθείας (δηλαδή χωρίς ανθρώπινη παρέμβαση) για τη λήψη αποφάσεων που επηρεάζουν άτομα. Με βάση τον ΓΚΠΔ,

τα άτομα έχουν το δικαίωμα να μην υπόκεινται σε αποφάσεις που βασίζονται μόνο σε αυτοματοποιημένη επεξεργασία, όταν αυτές οι αποφάσεις έχουν νομικές ή όμοια σημαντικές επιδράσεις, εκτός εάν υλοποιούνται κατάλληλα μέτρα προστασίας (π.χ. ανθρώπινη εποπτεία, δυνατότητα αμφισβήτησης, ή ρητή συγκατάθεση).

Βλέπε επίσης: μηχανική μάθηση, πρόβλεψη, μοντέλο, ΓΚΠΔ.

### **γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ) Ο**

ΓΚΠΔ (general data protection regulation - GDPR) θεσπίστηκε από την ΕΕ και τέθηκε σε ισχύ από τις 25 Μαΐου 2018 [64]. Διαφυλάσσει την ιδιωτικότητα και τα δικαιώματα δεδομένων των ατόμων στην ΕΕ. Ο ΓΚΠΔ έχει σημαντικές επιπτώσεις για το πώς συλλέγονται δεδομένα, πώς αποθηκεύονται, και πώς χρησιμοποιούνται στις εφαρμογές μηχανικής μάθησης. Βασικές διατάξεις περιλαμβάνουν τα εξής:

- Αρχή της ελαχιστοποίησης των δεδομένων: Τα συστήματα μηχανικής μάθησης θα πρέπει να χρησιμοποιούν μόνο την απαραίτητη ποσότητα προσωπικών δεδομένων για τον σκοπό τους.
- Διαφάνεια και εξηγησιμότητα: Τα συστήματα μηχανικής μάθησης θα πρέπει να επιτρέπουν στους χρήστες τους να κατανοούν πώς τα συστήματα παίρνουν αποφάσεις που επηρεάζουν τους χρήστες.
- Δικαιώματα των υποκειμένων των δεδομένων: Οι χρήστες θα πρέπει να έχουν την ευκαιρία να έχουν πρόσβαση, να διορθώνουν, και να διαγράφουν τα προσωπικά δεδομένα τους, καθώς και να αντιτίθενται στην αυτοματοποιημένη λήψη αποφάσεων και στην κατάρτιση προφίλ.

- **Λογοδοσία:** Οι οργανισμοί πρέπει να εξασφαλίζουν την εύρωστη ασφάλεια δεδομένων και να αποδεικνύουν συμμόρφωση μέσω τεχνικών και τακτικών ελέγχων.

Βλέπε επίσης: data, μηχανική μάθηση, αρχή της ελαχιστοποίησης των δεδομένων, σύστημα μηχανικής μάθησης, προσωπικά δεδομένα, διαφάνεια, εξηγησιμότητα, αυτοματοποιημένη λήψη αποφάσεων, κατάρτιση προφίλ.

**διαφάνεια** Η διαφάνεια είναι μία θεμελιώδης απαίτηση για αξιόπιστη ΤΝ [144].

Στο πλαίσιο μεθόδων μηχανικής μάθησης, η διαφάνεια χρησιμοποιείται συχνά εναλλακτικά με την εξηγησιμότητα [83], [145]. Ωστόσο, στο ευρύτερο πεδίο συστημάτων ΤΝ, η διαφάνεια επεκτείνεται πέρα από την εξηγησιμότητα και περιλαμβάνει την παροχή πληροφοριών σχετικά με τους περιορισμούς, την αξιοπιστία, και την επιθυμητή χρήση του συστήματος. Σε συστήματα ιατρικής διάγνωσης, η διαφάνεια απαιτεί τη γνωστοποίηση του επιπέδου εμπιστοσύνης για τις προβλέψεις που παραδίδονται από ένα εκπαιδευμένο μοντέλο. Στην πιστωτική ικανότητα, οι αποφάσεις δανεισμού που βασίζονται στην ΤΝ θα πρέπει να συνοδεύονται από εξηγήσεις παραγόντων που συμβάλλουν, όπως το επίπεδο εισοδήματος ή το πιστωτικό ιστορικό. Αυτές οι εξηγήσεις επιτρέπουν τους ανθρώπους (π.χ. έναν αιτούντα δανείου) να κατανοήσουν και να αμφισβητήσουν αυτοματοποιημένες αποφάσεις. Κάποιες μέθοδοι μηχανικής μάθησης προσφέρουν εγγενώς διαφάνεια. Για παράδειγμα, η λογιστική παλινδρόμηση παρέχει ένα ποσοτικό μέτρο της αξιοπιστίας της ταξινόμησης μέσω της τιμής  $|h(\mathbf{x})|$ . Ένα ακόμα παράδειγμα αποτελούν τα δέντρα αποφάσεων, καθώς επιτρέπουν κανόνες αποφάσεων που είναι αναγνώσιμοι από άνθρω-

πο [81]. Η διαφάνεια επίσης απαιτεί μία σαφή ένδειξη όταν ένας χρήστης αλληλεπιδρά με ένα σύστημα TN. Για παράδειγμα, τα chatbots που λειτουργούν με TN θα πρέπει να ειδοποιούν τους χρήστες ότι αλληλεπιδρούν με ένα αυτοματοποιημένο σύστημα και όχι με άνθρωπο. Επιπλέον, η διαφάνεια συμπεριλαμβάνει περιεκτική τεκμηρίωση που περιγράφει λεπτομερώς τον σκοπό και τις επιλογές σχεδιασμού που αποτελούν τη βάση του συστήματος TN. Για παράδειγμα, τα φύλλα δεδομένων μοντέλων [111] και οι κάρτες συστημάτων TN [146] βοηθούν τους επαγγελματίες να κατανοήσουν τις περιπτώσεις επιθυμητής χρήσης και τους περιορισμούς ενός συστήματος TN [147].

Βλέπε επίσης: αξιόπιστη TN, μηχανική μάθηση, εξηγησιμότητα, σύστημα TN, πρόβλεψη, μοντέλο, TN, εξήγηση, λογιστική παλινδρόμηση, μέτρο, ταξινόμηση, δέντρο αποφάσεων.

**κατάρτιση προφίλ** Η κατάρτιση προφίλ (profiling) στοχεύει στην αναγνώριση μοτίβων και στην εξαγωγή συμπερασμάτων σχετικά με άτομα βάσει των δεδομένων τους. Οι τεχνικές κατάρτισης προφίλ χρησιμοποιούν μεθόδους μηχανικής μάθησης για να προβλέψουν την επίδοση ατόμων στη δουλειά, την οικονομική τους κατάσταση, την υγεία ή τις προσωπικές τους προτιμήσεις. Η κατάρτιση προφίλ είναι καίρια για τη στοχευμένη διαφήμιση, την πιστωτική ικανότητα, τον εντοπισμό απάτης, και τις εξατομικευμένες υπηρεσίες. Ο ΓΚΠΔ επιβάλλει αυστηρές απαιτήσεις σε οργανισμούς που ασχολούνται με δραστηριότητες κατάρτισης προφίλ, ώστε να εξασφαλίζεται η προστασία των δικαιωμάτων των ατόμων [64].

Βλέπε επίσης: data, μηχανική μάθηση, ΓΚΠΔ.

**προσωπικά δεδομένα** Προσωπικά δεδομένα (personal data) είναι κάθε πληροφορία που σχετίζεται με ένα ταυτοποιημένο ή ταυτοποιήσιμο φυσικό πρόσωπο (δηλαδή το υποκείμενο των δεδομένων). Ένα φυσικό πρόσωπο είναι ταυτοποιήσιμο αν μπορεί να ταυτοποιηθεί, άμεσα ή έμμεσα, συγκεκριμένα με αναφορά σε ένα αναγνωριστικό όπως όνομα, αριθμό ταυτοποίησης, δεδομένα τοποθεσίας, διαδικτυακό αναγνωριστικό, ή έναν ή περισσότερους παράγοντες συγκεκριμένα για τη σωματική, φυσιολογική, γενετική, διανοητική, οικονομική, πολιτιστική, ή κοινωνική ταυτότητα αυτού του ατόμου [64]. Στα συστήματα μηχανικής μάθησης, προσωπικά δεδομένα μπορεί να εμφανίζονται στα δεδομένα εκπαίδευσης, στις εισόδους του μοντέλου, στις ενδιάμεσες αναπαραστάσεις (π.χ. διανύσματα χαρακτηριστικών ή εμφυτεύσεις), ή στις εξόδους του μοντέλου, εφόσον οι πληροφορίες σχετίζονται με ένα ταυτοποιήσιμο φυσικό πρόσωπο. Ο Κανονισμός της ΕΕ για την ΤΝ (Artificial Intelligence Act - AI Act) δεν εισάγει έναν ξεχωριστό ορισμό για τα προσωπικά δεδομένα· αντ' αυτού, κάθε φορά που ένα σύστημα ΤΝ επεξεργάζεται προσωπικά δεδομένα, εφαρμόζονται πλήρως ο ορισμός και οι υποχρεώσεις του ΓΚΠΔ.

Βλέπε επίσης: data, σύστημα μηχανικής μάθησης, εκπαίδευση, μοντέλο, διάνυσμα χαρακτηριστικών, έξοδος, σύστημα ΤΝ, ΓΚΠΔ.

**προϊόν βαθυπαραποίησης** Τα προϊόντα βαθυπαραποίησης (deep fakes) είναι συνθετικά μέσα που παράγονται ή τροποποιούνται σημαντικά από ένα σύστημα ΤΝ, έτσι ώστε να φαίνεται ψευδώς ότι απεικονίζουν ένα πραγματικό πρόσωπο, αντικείμενο, ή γεγονός. Τα προϊόντα βαθυπαραποίησης παράγονται συνήθως με τη χρήση παραγωγικών μεθόδων, οι οποίες εκπαιδεύονται να μιμούνται οπτικά, ακουστικά, ή οπτικοακουστικά χαρακτη-

ριστικά πραγματικών δεδομένων. Από άποψη συστήματος, τα προϊόντα βαθυπαραποίησης χαρακτηρίζονται από μία σκόπιμη ασυμβατικότητα μεταξύ του παρατηρήσιμου περιεχομένου και της πραγματικής προέλευσης, γεγονός που μπορεί να οδηγήσει σε απάτη, παραπληροφόρηση, ή χειραγώγηση.

Βλέπε επίσης: σύστημα TN, γεγονός, data.

### **σύστημα τεχνητής νοημοσύνης (σύστημα TN)** Ο Κανονισμός της

ΕΕ για την TN (AI Act) [148] ορίζει ένα σύστημα TN (artificial intelligence system - AI system) ως ένα σύστημα βασισμένο σε μηχανή που έχει σχεδιαστεί να λειτουργεί με μεταβαλλόμενα επίπεδα αυτονομίας και που μπορεί να επιδεικνύει προσαρμοστικότητα (π.χ. επανεκπαίδευση μοντέλου) μετά την ανάπτυξή του. Τα συστήματα TN υπολογίζουν προβλέψεις που μπορούν να επηρεάσουν περιβάλλοντα ή αποφάσεις [149]. Σε συμφωνία με αυτόν τον ορισμό, οι κανονιστικές υποχρεώσεις και οι κατηγορίες κινδύνου εφαρμόζονται στο επίπεδο του συστήματος TN και όχι στο επίπεδο μεμονωμένων μοντέλων ή αλγόριθμων. Η εξέταση σε επίπεδο συστήματος τονίζει ότι οι ιδιότητες όπως η στιβαρότητα, η δικαιοσύνη, και η διαφάνεια προκύπτουν από την αλληλεπίδραση των μοντέλων, των δεδομένων, και του λειτουργικού πλαισίου, και όχι από μεμονωμένες συνιστώσες.

Βλέπε επίσης: TN, μοντέλο, πρόβλεψη, αλγόριθμος, στιβαρότητα, διαφάνεια, data.

### **σύστημα τεχνητής νοημοσύνης υψηλού κινδύνου (σύστημα TN υψηλού κινδύνου)**

Ένα υποσύνολο των συστημάτων TN ταξινομείται ως υψηλού κινδύνου

λόγω της δυνατότητάς του να επηρεάζει σημαντικά την ασφάλεια, τα θεμελιώδη δικαιώματα, ή τις κοινωνικές λειτουργίες ζωτικής σημασίας. Τα συστήματα ΤΝ υψηλού κινδύνου (high-risk artificial intelligence system - high-risk AI system) υπόκεινται σε αυστηρές κανονιστικές απαιτήσεις με βάση τον Κανονισμό της ΕΕ για την ΤΝ (AI Act), οι οποίες περιλαμβάνουν αξιολογήσεις συμμόρφωσης, διαχείριση κινδύνου, υποχρεώσεις διαφάνειας, και παρακολούθηση μετά τη διάθεση στην αγορά [149]. Παραδείγματα συστημάτων ΤΝ υψηλού κινδύνου περιλαμβάνουν εκείνα που χρησιμοποιούνται σε υποδομές ζωτικής σημασίας, στην εκπαίδευση, στην απασχόληση, στην επιβολή του νόμου, και στη βιομετρική ταυτοποίηση. Βλέπε επίσης: σύστημα ΤΝ, διαφάνεια.

**FAIR principles** TBC.

**SHapley Additive exPlanations (SHAP)** TBC.

## Index

αβεβαιότητα	85	ανάλυση κύριων συνιστωσών	94
αισιοδοξία παρά την αβεβαιότητα	85	ανάστροφος	31
ακολουθία	28	ανεξάρτητες και ταυτόσημα κατανεμημένες	31
ακολουθία Cauchy	29	ανισότητα του Markov	32
ακραία τιμή	88	ανισότητα συγκέντρωσης	32
ακρίβεια	87	ανισότητα του Chebyshev	32
ακρίβεια	87	ανισότητα του Hoeffding	32
αλγεβρική συνεκτικότητα	29	ανταμοιβή	96
αλγόριθμος	89	αντικειμενική συνάρτηση	96
αλγόριθμος $k$ -μέσων	90	αντιστροφή μοντέλου	97
αλγόριθμος του Lloyd	91	αντίστροφος πίνακας	32
αμοιβαίες πληροφορίες	91	άνω φράγμα εμπιστοσύνης (ΑΦΕ)	97
αμφικλινής παλινδρόμηση	92	αξιολόγηση πολιτικής	203
ανάκληση	93	αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη ΤΝ)	217
ανάλυση ιδιαζουσών τιμών	30	απεικόνιση	33
ανάλυση ιδιοτιμών	31		



απεικόνιση χαρακτηριστικών	98	αυτοματοποιημένη λήψη αποφάσεων	217
απόκλιση	98	βαθιά μάθηση	104
απόκλιση Kullback-Leibler (απόκλιση KL)	33	βαθμός κόμβου	34
απόκλιση Rényi	34	βαθμός συσχέτισης	104
αποτελεσματική διάσταση	99	βαθύ δίκτυο	105
απώλεια	99	βάρος	105
απώλεια απόλυτου σφάλματος	99	βάρος ακμής	106
απώλεια άρθρωσης	102	βάση αναφοράς	106
απώλεια τετραγωνικού σφάλματος	102	βελτιστοποίηση	35
απώλεια Huber	103	βήμα κλίσης	35
αριθμήσιμο	34	γεγονός	35
αριθμός συνθήκης	34	γείτονας	106
αρχή της ελαχιστοποίησης των δεδομένων	103	γειτονιά	35
αυτοεποπτευόμενη μάθηση	103	γενικευμένη ολική μεταβολή	106
αυτοκωδικοποιητής	103	γενίκευση	107
αυτόματο	211	γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ)	218
		γεωμετρική διάμεσος	36

γινόμενο Kronecker	107	δηλητηρίαση δεδομένων	113
Γκαουσιανή διαδικασία	36	διάγραμμα διασποράς	114
Γκαουσιανή τυχαία μεταβλητή	36	διαγωνοποιήσιμος	38
Γκαουσιανό μοντέλο μείγματος	108	διαδικασία απόφασης Markov	203
Γκαουσιανός	36	διαδικτυακή μάθηση	114
γραμμικά ανεξάρτητο	36	διαδικτυακός αλγόριθμος	114
γραμμική απεικόνιση	36	διακινδύνευση	115
γραμμική παλινδρόμηση	108	διακινδύνευση Bayes	115
γραμμικό μοντέλο	111	διακριτή τυχαία μεταβλητή	39
γραμμικός ταξινομητής	111	διακύμανση	39
γράφος	36	διάμεσος	39
γράφος Erdős–Rényi	37	διάνυσμα	39
γράφος ομοιότητας	112	διάνυσμα ετικετών	116
δεδομένα	112	διάνυσμα χαρακτηριστικών	116
δείγμα	37	διανυσματικός χώρος	40
δειγματικός χώρος	112	διαρροή ιδιωτικότητας	116
δέντρο αποφάσεων	113	διάσταση	41
δέσμη	113	διάσταση Vapnik–Chervonenkis	117

διασταυρούμενη επικύρωση $k$ -αναδιπλώσεων	117	ελαχιστοποίηση γενικευμένης ολικής μεταβολής	122
διάυλος ιδιωτικότητας	118	ελαχιστοποίηση δομικής διακινδύνευσης	122
διαφάνεια	219	εμπειρική διακινδύνευση	123
διαφορική εντροπία	41	εμπειρική ελαχιστοποίηση διακινδύνευσης	123
διαφορική ιδιωτικότητα	118		
διαχρονικά δεδομένα	211	εμπειρική κατανομή	43
διεπαφή προγραμματισμού εφαρμογών	118	εμπειρογνώμονας	124
		ενέργεια	205
δίκτυο ομοσπονδιακής μάθησης	118	ενεργοποίηση	125
δυαδική ταξινόμηση	120	ενισχυτική μάθηση	206
δυναμικό σύστημα	211	εντροπία	43
έχβαση	42	εξαγωγή συμπερασμάτων	125
εκκίνηση	120	εξήγηση	126
εκπαίδευση	121	εξηγήσιμη εμπειρική ελαχιστοποίηση διακινδύνευσης	127
εκτιμητής	42		
εκτιμητής Bayes	121	εξηγήσιμη μηχανική μάθηση	128
ελάχιστο	42	εξηγησιμότητα	128
ελάχιστο άνω φράγμα (ή supremum)	42	εξίσωση σταθερού σημείου	43

έξοδος	128	Ευκλείδεια απόσταση	45
επανάληψη	128	Ευκλείδεια νόρμα	45
επανάληψη σταθερού σημείου	43	Ευκλείδειος χώρος	46
επανάληψη τιμής	207	ευστάθεια	134
επαυξημένος κατά Lagrange	43	ημιοποπτευόμενη μάθηση	134
επαύξηση δεδομένων	128	θετικά ημιορισμένος	46
επιγράφος	44	ιδιάζουσα τιμή	46
επίθεση	129	ιδιοδιάνυσμα	46
επίθεση άρνησης υπηρεσιών	129	ιδιότητα Markov	46
επίθεση της ιδιωτικότητας	129	ιδιοτιμή	47
επικύρωση	130	ιστόγραμμα	135
επιλογή μοντέλου	131	ίχνος	47
εργασία μάθησης	132	καθεστώς υψηλής διάστασης	135
ερμηνευσιμότητα	132	κάθοδος κλίσης	135
Ερσιανός	44	κάθοδος υποκλίσης	136
εσωτερικό γινόμενο	45	κανονικές εξισώσεις	136
ετικέτα	133	κανονικοποίηση δεδομένων	136
ευαίσθητο ιδιοχαρακτηριστικό	134	κανονικός πίνακας	47

κατακόρυφη ομοσπονδιακή μάθηση	136	κωδικοποιητής	138
		λεία	50
κατανεμημένος αλγόριθμος	136	λογιστική απώλεια	138
κατανομή πιθανότητας	47	λογιστική παλινδρόμηση	139
κατανομή πιθανότητας υπό συνθήκη	48	μάθηση πολυδιεργασίας	140
κατάρτιση προφίλ	220	μάθηση χαρακτηριστικών	140
κατάσταση	48	μαλακή συσταδοποίηση	141
κατευθυνόμενος μη κυκλικός γράφος	48	μεγάλο γλωσσικό μοντέλο	142
κεντρικό οριακό θεώρημα	48	μέγεθος βήματος	143
κέντρο βάρους συστάδας	136	μέγεθος δείγματος	143
κερκόπορτα	136	μέγιστη πιθανοφάνεια	143
κινητή συσκευή	212	μέγιστο	50
κλίση	48	μέθοδος βελτιστοποίησης	50
κριτήριο τερματισμού	137	μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών	51
κυρτή βελτιστοποίηση	49	μέθοδος με βάση την κλίση	144
κυρτή συσταδοποίηση	137	μέθοδος πυρήνα	144
κυρτό	49	μέθοδος των πολλαπλασιαστών	51

μείωση της διαστασιμότητας	145	μονάδα δεδομένων	149
μερική παράγωγος	53	μοντέλο (μηχανική μάθηση)	149
μεροληψία	145	μοντέλο στοχαστικής ομάδας	150
μέση τιμή	53	νόμος των μεγάλων αριθμών	57
μέση τιμή δείγματος	146	νόρμα	57
μέσο τετραγωνικό σφάλμα εκτίμησης	147	ολική μεταβολή	58
μέσος βαθμός κόμβου	53	ολοκλήρωμα Lebesgue	58
μετασχηματιστής	147	ολοκληρώσιμη	58
μετρήσιμο	54	ομαλοποιημένη ελαχιστοποίηση απώλειας	151
μετρική	55	ομαλοποιημένη εμπειρική ελαχιστοποίηση διακινδύνευσης	151
μετρικός χώρος	56	ομαλοποίηση	151
μέτρο	57	ομαλοποιητής	151
μη κατευθυνόμενος γράφος	57	ομοσπονδιακή μάθηση	152
μη λεία	57	οπισθοδιάδοση	152
μηχανή διανυσμάτων υποστήριξης (ΜΔΥ)	147	οριζόντια ομοσπονδιακή μάθηση	152
μηχανική μάθηση	147	ορίζουσα	58
μηχανική μάθηση ως υπηρεσία	212		

όριο	60	περιοχή αποφάσεων	156
όριο απόφασης	152	πιθανότητα	156
όρος ποινής	153	πιθανοτικό μοντέλο	60
παλινδρόμηση	153	πίνακας	61
παλινδρόμηση ελάχιστης απόλυτης απόκλισης	153	πίνακας σύγχυσης	156
παλινδρόμηση Huber	153	πίνακας συνδιακύμανσης	63
παραγωγίσιμη	60	πίνακας συνδιακύμανσης δείγματος	63
παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων	154	πίνακας χαρακτηριστικών	157
παραδοχή συσταδοποίησης	154	πίνακας Laplace	62
παραμετρικό μοντέλο	155	πλήρους τάξης	64
παραμετρικός χώρος	198	πλησιέστερος γείτονας	158
παράμετρος	155	πολιτική	207
παράμετρος μοντέλου	155	πολυμεταβλητή κανονική κατανομή	64
πεδίο	60	πολυπλοκότητα Rademacher	158
πεδίο τιμών	60	πολυωνυμική παλινδρόμηση	159
περιβάλλον (ενισχυτική μάθηση)	207	πραγμάτωση	159
		πράκτορας	208

προβλεπόμενη κάθοδος κλίσης	64	σημείο δεδομένων με ετικέτα	169
πρόβλεψη	160	σ-άλγεβρα	66
πρόβλημα βελτιστοποίησης	65	σκληρή συσταδοποίηση	169
προβολή	65	σταθερό σημείο	66
προγνωστικός παράγοντας	160	στατιστική διάσταση	169
προεικόνα	66	στιβαρότητα	169
προεπεξεργασία	213	στοίβαξη	170
προϊόν βαθυπαραποίησης	221	στοχαστική	67
προσδοκία	160	στοχαστική διαδικασία	67
προσδοκία υπό συνθήκη	66	στοχαστική κάθοδος κλίσης	170
προσεγγίσιμος	66	στοχαστικός αλγόριθμος	171
προσοχή	161	στρώμα	172
προστασία της ιδιωτικότητας	163	σύγκλιση	68
προσωπικά δεδομένα	220	συμμεταβλητή	172
πυρήνας (μέθοδος πυρήνα)	163	συμμετρικός πίνακας	69
ρήτρα μεταβολής γνώμης	208	συνάρτηση	69
ρυθμός μάθησης	165	συνάρτηση απώλειας	172
σημείο δεδομένων	166	συνάρτηση ενεργοποίησης	173



συνάρτηση κατάστασης-τιμής	208	συσταδοποίηση γράφου	182
συνάρτηση μάζας πιθανότητας	70	συσταδοποίηση με βάση τη ροή	182
συνάρτηση πυκνότητας πιθανότητας	70	σύστημα μηχανικής μάθησης	213
συνάρτηση τιμής	209	σύστημα ομοσπονδιακής μάθησης	214
συνδιακύμανση	70	σύστημα τεχνητής νοημοσύνης (σύστημα TN)	222
συνεκτικός	70	σύστημα τεχνητής νοημοσύνης	222
συνεχής	71	υψηλού κινδύνου (σύστημα TN υψηλού κινδύνου)	222
συνθήκη μηδενικής κλίσης	174	συστολικός τελεστής	71
σύνολο	175	σφάλμα εκπαίδευσης	183
σύνολο δεδομένων	177	σφάλμα εκτίμησης	183
σύνολο εκπαίδευσης	179	σφάλμα επικύρωσης	184
σύνολο ελέγχου	179	τάξη	72
σύνολο επικύρωσης	179	ταξινόμηση	184
συσκευή	180	ταξινομητής	184
συσκευή ακμής	213	τελεστής	72
συστάδα	180	τελεστής εγγύτητας	72
συσταδοποίηση	181	τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής	185

τελεστής Bellman	209	υποπροσαρμογή	191
τετραγωνική συνάρτηση	185	υποχώρος	77
τεχνητή νοημοσύνη (TN)	186	φασματική ανάλυση	77
τεχνητό νευρωνικό δίκτυο (ΤΝΔ)	186	φασματική συσταδοποίηση	192
τμηματοποίηση εικόνας	188	φασματογράφημα	199
τοπικό μοντέλο	188	Φινλανδικό Μετεωρολογικό Ινστιτούτο	194
τοπικό σύνολο δεδομένων	188	φράγμα Chernoff	77
τυχαία μεταβλητή	74	χαρακτηριστική συνάρτηση	78
τυχαίο δάσος	189	χαρακτηριστικό	194
τυχαίο πείραμα	75	χάσμα γενίκευσης	195
υπερεπίπεδο	77	χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα	196
υπερπροσαρμογή	189		
υπόθεση	190	χώρος ενεργειών	210
υποκλίση	77	χώρος ετικετών	197
υπολογιστική ακμής	215	χώρος καταστάσεων	78
υπολογιστική διάσταση	190	χώρος με νόρμα	78
υπολογιστική νέφους	215	χώρος μέτρου	78

χώρος πιθανοτήτων	79	χώρος Hilbert	80
χώρος στηλών	80	ψευδοαντίστροφος	81
χώρος υποθέσεων	200	0/1 απώλεια	200
χώρος χαρακτηριστικών	200		

## References

- [1] W. Rudin, *Real and Complex Analysis*, 3rd ed. New York, NY, USA: McGraw-Hill, 1987.
- [2] W. Rudin, *Principles of Mathematical Analysis*, 3rd ed. New York, NY, USA: McGraw-Hill, 1976.
- [3] G. H. Golub and C. F. Van Loan, *Matrix Computations*, 4th ed. Baltimore, MD, USA: The Johns Hopkins Univ. Press, 2013.
- [4] G. H. Golub and C. F. Van Loan, “An analysis of the total least squares problem,” *SIAM J. Numer. Anal.*, vol. 17, no. 6, pp. 883–893, Dec. 1980, doi: 10.1137/0717073.
- [5] A. Klenke, *Probability Theory: A Comprehensive Course*, 3rd ed. Cham, Switzerland: Springer Nature, 2020.
- [6] P. Billingsley, *Probability and Measure*, 2nd ed. New York, NY, USA: Wiley, 1986.
- [7] D. P. Bertsekas and J. N. Tsitsiklis, *Introduction to Probability*, 2nd ed. Belmont, MA, USA: Athena Scientific, 2008.
- [8] A. Jung, *Machine Learning: The Basics*. Singapore, Singapore: Springer Nature, 2022.
- [9] F. R. K. Chung, *Spectral Graph Theory*. Providence, RI, USA: American Mathematical Society, 1997.

- [10] D. A. Spielman, *Spectral and Algebraic Graph Theory (Incomplete Draft)*. Ebook, 2025, Accessed: December 9, 2025. [Online]. Available: <http://cs-www.cs.yale.edu/homes/spielman/sagt>
- [11] M. J. Wainwright, *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge, U.K.: Cambridge Univ. Press, 2019.
- [12] G. Strang, *Computational Science and Engineering*. Wellesley, MA, USA: Wellesley-Cambridge Press, 2007.
- [13] R. A. Horn and C. R. Johnson, *Topics in Matrix Analysis*. Cambridge, U.K.: Cambridge Univ. Press, 1991.
- [14] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ, USA: Wiley, 2006.
- [15] I. Csiszar, “Generalized cutoff rates and Renyi’s information measures,” *IEEE Trans. Inf. Theory*, vol. 41, no. 1, pp. 26–34, Jan. 1995, doi: 10.1109/18.370121.
- [16] T. Opsahl, F. Agneessens, and J. Skvoretz, “Node centrality in weighted networks: Generalizing degree and shortest paths,” *Social Netw.*, vol. 32, no. 3, pp. 245–251, Jul. 2010, doi: 10.1016/j.socnet.2010.03.006.
- [17] R. Durrett, *Probability: Theory and Examples*, 4th ed. Cambridge, U.K.: Cambridge Univ. Press, 2010.
- [18] R. T. Rockafellar, *Network Flows and Monotropic Optimization*. Belmont, MA, USA: Athena Scientific, 1998.

- [19] B. S. Everitt and A. Skrondal, *The Cambridge Dictionary of Statistics*, 4th ed. Cambridge, U.K.: Cambridge Univ. Press, 2010.
- [20] G. Upton and I. Cook, *A Dictionary of Statistics*, 3rd ed. Oxford, U.K.: Oxford Univ. Press, 2014.
- [21] G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, 2nd ed. New York, NY, USA: Wiley, 1999.
- [22] S. Boyd and L. Vandenberghe, *Convex Optimization*. Cambridge, U.K.: Cambridge Univ. Press, 2004.
- [23] P. R. Halmos, *Finite-Dimensional Vector Spaces*. New York, NY, USA: Springer-Verlag, 1974.
- [24] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed. New York, NY, USA: Cambridge Univ. Press, 2013.
- [25] S. Axler, *Linear Algebra Done Right*, 3rd ed. Cham, Switzerland: Springer Nature, 2015.
- [26] B. Schölkopf and A. J. Smola, *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. Cambridge, MA, USA: MIT Press, 2002.
- [27] R. M. Gray, *Probability, Random Processes, and Ergodic Properties*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2009.
- [28] O. Kallenberg, *Foundations of Modern Probability*. New York, NY, USA: Springer-Verlag, 1997.

- [29] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- [30] D. P. Bertsekas, *Dynamic Programming and Optimal Control*, vol. 2, 3rd ed. Belmont, MA, USA: Athena Scientific, 2007.
- [31] D. P. Bertsekas, *Nonlinear Programming*, 2nd ed. Belmont, MA, USA: Athena Scientific, 1999.
- [32] Y. Nesterov, *Introductory Lectures on Convex Optimization: A Basic Course*. Boston, MA, USA: Kluwer Academic, 2004.
- [33] S. Boyd, N. Parikh, E. Chu, B. Peleato, and J. Eckstein, “Distributed optimization and statistical learning via the alternating direction method of multipliers,” *Found. Trends Mach. Learn.*, vol. 3, no. 1, pp. 1–122, Jul. 2011, doi: 10.1561/22000000016.
- [34] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [35] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer Science+Business Media, 2006.
- [36] A. Papoulis and S. U. Pillai, *Probability, Random Variables, and Stochastic Processes*, 4th ed. New York, NY, USA: McGraw-Hill Higher Education, 2002.
- [37] H. J. Dirschmid, *Tensors and Fields*, (in German). Vienna, Austria: Springer-Verlag, 1996.

- [38] E. L. Lehmann and G. Casella, *Theory of Point Estimation*, 2nd ed. New York, NY, USA: Springer-Verlag, 1998.
- [39] G. Strang, *Introduction to Linear Algebra*, 5th ed. Wellesley, MA, USA: Wellesley-Cambridge Press, 2016.
- [40] U. von Luxburg, “A tutorial on spectral clustering,” *Statist. Comput.*, vol. 17, no. 4, pp. 395–416, Dec. 2007, doi: 10.1007/s11222-007-9033-z.
- [41] A. Y. Ng, M. I. Jordan, and Y. Weiss, “On spectral clustering: Analysis and an algorithm,” in *Adv. Neural Inf. Process. Syst.*, T. Dietterich, S. Becker, and Z. Ghahramani, Eds., vol. 14, 2001, pp. 849–856. [Online]. Available: [https://papers.nips.cc/paper\\_files/paper/2001/hash/801272ee79cfde7fa5960571fee36b9b-Abstract.html](https://papers.nips.cc/paper_files/paper/2001/hash/801272ee79cfde7fa5960571fee36b9b-Abstract.html)
- [42] L. Condat, “A primal–dual splitting method for convex optimization involving lipschitzian, proximable and linear composite terms,” *J. Optim. Theory Appl.*, vol. 158, no. 2, pp. 460–479, Aug. 2013, doi: 10.1007/s10957-012-0245-9.
- [43] P. J. Brockwell and R. A. Davis, *Time Series: Theory and Methods*, 2nd ed. New York, NY, USA: Springer-Verlag, 1991.
- [44] H. H. Bauschke and P. L. Combettes, *Convex Analysis and Monotone Operator Theory in Hilbert Spaces*. New York, NY, USA: Springer Science+Business Media, 2011.
- [45] N. Parikh and S. Boyd, “Proximal algorithms,” *Found. Trends Optim.*, vol. 1, no. 3, pp. 127–239, Jan. 2014, doi: 10.1561/24000000003.



- [46] H. H. Bauschke and P. L. Combettes, *Convex Analysis and Monotone Operator Theory in Hilbert Spaces*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2017.
- [47] N. Dunford and J. T. Schwartz, *Linear Operators, Part I: General Theory*. New York, NY, USA: Wiley, 1988.
- [48] D. P. Bertsekas, A. Nedic, and A. E. Ozdaglar, *Convex Analysis and Optimization*. Belmont, MA, USA: Athena Scientific, 2003.
- [49] P. R. Halmos, *Measure Theory*. New York, NY, USA: Springer-Verlag, 1974.
- [50] S. Ross, *A First Course in Probability*, 9th ed. Boston, MA, USA: Pearson Education, 2014.
- [51] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2009.
- [52] A. Ben-Israel and T. N. E. Greville, *Generalized Inverses: Theory and Applications*, 2nd ed. New York, NY, USA: Springer-Verlag, 2003.
- [53] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *J. Roy. Statist. Soc.: Ser. B (Statist. Methodology)*, vol. 61, no. 3, pp. 611–622, 1999, doi: 10.1111/1467-9868.00196.
- [54] S. Shalev-Shwartz and S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*. New York, NY, USA: Cambridge Univ. Press, 2014.

- [55] S. Bubeck and N. Cesa-Bianchi, “Regret analysis of stochastic and non-stochastic multi-armed bandit problems,” *Found. Trends Mach. Learn.*, vol. 5, no. 1, pp. 1–122, Dec. 2012, doi: 10.1561/22000000024.
- [56] M. Kearns and M. Li, “Learning in the presence of malicious errors,” *SIAM J. Comput.*, vol. 22, no. 4, pp. 807–837, Aug. 1993, doi: 10.1137/0222052.
- [57] G. Lugosi and S. Mendelson, “Robust multivariate mean estimation: The optimality of trimmed mean,” *Ann. Statist.*, vol. 49, no. 1, pp. 393–410, Feb. 2021, doi: 10.1214/20-AOS1961.
- [58] T. H. Cormen, C. E. Leiserson, R. L. Rivest, and C. Stein, *Introduction to Algorithms*, 4th ed. Cambridge, MA, USA: MIT Press, 2022.
- [59] M. Sipser, *Introduction to the Theory of Computation*, 3rd ed. Andover, U.K.: Cengage Learning, 2013.
- [60] M. Mahajan, P. Nimbhorkar, and K. Varadarajan, “The planar k-means problem is NP-hard,” in *WALCOM: Algorithms and Computation*, S. Das and R. Uehara, Eds. Berlin, Heidelberg, Germany: Springer-Verlag, 2009, pp. 274–285.
- [61] C. D. Meyer, *Matrix Analysis and Applied Linear Algebra*. Philadelphia, PA, USA: SIAM, 2000.
- [62] S. Sra, S. Nowozin, and S. J. Wright, Eds., *Optimization for Machine Learning*. Cambridge, MA, USA: MIT Press, 2012.
- [63] C. H. Lampert, “Kernel methods in computer vision,” *Found. Trends*

*Comput. Graph. Vis.*, vol. 4, no. 3, pp. 193–285, Sep. 2009, doi: 10.1561/06000000027.

- [64] European Parliament and Council of the European Union, “Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation) (Text with EEA relevance),” Official Journal of the European Union, L 119/1, May 4, 2016, Accessed: July, 2025. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- [65] European Parliament and Council of the European Union, “Regulation (EU) 2018/1725 of the European Parliament and of the Council of 23 October 2018 on the protection of natural persons with regard to the processing of personal data by the Union institutions, bodies, offices and agencies and on the free movement of such data, and repealing Regulation (EC) No 45/2001 and Decision No 1247/2002/EC (Text with EEA relevance),” Official Journal of the European Union, L 295/39, Nov. 21, 2018, Accessed: December 1, 2025. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2018/1725/oj>
- [66] International Organization for Standardization and International Electrotechnical Commission, “Information technology — Vocabulary,” ISO/IEC 2382:2015, 2015, Accessed: September 21, 2025. [Online]. Available: <https://www.iso.org/standard/63598.html>

- [67] R. B. Ash, *Probability and Measure Theory*, 2nd ed. San Diego, CA, USA: Academic, 2000.
- [68] X. Liu, H. Li, G. Xu, Z. Chen, X. Huang, and R. Lu, “Privacy-enhanced federated learning against poisoning adversaries,” *IEEE Trans. Inf. Forensics Security*, vol. 16, pp. 4574–4588, 2021, doi: 10.1109/TIFS.2021.3108434.
- [69] J. Zhang, B. Chen, X. Cheng, H. T. T. Binh, and S. Yu, “PoisonGAN: Generative poisoning attacks against federated learning in edge computing systems,” *IEEE Internet Things J.*, vol. 8, no. 5, pp. 3310–3322, Mar. 2021, doi: 10.1109/JIOT.2020.3023126.
- [70] A. Ünsal and M. Önen, “Information-theoretic approaches to differential privacy,” *ACM Comput. Surv.*, vol. 56, no. 3, Oct. 2023, Art. no. 76, doi: 10.1145/3604904.
- [71] A. Makhdoumi, S. Salamatian, N. Fawaz, and M. Médard, “From the information bottleneck to the privacy funnel,” in *2014 IEEE Inf. Theory Workshop*, 2014, pp. 501–505, doi: 10.1109/ITW.2014.6970882.
- [72] A. Jung, *Federated Learning: From Theory to Practice*. Singapore, Singapore: Springer Nature, 2026.
- [73] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman & Hall, 1993.
- [74] Y. SarcheshmehPour, Y. Tian, L. Zhang, and A. Jung, “Clustered federated learning via generalized total variation minimization,”

- IEEE Trans. Signal Process.*, vol. 71, pp. 4240–4256, 2023, doi: 10.1109/TSP.2023.3322848.
- [75] N. Cesa-Bianchi and G. Lugosi, *Prediction, Learning, and Games*. New York, NY, USA: Cambridge Univ. Press, 2006.
  - [76] E. Hazan, “Introduction to online convex optimization,” *Found. Trends Optim.*, vol. 2, no. 3–4, pp. 157–325, Aug. 2016, doi: 10.1561/24000000013.
  - [77] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. Cambridge, MA, USA: MIT Press, 2012.
  - [78] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 3rd ed. Ebook, 2025, Accessed: August 1, 2025. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>
  - [79] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *2017 IEEE Int. Conf. Comput. Vis.*, 2017, pp. 618–626, doi: 10.1109/ICCV.2017.74.
  - [80] L. Zhang, G. Karakasidis, A. Odnoblyudova, L. Dogruel, Y. Tian, and A. Jung, “Explainable empirical risk minimization,” *Neural Comput. Appl.*, vol. 36, no. 8, pp. 3983–3996, Mar. 2024, doi: 10.1007/s00521-023-09269-3.
  - [81] C. Rudin, “Stop explaining black box machine learning models for high-stakes decisions and use interpretable models instead,” *Nature Mach. Intell.*, vol. 1, no. 5, pp. 206–215, May 2019, doi: 10.1038/s42256-019-0048-x.

- [82] J. Colin, T. Fel, R. Cadène, and T. Serre, “What I cannot predict, I do not understand: A human-centered evaluation framework for explainability methods,” in *Adv. Neural Inf. Process. Syst.*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35, 2022, pp. 2832–2845. [Online]. Available: [https://proceedings.neurips.cc/paper\\_files/paper/2022/hash/13113e938f2957891c0c5e8df811dd01-Abstract-Conference.html](https://proceedings.neurips.cc/paper_files/paper/2022/hash/13113e938f2957891c0c5e8df811dd01-Abstract-Conference.html)
- [83] A. Jung and P. H. J. Nardelli, “An information-theoretic approach to personalized explainable machine learning,” *IEEE Signal Process. Lett.*, vol. 27, pp. 825–829, 2020, doi: 10.1109/LSP.2020.2993176.
- [84] J. Chen, L. Song, M. J. Wainwright, and M. I. Jordan, “Learning to explain: An information-theoretic perspective on model interpretation,” in *Proc. 35th Int. Conf. Mach. Learn.*, J. Dy and A. Krause, Eds., vol. 80, 2018, pp. 883–892. [Online]. Available: <https://proceedings.mlr.press/v80/chen18j.html>
- [85] F. Doshi-Velez and B. Kim, “Towards a rigorous science of interpretable machine learning,” arXiv preprint arXiv:1702.08608, Mar. 2017. [Online]. Available: <https://arxiv.org/abs/1702.08608>
- [86] P. Hase and M. Bansal, “Evaluating explainable AI: Which algorithmic explanations help users predict model behavior?” in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics*, D. Jurafsky, J. Chai, N. Schluter, and J. Tetreault, Eds., Jul. 2020, pp. 5540–5552. [Online]. Available: <https://aclanthology.org/2020.acl-main.491>

- [87] Z. C. Lipton, “The mythos of model interpretability: In machine learning, the concept of interpretability is both important and slippery,” *Queue*, vol. 16, no. 3, pp. 31–57, Jun. 2018, doi: 10.1145/3236386.3241340.
- [88] D. N. Gujarati and D. C. Porter, *Basic Econometrics*, 5th ed. New York, NY, USA: McGraw-Hill/Irwin, 2009.
- [89] Y. Dodge, Ed., *The Oxford Dictionary of Statistical Terms*. New York, NY, USA: Oxford Univ. Press, 2003.
- [90] B. S. Everitt, *The Cambridge Dictionary of Statistics*, 2nd ed. Cambridge, U.K.: Cambridge Univ. Press, 2002.
- [91] O. Chapelle, B. Schölkopf, and A. Zien, Eds., *Semi-Supervised Learning*. Cambridge, MA, USA: MIT Press, 2006.
- [92] D. Sun, K.-C. Toh, and Y. Yuan, “Convex clustering: Model, theoretical guarantee and efficient algorithm,” *J. Mach. Learn. Res.*, vol. 22, no. 9, pp. 1–32, Jan. 2021. [Online]. Available: <http://jmlr.org/papers/v22/18-694.html>
- [93] K. Pelckmans, J. De Brabanter, J. A. K. Suykens, and B. De Moor, “Convex clustering shrinkage,” presented at the PASCAL Workshop Statist. Optim. Clustering Workshop, 2005.
- [94] S. M. Kay, *Fundamentals of Statistical Signal Processing: Estimation Theory*. Upper Saddle River, NJ, USA: Prentice-Hall, 1993.
- [95] T. Hastie, R. Tibshirani, and M. Wainwright, *Statistical Learning with*

- Sparsity: The Lasso and Generalizations.* Boca Raton, FL, USA: CRC Press, 2015.
- [96] L. Bottou, “On-line learning and stochastic approximations,” in *On-Line Learning in Neural Networks*, D. Saad, Ed. New York, NY, USA: Cambridge Univ. Press, 1999, ch. 2, pp. 9–42.
  - [97] E. A. Bender, *An Introduction to Mathematical Modeling.* New York, NY, USA: Wiley, 1978.
  - [98] E. Abbe, “Community detection and stochastic block models: Recent developments,” *J. Mach. Learn. Res.*, vol. 18, no. 177, pp. 1–86, Apr. 2018. [Online]. Available: <http://jmlr.org/papers/v18/16-480.html>
  - [99] Q. Yang, Y. Liu, Y. Cheng, Y. Kang, T. Chen, and H. Yu, “Horizontal federated learning,” in *Federated Learning.* Cham, Switzerland: Springer Nature, 2020, ch. 4, pp. 49–67.
  - [100] P. J. Huber, “Robust estimation of a location parameter,” in *Breakthroughs in Statistics: Methodology and Distribution.* New York, NY, USA: Springer-Verlag, 1992, ch. 35, pp. 492–518.
  - [101] P. L. Bartlett and S. Mendelson, “Rademacher and gaussian complexities: Risk bounds and structural results,” *J. Mach. Learn. Res.*, vol. 3, no. Nov., pp. 463–482, 2002. [Online]. Available: <https://www.jmlr.org/papers/v3/bartlett02a.html>
  - [102] D. M. Blei, A. Y. Ng, and M. I. Jordan, “Latent dirichlet allocation,” *J. Mach. Learn. Res.*, vol. 3, pp. 993–1022, Jan. 2003.



- [103] A. Vaswani et al., “Attention is all you need,” in *Adv. Neural Inf. Process. Syst.*, I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds., vol. 30, 2017, pp. 5998–6008. [Online]. Available: [https://papers.nips.cc/paper\\_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html](https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html)
- [104] R. Motwani and P. Raghavan, *Randomized Algorithms*. Cambridge, U.K.: Cambridge Univ. Press, 1995.
- [105] R. G. Gallager, *Stochastic Processes: Theory for Applications*. New York, NY, USA: Cambridge Univ. Press, 2013.
- [106] A. Silberschatz, H. F. Korth, and S. Sudarshan, *Database System Concepts*, 7th ed. New York, NY, USA: McGraw-Hill Education, 2019.
- [107] S. Abiteboul, R. Hull, and V. Vianu, *Foundations of Databases*. Reading, MA, USA: Addison-Wesley, 1995.
- [108] S. Hoberman, *Data Modeling Made Simple: A Practical Guide for Business and IT Professionals*, 2nd ed. Basking Ridge, NJ, USA: Technics Publications, 2009.
- [109] R. Ramakrishnan and J. Gehrke, *Database Management Systems*, 3rd ed. New York, NY, USA: McGraw-Hill, 2002.
- [110] E. F. Codd, “A relational model of data for large shared data banks,” *Commun. ACM*, vol. 13, no. 6, pp. 377–387, Jun. 1970, doi: 10.1145/362384.362685.

- [111] T. Gebru et al., “Datasheets for datasets,” *Commun. ACM*, vol. 64, no. 12, pp. 86–92, Nov. 2021, doi: 10.1145/3458723.
- [112] D. A. Patterson and J. L. Hennessy, *Computer Organization and Design: The Hardware/Software Interface*, 5th ed. San Francisco, CA, USA: Morgan Kaufmann, 2013.
- [113] Y. SarcheshmehPour, Y. Tian, L. Zhang, and A. Jung, “Flow-based clustering and spectral clustering: A comparison,” in *2021 55th Asilomar Conf. Signals, Syst., Comput.*, M. B. Matthews, Ed., 2021, pp. 1292–1296, doi: 10.1109/IEEECONF53345.2021.9723162.
- [114] R. Tibshirani, “Regression shrinkage and selection via the lasso,” *J. Roy. Statist. Soc.: Ser. B (Methodological)*, vol. 58, no. 1, pp. 267–288, 1996, doi: 10.1111/j.2517-6161.1996.tb02080.x.
- [115] P. Bühlmann and S. van de Geer, *Statistics for High-Dimensional Data: Methods, Theory and Applications*. Berlin, Germany: Springer-Verlag, 2011.
- [116] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *2016 IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.
- [117] A. Jung and Y. SarcheshmehPour, “Local graph clustering with network Lasso,” *IEEE Signal Process. Lett.*, vol. 28, pp. 106–110, 2021, doi: 10.1109/LSP.2020.3045832.
- [118] C. R. Wren, A. Azarbayejani, T. Darrell, and A. P. Pentland, “Pfinder:

- Real-time tracking of the human body,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 19, no. 7, pp. 780–785, Jul. 1997, doi: 10.1109/34.598236.
- [119] L. Cohen, *Time-Frequency Analysis*. Upper Saddle River, NJ, USA: Prentice-Hall, 1995.
  - [120] J. Li, L. Han, X. Li, J. Zhu, B. Yuan, and Z. Gou, “An evaluation of deep neural network models for music classification using spectrograms,” *Multimedia Tools Appl.*, vol. 81, no. 4, pp. 4621–4647, Feb. 2022, doi: 10.1007/s11042-020-10465-9.
  - [121] B. Boashash, Ed., *Time Frequency Signal Analysis and Processing: A Comprehensive Reference*. Oxford, U.K.: Elsevier, 2003.
  - [122] S. Mallat, *A Wavelet Tour of Signal Processing: The Sparse Way*, 3rd ed. Burlington, MA, USA: Academic, 2009.
  - [123] D. P. Bertsekas, *Dynamic Programming and Optimal Control*, vol. 1, 4th ed. Belmont, MA, USA: Athena Scientific, 2017.
  - [124] S. J. Russel and P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed. Upper Saddle River, NJ, USA: Prentice-Hall, 2010.
  - [125] R. Bellman, *Dynamic Programming*. Princeton, NJ, USA: Princeton Univ. Press, 1957.
  - [126] D. P. Bertsekas and J. N. Tsitsiklis, *Parallel and Distributed Computation: Numerical Methods*. Belmont, MA, USA: Athena Scientific, 2015.

- [127] N. A. Lynch, *Distributed Algorithms*. San Francisco, CA, USA: Morgan Kaufmann, 1996.
- [128] G. M. Fitzmaurice, N. M. Laird, and J. H. Ware, *Applied Longitudinal Analysis*, 2nd ed. Hoboken, NJ, USA: Wiley, 2011.
- [129] C. H. Mallinckrodt and I. Lipkovich, *Analyzing Longitudinal Clinical Trial Data: A Practical Guide*. Boca Raton, FL, USA: Chapman & Hall/CRC Press, 2017.
- [130] S. H. Strogatz, *Nonlinear Dynamics and Chaos: With Applications to Physics, Biology, Chemistry, and Engineering*, 2nd ed. Boca Raton, FL, USA: CRC Press, 2015.
- [131] N. D. Lane and P. Georgiev, “Can deep learning revolutionize mobile sensing?” in *Proc. 16th Int. Workshop Mobile Comput. Syst. Appl.*, Feb. 2015, pp. 117–122, doi: 10.1145/2699343.2699349.
- [132] V. Tsoukas, A. Gkogkidis, E. Boumpa, and A. Kakarountas, “A review on the emerging technology of TinyML,” *ACM Comput. Surv.*, vol. 56, no. 10, Jun. 2024, Art. no. 259, doi: 10.1145/3661820.
- [133] D. E. Comer, *The Cloud Computing Book: The Future of Computing Explained*. Boca Raton, FL, USA: CRC Press, 2021.
- [134] H. Hapke and C. Nelson, *Building Machine Learning Pipelines: Automating Model Life Cycles with TensorFlow*. Sebastopol, CA, USA: O’Reilly Media, 2020.

- [135] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, “Edge computing: Vision and challenges,” *IEEE Internet Things J.*, vol. 3, no. 5, pp. 637–646, Oct. 2016, doi: 10.1109/JIOT.2016.2579198.
- [136] O. Hashash, S. Sharafeddine, Z. Dawy, A. Mohamed, and E. Yaacoub, “Energy-aware distributed edge ML for mHealth applications with strict latency requirements,” *IEEE Wireless Commun. Lett.*, vol. 10, no. 12, pp. 2791–2794, Dec. 2021, doi: 10.1109/LWC.2021.3117876.
- [137] D. E. Knuth, *The Art of Computer Programming*, vol. 1: *Fundamental Algorithms*, 3rd ed. Reading, MA, USA: Addison-Wesley, 1997.
- [138] A. S. Tanenbaum, *Modern Operating Systems*, 3rd ed. Upper Saddle River, NJ, USA: Prentice-Hall, 2008.
- [139] M. van Steen and A. S. Tanenbaum, *Distributed Systems*, 3rd ed. Ebook, 2017. [Online]. Available: <https://www.distributed-systems.net/index.php/books/ds3/>
- [140] T. N. Gia, L. Qingqing, J. P. Queralta, Z. Zou, H. Tenhunen, and T. Westerlund, “Edge AI in smart farming IoT: CNNs at the edge and fog computing with LoRa,” in *2019 IEEE AFRICON*, 2019, pp. 1–6, doi: 10.1109/AFRICON46755.2019.9134049.
- [141] M. Armbrust et al., “A view of cloud computing,” *Commun. ACM*, vol. 53, no. 4, pp. 50–58, Apr. 2010, doi: 10.1145/1721654.1721672.
- [142] D. Pfau and A. Jung, “Engineering trustworthy AI: A developer guide for empirical risk minimization,” arXiv preprint arXiv:2410.19361, Nov. 2024. [Online]. Available: <https://arxiv.org/abs/2410.19361>

- [143] High-Level Expert Group on Artificial Intelligence, “The assessment list for trustworthy artificial intelligence (ALTAI): For self assessment,” European Commission, Jul. 17, 2020. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment>
- [144] High-Level Expert Group on Artificial Intelligence, “Ethics guidelines for trustworthy AI,” European Commission, Apr. 8, 2019. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>
- [145] C. Gallese, “The AI Act proposal: A new right to technical interpretability?” *SSRN Electron. J.*, Feb. 2023. [Online]. Available: <https://ssrn.com/abstract=4398206>
- [146] M. Mitchell et al., “Model cards for model reporting,” in *Proc. Conf. Fairness, Accountability, Transparency*, 2019, pp. 220–229, doi: 10.1145/3287560.3287596.
- [147] K. Shahriari and M. Shahriari, “IEEE standard review — Ethically aligned design: A vision for prioritizing human wellbeing with artificial intelligence and autonomous systems,” in *2017 IEEE Canada Int. Humanitarian Technol. Conf.*, 2017, pp. 197–201, doi: 10.1109/IHTC.2017.8058187.
- [148] European Commission, “Proposal for a regulation of the European Parliament and of the Council laying down harmonised rules on artificial intelligence (Artificial Intelligence Act) and amending

certain Union legislative acts,” COM/2021/206 final, Apr. 21, 2021, Accessed: December 16, 2025. [Online]. Available: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=celex:52021PC0206>

- [149] European Parliament and Council of the European Union, “Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence and amending Regulations (EC) No 300/2008, (EU) No 167/2013, (EU) No 168/2013, (EU) 2018/858, (EU) 2018/1139 and (EU) 2019/2144 and Directives 2014/90/EU, (EU) 2016/797 and (EU) 2020/1828 (Artificial Intelligence Act) (Text with EEA relevance),” Official Journal of the European Union, L series, Jul. 12, 2024, Accessed: July 2025. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>