

Το **A'**alto Λεξικό της Μηχανικής Μάθησης

Alexander Jung¹, Konstantina Olioumtsevits¹, Ekkehard Schnoor¹,
Tommi Flores Ryynänen¹, Juliette Gronier², Salvatore Rastelli¹, και
Mikko Seesto¹

¹Aalto University ²ENS Lyon

Μετάφραση από την Konstantina Olioumtsevits

May 15, 2026



αναφορά ως: A. Jung, K. Olioumtsevits, E. Schnoor, T. Ryynänen,
J. Gronier, S. Rastelli, and M. Seesto, *To Aalto Λεξικό της
Μηχανικής Μάθησης* [The Aalto Dictionary of Machine Learning].
Transl. K. Olioumtsevits. Espoo, Finland: Aalto University, 2026.

Ευχαριστίες

Αυτό το λεξικό της μηχανικής μάθησης αναπτύχθηκε κατά τον σχεδιασμό και την υλοποίηση διαφορετικών μαθημάτων, συμπεριλαμβανομένων των CS-E3210 Machine Learning: Basic Principles, CS-C3240 Machine Learning, CS-E4800 Artificial Intelligence, CS-EJ3211 Machine Learning with Python, CS-EJ3311 Deep Learning with Python, CS-E4740 Federated Learning, και CS-E407507 Human-Centered Machine Learning. Αυτά τα μαθήματα προσφέρονται στο Aalto University <https://www.aalto.fi/en>, σε ενήλικους/ες σπουδαστές/σπουδάστριες μέσω του The Finnish Institute of Technology (FITech) <https://fitech.io/en/>, και σε διεθνείς φοιτητές/φοιτήτριες μέσω της European University Alliance Unite! <https://www.aalto.fi/en/unite>. Είμαστε ευγνώμονες στους/στις σπουδαστές/σπουδάστριες που παρείχαν πολύτιμα σχόλια που ήταν καθοριστικά για το συγκεκριμένο λεξικό.

Αυτό το έργο υποστηρίχθηκε από

- το Research Council of Finland (grants 331197, 363624, 349966).
- την Ευρωπαϊκή Ένωση (grant 952410).
- το Jane and Aatos Erkkö Foundation (grant A835).
- την Business Finland, ως μέρος του έργου Forward-Looking AI Governance in Banking and Insurance (FLAIG).

Η μετάφραση στα ελληνικά βασίστηκε ιδιαίτερα σε σχετικά σχολικά βιβλία λυκείου <https://ebooks.edu.gr/ebooks>, σε αρχεία από την Εθνική Υπηρεσία Πληροφοριών της Ελλάδας <https://www.nis.gr/en>, σε έγγραφα της Ευρωπαϊκής Ένωσης όπως <https://eur-lex.europa.eu/legal-content/EL/>

TXT/?uri=CELEX:32024R1689, στο παρακάτω βιβλίο:

A. Jung, *Μηχανική Μάθηση: Τα Βασικά*. Αθήνα, Ελλάδα: Fountas, 2024.

καθώς και σε σχετικά λεξικά:

Γ. Γεωργίου, *Αγγλοελληνικό Λεξικό Μαθηματικής Ορολογίας*, 1999. [Διαδικτυακά]. Διαθέσιμο: <https://www.mas.ucy.ac.cy/georgios/bookfiles/dict1.pdf>. Πρόσβαση: 30 Μαΐου 2025.

A. Καλογεροπούλου, M. Γκίκας, Δ. Καραγιαννάκης, και M. Λάμπρου, *Αγγλοελληνικό Λεξικό Μαθηματικών Όρων*. Αθήνα, Ελλάδα: Τροχαλία, 1992.

Σ. Καπιδάκης, K. Τοράκη, Σ. Χατζημαρή, K. Βαλεοντής, και Υ. Κύττα, *Λεξικό Επιστήμης της Πληροφόρησης*. Αθήνα, Ελλάδα: Κάλλιπος, Ανοιχτές Ακαδημαϊκές Εκδόσεις, 2024.

Περιεχόμενα

Κατάλογοι Συμβόλων	5
Μαθηματικά Εργαλεία	28
Έννοιες Μηχανικής Μάθησης	116
Ενισχυτική Μάθηση	281
Συστήματα Μηχανικής Μάθησης	289
Κανονισμός Μηχανικής Μάθησης	303
Ευρετήριο	313
Βιβλιογραφικές Αναφορές	329

Κατάλογοι Συμβόλων

Σύνολα και Συναρτήσεις

$a \in \mathcal{A}$ Το αντικείμενο a είναι ένα στοιχείο του συνόλου $\mathcal{A}$.

$a := b$ Ορίζουμε το a ως b .

$|\mathcal{A}|$ Η πληθικότητα (δηλαδή ο αριθμός των στοιχείων) ενός πεπερασμένου συνόλου $\mathcal{A}$.

$\mathcal{A} \subseteq \mathcal{B}$ Το $\mathcal{A}$ είναι ένα υποσύνολο του $\mathcal{B}$.

$\mathcal{A} \subset \mathcal{B}$ Το $\mathcal{A}$ είναι ένα αυστηρό υποσύνολο του $\mathcal{B}$.

$\mathcal{A} \times \mathcal{B}$ Το Καρτεσιανό γινόμενο των συνόλων $\mathcal{A}$ και $\mathcal{B}$.

$\mathbb{N}$ Οι φυσικοί αριθμοί $1, 2, \dots$.

$\mathbb{R}$ Οι πραγματικοί αριθμοί x [1].

$\mathbb{R}_+$ Οι μη αρνητικοί πραγματικοί αριθμοί $x \geq 0$.

$\mathbb{R}_{++}$ Οι θετικοί πραγματικοί αριθμοί $x > 0$.

$\{0, 1\}$ Το σύνολο που αποτελείται από τους δύο πραγματικούς αριθμούς 0 και 1.

$[0, 1]$ Το κλειστό διάστημα που αποτελείται από $x \in \mathbb{R}$ για κάθε $0 \leq x \leq 1$.

$\arg \min_{\mathbf{w} \in \mathcal{C}} f(\mathbf{w})$	Το σύνολο των $\mathbf{w} \in \mathcal{C}$ που ελαχιστοποιούν τη συνάρτηση πραγματικής τιμής $f : \mathcal{C} \rightarrow \mathbb{R}$. Βλέπε επίσης: συνάρτηση.
$\mathbb{S}^{(n)}$	Το σύνολο των διανυσμάτων μοναδιαίας νόρμας στο $\mathbb{R}^{n+1}$. Βλέπε επίσης: νόρμα, διάνυσμα.
$\exp(a)$	Η εκθετική συνάρτηση που αξιολογείται στον πραγματικό αριθμό $a \in \mathbb{R}$. Βλέπε επίσης: συνάρτηση.
$\log a$	Ο λογάριθμος του θετικού αριθμού $a \in \mathbb{R}_{++}$.
$f(\cdot) : \mathcal{A} \rightarrow \mathcal{B} : a \mapsto f(a)$	Μία συνάρτηση (ή απεικόνιση) από ένα σύνολο $\mathcal{A}$ σε ένα σύνολο $\mathcal{B}$, η οποία αποδίδει σε κάθε είσοδο $a \in \mathcal{A}$ μία καλά ορισμένη έξοδο $f(a) \in \mathcal{B}$. Το σύνολο $\mathcal{A}$ είναι το πεδίο ορισμού της συνάρτησης f και το σύνολο $\mathcal{B}$ είναι το πεδίο τιμών της f. Η μηχανική μάθηση στοχεύει να μάθει μία συνάρτηση που αντιστοιχίζει χαρακτηριστικά $\mathbf{x}$ ενός σημείου δεδομένων σε μία πρόβλεψη $h(\mathbf{x})$ για την ετικέτα του y. Βλέπε επίσης: συνάρτηση, απεικόνιση, έξοδος, πεδίο ορισμού, πεδίο τιμών, μηχανική μάθηση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα.

$\text{epi}(f)$	Ο επιγράφος μίας συνάρτησης πραγματικής τιμής $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Βλέπε επίσης: επιγράφος, συνάρτηση.
$(a_r)_{r \in \mathbb{N}}, (a^{(r)})_{r \in \mathbb{N}}, \{a^{(r)}\}_{r \in \mathbb{N}}$	Μία ακολουθία στοιχείων. Βλέπε επίσης: ακολουθία.
$\mathbb{I}_{\mathcal{A}}(x)$	Η δείκτρια συνάρτηση ενός συνόλου $\mathcal{A}$ παραδίδει $f(x) = 1$ για κάθε $x \in \mathcal{A}$ και $f(x) = 0$ διαφορετικά. Βλέπε επίσης: δείκτρια συνάρτηση.
$\frac{\partial f(w_1, \dots, w_d)}{\partial w_j}$	Η μερική παράγωγος (αν υφίσταται) μίας συνάρτησης πραγματικής τιμής $f : \mathbb{R}^d \rightarrow \mathbb{R}$ αναφορικά με το w_j [2, Κεφ. 9]. Βλέπε επίσης: μερική παράγωγος, συνάρτηση.
$\nabla f(\mathbf{w})$	Η κλίση μίας παραγωγίσιμης συνάρτησης πραγματικής τιμής $f : \mathbb{R}^d \rightarrow \mathbb{R}$ είναι το διάνυσμα $\nabla f(\mathbf{w}) = (\partial f / \partial w_1, \dots, \partial f / \partial w_d)^T \in \mathbb{R}^d$ [2, Κεφ. 9]. Βλέπε επίσης: κλίση, παραγωγίσιμη, συνάρτηση, διάνυσμα.
$\partial \mathcal{C}$	Το όριο ενός υποσυνόλου $\mathcal{C}$ κάποιου μετρικού χώρου. Βλέπε επίσης: όριο, μετρικός χώρος.
Id	Ο τελεστή ταυτότητας. Βλέπε επίσης: τελεστής.

Διανυσματικοί χώροι

$\mathbf{x} = (x_1, \dots, x_d)^T$	Ένα διάνυσμα μήκους d , με την j -οστή του καταχώριση να είναι x_j . Βλέπε επίσης: διάνυσμα.
$\mathbb{R}^d$	Το σύνολο όλων των διανυσμάτων $\mathbf{x} = (x_1, \dots, x_d)^T$ που αποτελούνται από d καταχωρίσεις πραγματικών τιμών $x_1, \dots, x_d \in \mathbb{R}$. Βλέπε επίσης: διάνυσμα.
$\mathbf{I}_{l \times d}$	Ένας γενικευμένος ταυτοτικός πίνακας με l γραμμές και d στήλες. Οι καταχωρίσεις του $\mathbf{I}_{l \times d} \in \mathbb{R}^{l \times d}$ είναι ίσες με 1 κατά μήκος της κύριας διαγωνίου και με 0 διαφορετικά. Βλέπε επίσης: πίνακας.
$\mathbf{I}_d, \mathbf{I}$	Ένας τετραγωνικός ταυτοτικός πίνακας μεγέθους $d \times d$. Αν το μέγεθος είναι προφανές από τα συμφραζόμενα, παραλείπουμε τον δείκτη. Βλέπε επίσης: πίνακας.
$\ \mathbf{x}\ _2$	Η Ευκλείδειος (ή ℓ_2) νόρμα του διανύσματος $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$ ορίζεται ως $\ \mathbf{x}\ _2 := \sqrt{\sum_{j=1}^d x_j^2}$. Βλέπε επίσης: νόρμα, διάνυσμα.
$\ \mathbf{x}\ $	Κάποια νόρμα του διανύσματος $\mathbf{x} \in \mathbb{R}^d$ [3]. Εκτός αν προσδιορίζεται διαφορετικά, εννοούμε την Ευκλείδεια νόρμα $\ \mathbf{x}\ _2$. Βλέπε επίσης: νόρμα, διάνυσμα, Ευκλείδεια νόρμα.

$\mathbf{x}^T$	Ο ανάστροφος ενός διανύσματος $\mathbf{x} \in \mathbb{R}^d$ είναι ένας πίνακας $\mathbf{x}^T \in \mathbb{R}^{1 \times d}$ με το διάνυσμα ως μοναδική του γραμμή. Βλέπε επίσης: ανάστροφος, διάνυσμα, πίνακας.
$\mathbf{X}^T$	Ο ανάστροφος πίνακας $\mathbf{X} \in \mathbb{R}^{m \times d}$. Ένας τετραγωνικός πίνακας πραγματικών τιμών $\mathbf{X} \in \mathbb{R}^{m \times m}$ λέγεται συμμετρικός αν $\mathbf{X} = \mathbf{X}^T$. Βλέπε επίσης: ανάστροφος, πίνακας.
$\mathbf{X}^{-1}$	Ο αντίστροφος πίνακας ενός πίνακα $\mathbf{X} \in \mathbb{R}^{d \times d}$. Βλέπε επίσης: αντίστροφος πίνακας, πίνακας.
$\mathbf{0} = (0, \dots, 0)^T$	Το διάνυσμα στον $\mathbb{R}^d$ με κάθε καταχώριση να είναι ίση με μηδέν. Βλέπε επίσης: διάνυσμα.
$\mathbf{1} = (1, \dots, 1)^T$	Το διάνυσμα στον $\mathbb{R}^d$ με κάθε καταχώριση να είναι ίση με ένα. Βλέπε επίσης: διάνυσμα.
$(\mathbf{v}^T, \mathbf{w}^T)^T$	Το διάνυσμα μήκους $d + d'$ που προκύπτει από την αλληλουχία των καταχωρίσεων του διανύσματος $\mathbf{v} \in \mathbb{R}^d$ με τις καταχωρίσεις του $\mathbf{w} \in \mathbb{R}^{d'}$. Βλέπε επίσης: διάνυσμα.

$\text{span}(\mathbf{B})$	Το εύρος ενός πίνακα $\mathbf{B} \in \mathbb{R}^{a \times b}$, ο οποίος είναι ο υποχώρος όλων των γραμμικών συνδυασμών των στηλών του $\mathbf{B}$ έτσι ώστε $\text{span}(\mathbf{B}) = \{\mathbf{B}\mathbf{a} : \mathbf{a} \in \mathbb{R}^b\} \subseteq \mathbb{R}^a$. Βλέπε επίσης: πίνακας, υποχώρος.
$\text{null}(\mathbf{A})$	Ο nullspace ενός πίνακα $\mathbf{A} \in \mathbb{R}^{a \times b}$, ο οποίος είναι ο υποχώρος των διανυσμάτων $\mathbf{a} \in \mathbb{R}^b$ έτσι ώστε $\mathbf{A}\mathbf{a} = \mathbf{0}$. Βλέπε επίσης: nullspace, πίνακας, υποχώρος, διάνυσμα.
$\det(\mathbf{C})$	Η ορίζουσα του πίνακα $\mathbf{C}$. Βλέπε επίσης: ορίζουσα, πίνακας.
$\text{tr}(\mathbf{C})$	Το ίχνος του πίνακα $\mathbf{C}$. Βλέπε επίσης: ίχνος, πίνακας.
$\mathbf{A} \otimes \mathbf{B}$	Το γινόμενο Kronecker των πινάκων $\mathbf{A}$ και $\mathbf{B}$ [4]. Βλέπε επίσης: γινόμενο Kronecker, πίνακας.
$\mathbf{a} \geq \mathbf{b}$	Η ανισότητα από άποψη καταχωρίσεων μεταξύ των διανυσμάτων $\mathbf{a}, \mathbf{b} \in \mathbb{R}^d$, δηλαδή $a_j \geq b_j \text{ για } j = 1, \dots, d.$ Βλέπε επίσης: διάνυσμα.

$\overline{\mathcal{B}}_\varepsilon(\mathbf{x})$ Μία κλειστή μπάλα σε κάποιον μετρικό χώρο που περιέχει όλα τα σημεία με απόσταση από το $\mathbf{x}$ μικρότερη ή ίση της ε .
Βλέπε επίσης: μετρικός χώρος, απόσταση.

$\|\mathbf{w}\|_{\mathcal{H}}$ Η νόρμα ενός διανύσματος $\mathbf{w} \in \mathcal{H}$ σε έναν χώρο Hilbert $\mathcal{H}$.
Βλέπε επίσης: νόρμα, διάνυσμα, χώρος Hilbert.

Θεωρία Πιθανοτήτων

$\mathbf{x} \sim \mathbb{P}$ Η τυχαία μεταβλητή $\mathbf{x}$ κατανέμεται σύμφωνα με την κατανομή πιθανότητας $\mathbb{P}$ [5], [6].

Βλέπε επίσης: τυχαία μεταβλητή, κατανομή πιθανότητας.

$\mathbb{E}_{\mathbb{P}}\{f(\mathbf{z})\}$ Η προσδοκία μίας τυχαίας μεταβλητής $f(\mathbf{z})$ που προκύπτει από την εφαρμογή μίας ντετερμινιστικής συνάρτησης f σε μία τυχαία μεταβλητή $\mathbf{z}$ της οποίας η κατανομή πιθανότητας είναι $\mathbb{P}$. Αν η κατανομή πιθανότητας είναι προφανής από τα συμφραζόμενα, γράφουμε απλώς $\mathbb{E}\{f(\mathbf{z})\}$.

Βλέπε επίσης: προσδοκία, τυχαία μεταβλητή, συνάρτηση, κατανομή πιθανότητας.

$\text{cov}(x, y)$ Η συνδιακύμανση μεταξύ δύο τυχαίων μεταβλητών πραγματικής τιμής που ορίζεται πάνω σε έναν κοινό χώρο πιθανοτήτων.

Βλέπε επίσης: συνδιακύμανση, τυχαία μεταβλητή, κατανομή πιθανότητας.

$\mathbb{P}^{(\mathbf{x}, y)}$ Μία (από κοινού) κατανομή πιθανότητας μίας τυχαίας μεταβλητής της οποίας οι πραγματώσεις είναι σημεία δεδομένων με χαρακτηριστικά $\mathbf{x}$ και ετικέτα y .

Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, πραγματώση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα.

$\mathbb{P}(y \mathbf{x})$	Μία κατανομή πιθανότητας υπό συνθήκη μίας τυχαίας μεταβλητής y δεδομένης (ή υπό τον όρο) της τιμής μίας άλλης τυχαίας μεταβλητής $\mathbf{x}$ [7, Sec. 3.5]. Βλέπε επίσης: κατανομή πιθανότητας υπό συνθήκη, τυχαία μεταβλητή.
$\mathbb{P}(\mathcal{A})$	Η πιθανότητα του μετρήσιμου γεγονότος $\mathcal{A}$. Βλέπε επίσης: πιθανότητα, μετρήσιμο, γεγονός.
$M_x(t)$	Η ροπογεννήτρια συνάρτηση μίας τυχαίας μεταβλητής x. Βλέπε επίσης: ροπογεννήτρια συνάρτηση, τυχαία μεταβλητή, κατανομή πιθανότητας, συνάρτηση πυκνότητας πιθανότητας.
$\mathbb{P}(\mathcal{D})$	Η εμπειρική κατανομή ενός συνόλου δεδομένων $\mathcal{D}$. Βλέπε επίσης: εμπειρική κατανομή, σύνολο δεδομένων, bootstrap.
$\mathbb{P}(\mathbf{x};\mathbf{w})$	Μία παραμετροποιημένη κατανομή πιθανότητας μίας τυχαίας μεταβλητής $\mathbf{x}$. Η κατανομή πιθανότητας εξαρτάται από ένα παραμετρικό διάνυσμα $\mathbf{w}$. Για παράδειγμα, $\mathbb{P}(\mathbf{x};\mathbf{w})$ θα μπορούσε να είναι μία πολυμεταβλητή κανονική κατανομή με το παραμετρικό διάνυσμα $\mathbf{w}$ που δίνεται από τις καταχωρίσεις του διανύσματος μέσης τιμής $\mathbb{E}\{\mathbf{x}\}$ και τον πίνακα συνδιακύμανσης $\mathbb{E}\left\{(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})(\mathbf{x} - \mathbb{E}\{\mathbf{x}\})^T\right\}$. Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, παράμετρος, διάνυσμα, πολυμεταβλητή κανονική κατανομή, μέση τιμή, πίνακας συνδιακύμανσης, πιθανοτικό μοντέλο.

$\mathcal{N}(\mu, \sigma^2)$	Η κατανομή πιθανότητας μίας Γκαουσιανής τυχαίας μεταβλητής $x \in \mathbb{R}$ με μέση τιμή (ή προσδοκία) $\mu = \mathbb{E}\{x\}$ και διακύμανση $\sigma^2 = \mathbb{E}\{(x - \mu)^2\}$. Βλέπε επίσης: κατανομή πιθανότητας, Γκαουσιανή τυχαία μεταβλητή, μέση τιμή, προσδοκία, διακύμανση.
$\mathcal{N}(\boldsymbol{\mu}, \mathbf{C})$	Η πολυμεταβλητή κανονική κατανομή μίας Γκαουσιανής τυχαίας μεταβλητής τιμής διανύσματος $\mathbf{x} \in \mathbb{R}^d$ με μέση τιμή (ή προσδοκία) $\boldsymbol{\mu} = \mathbb{E}\{\mathbf{x}\}$ και πίνακα συνδιακύμανσης $\mathbf{C} = \mathbb{E}\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\}$. Βλέπε επίσης: πολυμεταβλητή κανονική κατανομή, διάνυσμα, Γκαουσιανή τυχαία μεταβλητή, μέση τιμή, προσδοκία, πίνακας συνδιακύμανσης.
Δ^k	Το probability simplex, το οποίο αποτελείται από όλα τα διανύσματα $\mathbf{p} = (p_1, \dots, p_k)^T \in \mathbb{R}^k$ με μη αρνητικές καταχωρίσεις που αθροίζουν στο ένα, δηλαδή $p_c \geq 0$ για $c = 1, \dots, k$ και $\sum_{c=1}^k p_c = 1$. Βλέπε επίσης: συνάρτηση μάζας πιθανότητας.
$H(x)$	Η εντροπία μίας διακριτής τυχαίας μεταβλητής x. Βλέπε επίσης: εντροπία, διακριτή τυχαία μεταβλητή.
Ω	Ένας δειγματικός χώρος όλων των πιθανών εκβάσεων ενός τυχαίου πειράματος. Βλέπε επίσης: δειγματικός χώρος, έκβαση, τυχαίο πείραμα, γεγονός.
Σ	Μία συλλογή μετρήσιμων υποσυνόλων ενός δειγματικού χώρου Ω. Βλέπε επίσης: μετρήσιμο, δειγματικός χώρος, γεγονός.

Ένας χώρος πιθανοτήτων που αποτελείται από έναν δειγματικό χώρο Ω , μία σ -άλγεβρα Σ μετρήσιμων υποσυνόλων του Ω , και μία κατανομή πιθανότητας $\mathbb{P}(\cdot)$.

Βλέπε επίσης: χώρος πιθανοτήτων, δειγματικός χώρος, σ -άλγεβρα, μετρήσιμο, κατανομή πιθανότητας.

Μηχανική Μάθηση

r	Ένας δείκτης $r = 1, 2, \dots$ που απαριθμεί τα σημεία δεδομένων. Βλέπε επίσης: σημείο δεδομένων.
m	Ο αριθμός των σημείων δεδομένων σε ένα σύνολο δεδομένων (δηλαδή το μέγεθός του). Βλέπε επίσης: σημείο δεδομένων, σύνολο δεδομένων.
$\mathcal{D}$	Ένα σύνολο δεδομένων $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$ είναι μία λίστα μεμονωμένων σημείων δεδομένων $\mathbf{z}^{(r)}$, for $r = 1, \dots, m$. Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων.
d	Ο αριθμός των χαρακτηριστικών που χαρακτηρίζουν ένα σημείο δεδομένων. Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων.
x_j	Το j-οστό χαρακτηριστικό ενός σημείου δεδομένων. Το πρώτο χαρακτηριστικό δηλώνεται με x_1, το δεύτερο χαρακτηριστικό x_2, και ούτω καθεξής. Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό.
$\mathbf{x}$	Το διάνυσμα χαρακτηριστικών $\mathbf{x} = (x_1, \dots, x_d)^T$ ενός σημείου δεδομένων. Του διανύσματος οι καταχωρίσεις είναι τα μεμονωμένα χαρακτηριστικά ενός σημείου δεδομένων. Βλέπε επίσης: διάνυσμα χαρακτηριστικών, σημείο δεδομένων, διάνυσμα, χαρακτηριστικό.

$\mathcal{X}$ Ο χώρος χαρακτηριστικών $\mathcal{X}$ είναι το σύνολο όλων των πιθανών τιμών που μπορούν να πάρουν τα χαρακτηριστικά $\mathbf{x}$ ενός σημείου δεδομένων. Βλέπε επίσης: χώρος χαρακτηριστικών, χαρακτηριστικό, σημείο δεδομένων.

$\mathbf{z}$ Αντί του συμβόλου $\mathbf{x}$, χρησιμοποιούμε μερικές φορές $\mathbf{z}$ ως ένα άλλο σύμβολο για να δηλώσουμε ένα διάνυσμα του οποίου οι καταχωρίσεις είναι τα μεμονωμένα χαρακτηριστικά ενός σημείου δεδομένων. Χρειάζομαστε δύο διαφορετικά σύμβολα για να διακρίνουμε τα αχατέργαστα χαρακτηριστικά από αυτά που έχουν μαθευτεί [8, Κεφ. 9]. Βλέπε επίσης: διάνυσμα, χαρακτηριστικό, σημείο δεδομένων.

$\mathbf{x}^{(r)}$ Το διάνυσμα χαρακτηριστικών του r -στού σημείου δεδομένων εντός ενός συνόλου δεδομένων. Βλέπε επίσης: διάνυσμα χαρακτηριστικών, σημείο δεδομένων, σύνολο δεδομένων.

$x_j^{(r)}$ Το j -οστό χαρακτηριστικό του r -στού σημείου δεδομένων εντός ενός συνόλου δεδομένων. Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων, σύνολο δεδομένων.

$\mathcal{B}$ Μία μικρο-δέσμη (ή υποσύνολο) τυχαία επιλεγμένων σημείων δεδομένων. Βλέπε επίσης: δέσμη, σημείο δεδομένων.

B Το μέγεθος μίας μικρο-δέσμης (δηλαδή ο αριθμός των σημείων δεδομένων σε αυτή). Βλέπε επίσης: σημείο δεδομένων, δέσμη.

y	Η ετικέτα (ή η ποσότητα ενδιαφέροντος) ενός σημείου δεδομένων. Βλέπε επίσης: ετικέτα, σημείο δεδομένων.
$y^{(r)}$	Η ετικέτα του rστού σημείου δεδομένων. Βλέπε επίσης: ετικέτα, σημείο δεδομένων.
$(\mathbf{x}^{(r)}, y^{(r)})$	Τα χαρακτηριστικά και η ετικέτα του rστού σημείου δεδομένων. Βλέπε επίσης: χαρακτηριστικό, ετικέτα, σημείο δεδομένων.
$\mathcal{Y}$	Ο χώρος ετικετών $\mathcal{Y}$ μίας μεθόδου μηχανικής μάθησης αποτελείται από όλες τις πιθανές τιμές ετικετών που ένα σημείο δεδομένων μπορεί να φέρει. Ο ονομαστικός χώρος ετικετών μπορεί να είναι μεγαλύτερος από το σύνολο των διαφορετικών τιμών ετικετών που προκύπτουν σε ένα συγκεκριμένο σύνολο δεδομένων (π.χ. ένα σύνολο εκπαίδευσης). Προβλήματα (ή μέθοδοι) μηχανικής μάθησης που χρησιμοποιούν έναν αριθμητικό χώρο ετικετών, όπως $\mathcal{Y} = \mathbb{R}$ ή $\mathcal{Y} = \mathbb{R}^3$, αναφέρονται ως προβλήματα (ή μέθοδοι) παλινδρόμησης. Προβλήματα (ή μέθοδοι) μηχανικής μάθησης που χρησιμοποιούν έναν διακριτό χώρο ετικετών, όπως $\mathcal{Y} = \{0, 1\}$ ή $\mathcal{Y} = \{\text{γάτα}, \text{σκύλος}, \text{ποντίκι}\}$, αναφέρονται ως προβλήματα (ή μέθοδοι) ταξινόμησης. Βλέπε επίσης: χώρος ετικετών, μηχανική μάθηση, ετικέτα, σημείο δεδομένων, σύνολο δεδομένων, σύνολο εκπαίδευσης, παλινδρόμηση, ταξινόμηση.

η	Ο ρυθμός μάθησης (ή το μέγεθος βήματος) που χρησιμοποιείται από τις μεθόδους με βάση την κλίση. Βλέπε επίσης: ρυθμός μάθησης, μέγεθος βήματος, μέθοδος με βάση την κλίση.
$h(\cdot)$	Μία απεικόνιση υπόθεσης που αντιστοιχίζει τα χαρακτηριστικά ενός σημείου δεδομένων σε μία πρόβλεψη $\hat{y} = h(\mathbf{x})$ για την ετικέτα του y. Βλέπε επίσης: υπόθεση, απεικόνιση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα.
$\mathcal{Y}^{\mathcal{X}}$	Δεδομένων δύο συνόλων $\mathcal{X}$ και $\mathcal{Y}$, δηλώνουμε με $\mathcal{Y}^{\mathcal{X}}$ το σύνολο όλων των πιθανών απεικονίσεων υπόθεσης $h : \mathcal{X} \rightarrow \mathcal{Y}$. Βλέπε επίσης: υπόθεση, απεικόνιση.
$\mathcal{H}$	Ένας χώρος υποθέσεων ή μοντέλο που χρησιμοποιείται από μία μέθοδο μηχανικής μάθησης. Ο χώρος υποθέσεων αποτελείται από διαφορετικές απεικονίσεις υπόθεσης $h : \mathcal{X} \rightarrow \mathcal{Y}$ μεταξύ των οποίων η μέθοδος μηχανικής μάθησης πρέπει να επιλέξει. Βλέπε επίσης: χώρος υποθέσεων, μοντέλο, μηχανική μάθηση, υπόθεση, απεικόνιση.
$d_{\text{eff}}(\mathcal{H})$	Η αποτελεσματική διάσταση ενός χώρου υποθέσεων $\mathcal{H}$. Βλέπε επίσης: αποτελεσματική διάσταση, χώρος υποθέσεων.

B^2	Η τετραγωνική μεροληψία μίας υπόθεσης $\hat{h}$ που έχει μαθευτεί, ή των παραμέτρων της. Σημείωση ότι η $\hat{h}$ γίνεται μία τυχαία μεταβλητή αν μαθαίνεται από σημεία δεδομένων που είναι και τα ίδια τυχαίες μεταβλητές. Βλέπε επίσης: μεροληψία, υπόθεση, παράμετρος, τυχαία μεταβλητή, σημείο δεδομένων.
V	Η διακύμανση μίας υπόθεσης $\hat{h}$ που έχει μαθευτεί, ή των παραμέτρων της. Σημείωση ότι η $\hat{h}$ γίνεται μία τυχαία μεταβλητή αν μαθαίνεται από σημεία δεδομένων που είναι και τα ίδια τυχαίες μεταβλητές. Βλέπε επίσης: διακύμανση, υπόθεση, παράμετρος, τυχαία μεταβλητή, σημείο δεδομένων.
$L((\mathbf{x}, y), h)$	Η απώλεια που προκαλείται από την πρόβλεψη της ετικέτας y ενός σημείου δεδομένων χρησιμοποιώντας την πρόβλεψη $\hat{y} = h(\mathbf{x})$. Η πρόβλεψη $\hat{y}$ προκύπτει από την αξιολόγηση της υπόθεσης $h \in \mathcal{H}$ για το διάνυσμα χαρακτηριστικών $\mathbf{x}$ του σημείου δεδομένων. Βλέπε επίσης: απώλεια, ετικέτα, σημείο δεδομένων, πρόβλεψη, υπόθεση, διάνυσμα χαρακτηριστικών.
E_v	Το σφάλμα επικύρωσης μίας υπόθεσης h, το οποίο είναι η μέση της απώλεια που προκαλείται σε ένα σύνολο επικύρωσης. Βλέπε επίσης: σφάλμα επικύρωσης, υπόθεση, απώλεια, σύνολο επικύρωσης.

$\hat{L}(h \mathcal{D})$	Η εμπειρική διακινδύνευση, ή η μέση απώλεια, που προκαλείται από την υπόθεση h σε ένα σύνολο δεδομένων $\mathcal{D}$. Βλέπε επίσης: εμπειρική διακινδύνευση, απώλεια, υπόθεση, σύνολο δεδομένων.
E_t	Το σφάλμα εκπαίδευσης μίας υπόθεσης h, που είναι η μέση της απώλεια που προκαλείται σε ένα σύνολο εκπαίδευσης. Βλέπε επίσης: σφάλμα εκπαίδευσης, υπόθεση, απώλεια, σύνολο εκπαίδευσης.
t	Ένας δείκτης διακριτού χρόνου $t = 0, 1, \dots$ που χρησιμοποιείται για την απαρίθμηση ακολουθιακών γεγονότων (ή χρονικών στιγμών). Βλέπε επίσης: γεγονός.
t	Ένας δείκτης που απαριθμεί εργασίες μάθησης εντός ενός προβλήματος μάθησης πολυδιεργασίας. Βλέπε επίσης: εργασία μάθησης, μάθηση πολυδιεργασίας.
α	Μία παράμετρος ομαλοποίησης που ελέγχει το ποσό της ομαλοποίησης. Βλέπε επίσης: παράμετρος, ομαλοποίηση.
$\lambda_j(\mathbf{Q})$	Η j-οστή ιδιοτιμή (ταξινομημένη σε αύξουσα ή φθίνουσα σειρά) ενός θετικά ημιορισμένου πίνακα $\mathbf{Q}$. Χρησιμοποιούμε επίσης τη συντομογραφία λ_j αν ο αντίστοιχος πίνακας είναι προφανής από τα συμφραζόμενα. Βλέπε επίσης: ιδιοτιμή, θετικά ημιορισμένος, πίνακας.

$\sigma(\cdot)$	Η συνάρτηση ενεργοποίησης που χρησιμοποιείται από έναν τεχνητό νευρώνα εντός ενός ΤΝΔ. Βλέπε επίσης: συνάρτηση ενεργοποίησης, τεχνητός νευρώνας, τεχνητό νευρωνικό δίκτυο (ΤΝΔ).
$\mathcal{R}_{\hat{g}}$	Μία περιοχή αποφάσεων εντός ενός χώρου χαρακτηριστικών. Βλέπε επίσης: περιοχή αποφάσεων, χώρος χαρακτηριστικών.
$\mathbf{w}$	Ένα παραμετρικό διάνυσμα $\mathbf{w} = (w_1, \dots, w_d)^T$ ενός μοντέλου, π.χ. τα βάρη ενός γραμμικού μοντέλου ή ενός ΤΝΔ. Βλέπε επίσης: παράμετρος, διάνυσμα, μοντέλο, βάρος, γραμμικό μοντέλο, ΤΝΔ.
$h^{(\mathbf{w})}(\cdot)$	Μία απεικόνιση υπόθεσης που περιλαμβάνει ρυθμιζόμενες παραμέτρους μοντέλου $w_1, \dots, w_d$ στοιβαγμένες στο διάνυσμα $\mathbf{w} = (w_1, \dots, w_d)^T$. Βλέπε επίσης: υπόθεση, απεικόνιση, παράμετρος μοντέλου, διάνυσμα.
$\phi(\cdot)$	Ένας απεικόνιση χαρακτηριστικών $\phi : \mathcal{X} \rightarrow \mathcal{X}' : \mathbf{x} \mapsto \phi(\mathbf{x})$ που μετασχηματίζει το διάνυσμα χαρακτηριστικών $\mathbf{x}$ ενός σημείου δεδομένων σε ένα νέο διάνυσμα χαρακτηριστικών $\mathbf{x}' = \phi(\mathbf{x}) \in \mathcal{X}'$. Βλέπε επίσης: απεικόνιση χαρακτηριστικών, διάνυσμα χαρακτηριστικών, σημείο δεδομένων.

$k(\cdot, \cdot)$	Δεδομένου κάποιου χώρου χαρακτηριστικών $\mathcal{X}$, ένας πυρήνας είναι μία απεικόνιση $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{C}$ που είναι θετικά ημιορισμένη. Βλέπε επίσης: χώρος χαρακτηριστικών, πυρήνας, απεικόνιση, θετικά ημιορισμένος.
$\text{VCdim}(\mathcal{H})$	Η διάσταση Vapnik–Chervonenkis του χώρου υποθέσεων $\mathcal{H}$. Βλέπε επίσης: διάσταση Vapnik–Chervonenkis, χώρος υποθέσεων.

Ομοσπονδιακή Μάθηση

$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	Ένας μη κατευθυνόμενος γράφος του οποίου οι κόμβοι $i \in \mathcal{V}$ αναπαριστούν συσκευές εντός ενός δικτύου ομοσπονδιακής μάθησης. Οι μη κατευθυνόμενες σταθμισμένες ακμές $\mathcal{E}$ αναπαριστούν τη συνδεσιμότητα μεταξύ συσκευών και τις στατιστικές ομοιότητες μεταξύ των συνόλων δεδομένων τους και των εργασιών μάθησης. Βλέπε επίσης: μη κατευθυνόμενος γράφος, συσκευή, δίκτυο ομοσπονδιακής μάθησης, σύνολο δεδομένων, εργασία μάθησης.
$i \in \mathcal{V}$	Ένας κόμβος που αναπαριστά κάποια συσκευή εντός ενός δικτύου ομοσπονδιακής μάθησης. Η συσκευή μπορεί να έχει πρόσβαση σε ένα τοπικό σύνολο δεδομένων και να εκπαιδεύσει ένα τοπικό μοντέλο. Βλέπε επίσης: συσκευή, δίκτυο ομοσπονδιακής μάθησης, τοπικό σύνολο δεδομένων, τοπικό μοντέλο.
$\mathcal{G}^{(\mathcal{C})}$	Ο επαγόμενος υπογράφος του $\mathcal{G}$ χρησιμοποιώντας τους κόμβους στο $\mathcal{C} \subseteq \mathcal{V}$.
$\mathbf{L}^{(\mathcal{G})}$	Ο Λαπλασιανός πίνακας ενός γράφου $\mathcal{G}$. Βλέπε επίσης: Λαπλασιανός πίνακας, γράφος.
$\mathbf{L}^{(\mathcal{C})}$	Ο Λαπλασιανός πίνακας του επαγόμενου γράφου $\mathcal{G}^{(\mathcal{C})}$. Βλέπε επίσης: Λαπλασιανός πίνακας, γράφος.

$\mathcal{N}^{(i)}$	Η γειτονιά του κόμβου i σε έναν γράφο $\mathcal{G}$. Βλέπε επίσης: γειτονιά, γράφος.
$d^{(i)}$	Ο σταθμισμένος βαθμός κόμβου $d^{(i)} := \sum_{i' \in \mathcal{N}^{(i)}} A_{i,i'}$ του κόμβου i. Βλέπε επίσης: βαθμός κόμβου.
$d_{\max}^{(\mathcal{G})}$	Ο μέγιστος σταθμισμένος βαθμός κόμβου ενός γράφου $\mathcal{G}$. Βλέπε επίσης: μέγιστο, βαθμός κόμβου, γράφος.
$\mathcal{D}^{(i)}$	Το τοπικό σύνολο δεδομένων $\mathcal{D}^{(i)}$ που φέρει ο κόμβος $i \in \mathcal{V}$ ενός δικτύου ομοσπονδιακής μάθησης. Βλέπε επίσης: τοπικό σύνολο δεδομένων, δίκτυο ομοσπονδιακής μάθησης.
m_i	Ο αριθμός των σημείων δεδομένων (δηλαδή το μέγεθος δείγματος) που περιέχονται στο τοπικό σύνολο δεδομένων $\mathcal{D}^{(i)}$ στον κόμβο $i \in \mathcal{V}$. Βλέπε επίσης: σημείο δεδομένων, μέγεθος δείγματος, τοπικό σύνολο δεδομένων.
$\mathbf{x}^{(i,r)}$	Τα χαρακτηριστικά του rστού σημείου δεδομένων στο τοπικό σύνολο δεδομένων $\mathcal{D}^{(i)}$. Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων, τοπικό σύνολο δεδομένων.
$y^{(i,r)}$	Η ετικέτα του rστού σημείου δεδομένων στο τοπικό σύνολο δεδομένων $\mathcal{D}^{(i)}$. Βλέπε επίσης: ετικέτα, σημείο δεδομένων, τοπικό σύνολο δεδομένων.

$\mathbf{w}^{(i)}$	Οι τοπικοί παράμετροι μοντέλου της συσκευής i εντός ενός δικτύου ομοσπονδιακής μάθησης. Βλέπε επίσης: παράμετρος μοντέλου, συσκευή, δίκτυο ομοσπονδιακής μάθησης.
$L_i(\mathbf{w})$	Η τοπική συνάρτηση απώλειας που χρησιμοποιείται από τη συσκευή i για να μετρήσει τη χρησιμότητα κάποιας επιλογής $\mathbf{w}$ για τις τοπικές παραμέτρους μοντέλου. Βλέπε επίσης: συνάρτηση απώλειας, συσκευή, παράμετρος μοντέλου.
$L^{(d)}(\mathbf{x}, h(\mathbf{x}), h'(\mathbf{x}))$	Η απώλεια που προκαλείται από μία υπόθεση h' σε ένα σημείο δεδομένων με χαρακτηριστικά $\mathbf{x}$ και ετικέτα $h(\mathbf{x})$ που προκύπτει από μία άλλη υπόθεση. Βλέπε επίσης: απώλεια, υπόθεση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα.
$\text{stack}\{\mathbf{w}^{(i)}\}_{i=1}^n$	Το διάνυσμα $\left((\mathbf{w}^{(1)})^T, \dots, (\mathbf{w}^{(n)})^T \right)^T \in \mathbb{R}^{dn}$ που προκύπτει από την κάθετη στοίβαξη των τοπικών παραμέτρων μοντέλου $\mathbf{w}^{(i)} \in \mathbb{R}^d$, για $i = 1, \dots, n$. Βλέπε επίσης: διάνυσμα, στοίβαξη, παράμετρος μοντέλου.
$h^{(i)}$	Μία υπόθεση $h^{(i)} \in \mathcal{H}^{(i)}$ σε κάποιον κόμβο i εντός ενός δικτύου ομοσπονδιακής μάθησης. Βλέπε επίσης: υπόθεση, δίκτυο ομοσπονδιακής μάθησης.

$\hat{h}^{(i)}$

Μία υπόθεση $\hat{h}^{(i)} \in \mathcal{H}^{(i)}$ που έχει μαθευτεί, η οποία έχει προκύψει από κάποια μέθοδο ομοσπονδιακής μάθησης, σε κάποιον κόμβο i εντός ενός δικτύου ομοσπονδιακής μάθησης.

Βλέπε επίσης: υπόθεση, ομοσπονδιακή μάθηση, δίκτυο ομοσπονδιακής μάθησης.

Μαθηματικά Εργαλεία

αθροιστική συνάρτηση κατανομής Μία αθροιστική συνάρτηση κατανομής (cumulative distribution function - cdf) $F^{(x)}(\eta)$ μίας τυχαίας μεταβλητής πραγματικής τιμής x είναι [9], [10]

$$F^{(x)}(\eta) := \mathbb{P}(x \leq \eta).$$

Βλέπε επίσης: τυχαία μεταβλητή, συνάρτηση πυκνότητας πιθανότητας, κατανομή πιθανότητας.

αιτιότητα Στο πλαίσιο της μηχανικής μάθησης, η αιτιότητα (causality) αναφέρεται σε σχέσεις αιτίου–αποτελέσματος μεταξύ ποσοτήτων, όπως τα χαρακτηριστικά και οι ετικέτες σημείων δεδομένων [11], [12]. Στη βιβλιογραφία έχουν αναπτυχθεί διαφορετικές έννοιες αιτιότητας. Μία ευρέως χρησιμοποιούμενη έννοια βασίζεται σε ένα δομικό αιτιώδες μοντέλο, το οποίο αναπαριστά τους αιτιώδεις μηχανισμούς μέσω συναρτησιακών σχέσεων [11]. Για δεδομένα χρονοσειρών, η αιτιότητα κατά Granger ορίζει μια προβλεπτική έννοια αιτιότητας [13], [14]. Μία στοχαστική διαδικασία $X_1, X_2, \dots$ λέγεται ότι προκαλεί μία άλλη στοχαστική διαδικασία $Y_1, Y_2, \dots$ αν η χρήση προηγούμενων τιμών $X_{t'}, t' < t$, βελτιώνει την πρόβλεψη της Y_t πέρα από τη χρήση μόνο της προηγούμενης της Y . Βλέπε επίσης: μηχανική μάθηση, χαρακτηριστικό, ετικέτα, σημείο δεδο-

μένων, δομικό αιτιώδες μοντέλο, δεδομένα, στοχαστική διαδικασία, πρόβλεψη.

αιτιότητα κατά Granger Βλέπε αιτιότητα.

Βλέπε επίσης: δομικό αιτιώδες μοντέλο, στοχαστική διαδικασία.

ακολουθία Μία ακολουθία (sequence) είναι μία διατεταγμένη συλλογή τιμών από ένα σύνολο $\mathcal{A}$. Για παράδειγμα, μία ακολουθία τιμών από το σύνολο $\mathcal{A} = \{\star, \otimes\}$ θα μπορούσε να είναι

$$a = (\star, \otimes, \star, \star, \otimes, \dots).$$

Τυπικά, μία ακολουθία a είναι μία συνάρτηση [2]

$$a : \mathbb{N} \rightarrow \mathcal{A} : r \mapsto a_r.$$

Δηλώνουμε μία ακολουθία με $(a_r)_{r \in \mathbb{N}}$ ή $(a^{(r)})_{r \in \mathbb{N}}$. Μερικές φορές χρησιμοποιούμε και τον συμβολισμό $\{a^{(r)}\}_{r \in \mathbb{N}}$. Σημείωση ότι η ίδια τιμή $a \in \mathcal{A}$ μπορεί να εμφανιστεί πολλές φορές στην ακολουθία σε διαφορετικές θέσεις r . Οι ακολουθίες είναι θεμελιώδεις για τη μελέτη μεθόδων μηχανικής μάθησης, για παράδειγμα όταν περιγράφουμε διαδοχικές επαναλήψεις $\{\mathbf{w}^{(t)}\}_{t \in \mathbb{N}}$ ενός επαναληπτικού αλγόριθμου που ενημερώνει ένα διάνυσμα παραμέτρων. Μπορούμε επίσης να χρησιμοποιήσουμε μία ακολουθία για να αναπαραστήσουμε ένα άπειρο σύνολο δεδομένων


$$\mathcal{D} = \{ (\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots \}.$$

Βλέπε επίσης: συνάρτηση, μηχανική μάθηση, αλγόριθμος, παράμετρος, διάνυσμα, σύνολο δεδομένων, σύγκλιση, ακολουθία Cauchy.

ακολουθία Cauchy Μία ακολουθία Cauchy (Cauchy sequence) είναι μία ακολουθία $(\mathbf{x}^{(r)})_{r \in \mathbb{N}}$ σε έναν μετρικό χώρο $(\mathcal{X}, d(\cdot, \cdot))$ έτσι ώστε τα στοιχεία $\mathbf{x}^{(r)} \in \mathcal{X}$ γίνονται τελικά αυθαίρετα κοντινά το ένα στο άλλο. Με άλλα λόγια, [2, Ορισμός 3.8],

$$\forall \epsilon > 0, \exists N \in \mathbb{N} \text{ έτσι ώστε } \forall r, r' \geq N, d(\mathbf{x}^{(r)}, \mathbf{x}^{(r')}) < \epsilon.$$

Το Σχ. 1 δείχνει μία ακολουθία Cauchy στον μετρικό χώρο $(\mathbb{Q}, |\cdot|)$ ρητών αριθμών.




Σχ. 1. Ακολουθία Cauchy $(x^{(r)})_{r \in \mathbb{N}}$ στον μετρικό χώρο $(\mathbb{Q}, |\cdot|)$. Αυτή η ακολουθία παράγεται από μία επανάληψη σταθερού σημείου που χρησιμοποιείται για την προσέγγιση του $\sqrt{2}$. Για όλα τα $r \geq N$, τα στοιχεία της ακολουθίας βρίσκονται εντός μίας ζώνης πλάτους ϵ . Σημείωση ότι η ακολουθία δεν συγκλίνει στον $\mathbb{Q}$, εφόσον $\sqrt{2} \notin \mathbb{Q}$ [2, Παράδειγμα 1.1].

Βλέπε επίσης: ακολουθία, μετρικός χώρος, επανάληψη σταθερού σημείου, σύγκλιση.

αλγεβρική συνδεσιμότητα Η αλγεβρική συνδεσιμότητα (algebraic con-

nectivity) ενός μη κατευθυνόμενου γράφου είναι η δεύτερη μικρότερη ιδιοτιμή λ_2 του Λαπλασιανού πίνακα του. Ένας μη κατευθυνόμενος γράφος είναι συνδεδεμένος αν και μόνο αν $\lambda_2 > 0$ (βλέπε Σχ. 2) [15], [16].



Σχ. 2. Τρία παραδείγματα μη κατευθυνόμενων γράφων.

Βλέπε επίσης: μη κατευθυνόμενος γράφος, ιδιοτιμή, Λαπλασιανός πίνακας, συνδεδεμένος, γράφος.

αλγόριθμος εγγύτητας A proximal αλγόριθμος refers to an μέθοδος βελτιστοποίησης that uses τελεστής εγγύτητας as the main computational primitive [17]. Proximal αλγόριθμοι generalize μέθοδος με βάση την κλίσης by replacing βήμα κλίσης with the application of τελεστής εγγύτητας induced by the αντικειμενική συνάρτηση or some approximation. It is interesting to note that the βήμα κλίσης for a λεία and κυρτό συνάρτηση coincides with the τελεστής εγγύτητας of a local linear approximation. Proximal αλγόριθμοι can be applied to a wide range of πρόβλημα βελτιστοποίησης, including those with a μη λεία αντικειμενική συνάρτηση [17].

See also: τελεστής, χώρος Hilbert, σταθερό σημείο.

αλγόριθμος προσδοκίας-μεγιστοποίησης TBC.

αλυσίδα Markov Μία αλυσίδα Markov (Markov chain) είναι μία στοχαστική διαδικασία $\{X_t\}_{t \in \mathbb{N}}$ που ορίζεται σε έναν κοινό χώρο πιθανοτήτων και χρησιμοποιεί το σύνολο δεικτών $\mathbb{N}$. Η τυχαία μεταβλητή X_t μπορεί να αναπαριστά μία κατάσταση (ή την παραγωγή της) ενός φυσικού συστήματος τη χρονική στιγμή t . Η καθοριστική ιδιότητα μίας αλυσίδας Markov είναι η ιδιότητα Markov [10], [18], [19]. Για κάθε $t \in \mathbb{N}$,

$$\mathbb{P}(X_{t+1}|X_t, \dots, X_1) = \mathbb{P}(X_{t+1}|X_t).$$

Με άλλα λόγια, η κατανομή πιθανότητας υπό συνθήκη της επόμενης κατάστασης X_{t+1} εξαρτάται από προηγούμενες $X_t, X_{t-1}, \dots, X_1$ μόνο μέσω της τρέχουσας κατάστασης X_t . Η έννοια της αλυσίδας Markov μπορεί να γενικευτεί από τον διακριτό χρόνο (με σύνολο δεικτών $\mathbb{N}$) στον συνεχή χρόνο (με σύνολο δεικτών $\mathbb{R}$) [19].

Βλέπε επίσης: στοχαστική διαδικασία, χώρος πιθανοτήτων, τυχαία μεταβλητή, κατάσταση, ιδιότητα Markov, κατανομή πιθανότητας υπό συνθήκη, διαδικασία απόφασης Markov.

αμερόληπτος εκτιμητής Ένας εκτιμητής για τις παραμέτρους ενός πιθανοτικού μοντέλου είναι αμερόληπτος (unbiased estimator) αν η προσδοκία του ισούται με την πραγματική τιμή των παραμέτρων [20], [21].

Βλέπε επίσης: εκτιμητής, παράμετρος, πιθανοτικό μοντέλο, προσδοκία.

αμφιμονοσήμαντη Μία συνάρτηση $f : \mathcal{U} \rightarrow \mathcal{V}$ είναι αμφιμονοσήμαντη (injective) αν αντιστοιχίζει διαφορετικά στοιχεία του πεδίου ορισμού της σε


διαφορετικά στοιχεία του πεδίου τιμών της, δηλαδή αν $f(u_1) = f(u_2)$ συνεπάγεται $u_1 = u_2$ για όλα τα $u_1, u_2 \in \mathcal{U}$ [22]. Ισοδύναμα, δεν υπάρχουν δύο διαφορετικές είσοδοι της συνάρτησης που να αντιστοιχίζονται στην ίδια έξοδο της συνάρτησης.

Βλέπε επίσης: συνάρτηση, πεδίο ορισμού, co-domain, έξοδος.

ανάλυση ιδιζουσών τιμών Η ανάλυση ιδιζουσών τιμών (singular value decomposition - SVD) για έναν πίνακα $\mathbf{A} \in \mathbb{R}^{m \times d}$ είναι μία παραγοντοποίηση της ακόλουθης μορφής:

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{U}^T$$

με ορθοκανονικούς πίνακες $\mathbf{V} = (\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(m)}) \in \mathbb{R}^{m \times m}$ και $\mathbf{U} = (\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}) \in \mathbb{R}^{d \times d}$ [3] (βλέπε Σχ. 3).



Σχ. 3. Ορθοκανονικοί πίνακες $\mathbf{V}$ και $\mathbf{U}$.

Ο πίνακας $\mathbf{\Lambda} \in \mathbb{R}^{m \times d}$ είναι μη μηδενικός μόνο κατά την κύρια διαγώνιο, της οποίας οι καταχωρίσεις $\Lambda_{j,j}$ είναι μη αρνητικές και αναφέρονται ως ιδιάζουσες τιμές.

Βλέπε επίσης: πίνακας, ιδιάζουσα τιμή.

ανάλυση ιδιοτιμών Η ανάλυση ιδιοτιμών (eigenvalue decomposition - EVD) για έναν τετραγωνικό πίνακα $\mathbf{A} \in \mathbb{R}^{d \times d}$ είναι μία παραγοντοποίηση της

μορφής

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}.$$

Οι στήλες του πίνακα $\mathbf{V} = (\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(d)})$ είναι τα ιδιοδιανύσματα του πίνακα $\mathbf{V}$. Ο διαγώνιος πίνακας $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \dots, \lambda_d\}$ περιέχει τις ιδιοτιμές λ_j που αντιστοιχούν στα ιδιοδιανύσματα $\mathbf{v}^{(j)}$. Οι πίνακες που επιτρέπουν μία ανάλυση ιδιοτιμών αναφέρονται ως διαγωνοποιήσιμοι.

Βλέπε επίσης: πίνακας, ιδιοδιάνυσμα, ιδιοτιμή, διαγωνοποιήσιμος.

ανάλυση Schur Κάθε τετραγωνικός πίνακας $\mathbf{A} \in \mathbb{C}^{d \times d}$ επιτρέπει μία ανάλυση Schur (Schur decomposition) ως εξής [3, Θεώρημα 7.1.3]:

$$\mathbf{A} = \mathbf{U}\mathbf{T}\mathbf{U}^H.$$

Εδώ, ο $\mathbf{U} \in \mathbb{C}^{d \times d}$ είναι ένας ορθομοναδιαίος πίνακας (δηλαδή $\mathbf{U}^H\mathbf{U} = \mathbf{I}$) και ο $\mathbf{T}$ είναι ένας άνω τριγωνικός με τις ιδιοτιμές του $\mathbf{A}$ στην κύρια διαγώνιό του. Σημειώστε προσεκτικά ότι η ανάλυση Schur υπάρχει και για έναν πίνακα $\mathbf{A}$ που δεν είναι διαγωνοποιήσιμος. Η ταυτότητα

$$(\mathbf{U}^{(1)})^H \mathbf{A} \mathbf{U}^{(1)} = \begin{pmatrix} (\mathbf{x}^{(1)})^H \\ (\mathbf{X}^{(2)})^H \end{pmatrix} \mathbf{A} \begin{pmatrix} \mathbf{x}^{(1)} & \mathbf{X}^{(2)} \end{pmatrix} = \begin{pmatrix} \lambda_1 & \mathbf{b}^H \\ 0 & \mathbf{A}^{(1)} \end{pmatrix}$$

αναπαριστά το πρώτο βήμα στην κατασκευή της ανάλυσης Schur. Κάθε πίνακας $\mathbf{A} \in \mathbb{C}^{n \times n}$ έχει τουλάχιστον μία ιδιοτιμή λ_1 με ένα μοναδιαίας νόρμας ιδιοδιάνυσμα $\mathbf{x}^{(1)}$, $\mathbf{A}\mathbf{x}^{(1)} = \lambda_1\mathbf{x}^{(1)}$. Αυτό το ιδιοδιάνυσμα μας επιτρέπει να αναλύσουμε τον $\mathbf{A}$ όπως φαίνεται παραπάνω. Εδώ, επεκτείνουμε το $\mathbf{x}^{(1)}$ σε μία ορθοκανονική βάση $\mathbf{Q}^{(1)} = (\mathbf{x}^{(1)} \mid \mathbf{X}^{(2)})$ και χρησιμοποι-

ούμε $\mathbf{b}^H := (\mathbf{x}^{(1)})^H \mathbf{A} \mathbf{X}^{(2)}$ και $\mathbf{A}^{(1)} := (\mathbf{X}^{(2)})^H \mathbf{A} \mathbf{X}^{(2)}$. Η εφαρμογή της ίδιας κατασκευής αναδρομικά στον $\mathbf{A}^{(1)}$ αποφέρει την ανάλυση Schur. Βλέπε επίσης: πίνακας, ορθομοναδιαίος πίνακας, ιδιοτιμή, διαγωνοποιήσιμος, νόρμα, ιδιοδιάνυσμα, βάση, ανάλυση ιδιοτιμών.

ανάστροφος Ο ανάστροφος (transpose) ενός πίνακα πραγματικής τιμής προκύπτει με την ανταλλαγή γραμμών και στηλών. Για έναν πίνακα $\mathbf{A} \in \mathbb{R}^{m \times d}$, ο ανάστροφός του δηλώνεται με $\mathbf{A}^T$ και ικανοποιεί $(\mathbf{A}^T)_{j,j'} = \mathbf{A}_{j',j}$.

Βλέπε επίσης: πίνακας, συμμετρικός πίνακας.

ανεξάρτητες και ταυτόσημα κατανεμημένες Μία συλλογή τυχαίων μεταβλητών $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$ ορισμένων στον ίδιο χώρο πιθανοτήτων $(\Omega, \Sigma, \mathbb{P}(\cdot))$ αναφέρεται ως συλλογή ανεξάρτητων και ταυτόσημα κατανεμημένων (independent and identically distributed - i.i.d.) αν κάθε $\mathbf{z}^{(r)}$ ακολουθεί την ίδια κατανομή πιθανότητας, και οι τυχαίες μεταβλητές είναι αμοιβαία ανεξάρτητες. Για την ακρίβεια, για οποιαδήποτε συλλογή γεγονότων $\mathcal{A}_1, \dots, \mathcal{A}_m$, έχουμε

$$\mathbb{P}(\mathbf{z}^{(1)} \in \mathcal{A}_1, \dots, \mathbf{z}^{(m)} \in \mathcal{A}_m) = \prod_{r=1}^m \mathbb{P}(\mathbf{z}^{(r)} \in \mathcal{A}_r).$$

Η θεωρία πιθανοτήτων εγγυάται επίσης την ύπαρξη και την κατασκευή ανεξάρτητων αντιγράφων τυχαίων μεταβλητών [5, Θεώρημα 2.19].

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, κατανομή πιθανότητας, γεγονός, σημείο δεδομένων, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων.

ανισότητα συγκέντρωσης Η ανισότητα συγκέντρωσης (concentration inequality) αναφέρεται σε ένα άνω φράγμα της πιθανότητας ότι μία τυχαία μεταβλητή αποκλίνει περισσότερο από ένα καθορισμένο ποσό από την προσδοκία της [23].


Βλέπε επίσης: πιθανότητα, τυχαία μεταβλητή, προσδοκία, ανισότητα του Markov, ανισότητα του Chebyshev, ανισότητα του Hoeffding, φράγμα Chernoff.

ανισότητα Cauchy-Schwarz TBC.

ανισότητα του Chebyshev Θεωρούμε μία τυχαία μεταβλητή πραγματικής τιμής x για την οποία η δεύτερη ροπή $\mathbb{E}\{x^2\}$ υφίσταται (και είναι πεπερασμένη). Η ύπαρξη της δεύτερης ροπής συνεπάγεται την ύπαρξη μίας πεπερασμένης προσδοκίας $\mu := \mathbb{E}\{x\}$ και μίας πεπερασμένης διακύμανσης $\sigma^2 := \mathbb{E}\{(x-\mu)^2\}$ [24, Πρόταση 6.12]. Η ανισότητα του Chebyshev (Chebyshev's inequality) αναφέρεται στο ακόλουθο άνω φράγμα στην πιθανότητα η x να αποκλίνει από την μ περισσότερο από ένα δεδομένο κατώφλι η [25, Κεφ. 4]. Συγκεκριμένα,

$$\mathbb{P}(|x - \mu| \geq \eta) \leq \frac{\sigma^2}{\eta^2} \quad \text{για οποιοδήποτε } \eta > 0.$$

Αυτό το άνω φράγμα μπορεί να προκύψει εφαρμόζοντας την ανισότητα του Markov στη νέα τυχαία μεταβλητή $\tilde{x} := (x - \mu)^2$.



Σχ. 4. Η ανισότητα του Chebyshev παρέχει ένα άνω φράγμα στην πιθανότητα ουράς $\mathbb{P}(|x - \mu| \geq \eta)$ (δηλαδή η χρωματισμένη περιοχή) μίας τυχαίας μεταβλητής πραγματικής τιμής x με μία πεπερασμένη δεύτερη ροπή.

Βλέπε επίσης: τυχαία μεταβλητή, προσδοκία, διακύμανση, πιθανότητα, ανισότητα του Markov, ανισότητα συγκέντρωσης.

ανισότητα του Hoeffding Η ανισότητα του Hoeffding (Hoeffding's inequality) [26] είναι μία θεμελιώδης ανισότητα συγκέντρωσης που παρέχει ένα άνω φράγμα στην πιθανότητα ένα άθροισμα (ή μέσος όρος) ανεξάρτητων, φραγμένων τυχαίων μεταβλητών να αποκλίνει από τη μέση τιμή του περισσότερο από κάποιο κατώφλι. Έστω $x_1, \dots, x_n$ ανεξάρτητες τυχαίες μεταβλητές πραγματικής τιμής x_i που παίρνουν τιμές στο $[a_i, b_i] \subset \mathbb{R}$, και $S_n := \sum_{i=1}^n x_i$ και $\mathbb{E}\{S_n\} = \sum_{i=1}^n \mathbb{E}\{x_i\}$. Τότε, η ανισότητα του Hoeffding [27, Θεώρημα 2.2.6] δηλώνει ότι

$$\mathbb{P}(|S_n - \mathbb{E}\{S_n\}| \geq t) \leq 2 \exp \left(- \frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2} \right) \quad \forall t > 0.$$

Η ανισότητα του Hoeffding παρέχει συνήθως οξύτερα φράγματα από την ανισότητα του Chebyshev, αλλά είναι πιο περιοριστική καθώς προϋποθέτει

φραγμένες τυχαίες μεταβλητές. Στο πλαίσιο της μηχανικής μάθησης, η ανισότητα του Hoeffding μπορεί να χρησιμοποιηθεί για την ανάλυση μεθόδων ελαχιστοποίησης εμπειρικής διακινδύνευσης ή MAB.

Βλέπε επίσης: ανισότητα συγκέντρωσης, πιθανότητα, τυχαία μεταβλητή, μέση τιμή, ανισότητα του Chebyshev, μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, MAB, προσδοκία, χώρος πιθανοτήτων, ανισότητα του Markov.

ανισότητα του Markov Θεωρούμε μία μη αρνητική τυχαία μεταβλητή πραγματικής τιμής x για την οποία υφίσταται η προσδοκία $\mathbb{E}\{x\}$. Η ανισότητα του Markov (Markov's inequality) παρέχει ένα άνω φράγμα στην πιθανότητα $\mathbb{P}(x \geq a)$ η x να υπερβαίνει ένα δεδομένο θετικό κατώφλι $a > 0$. Συγκεκριμένα,

$$\mathbb{P}(x \geq a) \leq \frac{\mathbb{E}\{x\}}{a} \quad \text{ισχύει για οποιοδήποτε } a > 0.$$


Αυτή η ανισότητα μπορεί να επαληθευτεί παρατηρώντας ότι η $\mathbb{P}(x \geq a)$ είναι η προσδοκία $\mathbb{E}\{g(x)\}$ με την ακόλουθη δείκτρια συνάρτηση:

$$g : \mathbb{R} \rightarrow \mathbb{R} : x' \mapsto \mathbb{I}_{\{x \geq a\}}(x').$$

Όπως απεικονίζεται στο Σχ. 5, για οποιοδήποτε θετικό $a > 0$,

$$g(x') \leq x'/a \quad \text{για κάθε } x' \in \mathbb{R}.$$

Αυτό συνεπάγεται την ανισότητα του Markov μέσω της ιδιότητας μονοτονίας του ολοκληρώματος Lebesgue [24, σελ. 50].



Σχ. 5. Προσδοκία $\mathbb{E}\{x\}$ και πιθανότητα $\mathbb{P}(x \geq a)$ μίας μη αρνητικής τυχαίας μεταβλητής x με μία συνάρτηση πυκνότητας πιθανότητας $p^{(x)}(\cdot)$, που προκύπτουν μέσω ολοκληρωμάτων Lebesgue των $f(x') = x'/a$ και $g(x') = \mathbb{I}_{\{x \geq a\}}(x')$, αντίστοιχα.

Βλέπε επίσης: τυχαία μεταβλητή, προσδοκία, πιθανότητα, δείκτρια συνάρτηση, ολοκλήρωμα Lebesgue, συνάρτηση πυκνότητας πιθανότητας, ανισότητα συγκέντρωσης.


αντιστρέψιμος (πίνακας) Ένας τετραγωνικός πίνακας $\mathbf{A} \in \mathbb{R}^{n \times n}$ ονομάζεται αντιστρέψιμος (invertible) αν υφίσταται ένας πίνακας $\mathbf{B} \in \mathbb{R}^{n \times n}$ τέτοιος ώστε $\mathbf{AB} = \mathbf{BA} = \mathbf{I}$, όπου $\mathbf{I}$ είναι ο ταυτοτικός πίνακας $n \times n$ [28], [29], [30]. Στην περίπτωση αυτή, ο $\mathbf{B}$ ονομάζεται αντίστροφος πίνακας του $\mathbf{A}$ και δηλώνεται με $\mathbf{A}^{-1}$.

Βλέπε επίσης: πίνακας, αντίστροφος πίνακας.

αντίστροφος πίνακας Ένας αντίστροφος πίνακας (inverse matrix) $\mathbf{A}^{-1}$ ορίζεται για έναν τετραγωνικό πίνακα $\mathbf{A} \in \mathbb{R}^{n \times n}$ που είναι πλήρους τάξης, που σημαίνει ότι οι στήλες του είναι γραμμικά ανεξάρτητες. Σε αυτή την περίπτωση, ο $\mathbf{A}$ λέγεται ότι είναι αντιστρέψιμος, και ο αντίστροφός του ικανοποιεί

$$\mathbf{AA}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}.$$

Ένας τετραγωνικός πίνακας είναι αντιστρέψιμος αν και μόνο αν η ορίζουσά του είναι μη μηδενική. Οι αντίστροφοι πίνακες είναι θεμελιώδεις στη λύση συστημάτων γραμμικών εξισώσεων και στην κλειστής μορφής λύση γραμμικής παλινδρόμησης [28], [31]. Η έννοια του αντίστροφου πίνακα μπορεί να επεκταθεί σε πίνακες που δεν είναι τετραγωνικοί ή πλήρους τάξης. Μπορεί κανείς να ορίσει έναν «αριστερό αντίστροφο» $\mathbf{B}$ που ικανοποιεί $\mathbf{BA} = \mathbf{I}$ ή έναν «δεξιό αντίστροφο» $\mathbf{C}$ που ικανοποιεί $\mathbf{AC} = \mathbf{I}$. Για γενικούς ορθογώνιους ή ιδιάζοντες πίνακες, ο ψευδοαντίστροφος Moore–Penrose $\mathbf{A}^+$ παρέχει μία ενοποιημένη έννοια γενικευμένου αντίστροφου πίνακα [3].



Σχ. 6. Πίνακας $\mathbf{A}$ που αναπαριστά έναν γραμμικό μετασχηματισμό του $\mathbb{R}^2$. αντίστροφος πίνακας $\mathbf{A}^{-1}$ που αναπαριστά τον αντίστροφο μετασχηματισμό.

Βλέπε επίσης: πίνακας, πλήρους τάξης, γραμμικά ανεξάρτητο, αντιστρέψιμος, ορίζουσα, γραμμική παλινδρόμηση, ψευδοαντίστροφος.

απεικόνιση Χρησιμοποιούμε τον όρο απεικόνιση (map) ως συνώνυμο της συνάρτησης.

Βλέπε επίσης: συνάρτηση.

απλή συνάρτηση Μία απλή συνάρτηση (simple function) $f : \mathbb{R}^d \rightarrow \mathbb{R}$ είναι

μία μετρήσιμη συνάρτηση που παίρνει μόνο πεπερασμένο αριθμό τιμών.

Με άλλα λόγια,

$$f(\mathbf{x}) = \sum_{c=1}^k \alpha_c \mathbb{I}_{\mathcal{C}^{(c)}}(\mathbf{x}),$$

όπου $\mathbb{I}_{\mathcal{C}}$ δηλώνει τη δείκτρια συνάρτηση ενός υποσυνόλου $\mathcal{C} \subset \mathbb{R}^d$ και οι $\alpha_1, \dots, \alpha_k \in \mathbb{R}$ είναι αυθαίρετοι συντελεστές. Τα υποσύνολα $\mathcal{C}^{(1)}, \dots, \mathcal{C}^{(k)}$ στην παραπάνω ανάλυση πρέπει να είναι μετρήσιμα και πρέπει να σχηματίζουν έναν διαχωρισμό του $\mathbb{R}^d$.

Βλέπε επίσης: συνάρτηση, μετρήσιμο, δείκτρια συνάρτηση, ολοκλήρωμα Lebesgue.

απόκλιση Bregman TBC.

απόκλιση Kullback–Leibler (απόκλιση KL) Η απόκλιση KL (Kullback–

Leibler divergence - KL divergence) είναι ένα ποσοτικό μέτρο του πόσο διαφορετική είναι μία κατανομή πιθανότητας $\mathbb{P}^{(1)}$ από μία άλλη κατανομή πιθανότητας $\mathbb{P}^{(2)}$, η οποία ορίζεται στον ίδιο χώρο πιθανοτήτων [32]. Η απόκλιση KL $D^{(\text{KL})}(\mathbb{P}^{(1)}, \mathbb{P}^{(2)})$ είναι καλά ορισμένη μόνο αν η $\mathbb{P}^{(1)}$ είναι απολύτως συνεχής ως προς την $\mathbb{P}^{(2)}$.

Ειδική περίπτωση: Αν οι $\mathbb{P}^{(1)}$ και $\mathbb{P}^{(2)}$ περιγράφονται από τις συναρτήσεις μάζας πιθανότητας $p^{(x)}(\cdot)$ και $p^{(y)}(\cdot)$ σε έναν δειγματικό χώρο Ω , τότε

$$D^{(\text{KL})}(p^{(x)}(\cdot), p^{(y)}(\cdot)) := \sum_{\omega \in \Omega} p^{(x)}(\omega) \log \frac{p^{(x)}(\omega)}{p^{(y)}(\omega)}.$$

Σε αυτό το διακριτό περιβάλλον, η απόκλιση KL συμπίπτει με την απόκλιση Bregman που παράγεται από τη συνάρτηση αρνητικής εντροπίας [33,

Ενότητα 4.3]

$$\phi(p) := \sum_{\omega \in \Omega} p^{(x)}(\omega) \log p^{(x)}(\omega).$$

Βλέπε επίσης: μέτρο, κατανομή πιθανότητας, χώρος πιθανοτήτων, συνεχής, συνάρτηση μάζας πιθανότητας, δειγματικός χώρος, απόκλιση Bregman, εντροπία, συνάρτηση.

απόκλιση Rényi Η απόκλιση Rényi μετράει την (αν)ομοιότητα μεταξύ δύο κατανομών πιθανοτήτων [34].


Βλέπε επίσης: κατανομή πιθανότητας.

απόσταση Η απόσταση (distance) μεταξύ δύο σημείων σε έναν μετρικό χώρο είναι η τιμή της μετρικής που αξιολογείται στα συγκεκριμένα σημεία [35].

Βλέπε επίσης: μετρικός χώρος, μετρική, Ευκλείδεια απόσταση.

αριθμήσιμο Ένα σύνολο ονομάζεται αριθμήσιμο (countable) αν τα στοιχεία του μπορούν να τεθούν σε ένα προς ένα αντιστοιχία με τους φυσικούς αριθμούς $\mathbb{N} = \{1, 2, 3, \dots\}$ ή με ένα πεπερασμένο υποσύνολο των $\mathbb{N}$ [22].

Ισοδύναμα, ένα σύνολο $\mathcal{A}$ είναι αριθμήσιμο αν υφίσταται μία αμφιμονοσήμαντη συνάρτηση $f : \mathcal{A} \rightarrow \mathbb{N}$.



Σχ. 7. Αμφιμονοσήμαντη συνάρτηση που αντιστοιχίζει τα στοιχεία ενός πεπερασμένου συνόλου $\mathcal{A}$ στους φυσικούς αριθμούς $\mathbb{N}$, γεγονός που συνεπάγεται ότι το $\mathcal{A}$ είναι αριθμήσιμο.

Τυπικά παραδείγματα περιλαμβάνουν το σύνολο των ακέραιων αριθμών $\mathbb{Z}$ και των ρητών αριθμών $\mathbb{Q}$. Αντίθετα, το σύνολο των πραγματικών αριθμών $\mathbb{R}$ δεν είναι αριθμήσιμο, που σημαίνει ότι δεν υφίσταται τέτοια ένα προς ένα αντιστοιχία με τους $\mathbb{N}$.

Βλέπε επίσης: αμφιμονοσήμαντη, συνάρτηση.

αριθμός συνθήκης Ο αριθμός συνθήκης (condition number) $\kappa(\mathbf{Q}) \geq 1$ ενός θετικά ορισμένου πίνακα $\mathbf{Q} \in \mathbb{R}^{d \times d}$ είναι ο λόγος α/β , όπου α και β δηλώνουν τη μεγαλύτερη και μικρότερη ιδιοτιμή του $\mathbf{Q}$, αντίστοιχα. Ο αριθμός συνθήκης είναι χρήσιμος για την ανάλυση μεθόδων μηχανικής μάθησης. Η υπολογιστική πολυπλοκότητα των μεθόδων με βάση την κλίση για γραμμική παλινδρόμηση εξαρτάται κρίσιμα από τον αριθμό συνθήκης του πίνακα $\mathbf{Q} = \mathbf{X}\mathbf{X}^T$, όπου $\mathbf{X}$ είναι ο πίνακας χαρακτηριστικών του

συνόλου εκπαίδευσης. Αυτές οι μέθοδοι συγκλίνουν ταχύτερα όταν ο αριθμός συνθήκης $\kappa(\mathbf{Q})$ είναι κοντά στο 1.

Βλέπε επίσης: πίνακας, ιδιοτιμή, μηχανική μάθηση, μέθοδος με βάση την κλίση, γραμμική παλινδρόμηση, πίνακας χαρακτηριστικών, σύνολο εκπαίδευσης.

αυστηρά κυρτή Μία συνάρτηση πραγματικής τιμής $f : \mathcal{U} \rightarrow \mathbb{R}$ με κυρτό πεδίο ορισμού $\mathcal{U} \subset \mathbb{R}^d$ είναι αυστηρά κυρτή (strictly convex) αν, για οποιαδήποτε δύο διαφορετικά $\mathbf{x}, \mathbf{y} \in \mathcal{U}$ και κάθε $\lambda \in (0, 1)$, ικανοποιεί [36, Ορισμός 3.1.1]

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) < \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

Επιπλέον, αν η f είναι παραγωγίσιμη, αυτή η συνθήκη είναι ισοδύναμη με

$$f(\mathbf{y}) > f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$$

για οποιοδήποτε $\mathbf{x} \neq \mathbf{y}$, κάτι που συνεπάγεται ότι η $f(\cdot)$ επιτρέπει έναν μοναδικό ελαχιστοποιητή σε οποιοδήποτε κυρτό υποσύνολο του πεδίου ορισμού της. Σε αντίθεση με τις ισχυρά κυρτές συναρτήσεις, οι αυστηρά κυρτές συναρτήσεις δεν απαιτούν ένα ομοιόμορφο τετραγωνικό κάτω φράγμα.

Βλέπε επίσης: συνάρτηση, κυρτό, πεδίο ορισμού, παραγωγίσιμη, ισχυρά κυρτή.

αυτοκωδικοποιητής αποθρομβοποίησης TBC.

βαθμός κόμβου Ο βαθμός $d^{(i)}$ ενός κόμβου $i \in \mathcal{V}$ (node degree) σε έναν μη

κατευθυνόμενο γράφο είναι ο αριθμός των γειτόνων του, δηλαδή $d^{(i)} := |\mathcal{N}^{(i)}|$. Για έναν σταθμισμένο μη κατευθυνόμενο γράφο $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$, μπορούμε εναλλακτικά να ορίσουμε τον (σταθμισμένο) βαθμό κόμβου ως το άθροισμα των βαρών όλων των ακμών που συνδέονται με τον κόμβο i , δηλαδή $d^{(i)} = \sum_{i' \in \mathcal{V}} A_{i,i'}$ [37].

Βλέπε επίσης: μη κατευθυνόμενος γράφος, γείτονας, συνδεδεμένος, μέσος βαθμός κόμβου.

βάση Μία βάση (basis) ενός διανυσματικού χώρου πεπερασμένης διάστασης $\mathcal{V}$ είναι ένα σύνολο γραμμικά ανεξάρτητων διανυσμάτων $\mathcal{B} = \{\mathbf{b}^{(1)}, \dots, \mathbf{b}^{(d)}\} \subseteq \mathcal{V}$ έτσι ώστε οποιοδήποτε διάνυσμα $\mathbf{v} \in \mathcal{V}$ μπορεί να εκφραστεί ως ένας γραμμικός συνδυασμός των διανυσμάτων της βάσης $\mathbf{b}^{(1)}, \dots, \mathbf{b}^{(d)}$, δηλαδή

$$\mathbf{v} = \sum_{j=1}^d \alpha_j \mathbf{b}^{(j)} \quad \text{για κάποιους } \alpha_1, \dots, \alpha_d.$$

Οι βαθμωτοί $\alpha_1, \dots, \alpha_d$ μπορούν να θεωρηθούν ως οι συντεταγμένες του $\mathbf{v}$ ως προς τη βάση $\mathcal{B}$. Οποιαδήποτε βάση του $\mathcal{V}$ έχει τον ίδιο αριθμό d στοιχείων, ο οποίος είναι η διάσταση του $\mathcal{V}$.

Βλέπε επίσης: διανυσματικός χώρος, γραμμικά ανεξάρτητο, διάνυσμα, διάσταση.

βελτιστοποίηση Βλέπε κυρτή βελτιστοποίηση, μέθοδος βελτιστοποίησης, πρόβλημα βελτιστοποίησης.

βήμα κλίσης TBC.

γεγονός Θεωρούμε μία τυχαία μεταβλητή $\mathbf{x}$, ορισμένη σε κάποιον χώρο πιθανοτήτων $\mathcal{P}$, η οποία παίρνει τιμές σε έναν μετρήσιμο χώρο $\mathcal{X}$. Ένα γε-

γονός (event) $\mathcal{A} \subseteq \mathcal{X}$ είναι ένα υποσύνολο του $\mathcal{X}$ έτσι ώστε η πιθανότητα $\mathbb{P}(\mathbf{x} \in \mathcal{A})$ είναι καλά ορισμένη. Με άλλα λόγια, η προεικόνα $\mathbf{x}^{-1}(\mathcal{A})$ ενός γεγονότος ανήκει στην υποκείμενη σ -άλγεβρα, δηλαδή η προεικόνα είναι ένα μετρήσιμο υποσύνολο του δειγματικού χώρου [1], [6], [18]. Σε γενικές γραμμές, ένα γεγονός αναπαριστά ένα σύνολο πιθανών εκβάσεων κάποιας διαδικασίας. Ένα παράδειγμα μίας τέτοιας διαδικασίας θα μπορούσε επίσης να είναι η θεραπευτική αγωγή ενός ασθενή υγειονομικής περίθαλψης.

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μετρήσιμο, πιθανότητα, προεικόνα, σ -άλγεβρα, δειγματικός χώρος, έμβαση, σημείο δεδομένων, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, πιθανοτικό μοντέλο.

γειτονιά Θεωρούμε κάποιον μετρικό χώρο $\mathcal{X}$ με μία μετρική $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$. Η γειτονιά (neighborhood) ενός σημείου $\mathbf{x} \in \mathcal{X}$ είναι το σύνολο άλλων σημείων που έχουν μία επαρκώς μικρή απόσταση από το $\mathbf{x}$. Για παράδειγμα, η ϵ -γειτονιά του $\mathbf{x}$ ορίζεται ως

$$\{\mathbf{x}' \in \mathcal{X} : d(\mathbf{x}, \mathbf{x}') \leq \epsilon\}.$$

Αν ο $\mathcal{X}$ είναι ένας μη κατευθυνόμενος γράφος, ο οποίος αποτελεί μία ειδική περίπτωση μετρικού χώρου, η γειτονιά ενός κόμβου $i \in \mathcal{V}$ είναι το σύνολο των γειτόνων του.

Βλέπε επίσης: μετρικός χώρος, μετρική, απόσταση, μη κατευθυνόμενος γράφος, γείτονας.

γεωμετρική διάμεσος TBC.

Γκαουσιανή Βλέπε Γκαουσιανή τυχαία μεταβλητή.

Γκαουσιανή διαδικασία TBC.

Γκαουσιανή τυχαία μεταβλητή TBC.

γραμμικά ανεξάρτητο Ένα υποσύνολο $\{\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)}\} \in \mathcal{V}$ ενός διανυσματικού χώρου είναι γραμμικά ανεξάρτητο (linearly independent) αν δεν υπάρχει μη τετριμμένος γραμμικός συνδυασμός αυτών των διανυσμάτων που να ισούται με το μηδενικό διάνυσμα [30]. Με άλλα λόγια,

$$\sum_{j=1}^d \alpha_j \mathbf{a}^{(j)} = \mathbf{0} \quad \text{συνεπάγεται} \quad \alpha_1 = \alpha_2 = \dots = \alpha_d = 0.$$

Βλέπε επίσης: διανυσματικός χώρος, διάνυσμα, διάσταση, βάση, γραμμικά εξαρτημένο.

γραμμικά εξαρτημένο Ένα υποσύνολο $\{\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)}\} \in \mathcal{V}$ ενός διανυσματικού χώρου $\mathcal{V}$ πάνω από ένα σώμα $\mathbb{F}$ είναι γραμμικά εξαρτημένο (linearly dependent) αν δεν είναι γραμμικά ανεξάρτητο. Αυτό συμβαίνει αν υφίσταται ένα σύνολο βαθμωτών $\alpha_1, \dots, \alpha_d \in \mathbb{F}$, όχι όλοι ίσοι με μηδέν, τέτοιο ώστε

$$\sum_{j=1}^d \alpha_j \mathbf{a}^{(j)} = \mathbf{0}.$$

Διαισθητικά, αυτό σημαίνει ότι τουλάχιστον ένα διάνυσμα του συνόλου μπορεί να εκφραστεί ως ένας (μη τετριμμένος) γραμμικός συνδυασμός των υπολοίπων.

Βλέπε επίσης: διανυσματικός χώρος, σώμα, γραμμικά ανεξάρτητο, διάνυ-

σμα.

γραμμική απεικόνιση Μία γραμμική απεικόνιση (linear map) $f : \mathbb{R}^d \rightarrow \mathbb{R}^m$ είναι μία συνάρτηση που ικανοποιεί την προσθετικότητα, δηλαδή $f(\mathbf{x} + \mathbf{y}) = f(\mathbf{x}) + f(\mathbf{y})$, και την ομοιογένεια, δηλαδή $f(c\mathbf{x}) = cf(\mathbf{x})$, για όλα τα διανύσματα $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$ και βαθμωτούς $c \in \mathbb{R}$. Συγκεκριμένα, $f(\mathbf{0}) = \mathbf{0}$. Οποιαδήποτε γραμμική απεικόνιση μπορεί να αναπαρασταθεί ως πολλαπλασιασμός πίνακα $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$ για κάποιον πίνακα $\mathbf{A} \in \mathbb{R}^{m \times n}$. Η συλλογή των γραμμικών απεικονίσεων πραγματικών τιμών (όπου $m = 1$), για μία δεδομένη διάσταση d , αποτελεί ένα γραμμικό μοντέλο. Η έννοια της γραμμικής απεικόνισης μπορεί να γενικευτεί από το πεδίο ορισμού $\mathbb{R}^d$ και το πεδίο τιμών $\mathbb{R}^m$ σε αυθαίρετους διανυσματικούς χώρους. Βλέπε επίσης: απεικόνιση, συνάρτηση, διάνυσμα, πίνακας, γραμμικό μοντέλο, πεδίο ορισμού, co-domain, διανυσματικός χώρος.

γραμμικός τελεστής Ένας γραμμικός τελεστής (linear operator) είναι ένας τελεστής $\mathcal{F}$ του οποίου το πεδίο ορισμού και το πεδίο τιμών είναι διανυσματικοί χώροι και ο οποίος ικανοποιεί [38]


$$\mathcal{F}(\alpha\mathbf{w} + \beta\mathbf{w}') = \alpha\mathcal{F}(\mathbf{w}) + \beta\mathcal{F}(\mathbf{w}')$$

για όλα τα $\mathbf{w}, \mathbf{w}'$ στο πεδίο ορισμού και όλους τους βαθμωτούς α, β .

Βλέπε επίσης: τελεστής, πεδίο ορισμού, co-domain, διανυσματικός χώρος, πίνακας.

γράφος Ένας γράφος (graph) $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ αποτελείται από ένα σύνολο κόμβων $\mathcal{V}$ και ένα σύνολο ακμών $\mathcal{E}$. Κάθε ακμή $e \in \mathcal{E}$ χαρακτηρίζεται από

τους κόμβους με τους οποίους συνδέεται και από τον ακριβή τρόπο της σύνδεσης. Για παράδειγμα, μία ακμή ενός κατευθυνόμενου γράφου ξεκινάει από έναν κόμβο και καταλήγει σε έναν άλλον κόμβο. Μία ακμή ενός μη κατευθυνόμενου γράφου συνδέει δύο κόμβους χωρίς καμία έννοια κατεύθυνσης [39], [40]. Στη θεωρία, μπορούν επίσης να υπάρχουν αρκετές (παράλληλες) ακμές που συνδέονται με τις ίδιους κόμβους με τον ίδιο τρόπο [40]. Επιπλέον, οι ακμές μπορεί να συνδέουν έναν κόμβο με τον εαυτό του, οδηγώντας στους λεγόμενους αυτοβρόχους [39]. Ένας απλός μη κατευθυνόμενος γράφος δεν περιέχει παράλληλες ακμές ούτε αυτοβρόχους [41]. Κάθε ακμή $e \in \mathcal{E}$ ενός απλού μη κατευθυνόμενου γράφου μπορεί να ταυτοποιηθεί με ένα σύνολο δύο κόμβων i, i' .



Σχ. 8. Απλός μη κατευθυνόμενος γράφος με τέσσερις κόμβους $\mathcal{V} = \{i_1, i_2, i_3, i_4\}$ και τέσσερις ακμές $\mathcal{E} = \{\{i_1, i_2\}, \{i_2, i_3\}, \{i_3, i_1\}, \{i_2, i_4\}\}$.


Οι σταθμισμένοι γράφοι αποδίδουν μία αριθμητική τιμή A_e , που αναφέρεται ως βάρος ακμής, σε κάθε ακμή $e \in \mathcal{E}$.

Βλέπε επίσης: συνδεδεμένος, κατευθυνόμενος γράφος, μη κατευθυνόμενος γράφος, σταθμισμένος γράφος, βάρος ακμής.

γράφος Erdős–Rényi Ένας γράφος Erdős–Rényi (Erdős–Rényi graph - ER graph) [42], [43] είναι ένα πιθανοτικό μοντέλο για γράφους που ορίζονται πάνω σε ένα δεδομένο σύνολο κόμβων $i = 1, \dots, n$. Ένας

τρόπος ορισμού του γράφου Erdős–Rényi είναι μέσω της συλλογής ανεξάρτητων και ταυτόσημα κατανεμημένων δυαδικών τυχαίων μεταβλητών $b^{\{i,i'\}} \in \{0,1\}$ για κάθε ζεύγος διαφορετικών κόμβων i, i' . Μία συγκεκριμένη πραγμάτωση ενός γράφου Erdős–Rényi περιέχει μία ακμή $\{i, i'\}$ αν και μόνο αν $b^{\{i,i'\}} = 1$. Ο γράφος Erdős–Rényi παραμετροποιείται από τον αριθμό n κόμβων και την πιθανότητα $\mathbb{P}(b^{\{i,i'\}} = 1)$.
 Βλέπε επίσης: γράφος, πιθανοτικό μοντέλο, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, πραγμάτωση, πιθανότητα.

δείγμα Στο πλαίσιο της μηχανικής μάθησης, ένα δείγμα (sample) είναι μία πεπερασμένη ακολουθία (μήκους m) σημείων δεδομένων $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$. Ο αριθμός m ονομάζεται μέγεθος δείγματος. Οι μέθοδοι που βασίζονται στην ελαχιστοποίηση εμπειρικής διακινδύνευσης χρησιμοποιούν ένα δείγμα για να εκπαιδεύσουν ένα μοντέλο (ή να μάθουν μία υπόθεση) ελαχιστοποιώντας τη μέση απώλεια (δηλαδή την εμπειρική διακινδύνευση) πάνω σε αυτό το δείγμα. Εφόσον ένα δείγμα ορίζεται ως μία ακολουθία, το ίδιο σημείο δεδομένων μπορεί να εμφανιστεί περισσότερες από μία φορές. Αντίθετα, ορισμένοι συγγραφείς στη στατιστική ορίζουν ένα δείγμα ως ένα σύνολο σημείων δεδομένων, οπότε δεν επιτρέπονται διπλότυπα [44], [45]. Αυτές οι δύο θέσεις (δηλαδή ακολουθία έναντι συνόλου) μπορούν να συμφιλιωθούν αν θεωρήσουμε ένα δείγμα ως μία ακολουθία ζευγών χαρακτηριστικών–ετικέτας $(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})$. Το r -οστό ζεύγος αποτελείται από τα χαρακτηριστικά $\mathbf{x}^{(r)}$ και την ετικέτα $y^{(r)}$ ενός μοναδικού υποκείμενου σημείου δεδομένων $\tilde{\mathbf{z}}^{(r)}$. Ενώ τα υποκείμενα σημεία δεδομένων $\tilde{\mathbf{z}}^{(1)}, \dots, \tilde{\mathbf{z}}^{(m)}$ είναι μοναδικά, κάποια από αυτά μπορεί να έχουν ταυτόσημα χαρακτηριστικά και ετικέτες.



Σχ. 9. Δείγμα που θεωρείται ως μία πεπερασμένη ακολουθία. Κάθε στοιχείο αυτού του δείγματος αποτελείται από το διάνυσμα χαρακτηριστικών και την ετικέτα ενός σημείου δεδομένων από έναν υποκείμενο πληθυσμό. Το ίδιο σημείο δεδομένων μπορεί να εμφανιστεί περισσότερες από μία φορές στο δείγμα.

Για την ανάλυση μεθόδων μηχανικής μάθησης, είναι σύνηθες να ερμηνεύεται ένα δείγμα (ή η παραγωγή του) ως η πραγμάτωση μίας στοχαστικής διαδικασίας με δείκτες $\{1, \dots, m\}$. Μία ευρέως χρησιμοποιούμενη παραδοχή είναι η παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, όπου τα στοιχεία δείγματος $(\mathbf{x}^{(r)}, y^{(r)})$, για $r = 1, \dots, m$, είναι ανεξάρτητες και ταυτόσημα κατανομημένες τυχαίες μεταβλητές με κοινή κατανομή πιθανότητας.

Βλέπε επίσης: μηχανική μάθηση, ακολουθία, σημείο δεδομένων, μέγεθος δείγματος, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μοντέλο, υπόθεση, απώλεια, εμπειρική διακινδύνευση, χαρακτηριστικό, ετικέτα, διάνυσμα χαρακτηριστικών, πραγμάτωση, στοχαστική διαδικασία, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, σύνολο δεδομένων.

δείκτρια συνάρτηση Θεωρούμε κάποια διαδικασία που μπορεί να οδηγήσει σε διαφορετικές πιθανές εκβάσεις (π.χ. επιβίωση ή θάνατος ενός ασθενή). Μία τέτοια διαδικασία μπορεί να μοντελοποιηθεί ως ένα τυχαίο πείραμα με δειγματικό χώρο Ω που περιέχει όλες τις πιθανές εκβάσεις. Η δείκτρια συνάρτηση (indicator function) $\mathbb{I}_{\mathcal{A}}$ ενός γεγονότος $\mathcal{A} \subseteq \Omega$ είναι μία συνάρτηση που ορίζεται ως [7]

$$\mathbb{I}_{\mathcal{A}}(\omega) = \begin{cases} 1 & \text{if } \omega \in \mathcal{A}, \\ 0 & \text{if } \omega \notin \mathcal{A}. \end{cases}$$

Η έννοια της δείκτριας συνάρτησης δεν περιορίζεται στις εκβάσεις ενός τυχαίου πειράματος. Στην ουσία, είναι απλώς ένας βασικός τρόπος αναπαράστασης ενός συνόλου $\mathcal{A}$ μέσω μίας συνάρτησης $\mathbb{I}_{\mathcal{A}}$ [36]. Για έναν χώρο πιθανοτήτων $(\Omega, \Sigma, \mathbb{P}(\cdot))$ and $\mathcal{A} \in \Sigma$, η δείκτρια συνάρτηση $\mathbb{I}_{\mathcal{A}}$ είναι μία τυχαία μεταβλητή και ισχύει ότι $\mathbb{E}\{\mathbb{I}_{\mathcal{A}}\} = \mathbb{P}(\mathcal{A})$.

Βλέπε επίσης: έκβαση, τυχαίο πείραμα, δειγματικός χώρος, συνάρτηση, γεγονός, χώρος πιθανοτήτων, τυχαία μεταβλητή.

διαγωνοποιήσιμος Ένας τετραγωνικός πίνακας $\mathbf{A} \in \mathbb{C}^{d \times d}$ ονομάζεται διαγωνοποιήσιμος (diagonalizable) αν είναι όμοιος με έναν διαγώνιο πίνακα [46], [29]. Τυπικά, ο $\mathbf{A}$ είναι διαγωνοποιήσιμος αν υφίσταται ένας μη αντιστρέψιμος πίνακας $\mathbf{P} \in \mathbb{C}^{d \times d}$ τέτοιος ώστε

$$\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1},$$

όπου $\mathbf{D} \in \mathbb{C}^{d \times d}$ είναι ένας διαγώνιος πίνακας του οποίου οι καταχωρίσεις

της κύριας διαγωνίου είναι οι ιδιοτιμές του $\mathbf{A}$. Ένας πίνακας $\mathbf{A} \in \mathbb{R}^{d \times d}$ είναι διαγωνοποιήσιμος αν και μόνο αν έχει d γραμμικά ανεξάρτητα ιδιοδιανύσματα [46].

Βλέπε επίσης: πίνακας, αντιστρέψιμος, ιδιοτιμή, γραμμικά ανεξάρτητο, ιδιοδιάνυσμα, ανάλυση ιδιοτιμών.

διακριτή τυχαία μεταβλητή Μία τυχαία μεταβλητή, δηλαδή μία συνάρτηση που αντιστοιχίζει τις εκβάσεις ενός τυχαίου πειράματος σε στοιχεία ενός μετρήσιμου χώρου $\mathcal{X}$, αναφέρεται ως διακριτή (discrete random variable - discrete RV) αν ο χώρος τιμών της $\mathcal{X}$ είναι αριθμήσιμος [6].

Βλέπε επίσης: τυχαία μεταβλητή, συνάρτηση, έκβαση, τυχαίο πείραμα, μετρήσιμο, αριθμήσιμο, πιθανότητα, κατανομή πιθανότητας.

διακύμανση Η διακύμανση (variance) μίας τυχαίας μεταβλητής πραγματικής τιμής x ορίζεται ως η προσδοκία $\mathbb{E}\{(x - \mathbb{E}\{x\})^2\}$ της τετραγωνικής διαφοράς μεταξύ της x και της προσδοκίας της $\mathbb{E}\{x\}$. Επεκτείνουμε αυτόν τον ορισμό σε τυχαίες μεταβλητές διανυσματικής τιμής $\mathbf{x}$ ως $\mathbb{E}\{\|\mathbf{x} - \mathbb{E}\{\mathbf{x}\}\|_2^2\} = \text{tr}(\mathbf{C}^{(\mathbf{x})})$, δηλαδή το άθροισμα των διακυμάνσεων κάθε καταχώρισης της $\mathbf{x}$, η οποία μπορεί να γραφεί συμπαγώς ως το ίχνος του πίνακα συνδιακύμανσης $\mathbf{C}^{(\mathbf{x})}$ της $\mathbf{x}$.

Βλέπε επίσης: τυχαία μεταβλητή, προσδοκία, διάνυσμα, ίχνος, πίνακας συνδιακύμανσης.

διακύμανση δείγματος Θεωρούμε ένα σύνολο δεδομένων $\mathcal{D}$ που αποτελείται από σημεία δεδομένων που χαρακτηρίζονται από βαθμωτές τιμές $y^{(1)}, \dots, y^{(m)} \in \mathbb{R}$. Η διακύμανση δείγματος (sample variance) του $\mathcal{D}$ ορίζεται ως η διακύμανση ως προς την εμπειρική κατανομή $\mathbb{P}^{(\mathcal{D})}$ που ε-

πάγεται από το $\mathcal{D}$. Δίνεται ρητά από

$$\frac{1}{m} \sum_{r=1}^m (y^{(r)} - \hat{y})^2,$$


όπου $\hat{y}$ είναι η μέση τιμή δείγματος του $\mathcal{D}$. Η διακύμανση δείγματος αποτελεί μία ειδική περίπτωση του πίνακα συνδιακύμανσης δείγματος όταν κάθε σημείο δεδομένων χαρακτηρίζεται από μία μοναδική αριθμητική τιμή. Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, δείγμα, διακύμανση, εμπειρική κατανομή, μέση τιμή δείγματος, πίνακας συνδιακύμανσης δείγματος.

διάμεσος TBC.

διάνυσμα Ένα διάνυσμα (vector) είναι ένα στοιχείο ενός διανυσματικού χώρου. Στο πλαίσιο της μηχανικής μάθησης, ένα ιδιαίτερα σημαντικό παράδειγμα διανυσματικού χώρου είναι ο Ευκλείδειος χώρος $\mathbb{R}^d$, όπου $d \in \mathbb{N}$ είναι η (πεπερασμένη) διάσταση του χώρου. Ένα διάνυσμα $\mathbf{x} \in \mathbb{R}^d$ μπορεί να αναπαρασταθεί ως μία λίστα ή μονοδιάστατη (1-D) διάταξη πραγματικών αριθμών, δηλαδή $x_1, \dots, x_d$ με $x_j \in \mathbb{R}$ για $j = 1, \dots, d$. Η τιμή x_j είναι η j -οστή καταχώριση του διανύσματος $\mathbf{x}$. Μπορεί επίσης να είναι χρήσιμο να θεωρήσουμε ένα διάνυσμα $\mathbf{x} \in \mathbb{R}^d$ ως μία συνάρτηση που αντιστοιχίζει κάθε δείκτη $j \in \{1, \dots, d\}$ σε μία τιμή $x_j \in \mathbb{R}$, δηλαδή $\mathbf{x} : j \mapsto x_j$. Αυτή η προοπτική είναι ιδιαίτερα χρήσιμη για την μελέτη των μεθόδων πυρήνα. Βλέπε Σχ. 10 για τις δύο όψεις ενός διανύσματος.

2, -1, 3, 0, -2, 1

(a)




(b)

Σχ. 10. Δύο ισοδύναμες όψεις ενός διανύσματος $\mathbf{x} = (2, -1, 3, 0, -2, 1)^T \in \mathbb{R}^6$. (a) Ως μία αριθμητική διάταξη. (b) Ως μία απεικόνιση $j \mapsto x_j$, όπου $j \in \{1, \dots, 6\}$.

Βλέπε επίσης: διανυσματικός χώρος, μηχανική μάθηση, Ευκλείδειος χώρος, διάσταση, συνάρτηση, μέθοδος πυρήνα, απεικόνιση, βάση, πίνακας, γραμμική απεικόνιση.

διανυσματικός χώρος Ένας διανυσματικός χώρος (vector space) $\mathcal{V}$ (που ονομάζεται επίσης γραμμικός χώρος) είναι μία συλλογή στοιχείων, τα οποία ονομάζονται διανύσματα, μαζί με τις εξής δύο λειτουργίες (βλέπε επίσης Σχ. 11): 1) πρόσθεση (που δηλώνεται με $\mathbf{v} + \mathbf{w}$) δύο διανυσμάτων $\mathbf{v}, \mathbf{w}$, και 2) πολλαπλασιασμός (που δηλώνεται με $c \cdot \mathbf{v}$) ενός διανύσματος $\mathbf{v}$ με έναν βαθμωτό c που ανήκει σε κάποιο σώμα αριθμών (όπως οι πραγματικοί αριθμοί $\mathbb{R}$ ή οι μιγαδικοί αριθμοί $\mathbb{C}$). Η καθοριστική ιδιότητα ενός διανυσματικού χώρου είναι ότι είναι κλειστός υπό δύο συγκεκριμένες λειτουργίες. Πρώτον, αν $\mathbf{v}, \mathbf{w} \in \mathcal{V}$, τότε $\mathbf{v} + \mathbf{w} \in \mathcal{V}$. Δεύτερον, αν $\mathbf{v} \in \mathcal{V}$ και $c \in \mathbb{R}$, τότε $c\mathbf{v} \in \mathcal{V}$.




Σχ. 11. Διανυσματικός χώρος $\mathcal{V}$ είναι μία συλλογή διανυσμάτων, έτσι ώστε η κλιμακοθέτηση και η πρόσθεσή τους πάντα να αποφέρει ένα άλλο διάνυσμα στο $\mathcal{V}$.

Ένα σύννηθες παράδειγμα διανυσματικού χώρου είναι ο Ευκλείδειος χώρος $\mathbb{R}^n$, ο οποίος χρησιμοποιείται ευρέως στη μηχανική μάθηση για την αναπαράσταση συνόλων δεδομένων. Μπορούμε επίσης να χρησιμοποιήσουμε τον $\mathbb{R}^n$ για να αναπαραστήσουμε, είτε ακριβώς είτε προσεγγιστικά, τον χώρο υποθέσεων που χρησιμοποιείται από μία μέθοδο μηχανικής μάθησης. Ένα άλλο παράδειγμα διανυσματικού χώρου, ο οποίος σχετίζεται φυσικά με κάθε χώρο πιθανοτήτων $(\Omega, \mathcal{F}, \mathbb{P}(\cdot))$, είναι η συλλογή όλων των τυχαίων μεταβλητών πραγματικής τιμής $x : \Omega \rightarrow \mathbb{R}$ [1], [24].

Βλέπε επίσης: διάνυσμα, σώμα, Ευκλείδειος χώρος, μηχανική μάθηση, σύνολο δεδομένων, χώρος υποθέσεων, χώρος πιθανοτήτων, τυχαία μεταβλητή, γραμμικό μοντέλο, γραμμική απεικόνιση.

διάσταση Η διάσταση (dimension) $\dim \mathcal{A}$ ενός διανυσματικού χώρου $\mathcal{A}$ είναι η πληθικότητα οποιασδήποτε βάσης του $\mathcal{A}$ [30]. Αυστηρά μιλώντας, αυ-

τός ο ορισμός ισχύει μόνο για πεπερασμένης διάστασης διανυσματικούς χώρους, δηλαδή εκείνους που διαθέτουν μία πεπερασμένη βάση.



Σχ. 12. Τρεις βάσεις, $\{\mathbf{e}^{(1)}, \mathbf{e}^{(2)}\}$, $\{\mathbf{u}^{(1)}, \mathbf{u}^{(2)}\}$, $\{\mathbf{w}^{(1)}, \mathbf{w}^{(2)}\}$, για τον διανυσματικό χώρο $\mathbb{R}^2$.

Για τέτοιους χώρους, όλες οι βάσεις έχουν την ίδια πληθικότητα, η οποία είναι η διάσταση του χώρου [29, Κεφ. 2].

Βλέπε επίσης: διανυσματικός χώρος, βάση.

διαφορική εντροπία Για μία τυχαία μεταβλητή $\mathbf{x} \in \mathbb{R}^d$ με μία συνάρτηση πυκνότητας πιθανότητας $p^{(\mathbf{x})}(\cdot)$, η διαφορική εντροπία (differential entropy) ορίζεται ως [32]

$$h(\mathbf{x}) := - \int_{\mathbf{x}' \in \mathbb{R}^d} \log p(\mathbf{x}') p^{(\mathbf{x})}(\mathbf{x}') d\mathbf{x}'.$$

Η διαφορική εντροπία μπορεί να είναι αρνητική και στερείται κάποιων ιδιοτήτων της εντροπίας για τυχαίες μεταβλητές διακριτών τιμών, όπως η αναλλοιωσιμότητα υπό μία αλλαγή μεταβλητών [32]. Μεταξύ όλων των τυχαίων μεταβλητών με μία δεδομένη μέση τιμή $\boldsymbol{\mu}$ και πίνακα συνδιακύμανσης $\mathbf{C}$, η $h(\mathbf{x})$ μεγιστοποιείται από $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{C})$.

Βλέπε επίσης: τυχαία μεταβλητή, συνάρτηση πυκνότητας πιθανότητας, εντροπία, μέση τιμή, πίνακας συνδιακύμανσης, αβεβαιότητα, πιθανοτικό μοντέλο.

δομικό αιτιώδες μοντέλο Ένα δομικό αιτιώδες μοντέλο (structural causal model - SCM) είναι ένα μαθηματικό μοντέλο σχέσεων αιτίου-αποτελέσματος που αποτελούν τη βάση μίας διαδικασίας παραγωγής δεδομένων [11].
Βλέπε επίσης: μοντέλο, δεδομένα, αιτιότητα.

δυϊκή νόρμα Κάθε νόρμα $\|\cdot\|$ που ορίζεται σε έναν Ευκλείδειο χώρο $\mathbb{R}^d$ έχει μία σχετική δυϊκή νόρμα, η οποία δηλώνεται με $\|\cdot\|_*$ και ορίζεται ως $\|\mathbf{y}\|_* := \sup_{\|\mathbf{x}\| \leq 1} \mathbf{y}^T \mathbf{x}$. Η δυϊκή νόρμα μετράει το μεγαλύτερο δυνατό εσωτερικό γινόμενο μεταξύ του $\mathbf{y}$ και οποιουδήποτε διανύσματος στη μοναδιαία μπάλα της αρχικής νόρμας. Για περισσότερες λεπτομέρειες, βλέπε [36, Ενότητα A.1.6].

Βλέπε επίσης: νόρμα, Ευκλείδειος χώρος, εσωτερικό γινόμενο, διάνυσμα.

δυϊκή συνάρτηση Lagrange TBC.

δυϊκό πρόβλημα TBC.

έκβαση Έκβαση (outcome) είναι ένα πιθανό αποτέλεσμα μίας φυσικής διαδικασίας. Μία τέτοια διαδικασία θα μπορούσε να είναι η παρατήρηση ενός φυσικού φαινομένου, ένας υπολογισμός που εκτελείται από έναν αλγόριθμο, ή ένα τυχαίο πείραμα [6].

Βλέπε επίσης: αλγόριθμος, τυχαίο πείραμα, δειγματικός χώρος.

εκθετική οικογένεια TBC.

εκτιμητής Τα συστήματα μηχανικής μάθησης αναλύονται συχνά χρησιμοποιώντας ένα πιθανοτικό μοντέλο $\mathbb{P}(\mathbf{x}; \mathbf{w})$ για την παραγωγή δεδομένων $\mathbf{x}$ [8]. Η πραγματική τιμή των παραμέτρων του μοντέλου $\mathbf{w}$ είναι συνήθως άγνωστη και χρειάζεται να εκτιμηθεί. Ένας εκτιμητής (estimator) είναι μία μετρήσιμη συνάρτηση $h(\mathbf{x})$ που διαβάζει τα δεδομένα $\mathbf{x}$ και παραδίδει μία εκτίμηση (ή προσέγγιση) $\hat{\mathbf{w}} = h(\mathbf{x})$ της πραγματικής τιμής των παραμέτρων του μοντέλου $\mathbf{w}$ [20], [21].

Βλέπε επίσης: σύστημα μηχανικής μάθησης, πιθανοτικό μοντέλο, δεδομένα, παράμετρος μοντέλου, μετρήσιμο, συνάρτηση.

εκ των προτέρων κατανομή TBC.

εκ των υστέρων κατανομή TBC.

εκ των υστέρων (πρόβλεψη) TBC.

ελάχιστο Δεδομένου ενός συνόλου πραγματικών αριθμών, το ελάχιστο (minimum) είναι ο μικρότερος από αυτούς τους αριθμούς. Σημείωση ότι για κάποια σύνολα, όπως το σύνολο αρνητικών πραγματικών αριθμών, το ελάχιστο δεν υφίσταται.

Βλέπε επίσης: μέγιστο.

εμπειρική κατανομή TBC.

εντροπία Η εντροπία (entropy) ποσοτικοποιεί την αβεβαιότητα ή τη μη προβλεψιμότητα που σχετίζεται με μία τυχαία μεταβλητή [32]. Για μία διακριτή τυχαία μεταβλητή x που παίρνει τιμές σε ένα πεπερασμένο σύνολο $\mathcal{S} = \{x_1, \dots, x_k\}$ με μία συνάρτηση μάζας πιθανότητας $p^{(x)}(x_c)$ ($=$

$\mathbb{P}(x = x_c)$), η εντροπία ορίζεται ως [32]

$$H(x) := - \sum_{c=1}^k p^{(x)}(x_c) \log p^{(x)}(x_c).$$

Για ένα δεδομένο σύνολο τιμών $\mathcal{S}$, η εντροπία μεγιστοποιείται για μία ομοιόμορφα καταταμημένη τυχαία μεταβλητή, όπου $p^{(x)}(x_c) = 1/k$. Η ελάχιστη εντροπία, η οποία είναι μηδέν, προκύπτει όταν $p^{(x)}(x_c) = 1$ για κάποια $x_c \in \mathcal{S}$. Η διαφορική εντροπία γενικεύει την έννοια της εντροπίας από διακριτές τυχαίες μεταβλητές σε συνεχείς τυχαίες μεταβλητές.

Βλέπε επίσης: αβεβαιότητα, τυχαία μεταβλητή, διακριτή τυχαία μεταβλητή, συνάρτηση μάζας πιθανότητας, διαφορική εντροπία, συνεχής, πιθανοτικό μοντέλο.

εξίσωση σταθερού σημείου Μία εξίσωση σταθερού σημείου (fixed-point equation) είναι μία εξίσωση της ακόλουθης μορφής:

$$\mathbf{w} = \mathcal{F}(\mathbf{w}),$$

όπου $\mathcal{F} : \mathcal{H} \rightarrow \mathcal{H}$ είναι ένας τελεστής ορισμένος σε έναν χώρο Hilbert $\mathcal{H}$. Η λύση μίας εξίσωσης σταθερού σημείου ισοδυναμεί με την εύρεση των σταθερών σημείων του $\mathcal{F}$. Πολλά προβλήματα βελτιστοποίησης, συμπεριλαμβανομένων περιπτώσεων ελαχιστοποίησης εμπειρικής διακινδύνευσης, μπορούν να διατυπωθούν υπό αυτή τη μορφή. Για παράδειγμα, η ελαχιστοποίηση μίας λείας κυρτής συνάρτησης f είναι ισοδύναμη με τη λύση

της ακόλουθης εξίσωσης σταθερού σημείου:

$$\mathbf{w} = \mathcal{F}\mathbf{w} \quad \text{με } \mathcal{F} : \mathbf{w} \mapsto \mathbf{w} - \eta \nabla f(\mathbf{w}).$$

Εδώ, το $\eta > 0$ μπορεί να επιλεγθεί ελεύθερα. Η παραπάνω εξίσωση σταθερού σημείου δεν είναι παρά η συνθήκη μηδενικής κλίσης για τον ελαχιστοποιητή της f [36]. Ομοίως, μπορεί κανείς να αναδιατυπώσει τις συνθήκες βελτιστότητας (δηλαδή τις συνθήκες KKT) προβλημάτων βελτιστοποίησης με περιορισμούς ως μία εξίσωση σταθερού σημείου [36], [47].

Βλέπε επίσης: τελεστής, χώρος Hilbert, σταθερό σημείο, πρόβλημα βελτιστοποίησης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, λεία, κυρτό, συνάρτηση, συνθήκη μηδενικής κλίσης, συνθήκες Karush–Kuhn–Tucker (συνθήκες KKT).

επανάληψη σταθερού σημείου TBC.

επαυξημένος κατά Lagrange TBC.

επιγράφος TBC.

Ερμιτιανός Ένας τετραγωνικός πίνακας $\mathbf{A} \in \mathbb{C}^{d \times d}$ είναι Ερμιτιανός (Hermitian) αν συμπίπτει με τον συζυγή ανάστροφό του, δηλαδή $\mathbf{A} = \mathbf{A}^H$. Προφανώς, ένας Ερμιτιανός πίνακας είναι επίσης ένας κανονικός πίνακας. Βλέπε επίσης: πίνακας, συζυγής ανάστροφος, κανονικός πίνακας.

Εσσιανός Θεωρούμε μία συνάρτηση $f : \mathbb{R}^d \rightarrow \mathbb{R}$ για την οποία οι μερικές παράγωγοι δεύτερης τάξης υφίστανται στο $\mathbf{x}'$. Τότε, ο Εσσιανός (Hessian) $\nabla^2 f(\mathbf{x}')$ της f στο $\mathbf{x}$ ορίζεται ως ο πίνακας μερικών παραγώγων


δεύτερης τάξης της f στο $\mathbf{x}'$, δηλαδή

$$\nabla^2 f(\mathbf{x}') = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_d} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \frac{\partial^2 f}{\partial x_d \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_d^2} \end{pmatrix}.$$

Αν οι μερικές παράγωγοι δεύτερης τάξης είναι συνεχείς σε μία γειτονιά γύρω από το $\mathbf{x}'$, τότε ο Εσσιανός είναι ένας συμμετρικός πίνακας, δηλαδή $\partial^2 f / \partial x_j \partial x_{j'} = \partial^2 f / \partial x_{j'} \partial x_j$ για όλους τους j, j' [2]. Αν επιπλέον η f είναι κυρτή, τότε ο Εσσιανός είναι ένας θετικά ημιορισμένος πίνακας [36]. Ο Εσσιανός $\nabla^2 f(\mathbf{x}')$ μπορεί να χρησιμοποιηθεί για τον υπολογισμό μίας τετραγωνικής συνάρτησης

$$q(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}')^T \underbrace{\nabla^2 f(\mathbf{x}')}_{\text{Εσσιανός}}(\mathbf{x} - \mathbf{x}') + (\mathbf{x} - \mathbf{x}')^T \underbrace{\nabla f(\mathbf{x}')}_{\text{κλίση}} + f(\mathbf{x}')$$

που προσεγγίζει τοπικά την f γύρω από το $\mathbf{x}'$ (βλέπε επίσης Σχ. 13).



Σχ. 13. Συνάρτηση $f(\mathbf{x})$, επαρκώς λεία σε ένα σημείο $\mathbf{x}'$, που προσεγγίζεται τοπικά από μία τετραγωνική συνάρτηση $q(\mathbf{x})$, η οποία παρέχει μία ακριβέστερη προσέγγιση σε σύγκριση με μία γραμμική συνάρτηση $g(\mathbf{x})$.

Βλέπε επίσης: συνάρτηση, μερική παράγωγος, πίνακας, συνεχής, γειτονιά,

συμμετρικός πίνακας, κυρτό, θετικά ημιορισμένος, τετραγωνική συνάρτηση, κλίση, λεία.

εσωτερικό γινόμενο TBC.

Ευκλείδεια απόσταση Η Ευκλείδεια απόσταση (Euclidean distance) μεταξύ δύο διανυσμάτων $\mathbf{w}, \mathbf{w}' \in \mathbb{R}^d$ είναι η Ευκλείδεια νόρμα $\|\mathbf{w} - \mathbf{w}'\|_2$ της διαφοράς $\mathbf{w} - \mathbf{w}'$.

Βλέπε επίσης: απόσταση, διάνυσμα, Ευκλείδεια νόρμα, Ευκλείδειος χώρος.

Ευκλείδεια νόρμα Η Ευκλείδεια νόρμα (Euclidean norm) (ή 2-νόρμα, ή ℓ_2 -νόρμα) $\|\mathbf{w}\|_2$ ενός διανύσματος $\mathbf{w} = (w_1, \dots, w_d) \in \mathbb{R}^d$ ορίζεται ως

$$\|\mathbf{w}\|_2 := \sqrt{\sum_{j=1}^d w_j^2}.$$

Η Ευκλείδεια νόρμα είναι διαφορετική από όλες τις νόρμες στον $\mathbb{R}^d$, υπό την έννοια ότι επάγεται από το εσωτερικό γινόμενο $\mathbf{w}^T \mathbf{v}$ [1], [36], [48].

Με άλλα λόγια, $\|\mathbf{w}\|_2 = \sqrt{\mathbf{w}^T \mathbf{w}}$.

Βλέπε επίσης: νόρμα, διάνυσμα, εσωτερικό γινόμενο, Ευκλείδειος χώρος.

Ευκλείδειος χώρος Ο Ευκλείδειος χώρος (Euclidean space) $\mathbb{R}^d$ διάστασης $d \in \mathbb{N}$ αποτελείται από διανύσματα $\mathbf{x} = (x_1, \dots, x_d)$, με d καταχωρίσεις πραγματικής τιμής $x_1, \dots, x_d \in \mathbb{R}$. Ένας τέτοιος Ευκλείδειος χώρος είναι εξοπλισμένος με μία γεωμετρική δομή που ορίζεται από το εσωτερικό γινόμενο $\mathbf{x}^T \mathbf{x}' = \sum_{j=1}^d x_j x'_j$ μεταξύ οποιωνδήποτε δύο διανυσμάτων $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^d$ [2].

Βλέπε επίσης: διάνυσμα, εσωτερικό γινόμενο.

ημιχώρος Βλέπε υπερεπίπεδο.

θετικά ημιορισμένος Ένας συμμετρικός πίνακας (πραγματικών τιμών) $\mathbf{Q} =$

$\mathbf{Q}^T \in \mathbb{R}^{d \times d}$ αναφέρεται ως θετικά ημιορισμένος (positive semi-definite - psd) αν $\mathbf{x}^T \mathbf{Q} \mathbf{x} \geq 0$ για κάθε διάνυσμα $\mathbf{x} \in \mathbb{R}^d$. Ένας θετικά ημιορισμένος πίνακας $\mathbf{Q}$ επιτρέπει μία φασματική ανάλυση με μη αρνητικές ιδιοτιμές $\lambda_1, \dots, \lambda_d \geq 0$ [29], [46]. Η έννοια του να είναι θετικά ημιορισμένος μπορεί να επεκταθεί από πίνακες σε συμμετρικές απεικονίσεις πυρήνα (πραγματικών τιμών) $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ (με $k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x}', \mathbf{x})$) ως εξής: Για οποιοδήποτε πεπερασμένο σύνολο διανυσμάτων χαρακτηριστικών $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$, ο επακόλουθος πίνακας $\mathbf{Q} \in \mathbb{R}^{m \times m}$ με καταχωρίσεις $Q_{r,r'} = k(\mathbf{x}^{(r)}, \mathbf{x}^{(r')})$ είναι θετικά ημιορισμένος [49].

Η ιδιότητα της θετικής ημιοριστικότητας επάγει μία μερική διάταξη στους συμμετρικούς πίνακες: Γράφουμε $\mathbf{A} \succeq \mathbf{B}$ (για συμμετρικούς $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{d \times d}$) αν η διαφορά $\mathbf{A} - \mathbf{B}$ είναι θετικά ημιορισμένη [36, Ενότητα 2.4].

Συγκεκριμένα, $\mathbf{A} \succeq \mathbf{0}$ σημαίνει ότι ο $\mathbf{A}$ είναι θετικά ημιορισμένος.

Βλέπε επίσης: συμμετρικός πίνακας, διάνυσμα, πίνακας, φασματική ανάλυση, ιδιοτιμή, πυρήνας, απεικόνιση, διάνυσμα χαρακτηριστικών.

θετικά ορισμένος Ένας συμμετρικός πίνακας (πραγματικών τιμών) $\mathbf{Q} =$

$\mathbf{Q}^T \in \mathbb{R}^{d \times d}$ αναφέρεται ως θετικά ορισμένος (positive definite - pd) αν $\mathbf{x}^T \mathbf{Q} \mathbf{x} > 0$ για κάθε μη μηδενικό διάνυσμα $\mathbf{x} \in \mathbb{R}^d$. Κάθε θετικά ορισμένος πίνακας είναι θετικά ημιορισμένος, αλλά το αντίστροφο δεν ισχύει. Ένας θετικά ορισμένος πίνακας $\mathbf{Q}$ επιτρέπει μία φασματική ανάλυση με αυστηρά θετικές ιδιοτιμές $\lambda_1, \dots, \lambda_d > 0$ [46]. Συγκεκριμένα, ο θετικά ορισμένος πίνακας είναι αντιστρέψιμος.

Ανάλογα με τη θετικά ημιορισμένη διάταξη, γράφουμε $\mathbf{A} \succ \mathbf{B}$ αν ο $\mathbf{A} - \mathbf{B}$ είναι θετικά ορισμένος [36, Ενότητα 2.4].

Βλέπε επίσης: συμμετρικός πίνακας, διάνυσμα, πίνακας, θετικά ημιορισμένος, φασματική ανάλυση, ιδιοτιμή, αντιστρέψιμος.

θεώρημα σταθερού σημείου του Banach TBC.

Ιακωβιανός πίνακας Ο Ιακωβιανός πίνακας (Jacobian matrix) μίας συνάρτησης διανυσματικής τιμής

$$\mathbf{f} : \mathbb{R}^d \rightarrow \mathbb{R}^{d'} : \mathbf{x} \mapsto \mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_{d'}(\mathbf{x}))^T$$

είναι ο πίνακας που αποτελείται από όλες τις πρώτης τάξης μερικές παραγώγους της $\mathbf{f}$ [2], [50]. Πιο αναλυτικά,

$$D_{\mathbf{f}}(\mathbf{x}) := \begin{bmatrix} \frac{\partial f_1}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial f_1}{\partial x_d}(\mathbf{x}) \\ \vdots & \ddots & \vdots \\ \frac{\partial f_{d'}}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial f_{d'}}{\partial x_d}(\mathbf{x}) \end{bmatrix}.$$

Ο Ιακωβιανός πίνακας αναπαριστά την καλύτερη γραμμική προσέγγιση της $\mathbf{f}$ γύρω από ένα δεδομένο διάνυσμα ορίσματος $\mathbf{x}$. Σημείωση ότι η i -οστή γραμμή του Ιακωβιανού πίνακα συμπίπτει με τον ανάστροφο της κλίσης μίας συνάρτησης συνιστώσας f_i που αξιολογείται στο $\mathbf{x}$.

Βλέπε επίσης: πίνακας, διάνυσμα, συνάρτηση, μερική παράγωγος, ανάστροφος, κλίση.

ιδιάζουσα τιμή Βλέπε ανάλυση ιδιάζουσών τιμών.


ιδιοδιάνυσμα Ένα ιδιοδιάνυσμα (eigenvector) ενός πίνακα $\mathbf{A} \in \mathbb{R}^{d \times d}$ είναι

ένα μη μηδενικό διάνυσμα $\mathbf{x} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$ τέτοιο ώστε $\mathbf{Ax} = \lambda\mathbf{x}$ με κάποια ιδιοτιμή λ . Τα ιδιοδιανύσματα που αντιστοιχούν στην ιδιοτιμή λ παράγουν έναν υποχώρο του $\mathbb{R}^d$, δηλαδή τον nullspace του $\mathbf{A} - \lambda\mathbf{I}$.

Βλέπε επίσης: πίνακας, διάνυσμα, ιδιοτιμή, υποχώρος, nullspace.

ιδιότητα Markov Βλέπε αλυσίδα Markov.

ιδιοτιμή Αναφερόμαστε σε έναν αριθμό $\lambda \in \mathbb{R}$ ως ιδιοτιμή (eigenvalue) ενός τετραγωνικού πίνακα $\mathbf{A} \in \mathbb{R}^{d \times d}$ αν υφίσταται ένα μη μηδενικό διάνυσμα $\mathbf{x} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$ τέτοιο ώστε $\mathbf{Ax} = \lambda\mathbf{x}$ (βλέπε Σχ. 14).



Σχ. 14. Ιδιοδιάνυσμα που αντιστοιχεί στην ιδιοτιμή λ .

Βλέπε επίσης: πίνακας, διάνυσμα, ιδιοδιάνυσμα.

ισχυρά κυρτή TBC.

ίχνος TBC.

κάθετο διάνυσμα Βλέπε υπερεπίπεδο.

κανονική κατανομή Βλέπε Γκαουσιανή τυχαία μεταβλητή, πολυμεταβλητή κανονική κατανομή, κεντρικό οριακό θεώρημα.

κανονικός πίνακας Ένας κανονικός πίνακας (normal matrix) είναι ένας τετραγωνικός πίνακας $\mathbf{A} \in \mathbb{C}^{d \times d}$ που αντιμετατίθεται με τον συζυγή α-νάστροφό του, δηλαδή $\mathbf{AA}^H = \mathbf{A}^H\mathbf{A}$. Οι κανονικοί πίνακες επιτρέπουν

μία ορθοκανονική βάση ιδιοδιανυσμάτων και είναι μονοδιαία διαγωνοποιήσιμοι.

Βλέπε επίσης: πίνακας, συζυγής ανάστροφος, βάση, ιδιοδιάνυσμα, διαγωνοποιήσιμος.

κατανομή πιθανότητας Για να αναλύσουμε μεθόδους μηχανικής μάθησης, μπορεί να είναι χρήσιμο να ερμηνεύσουμε σημεία δεδομένων ως ανεξάρτητες και ταυτόσημα κατανεμημένες πραγματώσεις μίας τυχαίας μεταβλητής. Οι τυπικές ιδιότητες τέτοιων σημείων δεδομένων διέπονται τότε από την κατανομή πιθανότητας (probability distribution) αυτής της τυχαίας μεταβλητής. Η κατανομή πιθανότητας μίας δυαδικής τυχαίας μεταβλητής $y \in \{0, 1\}$ προσδιορίζεται πλήρως από τις πιθανότητες $\mathbb{P}(y = 0)$ και $\mathbb{P}(y = 1) = 1 - \mathbb{P}(y = 0)$. Η κατανομή πιθανότητας μίας τυχαίας μεταβλητής πραγματικής τιμής $x \in \mathbb{R}$ μπορεί να προσδιορίζεται από μία συνάρτηση πυκνότητας πιθανότητας $p(x)$ έτσι ώστε $\mathbb{P}(x \in [a, b]) \approx p(a)|b - a|$. Στην πιο γενική περίπτωση, η κατανομή πιθανότητας ορίζεται από ένα μέτρο πιθανότητας [6], [51].

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, ανεξάρτητες και ταυτόσημα κατανεμημένες, πραγμάτωση, τυχαία μεταβλητή, πιθανότητα, μέτρο, συνάρτηση πυκνότητας πιθανότητας.

κατανομή πιθανότητας υπό συνθήκη Θεωρούμε μία στοχαστική διαδικασία που αποτελείται από δύο τυχαίες μεταβλητές $\mathbf{x}$ και y με κατανομή πιθανότητας $\mathbb{P}(\mathbf{x}, y)$. Η κατανομή πιθανότητας υπό συνθήκη (conditional probability distribution) της y δεδομένης (ή υπό τον όρο) της $\mathbf{x}$ δηλώνεται με $\mathbb{P}(y|\mathbf{x})$. Ορίζεται μέσω των προσδοκιών υπό συνθήκη των δεικτριών

συναρτήσεων μετρήσιμων συνόλων στη σ -άλγεβρα που παράγεται από την τυχαία μεταβλητή y [6, Ενότητα 34], [52].

Βλέπε επίσης: στοχαστική διαδικασία, τυχαία μεταβλητή, κατανομή πιθανότητας, προσδοκία υπό συνθήκη, δείκτρια συνάρτηση, μετρήσιμο, σ -άλγεβρα.

κατάσταση Μία κατάσταση (state) είναι μία μαθηματική αναπαράσταση των ελάχιστων πληροφοριών που χρειάζονται για να χαρακτηριστεί ένα σύστημα σε μία δεδομένη στιγμή, έτσι ώστε, μαζί με τη δυναμική του συστήματος, να επαρκούν για την πρόβλεψη της μελλοντικής συμπεριφοράς του συστήματος [53], [54].

Βλέπε επίσης: διάνυσμα χαρακτηριστικών, υπόθεση, ενέργεια.

κατευθυνόμενος γράφος TBC.

κατευθυνόμενος κύκλος TBC.

κατευθυνόμενος μη κυκλικός γράφος TBC.

κεντρικό οριακό θεώρημα TBC.

κλίση Για μία συνάρτηση πραγματικής τιμής $f : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{w} \mapsto f(\mathbf{w})$, αν υφίσταται ένα διάνυσμα $\mathbf{g}$ τέτοιο ώστε

$$\lim_{\mathbf{w} \rightarrow \mathbf{w}'} \frac{f(\mathbf{w}) - (f(\mathbf{w}') + \mathbf{g}^T(\mathbf{w} - \mathbf{w}'))}{\|\mathbf{w} - \mathbf{w}'\|} = 0,$$

αναφέρεται ως η κλίση (gradient) της f στο $\mathbf{w}'$. Αν υφίσταται, η κλίση είναι μοναδική και δηλώνεται με $\nabla f(\mathbf{w}')$ ή $\nabla f(\mathbf{w})|_{\mathbf{w}'}$ [2]. Για μία παραγωγίσιμη συνάρτηση, η κλίση είναι το διάνυσμα του οποίου οι καταχωρίσεις

είναι οι μερικές παράγωγοι της f ως προς κάθε συνιστώσα εισόδου, έτσι ώστε $\nabla f(\mathbf{w}) = [\partial f/\partial x_1, \dots, \partial f/\partial x_d]^T$. Γεωμετρικά, η κλίση δείχνει την κατεύθυνση της μέγιστης αύξησης.

Βλέπε επίσης: συνάρτηση, διάνυσμα, παραγωγίσιμη, μερική παράγωγος, μέθοδος με βάση την κλίση, κάθοδος κλίσης, συνθήκη μηδενικής κλίσης, Εσσιανός.

κυρτή βελτιστοποίηση TBC.

κυρτό Ένα υποσύνολο $\mathcal{C} \subseteq \mathbb{R}^d$ του Ευκλείδειου χώρου $\mathbb{R}^d$ αναφέρεται ως κυρτό (convex) αν περιέχει το ευθύγραμμο τμήμα μεταξύ οποιωνδήποτε δύο σημείων $\mathbf{x}, \mathbf{y} \in \mathcal{C}$ σε αυτό το σύνολο, δηλαδή

$$\alpha \mathbf{x} + (1 - \alpha) \mathbf{y} \in \mathcal{C} \quad \text{για κάθε } \alpha \in [0, 1].$$

Όμοια, μία συνάρτηση $f : \mathbb{R}^d \rightarrow \mathbb{R}$ είναι κυρτή αν ο επιγράφος της $\{(\mathbf{w}^T, t)^T \in \mathbb{R}^{d+1} : t \geq f(\mathbf{w})\}$ είναι ένα κυρτό σύνολο [36]. Παρουσιάζουμε ένα παράδειγμα ενός κυρτού συνόλου και μίας κυρτής συνάρτησης στο Σχ. 15.



Σχ. 15. (a) Κυρτό σύνολο $\mathcal{C} \subseteq \mathbb{R}^d$. (b) Κυρτή συνάρτηση $f : \mathbb{R}^d \rightarrow \mathbb{R}$.


Βλέπε επίσης: Ευκλείδειος χώρος, συνάρτηση, επιγράφος.

Λαγκρανζιανή TBC.

Λαπλασιανός πίνακας Η δομή ενός γράφου $\mathcal{G}$, με κόμβους $i = 1, \dots, n$, μπορεί να αναλυθεί χρησιμοποιώντας τις ιδιότητες ειδικών πινάκων που σχετίζονται με τον $\mathcal{G}$. Ένας τέτοιος πίνακας είναι ο Λαπλασιανός πίνακας (Laplacian matrix) γράφου $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{n \times n}$, ο οποίος ορίζεται για έναν μη κατευθυνόμενο και σταθμισμένο γράφο [55], [56]. Από άποψη στοιχείων ορίζεται ως (βλέπε Σχ. 16)

$$L_{i,i'}^{(\mathcal{G})} := \begin{cases} -A_{i,i'}, & \text{for } i \neq i', \{i, i'\} \in \mathcal{E}, \\ \sum_{i'' \neq i} A_{i,i''}, & \text{for } i = i', \\ 0, & \text{else.} \end{cases}$$

Εδώ $A_{i,i'}$ δηλώνει το βάρος ακμής μίας ακμής $\{i, i'\} \in \mathcal{E}$.



(a)

$$\mathbf{L}^{(\mathcal{G})} = \begin{pmatrix} 2 & -1 & -1 \\ -1 & 1 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

(b)

Σχ. 16. (a) Μη κατευθυνόμενος γράφος $\mathcal{G}$ με τρεις κόμβους $i = 1, 2, 3$. (b) Λαπλασιανός πίνακας $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{3 \times 3}$ του $\mathcal{G}$.

Βλέπε επίσης: γράφος, πίνακας, βάρος ακμής, μη κατευθυνόμενος γράφος.

λεία TBC.

λήμμα Johnson–Lindenstrauss (λήμμα JL) TBC.

μέγιστη πιθανοφάνεια Θεωρούμε σημεία δεδομένων $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$ που ερμηνεύονται ως τις πραγματώσεις ανεξάρτητων και ταυτόσημα κατα-
νεμημένων τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας $\mathbb{P}^{(\mathcal{D}; \mathbf{w})}$, η
οποία εξαρτάται από τις παραμέτρους μοντέλου $\mathbf{w} \in \mathcal{W} \subseteq \mathbb{R}^n$. Οι μέθο-
δοι μέγιστης πιθανοφάνειας (maximum likelihood) μαθαίνουν τις παρα-
μέτρους του μοντέλου $\mathbf{w}$ μεγιστοποιώντας την συνάρτηση πυκνότητας πι-
θανότητας (ή συνάρτηση μάζας πιθανότητας) $p^{(\mathcal{D}; \mathbf{w})}(\mathcal{D}') = \prod_{r=1}^m p^{(\mathbf{z}; \mathbf{w})}(\mathbf{z}^{(r)})$
του παρατηρούμενου συνόλου δεδομένων. Συνεπώς, ο εκτιμητής μέγι-
στης πιθανοφάνειας είναι μία λύση του προβλήματος βελτιστοποίησης
 $\max_{\mathbf{w} \in \mathcal{W}} p^{(\mathcal{D}; \mathbf{w})}(\mathcal{D}')$.

Βλέπε επίσης: σημείο δεδομένων, πραγμάτωση, ανεξάρτητες και ταυτόση-
μα κατανεμημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, παράμε-
τρος μοντέλου, μέγιστο, συνάρτηση πυκνότητας πιθανότητας, συνάρτηση
μάζας πιθανότητας, σύνολο δεδομένων, εκτιμητής, πρόβλημα βελτιστο-
ποίησης, πιθανοτικό μοντέλο.

μέγιστο Το μέγιστο (maximum) ενός συνόλου $\mathcal{A} \subseteq \mathbb{R}$ πραγματικών αριθμών
είναι το μεγαλύτερο στοιχείο σε αυτό το σύνολο αν ένα τέτοιο στοιχείο
υφίσταται. Ένα σύνολο $\mathcal{A}$ έχει ένα μέγιστο αν είναι άνω φραγμένο και
επιτυγχάνει το supremum του [2, Ενότητα 1.4].

Βλέπε επίσης: supremum (ή ελάχιστο άνω φράγμα).

μέθοδος βελτιστοποίησης Μία μέθοδος βελτιστοποίησης (optimization
method) είναι ένας αλγόριθμος που διαβάζει μία αναπαράσταση ενός προ-
βλήματος βελτιστοποίησης ως είσοδο και υπολογίζει μία (προσεγγιστική)

λύση ως έξοδό του. Ένα κεντρικό παράδειγμα προβλήματος βελτιστοποίησης στη μηχανική μάθηση είναι η ελαχιστοποίηση εμπειρικής διακινδύνευσης. Εφαρμόζοντας μία κατάλληλη μέθοδο βελτιστοποίησης στην ελαχιστοποίηση εμπειρικής διακινδύνευσης, αποκτούμε έναν συγκεκριμένο αλγόριθμο μάθησης [36], [57], [58].

Βλέπε επίσης: βελτιστοποίηση, αλγόριθμος, πρόβλημα βελτιστοποίησης, έξοδος, μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης.

μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών

Η μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών (alternating direction method of multipliers - ADMM) είναι μία επαναληπτική μέθοδος βελτιστοποίησης για τη λύση ενός δομημένου προβλήματος βελτιστοποίησης. Συγκεκριμένα, η μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών μπορεί να χρησιμοποιηθεί για τη λύση ενός προβλήματος βελτιστοποίησης της ακόλουθης μορφής:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^d, \mathbf{x}' \in \mathbb{R}^{d'}} & f(\mathbf{x}) + g(\mathbf{x}') \\ \text{s.t. } & \mathbf{Ax} - \mathbf{Bx}' = \mathbf{c} \end{aligned}$$

για δεδομένους πίνακες $\mathbf{A} \in \mathbb{R}^{p \times d}$ και $\mathbf{B} \in \mathbb{R}^{p \times d'}$, καθώς και ένα δεδομένο διάνυσμα $\mathbf{c} \in \mathbb{R}^p$.

Βλέπε επίσης: μέθοδος βελτιστοποίησης, πρόβλημα βελτιστοποίησης, πίνακας, διάνυσμα, μέθοδος των πολλαπλασιαστών.

μέθοδος του Newton TBC.

μέθοδος των πολλαπλασιαστών Η μέθοδος των πολλαπλασιαστών

(method of multipliers - MoM) είναι μία επαναληπτική μέθοδος βελτιστοποίησης για τη λύση ενός προβλήματος βελτιστοποίησης με περιορισμούς της ακόλουθης μορφής [59]:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) \\ \text{s.t. } \mathbf{Ax} = \mathbf{b}. \end{aligned}$$

Εδώ $f : \mathbb{R}^d \rightarrow \mathbb{R}$ δηλώνει την αντικειμενική συνάρτηση, $\mathbf{A} \in \mathbb{R}^{m \times d}$ είναι ένας δεδομένος πίνακας, και $\mathbf{b} \in \mathbb{R}^m$ είναι ένα δεδομένο διάνυσμα. Η μέθοδος των πολλαπλασιαστών βασίζεται στον επαυξημένο κατά Lagrange

$$L_\rho(\mathbf{x}, \mathbf{y}) = f(\mathbf{x}) + \mathbf{y}^\top \mathbf{Ax} + \frac{\rho}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2,$$

όπου $\mathbf{y}$ δηλώνει το διάνυσμα των πολλαπλασιαστών του Lagrange και $\rho > 0$ είναι μία παράμετρος ποινής. Η μέθοδος των πολλαπλασιαστών κατασκευάζει μία ακολουθία εκτιμήσεων $(\mathbf{x}^{(1)}, \mathbf{y}^{(1)})$, $\dots$ που συγκλίνουν σε μία λύση του προβλήματος βελτιστοποίησης. Συγκεκριμένα, κατά τη διάρκεια κάθε επανάληψης t , οι τρέχουσες εκτιμήσεις $\mathbf{x}^{(k)}, \mathbf{y}^{(k)}$ ενημερώνονται ως εξής:

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \arg \min_{\mathbf{x} \in \mathbb{R}^d} L_\rho(\mathbf{x}, \mathbf{y}^{(k)}), \\ \mathbf{y}^{(k+1)} &= \mathbf{y}^{(k)} + \rho (\mathbf{Ax}^{(k+1)} - \mathbf{b}). \end{aligned}$$

Η μέθοδος των πολλαπλασιαστών μπορεί να γραφεί ως μία επανάληψη

σταθερού σημείου της ακόλουθης μορφής:

$$(\mathbf{x}^{(k+1)}, \mathbf{y}^{(k+1)}) = \mathcal{F}(\mathbf{x}^{(k)}, \mathbf{y}^{(k)})$$

με

$$\mathcal{F} : \mathbb{R}^d \times \mathbb{R}^m \rightarrow \mathbb{R}^d \times \mathbb{R}^m : (\mathbf{x}, \mathbf{y}) \mapsto (\mathbf{x}', \mathbf{y} + \rho(\mathbf{A}\mathbf{x}' - \mathbf{b}))$$

$$\text{με } \mathbf{x}' = \arg \min_{\mathbf{x} \in \mathbb{R}^d} L_\rho(\mathbf{x}, \mathbf{y}).$$

Βλέπε επίσης: μέθοδος βελτιστοποίησης, πρόβλημα βελτιστοποίησης με περιορισμούς, αντικειμενική συνάρτηση, πίνακας, διάνυσμα, επαυξημένος κατά Lagrange, παράμετρος, ακολουθία, επανάληψη, επανάληψη σταθερού σημείου.

μερική παράγωγος TBC.

μέση τιμή Η μέση τιμή (mean) μίας τυχαίας μεταβλητής $\mathbf{x}$, η οποία παίρνει τιμές σε έναν Ευκλείδειο χώρο $\mathbb{R}^d$, είναι η προσδοκία της $\mathbb{E}\{\mathbf{x}\}$. Ορίζεται ως το ολοκλήρωμα Lebesgue της $\mathbf{x}$ αναφορικά με την υποκείμενη κατανομή πιθανότητας $\mathbb{P}(\cdot)$ (π.χ. βλέπε [2] ή [6]), δηλαδή

$$\mathbb{E}\{\mathbf{x}\} = \int_{\mathbb{R}^d} \mathbf{x} dP(\mathbf{x}).$$

Χρησιμοποιούμε επίσης τον όρο για να αναφερθούμε στη μέση τιμή δείγματος ενός πεπερασμένου συνόλου δεδομένων $\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d\}$. Ωστόσο, αυτοί οι δύο ορισμοί είναι ουσιαστικά ίδιοι. Πράγματι, μπορούμε να χρησιμοποιήσουμε ένα σύνολο δεδομένων για να κατασκευ-

άσουμε μία διακριτή τυχαία μεταβλητή $\tilde{\mathbf{x}} = \mathbf{x}^{(I)}$ στον δειγματικό χώρο $\{1, \dots, m\}$. Εδώ ο δείκτης I επιλέγεται ομοιόμορφα στην τύχη, δηλαδή $\mathbb{P}(I = r) = 1/m$ για κάθε $r = 1, \dots, m$. Η μέση τιμή της $\tilde{\mathbf{x}}^{(D)}$ είναι ακριβώς ο μέσος όρος $(1/m) \sum_{r=1}^m \mathbf{x}^{(r)}$. Για μία τυχαία μεταβλητή με πεπερασμένη ροπή δεύτερης τάξης, δηλαδή η $\mathbb{E}\{\|\mathbf{x}\|_2^2\}$ είναι καλά ορισμένη και πεπερασμένη, η μέση τιμή χαρακτηρίζεται ως η λύση του ακόλουθου προβλήματος ελαχιστοποίησης διακινδύνευσης [7]:

$$\mathbb{E}\{\mathbf{x}\} = \arg \min_{\mathbf{c} \in \mathbb{R}^d} \mathbb{E}\{\|\mathbf{x} - \mathbf{c}\|_2^2\}.$$

Για την τυχαία μεταβλητή $\tilde{\mathbf{x}}^{(D)}$, που σχετίζεται με ένα σύνολο δεδομένων $\mathcal{D}$, αυτό το πρόβλημα βελτιστοποίησης ανάγεται σε ελαχιστοποίηση εμπειρικής διακινδύνευσης με απώλεια τετραγωνικού σφάλματος στο $\mathcal{D}$.


Βλέπε επίσης: τυχαία μεταβλητή, Ευκλείδειος χώρος, προσδοκία, ολοκλήρωμα Lebesgue, κατανομή πιθανότητας, μέση τιμή δείγματος, σύνολο δεδομένων, διακριτή τυχαία μεταβλητή, δειγματικός χώρος, διακινδύνευση, πρόβλημα βελτιστοποίησης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια τετραγωνικού σφάλματος.

μέσος βαθμός κόμβου Ο μέσος βαθμός κόμβου (average node degree) $\bar{d}$ ενός σταθμισμένου μη κατευθυνόμενου γράφου $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$ είναι ο μέσος όρος όλων των βαθμών κόμβων, δηλαδή $\bar{d} = (1/n) \sum_{i \in \mathcal{V}} d^{(i)}$.

Βλέπε επίσης: βαθμός κόμβου, μη κατευθυνόμενος γράφος, γείτονας.

μετρήσιμο Θεωρούμε ένα τυχαίο πείραμα, όπως η καταγραφή της θερμοκρασίας του αέρα σε έναν μετεωρολογικό σταθμό του Φινλανδικού Μετεωρολογικού Ινστιτούτου. Ο αντίστοιχος δειγματικός χώρος Ω αποτελείται

από όλες τις πιθανές εκβάσεις ω (π.χ. όλες τις πιθανές τιμές θερμοκρασίας σε βαθμούς Κελσίου). Σε πολλές εφαρμογές μηχανικής μάθησης, δε μας ενδιαφέρει η ακριβής έκβαση ω , αλλά μόνο το αν ανήκει σε ένα υποσύνολο $\mathcal{A} \subseteq \Omega$ (π.χ. ο καθορισμός του αν η θερμοκρασία είναι κάτω από το μηδέν). Ονομάζουμε ένα τέτοιο υποσύνολο $\mathcal{A}$ μετρήσιμο (measurable) αν είναι δυνατό να αποφασίσουμε, για οποιαδήποτε έκβαση ω , αν $\omega \in \mathcal{A}$ (βλέπε Σχ. 17).



Σχ. 17. Δειγματικός χώρος που αποτελείται από όλες τις πιθανές τιμές θερμοκρασίας ω που μπορούν να εμφανιστούν σε έναν σταθμό του Φινλανδικού Μετεωρολογικού Ινστιτούτου. Δύο μετρήσιμα υποσύνολα τιμών θερμοκρασίας, τα οποία συμβολίζονται με $\mathcal{A}^{(1)}$ και $\mathcal{A}^{(2)}$, επισημαίνονται. Για οποιαδήποτε πραγματική τιμή θερμοκρασίας ω , είναι δυνατό να καθοριστεί (μέσω κάποιου εξοπλισμού) αν $\omega \in \mathcal{A}^{(1)}$ και αν $\omega \in \mathcal{A}^{(2)}$.

Στη θεωρία, μετρήσιμα σύνολα μπορούν να επιλεγούν ελεύθερα (π.χ. ανάλογα με την ανάλυση του εξοπλισμού μέτρησης). Ωστόσο, είναι συχνά χρήσιμο να επιβάλλονται ορισμένες απαιτήσεις πληρότητας στη συλλογή των μετρήσιμων συνόλων. Για παράδειγμα, ο ίδιος ο δειγματικός χώρος θα πρέπει να είναι μετρήσιμος, και η ένωση δύο μετρήσιμων συνόλων θα πρέπει επίσης να είναι μετρήσιμη. Αυτές οι απαιτήσεις πληρότητας μπορούν να τυποποιηθούν μέσω της έννοιας της σ -άλγεβρας (ή σ -σώματος) [1], [6], [18]. Ένας μετρήσιμος χώρος είναι ένα ζεύγος $(\mathcal{X}, \mathcal{F})$

που αποτελείται από ένα αυθαίρετο σύνολο $\mathcal{X}$ και μία συλλογή $\mathcal{F}$ μετρήσιμων υποσυνόλων του $\mathcal{X}$ που σχηματίζουν μία σ -άλγεβρα.

Βλέπε επίσης: τυχαίο πείραμα, Φινλανδικό Μετεωρολογικό Ινστιτούτο, δειγματικός χώρος, έκβαση, μηχανική μάθηση, σ -άλγεβρα, σ -σώμα, πιθανότητα.

μετρική Μία μετρική (metric) είναι ένα ποσοτικό μέτρο που χρησιμοποιείται για τη σύγκριση αντικειμένων. Στα μαθηματικά, μία μετρική μετράει την απόσταση μεταξύ δύο σημείων σε έναν χώρο και πρέπει να ακολουθεί συγκεκριμένους κανόνες, δηλαδή η απόσταση να είναι πάντα μη αρνητική, να είναι μηδενική μόνο αν τα σημεία είναι ίδια, να είναι συμμετρική, και να ικανοποιεί την τριγωνική ανισότητα [2]. Στο πλαίσιο της μηχανικής μάθησης, ο όρος μετρική αναφέρεται σε ένα ποσοτικό μέτρο του πόσο καλά επιδίδει ένα μοντέλο (κάπως όμοιο με μία συνάρτηση απώλειας). Παραδείγματα περιλαμβάνουν την ακρίβεια (accuracy), την ακρίβεια (precision), και τη μέση απώλεια 0/1 σε ένα σύνολο ελέγχου [60], [61]. Ο όρος συνάρτηση απώλειας χρησιμοποιείται συνήθως στο πλαίσιο της εκπαίδευσης μοντέλου, ενώ ο όρος μετρική χρησιμοποιείται στο πλαίσιο της επικύρωσης μοντέλου.


Βλέπε επίσης: μέτρο, απόσταση, μηχανική μάθηση, μοντέλο, συνάρτηση απώλειας, ακρίβεια, ακρίβεια, απώλεια 0/1, σύνολο ελέγχου, εκπαίδευση, επικύρωση, απώλεια.

μετρικός χώρος Ένας μετρικός χώρος (metric space) είναι ένα σύνολο $\mathcal{X}$ εξοπλισμένο με μία συνάρτηση (η οποία αναφέρεται ως μετρική) $d(\cdot, \cdot) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ που ικανοποιεί τις ακόλουθες απαιτήσεις για όλα τα

$\mathbf{x}, \mathbf{x}', \mathbf{x}'' \in \mathcal{X}$:

- 1) Μη αρνητικότητα: $d(\mathbf{x}, \mathbf{x}') \geq 0$.
- 2) Ταυτότητα: $d(\mathbf{x}, \mathbf{x}') = 0$ αν και μόνο αν $\mathbf{x} = \mathbf{x}'$.
- 3) Συμμετρία: $d(\mathbf{x}, \mathbf{x}') = d(\mathbf{x}', \mathbf{x})$.
- 4) Τριγωνική ανισότητα: $d(\mathbf{x}, \mathbf{x}'') \leq d(\mathbf{x}, \mathbf{x}') + d(\mathbf{x}', \mathbf{x}'')$.

Τυπικά, ένας μετρικός χώρος είναι ένα ζεύγος $(\mathcal{X}, d(\cdot, \cdot))$ που ικανοποιεί τις παραπάνω απαιτήσεις [35].



Σχ. 18. Παραδείγματα μετρικών χώρων. (a) Ευκλείδειος χώρος $\mathbb{R}^2$ με την Ευκλείδεια απόσταση ως μία μετρική. (b) Μη κατευθυνόμενος γράφος $(\mathcal{V}, \mathcal{E})$ με την απόσταση της συντομότερης διαδρομής ως μία μετρική.

Ένα περίφημο παράδειγμα μετρικού χώρου είναι ο Ευκλείδειος χώρος εξοπλισμένος με μία μετρική που δίνεται από την Ευκλείδεια απόσταση $d(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\|_2$. Ένα άλλο καλά γνωστό παράδειγμα μετρικού χώρου είναι ένας μη κατευθυνόμενος γράφος $\mathcal{G} = (\mathcal{V}, \mathcal{E})$, με τη μετρική $d(i, i')$ ορισμένη από το μήκος της συντομότερης διαδρομής που συνδέει τους κόμβους i και i' .

Βλέπε επίσης: μετρική, συνάρτηση, Ευκλείδειος χώρος, μη κατευθυνόμενος γράφος, Ευκλείδεια απόσταση, απόσταση, χώρος χαρακτηριστικών.

μέτρο Ένα μέτρο (measure) μ σε ένα σύνολο Ω εξοπλισμένο με μία σ -άλγεβρα Σ είναι μία συνάρτηση $\mu : \Sigma \rightarrow [0, \infty)$ που αποδίδει μία μη αρνητική τιμή σε κάθε μετρήσιμο σύνολο $A \in \Sigma$ έτσι ώστε [2], [6], [62]: 1) $\mu(\emptyset) = 0$, και 2) για οποιαδήποτε αριθμήσιμη συλλογή $\{A_i\}_{i=1}^{\infty}$ κατά ζεύγη ξένων συνόλων στη Σ ,

$$\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i),$$

η οποία αναφέρεται ως «αριθμήσιμη προσθετικότητα».

Βλέπε επίσης: σ -άλγεβρα, συνάρτηση, μετρήσιμο, αριθμήσιμο.

μη κατευθυνόμενος γράφος Βλέπε γράφος.

μη λεία Αναφερόμαστε σε μία συνάρτηση ως μη λεία (non-smooth) αν δεν είναι λεία [58].

Βλέπε επίσης: συνάρτηση, λεία.

νόμος των μεγάλων αριθμών Ο νόμος των μεγάλων αριθμών (law of large numbers) αναφέρεται στη σύγκλιση του μέσου όρου ενός αυξανόμενου (μεγάλου) αριθμού ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών στη μέση τιμή της κοινής τους κατανομής πιθανότητας. Διαφορετικές περιπτώσεις του νόμου των μεγάλων αριθμών προκύπτουν από τη χρήση διαφορετικών εννοιών σύγκλισης [10].

Βλέπε επίσης: σύγκλιση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, μέση τιμή, κατανομή πιθανότητας.

νόρμα TBC.

ολική μεταβολή Βλέπε γενικευμένη ολική μεταβολή.

ολοκλήρωμα Lebesgue TBC.

ολοκληρώσιμη Μία μετρήσιμη συνάρτηση $f: \Omega \rightarrow \mathbb{R}$ ορισμένη σε έναν χώρο μέτρου (Ω, Σ, μ) ονομάζεται ολοκληρώσιμη (integrable) αν το ολοκλήρωμα Lebesgue της απόλυτης τιμής της είναι πεπερασμένο, δηλαδή

$$\int_{\Omega} |f(x)| \, d\mu < \infty.$$

Σε αυτήν την περίπτωση, το ολοκλήρωμα Lebesgue $\int_{\Omega} f(x) \, d\mu$ είναι καλά ορισμένο και πεπερασμένο. Μία τυχαία μεταβλητή x ορισμένη στον δειγματικό χώρο ενός χώρου πιθανοτήτων $(\Omega, \Sigma, \mathbb{P})$ είναι ολοκληρώσιμη αν

$$\mathbb{E}\{|x|\} = \int_{\Omega} |x(\omega)| \, d\mathbb{P} < \infty,$$

κάτι που είναι ισοδύναμο με την ύπαρξη της προσδοκίας $\mathbb{E}\{x\}$ (δηλαδή είναι πεπερασμένη).

Βλέπε επίσης: μετρήσιμο, συνάρτηση, χώρος μέτρου, ολοκλήρωμα Lebesgue, τυχαία μεταβλητή, δειγματικός χώρος, χώρος πιθανοτήτων, προσδοκία, μέτρο.

ομάδα TBC.

ορθομοναδιαίος πίνακας Ένας τετραγωνικός πίνακας $\mathbf{U} \in \mathbb{C}^{d \times d}$ ονομάζεται ορθομοναδιαίος (unitary matrix) αν ο συζυγής ανάστροφός του (ή Ερμιτιανός ανάστροφος) $\mathbf{U}^H$ είναι επίσης ο αντίστροφος πίνακάς του, δηλαδή αν

$$\mathbf{U}^H \mathbf{U} = \mathbf{U} \mathbf{U}^H = \mathbf{I}.$$

Ισοδύναμα, οι στήλες (και γραμμές) ενός ορθομοναδιαίου πίνακα σχηματίζουν μία ορθοκανονική βάση του $\mathbb{C}^d$ ως προς το τυπικό εσωτερικό γινόμενο [29], [46].

Βλέπε επίσης: πίνακας, συζυγής ανάστροφος, Ερμιτιανός, ανάστροφος, αντίστροφος πίνακας, βάση, εσωτερικό γινόμενο.

ορίζουσα Η ορίζουσα (determinant) $\det(\mathbf{A})$ ενός τετραγωνικού πίνακα $\mathbf{A} = (\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)}) \in \mathbb{R}^{d \times d}$ είναι μία συνάρτηση των στηλών του $\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(d)} \in \mathbb{R}^d$, δηλαδή πληροί τις ακόλουθες ιδιότητες [63]:

- Κανονικοποιημένη:

$$\det(\mathbf{I}) = 1$$

- Πολυγραμμική:


$$\begin{aligned} \det(\mathbf{a}^{(1)}, \dots, \alpha \mathbf{u} + \beta \mathbf{v}, \dots, \mathbf{a}^{(d)}) &= \alpha \det(\mathbf{a}^{(1)}, \dots, \mathbf{u}, \dots, \mathbf{a}^{(d)}) \\ &+ \beta \det(\mathbf{a}^{(1)}, \dots, \mathbf{v}, \dots, \mathbf{a}^{(d)}). \end{aligned}$$

- Αντισυμμετρική:

$$\det(\dots, \mathbf{a}^{(j)}, \dots, \mathbf{a}^{(j')}, \dots) = -\det(\dots, \mathbf{a}^{(j')}, \dots, \mathbf{a}^{(j)}, \dots).$$

Μπορούμε να ερμηνεύσουμε έναν πίνακα $\mathbf{A}$ ως έναν γραμμικό μετασχηματισμό στον $\mathbb{R}^d$. Η ορίζουσα $\det(\mathbf{A})$ χαρακτηρίζει πώς οι όγκοι στον $\mathbb{R}^d$ (και ο προσανατολισμός τους) μεταβάλλονται από αυτόν τον μετασχηματισμό (βλέπε Σχ. 19) [3], [28]. Συγκεκριμένα, $\det(\mathbf{A}) > 0$ διατηρεί τον προσανατολισμό, $\det(\mathbf{A}) < 0$ αντιστρέφει τον προσανατολισμό, και

$\det(\mathbf{A}) = 0$ συρρικνώνει πλήρως τον όγκο, υποδεικνύοντας ότι ο $\mathbf{A}$ είναι μη αντιστρέψιμος. Η ορίζουσα ικανοποιεί επίσης $\det(\mathbf{AB}) = \det(\mathbf{A}) \cdot \det(\mathbf{B})$, και αν ο $\mathbf{A}$ είναι διαγωνοποιήσιμος με ιδιοτιμές $\lambda_1, \dots, \lambda_d$, τότε $\det(\mathbf{A}) = \prod_{j=1}^d \lambda_j$ [46]. Για τις ειδικές περιπτώσεις $d = 2$ (δηλαδή σε δισδιάστατο (2-D) χώρο $\mathbb{R}^2$) και $d = 3$ (δηλαδή σε τρισδιάστατο (3-D) χώρο $\mathbb{R}^3$), η ορίζουσα μπορεί να ερμηνευτεί ως ένα προσανατολισμένο εμβαδόν ή ένας προσανατολισμένος όγκος που παράγεται από τα διανύσματα στηλών του $\mathbf{A}$.



Σχ. 19. Μπορούμε να ερμηνεύσουμε έναν τετραγωνικό πίνακα $\mathbf{A}$ ως έναν γραμμικό μετασχηματισμό του $\mathbb{R}^d$ στον εαυτό του. Η ορίζουσα $\det(\mathbf{A})$ χαρακτηρίζει πώς αυτός ο μετασχηματισμός μεταβάλλει έναν προσανατολισμένο όγκο.

Βλέπε επίσης: πίνακας, συνάρτηση, αντιστρέψιμος, διαγωνοποιήσιμος, ι-διοτιμή, διάνυσμα, αντίστροφος πίνακας.

όριο TBC.

παραγωγίσιμη Μία συνάρτηση πραγματικής τιμής $f : \mathbb{R}^d \rightarrow \mathbb{R}$ είναι παραγωγίσιμη (differentiable) αν μπορεί να προσεγγιστεί τοπικά σε οποιοδήποτε σημείο από μία γραμμική συνάρτηση. Η τοπική γραμμική προσέγγιση στο σημείο $\mathbf{x}$ καθορίζεται από την κλίση $\nabla f(\mathbf{x})$ [2].

Βλέπε επίσης: συνάρτηση, κλίση.

παράγωγος Βλέπε μερική παράγωγος.

πεδίο ορισμού Το πεδίο ορισμού (domain) μίας συνάρτησης $f : \mathcal{U} \rightarrow \mathcal{V}$ είναι το σύνολο $\mathcal{U}$ από το οποίο η f παίρνει τις εισόδους της.
Βλέπε επίσης: συνάρτηση, co-domain, απεικόνιση.

πεδίο τιμών TBC.

περιθώρια κατανομή TBC.

περιθωριοποίηση Ο όρος περιθωριοποίηση (marginalization) αναφέρεται στη διαδικασία υπολογισμού της κατανομής πιθανότητας ενός υποσυνόλου τυχαίων μεταβλητών από την από κοινού κατανομή πιθανότητας μίας στοχαστικής διαδικασίας [64].
Βλέπε επίσης: κατανομή πιθανότητας, τυχαία μεταβλητή, στοχαστική διαδικασία, περιθώρια κατανομή.

πρόβλημα βελτιστοποίησης με περιορισμούς Ένα πρόβλημα βελτιστοποίησης με περιορισμούς (constrained optimization problem) είναι ένα πρόβλημα βελτιστοποίησης που περιλαμβάνει περιορισμούς στη μεταβλητή βελτιστοποίησης. Για παράδειγμα, θεωρούμε το πρόβλημα βελτιστοποίησης

$$\min_{\mathbf{w} \in \mathcal{W}} f(\mathbf{w}),$$

όπου η αντικειμενική συνάρτηση $f : \mathbb{R}^d \rightarrow \mathbb{R}$ πρόκειται να ελαχιστοποιηθεί πάνω σε ένα σύνολο περιορισμών $\mathcal{W} \subseteq \mathbb{R}^d$. Εδώ το σύνολο περιορισμών $\mathcal{W}$ περιορίζει τις εφικτές τιμές της μεταβλητής βελτιστοποίησης $\mathbf{w}$. Αν $\mathcal{W} = \mathbb{R}^d$, τότε το παραπάνω πρόβλημα βελτιστοποίησης ανάγεται σε ένα πρόβλημα βελτιστοποίησης χωρίς περιορισμούς.

Βλέπε επίσης: πρόβλημα βελτιστοποίησης, βελτιστοποίηση, αντικειμενική

συνάρτηση.

πιθανοτική ανάλυση κύριων συνιστωσών Η πιθανοτική ανάλυση κύριων συνιστωσών (probabilistic principal component analysis - PPCA) επεκτείνει τη βασική ανάλυση κύριων συνιστωσών χρησιμοποιώντας ένα πιθανοτικό μοντέλο για σημεία δεδομένων. Η χρήση ενός πιθανοτικού μοντέλου μάς επιτρέπει να διατυπώσουμε τη μείωση της διαστασιμότητας ως ένα πρόβλημα εκτίμησης που μπορεί να λυθεί με τη χρήση της αλγόριθμος προσδοκίας-μεγιστοποίησης [65].
Βλέπε επίσης: ανάλυση κύριων συνιστωσών, πιθανοτικό μοντέλο, σημείο δεδομένων, μείωση της διαστασιμότητας, αλγόριθμος προσδοκίας-μεγιστοποίησης.

πιθανοτικό μοντέλο Ένα πιθανοτικό μοντέλο (probabilistic model) για την παραγωγή σημείων δεδομένων αποτελείται από τυχαίες μεταβλητές με μία από κοινού κατανομή πιθανότητας [7]. Αυτή η από κοινού κατανομή πιθανότητας συνήθως περιλαμβάνει παραμέτρους (ή παραμέτρους του μοντέλου) που είτε επιλέγονται χειρωνακτικά είτε μαθαίνονται μέσω μεθόδων στατιστικής εξαγωγής συμπερασμάτων, όπως η εκτίμηση μέγιστης πιθανοφάνειας [20].

Βλέπε επίσης: μοντέλο, σημείο δεδομένων, τυχαία μεταβλητή, κατανομή πιθανότητας, παράμετρος, παράμετρος μοντέλου, εξαγωγή συμπερασμάτων, μέγιστη πιθανοφάνεια, πραγμάτωση.

πίνακας Ένας πίνακας (matrix) μεγέθους $m \times d$ είναι μία 2-D διάταξη αριθ-

μών, η οποία δηλώνεται με

$$\mathbf{A} = \begin{pmatrix} A_{1,1} & A_{1,2} & \dots & A_{1,d} \\ A_{2,1} & A_{2,2} & \dots & A_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ A_{m,1} & A_{m,2} & \dots & A_{m,d} \end{pmatrix} \in \mathbb{R}^{m \times d}.$$

Εδώ $A_{r,j}$ δηλώνει την καταχώριση του πίνακα στην r -οστή γραμμή και την j -οστή στήλη. Οι πίνακες είναι χρήσιμες αναπαραστάσεις διάφορων μαθηματικών αντικειμένων [30], συμπεριλαμβανομένων των εξής:

- Συστήματα γραμμικών εξισώσεων: Μπορούμε να χρησιμοποιήσουμε έναν πίνακα για να αναπαραστήσουμε ένα σύστημα γραμμικών εξισώσεων

$$\begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \text{ συμπαγώς ως } \mathbf{A}\mathbf{w} = \mathbf{y}.$$


Ένα σημαντικό παράδειγμα συστημάτων γραμμικών εξισώσεων είναι η συνθήκη βελτιστότητας για τις παραμέτρους μοντέλου εντός γραμμικής παλινδρόμησης.

- Γραμμικές απεικονίσεις: Θεωρούμε έναν d -διάστατο διανυσματικό χώρο $\mathcal{U}$ και έναν m -διάστατο διανυσματικό χώρο $\mathcal{V}$. Αν σταθεροποιήσουμε μία βάση $\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}$ για $\mathcal{U}$ και μία βάση $\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(m)}$ για $\mathcal{V}$, κάθε πίνακας $\mathbf{A} \in \mathbb{R}^{m \times d}$ ορίζει φυσικά μία γραμμική απεικόνι-

ση $\alpha : \mathcal{U} \rightarrow \mathcal{V}$ (βλέπε Σχ. 20) έτσι ώστε

$$\mathbf{u}^{(j)} \mapsto \sum_{r=1}^m A_{r,j} \mathbf{v}^{(r)}.$$

- **Σύνολα δεδομένων:** Μπορούμε να χρησιμοποιήσουμε έναν πίνακα για να αναπαραστήσουμε ένα σύνολο δεδομένων. Κάθε γραμμή αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και κάθε στήλη αντιστοιχεί σε ένα συγκεκριμένο χαρακτηριστικό ή ετικέτα ενός σημείου δεδομένων.



Σχ. 20. Πίνακας $\mathbf{A}$ που ορίζει μία γραμμική απεικόνιση μεταξύ δύο διανυσματικών χώρων.

Βλέπε επίσης: παράμετρος μοντέλου, γραμμική παλινδρόμηση, γραμμική απεικόνιση, διανυσματικός χώρος, βάση, σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, γραμμικό μοντέλο.

πίνακας συνδιακύμανσης Ο πίνακας συνδιακύμανσης (covariance matrix) μίας τυχαίας μεταβλητής $\mathbf{x} \in \mathbb{R}^d$ ορίζεται ως η προσδοκία (αν υφίσταται):

$$\mathbf{C}^{(\mathbf{x})} := \mathbb{E} \left\{ (\mathbf{x} - \mathbb{E}\{\mathbf{x}\}) (\mathbf{x} - \mathbb{E}\{\mathbf{x}\})^T \right\}.$$

Βλέπε επίσης: συνδιακύμανση, πίνακας, τυχαία μεταβλητή, προσδοκία.

πίνακας συνδιακύμανσης δείγματος Θεωρούμε ένα σύνολο δεδομένων $\mathcal{D}$ που αποτελείται από σημεία δεδομένων που χαρακτηρίζονται από διάνυσματα χαρακτηριστικών $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$. Ο πίνακας συνδιακύμανσης δείγματος (sample covariance matrix) του $\mathcal{D}$ ορίζεται ως ο πίνακας συνδιακύμανσης αναφορικά με την εμπειρική κατανομή $\mathbb{P}^{(\mathcal{D})}$ που επάγεται από το $\mathcal{D}$. Δίνεται ρητά από

$$\hat{\mathbf{C}} = \frac{1}{m} \sum_{r=1}^m (\mathbf{x}^{(r)} - \hat{\mathbf{m}})(\mathbf{x}^{(r)} - \hat{\mathbf{m}})^T.$$

Εδώ χρησιμοποιούμε τη μέση τιμή δείγματος $\hat{\boldsymbol{\mu}}$.


Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, δείγμα, πίνακας συνδιακύμανσης, εμπειρική κατανομή, μέση τιμή δείγματος.

πλήρους τάξης TBC.

πολυμεταβλητή κανονική κατανομή TBC.

προβεβλημένη κάθοδος κλίσης Θεωρούμε μία μέθοδο βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιεί ένα παραμετροποιημένο μοντέλο με παραμετρικό χώρο $\mathcal{W} \subseteq \mathbb{R}^d$. Ακόμα και αν η αντικειμενική συνάρτηση ελαχιστοποίησης εμπειρικής διακινδύνευσης είναι λεία, δεν μπορούμε να χρησιμοποιήσουμε τη βασική καθόδο κλίσης, καθώς δεν λαμβάνει υπόψη περιορισμούς στη μεταβλητή βελτιστοποίησης (δηλαδή τις παραμέτρους του μοντέλου). Η προβεβλημένη κάθοδος

κλίσης (projected gradient descent - projected GD) επεκτείνει τη βασική καθόδo κλίσης για να αντιμετωπίσει αυτό το ζήτημα. Μία μοναδική επανάληψη της προβεβλημένης καθόδου κλίσης περιλαμβάνει πρώτα τη λήψη ενός βήματος κλίσης και στη συνέχεια την προβολή του αποτελέσματος πίσω στον παραμετρικό χώρο. Βλέπε Σχ. 21 για μία οπτική απεικόνιση.



Σχ. 21. Προβεβλημένη καθόδo κλίσης που επαυξάνει ένα βασικό βήμα κλίσης με μία προβολή πίσω στο σύνολο περιορισμών $\mathcal{W}$.

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, μοντέλο, παραμετρικός χώρος, αντικειμενική συνάρτηση, λεία, καθόδo κλίσης, βελτιστοποίηση, παράμετρος μοντέλου, βήμα κλίσης, προβολή.

πρόβλημα βελτιστοποίησης Ένα πρόβλημα βελτιστοποίησης (optimization problem) είναι μία μαθηματική δομή που αποτελείται από μία αντικειμενική συνάρτηση $f : \mathcal{U} \rightarrow \mathcal{V}$ ορισμένη πάνω σε μία μεταβλητή βελτιστοποίησης $w \in \mathcal{U}$, μαζί με ένα εφικτό σύνολο $\mathcal{W} \subseteq \mathcal{U}$. Το πεδίο τιμών $\mathcal{V}$ θεωρείται ότι είναι διατεταγμένο, που σημαίνει ότι για οποιαδήποτε δύο στοιχεία $\mathbf{a}, \mathbf{b} \in \mathcal{V}$, μπορούμε να καθορίσουμε αν $\mathbf{a} \leq \mathbf{b}$. Εδώ ' $\leq$ ' δηλώνει μία γενική σχέση μερικής διάταξης, η οποία μπορεί να διαφέρει από την εγγενή διάταξη των πραγματικών αριθμών [36, Ενότητα 2.4]. Ο στόχος

στη βελτιστοποίηση είναι να βρεθούν εκείνες οι τιμές $\hat{\mathbf{w}} \in \mathcal{W}$ για τις οποίες η αντικειμενική $f(\mathbf{w})$ είναι ακρότατη, δηλαδή είτε ελάχιστη είτε μέγιστη [36], [57], [58].

Βλέπε επίσης: βελτιστοποίηση, αντικειμενική συνάρτηση, co-domain.

πρόβλημα κυρτής βελτιστοποίησης Βλέπε κυρτή βελτιστοποίηση.

προβολή Θεωρούμε ένα φραγμένο υποσύνολο $\mathcal{W} \subseteq \mathbb{R}^d$ του d -διάστατου Ευκλείδειου χώρου. Ορίζουμε την προβολή (projection) $P_{\mathcal{W}}(\mathbf{w})$ ενός διανύσματος $\mathbf{w} \in \mathbb{R}^d$ στο $\mathcal{W}$ ως

$$P_{\mathcal{W}}(\mathbf{w}) = \arg \min_{\mathbf{w}' \in \mathcal{W}} \|\mathbf{w} - \mathbf{w}'\|_2.$$

Με άλλα λόγια, η $P_{\mathcal{W}}(\mathbf{w})$ είναι το διάνυσμα στο $\mathcal{W}$ που είναι πιο κοντά στο $\mathbf{w}$. Η προβολή είναι καλά ορισμένη μόνο για υποσύνολα $\mathcal{W}$ για τα οποία υφίσταται το παραπάνω ελάχιστο [36].

Βλέπε επίσης: Ευκλείδειος χώρος, διάνυσμα, ελάχιστο.

προεικόνα Θεωρούμε μία συνάρτηση $f: \mathcal{U} \rightarrow \mathcal{V}$ μεταξύ δύο συνόλων. Η προεικόνα (preimage) $f^{-1}(\mathcal{B})$ ενός υποσυνόλου $\mathcal{B} \subseteq \mathcal{V}$ είναι το σύνολο όλων των εισόδων $u \in \mathcal{U}$ που αντιστοιχίζονται στο $\mathcal{B}$ από την f , δηλαδή

$$f^{-1}(\mathcal{B}) := \{u \in \mathcal{U} \mid f(u) \in \mathcal{B}\}.$$

Η προεικόνα είναι καλά ορισμένη ακόμα και αν η συνάρτηση f είναι μη αντιστρέψιμη [2].

Βλέπε επίσης: συνάρτηση.

προσδοκία υπό συνθήκη TBC.

ροπογεννήτρια συνάρτηση TBC.

σ -άλγεβρα TBC.

σ -σώμα Βλέπε σ -άλγεβρα.

σταθερό σημείο TBC.

σταθμισμένος γράφος TBC.

στοχαστική Αναφερόμαστε σε μία μέθοδο ως στοχαστική (stochastic) αν περιλαμβάνει μία τυχαία συνιστώσα ή διέπεται από πιθανοτικούς νόμους. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν τυχειότητα για να μειώσουν την υπολογιστική πολυπλοκότητα (π.χ. βλέπε στοχαστική κάθοδος κλίσης) ή για να αποτυπώσουν την αβεβαιότητα σε πιθανοτικά μοντέλα.

Βλέπε επίσης: μηχανική μάθηση, στοχαστική κάθοδος κλίσης, αβεβαιότητα, πιθανοτικό μοντέλο.

στοχαστική διαδικασία Μία στοχαστική διαδικασία (stochastic process) είναι μία συλλογή τυχαίων μεταβλητών που ορίζονται πάνω σε έναν κοινό χώρο πιθανοτήτων και που έχουν δείκτες από κάποιο σύνολο $\mathcal{I}$ [10], [51], [66]. Το σύνολο δεικτών $\mathcal{I}$ συνήθως αναπαριστά χρόνο και χώρο, επιτρέποντάς μας να αναπαραστήσουμε τυχαία φαινόμενα που εξελίσσονται στον χρόνο ή σε χωρικές διαστάσεις—για παράδειγμα, θόρυβο αισθητήρα ή οικονομικές χρονοσειρές. Οι στοχαστικές διαδικασίες δεν περιορίζονται σε χρονικά ή χωρικά περιβάλλοντα. Για παράδειγμα, τυχαίοι γράφοι όπως


ο γράφος Erdős–Rényi ή το μοντέλο στοχαστικής ομάδας μπορούν επίσης να θεωρηθούν στοχαστικές διαδικασίες. Εδώ το σύνολο δεικτών $\mathcal{I}$ αποτελείται από ζεύγη κόμβων που ευρετηριάζουν τυχαίες μεταβλητές των οποίων οι τιμές κωδικοποιούν την παρουσία ή το βάρος μίας ακμής μεταξύ δύο κόμβων. Επιπλέον, οι στοχαστικές διαδικασίες προκύπτουν φυσικά στην ανάλυση στοχαστικών αλγόριθμων, όπως η στοχαστική κάθοδος κλίσης, οι οποίοι κατασκευάζουν μία ακολουθία τυχαίων μεταβλητών. Βλέπε επίσης: στοχαστική, τυχαία μεταβλητή, χώρος πιθανοτήτων, γράφος, γράφος Erdős–Rényi, μοντέλο στοχαστικής ομάδας, στοχαστικός αλγόριθμος, στοχαστική κάθοδος κλίσης, ακολουθία, αβεβαιότητα, πιθανοτικό μοντέλο.

σύγκλιση Θεωρούμε μία ακολουθία $(a_r)_{r \in \mathbb{N}}$ με αριθμητικές τιμές $a_r \in \mathbb{R}$. Λέμε ότι αυτή η ακολουθία συγκλίνει σε μία τιμή a^* αν οι τιμές a_r γίνονται αυθαίρετα κοντινές στην a^* για επαρκώς μεγάλους δείκτες r . Από μαθηματική άποψη, η ακολουθία συγκλίνει στην a^* αν [1], [2]

$$\forall \epsilon > 0, \exists N \in \mathbb{N} : r > N \Rightarrow |a_r - a^*| < \epsilon.$$

Δηλώνουμε τη σύγκλιση (convergence) μίας ακολουθίας στην a^* με

$$\lim_{r \rightarrow \infty} a_r = a^*.$$



Σχ. 22. Ακολουθία πραγματικής τιμής $(a_r)_{r \in \mathbb{N}}$ που συγκλίνει στο όριο $a^* = 1$.

Η έννοια της σύγκλισης μίας ακολουθίας πραγματικής τιμής (όπου $\mathcal{A} = \mathbb{R}$) επεκτείνεται φυσικά σε μία ακολουθία σε έναν αυθαίρετο μετρικό χώρο $\mathcal{A}$. Πράγματι, χρειάζεται απλώς να αντικαταστήσουμε την απόλυτη διαφορά $|a_r - a^*|$ με τη μετρική $d(a_r, a^*)$. Σημείωση ότι μία ακολουθία μπορεί να συγκλίνει μόνο αν είναι μία ακολουθία Cauchy [2]. Ωστόσο, δε συγκλίνει κάθε ακολουθία Cauchy, εκτός αν ο υποκείμενος μετρικός χώρος είναι πλήρης.

Βλέπε επίσης: ακολουθία, μετρικός χώρος, μετρική, ακολουθία Cauchy.

συζυγής ανάστροφος TBC.


συζυγής εκ των προτέρων κατανομή TBC.

συμμετρικός πίνακας TBC.

συνάρτηση Μία συνάρτηση (function) μεταξύ δύο συνόλων $\mathcal{U}$ και $\mathcal{V}$ αποδίδει σε κάθε στοιχείο $u \in \mathcal{U}$ ακριβώς ένα στοιχείο $f(u) \in \mathcal{V}$ [2]. Το γράφουμε αυτό ως

$$f : \mathcal{U} \rightarrow \mathcal{V} : u \mapsto f(u),$$

όπου $\mathcal{U}$ είναι το πεδίο ορισμού και $\mathcal{V}$ το πεδίο τιμών της f . Για την ακρίβεια, η συνάρτηση f ορίζει μία μοναδική έξοδο $f(u) \in \mathcal{V}$ για κάθε είσοδο $u \in \mathcal{U}$ (βλέπε Σχ. 23).



Σχ. 23. Συνάρτηση $f: \mathcal{U} \rightarrow \mathcal{V}$ που αντιστοιχίζει κάθε στοιχείο του πεδίου ορισμού $\mathcal{U} = \{a, b, c\}$ σε ακριβώς ένα στοιχείο του πεδίου τιμών $\mathcal{V} = \{\star, \circ, \otimes\}$.

Βλέπε επίσης: πεδίο ορισμού, co-domain, έξοδος.

συνάρτηση μάζας πιθανότητας TBC.

συνάρτηση μάζας πιθανότητας υπό συνθήκη TBC.

συνάρτηση πιθανοφάνειας Η συνάρτηση πιθανοφάνειας (likelihood function) ενός πιθανοτικού μοντέλου με παραμέτρους $\mathbf{w}$ προκύπτει από την αξιολόγηση της συνάρτησης πυκνότητας πιθανότητας (ή της συνάρτησης μάζας πιθανότητας) για το παρατηρούμενο σύνολο δεδομένων [20], [67]. Πιο συγκεκριμένα, θεωρούμε ένα σύνολο δεδομένων $\mathcal{D}' = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$ που υποτίθεται ότι έχει παραχθεί μέσω ανεξάρτητων και ταυτόσημων κα-

τανεμημένων τυχαίων μεταβλητών με κοινή συνάρτηση πυκνότητας πιθανότητας $p^{(\mathbf{z}; \mathbf{w})}(\cdot)$. Η κοινή συνάρτηση πυκνότητας πιθανότητας παραμετροποιείται από τις παραμέτρους του μοντέλου $\mathbf{w}$. Η συνάρτηση πιθανοφάνειας ορίζεται τότε ως $L^{(\mathcal{D}')}(\mathbf{w}) = \prod_{r=1}^m p^{(\mathbf{z}; \mathbf{w})}(\mathbf{z}^{(r)})$. Η συνάρτηση πιθανοφάνειας μπορεί να χρησιμοποιηθεί για την κατασκευή μίας συνάρτησης απώλειας για την ελαχιστοποίηση εμπειρικής διακινδύνευσης, κάτι που οδηγεί στη μέγιστη πιθανοφάνεια.

Βλέπε επίσης: συνάρτηση, πιθανοτικό μοντέλο, παράμετρος, συνάρτηση πυκνότητας πιθανότητας, συνάρτηση μάζας πιθανότητας, σύνολο δεδομένων, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, παράμετρος μοντέλου, συνάρτηση απώλειας, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μέγιστη πιθανοφάνεια.

συνάρτηση πυκνότητας πιθανότητας Η συνάρτηση πυκνότητας πιθανότητας (probability density function - pdf) $p^{(x)}(\cdot)$ μίας συνεχούς τυχαίας μεταβλητής πραγματικής τιμής $x \in \mathbb{R}$ μας επιτρέπει να υπολογίσουμε την πιθανότητα $\mathbb{P}(x \in \mathcal{B})$ (του γεγονότος $\mathcal{B} \subseteq \mathbb{R}$) μέσω ενός ολοκληρώματος Lebesgue ως εξής [7, Κεφ. 3]:

$$\mathbb{P}(x \in \mathcal{B}) = \int_{\mathcal{B}} p^{(x)}(\eta) d\eta.$$

Αυτός ο ορισμός επεκτείνεται φυσικά σε μία (συνεχή) τυχαία μεταβλητή διανυσματικής τιμής $\mathbf{x} \in \mathbb{R}^d$, καθώς το ολοκλήρωμα Lebesgue ορίζεται για τον $\mathbb{R}^d$ με οποιαδήποτε διάσταση d .

Βλέπε επίσης: συνεχής, τυχαία μεταβλητή, πιθανότητα, γεγονός, ολοκλήρωμα Lebesgue, διάνυσμα, διάσταση, κατανομή πιθανότητας, μετρήσι-


μο.

συνάρτηση συνδιακύμανσης Μία συνάρτηση συνδιακύμανσης (covariance function) χαρακτηρίζει τη δομή εξάρτησης δεύτερης τάξης μίας στοχαστικής διαδικασίας. Για μία στοχαστική διαδικασία πραγματικής τιμής $\{x(t)\}_{t \in \mathcal{I}}$ με πεπερασμένες ροπές δεύτερης τάξης, η συνάρτηση συνδιακύμανσης ορίζεται ως [68]

$$\begin{aligned} \text{cov}^{(x)}(t, t') &:= \text{cov}(x(t), x(t')) \\ &= \mathbb{E}[(x(t) - \mathbb{E}[x(t)])(x(t') - \mathbb{E}[x(t')])], \quad t, t' \in \mathcal{I}. \end{aligned}$$

Βλέπε επίσης: συνδιακύμανση, συνάρτηση, στοχαστική διαδικασία.

συνδεδεμένος Ένας μη κατευθυνόμενος γράφος $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ είναι συνδεδεμένος (connected) αν, για κάθε μη κενό υποσύνολο $\mathcal{V}' \subset \mathcal{V}$, μπορούμε να βρούμε τουλάχιστον μία ακμή που συνδέει έναν κόμβο στο $\mathcal{V}'$ με κάποιον κόμβο στο $\mathcal{V} \setminus \mathcal{V}'$. Παρουσιάζουμε δύο παραδείγματα μη κατευθυνόμενων γράφων στο Σχ. 24.



Σχ. 24. (a) Μη συνδεδεμένος γράφος. (b) Συνδεδεμένος γράφος.


Βλέπε επίσης: μη κατευθυνόμενος γράφος, γράφος, αλγεβρική συνδεσι-

μότητα.

συνδιακύμανση Η συνδιακύμανση (covariance) μεταξύ δύο τυχαίων μεταβλητών πραγματικών τιμών x και y , ορισμένων σε έναν κοινό χώρο πιθανοτήτων, μετράει τη γραμμική τους εξάρτηση. Ορίζεται ως

$$\text{cov}(x, y) = \mathbb{E}\{(x - \mathbb{E}\{x\})(y - \mathbb{E}\{y\})\}.$$

Μία θετική συνδιακύμανση υποδεικνύει ότι οι x και y τείνουν να αυξάνονται μαζί, ενώ μία αρνητική συνδιακύμανση υποδηλώνει ότι η μία τείνει να αυξάνεται καθώς η άλλη μειώνεται. Αν $\text{cov}(x, y) = 0$, οι τυχαίες μεταβλητές λέγεται ότι είναι μη συσχετισμένες, αν και όχι απαραίτητα στατιστικά ανεξάρτητες. Βλέπε Σχ. 25 για οπτικές απεικονίσεις.




Σχ. 25. Διαγράμματα διασποράς που απεικονίζουν πραγματώσεις από τρία διαφορετικά πιθανοτικά μοντέλα για δύο τυχαίες μεταβλητές με διαφορετικές τιμές συνδιακύμανσης. (a) Αρνητική. (b) Μηδενική. (c) Θετική.

Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, διάγραμμα διασποράς, πραγμάτωση, πιθανοτικό μοντέλο, προσδοκία.

συνέχεια κατά Lipschitz Μία συνάρτηση μεταξύ δύο μετρικών χώρων είναι συνεχής κατά Lipschitz (Lipschitz continuity) αν υφίσταται μία σταθερά $L > 0$ τέτοια ώστε η απόσταση μεταξύ των τιμών της συνάρτησης σε οποιαδήποτε δύο σημεία είναι το πολύ L φορές η απόσταση μεταξύ των σημείων αυτών [35].

Βλέπε επίσης: συνάρτηση, μετρικός χώρος, συνεχής, απόσταση, διάνυσμα.

συνεχής Μία συνάρτηση $f : \mathbb{R}^d \rightarrow \mathbb{R}$ είναι συνεχής (continuous) σε ένα σημείο $\mathbf{x}' \in \mathbb{R}^d$ αν, για κάθε $\epsilon > 0$, υπάρχει $\delta > 0$ έτσι ώστε, για κάθε $\mathbf{x} \in \mathbb{R}^d$ με $\|\mathbf{x} - \mathbf{x}'\|_2 < \delta$, ισχύει ότι $|f(\mathbf{x}) - f(\mathbf{x}')| < \epsilon$ [2]. Με άλλα λόγια, μπορούμε να κάνουμε την $f(\mathbf{x})$ αυθαίρετα κοντά στην $f(\mathbf{x}')$ επιλέγοντας το $\mathbf{x}$ αρκετά κοντά στο $\mathbf{x}'$.



Σχ. 26. Συνάρτηση $f(x) = 0.3(x - 2)^3 + 2.5$, συνεχής σε κάθε x' .


Αν η f είναι συνεχής σε κάθε σημείο $\mathbf{x}' \in \mathbb{R}^d$, τότε η f λέγεται ότι είναι συνεχής στον $\mathbb{R}^d$. Η έννοια της συνεχούς συνάρτησης μπορεί να επεκταθεί φυσικά σε συναρτήσεις μεταξύ γενικών μετρικών χώρων [2].
Βλέπε επίσης: συνάρτηση, μετρικός χώρος, Ευκλείδειος χώρος, μετρική.

συνθήκες Karush–Kuhn–Tucker (συνθήκες KKT) TBC.

συστολικός τελεστής Ένας τελεστής $\mathcal{F} : \mathcal{V} \rightarrow \mathcal{V}$ σε έναν χώρο με νόρμα $(\mathcal{V}, \|\cdot\|)$ λέγεται συστολή (ή συστολικός (contractive operator)) αν, για κάποιον $\kappa \in [0, 1)$, [17], [69]

$$\|\mathcal{F}\mathbf{w} - \mathcal{F}\mathbf{w}'\| \leq \kappa \|\mathbf{w} - \mathbf{w}'\| \quad \text{ισχύει για οποιαδήποτε } \mathbf{w}, \mathbf{w}' \in \mathcal{V}.$$

Η έννοια του συστολικού τελεστή γενικεύεται φυσικά από χώρους με νόρμα σε αυθαίρετους μετρικούς χώρους [69].



Σχ. 27. Συστολικός τελεστής $\mathcal{F} : \mathcal{X} \rightarrow \mathcal{X}$ με ένα μοναδικό σταθερό σημείο $\mathbf{x}^*$ που ικανοποιεί $\mathcal{F}\mathbf{x}^* = \mathbf{x}^*$. Για οποιαδήποτε δύο σημεία $\mathbf{x}, \mathbf{x}'$ στον ίδιο χώρο, η απόσταση μεταξύ των εικόνων τους $\mathcal{F}\mathbf{x}$ και $\mathcal{F}\mathbf{x}'$ είναι αυστηρά μικρότερη.

Ενστικτωδώς, ένας συστολικός τελεστής φέρνει οποιαδήποτε δύο σημεία από το πεδίο ορισμού του πιο κοντά μεταξύ τους τουλάχιστον κατά έναν

παράγοντα κ .

Βλέπε επίσης: τελεστής, μετρικός χώρος, σταθερό σημείο, απόσταση, πεδίο ορισμού.

σώμα Ένα σώμα (field) $(\mathbb{F}, +, \cdot)$ είναι μία αλγεβρική δομή που γενικεύει τους πραγματικούς και τους μιγαδικούς αριθμούς. Τυπικά, ένα σώμα αποτελείται από ένα σύνολο $\mathbb{F}$ εξοπλισμένο με δύο δυαδικές πράξεις, μία πρόσθεση $\oplus$ και έναν πολλαπλασιασμό $\odot$, όπου το $(\mathbb{F}, \oplus)$ είναι μία αβελιανή ομάδα με ένα στοιχείο ταυτότητας 0 και το $(\mathbb{F} \setminus \{0\}, \odot)$ είναι μία αβελιανή ομάδα με ένα στοιχείο ταυτότητας 1 . Επιπλέον, ικανοποιείται η επιμεριστικότητα, δηλαδή $a \odot (b \oplus c) = (a \odot b) \oplus (a \odot c)$ για κάθε $a, b, c \in \mathbb{F}$. Τα πιο συνήθη παραδείγματα είναι τα $(\mathbb{R}, +, \cdot)$ και $(\mathbb{C}, +, \cdot)$, με την πρόσθεση και τον πολλαπλασιασμό με τη συνηθισμένη έννοια. Τα σώματα παρέχουν το σύνολο των βαθμωτών που απαιτούνται για τον ορισμό ενός διανυσματικού χώρου.

Βλέπε επίσης: ομάδα, διανυσματικός χώρος, υποχώρος, Ευκλείδειος χώρος, εσωτερικό γινόμενο.

τάξη Η τάξη (rank) ενός πίνακα $\mathbf{A} \in \mathbb{R}^{m \times d}$, που δηλώνεται με $\text{rank } \mathbf{A}$, είναι ο μέγιστος αριθμός γραμμικά ανεξάρτητων στηλών του $\mathbf{A}$ [30]. Ισοδύναμα, η τάξη μπορεί να οριστεί ως η διάσταση του χώρου στηλών $\text{span}(\mathbf{A}) = \{\mathbf{A}\mathbf{w} \text{ για κάποιο } \mathbf{w} \in \mathbb{R}^d\}$. Η τάξη ενός πίνακα $\mathbf{A} \in \mathbb{R}^{m \times d}$ δεν μπορεί να υπερβαίνει ούτε τον αριθμό των γραμμών ούτε τον αριθμό των στηλών του $\mathbf{A}$ [31], [70], δηλαδή $\text{rank } \mathbf{A} \leq \min\{m, d\}$.

Βλέπε επίσης: πίνακας, μέγιστο, γραμμικά ανεξάρτητο, διάσταση, χώρος στηλών, γραμμική απεικόνιση.


τελεστής Ένας τελεστής (operator) είναι μία συνάρτηση της οποίας το πεδίο ορισμού και το πεδίο τιμών διαθέτουν μία συγκεκριμένη μαθηματική δομή, όπως ένας διανυσματικός χώρος, ένας χώρος Hilbert, ή ένας μετρικός χώρος [38], [71]. Πολλές μέθοδοι μηχανικής μάθησης περιλαμβάνουν τελεστές των οποίων το πεδίο ορισμού και το πεδίο τιμών είναι Ευκλείδειοι χώροι.

Βλέπε επίσης: συνάρτηση, πεδίο ορισμού, co-domain, διανυσματικός χώρος, χώρος Hilbert, μετρικός χώρος, μηχανική μάθηση, Ευκλείδειος χώρος.

τελεστής εγγύτητας Δεδομένης μίας κυρτής συνάρτησης $f(\mathbf{w}')$, ορίζουμε τον τελεστή εγγύτητάς της ως [17], [71]

$$\text{prox}_{f(\cdot)}(\mathbf{w})\rho := \arg \min_{\mathbf{w}' \in \mathbb{R}^d} \left[f(\mathbf{w}') + \frac{\rho}{2} \|\mathbf{w} - \mathbf{w}'\|_2^2 \right] \text{ με } \rho > 0.$$

Όπως απεικονίζεται στο Σχ. 28, η αξιολόγηση του τελεστή εγγύτητας ισοδυναμεί με την ελαχιστοποίηση μίας παραλλαγής της $f(\mathbf{w}')$ που έχει επιβληθεί ως ποινή. Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια απόσταση σε ένα δεδομένο διάνυσμα $\mathbf{w}$ (το οποίο είναι η είσοδος στον τελεστή εγγύτητας). Ο τελεστής εγγύτητας μπορεί να ερμηνευτεί ως μία γενίκευση του βήματος κλίσης, το οποίο ορίζεται ως μία λεία κυρτή συνάρτηση $f(\mathbf{w}')$. Πράγματι, η εκτέλεση ενός βήματος κλίσης με μέγεθος βήματος η στο τρέχον διάνυσμα $\mathbf{w}$ είναι το ίδιο με την εφαρμογή του τελεστή εγγύτητας της συνάρτησης $\tilde{f}(\mathbf{w}') = (\nabla f(\mathbf{w}))^T (\mathbf{w}' - \mathbf{w})$ και τη χρήση $\rho = 1/\eta$.



Σχ. 28. Ο τελεστής εγγύτητας ενημερώνει ένα διάνυσμα $\mathbf{w}$ ελαχιστοποιώντας μία εκδοχή της συνάρτησης $f(\cdot)$ που έχει επιβληθεί ως ποινή. Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια απόσταση μεταξύ της μεταβλητής βελτιστοποίησης $\mathbf{w}'$ και του δεδομένου διανύσματος $\mathbf{w}$.

Βλέπε επίσης: κυρτό, συνάρτηση, διάνυσμα, γενίκευση, βήμα κλίσης, λεία, μέγεθος βήματος.

τυπική απόκλιση Η τυπική απόκλιση (standard deviation) μίας τυχαίας μεταβλητής πραγματικής τιμής x ορίζεται ως η τετραγωνική ρίζα της διακύμανσής της, δηλαδή $\sqrt{\mathbb{E}\{(x - \mathbb{E}\{x\})^2\}}$.

Βλέπε επίσης: τυχαία μεταβλητή, διακύμανση, προσδοκία.

τυπικό κανονικό τυχαίο διάνυσμα Ένα τυπικό κανονικό τυχαίο διάνυσμα (standard normal random vector) είναι μία τυχαία μεταβλητή $\mathbf{x} = (x_1, \dots, x_d)^T$ της οποίας οι καταχωρίσεις είναι ανεξάρτητες και ταυτόσημα κατανομημένες Γκαουσιανές τυχαίες μεταβλητές $x_j \sim \mathcal{N}(0, 1)$. Η κατανομή πιθανότητας ενός τυπικού κανονικού τυχαίου διανύσματος αποτελεί μία ειδική περίπτωση πολυμεταβλητής κανονικής κατανομής $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Βλέπε επίσης: διάνυσμα, τυχαία μεταβλητή, ανεξάρτητες και ταυτόσημα κατανομημένες, Γκαουσιανή τυχαία μεταβλητή, κατανομή πιθανότητας, πολυμεταβλητή κανονική κατανομή.

τυπικό σύνολο Βλέπε συνάρτηση μάζας πιθανότητας.

τυχαία μεταβλητή Μία τυχαία μεταβλητή (random variable - RV) είναι μία συνάρτηση που αντιστοιχίζει τις εκβάσεις ενός τυχαίου πειράματος σε στοιχεία ενός μετρήσιμου χώρου [6], [51]. Από μαθηματική άποψη, μία τυχαία μεταβλητή είναι μία συνάρτηση $x : \Omega \rightarrow \mathcal{X}$ της οποίας το πεδίο ορισμού είναι ο δειγματικός χώρος Ω ενός χώρου πιθανοτήτων και της οποίας το πεδίο τιμών είναι ένας μετρήσιμος χώρος $\mathcal{X}$. Διαφορετικοί τύποι τυχαίων μεταβλητών περιλαμβάνουν

- δυαδικές τυχαίες μεταβλητές, οι οποίες αντιστοιχίζουν κάθε έκβαση σε ένα στοιχείο ενός δυαδικού συνόλου (π.χ. $\{-1, 1\}$ ή $\{\text{γάτα}, \text{όχι γάτα}\}$).
- διακριτές τυχαίες μεταβλητές, οι οποίες παίρνουν τιμές σε ένα αριθμήσιμο σύνολο (το οποίο μπορεί να είναι πεπερασμένο ή αριθμήσιμα άπειρο).
- τυχαίες μεταβλητές πραγματικής τιμής, οι οποίες παίρνουν τιμές στους πραγματικούς αριθμούς $\mathbb{R}$.
- τυχαίες μεταβλητές διανυσματικής τιμής, οι οποίες αντιστοιχίζουν εκβάσεις στον Ευκλείδειο χώρο $\mathbb{R}^d$.


Η θεωρία πιθανοτήτων χρησιμοποιεί την έννοια των μετρήσιμων χώρων για να ορίσει ενδελεχώς και να μελετήσει τις ιδιότητες συλλογών τυχαίων

μεταβλητών [6].

Βλέπε επίσης: συνάρτηση, έκβαση, τυχαίο πείραμα, μετρήσιμο, πεδίο ορισμού, δειγματικός χώρος, χώρος πιθανοτήτων, co-domain, διακριτή τυχαία μεταβλητή, αριθμήσιμο, διάνυσμα, Ευκλείδειος χώρος, πιθανότητα.

τυχαίος γεωμετρικός γράφος TBC.

τυχαίο πείραμα Ένα τυχαίο πείραμα (random experiment) είναι μία φυσική (ή αφηρημένη) διαδικασία που παράγει μία έκβαση ω από ένα σύνολο Ω πιθανοτήτων. Αυτό το σύνολο όλων των πιθανών εκβάσεων αναφέρεται ως ο δειγματικός χώρος του πειράματος. Το κύριο χαρακτηριστικό ενός τυχαίου πειράματος είναι ότι η έκβασή του είναι απρόβλεπτη (ή αβέβαιη). Οποιαδήποτε μέτρηση ή παρατήρηση της έκβασης είναι μία τυχαία μεταβλητή, δηλαδή μία συνάρτηση της έκβασης $\omega \in \Omega$. Η θεωρία πιθανοτήτων χρησιμοποιεί έναν χώρο πιθανοτήτων ως μία μαθηματική δομή για τη μελέτη τυχαίων πειραμάτων. Μία κύρια εννοιολογική ιδιότητα ενός τυχαίου πειράματος είναι ότι μπορεί να επαναληφθεί υπό ταυτόσημες συνθήκες. Αυστηρά μιλώντας, η επανάληψη ενός τυχαίου πειράματος έναν δεδομένο αριθμό m φορές ορίζει ένα νέο τυχαίο πείραμα. Οι εκβάσεις αυτού του νέου πειράματος είναι ακολουθίες μήκους m εκβάσεων από το αρχικό πείραμα (βλέπε Σχ. 29). Ενώ η έκβαση ενός μοναδικού πειράματος είναι αβέβαιη, η μακροπρόθεσμη συμπεριφορά των εκβάσεων επαναλαμβανόμενων πειραμάτων τείνει να γίνεται ολοένα και περισσότερο προβλέψιμη. Αυτός ο ανεπίσημος ισχυρισμός μπορεί να γίνει ακριβής μέσω θεμελιωδών αποτελεσμάτων της θεωρίας πιθανοτήτων, όπως ο νόμος των μεγάλων αριθμών και το κεντρικό οριακό θεώρημα.



Σχ. 29. Τυχαίο πείραμα που παράγει μία έκβαση $\omega \in \Omega$ από ένα σύνολο πιθανοτήτων (δηλαδή ένα δειγματικό χώρο) Ω . Η επανάληψη του πειράματος m φορές αποφέρει ένα άλλο τυχαίο πείραμα, του οποίου οι εκβάσεις είναι ακολουθίες $(\omega^{(1)}, \omega^{(2)}, \dots, \omega^{(m)}) \in \Omega \times \dots \times \Omega$. Ένα παράδειγμα τυχαίου πειράματος που προκύπτει σε πολλές εφαρμογές μηχανικής μάθησης είναι η συγκέντρωση ενός συνόλου εκπαίδευσης $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$.

Παραδείγματα τυχαίων πειραμάτων που προκύπτουν σε εφαρμογές μηχανικής μάθησης περιλαμβάνουν τα εξής:

- Συλλογή δεδομένων: Τα σημεία δεδομένων που συλλέγονται σε μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης μπορούν να ερμηνευτούν ως τυχαίες μεταβλητές, δηλαδή ως συναρτήσεις της έκβασης $\omega \in \Omega$ ενός τυχαίου πειράματος.
- Η στοχαστική κάθοδος κλίσης χρησιμοποιεί ένα τυχαίο πείραμα σε κάθε επανάληψη για την επιλογή ενός υποσυνόλου του συνόλου εκπαίδευσης.

- Οι μέθοδοι προστάσιας της ιδιωτικότητας χρησιμοποιούν τυχαία πειράματα για διαταράζουν τις εξόδους μίας μεθόδου μηχανικής μάθησης, ώστε να εξασφαλίζεται η διαφορική ιδιωτικότητα.

Βλέπε επίσης: έκβαση, δειγματικός χώρος, τυχαία μεταβλητή, συνάρτηση, πιθανότητα, χώρος πιθανοτήτων, ακολουθία, νόμος των μεγάλων αριθμών, κεντρικό οριακό θεώρημα, μηχανική μάθηση, σύνολο εκπαίδευσης, δεδομένα, σημείο δεδομένων, ελαχιστοποίηση εμπειρικής διακινδύνευσης, στοχαστική κάθοδος κλίσης, επανάληψη, προστάσια της ιδιωτικότητας, έξοδος, διαφορική ιδιωτικότητα.

υπερεπίπεδο Ένα υπερεπίπεδο (hyperplane) είναι ένας $(d - 1)$ -διάστατος αφινικός υποχώρος ενός d -διάστατου διανυσματικού χώρου. Στο πλαίσιο ενός Ευκλείδειου χώρου $\mathbb{R}^d$, ένα υπερεπίπεδο είναι ένα σύνολο της ακόλουθης μορφής:

$$\{\mathbf{x} \in \mathbb{R}^d : \mathbf{w}^\top \mathbf{x} = b\},$$

όπου $\mathbf{w} \in \mathbb{R}^d \setminus \{0\}$ είναι ένα κάθετο διάνυσμα και $b \in \mathbb{R}$ είναι μια μετατόπιση. Ένα τέτοιο υπερεπίπεδο διαιρεί τον $\mathbb{R}^d$ σε δύο ημιχώρους:

$$\{\mathbf{x} \in \mathbb{R}^d : \mathbf{w}^\top \mathbf{x} > b\} \quad \text{και} \quad \{\mathbf{x} \in \mathbb{R}^d : \mathbf{w}^\top \mathbf{x} < b\}.$$

Τα υπερεπίπεδα ανακύπτουν ως όρια απόφασης γραμμικών ταξινομητών. Βλέπε επίσης: υποχώρος, διανυσματικός χώρος, Ευκλείδειος χώρος, διάνυσμα, ημιχώρος, όριο απόφασης, γραμμικός ταξινομητής, εσωτερικό γινόμενο.

υποκλίση Για μία συνάρτηση πραγματικής τιμής $f : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{w} \mapsto f(\mathbf{w})$,

ένα διάνυσμα $\mathbf{a}$ τέτοιο ώστε $f(\mathbf{w}) \geq f(\mathbf{w}') + (\mathbf{w} - \mathbf{w}')^T \mathbf{a}$ αναφέρεται ως μία υποκλίση (subgradient) της f στο $\mathbf{w}'$ [57], [72].

Βλέπε επίσης: συνάρτηση, διάνυσμα.

υποστηρίζον υπερεπίπεδο TBC.

υποχώρος Ένα υποσύνολο ενός διανυσματικού χώρου $\mathcal{V}$ είναι ένας υποχώρος (subspace) του $\mathcal{V}$ αν είναι επίσης διανυσματικός χώρος ως προς τις ίδιες πράξεις με τον $\mathcal{V}$. Το Σχ. 30 το απεικονίζει αυτό για τον διανυσματικό χώρο $\mathbb{R}^2$ (πάνω στο σώμα $\mathbb{R}$).




Fig. 30. Κάθε $\mathbf{x} \in \mathbb{R}^2$ ορίζει έναν υποχώρο $\mathcal{U}_{\mathbf{x}} \subset \mathbb{R}^2$ με $\mathcal{U}_{\mathbf{x}} = \{\lambda \cdot \mathbf{x} : \lambda \in \mathbb{R}\} \subset \mathbb{R}^2$. Για $\mathbf{x} \neq \mathbf{0}$, αυτό αντιστοιχεί σε ευθείες γραμμές που διέρχονται από την αρχή των αξόνων (απεικονίζονται με $\mathcal{U}_1$ και $\mathcal{U}_2$). Για το μηδενικό διάνυσμα $\mathbf{x} = \mathbf{0}$, αυτό οδηγεί στον τετριμμένο υποχώρο $\{\mathbf{0}\}$ που περιέχει μόνο το μηδενικό διάνυσμα.

Βλέπε επίσης: διανυσματικός χώρος, σώμα, διάνυσμα, διάσταση, βάση.

φάσμα Το φάσμα (spectrum) ενός γραμμικού τελεστή $\mathcal{F}$ είναι το σύνολο των τιμών λ για τις οποίες ο τελεστής $\mathcal{F} - \lambda \text{Id}$ δεν καταφέρνει να είναι αντιστρέψιμος [73]. Η έννοια του φάσματος μπορεί στη συνέχεια να επεκταθεί

φυσικά σε κάθε είδους αντικείμενο για το οποίο μπορεί να οριστεί ένας σχετικός γραμμικός τελεστής. Για παράδειγμα, το φάσμα ενός τετραγωνικού πίνακα $\mathbf{A} \in \mathbb{R}^{d \times d}$ προκύπτει μέσω του φάσματος του σχετικού γραμμικού τελεστή [31]. Ως ένα άλλο παράδειγμα, μπορούμε να ορίσουμε το φάσμα μίας στοχαστικής διαδικασίας μέσω ενός γραμμικού τελεστή που κατασκευάζεται από τη συνάρτηση συνδιακύμανσής της [68].
 Βλέπε επίσης: γραμμικός τελεστής, τελεστής, πίνακας, στοχαστική διαδικασία, συνάρτηση συνδιακύμανσης.

φασματική ανάλυση Μία ανάλυση ιδιοτιμών ενός κανονικού πίνακα ονομάζεται φασματική ανάλυση (spectral decomposition). Έχει την ιδιαίτερη ιδιότητα ότι τα ιδιοδιανύσματα του κανονικού πίνακα είναι ορθοκανονικά. Αυτό ισχύει και αντίστροφα, δηλαδή οποιοσδήποτε πίνακας που έχει ορθοκανονικά ιδιοδιανύσματα είναι ένας κανονικός πίνακας.
 Βλέπε επίσης: ανάλυση ιδιοτιμών, κανονικός πίνακας, ιδιοδιάνυσμα, πίνακας.

φράγμα Chernoff TBC.

χαρακτηριστική συνάρτηση Η χαρακτηριστική συνάρτηση (characteristic function) μίας τυχαίας μεταβλητής πραγματικής τιμής x είναι η ακόλουθη συνάρτηση [6, Ενότητα 26]:

$$\phi_x(t) := \mathbb{E} \exp(jtx) \quad \text{με } j = \sqrt{-1}.$$

Η χαρακτηριστική συνάρτηση προσδιορίζει μοναδικά την κατανομή πιθανότητας της x .

Βλέπε επίσης: συνάρτηση, τυχαία μεταβλητή, κατανομή πιθανότητας.

χάσμα δυϊκότητας Θεωρούμε ένα πρόβλημα βελτιστοποίησης με περιορισμούς με Λαγκρανζιανή

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f_0(\mathbf{x}) + \sum_{i=1}^k \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^l \nu_j g_j(\mathbf{x}).$$

Το δυϊκό πρόβλημα ορίζεται ως

$$\max_{\boldsymbol{\lambda} \in \mathbb{R}_+^k, \boldsymbol{\nu} \in \mathbb{R}^l} \underbrace{q(\boldsymbol{\lambda}, \boldsymbol{\nu})}_{:= \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu})}.$$

Έστω p^* η βέλτιστη τιμή του πρωτεύοντος προβλήματος και d^* η βέλτιστη τιμή του σχετικού δυϊκού προβλήματος. Το χάσμα δυϊκότητας (duality gap) ορίζεται ως

$$p^* - d^* \geq 0.$$

Το χάσμα δυϊκότητας είναι πάντα μη αρνητικό, ακόμα και για μη-κυρτά και μη λεία προβλήματα βελτιστοποίησης. Όταν το χάσμα δυϊκότητας είναι μηδέν, δηλαδή $p^* = d^*$, λέμε ότι ισχύει η ισχυρή δυϊκότητα [36, Κεφ. 5].

Βλέπε επίσης: πρόβλημα βελτιστοποίησης με περιορισμούς, Λαγκρανζιανή, δυϊκό πρόβλημα, κυρτό, μη λεία, πρόβλημα βελτιστοποίησης.

χώρος καταστάσεων Ο χώρος καταστάσεων (state space) ενός συστήματος αποτελείται από όλες τις πιθανές καταστάσεις του συστήματος σε οποιαδήποτε χρονική στιγμή.

Βλέπε επίσης: κατάσταση, διάνυσμα χαρακτηριστικών, υπόθεση, ενέργεια.

χώρος με νόρμα Ένας χώρος με νόρμα (normed space) είναι ένας διανυσματικός χώρος $\mathcal{V}$ εξοπλισμένος με μία νόρμα $\|\cdot\|$. Τυπικά, δηλώνεται ως το ζεύγος $(\mathcal{V}, \|\cdot\|)$. Κάθε χώρος με νόρμα είναι ένας μετρικός χώρος με την επαγόμενη μετρική που ορίζεται από $d(\mathbf{x}, \mathbf{x}') = \|\mathbf{x} - \mathbf{x}'\|$ για όλα τα $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$. Στη μηχανική μάθηση, οι χώροι με νόρμα αποτελούν ένα κοινό πλαίσιο για χώρους χαρακτηριστικών και παραμετρικούς χώρους, συνήθως τους Ευκλείδειους χώρους $\mathbb{R}^d$ με την Ευκλείδεια νόρμα. Βλέπε επίσης: διανυσματικός χώρος, νόρμα, μετρικός χώρος, μετρική, μηχανική μάθηση, χώρος χαρακτηριστικών, παραμετρικός χώρος, Ευκλείδειος χώρος, Ευκλείδεια νόρμα, χώρος Hilbert.

χώρος μέτρου Ένας χώρος μέτρου (measure space) είναι μία τριάδα (Ω, Σ, μ) που αποτελείται από ένα σύνολο Ω , μία σ -άλγεβρα Σ υποσυνόλων του Ω , και ένα μέτρο $\mu : \Sigma \rightarrow [0, \infty)$. Το μέτρο μ αποδίδει έναν μη αρνητικό αριθμό σε κάθε μετρήσιμο σύνολο $\mathcal{A} \in \Sigma$, γενικεύοντας τις έννοιες του μήκους, του εμβαδού, ή του όγκου σε Ευκλείδειους χώρους [2], [62]. Οι χώροι μέτρου παρέχουν τη μαθηματική θεμελίωση για το ολοκλήρωμα Lebesgue ή για τον ορισμό τυχαίων μεταβλητών ως μετρήσιμων αντιστοιχίσεων μεταξύ χώρων μέτρου. Ένας χώρος πιθανοτήτων είναι μία ειδική περίπτωση χώρου μέτρου όπου το συνολικό μέτρο του δειγματικού χώρου κανονικοποιείται στη μονάδα, δηλαδή $\mu(\Omega) = 1$. Σε αυτή την περίπτωση, το μ λέγεται κατανομή πιθανότητας. Βλέπε επίσης: μέτρο, σ -άλγεβρα, μετρήσιμο, Ευκλείδειος χώρος, ολοκλήρωμα Lebesgue, τυχαία μεταβλητή, χώρος πιθανοτήτων, δειγματικός χώρος, κατανομή πιθανότητας.

χώρος πιθανοτήτων Ένας χώρος πιθανοτήτων (probability space) είναι μία μαθηματική δομή που μας επιτρέπει να συλλογιστούμε για ένα τυχαίο πείραμα, π.χ. την παρατήρηση ενός φυσικού φαινομένου. Τυπικά, ένας χώρος πιθανοτήτων $\mathcal{P}$ είναι μία τριάδα $(\Omega, \mathcal{F}, \mathbb{P}(\cdot))$, όπου

- Ω είναι ένας δειγματικός χώρος που περιλαμβάνει όλες τις πιθανές εκβάσεις ενός τυχαίου πειράματος.
- $\mathcal{F}$ είναι μία σ -άλγεβρα, δηλαδή μία συλλογή υποσυνόλων του Ω (που ονομάζονται γεγονότα) που ικανοποιεί ορισμένες ιδιότητες κλειστότητας υπό πράξεις συνόλων.
- $\mathbb{P}(\cdot)$ είναι μία κατανομή πιθανότητας, δηλαδή μία συνάρτηση που αποδίδει μία πιθανότητα $\mathbb{P}(\mathcal{A}) \in [0, 1]$ σε κάθε γεγονός $\mathcal{A} \in \mathcal{F}$. Αυτή η συνάρτηση πρέπει να ικανοποιεί $\mathbb{P}(\Omega) = 1$ και $\mathbb{P}(\bigcup_{i=1}^{\infty} \mathcal{A}_i) = \sum_{i=1}^{\infty} \mathbb{P}(\mathcal{A}_i)$ για οποιαδήποτε αριθμήσιμη ακολουθία κατά ζεύγη ξένων γεγονότων $\mathcal{A}_1, \mathcal{A}_2, \dots$ στο $\mathcal{F}$.

Οι χώροι πιθανοτήτων παρέχουν τη θεμελίωση των πιθανοτικών μοντέλων που μπορούν να χρησιμοποιηθούν για να μελετηθεί η συμπεριφορά των μεθόδων μηχανικής μάθησης [6], [51], [74].

Βλέπε επίσης: πιθανότητα, τυχαίο πείραμα, δειγματικός χώρος, έκβαση, σ -άλγεβρα, γεγονός, κατανομή πιθανότητας, συνάρτηση, αριθμήσιμο, ακολουθία, πιθανοτικό μοντέλο, μηχανική μάθηση.

χώρος στηλών Ο χώρος στηλών (column space) ενός πίνακα $\mathbf{A} \in \mathbb{R}^{m \times d}$, που δηλώνεται με $\text{span}(\mathbf{A})$, είναι το σύνολο όλων των γραμμικών συν-

δυσασμών των στηλών του $\mathbf{A}$. Με άλλα λόγια,

$$\text{span}(\mathbf{A}) = \{\mathbf{A}\mathbf{w} : \mathbf{w} \in \mathbb{R}^d\}.$$


Ο χώρος στηλών $\text{span}(\mathbf{A})$ του πίνακα $\mathbf{A}$ είναι ένας υποχώρος του Ευκλείδειου χώρου $\mathbb{R}^m$.

Βλέπε επίσης: πίνακας, υποχώρος, Ευκλείδειος χώρος, διανυσματικός χώρος.

χώρος Hilbert Ένας χώρος Hilbert (Hilbert space) $\mathcal{H}$ είναι ένας πλήρης χώρος με εσωτερικό γινόμενο. Συνεπώς, ο $\mathcal{H}$ είναι ένας διανυσματικός χώρος εξοπλισμένος με ένα εσωτερικό γινόμενο $\langle \cdot, \cdot \rangle$. Το εσωτερικό γινόμενο επάγει μία νόρμα $\|\cdot\|_{\mathcal{H}}$ μέσω

$$\|\mathbf{w}\|_{\mathcal{H}} = \sqrt{\langle \mathbf{w}, \mathbf{w} \rangle}.$$

Επιπλέον, ο $\mathcal{H}$ είναι πλήρης, με την έννοια ότι κάθε ακολουθία Cauchy $(\mathbf{w}^{(r)})_{r \in \mathbb{N}}$ στον $\mathcal{H}$ συγκλίνει σε ένα όριο $\lim_{r \rightarrow \infty} \mathbf{w}^{(r)}$ που επίσης περιέχεται στον $\mathcal{H}$.



Σχ. 31. Για δύο διανύσματα μοναδιαίας νόρμας $\mathbf{u}, \mathbf{v} \in \mathbb{S}^{(d)} \subseteq \mathbb{R}^d$, το εσωτερικό γινόμενο $\langle \mathbf{u}, \mathbf{v} \rangle$ είναι ο συντελεστής αναπτύγματος για την προβολή του $\mathbf{v}$ στον υποχώρο $\{c\mathbf{u} : c \in \mathbb{R}\}$ που παράγεται από το $\mathbf{u}$. Η απόλυτη τιμή $|\langle \mathbf{u}, \mathbf{v} \rangle|$ μετράει τη νόρμα αυτής της προβολής.

Ένα σημαντικό παράδειγμα χώρου Hilbert είναι ο Ευκλείδειος χώρος $\mathbb{R}^d$ με το εσωτερικό γινόμενο $\langle \mathbf{w}, \mathbf{w}' \rangle = \mathbf{w}^\top \mathbf{w}'$.

Βλέπε επίσης: εσωτερικό γινόμενο, διανυσματικός χώρος, νόρμα, ακολουθία Cauchy, διάνυσμα, προβολή, υποχώρος, Ευκλείδειος χώρος.

ψευδοαντίστροφος Ο ψευδοαντίστροφος (pseudoinverse) Moore–Penrose $\mathbf{A}^+$ ενός πίνακα $\mathbf{X} \in \mathbb{R}^{m \times d}$ γενικεύει την έννοια ενός αντίστροφου πίνακα [3]. Ο ψευδοαντίστροφος ανακύπτει φυσικά στην αμφικλινή παλινδρόμηση για ένα σύνολο δεδομένων με πίνακα χαρακτηριστικών $\mathbf{X}$ και διάνυσμα ετικετών $\mathbf{y}$ [75, Κεφ. 3]. Οι παράμετροι μοντέλου που μαθαίνονται μέσω της αμφικλινούς παλινδρόμησης δίνονται από

$$\hat{\mathbf{w}}^{(\alpha)} = (\mathbf{X}^\top \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \alpha > 0.$$

Μπορούμε τότε να ορίσουμε τον ψευδοαντίστροφο $\mathbf{X}^+ \in \mathbb{R}^{d \times m}$ μέσω του ορίου [76, Κεφ. 3]:

$$\lim_{\alpha \rightarrow 0^+} \hat{\mathbf{w}}^{(\alpha)} = \mathbf{X}^+ \mathbf{y}.$$

Βλέπε επίσης: πίνακας, αντίστροφος πίνακας, αμφικλινής παλινδρόμηση, σύνολο δεδομένων, πίνακας χαρακτηριστικών, διάνυσμα ετικετών, παράμετρος μοντέλου.

ψευδοσυστολικός τελεστής TBC.

Courant–Fischer–Weyl min–max characterization TBC.

firmly non-expansive operator TBC.

fixed-point characterization TBC.

graph of a function TBC.

infimum (ή μέγιστο κάτω φράγμα) Το infimum (ή greatest lower bound) ενός συνόλου πραγματικών αριθμών είναι ο μεγαλύτερος αριθμός που είναι μικρότερος ή ίσος κάθε στοιχείου του συνόλου. Πιο τυπικά, ένας πραγματικός αριθμός a είναι το infimum ενός συνόλου $\mathcal{A} \subseteq \mathbb{R}$ αν: 1) ο a είναι κάτω φράγμα του $\mathcal{A}$, και 2) κανένας αριθμός μεγαλύτερος του a δεν είναι κάτω φράγμα του $\mathcal{A}$. Κάθε μη κενό σύνολο πραγματικών αριθμών που είναι κάτω φραγμένο έχει infimum, ακόμα και αν δεν περιέχει το infimum του ως στοιχείο [2, Ενότητα 1.4].

Βλέπε επίσης: supremum.

kernel (linear map) See nullspace.

majorize-minimize (MM) TBC.

mirror descent TBC.

non-expansive operator TBC.

nullspace TBC.

probability simplex TBC.

proximable Μία κυρτή συνάρτηση για την οποία ο τελεστής εγγύτητας μπορεί να υπολογιστεί αποτελεσματικά αναφέρεται μερικές φορές ως proximable ή απλή [77].

Βλέπε επίσης: κυρτό, συνάρτηση, τελεστής εγγύτητας.

rank-deficient TBC.

reproducing kernel Hilbert space (RKHS) TBC.

supremum (ή ελάχιστο άνω φράγμα) Το supremum (ή least upper bound) ενός συνόλου πραγματικών αριθμών είναι ο μικρότερος αριθμός που είναι μεγαλύτερος ή ίσος κάθε στοιχείου του συνόλου. Πιο τυπικά, ένας πραγματικός αριθμός a είναι το supremum ενός συνόλου $\mathcal{A} \subseteq \mathbb{R}$ αν: 1) ο a είναι άνω φράγμα του $\mathcal{A}$, και 2) κανένας αριθμός μικρότερος του a δεν είναι άνω φράγμα του $\mathcal{A}$. Κάθε μη κενό σύνολο πραγματικών αριθμών που είναι άνω φραγμένο έχει supremum, ακόμα και αν δεν περιέχει το

supremum του ως στοιχείο [2, Ενότητα 1.4].

Βλέπε επίσης: infimum (or greatest lower bound).

tall matrix TBC.

wide matrix TBC.

Έννοιες Μηχανικής Μάθησης

συνθήκη ορθογωνιότητας TBC.

απόκριση TBC.


απώλεια 0/1 Η απώλεια 0/1 (0/1 loss) $L^{(0/1)}((\mathbf{x}, y), h)$ μετράει την ποιότητα ενός ταξινομητή $h(\mathbf{x})$ που παραδίδει μία πρόβλεψη $\hat{y}$ (π.χ. μέσω κατωφλίου (7)) για την ετικέτα y ενός σημείου δεδομένων με χαρακτηριστικά $\mathbf{x}$. Είναι ίση με 0 αν η πρόβλεψη είναι σωστή, δηλαδή $L^{(0/1)}((\mathbf{x}, y), h) = 0$ όταν $\hat{y} = y$. Είναι ίση με 1 αν η πρόβλεψη είναι λανθασμένη, δηλαδή $L^{(0/1)}((\mathbf{x}, y), h) = 1$ όταν $\hat{y} \neq y$.

Βλέπε επίσης: απώλεια, ταξινομητής, πρόβλεψη, ετικέτα, σημείο δεδομένων, χαρακτηριστικό.

αβεβαιότητα Στο πλαίσιο της μηχανικής μάθησης, η αβεβαιότητα (uncertainty) αναφέρεται στην παρουσία πολλαπλών εύλογων εκβάσεων ή εξηγήσεων με βάση τα διαθέσιμα δεδομένα. Για παράδειγμα, η πρόβλεψη $\hat{h}(\mathbf{x})$ που παράγεται από ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης $\hat{h}$ συχνά αντανακλά ένα πεδίο πιθανών τιμών για την αληθή ετικέτα ενός συγκεκριμένου σημείου δεδομένων. Όσο πιο ευρύ το πεδίο, τόσο μεγαλύτερη η σχετική αβεβαιότητα. Η θεωρία πιθανοτήτων μας επιτρέπει να αναπαριστούμε, να ποσοτικοποιούμε, και να συλλογίζόμαστε για την αβεβαιότητα με έναν μαθηματικά ενδεδειγμένο τρόπο.

Βλέπε επίσης: μηχανική μάθηση, έκβαση, εξήγηση, δεδομένα, πρόβλεψη, μοντέλο, ετικέτα, σημείο δεδομένων, πιθανότητα, πιθανοτικό μοντέλο, διακινδύνευση, εντροπία, διαχύμανση.

αισιοδοξία παρά την αβεβαιότητα Οι μέθοδοι μηχανικής μάθησης μαθαίνουν τις παραμέτρους μοντέλου $\mathbf{w}$ σύμφωνα με κάποιο κριτήριο επίδοσης $\bar{f}(\mathbf{w})$. Ωστόσο, δεν μπορούν συνήθως να έχουν άμεση πρόσβαση στο $\bar{f}(\mathbf{w})$, αλλά βασίζονται σε μία εκτίμηση (ή προσέγγιση) $f(\mathbf{w})$ του $\bar{f}(\mathbf{w})$. Ως ένα χαρακτηριστικό παράδειγμα, οι μέθοδοι βασιμμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης χρησιμοποιούν τη μέση απώλεια σε ένα συγκεκριμένο σύνολο δεδομένων (δηλαδή το σύνολο εκπαίδευσης) ως μία εκτίμηση για τη διακινδύνευση μίας υπόθεσης. Χρησιμοποιώντας ένα πιθανοτικό μοντέλο, μπορεί κανείς να κατασκευάσει ένα διάστημα εμπιστοσύνης $[l^{(\mathbf{w})}, u^{(\mathbf{w})}]$ για κάθε επιλογή $\mathbf{w}$ για τις παραμέτρους του μοντέλου. Μία απλή κατασκευή είναι $l^{(\mathbf{w})} := f(\mathbf{w}) - \sigma/2$, $u^{(\mathbf{w})} := f(\mathbf{w}) + \sigma/2$, με το σ να είναι ένα μέτρο της (αναμενόμενης) απόκλισης του $f(\mathbf{w})$ από το $\bar{f}(\mathbf{w})$. Μπορούμε επίσης να χρησιμοποιήσουμε άλλες κατασκευές για αυτό το διάστημα εφόσον εξασφαλίζουν ότι $\bar{f}(\mathbf{w}) \in [l^{(\mathbf{w})}, u^{(\mathbf{w})}]$ με αρκετά υψηλή πιθανότητα. Ένας αισιόδοξος επιλέγει τις παραμέτρους του μοντέλου σύμφωνα με την πιο ευνοϊκή—αλλά εύλογη—τιμή $\tilde{f}(\mathbf{w}) := l^{(\mathbf{w})}$ του κριτηρίου επίδοσης (βλέπε Σχ. 32). Δύο παραδείγματα μεθόδων μηχανικής μάθησης που χρησιμοποιούν μία τέτοια αισιόδοξη κατασκευή μίας αντικειμενικής συνάρτησης είναι οι μέθοδοι δομικής ελαχιστοποίησης διακινδύνευσης [78, Κεφ. 11] και άνω φράγματος εμπιστοσύνης για διαδοχική λήψη αποφάσεων [79, Ενότητα 2.2].



Σχ. 32. Οι μέθοδοι μηχανικής μάθησης μαθαίνουν τις παραμέτρους μοντέλου $\mathbf{w}$ χρησιμοποιώντας κάποια εκτίμηση του $f(\mathbf{w})$ για το τελικό κριτήριο επίδοσης $\bar{f}(\mathbf{w})$. Χρησιμοποιώντας ένα πιθανοτικό μοντέλο, κανείς μπορεί να χρησιμοποιήσει το $f(\mathbf{w})$ για να κατασκευάσει διαστήματα εμπιστοσύνης $[l(\mathbf{w}), u(\mathbf{w})]$, τα οποία περιέχουν το $\bar{f}(\mathbf{w})$ με υψηλή πιθανότητα. Το καλύτερο εύλογο μέτρο επίδοσης για μία συγκεκριμένη επιλογή $\mathbf{w}$ των παραμέτρων του μοντέλου είναι $\tilde{f}(\mathbf{w}) := l(\mathbf{w})$.

Βλέπε επίσης: μηχανική μάθηση, παράμετρος μοντέλου, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια, σύνολο δεδομένων, σύνολο εκπαίδευσης, διακινδύνευση, υπόθεση, πιθανοτικό μοντέλο, μέτρο, πιθανότητα, αντικειμενική συνάρτηση, δομική ελαχιστοποίηση διακινδύνευσης, άνω φράγμα εμπιστοσύνης, μέθοδος βελτιστοποίησης, μέθοδος με βάση την κλίση.

ακρίβεια Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά $\mathbf{x} \in \mathcal{X}$ και μία κατηγορική ετικέτα y που παίρνει τιμές από ένα πεπερασμένο χώρο ετικετών $\mathcal{Y}$. Η ακρίβεια (accuracy) μίας υπόθεσης $h : \mathcal{X} \rightarrow \mathcal{Y}$, όταν εφαρμόζεται στα σημεία δεδομένων ενός συνόλου δε-

δομένων $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$, ορίζεται τότε ως

$$1 - \frac{1}{m} \sum_{r=1}^m L^{(0/1)}((\mathbf{x}^{(r)}, y^{(r)}), h)$$

χρησιμοποιώντας την απώλεια $0/1$ $L^{(0/1)}(\cdot, \cdot)$.

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, χώρος ετικετών, υπόθεση, σύνολο δεδομένων, απώλεια $0/1$, απώλεια, μετρική.

ακρίβεια Η ακρίβεια (precision) είναι μία μετρική που χρησιμοποιείται συχνά στη δυαδική ταξινόμηση. Μετράει το ποσοστό των αληθώς θετικών (δηλαδή των σωστά προβλεφθέντων θετικών σημείων δεδομένων) μεταξύ όλων των σημείων δεδομένων που προβλέφθηκαν ως θετικά. Με άλλα λόγια, είναι η ακρίβεια των σημείων δεδομένων που προβλέφθηκαν ως θετικά. Η ακρίβεια μπορεί επίσης να επεκταθεί στην ταξινόμηση πολλαπλών κλάσεων.

Η ακρίβεια σπάνια χρησιμοποιείται από μόνη της, καθώς ενθαρρύνει την επιλογή μόνο των πιο πιθανών σημείων δεδομένων. Ωστόσο, σε αντίθεση με την ακρίβεια, η ακρίβεια παραμένει μία έγκυρη μετρική ακόμα και με μη ισορροπημένα σύνολα δεδομένων.

Βλέπε επίσης: μετρική, δυαδική ταξινόμηση, σημείο δεδομένων, ακρίβεια, ταξινόμηση, σύνολο δεδομένων, πίνακας σύγχυσης, ανάκληση.

ακραία τιμή Πολλές μέθοδοι μηχανικής μάθησης παρακινούνται από την παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, η οποία ερμηνεύει σημεία δεδομένων ως πραγματώσεις ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών με κοινή κατανομή πιθανότητας. Η παραδο-

χή ανεξάρτητων και ταυτόσημα κατανομημένων είναι χρήσιμη για εφαρμογές όπου οι στατιστικές ιδιότητες της διαδικασίας παραγωγής δεδομένων είναι στάσιμες (ή χρονικά αναλλοίωτες) [66]. Ωστόσο, σε κάποιες εφαρμογές, τα δεδομένα αποτελούνται από μία πλειοψηφία ομαλών σημείων δεδομένων που συμμορφώνονται με την παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων καθώς και από έναν μικρό αριθμό σημείων δεδομένων που έχουν θεμελιωδώς διαφορετικές στατιστικές ιδιότητες συγκριτικά με τα ομαλά σημεία δεδομένων. Αναφερόμαστε σε ένα σημείο δεδομένων που αποκλίνει ουσιαστικά από τις στατιστικές ιδιότητες των περισσότερων σημείων δεδομένων ως μία ακραία τιμή. Διαφορετικές μέθοδοι για την ανίχνευση ακραίας τιμής χρησιμοποιούν διαφορετικά μέτρα για αυτή την απόκλιση. Η θεωρία στατιστικής μάθησης μελετάει τα θεμελιώδη όρια στη δυνατότητα να μετριάσουν αξιόπιστα οι ακραίες τιμές [80], [81].

Βλέπε επίσης: μηχανική μάθηση, παραδοχή ανεξάρτητων και ταυτόσημα κατανομημένων, σημείο δεδομένων, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανομημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, δεδομένα, μέτρο, στιβαρότητα, ευστάθεια, παλινδρόμηση Huber, πιθανοτικό μοντέλο.

αλγόριθμος Ένας αλγόριθμος (algorithm) είναι μία ακριβής, βήμα προς βήμα προδιαγραφή για την παραγωγή μίας εξόδου από μία δεδομένη είσοδο εντός ενός πεπερασμένου αριθμού καλά ορισμένων υπολογιστικών βημάτων [82]. Για παράδειγμα, μία μέθοδος με βάση την κλίση για γραμμική παλινδρόμηση είναι ένας αλγόριθμος που περιγράφει ρητά πώς να αντιστοιχίζεται ένα δεδομένο σύνολο εκπαίδευσης σε παραμέτρους μοντέλου μέσω μιας ακολουθίας βημάτων κλίσης. Η ακριβής μορφή ενός αλγόριθ-

μου εξαρτάται από τη διαθέσιμη υπολογιστική υποδομή. Για παράδειγμα, αν αυτή η υποδομή μάς επιτρέπει να υπολογίσουμε έναν αντίστροφο πίνακα, τότε μπορούμε να ορίσουμε έναν αλγόριθμο γραμμικής παλινδρόμησης χρησιμοποιώντας τις κανονικές εξισώσεις. Αντίθετα, αν η υπολογιστική υποδομή επιτρέπει μόνο βασικές αριθμητικές πράξεις (δηλαδή πολλαπλασιασμό και πρόσθεση), οι κανονικές εξισώσεις πρέπει με κάποιον τρόπο να μεταφραστούν σε μία ακολουθία αριθμητικών πράξεων (π.χ. όπως στις μεθόδους με βάση την κλίση). Για να μελετήσουμε αλγόριθμους ενδελεχώς, μπορούμε να τους αναπαραστήσουμε (ή να τους προσεγγίσουμε) με διαφορετικές μαθηματικές δομές [83]. Μία προσέγγιση είναι να αναπαραστήσουμε έναν αλγόριθμο ως μία συλλογή πιθανών εκτελέσεων. Κάθε μεμονωμένη εκτέλεση είναι τότε μία ακολουθία της ακόλουθης μορφής:


input, $s_1, s_2, \dots, s_T$, output.

Αυτή η ακολουθία ξεκινάει από μία είσοδο και προοδεύει μέσω ενδιάμεσων βημάτων μέχρι να παραδοθεί μία έξοδος. Είναι κρίσιμο ότι ένας αλγόριθμος συμπεριλαμβάνει περισσότερα από απλώς μία αντιστοίχιση από είσοδο σε έξοδο· περιλαμβάνει επίσης ενδιάμεσα υπολογιστικά βήματα $s_1, \dots, s_T$.

Βλέπε επίσης: έξοδος, μέθοδος με βάση την κλίση, γραμμική παλινδρόμηση, σύνολο εκπαίδευσης, παράμετρος μοντέλου, βήμα κλίσης, αντίστροφος πίνακας, κανονικές εξισώσεις, ακολουθία, μοντέλο, στοχαστική.

αλγόριθμος του Lloyd Ο αλγόριθμος του Lloyd (Lloyd's algorithm) [84] είναι μία επαναληπτική μέθοδος βελτιστοποίησης για την εύρεση κέντρων


βάρους συστάδων που είναι προσεγγιστικά βέλτιστα για την αντικειμενική συνάρτηση του αλγόριθμου k -μέσων. Ο αλγόριθμος Lloyd εναλλάσσεται μεταξύ: 1) της ενημέρωσης της απόδοσης συστάδας για κάθε σημείο δεδομένων με βάση το πλησιέστερο τρέχον κέντρο βάρους συστάδας, και 2) του επανυπολογισμού των κέντρων βάρους συστάδων δεδομένων των ενημερωμένων αποδόσεων συστάδων [84].



Απόδοση στο πλησιέστερο κέντρο βάρους συστάδας. Επανυπολογισμός των κέντρων βάρους συστάδων.

(a)

(b)



Απόδοση στο πλησιέστερο κέντρο βάρους συστάδας.


(c)

Σχ. 33. Αλγόριθμος του Lloyd που εναλλάσσεται μεταξύ των (a) και (c), αποδίδοντας τα σημεία δεδομένων στο πλησιέστερο κέντρο βάρους συστάδας και στη συνέχεια (b) επανυπολογίζοντας τα κέντρα βάρους συστάδων με βάση τις νέες αποδόσεις συστάδων.

Βλέπε επίσης: αλγόριθμος, μέθοδος βελτιστοποίησης, κέντρο βάρους συστάδας, αλγόριθμος k -μέσων, αντικειμενική συνάρτηση, συστάδα, σημείο δεδομένων, συσταδοποίηση.

αλγόριθμος k -μέσων Η αρχή του αλγόριθμου k -μέσων τιμών (k -means)

είναι μία προσέγγιση βασισμένη στη βελτιστοποίηση για τη συσταδοποίηση σημείων δεδομένων με ένα αριθμητικό διάνυσμα χαρακτηριστικών [8, Κεφ. 8]. Ως μία προσέγγιση σκληρής συσταδοποίησης, ο αλγόριθμος k -μέσων τιμών χωρίζει ένα σύνολο δεδομένων σε k ξένα υποσύνολα (ή συστάδες), τα οποία έχουν δείκτες $c = 1, \dots, k$. Κάθε συστάδα $\mathcal{C}$ αναπαρίσταιται από το μέσο διάνυσμα χαρακτηριστικών των σημείων δεδομένων που ανήκουν σε αυτό. Αυτό το μέσο (ή μέσης τιμής) διάνυσμα χαρακτηριστικών αναφέρεται ως το κέντρο βάρους συστάδας $\mathbf{w}^{(c)}$. Μία οπτική απεικόνιση παρέχεται στο Σχ. 34.



Σχ. 34. Ένα διάγραμμα διασποράς σημείων δεδομένων, τα οποία έχουν δείκτες $r = 1, \dots, m$ και χαρακτηρίζονται από διανύσματα χαρακτηριστικών $\mathbf{x}^{(r)} \in \mathbb{R}^2$. Το διάγραμμα διασποράς περιλαμβάνει επίσης δύο κέντρα βάρους συστάδων $\mathbf{w}^{(1)}, \mathbf{w}^{(2)} \in \mathbb{R}^2$.

Η ποιότητα (ή χρησιμότητα) μίας συγκεκριμένης συσταδοποίησης μετράται μέσω κάποιας μορφής σφάλματος συσταδοποίησης, όπως η μέση τετραγωνική Ευκλείδεια απόσταση μεταξύ του διανύσματος χαρακτηριστικών ενός σημείου δεδομένων και του κέντρου βάρους συστάδας της συστάδας στην οποία ανήκει το σημείο δεδομένων. Γενικά, η ακριβής λύση του προβλήματος βελτιστοποίησης του αλγόριθμου k -μέσων τιμών είναι δύσκολη (ή NP-δύσκολη) [85]. Ωστόσο, υπάρχουν απλές επαναλη-

πτικές μέθοδοι για την εύρεση προσεγγιστικά βέλτιστων κέντρων βάρους συστάδων. Μία τέτοια μέθοδος αναφέρεται ως αλγόριθμος του Lloyd. Βλέπε επίσης: μέση τιμή, βελτιστοποίηση, συσταδοποίηση, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, σκληρή συσταδοποίηση, σύνολο δεδομένων, συστάδα, κέντρο βάρους συστάδας, διάγραμμα διασποράς, πρόβλημα βελτιστοποίησης, αλγόριθμος του Lloyd.

αμοιβαίες πληροφορίες Οι αμοιβαίες πληροφορίες (mutual information - MI) $I(\mathbf{x}; y)$ μεταξύ δύο τυχαίων μεταβλητών $\mathbf{x}, y$ που ορίζονται στον ίδιο χώρο πιθανοτήτων δίνονται από [32]

$$I(\mathbf{x}; y) := \mathbb{E} \left\{ \log \frac{p(\mathbf{x}, y)}{p(\mathbf{x})p(y)} \right\}.$$


Αποτελεί μέτρο του πόσο καλά μπορούμε να εκτιμήσουμε την y βάσει μόνο του $\mathbf{x}$. Μία μεγάλη τιμή του $I(\mathbf{x}; y)$ υποδεικνύει ότι η y μπορεί να προβλεφθεί καλά μόνο από τη $\mathbf{x}$. Αυτή η πρόβλεψη θα μπορούσε να προκύψει από μία υπόθεση που μαθαίνεται από μία μέθοδο μηχανικής μάθησης βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης. Βλέπε επίσης: τυχαία μεταβλητή, χώρος πιθανοτήτων, μέτρο, πρόβλεψη, υπόθεση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μηχανική μάθηση.

αμφικλινής παλινδρόμηση Θεωρούμε ένα πρόβλημα παλινδρόμησης όπου ο στόχος είναι να μαθευτεί μία υπόθεση $h^{(\mathbf{w})}$ για την πρόβλεψη της αριθμητικής ετικέτας ενός σημείου δεδομένων με βάση το διάνυσμα χαρακτηριστικών του. Η αμφικλινής παλινδρόμηση (ridge regression) μαθαίνει τις παραμέτρους $\mathbf{w}$ ελαχιστοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που έχει επιβληθεί ως ποινή. Η μέση απώλεια τετραγωνικού σφάλ-

ματος μετράται σε ένα σύνολο σημείων δεδομένων με ετικέτες (δηλαδή το σύνολο εκπαίδευσης)

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}).$$

Ο όρος ποινής είναι η ανηγμένη τετραγωνική Ευκλείδεια νόρμα $\alpha \|\mathbf{w}\|_2^2$ με μία παράμετρο ομαλοποίησης $\alpha > 0$. Ο σκοπός του όρου ποινής είναι η ομαλοποίηση, δηλαδή η αποφυγή υπερπροσαρμογής στο καθεστώς υψηλής διάστασης, όπου ο αριθμός των χαρακτηριστικών d υπερβαίνει τον αριθμό των σημείων δεδομένων m στο σύνολο εκπαίδευσης. Για την εκπαίδευση ενός γραμμικού μοντέλου, η προσθήκη του $\alpha \|\mathbf{w}\|_2^2$ στη μέση απώλεια τετραγωνικού σφάλματος ισοδυναμεί με τον υπολογισμό της μέσης απώλεια τετραγωνικού σφάλματος σε ένα επαυξημένο σύνολο εκπαίδευσης.



Σχ. 35. Για ένα γραμμικό μοντέλο, η προσθήκη του όρου ποινής $\alpha \|\mathbf{w}\|_2^2$ στην αντικειμενική συνάρτηση στην ελαχιστοποίηση εμπειρικής διακινδύνευσης ισοδυναμεί με την ελαχιστοποίηση εμπειρικής διακινδύνευσης σε ένα επαυξημένο σύνολο δεδομένων.

Αυτό το επαυξημένο σύνολο εκπαίδευσης προκύπτει αντικαθιστώντας κάθε σημείο δεδομένων $(\mathbf{x}^{(r)}, y^{(r)})$ στο αρχικό σύνολο εκπαίδευσης με την πραγμάτωση άπειρα πολλών ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών των οποίων η κατανομή πιθανότητας είναι κεντρική στο $(\mathbf{x}^{(r)}, y^{(r)})$.

Βλέπε επίσης: παλινδρόμηση, υπόθεση, ετικέτα, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, παράμετρος, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης, όρος ποινής, Ευκλείδεια νόρμα, ομαλοποίηση, υπερπροσαρμογή, καθεστώς υψηλής διάστασης, χαρακτηριστικό, εκπαίδευση, γραμμικό μοντέλο, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες, τυχαία μεταβλητή, κατανομή πιθανότητας, απεικόνιση, επαύξηση δεδομένων.

αναδρομικό νευρωνικό δίκτυο Ένα αναδρομικό νευρωνικό δίκτυο (recurrent neural network - RNN) είναι ένας συγκεκριμένος τύπος ΤΝΔ που έχει σχεδιαστεί για την επεξεργασία δεδομένων που αποτελούνται από μία ακολουθία από tokens. Ένα αναδρομικό νευρωνικό δίκτυο διατηρεί μία εσωτερική κρυφή κατάσταση, η οποία ενημερώνεται επαναληπτικά καθώς επεξεργάζονται νέα tokens. Αυτή η επαναληπτική εξάρτηση επιτρέπει στις πληροφορίες να διαδίδονται μέσα από χρονικά βήματα, καθιστώντας τα αναδρομικά νευρωνικά δίκτυα κατάλληλα για εργασίες όπως η αναγνώριση ομιλίας, η γλωσσική μοντελοποίηση, ή η πρόβλεψη χρονοσειρών. Ωστόσο, ο εγγενώς ακολουθιακός υπολογισμός τους περιορίζει την παραλληλοποίηση και δημιουργεί δυσκολίες στις μεθόδους με βάση την κλίση. Παραλλαγές όπως η μακρά βραχυπρόθεσμη μνήμη (long short-term memory - LSTM) και η φραγμένη αναδρομική μονάδα (gated recurrent

unit - GRU) μετριάζουν αυτά τα προβλήματα.

Βλέπε επίσης: ΤΝΔ, δεδομένα, ακολουθία, token, κατάσταση, πρόβλεψη, μέθοδος με βάση την κλίση.

ανάκληση Η ανάκληση (recall) είναι μία μετρική που χρησιμοποιείται συχνά στη δυαδική ταξινόμηση. Είναι ο λόγος των αληθώς θετικών (δηλαδή των σωστά προβλεφθέντων θετικών σημείων δεδομένων) προς όλα τα πραγματικά θετικά (δηλαδή τα σημεία δεδομένων με μία θετική πραγματική ετικέτα). Με άλλα λόγια, δείχνει το ποσοστό των αληθώς θετικών με σωστή ετικέτα. Η ανάκληση μπορεί επίσης να επεκταθεί στην ταξινόμηση πολλαπλών κλάσεων.

Η ανάκληση συνήθως δεν χρησιμοποιείται μόνης της, καθώς τέλεια ανάκληση μπορεί να επιτευχθεί με το να δίνεται σε όλα τα σημεία θετική ετικέτα. Ωστόσο, είναι στιβαρή σε μη ισορροπημένα σύνολα δεδομένων, σε αντίθεση, για παράδειγμα, με την ακρίβεια.

Βλέπε επίσης: μετρική, δυαδική ταξινόμηση, σημείο δεδομένων, ετικέτα, ταξινόμηση, σύνολο δεδομένων, ακρίβεια, πίνακας σύγχυσης, ακρίβεια.

ανάλυση κύριων συνιστωσών Θεωρούμε ένα σύνολο δεδομένων

$$\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$$

που αποτελείται από σημεία δεδομένων που χαρακτηρίζονται από διανύσματα χαρακτηριστικών $\mathbf{x}^{(r)} \in \mathbb{R}^d$ for $r = 1, \dots, m$. Η ανάλυση κύριων συνιστωσών (principal component analysis - PCA) καθορίζει, για έναν δεδομένα αριθμό $d' < d$, μία γραμμική απεικόνιση χαρακτηριστι-

κών

$$\Phi(\mathbf{W}) : \mathbb{R}^d \rightarrow \mathbb{R}^{d'} : \mathbf{x} \mapsto \mathbf{W}\mathbf{x}$$

έτσι ώστε τα νέα διανύσματα χαρακτηριστικών $\mathbf{z}^{(r)} = \mathbf{W}\mathbf{x}^{(r)}$ να μας επιτρέπουν να ξανακατασκευάσουμε τα αρχικά χαρακτηριστικά με το ελάχιστο σφάλμα ανακατασκευής [8], [61], [75]:

$$\min_{\mathbf{R} \in \mathbb{R}^{d \times d'}} \sum_{r=1}^m \|\mathbf{x}^{(r)} - \mathbf{R}\mathbf{W}\mathbf{x}^{(r)}\|_2^2.$$

Μπορούμε να θεωρήσουμε την ανάλυση κύριων συνιστωσών ως μία μορφή ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιεί τη συνάρτηση απώλειας $L(\mathbf{x}, \mathbf{W}) = \|\mathbf{x} - \hat{\mathbf{R}}\mathbf{W}\mathbf{x}\|_2^2$ με έναν πίνακα ανακατασκευής $\hat{\mathbf{R}}$ που επιτυγχάνει το παραπάνω ελάχιστο σφάλμα ανακατασκευής. Αυτό το πρόβλημα ελαχιστοποίησης εμπειρικής διακινδύνευσης μπορεί τελικά να λυθεί από έναν πίνακα $\mathbf{W} = (\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d')})^T$ του οποίου οι γραμμές δίνονται από d' ιδιοδιανύσματα που αντιστοιχούν στις d' μεγαλύτερες ιδιοτιμές του πίνακα:

$$\hat{\mathbf{Q}} = \frac{1}{m} \sum_{r=1}^m \mathbf{x}^{(r)} (\mathbf{x}^{(r)})^T = \mathbf{X}^T \mathbf{X}.$$

Σημείωση ότι ο $\hat{\mathbf{Q}}$ συμπίπτει με τον πίνακα συνδιακύμανσης δείγματος του $\mathcal{D}$ αν η μέση τιμή δείγματός του μηδενίζει. Ο θετικά ημιορισμένος πίνακας

$\hat{\mathbf{Q}}$ επιτρέπει μία ανάλυση ιδιοτιμών της ακόλουθης μορφής [46], [70]:

$$\hat{\mathbf{Q}} = \sum_{j=1}^d \lambda_j \mathbf{u}^{(j)} (\mathbf{u}^{(j)})^T = \begin{pmatrix} \mathbf{u}^{(1)} & \dots & \mathbf{u}^{(d)} \end{pmatrix} \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_d \end{pmatrix} \begin{pmatrix} (\mathbf{u}^{(1)})^T \\ \vdots \\ (\mathbf{u}^{(d)})^T \end{pmatrix}.$$

Αυτή η ανάλυση αποτελείται από μη αρνητικές ιδιοτιμές σε φθίνουσα σειρά $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0$ και τα αντίστοιχα ιδιοδιανύσματα $\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(d)}$ που σχηματίζουν μία ορθοκανονική βάση του $\mathbb{R}^d$.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, απεικόνιση χαρακτηριστικών, χαρακτηριστικό, ελάχιστο, ελαχιστοποίηση εμπειρικής διακινδύνευσης, συνάρτηση απώλειας, πίνακας, ιδιοδιάνυσμα, ιδιοτιμή, πίνακας συνδιακύμανσης δείγματος, μέση τιμή δείγματος, θετικά ημιορισμένος, ανάλυση ιδιοτιμών, βάση.

ανορθωμένη γραμμική μονάδα Η ανορθωμένη γραμμική μονάδα (rectified linear unit - ReLU) αποτελεί μία δημοφιλή επιλογή για τη συνάρτηση ενεργοποίησης ενός νευρώνα εντός ενός ΤΝΔ. Ορίζεται ως $\sigma(z) = \max\{0, z\}$, όπου z είναι μία σταθμισμένη είσοδος του τεχνητού νευρώνα.


Βλέπε επίσης: συνάρτηση ενεργοποίησης, νευρώνας, ΤΝΔ, τεχνητός νευρώνας.

ανταμοιβή Μία ανταμοιβή (reward) αναφέρεται σε κάποια παρατηρούμενη (ή μετρημένη) ποσότητα που μας επιτρέπει να εκτιμήσουμε την απώλεια που προκύπτει από την πρόβλεψη (ή απόφαση) μίας υπόθεσης $h(\mathbf{x})$. Για παράδειγμα, σε μία εφαρμογή μηχανικής μάθησης σε αυτοοδηγούμενα ο-

χήματα, η $h(\mathbf{x})$ θα μπορούσε να αναπαριστά την τρέχουσα κατεύθυνση οδήγησης ενός οχήματος. Θα μπορούσαμε να κατασκευάσουμε μία ανταμοιβή από τις μετρήσεις ενός αισθητήρα σύγκρουσης που υποδεικνύει αν το όχημα κινείται προς ένα εμπόδιο. Ορίζουμε μία χαμηλή ανταμοιβή για την κατεύθυνση οδήγησης $h(\mathbf{x})$ αν το όχημα κινείται επικίνδυνα προς ένα εμπόδιο.

Βλέπε επίσης: απώλεια, πρόβλεψη, υπόθεση, μηχανική μάθηση, MAB, ενισχυτική μάθηση.

αντικειμενική συνάρτηση Μία αντικειμενική συνάρτηση (objective function) είναι μία απεικόνιση που αποδίδει μία αριθμητική αντικειμενική τιμή $f(\mathbf{w})$ σε κάθε επιλογή $\mathbf{w}$ κάποιας μεταβλητής που θέλουμε να βελτιστοποιήσουμε (βλέπε Σχ. 36). Στο πλαίσιο της μηχανικής μάθησης, η μεταβλητή βελτιστοποίησης θα μπορούσε να είναι οι παράμετροι μοντέλου μίας υπόθεσης $h(\mathbf{w})$. Κοινές αντικειμενικές συναρτήσεις περιλαμβάνουν τη διακινδύνευση (δηλαδή την προσδοκώμενη απώλεια) ή την εμπειρική διακινδύνευση (δηλαδή τη μέση απώλεια πάνω σε ένα σύνολο εκπαίδευσης). Οι μέθοδοι μηχανικής μάθησης εφαρμόζουν τεχνικές βελτιστοποίησης, όπως τις μεθόδους με βάση την κλίση, για να βρούν την επιλογή $\mathbf{w}$ με τη βέλτιστη τιμή (π.χ., το ελάχιστο ή το μέγιστο) της αντικειμενικής συνάρτησης.



Σχ. 36. Μία αντικειμενική συνάρτηση αντιστοιχίζει κάθε πιθανή τιμή $\mathbf{w}$ μίας μεταβλητής βελτιστοποίησης, όπως οι παράμετροι μοντέλου ενός μοντέλου μηχανικής μάθησης, σε μία τιμή $f(\mathbf{w})$ που μετράει τη χρησιμότητα της $\mathbf{w}$.

Βλέπε επίσης: συνάρτηση, απεικόνιση, μηχανική μάθηση, βελτιστοποίηση, παράμετρος μοντέλου, υπόθεση, διακινδύνευση, απώλεια, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, μέθοδος με βάση την κλίση, ελάχιστο, μέγιστο, μοντέλο, συνάρτηση απώλειας, ελαχιστοποίηση εμπειρικής διακινδύνευσης, πρόβλημα βελτιστοποίησης.

άνω φράγμα εμπιστοσύνης (ΑΦΕ) Θεωρούμε μία εφαρμογή μηχανικής μάθησης που απαιτεί την επιλογή, σε κάθε χρονικό βήμα t , μίας ενέργειας a_t από ένα πεπερασμένο σύνολο εναλλακτικών $\mathcal{A}$. Η χρησιμότητα της επιλογής της ενέργειας a_t ποσοτικοποιείται από ένα αριθμητικό σήμα ανταμοιβής $r^{(a_t)}$. Ένα ευρέως χρησιμοποιούμενο πιθανοτικό μοντέλο για αυτόν τον τύπο προβλήματος ακολουθιακής λήψης αποφάσεων είναι το περιβάλλον στοχαστικής MAB [79]. Σε αυτό το μοντέλο, η ανταμοιβή $r^{(a)}$ θεωρείται ως η πραγμάτωση μίας τυχαίας μεταβλητής με άγνωστη μέση τιμή $\mu^{(a)}$. Ιδανικά, θα επιλέγαμε πάντα την ενέργεια με την μεγαλύτερη αναμενόμενη ανταμοιβή $\mu^{(a)}$, αλλά αυτές οι μέσες τιμές είναι άγνωστες

και πρέπει να εκτιμηθούν από παρατηρούμενα δεδομένα. Το να επιλεγεί απλά η ενέργεια με τη μεγαλύτερη εκτίμηση $\hat{\mu}^{(a)}$ μπορεί να οδηγήσει σε υποβέλτιστα αποτελέσματα λόγω της αβεβαιότητας στην εκτίμηση. Η στρατηγική ΑΦΕ (upper confidence bound - UCB) το αντιμετωπίζει αυτό επιλέγοντας ενέργειες όχι μόνο με βάση τις εκτιμώμενες μέσες τιμές αλλά και ενσωματώνοντας έναν όρο που αντανακλά την αβεβαιότητα σε αυτές τις εκτιμήσεις—ευνοώντας ενέργειες με υψηλή πιθανή ανταμοιβή και υψηλή αβεβαιότητα. Θεωρητικές εγγυήσεις για την επίδοση στρατηγικών ΑΦΕ, συμπεριλαμβανομένων των ορίων λογαριθμικής ρήτρα μεταβολής γνώμης, καταδεικνύονται στο [79].

Βλέπε επίσης: μηχανική μάθηση, ανταμοιβή, πιθανοτικό μοντέλο, στοχαστική, MAB, μοντέλο, πραγμάτωση, τυχαία μεταβλητή, μέση τιμή, δεδομένα, αβεβαιότητα, regret.

απεικόνιση χαρακτηριστικών Μία απεικόνιση χαρακτηριστικών (feature map) αναφέρεται σε μία συνάρτηση

$$\Phi : \mathcal{X} \rightarrow \mathcal{X}', \quad \mathbf{x} \mapsto \mathbf{x}'$$

που μετασχηματίζει ένα διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathcal{X}$ ενός σημείου δεδομένων σε ένα νέο διάνυσμα χαρακτηριστικών $\mathbf{x}' \in \mathcal{X}'$, όπου ο $\mathcal{X}'$ είναι συνήθως διαφορετικός από τον $\mathcal{X}$. Η μετασχηματισμένη αναπαράσταση $\mathbf{x}'$ είναι συχνά πιο χρήσιμη από την αρχική $\mathbf{x}$. Για παράδειγμα, η γεωμετρία των σημείων δεδομένων μπορεί να γίνει πιο γραμμική στον $\mathcal{X}'$, επιτρέποντας την εφαρμογή ενός γραμμικού μοντέλου στο $\mathbf{x}'$. Αυτή η ιδέα είναι κεντρική στον σχεδιασμό μεθόδων πυρήνα [49]. Άλλα πλεο-

νεκτήματα της χρήσης μίας απεικόνισης χαρακτηριστικών περιλαμβάνουν τη μείωση της υπερπροσαρμογής και τη βελτίωση της ερμηνευσιμότητας [86]. Μία κοινή περίπτωση χρήσης είναι η οπτικοποίηση δεδομένων, όπου μία απεικόνιση χαρακτηριστικών με δύο διαστάσεις εξόδου επιτρέπει την αναπαράσταση των σημείων δεδομένων σε ένα 2-D διάγραμμα διασποράς. Κάποιες μέθοδοι μηχανικής μάθησης χρησιμοποιούν εκπαιδευσιμες απεικονίσεις χαρακτηριστικών, των οποίων οι παράμετροι μαθαίνονται από τα δεδομένα. Ένα παράδειγμα είναι η χρήση κρυφών στρωμάτων σε ένα βαθύ δίκτυο, τα οποία λειτουργούν ως διαδοχικές απεικονίσεις χαρακτηριστικών [87]. Ένας βασικός τρόπος εκπαίδευσης μίας απεικόνισης χαρακτηριστικών είναι μέσω της ελαχιστοποίησης εμπειρικής διακινδύνευσης, χρησιμοποιώντας μία συνάρτηση απώλειας που μετράει την ποιότητα ανακατασκευής, π.χ. $L = \|\mathbf{x} - r(\mathbf{x}')\|^2$, όπου $r(\cdot)$ είναι μία εκπαιδευσιμη απεικόνιση που επιχειρεί να ανακατασκευάσει το $\mathbf{x}$ από ένα μετασχηματισμένο διάνυσμα χαρακτηριστικών $\mathbf{x}'$.

Βλέπε επίσης: χαρακτηριστικό, απεικόνιση, συνάρτηση, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, γραμμικό μοντέλο, μέθοδος πυρήνα, υπερπροσαρμογή, ερμηνευσιμότητα, δεδομένα, διάγραμμα διασποράς, μηχανική μάθηση, παράμετρος, στρώμα, βαθύ δίκτυο, ελαχιστοποίηση εμπειρικής διακινδύνευσης, συνάρτηση απώλειας, μάθηση χαρακτηριστικών, ανάλυση κύριων συνιστωσών.

απόκλιση Θεωρούμε μία εφαρμογή ομοσπονδιακής μάθησης με networked data που αναπαριστώνται από ένα δίκτυο ομοσπονδιακής μάθησης. Οι μέθοδοι ομοσπονδιακής μάθησης χρησιμοποιούν ένα μέτρο απόκλισης (discrepancy) για να συγκρίνουν απεικονίσεις υπόθεσης από τοπικά μο-

ντέλα στους κόμβους i, i' , οι οποίοι συνδέονται με μία ακμή στο δίκτυο ομοσπονδιακής μάθησης.

Βλέπε επίσης: ομοσπονδιακή μάθηση, δικτυωμένα δεδομένα, δίκτυο ομοσπονδιακής μάθησης, μέτρο, υπόθεση, απεικόνιση, τοπικό μοντέλο, συνδεόμενος.

αποτελεσματική διάσταση Η αποτελεσματική διάσταση (effective dimension) $d_{\text{eff}}(\mathcal{H})$ ενός άπειρου χώρου υποθέσεων $\mathcal{H}$ είναι ένα μέτρο του μεγέθους του. Σε γενικές γραμμές, η αποτελεσματική διάσταση είναι ίση με τον αποτελεσματικό αριθμό ανεξάρτητων ρυθμιζόμενων παραμέτρων μοντέλου. Αυτές οι παράμετροι μπορεί να είναι συντελεστές που χρησιμοποιούνται σε μία γραμμική απεικόνιση ή τα βάρη και οι όροι μεροληψίας ενός ΤΝΔ.

Βλέπε επίσης: διάσταση, χώρος υποθέσεων, μέτρο, παράμετρος μοντέλου, παράμετρος, γραμμική απεικόνιση, βάρος, μεροληψία, ΤΝΔ.

απώλεια Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν μία συνάρτηση απώλειας $L(\mathbf{z}, h)$ για να μετρήσουν το σφάλμα που προκαλείται από την εφαρμογή μίας συγκεκριμένης υπόθεσης σε ένα συγκεκριμένο σημείο δεδομένων. Με μία μικρή κατάχρηση του συμβολισμού, χρησιμοποιούμε τον όρο απώλεια (loss) και για την ίδια τη συνάρτηση απώλειας L και για τη συγκεκριμένη τιμή $L(\mathbf{z}, h)$ για ένα σημείο δεδομένων $\mathbf{z}$ και μία υπόθεση h .

Βλέπε επίσης: μηχανική μάθηση, συνάρτηση απώλειας, υπόθεση, σημείο δεδομένων, εμπειρική διακινδύνευση.


απώλεια απόλυτου σφάλματος Θεωρούμε ένα σημείο δεδομένων με χα-

ρακτηριστικά $\mathbf{x} \in \mathcal{X}$ και αριθμητική ετικέτα $y \in \mathbb{R}$. Όπως υποδηλώνει και το όνομά της, η απώλεια απόλυτου σφάλματος (absolute error loss) που προκαλείται από μία υπόθεση $h : \mathcal{X} \rightarrow \mathbb{R}$ ορίζεται ως

$$L((\mathbf{x}, y), h) = |y - h(\mathbf{x})|.$$

Το Σχ. 37 απεικονίζει την απώλεια απόλυτου σφάλματος για ένα σταθερό σημείο δεδομένων με διάνυσμα χαρακτηριστικών $\mathbf{x}$ και ετικέτα y . Υποδεικνύει επίσης τις τιμές απώλειας που προκαλούνται από δύο διαφορετικές υποθέσεις h' και h'' . Όμοια με την απώλεια τετραγωνικού σφάλματος, η απώλεια απόλυτου σφάλματος είναι επίσης μία κυρτή συνάρτηση της πρόβλεψης $\hat{y} = h(\mathbf{x})$. Ωστόσο, σε αντίθεση με την απώλεια τετραγωνικού σφάλματος, η απώλεια απόλυτου σφάλματος είναι μη λεία, καθώς δεν είναι παραγωγίσιμη στη βέλτιστη πρόβλεψη $\hat{y} = y$. Αυτή η ιδιότητα καθιστά τις μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιούν την απώλεια απόλυτου σφάλματος υπολογιστικά πιο απαιτητικές [58], [88]. Για να αναπτυχθεί η διαισθητική κατανόηση, είναι χρήσιμο να παρατηρήσουμε τις δύο υποθέσεις που απεικονίζονται στο Σχ. 37. Απλώς ελέγχοντας την κλίση της L γύρω από τις $h'(\mathbf{x})$ και $h''(\mathbf{x})$, είναι απίθανο να προσδιορίσουμε εάν βρισκόμαστε πολύ κοντά στο βέλτιστο (στην h') ή ακόμα μακριά (στην h''). Ως αποτέλεσμα, οποιαδήποτε μέθοδος βελτιστοποίησης που βασίζεται σε τοπικές προσεγγίσεις της συνάρτησης απώλειας (όπως η κάθοδος υποκλίσης) πρέπει να χρησιμοποιεί έναν φθίνοντα ρυθμό μάθησης για να αποφευχθεί η υπέρβαση κατά την προσέγγιση του βέλτιστου. Αυτή η απαιτούμενη μείωση στον ρυθμό μάθησης τείνει να επιβραδύνει τη σύγκλιση της μεθόδου βελτιστο-

ποίησης. Εκτός από την αυξημένη υπολογιστική πολυπλοκότητα, η χρήση της απώλειας απόλυτου σφάλματος στην ελαχιστοποίηση εμπειρικής διακινδύνευσης μπορεί να είναι ωφέλιμη στην παρουσία ακραίων τιμών στο σύνολο εκπαίδευσης. Σε αντίθεση με την απώλεια τετραγωνικού σφάλματος, η κλίση της απώλειας απόλυτου σφάλματος δεν αυξάνεται με την αύξηση του σφάλματος πρόβλεψης $y - h(\mathbf{x})$. Ως αποτέλεσμα, η επίδραση της εισαγωγής μίας ακραίας τιμής με μεγάλο σφάλμα πρόβλεψης στη λύση $\hat{h}$ της ελαχιστοποίησης εμπειρικής διακινδύνευσης με απώλεια απόλυτου σφάλματος είναι πολύ μικρότερη συγκριτικά με την επίδραση στη λύση της ελαχιστοποίησης εμπειρικής διακινδύνευσης με απώλεια τετραγωνικού σφάλματος.




Σχ. 37. Για ένα σημείο δεδομένων με αριθμητική ετικέτα $y \in \mathbb{R}$, το απόλυτο σφάλμα $|y - h(\mathbf{x})|$ μπορεί να χρησιμοποιηθεί ως μία συνάρτηση απώλειας για να καθοδηγήσει τη μάθηση μίας υπόθεσης h .

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, απώλεια, υπόθεση, διάνυσμα χαρακτηριστικών, απώλεια τετραγωνικού σφάλματος, κυρτό, συνάρτηση, πρόβλεψη, μη λεία, παραγωγίσιμη, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μέθοδος βελτιστοποίησης, συνάρτηση απώλειας,

κάθοδος υποκλίσης, ρυθμός μάθησης, σύγκλιση, ακραία τιμή, σύνολο εκπαίδευσης.

απώλεια άρθρωσης Θεωρούμε ένα σημείο δεδομένων που χαρακτηρίζεται από ένα διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$ και μία δυαδική ετικέτα $y \in \{-1, 1\}$. Η απώλεια άρθρωσης (hinge loss) που προκαλείται από μία απεικόνιση υπόθεσης πραγματικής τιμής $h(\mathbf{x})$ ορίζεται ως

$$L((\mathbf{x}, y), h) := \max\{0, 1 - yh(\mathbf{x})\}. \quad (1)$$



Σχ. 38. Η απώλεια άρθρωσης που προκαλείται από την πρόβλεψη $h(\mathbf{x}) \in \mathbb{R}$ για ένα σημείο δεδομένων με ετικέτα $y \in \{-1, 1\}$. Μία ομαλοποιημένη παραλλαγή της απώλειας άρθρωσης χρησιμοποιείται από τη μηχανή διανυσμάτων υποστήριξης [89].

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, ετικέτα, απώλεια, υπόθεση, απεικόνιση, πρόβλεψη, μηχανή διανυσμάτων υποστήριξης, ταξινόμηση, ταξινομητής.

απώλεια τετραγωνικού σφάλματος Η απώλεια τετραγωνικού σφάλμα-

τος (squared error loss) μετράει το σφάλμα πρόβλεψης μίας υπόθεσης h όταν προβλέπει μία αριθμητική ετικέτα $y \in \mathbb{R}$ από τα χαρακτηριστικά $\mathbf{x}$ ενός σημείου δεδομένων. Ορίζεται ως

$$L((\mathbf{x}, y), h) := \left(y - \underbrace{h(\mathbf{x})}_{=\hat{y}} \right)^2.$$

Βλέπε επίσης: απώλεια, πρόβλεψη, υπόθεση, ετικέτα, χαρακτηριστικό, σημείο δεδομένων.

απώλεια Huber Η απώλεια Huber (Huber loss) ενώνει την απώλεια τετραγωνικού σφάλματος και την απώλεια απόλυτου σφάλματος.

Βλέπε επίσης: απώλεια, απώλεια τετραγωνικού σφάλματος, απώλεια απόλυτου σφάλματος.


αρχή της ελαχιστοποίησης των δεδομένων Ο Ευρωπαϊκός κανονισμός για την προστασία δεδομένων περιλαμβάνει μία αρχή ελαχιστοποίησης δεδομένων (data minimization principle). Αυτή η αρχή απαιτεί έναν υπεύθυνο επεξεργασίας δεδομένων για να περιορίσει τη συλλογή προσωπικών πληροφοριών σε ό,τι είναι άμεσα σχετικό και απαραίτητο για την εκπλήρωση ενός προσδιορισμένου σκοπού. Τα δεδομένα πρέπει να φυλάσσονται μόνο για το χρονικό διάστημα που είναι απαραίτητα προκειμένου να εκπληρωθεί αυτός ο σκοπός [90, Άρθρο 5(1)(c)], [91].

Βλέπε επίσης: δεδομένα.

αυτοεποπτευόμενη μάθηση Η αυτοεποπτευόμενη μάθηση (self-supervised learning) χρησιμοποιεί κάποια από τα χαρακτηριστικά ενός σημείου δεδομένων ως ετικέτα του. Για παράδειγμα, αν ένα σημείο δεδομένων α-

ποτελείται από μία πρόταση μέσα σε ένα έγγραφο κειμένου, μπορούμε να χρησιμοποιήσουμε την τελευταία λέξη της πρότασης ως την ετικέτα που πρέπει να προβλεφθεί από όλες τις προηγούμενες λέξεις, οι οποίες αποτελούν τα χαρακτηριστικά του σημείου δεδομένων. Μία κύρια εφαρμογή της αυτοεποπτευόμενης μάθησης είναι στην ΕΦΓ για την εκπαίδευση μεγάλων γλωσσικών μοντέλων από μεγάλες συλλογές δεδομένων κειμένου. Βλέπε επίσης: χαρακτηριστικό, σημείο δεδομένων, ετικέτα, επεξεργασία φυσικής γλώσσας (ΕΦΓ), εκπαίδευση, μεγάλο γλωσσικό μοντέλο, δεδομένα.

αυτοκωδικοποιητής Ένας αυτοκωδικοποιητής (autoencoder) είναι μία μέθοδος μηχανικής μάθησης που μαθαίνει ταυτόχρονα μία απεικόνιση κωδικοποιητή $h \in \mathcal{H}$ και μία απεικόνιση αποκωδικοποιητή $h^* \in \mathcal{H}^*$. Διαφορετικοί αυτοκωδικοποιητές χρησιμοποιούν διαφορετικά μοντέλα $\mathcal{H}, \mathcal{H}^*$, π.χ. ΤΝΔ με διαφορετικές αρχιτεκτονικές. Η ειδική περίπτωση αυτοκωδικοποιητή που χρησιμοποιεί γραμμικά μοντέλα (διανυσματικό τιμής) για τα $\mathcal{H}, \mathcal{H}^*$ οδηγεί στην ανάλυση κύριων συνιστωσών.



Σχ. 39. Αυτοκωδικοποιητής με έναν κωδικοποιητή h που αντιστοιχίζει $\mathbf{x} \mapsto \mathbf{z}$ και έναν αποκωδικοποιητή h^* που αντιστοιχίζει $\mathbf{z} \mapsto \hat{\mathbf{x}}$.

Η εκπαίδευση του κωδικοποιητή και του αποκωδικοποιητή μπορεί να υλοποιηθεί μέσω ελαχιστοποίησης εμπειρικής διακινδύνευσης χρησιμοποιώντας μία απώλεια που μετράει την απόκλιση του ανακατασκευασμένου

διανύσματος χαρακτηριστικών $h^*(h(\mathbf{x}))$ από το αρχικό διάνυσμα χαρακτηριστικών $\mathbf{x}$.

Βλέπε επίσης: μηχανική μάθηση, κωδικοποιητής, απεικόνιση, μοντέλο, ΤΝΔ, διάνυσμα, γραμμικό μοντέλο, ανάλυση κύριων συνιστωσών, εκπαίδευση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια, διάνυσμα χαρακτηριστικών, μάθηση χαρακτηριστικών, μείωση της διαστασιμότητας.

βαθιά μάθηση Βλέπε βαθύ δίκτυο.


βαθμός συσχέτισης Ο βαθμός συσχέτισης (degree of belonging) είναι ένας αριθμός που υποδεικνύει το κατά πόσο ένα σημείο δεδομένων ανήκει σε μία συστάδα [8, Κεφ. 8]. Ο βαθμός συσχέτισης μπορεί να ερμηνευτεί ως μία μαλακή απόδοση συστάδας. Οι μέθοδοι μαλακής συσταδοποίησης μπορούν να κωδικοποιήσουν τον βαθμό συσχέτισης με έναν πραγματικό αριθμό στο διάστημα $[0, 1]$. Η σκληρή συσταδοποίηση προκύπτει ως η ακραία περίπτωση όταν ο βαθμός συσχέτισης παίρνει μόνο τιμές 0 or 1. Βλέπε επίσης: σημείο δεδομένων, συστάδα, μαλακή συσταδοποίηση, σκληρή συσταδοποίηση.

βαθύ δίκτυο Ένα βαθύ δίκτυο (deep net) είναι ένα ΤΝΔ με έναν (σχετικά) μεγάλο αριθμό κρυφών στρωμάτων. Η βαθιά μάθηση είναι ένας όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που χρησιμοποιούν ένα βαθύ δίκτυο ως μοντέλο τους [60].

Βλέπε επίσης: ΤΝΔ, στρώμα, βαθιά μάθηση, μηχανική μάθηση, μοντέλο, μεγάλο γλωσσικό μοντέλο.

βάρος Θεωρούμε έναν παραμετροποιημένο χώρο υποθέσεων $\mathcal{H}$. Χρησιμοποι-

ούμε τον όρο βάρη (weights) για αριθμητικές παραμέτρους μοντέλου που χρησιμοποιούνται για να κλιμακώσουν χαρακτηριστικά ή τους μετασχηματισμούς τους προκειμένου να υπολογίσουμε $h^{(\mathbf{w})} \in \mathcal{H}$. Ένα γραμμικό μοντέλο χρησιμοποιεί βάρη $\mathbf{w} = (w_1, \dots, w_d)^T$ για να υπολογίσει τον γραμμικό συνδυασμό $h^{(\mathbf{w})}(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$. Βάρη χρησιμοποιούνται επίσης σε ΤΝΔ για να σχηματιστούν γραμμικοί συνδυασμοί χαρακτηριστικών ή των εξόδων νευρώνων σε κρυφά στρώματα (βλέπε Σχ. 40).



Σχ. 40. Ένα τμήμα ενός ΤΝΔ που περιέχει ένα κρυφό στρώμα με εξόδους (ή ενεργοποιήσεις) h_1 , h_2 , και h_3 . Αυτές οι εξοδοί συνδυάζονται γραμμικά για να υπολογιστεί ο z , ο οποίος μπορεί να χρησιμοποιηθεί είτε ως έξοδος του ΤΝΔ είτε ως είσοδος σε ένα άλλο στρώμα.

Βλέπε επίσης: χώρος υποθέσεων, παράμετρος μοντέλου, χαρακτηριστικό, γραμμικό μοντέλο, ΤΝΔ, έξοδος, νευρώνας, στρώμα, ενεργοποίηση.

βάρος ακμής Σε κάθε ακμή $\{i, i'\}$ ενός δικτύου ομοσπονδιακής μάθησης αποδίδεται ένα μη αρνητικό βάρος ακμής (edge weight) $A_{i,i'} \geq 0$. Ένα μηδενικό βάρος ακμής $A_{i,i'} = 0$ υποδεικνύει την απουσία μίας ακμής μεταξύ των κόμβων $i, i' \in \mathcal{V}$.

Βλέπε επίσης: δίκτυο ομοσπονδιακής μάθησης.

βάση αναφοράς TBC.

γείτονας Ένας γείτονας (neighbor) ενός κόμβου $i \in \mathcal{V}$ εντός ενός μη κατευθυνόμενου γράφου είναι ένας κόμβος $i' \in \mathcal{V} \setminus \{i\}$ που συνδέεται με τον κόμβο i μέσω μίας ακμής.

Βλέπε επίσης: μη κατευθυνόμενος γράφος, συνδεδεμένος.

γενικευμένη ολική μεταβολή Η γενικευμένη ολική μεταβολή (generalized total variation - GTV) είναι ένα μέτρο της μεταβολής των εκπαιδευμένων τοπικών μοντέλων $h^{(i)}$ (ή των παραμέτρων του μοντέλου τους $\mathbf{w}^{(i)}$) που αποδίδονται στους κόμβους $i = 1, \dots, n$ ενός μη κατευθυνόμενου σταθμισμένου γράφου $\mathcal{G}$ με ακμές $\mathcal{E}$. Δεδομένου ενός μέτρου $d^{(h,h')}$ της απόκλισης μεταξύ απεικονίσεων υπόθεσης h, h' , η γενικευμένη ολική μεταβολή είναι

$$\sum_{\{i,i'\} \in \mathcal{E}} A_{i,i'} d^{(h^{(i)}, h^{(i')})}.$$

Εδώ $A_{i,i'} > 0$ δηλώνει το βάρος της μη κατευθυνόμενης ακμής $\{i, i'\} \in \mathcal{E}$.

Βλέπε επίσης: μέτρο, τοπικό μοντέλο, παράμετρος μοντέλου, γράφος, απόκλιση, υπόθεση, απεικόνιση.

γενικευμένο προσθετικό μοντέλο TBC.

γενίκευση TBC.

γινόμενο Kronecker Το γινόμενο Kronecker (Kronecker product) δύο πινάκων $\mathbf{A} \in \mathbb{R}^{m \times n}$ και $\mathbf{B} \in \mathbb{R}^{p \times q}$ είναι ένας σύνθετος πίνακας που δηλώνει-

ται με $\mathbf{A} \otimes \mathbf{B}$ και ορίζεται ως [3], [46]

$$\mathbf{A} \otimes \mathbf{B} = \begin{pmatrix} a_{11}\mathbf{B} & \cdots & a_{1n}\mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m1}\mathbf{B} & \cdots & a_{mn}\mathbf{B} \end{pmatrix} \in \mathbb{R}^{mp \times nq}.$$

Το γινόμενο Kronecker είναι μία ειδική περίπτωση του τανυστικού γινομένου για πίνακες και χρησιμοποιείται ευρέως στην πολυμεταβλητή στατιστική, στη γραμμική άλγεβρα, και σε δομημένα μοντέλα μηχανικής μάθησης. Ικανοποιεί την ταυτότητα $(\mathbf{A} \otimes \mathbf{B})(\mathbf{x} \otimes \mathbf{y}) = (\mathbf{A}\mathbf{x}) \otimes (\mathbf{B}\mathbf{y})$ για διανύσματα $\mathbf{x}$ και $\mathbf{y}$ συμβατών διαστάσεων.

Βλέπε επίσης: πίνακας, μηχανική μάθηση, μοντέλο, διάνυσμα.


Γκαουσιανό μοντέλο μείγματος Ένα Γκαουσιανό μοντέλο μείγματος (Gaussian mixture model - GMM) είναι ένα πιθανοτικό μοντέλο για σημεία δεδομένων (ή την παραγωγή σημείων δεδομένων) με αριθμητικά διανύσματα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$ [61], [92]. Υποθέτει ότι κάθε σημείο δεδομένων παράγεται αρχικά με την εξαγωγή ενός λανθάνοντος δείκτη συστάδας $I \in \{1, \dots, k\}$ σύμφωνα με τις πιθανότητες συστάδων

$$\mathbb{P}(I = c) = p_c, \quad \sum_{c=1}^k p_c = 1.$$

Υπό τον όρο $I = c$, το διάνυσμα χαρακτηριστικών $\mathbf{x}$ προέρχεται από μία πολυμεταβλητή κανονική κατανομή $\mathbb{P}^{(c)} = \mathcal{N}(\boldsymbol{\mu}^{(c)}, \mathbf{C}^{(c)})$. Η επακόλουθη περιθώρια κατανομή του $\mathbf{x}$ είναι επομένως ένα σταθμισμένο άθροισμα

πολυμεταβλητών κανονικών κατανομών, δηλαδή

$$\mathbb{P} = \sum_{c=1}^k p_c \mathcal{N}(\boldsymbol{\mu}^{(c)}, \mathbf{C}^{(c)}) .$$



Σχ. 41. Εικονογράφηση ενός Γκαουσιανού μοντέλου μείγματος με τρεις συνιστώσες.

Ένα Γκαουσιανό μοντέλο μείγματος παραμετροποιείται από την ανάλογη με τη συστάδα πιθανότητα p_c , τη μέση τιμή $\boldsymbol{\mu}^{(c)}$, και τον πίνακα συνδιακύμανσης $\mathbf{C}^{(c)}$ για $c = 1, \dots, k$.

Βλέπε επίσης: πιθανοτικό μοντέλο, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, συστάδα, πιθανότητα, πολυμεταβλητή κανονική κατανομή, περιθώρια κατανομή, μέση τιμή, πίνακας συνδιακύμανσης, συσταδοποίηση.

γραμμικά ελάχιστα τετράγωνα TBC.

γραμμική διακρίνουσα ανάλυση Η γραμμική διακρίνουσα ανάλυση (linear discriminant analysis - LDA) είναι μία κλασική μέθοδος μάθησης χαρακτηριστικών [61], [93]. Στο πλαίσιο προβλημάτων δυαδικής ταξινόμησης, η γραμμική διακρίνουσα ανάλυση επιδιώκει μία γραμμική απεικόνιση χαρακτηριστικών $\phi^{(\mathbf{w})} : \mathbb{R}^d \rightarrow \mathbb{R} : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}$ έτσι ώστε το νέο χαρακτη-

ριστικό $\phi^{(\mathbf{w})}(\mathbf{x})$ να μας επιτρέπει με βέλτιστο τρόπο να προβλέψουμε την ετικέτα ενός σημείου δεδομένων.


Βλέπε επίσης: μάθηση χαρακτηριστικών, δυαδική ταξινόμηση, απεικόνιση χαρακτηριστικών, χαρακτηριστικό, ετικέτα, σημείο δεδομένων, μείωση της διαστασιμότητας, αυτοεποπτευόμενη μάθηση.

γραμμική παλινδρόμηση Οι μέθοδοι γραμμικής παλινδρόμησης (linear regression) μαθαίνουν μία γραμμική απεικόνιση υπόθεσης $h^{(\mathbf{w})}(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ που χρησιμοποιείται για την πρόβλεψη της αριθμητικής ετικέτας $y \in \mathbb{R}$ ενός σημείου δεδομένων με βάση τα αριθμητικά διανύσματα χαρακτηριστικών του $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$. Η παραλλαγή ελάχιστων τετραγώνων της γραμμικής παλινδρόμησης μετράει την ποιότητα μίας απεικόνισης υπόθεσης μέσω της μέσης απώλειας τετραγωνικού σφάλματος που προκαλείται σε ένα σύνολο εκπαίδευσης

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}).$$

Ως μία περίπτωση ελαχιστοποίησης εμπειρικής διακινδύνευσης, η γραμμική (ελάχιστων τετραγώνων) παλινδρόμηση μαθαίνει τις παραμέτρους του μοντέλου $\mathbf{w}$ λύνοντας το ακόλουθο πρόβλημα βελτιστοποίησης:

$$\min_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{m} \sum_{r=1}^m (y^{(r)} - \mathbf{w}^T \mathbf{x}^{(r)})^2.$$



Σχ. 42. Για ένα γραμμικό μοντέλο με $d = 1$ και χρησιμοποιώντας το τετριμμένο χαρακτηριστικό $x = 1$ για οποιοδήποτε σημείο δεδομένων, η γραμμική παλινδρόμηση ανάγεται στον υπολογισμό του μέσου όρου $\hat{w} = (1/m) \sum_{r=1}^m y^{(r)}$. (a) Καθαρό σύνολο εκπαίδευσης και η επακόλουθη παράμετρος (που δίνεται από τον μέσο όρο). (b) Διαταραγμένο σύνολο δεδομένων (που περιλαμβάνει μία ακραία τιμή) και η επακόλουθη παράμετρος.

Μπορούμε να ξαναγράψουμε το παραπάνω πρόβλημα βελτιστοποίησης πιο συμπαγώς χρησιμοποιώντας τον πίνακα χαρακτηριστικών $\mathbf{X} = (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})^T \in \mathbb{R}^{m \times d}$ και το διάνυσμα ετικετών $\mathbf{y} = (y^{(1)}, \dots, y^{(m)})^T \in \mathbb{R}^m$. Αυτό μας επιτρέπει να ξαναγράψουμε το παραπάνω πρόβλημα βελτιστοποίησης ως

$$\min_{\mathbf{w} \in \mathbb{R}^d} \frac{1}{m} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2.$$

Από τη συνθήκη μηδενικής κλίσης, μία απαραίτητη και επαρκής συνθήκη ώστε ένα διάνυσμα $\hat{\mathbf{w}}$ να είναι μία λύση του παραπάνω προβλήματος βελτιστοποίησης είναι το γραμμικό σύστημα εξισώσεων [30]:

$$\mathbf{X}^T \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^T \mathbf{y}. \quad (2)$$

Αντί να λύνουμε άμεσα την (2) (μέσω του υπολογισμού του αντίστροφου πίνακα ή του ψευδοαντίστροφου), πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν παραλλαγές της καθόδου κλίσης για να κατασκευάσουν μία ακολουθία $\mathbf{w}^{(0)}, \mathbf{w}^{(1)}, \dots$ ολοένα και περισσότερο ακριβών προσεγγίσεων μία λύσης $\hat{\mathbf{w}}$ της (2). Αυτές οι μέθοδοι με βάση την κλίση μπορούν να ερμηνευτούν ως μία επανάληψη σταθερού σημείου για την ακόλουθη αναδιατύπωση της (2):

$$(\mathbf{I} - \mathbf{A}\mathbf{X}^T\mathbf{X})\hat{\mathbf{w}} + \mathbf{X}^T\mathbf{y} = \hat{\mathbf{w}} \quad \text{για κάποιον αντιστρέψιμο πίνακα } \mathbf{A}.$$

Αυτή η εξίσωση λύνεται από ένα διάνυσμα $\hat{\mathbf{w}}$ αν και μόνο αν αυτό το διάνυσμα επίσης λύνει την (2). Η συνθήκη του βέλτιστου (2) είναι επίσης χρήσιμη για τη μελέτη της ευστάθειας της γραμμικής παλινδρόμησης. Ιδανικά, θα θέλαμε οι λύσεις της (2) να μην επηρεάζονται σημαντικά από μικρές διαταραχές του συνόλου εκπαίδευσης. Μπορούμε να αποτυπώσουμε αυτές τις διαταραχές μέσω ενός διαταραγμένου πίνακα χαρακτηριστικών $\tilde{\mathbf{X}} = \mathbf{X} + \Delta\mathbf{X}$ και ενός διαταραγμένου διανύσματος ετικετών $\tilde{\mathbf{y}} = \mathbf{y} + \Delta\mathbf{y}$. Εδώ $\Delta\mathbf{X}$ και $\Delta\mathbf{y}$ αναπαριστούν μικρές διαταραχές στα διανύσματα χαρακτηριστικών και στις ετικέτες των σημείων δεδομένων του αρχικού συνόλου εκπαίδευσης. Η θεωρία διαταραχών πινάκων μας επιτρέπει να αξιολογήσουμε πόσο αποκλίνουν οι λύσεις του διαταραγμένου προβλήματος γραμμικής παλινδρόμησης [3, Ενότητα 2.6]

$$\tilde{\mathbf{X}}^T\tilde{\mathbf{X}}\tilde{\mathbf{w}} = \tilde{\mathbf{X}}^T\tilde{\mathbf{y}}$$

από τις λύσεις $\tilde{\mathbf{w}}$ του αρχικού προβλήματος γραμμικής παλινδρόμησης.

Βλέπε επίσης: παλινδρόμηση, υπόθεση, απεικόνιση, ετικέτα, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, απώλεια τετραγωνικού σφάλματος, σύνολο εκπαίδευσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, παράμετρος μοντέλου, πρόβλημα βελτιστοποίησης, ακραία τιμή, γραμμικό μοντέλο, χαρακτηριστικό, παράμετρος, σύνολο δεδομένων, πίνακας χαρακτηριστικών, διάνυσμα, συνθήκη μηδενικής κλίσης, αντίστροφος πίνακας, ψευδοαντίστροφος, μηχανική μάθηση, κάθοδος κλίσης, ακολουθία, μέθοδος με βάση την κλίση, επανάληψη σταθερού σημείου, αντιστρέψιμος, πίνακας, ευστάθεια.

γραμμικό μοντέλο TBC.

γραμμικός ταξινομητής Θεωρούμε σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά χαρακτηριστικά $\mathbf{x} \in \mathbb{R}^d$ και μία ετικέτα $y \in \mathcal{Y}$ από κάποιον πεπερασμένο χώρο ετικετών $\mathcal{Y}$. Ένας γραμμικός ταξινομητής (linear classifier) χαρακτηρίζεται από το γεγονός ότι έχει περιοχές αποφάσεων που διαχωρίζονται από υπερεπίπεδα στον $\mathbb{R}^d$ [8, Κεφ. 2].

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, χώρος ετικετών, ταξινομητής, περιοχή αποφάσεων, υπερεπίπεδο.

γράφος ομοιότητας Κάποιες εφαρμογές μηχανικής μάθησης παράγουν σημεία δεδομένων που σχετίζονται μέσω μίας ειδικής για τον εκάστοτε τομέα έννοιας ομοιότητας. Αυτές οι ομοιότητες μπορούν να αναπαρασταθούν με ευκολία χρησιμοποιώντας έναν γράφο ομοιότητας (similarity graph) $\mathcal{G} = (\mathcal{V} := \{1, \dots, m\}, \mathcal{E})$. Ο κόμβος $r \in \mathcal{V}$ αναπαριστά το r -οστό σημείο δεδομένων. Δύο κόμβοι συνδέονται με μία μη κατευθυνόμενη ακμή αν τα αντίστοιχα σημεία δεδομένων είναι όμοια.

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, γράφος, συνδεδεμένος.

δεδομένα Στο πλαίσιο της μηχανικής μάθησης, ο όρος δεδομένα (data) χρησιμοποιείται συχνά ως συνώνυμο του συνόλου δεδομένων [44], [45]. Το πρότυπο ISO/IEC 2382:2015 [94] ορίζει τα δεδομένα ως μία

reinterpretable representation of information in a formalized manner suitable for communication, interpretation, or processing

(δηλαδή μία «επανερμηνεύσιμη αναπαράσταση πληροφοριών με έναν τυποποιημένο τρόπο κατάλληλο για επικοινωνία, ερμηνεία, ή επεξεργασία»).



Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, σημείο δεδομένων, δείγμα.

δεδομένα σε μορφή πίνακα Τα δεδομένα σε μορφή πίνακα (tabular data) αποτελούνται από σημεία δεδομένων που χαρακτηρίζονται από ένα κοινό σύνολο ιδιοχαρακτηριστικών. Αυτά τα ιδιοχαρακτηριστικά μπορούν να χρησιμοποιηθούν ως τα χαρακτηριστικά ή οι ετικέτες των σημείων δεδομένων. Αν τα ιδιοχαρακτηριστικά είναι αριθμητικά, μπορούμε να αναπαράστησουμε ένα σύνολο δεδομένων με έναν πίνακα δεδομένων $\mathbf{D} \in \mathbb{R}^{m \times d}$, όπου καθεμία από τις m γραμμές αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και καθεμία από τις d στήλες αναπαριστά ένα συγκεκριμένο ιδιοχαρακτηριστικό [95].

Βλέπε επίσης: δεδομένα, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, σύνολο δεδομένων, πίνακας δεδομένων.

δειγματικός χώρος Ένας δειγματικός χώρος (sample space) είναι το σύνολο όλων των πιθανών εκβάσεων ενός τυχαίου πειράματος [6], [7], [10], [9].
Βλέπε επίσης: δείγμα, έκβαση, τυχαίο πείραμα, χώρος πιθανοτήτων.

δέντρο αποφάσεων Ένα δέντρο αποφάσεων (decision tree) είναι μία αναπαράσταση τύπου διαγράμματος ροής μίας απεικόνισης υπόθεσης h . Πιο τυπικά, ένα δέντρο αποφάσεων είναι ένας κατευθυνόμενος μη κυκλικός γράφος που περιέχει έναν κόμβο ρίζας, ο οποίος διαβάζει το διάνυσμα χαρακτηριστικών $\mathbf{x}$ ενός σημείου δεδομένων. Ο κόμβος ρίζας προωθεί στη συνέχεια το σημείο δεδομένων σε έναν από τους θυγατρικούς του κόμβους με βάση κάποιον στοιχειώδη έλεγχο πάνω στα χαρακτηριστικά $\mathbf{x}$. Αν ο θυγατρικός κόμβος που λαμβάνει δεν είναι ένας κόμβος φύλλου, δηλαδή αν ο ίδιος έχει θυγατρικούς κόμβους, τότε αναπαριστά έναν άλλον έλεγχο. Με βάση το αποτέλεσμα του ελέγχου, το σημείο δεδομένων προωθείται σε έναν από τους απογόνους του. Αυτή η διαδικασία ελέγχου και προώθησης του σημείου δεδομένων συνεχίζεται έως ότου το σημείο δεδομένων καταλήξει σε έναν κόμβο φύλλου χωρίς θυγατρικούς. Βλέπε Σχ. 43 για οπτικές απεικονίσεις.



Σχ. 43. (a) Δέντρο αποφάσεων ως μία αναπαράσταση τύπου διαγράμματος ροής μίας κατά τμήματα σταθεράς υπόθεσης $h : \mathcal{X} \rightarrow \mathbb{R}$. Κάθε τμήμα είναι μία περιοχή αποφάσεων $\mathcal{R}_{\hat{y}} := \{\mathbf{x} \in \mathcal{X} : h(\mathbf{x}) = \hat{y}\}$. Το απεικονιζόμενο δέντρο αποφάσεων μπορεί να εφαρμοστεί σε αριθμητικά διανύσματα χαρακτηριστικών, δηλαδή $\mathcal{X} \subseteq \mathbb{R}^d$. Παραμετροποιείται από το κατώφλι $\varepsilon > 0$ και τα διανύσματα $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$. (b) Δέντρο αποφάσεων που χωρίζει τον χώρο χαρακτηριστικών $\mathcal{X}$ σε περιοχές αποφάσεων. Κάθε περιοχή αποφάσεων $\mathcal{R}_{\hat{y}} \subseteq \mathcal{X}$ αντιστοιχεί σε έναν συγκεκριμένο κόμβο φύλλου στο δέντρο αποφάσεων.


Βλέπε επίσης: υπόθεση, απεικόνιση, κατευθυνόμενος μη κυκλικός γράφος, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, χαρακτηριστικό, περιοχή αποφάσεων, διάνυσμα, χώρος χαρακτηριστικών.

δέσμη Στο πλαίσιο της στοχαστικής καθόδου κλίσης, μία δέσμη (batch) αναφέρεται σε ένα τυχαία επιλεγμένο υποσύνολο του γενικού συνόλου εκπαίδευσης. Χρησιμοποιούμε τα σημεία δεδομένων σε αυτό το υποσύνολο για να εκτιμήσουμε την κλίση του σφάλματος εκπαίδευσης και στη συνέχεια να ενημερώσουμε τις παραμέτρους του μοντέλου. Ο αριθμός των σημείων δεδομένων σε μία δέσμη είναι το μέγεθος δέσμης B , το οποίο είναι μία υπερπαραμέτρος που ελέγχει έναν συμβιβασμό κατά την εκπαίδευση. Έ-

να μικρό μέγεθος δέσμης αποφέρει μία θορυβώδη εκτίμηση κλίσης, αλλά επιτρέπει συχνές ενημερώσεις των παραμέτρων του μοντέλου και μπορεί να βοηθήσει στην αποφυγή τοπικών ελαχίστων. Ένα μεγάλο μέγεθος δέσμης αποφέρει μία πιο ακριβή εκτίμηση κλίσης και επιτρέπει μεγαλύτερο παραλληλισμό δεδομένων μεταξύ συσκευών, αλλά απαιτεί περισσότερη μνήμη ανά ενημέρωση και μπορεί να επιβραδύνει τη σύγκλιση ανά επανάληψη.

Βλέπε επίσης: στοχαστική κάθοδος κλίσης, σύνολο εκπαίδευσης, σημείο δεδομένων, κλίση, σφάλμα εκπαίδευσης, παράμετρος μοντέλου, υπερ-παράμετρος, εκπαίδευση, ελάχιστο, παραλληλισμός δεδομένων, συσκευή, σύγκλιση, επανάληψη.


διάγνωση Θεωρούμε μία μέθοδο βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που οδήγησε σε ένα εκπαιδευμένο μοντέλο (ή μία υπόθεση που έχει μαθευτεί) $\hat{h} \in \mathcal{H}$. Μπορούμε να προβούμε σε διάγνωση (diagnosis) της μεθόδου συγκρίνοντας το σφάλμα εκπαίδευσης E_t με το σφάλμα επικύρωσης E_v που προκαλούνται από την $\hat{h}$ στο σύνολο εκπαίδευσης και στο σύνολο επικύρωσης.



Σχ. 44. Μπορούμε να προβούμε σε διάγνωση μίας μεθόδου μηχανικής μάθησης βασισμένης στην ελαχιστοποίηση εμπειρικής διακινδύνευσης συγκρίνοντας το σφάλμα εκπαίδευσης με το σφάλμα επικύρωσης της μεθόδου. Ιδανικά, και τα δύο βρίσκονται στο ίδιο επίπεδο με μία βάση αναφοράς.

Βλέπε επίσης: βάση αναφοράς, επικύρωση, διασταυρούμενη επικύρωση k -αναδιπλώσεων, γενίκευση.

διάγραμμα διασποράς Μία τεχνική οπτικοποίησης που απεικονίζει σημεία δεδομένων χρησιμοποιώντας σημεία σε ένα 2-D επίπεδο. Το Σχ. 45 απεικονίζει ένα παράδειγμα διαγράμματος διασποράς (scatterplot).



Σχ. 45. Ένα διάγραμμα διασποράς με κυκλικά σημεία, όπου τα σημεία δεδομένων αναπαριστούν ημερήσιες καιρικές συνθήκες στη Φινλανδία. Κάθε σημείο δεδομένων χαρακτηρίζεται από την ελάχιστη ημερήσια θερμοκρασία x ως χαρακτηριστικό και τη μέγιστη ημερήσια θερμοκρασία y ως ετικέτα. Οι θερμοκρασίες έχουν μετρηθεί στον μετεωρολογικό σταθμό Kaisaniemi στο Ελσίνκι του Φινλανδικού Μετεωρολογικού Ινστιτούτου κατά την περίοδο 1 Σεπτεμβρίου 2024—28 Οκτωβρίου 2024.

Ένα διάγραμμα διασποράς μπορεί να επιτρέψει τον οπτικό έλεγχο σημείων δεδομένων που αναπαριστώνται φυσικά από διανύσματα χαρακτηριστικών σε χώρους υψηλής διάστασης.

Βλέπε επίσης: σημείο δεδομένων, ελάχιστο, χαρακτηριστικό, μέγιστο, ετικέτα, Φινλανδικό Μετεωρολογικό Ινστιτούτο, διάνυσμα χαρακτηριστικών, μείωση της διαστασιμότητας.

διαδικτυακή μάθηση Κάποιες μέθοδοι μηχανικής μάθησης είναι σχεδιασμένες ώστε να επεξεργάζονται δεδομένα με διαδοχικό τρόπο, ενημερώνοντας τις παραμέτρους του μοντέλου τους μία κάθε φορά, καθώς νέα σημεία δεδομένων καθίστανται διαθέσιμα. Ένα τυπικό παράδειγμα είναι τα δεδομένα χρονοσειρών, όπως οι ημερήσιες ελάχιστες και μέγιστες θερμοκρασίες που καταγράφονται από έναν μετεωρολογικό σταθμό του Φινλανδικού Μετεωρολογικού Ινστιτούτου. Αυτές οι τιμές σχηματίζουν μία χρονολογική ακολουθία παρατηρήσεων. Κατά τη διάρκεια κάθε χρονικού βήματος t , οι μέθοδοι διαδικτυακής μάθησης (online learning) ενημε-

ρώνουν (ή βελτιώνουν) την τρέχουσα υπόθεση $h^{(t)}$ (ή τις παραμέτρους του μοντέλου $\mathbf{w}^{(t)}$) με βάση το νέο παρατηρούμενο σημείο δεδομένων $\mathbf{z}^{(t)}$. Βλέπε επίσης: μηχανική μάθηση, δεδομένα, παράμετρος μοντέλου, σημείο δεδομένων, ελάχιστο, μέγιστο, Φινλανδικό Μετεωρολογικό Ινστιτούτο, υπόθεση, online gradient descent (online GD), διαδικτυακός αλγόριθμος.

διαδικτυακός αλγόριθμος Ένας διαδικτυακός αλγόριθμος (online algorithm) επεξεργάζεται δεδομένα εισόδου σταδιακά, λαμβάνοντας σημεία δεδομένων ακολουθιακά και λαμβάνοντας αποφάσεις ή παράγοντας εξόδους (ή αποφάσεις) αμέσως, χωρίς να έχει εκ των προτέρων πρόσβαση σε ολόκληρη την είσοδο [96], [97]. Σε αντίθεση με έναν offline αλγόριθμο, ο οποίος έχει διαθέσιμη ολόκληρη την είσοδο από την αρχή, ένας διαδικτυακός αλγόριθμος πρέπει να διαχειρίζεται την αβεβαιότητα σχετικά με μελλοντικές εισόδους και δεν μπορεί να αναθεωρήσει προηγούμενες αποφάσεις. Όμοια με έναν offline αλγόριθμο, αναπαριστούμε έναν διαδικτυακό αλγόριθμο τυπικά ως μία συλλογή πιθανών εκτελέσεων. Ωστόσο, η ακολουθία εκτέλεσης για έναν διαδικτυακό αλγόριθμο έχει μία διαφορετική δομή ως εξής:

$$\text{in}_1, s_1, \text{out}_1, \text{in}_2, s_2, \text{out}_2, \dots, \text{in}_T, s_T, \text{out}_T.$$

Κάθε εκτέλεση ξεκινά από μία αρχική κατάσταση (δηλαδή in_1) και προχωρά μέσω εναλλασσόμενων υπολογιστικών βημάτων, εξόδων (ή αποφάσεων), και εισόδων. Συγκεκριμένα, στο βήμα t , ο αλγόριθμος εκτελεί ένα υπολογιστικό βήμα s_t , παράγει μία έξοδο out_t , και στη συνέχεια λαμβάνει την επόμενη είσοδο (σημείο δεδομένων) in_{t+1} . Ένα αξιοσημείωτο

παράδειγμα διαδικτυακού αλγόριθμου στη μηχανική μάθηση είναι η online GD, η οποία ενημερώνει σταδιακά τις παραμέτρους του μοντέλου καθώς φτάνουν νέα σημεία δεδομένων.

Βλέπε επίσης: αλγόριθμος, δεδομένα, σημείο δεδομένων, έξοδος, αβεβαιότητα, ακολουθία, μηχανική μάθηση, online GD, παράμετρος μοντέλου, διαδικτυακή μάθηση.

διακινδύνευση Θεωρούμε μία υπόθεση h που χρησιμοποιείται για να προβλεφθεί η ετικέτα y ενός σημείου δεδομένων βάσει των χαρακτηριστικών $\mathbf{x}$. Μετράμε την ποιότητα μίας συγκεκριμένης πρόβλεψης χρησιμοποιώντας μία συνάρτηση απώλειας $L((\mathbf{x}, y), h)$. Αν ερμηνεύσουμε τα σημεία δεδομένων ως τις πραγματώσεις ανεξάρτητων και ταυτόσημα κατανεμημένων τυχαίων μεταβλητών, τότε και η $L((\mathbf{x}, y), h)$ γίνεται η πραγμάτωση μίας τυχαίας μεταβλητής. Η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων μας επιτρέπει να ορίσουμε τη διακινδύνευση (risk) μίας υπόθεσης ως την αναμενόμενη απώλεια $\mathbb{E}\{L((\mathbf{x}, y), h)\}$. Σημείωση ότι η διακινδύνευση της h εξαρτάται τόσο από τη συγκεκριμένη επιλογή για τη συνάρτηση απώλειας όσο και από την κατανομή πιθανότητας των σημείων δεδομένων.

Βλέπε επίσης: υπόθεση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό, πρόβλεψη, συνάρτηση απώλειας, πραγμάτωση, ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαία μεταβλητή, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, απώλεια, κατανομή πιθανότητας.

διακινδύνευση Bayes Θεωρούμε ένα πιθανοτικό μοντέλο για μία εφαρμογή μηχανικής μάθησης όπου κάθε σημείο δεδομένων ερμηνεύεται ως μία

τυχαία μεταβλητή. Το πιθανοτικό μοντέλο περιλαμβάνει μία κατανομή πιθανότητας για τα χαρακτηριστικά $\mathbf{x}$ και την ετικέτα y ενός σημείου δεδομένων. Η διακινδύνευση Bayes (Bayes risk) είναι η ελάχιστη πιθανή διακινδύνευση που μπορεί να επιτευχθεί από οποιαδήποτε υπόθεση $h : \mathcal{X} \rightarrow \mathcal{Y}$. Οποιαδήποτε υπόθεση που επιτυγχάνει τη διακινδύνευση Bayes αναφέρεται ως ένας εκτιμητής Bayes [20].

Βλέπε επίσης: πιθανοτικό μοντέλο, μηχανική μάθηση, σημείο δεδομένων, τυχαία μεταβλητή, κατανομή πιθανότητας, χαρακτηριστικό, ετικέτα, διακινδύνευση, ελάχιστο, υπόθεση, εκτιμητής Bayes.

διάνυσμα αποκρίσεων TBC.

διάνυσμα εισόδου Ο όρος διάνυσμα εισόδου (input vector) χρησιμοποιείται συχνά ως συνώνυμο του διανύσματος χαρακτηριστικών ενός σημείου δεδομένων. Σε περιβάλλοντα όπου τα σημεία δεδομένων ανακύπτουν από ένα δυναμικό σύστημα που παρατηρείται προσοδευτικά, τα χαρακτηριστικά προκύπτουν από τη μέτρηση μεταβλητών εισόδου. Αυτές οι μεταβλητές εισόδου χρησιμοποιούνται τότε από μεθόδους μηχανικής μάθησης για την πρόβλεψη της εξόδου του συστήματος (η οποία στην ορολογία της μηχανικής μάθησης είναι μία ετικέτα).

Βλέπε επίσης: διάνυσμα, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, δυναμικό σύστημα, χαρακτηριστικό, μηχανική μάθηση, έξοδος, ετικέτα.

διάνυσμα εξόδου Ο όρος διάνυσμα εξόδου (output vector) χρησιμοποιείται ως συνώνυμο του διανύσματος ετικετών ενός συνόλου δεδομένων [92].

Βλέπε επίσης: έξοδος, διάνυσμα, διάνυσμα ετικετών, σύνολο δεδομένων.

διάνυσμα ετικετών Δεδομένου ενός συνόλου δεδομένων με m σημεία δε-

δομένων με ετικέτες

$$(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}),$$

είναι βολικό να συλλέξουμε τις αντίστοιχες ετικέτες σε ένα μοναδικό διάνυσμα ετικετών (label vector) $\mathbf{y} := (y_1, \dots, y_m)^T$ [61], [75].

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων με ετικέτα, ετικέτα, διάνυσμα, σημείο δεδομένων.

διάνυσμα στόχων TBC.

διάνυσμα χαρακτηριστικών Το διάνυσμα χαρακτηριστικών (feature vector) αναφέρεται σε ένα διάνυσμα $\mathbf{x} = (x_1, \dots, x_d)^T$ του οποίου οι καταχωρίσεις είναι μεμονωμένα χαρακτηριστικά $x_1, \dots, x_d$. Πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν διανύσματα χαρακτηριστικών που ανήκουν σε κάποιον Ευκλείδειο χώρο $\mathbb{R}^d$ πεπερασμένης διάστασης. Για κάποιες μεθόδους μηχανικής μάθησης, ωστόσο, μπορεί να είναι πιο βολικό να δουλεύουμε με διανύσματα χαρακτηριστικών που ανήκουν σε έναν διανυσματικό χώρο άπειρης διάστασης (π.χ. βλέπε μέθοδος πυρήνα). Βλέπε επίσης: χαρακτηριστικό, διάνυσμα, μηχανική μάθηση, Ευκλείδειος χώρος, διανυσματικός χώρος, μέθοδος πυρήνα.

διαρροή ιδιωτικότητας Θεωρούμε μία εφαρμογή μηχανικής μάθησης που επεξεργάζεται ένα σύνολο δεδομένων $\mathcal{D}$ και παραδίδει κάποια έξοδο, όπως οι προβλέψεις που προκύπτουν για νέα σημεία δεδομένων. Διαρροή ιδιωτικότητας (privacy leakage) ανακύπτει αν η έξοδος φέρει πληροφορίες σχετικά με ένα ιδιωτικό (ή ευαίσθητο) χαρακτηριστικό ενός σημείου δε-

δομένων του $\mathcal{D}$ (όπως ενός ανθρώπου). Με βάση ένα πιθανοτικό μοντέλο για την παραγωγή δεδομένων, μπορούμε να μετρήσουμε τη διαρροή ιδιωτικότητας μέσω των αμοιβαίων πληροφοριών μεταξύ της εξόδου και του ευαίσθητου χαρακτηριστικού. Ένα άλλο ποσοτικό μέτρο διαρροής ιδιωτικότητας είναι η διαφορική ιδιωτικότητα. Οι σχέσεις μεταξύ διαφορετικών μέτρων διαρροής ιδιωτικότητας έχουν μελετηθεί στη βιβλιογραφία (βλέπε [98]).

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, έξοδος, πρόβλεψη, σημείο δεδομένων, χαρακτηριστικό, πιθανοτικό μοντέλο, δεδομένα, αμοιβαίες πληροφορίες, μέτρο, διαφορική ιδιωτικότητα, επίθεση της ιδιωτικότητας, γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ).

διάσταση Vapnik–Chervonenkis TBC.

διασταυρούμενη εντροπία Θεωρούμε ένα πρόβλημα ταξινόμησης πολλών τάξεων με έναν χώρο χαρακτηριστικών $\mathcal{X}$ και έναν πεπερασμένο χώρο ετικετών $\mathcal{Y} = \{1, \dots, k\}$. Ένα σημείο δεδομένων με ένα διάνυσμα χαρακτηριστικών $\mathbf{x}$ αναπαρίσταται ως μία συνάρτηση μάζας πιθανότητας $\mathbf{y} = (y_1, \dots, y_k)^T$ πάνω στον $\mathcal{Y}$, όπου y_c δηλώνει την πιθανότητα ένα τυχαία επιλεγμένο σημείο δεδομένων με διάνυσμα χαρακτηριστικών $\mathbf{x}$ να έχει ετικέτα c . Μία υπόθεση $h(\mathbf{x})$ εξάγει μία προβλεπόμενη συνάρτηση μάζας πιθανότητας $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_k)^T$. Η σχετική απώλεια διασταυρούμενης εντροπίας (cross-entropy) είναι [32]

$$L((\mathbf{x}, \hat{\mathbf{y}}), h) := - \sum_{c=1}^k y_c \log \hat{y}_c.$$

Η απώλεια διασταυρούμενης εντροπίας ποσοτικοποιεί την ανομοιότητα μεταξύ της αληθούς συνάρτησης μάζας πιθανότητας $\mathbf{y}$ και της προβλεπόμενης συνάρτησης μάζας πιθανότητας $\hat{\mathbf{y}}$. Αποτελεί επίσης μέτρο του αναμενόμενου αριθμού bits που απαιτούνται για την κωδικοποίηση ετικετών που προέρχονται από την αληθή συνάρτηση μάζας πιθανότητας $\mathbf{y}$ όταν χρησιμοποιείται ένα σχήμα κωδικοποίησης βελτιστοποιημένο για την προβλεπόμενη συνάρτηση μάζας πιθανότητας $\hat{\mathbf{y}}$ [32].

Σημείωση ότι, για δυαδική ταξινόμηση (με $k = 2$), η απώλεια διασταυρούμενης εντροπίας ανάγεται στη λογιστική απώλεια όταν χρησιμοποιείται ένα παραμετρικό μοντέλο με παραμέτρους μοντέλου $\mathbf{w}$ έτσι ώστε $\hat{y}_2/\hat{y}_1 = \exp(\mathbf{w}^T \mathbf{x})$. Επιπλέον, η αναπαράσταση (5) της λογιστικής απώλειας απαιτεί την κωδικοποίηση του χώρου ετικετών $\{1, 2\}$ χρησιμοποιώντας τις τιμές -1 και 1 .

Βλέπε επίσης: ταξινόμηση, χώρος χαρακτηριστικών, χώρος ετικετών, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, συνάρτηση μάζας πιθανότητας, πιθανότητα, ετικέτα, υπόθεση, εντροπία, απώλεια, μέτρο, λογιστική απώλεια, παραμετρικό μοντέλο, παράμετρος μοντέλου.

διασταυρούμενη επικύρωση k -αναδιπλώσεων Η διασταυρούμενη επικύρωση k -αναδιπλώσεων (k -fold cross-validation - k -fold CV) είναι μία μέθοδος για την αξιολόγηση του χάσματος γενίκευσης μίας μεθόδου μηχανικής μάθησης βασισμένης στην ελαχιστοποίηση εμπειρικής διακινδύνευσης. Η ιδέα είναι να διαιρεθεί ένα σύνολο δεδομένων $\mathcal{D}$ ισότιμα σε k υποσύνολα (ή αναδιπλώσεις) $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(k)}$.

	$\mathcal{D}^{(1)}$	$\mathcal{D}^{(2)}$	$\mathcal{D}^{(3)}$	$\mathcal{D}^{(4)}$	$\mathcal{D}^{(5)}$
αναδίπλωση 1	■				
αναδίπλωση 2		■			
αναδίπλωση 3			■		
αναδίπλωση 4				■	
αναδίπλωση 5					■

Σχ. 46. Στη διασταυρούμενη επικύρωση k -αναδιπλώσεων, το διαθέσιμο σύνολο δεδομένων $\mathcal{D}$ διαιρείται ισότιμα σε k αναδιπλώσεις $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(k)}$. Κάθε αναδίπλωση χρησιμοποιείται μία φορά ως σύνολο επικύρωσης, ενώ οι υπόλοιπες $k - 1$ αναδιπλώσεις σχηματίζουν το σύνολο εκπαίδευσης.

Για κάθε αναδίπλωση $b = 1, \dots, k$, εκπαιδεύουμε το μοντέλο στην ένωση όλων των αναδιπλώσεων εκτός του $\mathcal{D}^{(b)}$ και το επικυρώνουμε στο $\mathcal{D}^{(b)}$. Η συνολική επίδοση προκύπτει από τον μέσο όρο των αποτελεσμάτων επικύρωσης σε όλες τις k αναδιπλώσεις.

Βλέπε επίσης: χάσμα γενίκευσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μηχανική μάθηση, σύνολο δεδομένων, σύνολο επικύρωσης, σύνολο εκπαίδευσης, μοντέλο, επικύρωση, σφάλμα επικύρωσης.

διάυλος ιδιωτικότητας Ο διάυλος ιδιωτικότητας (privacy funnel) είναι μία μέθοδος για τη μάθηση μίας απεικόνισης χαρακτηριστικών που παρέχει φιλικά προς την ιδιωτικότητα χαρακτηριστικά για ένα σημείο δεδομένων [99].

Βλέπε επίσης: απεικόνιση χαρακτηριστικών, χαρακτηριστικό, σημείο δεδομένων, ΓΚΠΔ, διαφορική ιδιωτικότητα.

διαφορική ιδιωτικότητα Θεωρούμε κάποια μέθοδο μηχανικής μάθησης $\mathcal{A}$ που διαβάζει ένα σύνολο δεδομένων (π.χ. το σύνολο εκπαίδευσης που

χρησιμοποιείται για την ελαχιστοποίηση εμπειρικής διακινδύνευσης) και παραδίδει κάποια έξοδο $\mathcal{A}(\mathcal{D})$. Η έξοδος θα μπορούσε να είναι είτε οι παράμετροι μοντέλου που έχουν μαθευτεί είτε οι προβλέψεις για συγκεκριμένα σημεία δεδομένων. Η διαφορική ιδιωτικότητα (differential privacy - DP) αποτελεί ένα ακριβές μέτρο της διαρροής ιδιωτικότητας που προκαλείται από την αποκάλυψη της έξοδο. Σε γενικές γραμμές, μία μέθοδος μηχανικής μάθησης είναι διαφορετικά ιδιωτική αν η κατανομή πιθανότητας της εξόδου $\mathcal{A}(\mathcal{D})$ παραμένει σε μεγάλο βαθμό αμετάβλητη όταν το ευαίσθητο ιδιοχαρακτηριστικό ενός σημείου δεδομένων στο σύνολο εκπαίδευσης αλλάζει. Σημείωση ότι η διαφορική ιδιωτικότητα βασίζεται σε ένα πιθανοτικό μοντέλο για μία μέθοδο μηχανικής μάθησης, δηλαδή ερμηνεύουμε την έξοδό της $\mathcal{A}(\mathcal{D})$ ως πραγμάτωση μίας τυχαίας μεταβλητής. Η τυχειότητα στην έξοδο μπορεί να εξασφαλιστεί με τη σκόπιμη προσθήκη της πραγμάτωση μίας βοηθητικής τυχαίας μεταβλητής (δηλαδή με την προσθήκη θορύβου) στην έξοδο της μεθόδου μηχανικής μάθησης.


Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, σύνολο εκπαίδευσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, έξοδος, παράμετρος μοντέλου, πρόβλεψη, σημείο δεδομένων, μέτρο, διαρροή ιδιωτικότητας, κατανομή πιθανότητας, ευαίσθητο ιδιοχαρακτηριστικό, πιθανοτικό μοντέλο, πραγμάτωση, τυχαία μεταβλητή, επίθεση της ιδιωτικότητας, δίαυλος ιδιωτικότητας.

δίκτυο ομοσπονδιακής μάθησης Ένα δίκτυο ομοσπονδιακής μάθησης (federated learning network - FL network) είναι ένα μαθηματικό μοντέλο για ένα σύστημα ομοσπονδιακής μάθησης που αποτελείται από διασυνδεδεμένες συσκευές. Αυτές οι συσκευές αναπαρίστανται από τους κόμβους

$\mathcal{V}$ ενός μη κατευθυνόμενου σταθμισμένου γράφου

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A}).$$

Μία ακμή $\{i, i'\} \in \mathcal{E}$ υποδεικνύει συνεργασίες μεταξύ δύο συσκευών $i, i' \in \mathcal{V}$. Τα βάρη ακμών $A_{i,i'} > 0$ ποσοτικοποιούν την έκταση των συνεργασιών, οι οποίες μπορεί να σχετίζονται με τη χωρητικότητα ενός συνδέσμου επικοινωνίας, τη στατιστική ομοιότητα μεταξύ τοπικών συνόλων δεδομένων, ή και τα δύο. Κάθε συσκευή $i \in \mathcal{V}$ έχει ενδεχομένως πρόσβαση σε ένα τοπικό σύνολο δεδομένων $\mathcal{D}^{(i)}$ και μπορεί να εκπαιδεύσει ένα τοπικό μοντέλο $\mathcal{H}^{(i)}$, π.χ. χρησιμοποιώντας μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης. Πολλές δημοφιλείς μέθοδοι ομοσπονδιακής μάθησης προκύπτουν από τη σύζευξη της εκπαίδευση αυτών των τοπικών μοντέλων στις ακμές του δικτύου ομοσπονδιακής μάθησης [100]. Αυτή η σύζευξη μπορεί να υλοποιηθεί με διαφορετικούς τρόπους, π.χ. με τη χρήση ενός όρου ποινής που επιβάλλει ομοιότητα μεταξύ των παραμέτρων μοντέλου γειτονικών συσκευών, ή με τη χρήση των προβλέψεων γειτονικών συσκευών για την επαύξηση των τοπικών συνόλων δεδομένων. Το Σχ. 47 απεικονίζει ένα δίκτυο ομοσπονδιακής μάθησης με τέσσερις συσκευές.



Σχ. 47. Ένα δίκτυο ομοσπονδιακής μάθησης με κόμβους $\mathcal{V} = \{i_1, i_2, i_3, i_4\}$ που αναπαριστούν τέσσερις συσκευές ενός συστήματος ομοσπονδιακής μάθησης.

Το δίκτυο ομοσπονδιακής μάθησης προσδιορίζει ποιες συσκευές μπορούν να αλληλεπιδρούν και σε τι βαθμό.

Βλέπε επίσης: ομοσπονδιακή μάθηση, σύστημα ομοσπονδιακής μάθησης, συσκευή, γράφος, βάρος ακμής, τοπικό σύνολο δεδομένων, τοπικό μοντέλο, ελαχιστοποίηση εμπειρικής διακινδύνευσης, εκπαίδευση, όρος ποιότητας, παράμετρος μοντέλου, πρόβλεψη, γράφος, ελαχιστοποίηση γενικευμένης ολικής μεταβολής.

networked data TBC.

δικτυωμένη εκθετική οικογένεια TBC.

δικτυωμένη ομοσπονδιακή μάθηση TBC.

δικτυωμένο μοντέλο TBC.

δομική ελαχιστοποίηση διακινδύνευσης Η δομική ελαχιστοποίηση διακινδύνευσης (structural risk minimization - SRM) είναι μία περίπτωση ομαλοποιημένης ελαχιστοποίησης εμπειρικής διακινδύνευσης, με την οποία το μοντέλο $\mathcal{H}$ μπορεί να εκφραστεί ως μία αριθμήσιμη ένωση υπομοντέλων, έτσι ώστε $\mathcal{H} = \bigcup_{n=1}^{\infty} \mathcal{H}^{(n)}$. Κάθε υπομοντέλο $\mathcal{H}^{(n)}$ επιτρέπει την

παραγωγή ενός προσεγγιστικού άνω φράγματος στο σφάλμα γενίκευσης που προκαλείται κατά την εφαρμογή ελαχιστοποίησης εμπειρικής διακινδύνευσης για την εκπαίδευση του $\mathcal{H}^{(n)}$. Αυτά τα μεμονωμένα φράγματα—ένα για κάθε υπομοντέλο—συνδυάζονται έπειτα για να σχηματίσουν έναν ομαλοποιητή που χρησιμοποιείται στον στόχο ομαλοποιημένης ελαχιστοποίησης εμπειρικής διακινδύνευσης. Αυτά τα προσεγγιστικά άνω φράγματα (ένα για κάθε $\mathcal{H}^{(n)}$) συνδυάζονται στη συνέχεια για να κατασκευάσουν έναν ομαλοποιητή για την ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης [78, Ενότητα 7.2].

Βλέπε επίσης: ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης, μοντέλο, αριθμησιμότητα, γενίκευση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, ομαλοποιητής, διακινδύνευση.

δυναμική διασταυρούμενη εντροπία Η απώλεια δυναμικής διασταυρούμενης εντροπίας (binary cross-entropy - BCE) είναι μία ειδική περίπτωση απώλειας διασταυρούμενης εντροπίας για ένα πρόβλημα δυναμικής ταξινόμησης.

Βλέπε επίσης: απώλεια, διασταυρούμενη εντροπία, ταξινόμηση.

δυναμική ταξινόμηση Η δυναμική ταξινόμηση (binary classification) αναφέρεται σε ταξινόμηση με δύο ετικέτες. Οι ετικέτες συνήθως ορίζονται ως $\{-1, 1\}$ ή $\{0, 1\}$.

Βλέπε επίσης: ταξινόμηση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό.

εκπαίδευση Στο πλαίσιο της μηχανικής μάθησης, η εκπαίδευση (training) αναφέρεται στη διαδικασία μάθησης μίας χρήσιμης υπόθεσης $\hat{h}$ από ένα μοντέλο $\mathcal{H}$. Η εκπαίδευση ενός μοντέλου $\mathcal{H}$ καθοδηγείται από την απώλεια

που προκαλείται σε ένα σύνολο σημείων δεδομένων, τα οποία χρησιμεύουν ως το σύνολο εκπαίδευσης. Για παραμετρικά μοντέλα, όπου κάθε υπόθεση $h^{(w)}$ χαρακτηρίζεται από μία συγκεκριμένη επιλογή για τις παραμέτρους του μοντέλου, η εκπαίδευση ισοδυναμεί με την εύρεση μίας βέλτιστης επιλογής για τις παραμέτρους του μοντέλου w . Μία ευρέως χρησιμοποιούμενη προσέγγιση εκπαίδευσης είναι η ελαχιστοποίηση εμπειρικής διακινδύνευσης, η οποία μαθαίνει μία υπόθεση ελαχιστοποιώντας τη μέση απώλεια που προκαλείται σε ένα σύνολο εκπαίδευσης. Μία από τις κύριες προκλήσεις στη μηχανική μάθηση είναι ο έλεγχος της απόκλισης μεταξύ της απώλειας που προκαλείται στο σύνολο εκπαίδευσης και της απώλειας που προκαλείται σε άλλα (μη παρατηρημένα) σημεία δεδομένων. Βλέπε επίσης: μηχανική μάθηση, υπόθεση, μοντέλο, απώλεια, σημείο δεδομένων, σύνολο εκπαίδευσης, παραμετρικό μοντέλο, παράμετρος μοντέλου, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απόκλιση.


εκτιμητής Bayes Θεωρούμε ένα πιθανοτικό μοντέλο με μία από κοινού κατανομή πιθανότητας $p(\mathbf{x}, y)$ πάνω στα χαρακτηριστικά $\mathbf{x}$ και την ετικέτα y ενός σημείου δεδομένων. Για μία δεδομένη συνάρτηση απώλειας $L(\cdot, \cdot)$, αναφερόμαστε σε μία υπόθεση h ως έναν εκτιμητή Bayes (Bayes estimator) αν η διακινδύνευσή της $\mathbb{E}\{L((\mathbf{x}, y), h)\}$ είναι η ελάχιστη επιτεύξιμη διακινδύνευση [20]. Σημείωση ότι το αν μία υπόθεση πληροί τις προϋποθέσεις για να θεωρηθεί εκτιμητής Bayes εξαρτάται από την υποκείμενη κατανομή πιθανότητας και την επιλογή για τη συνάρτηση απώλειας $L(\cdot, \cdot)$. Βλέπε επίσης: πιθανοτικό μοντέλο, κατανομή πιθανότητας, χαρακτηριστικό, ετικέτα, σημείο δεδομένων, συνάρτηση απώλειας, υπόθεση, εκτιμητής, διακινδύνευση, ελάχιστο.

ελάχιστα τετράγωνα TBC.

ελαχιστοποίηση γενικευμένης ολικής μεταβολής Η ελαχιστοποίηση γενικευμένης ολικής μεταβολής (generalized total variation minimization - GTVMin) είναι μία περίπτωση ομαλοποιημένης ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιεί την γενικευμένη ολική μεταβολή τοπικών παραμέτρων μοντέλου ως έναν ομαλοποιητή [101].
Βλέπε επίσης: ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης, γενικευμένη ολική μεταβολή, παράμετρος μοντέλου, ομαλοποιητής.

ελαχιστοποίηση εμπειρικής διακινδύνευσης Η ελαχιστοποίηση εμπειρικής διακινδύνευσης (empirical risk minimization - ERM) είναι το πρόβλημα βελτιστοποίησης της επιλογής μίας υπόθεσης $\hat{h} \in \mathcal{H}$ που ελαχιστοποιεί τη μέση απώλεια (ή εμπειρική διακινδύνευση) σε ένα σύνολο εκπαίδευσης $\mathcal{D}$. Η υπόθεση επιλέγεται από έναν χώρο υποθέσεων (ή μοντέλο) $\mathcal{H}$. Το σύνολο δεδομένων $\mathcal{D}$ αναφέρεται ως σύνολο εκπαίδευσης. Μια πληθώρα μεθόδων μηχανικής μάθησης βασισμένων στην ελαχιστοποίηση εμπειρικής διακινδύνευσης προκύπτει από διαφορετικές επιλογές σχεδιασμού για το σύνολο δεδομένων, το μοντέλο, και την απώλεια [8, Κεφ. 3]. Το Σχ. 48 απεικονίζει την ελαχιστοποίηση εμπειρικής διακινδύνευσης για ένα γραμμικό μοντέλο και σημεία δεδομένων που χαρακτηρίζονται από ένα μοναδικό χαρακτηριστικό x και μία ετικέτα y . Η υπόθεση h είναι μία γραμμική απεικόνιση που προβλέπει την ετικέτα ενός σημείου δεδομένων ως μία γραμμική συνάρτηση του χαρακτηριστικού του x , δηλαδή $h(x) = w_1x + w_0$, όπου w_1 και w_0 είναι οι παράμετροι μοντέλου της υπόθεσης h . Το πρόβλημα της ελαχιστοποίησης εμπειρικής διακιν-

δύνευσης είναι η εύρεση των παραμέτρων του μοντέλου w_1 και w_0 που ελαχιστοποιούν τη μέση απώλεια (ή εμπειρική διακινδύνευση) που προκαλείται από την υπόθεση h στο σύνολο εκπαίδευσης $\mathcal{D}$.



Σχ. 48. Η ελαχιστοποίηση εμπειρικής διακινδύνευσης μαθαίνει μία υπόθεση $h \in \mathcal{H}$ από ένα μοντέλο $\mathcal{H}$ ελαχιστοποιώντας τη μέση απώλεια (ή εμπειρική διακινδύνευση) $1/m \sum_{r=1}^m L((\mathbf{x}^{(r)}, y^{(r)}), h)$ που προκαλείται σε ένα σύνολο εκπαίδευσης $\mathcal{D}$.

Βλέπε επίσης: πρόβλημα βελτιστοποίησης, υπόθεση, απώλεια, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, χώρος υποθέσεων, μοντέλο, σύνολο δεδομένων, μηχανική μάθηση, γραμμικό μοντέλο, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, γραμμική απεικόνιση, συνάρτηση, παράμετρος μοντέλου, μέθοδος βελτιστοποίησης.

εμβαδόν κάτω από την καμπύλη Το εμβαδόν κάτω από την καμπύλη (area under the curve - AUC) είναι ένα ποσοτικό μέτρο της χρησιμότητας ενός δυαδικού ταξινομητή [102]. Ορίζεται (χρησιμοποιώντας το φυσικό μέτρο του Ευκλείδειου χώρου $\mathbb{R}^2$) ως το εμβαδόν κάτω από την καμπύλη

λειτουργικού χαρακτηριστικού δέκτη.

Βλέπε επίσης: μέτρο, ταξινομητής, Ευκλείδειος χώρος, λειτουργικός χαρακτηριστικός δέκτης.

εμπειρική διακινδύνευση Η εμπειρική διακινδύνευση (empirical risk) $\hat{L}(h|\mathcal{D})$

μίας υπόθεσης σε ένα σύνολο δεδομένων $\mathcal{D}$ είναι η μέση απώλεια που προκαλείται από την h όταν εφαρμόζεται στα σημεία δεδομένων του $\mathcal{D}$.

Βλέπε επίσης: διακινδύνευση, υπόθεση, σύνολο δεδομένων, απώλεια, σημείο δεδομένων.

εμπειρογνώμονας Η μηχανική μάθηση στοχεύει να μάθει μία υπόθεση h που προβλέπει με ακρίβεια την ετικέτα ενός σημείου δεδομένων με βάση τα χαρακτηριστικά του. Μετράμε το σφάλμα πρόβλεψης χρησιμοποιώντας κάποια συνάρτηση απώλειας. Ιδανικά, θέλουμε να βρούμε μία υπόθεση που προκαλεί ελάχιστη απώλεια σε οποιοδήποτε σημείο δεδομένων. Μπορούμε να καταστήσουμε αυτόν τον ανεπίσημο στόχο ακριβή μέσω της παραδοχής ανεξάρτητων και ταυτόσημα κατανεμημένων και χρησιμοποιώντας τη διακινδύνευση Bayes ως τη βάση αναφοράς για τη (μέση) απώλεια μίας υπόθεσης. Μία εναλλακτική προσέγγιση για την απόκτηση μίας βάσης αναφοράς είναι να χρησιμοποιήσουμε την υπόθεση h' που έχει μαθευτεί από μία υπάρχουσα μέθοδο μηχανικής μάθησης. Αναφερόμαστε σε αυτήν την υπόθεση h' ως εμπειρογνώμονα (expert) [96]. Οι μέθοδοι ελαχιστοποίησης ρήτρας μεταβολής γνώμης μαθαίνουν μία υπόθεση που προκαλεί μία απώλεια συγκρίσιμη με εκείνη της καλύτερης εμπειρογνώμονα [96], [97].

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, ετικέτα, σημείο δεδομένων,

χαρακτηριστικό, πρόβλεψη, συνάρτηση απώλειας, απώλεια, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, διακινδύνευση Bayes, βάση αναφοράς, regret.

ενεργοποίηση Η έξοδος ενός τεχνητού νευρώνα εντός ενός ΤΝΔ αναφέρεται ως η ενεργοποίησή του. Συγκεκριμένα, η ενεργοποίηση (activation) προκύπτει από την εφαρμογή μίας (συνήθως μη γραμμικής) συνάρτησης ενεργοποίησης σε ένα σταθμισμένο άθροισμα των εισόδων του. Βλέπε επίσης: έξοδος, τεχνητός νευρώνας, ΤΝΔ, συνάρτηση ενεργοποίησης, βαθύ δίκτυο.

ενσωμάτωση Μία ενσωμάτωση (embedding) είναι μία απεικόνιση h που αναπαριστά σημεία δεδομένων χρησιμοποιώντας τα στοιχεία (ή διανύσματα) ενός δεδομένου διανυσματικού χώρου. Η απεικόνιση κατασκευάζεται έτσι ώστε όμοια αντικείμενα να αναπαρίστανται από όμοια διανύσματα, σύμφωνα με κάποια μετρική στον διανυσματικό χώρο. Οι μέθοδοι μηχανικής μάθησης μαθαίνουν την απεικόνιση $h \in \mathcal{H}$, από ένα μοντέλο $\mathcal{H}$, βελτιστοποιώντας ένα ποσοτικό μέτρο του πόσο καλά αποτυπώνει την εγγενή δομή ενός δεδομένου συνόλου εκπαίδευσης. Για σημεία δεδομένων που ανήκουν σε έναν μετρικό χώρο, μία ευρέως χρησιμοποιούμενη προσέγγιση είναι η ελαχιστοποίηση του σφάλματος ανακατασκευής που προκαλείται από την ενσωμάτωση [60], [103, Κεφ. 13].

Βλέπε επίσης: απεικόνιση, σημείο δεδομένων, διάνυσμα, διανυσματικός χώρος, μετρική, μηχανική μάθηση, μοντέλο, μέτρο, σύνολο εκπαίδευσης, μετρικός χώρος, μάθηση χαρακτηριστικών.


εξαγωγή συμπερασμάτων Στο πλαίσιο της μηχανικής μάθησης, η εξα-

γωγή συμπερασμάτων (inference) αναφέρεται στη διαδικασία αξιολόγησης μίας υπόθεσης που έχει μαθευτεί (ή ενός εκπαιδευμένου μοντέλου) $\hat{h}(\mathbf{x})$ με βάση τα χαρακτηριστικά ενός σημείου δεδομένων [61], [92]. Μία βασική ροή έργου μηχανικής μάθησης ξεκινάει με την εκπαίδευση του μοντέλου και στη συνέχεια χρησιμοποιεί το εκπαιδευμένο μοντέλο για την εξαγωγή συμπερασμάτων.

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, μοντέλο, χαρακτηριστικό, σημείο δεδομένων, εκπαίδευση, απώλεια, ελαχιστοποίηση εμπειρικής διακινδύνευσης.

εξήγηση Μία προσέγγιση για να ενισχυθεί η διαφάνεια μίας μεθόδου μηχανικής μάθησης για τον χρήστη της που είναι άνθρωπος είναι να παρέχεται μία εξήγηση (explanation) μαζί με τις προβλέψεις που παραδίδονται από τη μέθοδο. Οι εξηγήσεις μπορούν να πάρουν διαφορετικές μορφές. Για παράδειγμα, μπορεί να αποτελούνται από κείμενο που είναι αναγνώσιμο από άνθρωπο ή ποσοτικούς δείκτες, όπως βαθμοί σημαντικότητας χαρακτηριστικών για τα μεμονωμένα χαρακτηριστικά ενός συγκεκριμένου σημείου δεδομένων [104]. Εναλλακτικά, οι εξηγήσεις μπορεί να είναι οπτικές—για παράδειγμα, απεικονίσεις έντασης που επισημαίνουν περιοχές της εικόνας που ωθούν την πρόβλεψη [105]. Το Σχ. 49 απεικονίζει δύο τύπους εξηγήσεων. Ο πρώτος είναι μία τοπική γραμμική προσέγγιση $g(\mathbf{x})$ ενός μη γραμμικού εκπαιδευμένου μοντέλου $\hat{h}(\mathbf{x})$ γύρω από ένα συγκεκριμένο διάνυσμα χαρακτηριστικών $\mathbf{x}'$, όπως χρησιμοποιείται στη μέθοδο LIME. Η δεύτερη μορφή εξήγησης που απεικονίζεται στο σχήμα είναι ένα αραιό σύνολο προβλέψεων $\hat{h}(\mathbf{x}^{(1)})$, $\hat{h}(\mathbf{x}^{(2)})$, $\hat{h}(\mathbf{x}^{(3)})$ σε επιλεγμένα διανύσματα χαρακτηριστικών, προσφέροντας συγκεκριμένα σημεία αναφοράς για τον

χρήστη.



Σχ. 49. Ένα εκπαιδευμένο μοντέλο $\hat{h}(\mathbf{x})$ μπορεί να εξηγηθεί τοπικά σε κάποιο σημείο $\mathbf{x}'$ μέσω μίας γραμμικής προσέγγισης $g(\mathbf{x})$. Για μία παραγωγίσιμη $\hat{h}(\mathbf{x})$, αυτή η προσέγγιση καθορίζεται από την κλίση $\nabla \hat{h}(\mathbf{x}')$. Μία άλλη μορφή εξήγησης θα μπορούσε να είναι οι τιμές της συνάρτησης $\hat{h}(\mathbf{x}^{(r)})$ για $r = 1, 2, 3$.

Βλέπε επίσης: διαφάνεια, μηχανική μάθηση, πρόβλεψη, χαρακτηριστικό, σημείο δεδομένων, απεικόνιση, μοντέλο, διάνυσμα χαρακτηριστικών, LIME, παραγωγίσιμη, κλίση, συνάρτηση, ταξινόμηση.

εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης Η εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης (explainable empirical risk minimization - EERM) είναι μία περίπτωση δομικής ελαχιστοποίησης διακινδύνευσης που προσθέτει έναν όρο ομαλοποίησης στη μέση απώλεια στην αντικειμενική συνάρτηση της ελαχιστοποίησης εμπειρικής διακινδύνευσης. Ο όρος ομαλοποίησης επιλέγεται ώστε να ευνοούνται απεικονίσεις υπόθεσης που είναι εγγενώς εξηγήσιμες για έναν συγκεκριμένο χρήστη. Αυτός ο χρήστης χαρακτηρίζεται από τις προβλέψεις του που παρέχονται για τα σημεία δεδομένων σε ένα σύνολο εκπαίδευσης [106]. Βλέπε επίσης: δομική ελαχιστοποίηση διακινδύνευσης, ομαλοποίηση, α-

πώλεια, αντικειμενική συνάρτηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, απεικόνιση, πρόβλεψη, σημείο δεδομένων, σύνολο εκπαίδευσης.


εξηγήσιμη μηχανική μάθηση Οι μέθοδοι εξηγήσιμης μηχανικής μάθησης (explainable machine learning - XML) στοχεύουν να συμπληρώσουν κάθε πρόβλεψη με μία εξήγηση για το πώς έχει προκύψει η πρόβλεψη. Η κατασκευή μίας ρητής εξήγησης μπορεί να μην είναι απαραίτητη αν η μέθοδος μηχανικής μάθησης χρησιμοποιεί ένα επαρκώς απλό (ή ερμηνεύσιμο) μοντέλο [107].

Βλέπε επίσης: πρόβλεψη, εξήγηση, μηχανική μάθηση, μοντέλο.

έξοδος Ο όρος έξοδος (output) χρησιμοποιείται κάποιες φορές ως συνώνυμο της ετικέτας ενός σημείου δεδομένων [92].

Βλέπε επίσης: ετικέτα, σημείο δεδομένων.


επανάληψη Το στοιχειώδες υπολογιστικό βήμα κατά την εκτέλεση ενός αλγόριθμου αναφέρεται ως επανάληψη (iteration) [82], [108]. Για παράδειγμα, το στοιχειώδες υπολογιστικό βήμα των μεθόδων με βάση την κλίση είναι ένα βήμα κλίσης. Πιο γενικά, το στοιχειώδες υπολογιστικό βήμα μίας επανάληψης σταθερού σημείου είναι η αξιολόγηση ενός υποκείμενου τελεστή $\mathcal{F}$, ο οποίος μπορεί να μεταβάλλεται μεταξύ επαναλήψεων (βλέπε Σχ. 50). Πολλοί σημαντικοί αλγόριθμοι μηχανικής μάθησης, συμπεριλαμβανομένων του αλγόριθμου του Lloyd και της καθόδου κλίσης, είναι επαναλήψεις σταθερού σημείου.



Σχ. 50. Επανάληψη σταθερού σημείου που αποτελείται από την επαναλαμβανόμενη εφαρμογή ενός τελεστή $\mathcal{F}$ με κάποιο σταθερό σημείο w^* , δηλαδή $\mathcal{F}w^* = w^*$.

Βλέπε επίσης: αλγόριθμος, μέθοδος με βάση την κλίση, βήμα κλίσης, επανάληψη σταθερού σημείου, τελεστής, μηχανική μάθηση, αλγόριθμος του Lloyd, κάθοδος κλίσης, σταθερό σημείο.

επαύξηση δεδομένων Οι μέθοδοι επαύξησης δεδομένων (data augmentation) προσθέτουν συνθετικά σημεία δεδομένων σε ένα υπάρχον σύνολο σημείων δεδομένων. Αυτά τα συνθετικά σημεία δεδομένων προκύπτουν από διαταραχές (π.χ. προσθήκη θορύβου σε φυσικές μετρήσεις) ή μετασχηματισμούς (π.χ. περιστροφές εικόνων) των αρχικών σημείων δεδομένων. Αυτές οι διαταραχές και οι μετασχηματισμοί είναι τέτοιοι ώστε τα επακόλουθα συνθετικά σημεία δεδομένων να διατηρούν την ίδια ετικέτα. Ως ένα χαρακτηριστικό παράδειγμα, μία περιστραμμένη εικόνα γάτας παραμένει μία εικόνα γάτας ακόμα και αν τα διανύσματα χαρακτηριστικών τους (που προκύπτουν από τη στοίβαξη των εντάσεων χρώματος των εικονοστοιχείων) είναι πολύ διαφορετικά (βλέπε Σχ. 51). Η επαύξηση δεδομένων μπορεί να είναι μία αποτελεσματική μορφή ομαλοποίησης.



Σχ. 51. Η επαύξηση δεδομένων εκμεταλλεύεται τις εγγενείς συμμετρίες των σημείων δεδομένων σε κάποιον χώρο χαρακτηριστικών $\mathcal{X}$. Μπορούμε να αναπαράσθουμε μία συμμετρία με έναν τελεστή $\mathcal{T}^{(\eta)} : \mathcal{X} \rightarrow \mathcal{X}$, παραμετροποιημένο από κάποιον αριθμό $\eta \in \mathbb{R}$. Για παράδειγμα, ο $\mathcal{T}^{(\eta)}$ μπορεί να αναπαριστά την επίδραση της περιστροφής μίας εικόνας γάτας κατά η μοίρες. Ένα σημείο δεδομένων με διάνυσμα χαρακτηριστικών $\mathbf{x}^{(2)} = \mathcal{T}^{(\eta)}(\mathbf{x}^{(1)})$ πρέπει να έχει την ίδια ετικέτα $y^{(2)} = y^{(1)}$ με ένα σημείο δεδομένων με διάνυσμα χαρακτηριστικών $\mathbf{x}^{(1)}$.

Βλέπε επίσης: δεδομένα, σημείο δεδομένων, ετικέτα, διάνυσμα χαρακτηριστικών, στοίβαξη, ομαλοποίηση, χώρος χαρακτηριστικών, τελεστής.

επεξεργασία φυσικής γλώσσας (ΕΦΓ) Η ΕΦΓ (natural language processing - NLP) μελετάει μεθόδους μηχανικής μάθησης για την ανάλυση και παραγωγή ανθρώπινης γλώσσας. Τυπικές εργασίες της ΕΦΓ περιλαμβάνουν την ταξινόμηση κειμένου, τη μηχανική μετάφραση, την ανάλυση συναισθήματος, και την απάντηση ερωτήσεων. Τα σύγχρονα συστήματα ΕΦΓ αναπαριστούν τη γλώσσα ως ακολουθίες από tokens και εκπαιδεύουν μοντέλα που αποτυπώνουν εξαρτήσεις σχετικά με τα πλαίσιο, όπως οι μέθοδοι που βασίζονται στην προσοχή.

Βλέπε επίσης: μηχανική μάθηση, ταξινόμηση, ακολουθία, token, μοντέλο, προσοχή.

επίθεση Μία επίθεση (attack) σε ένα σύστημα μηχανικής μάθησης αναφέρεται σε μία σκόπιμη ενέργεια—είτε ενεργή είτε παθητική—που διακυβεύει την ακεραιότητα, τη διαθεσιμότητα, ή την εμπιστευτικότητα του συστήματος. Οι ενεργές επιθέσεις περιλαμβάνουν τη διαταραχή συνιστωσών όπως τα σύνολα δεδομένων (μέσω δηλητηρίασης δεδομένων) ή τους συνδέσμους επικοινωνίας μεταξύ συσκευών εντός μίας εφαρμογής μηχανικής μάθησης. Οι παθητικές επιθέσεις, όπως οι επιθέσεις της ιδιωτικότητας, στοχεύουν να συμπεράνουν ευαίσθητα ιδιοχαρακτηριστικά χωρίς να τροποποιήσουν το σύστημα. Ανάλογα με τον στόχο τους, μπορούμε να διακρίνουμε ανάμεσα σε επιθέσεις άρνησης υπηρεσιών, επιθέσεις κερκόπορτας, και επιθέσεις της ιδιωτικότητας.


Βλέπε επίσης: σύστημα μηχανικής μάθησης, ενέργεια, σύνολο δεδομένων, δηλητηρίαση δεδομένων, συσκευή, μηχανική μάθηση, επίθεση της ιδιωτικότητας, ευαίσθητο ιδιοχαρακτηριστικό, επίθεση άρνησης υπηρεσιών, κερκόπορτα.

επίθεση της ιδιωτικότητας Μία επίθεση της ιδιωτικότητας (privacy attack) σε ένα σύστημα μηχανικής μάθησης στοχεύει να συμπεράνει ευαίσθητα ιδιοχαρακτηριστικά ατόμων εκμεταλλευόμενη μερική πρόσβαση σε ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Μία μορφή επίθεσης της ιδιωτικότητας είναι η αντιστροφή μοντέλου.

Βλέπε επίσης: επίθεση, σύστημα μηχανικής μάθησης, ευαίσθητο ιδιοχαρακτηριστικό, μηχανική μάθηση, μοντέλο, αντιστροφή μοντέλου, αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN), ΓΚΠΔ.

επικύρωση Θεωρούμε μία υπόθεση $\hat{h}$ που έχει μαθευτεί μέσω κάποιας με-

θόδου μηχανικής μάθησης, π.χ. λύνοντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης σε ένα σύνολο εκπαίδευσης $\mathcal{D}$. Η επικύρωση αναφέρεται στη διαδικασία της αξιολόγησης της απώλειας που προκαλείται από την υπόθεση $\hat{h}$ σε ένα σύνολο σημείων δεδομένων που δεν περιέχονται στο σύνολο εκπαίδευσης $\mathcal{D}$. Αυτό το σύνολο σημείων δεδομένων ονομάζεται σύνολο επικύρωσης. Η μέση απώλεια της $\hat{h}$ στο σύνολο επικύρωσης αναφέρεται ως σφάλμα επικύρωσης. Ένα παράδειγμα επικύρωσης παρουσιάζεται στο Σχ. 52.



Σχ. 52. Απεικόνιση επικύρωσης. Τα μπλε σημεία αναπαριστούν τα σημεία δεδομένων στο σύνολο εκπαίδευσης, ενώ το κόκκινο σημείο αναπαριστά ένα σημείο δεδομένων στο σύνολο επικύρωσης. Η υπόθεση $\hat{h}$ (μαύρη καμπύλη) προσαρμόζεται τέλεια στα σημεία δεδομένων στο σύνολο εκπαίδευσης, αλλά προκαλεί μεγάλη απώλεια στο σημείο δεδομένων του συνόλου επικύρωσης.

Βλέπε επίσης: υπόθεση, μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, απώλεια, σημείο δεδομένων, σύνολο επικύρωσης, σφάλμα επικύρωσης, υπερπροσαρμογή, γενίκευση, διασταυρούμενη επικύρωση k -αναδιπλώσεων, leave-one-out cross-validation (LOO-CV).

επιλογή μοντέλου Στη μηχανική μάθηση, η επιλογή μοντέλου (model selection) αναφέρεται στη διαδικασία επιλογής μεταξύ διαφορετικών υποψήφιων μοντέλων. Στην πιο βασική της μορφή, η επιλογή μοντέλου ισοδυναμεί με τα ακόλουθα βήματα [8, Κεφ. 6]:

- 1) την εκπαίδευση κάθε υποψήφιου μοντέλου.
- 2) τον υπολογισμό του σφάλματος επικύρωσης για κάθε εκπαιδευμένο μοντέλο.
- 3) την επιλογή του μοντέλου με το μικρότερο σφάλμα επικύρωσης.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, εκπαίδευση, σφάλμα επικύρωσης.

εργασία μάθησης Θεωρούμε ένα σύνολο δεδομένων $\mathcal{D}$ που αποτελείται από πολλαπλά σημεία δεδομένων $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$. Για παράδειγμα, το $\mathcal{D}$ μπορεί να είναι μία συλλογή εικόνων σε μία βάση δεδομένων εικόνων. Μία εργασία μάθησης (learning task) ορίζεται με τον προσδιορισμό εκκείνων των ιδιοτήτων (ή ιδιοχαρακτηριστικών) ενός σημείου δεδομένων που χρησιμοποιούνται ως χαρακτηριστικά και ετικέτες του. Δεδομένης μίας επιλογής μοντέλου $\mathcal{H}$ και συνάρτησης απώλειας, μία εργασία μάθησης οδηγεί σε μία περίπτωση ελαχιστοποίησης εμπειρικής διακινδύνευσης και μπορεί έτσι να αναπαρασταθεί από τη σχετική αντικειμενική συνάρτηση $\hat{L}(h|\mathcal{D})$ για $h \in \mathcal{H}$. Σημαντικά, πολλαπλές διαφορετικές εργασίες μάθησης μπορούν να κατασκευαστούν από το ίδιο σύνολο δεδομένων επιλέγοντας διαφορετικά σύνολα χαρακτηριστικών και ετικετών (βλέπε Σχ. 53).



Μία εικόνα που δείχνει αγελάδες να βοσκούν στην αυστριακή ύπαιθρο.

Εργασία 1 (παλινδρόμηση):

Τα χαρακτηριστικά είναι οι τιμές RGB των εικονοστοιχείων, και η ετικέτα είναι ο αριθμός των αγελάδων που απεικονίζονται.

Εργασία 2 (ταξινόμηση):

Τα χαρακτηριστικά περιλαμβάνουν τη μέση ένταση του πράσινου της εικόνας, και η ετικέτα υποδεικνύει εάν οι αγελάδες θα έπρεπε να μεταφερθούν σε άλλη τοποθεσία (δηλαδή ναι/όχι).

Σχ. 53. Δύο εργασίες μάθησης κατασκευασμένες από ένα μοναδικό σύνολο δεδομένων εικόνων. Αυτές οι εργασίες διαφέρουν ως προς την επιλογή χαρακτηριστικών και την επιλογή ετικέτας (δηλαδή τον στόχο), αλλά και οι δύο προέρχονται από το ίδιο σύνολο δεδομένων.

Διαφορετικές εργασίες μάθησης που προκύπτουν από το ίδιο υποκείμενο σύνολο δεδομένων είναι συχνά συζευγμένες. Για παράδειγμα, όταν ένα πιθανοτικό μοντέλο χρησιμοποιείται για την παραγωγή σημείων δεδομένων, οι στατιστικές εξαρτήσεις μεταξύ διαφορετικών ετικετών επάγουν εξαρτήσεις μεταξύ των αντίστοιχων εργασιών μάθησης. Γενικά, η από κοινού λύση εργασιών μάθησης, π.χ. με τη χρήση μεθόδων μάθησης

πολυδιεργασίας, τείνει να είναι πιο αποτελεσματική από την ανεξάρτητη λύση τους (αγνοώντας έτσι τις εξαρτήσεις μεταξύ των εργασιών μάθησης) [109], [110], [111].

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ετικέτας, μοντέλο, συνάρτηση απώλειας, ελαχιστοποίηση εμπειρικής διακινδύνευσης, αντικειμενική συνάρτηση, παλινδρόμηση, ταξινόμηση, πιθανοτικό μοντέλο, μάθηση πολυδιεργασίας, χώρος ετικετών.

ετικέτα Μία ετικέτα είναι ένα υψηλότερου επιπέδου γεγονός ή ποσότητα ενδιαφέροντος που σχετίζεται με ένα σημείο δεδομένων. Για παράδειγμα, αν το σημείο δεδομένων είναι μία εικόνα, η ετικέτα θα μπορούσε να υποδεικνύει αν η εικόνα περιέχει μία γάτα [95], [112], [113].


Βλέπε επίσης: σημείο δεδομένων, χώρος ετικετών.

ευαισθησία Βλέπε ανάκληση.

ευαίσθητο ιδιοχαρακτηριστικό Η μηχανική μάθηση περιστρέφεται γύρω από τη μάθηση μίας απεικόνισης υπόθεσης που μας επιτρέπει να προβλέψουμε την ετικέτα ενός σημείου δεδομένων από τα χαρακτηριστικά του. Σε κάποιες εφαρμογές, πρέπει να εξασφαλίσουμε ότι η έξοδος που παραδίδεται από ένα συστήματος μηχανικής μάθησης δεν μας επιτρέπει να συμπεράνουμε ευαίσθητα ιδιοχαρακτηριστικά (sensitive attributes) ενός σημείου δεδομένων. Ποιο μέρος ενός σημείου δεδομένων θεωρείται ευαίσθητο ιδιοχαρακτηριστικό είναι μία επιλογή σχεδιασμού που ποικίλλει μεταξύ διαφορετικών τομέων εφαρμογής.

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, απεικόνιση, ετικέτα, σημείο δεδομένων, χαρακτηριστικό, έξοδος, σύστημα μηχανικής μάθησης.

ευστάθεια Από μαθηματική άποψη, μία μέθοδος μηχανικής μάθησης είναι μία απεικόνιση $\mathcal{A}$ από ένα συγκεκριμένο σύνολο δεδομένων $\mathcal{D}$ σε μία έξοδο $\mathcal{A}(\mathcal{D})$. Ως ένα χαρακτηριστικό παράδειγμα, θεωρούμε μία μέθοδο μηχανικής μάθησης βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που αντιστοιχίζει ένα σύνολο εκπαίδευσης $\mathcal{D}$ στις παραμέτρους του μοντέλου $\mathcal{A}(\mathcal{D}) = \hat{\mathbf{w}}$ που έχουν μαθευτεί, οι οποίες επιτυγχάνουν την ελάχιστη μέση απώλεια στο σύνολο εκπαίδευσης. Αντί για τις παραμέτρους του μοντέλου που έχουν μαθευτεί, η έξοδος $\mathcal{A}(\mathcal{D})$ θα μπορούσε επίσης να είναι οι προβλέψεις που προκύπτουν από το εκπαιδευμένο μοντέλο. Η ευστάθεια (stability) αναφέρεται στην επιθυμητή ιδιότητα της $\mathcal{A}$, σύμφωνα με την οποία μικρές αλλαγές στο σύνολο δεδομένων εισόδου $\mathcal{D}$ οδηγούν σε μικρές αλλαγές στην έξοδο $\mathcal{A}(\mathcal{D})$. Η έννοια της ευστάθειας σχετίζεται στενά με την έννοια της γενίκευσης. Συγκεκριμένα, υπάρχουν τυπικές έννοιες ευστάθειας που μας επιτρέπουν να φράζουμε το χάσμα γενίκευσης (βλέπε [78, Κεφ. 13]). Για να αναπτυχθεί η διαισθητική κατανόηση, θεωρούμε τα τρία σύνολα δεδομένων που απεικονίζονται στο Σχ. 54, καθένα από τα οποία είναι εξίσου πιθανό υπό την ίδια κατανομή πιθανότητας παραγωγής δεδομένων. Εφόσον οι βέλτιστες παράμετροι του μοντέλου καθορίζονται από αυτή την υποκείμενη κατανομή πιθανότητας, μία ακριβής μέθοδος μηχανικής μάθησης $\mathcal{A}$ θα έπρεπε να επιστρέφει την ίδια (ή πολύ όμοια) έξοδο $\mathcal{A}(\mathcal{D})$ και για τα τρία σύνολα δεδομένων. Με άλλα λόγια, οποιαδήποτε χρήσιμη $\mathcal{A}$ πρέπει να είναι στιβαρή στη μεταβλητότητα των πραγματώσεων δείγματος από την ίδια κατανομή πιθανότητας, δηλαδή πρέπει να είναι ευσταθής.



Σχ. 54. Τρία σύνολα δεδομένων $\mathcal{D}^{(*)}$, $\mathcal{D}^{(\square)}$, και $\mathcal{D}^{(\Delta)}$, καθένα από τα οποία δειγματοληπτείται ανεξάρτητα από την ίδια κατανομή πιθανότητας παραγωγής δεδομένων. Μία ευσταθής μέθοδος μηχανικής μάθησης θα έπρεπε να επιστρέφει όμοιες εξόδους όταν εκπαιδεύεται σε οποιοδήποτε από αυτά τα σύνολα δεδομένων.


Βλέπε επίσης: μηχανική μάθηση, απεικόνιση, σύνολο δεδομένων, έξοδος, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, παράμετρος μοντέλου, ελάχιστο, απώλεια, πρόβλεψη, μοντέλο, γενίκευση, χάσμα γενίκευσης, δεδομένα, κατανομή πιθανότητας, δείγμα, πραγμάτωση, στιβαρότητα.

ημιεποπτευόμενη μάθηση Οι μέθοδοι ημιεποπτευόμενης μάθησης (semi-supervised learning - SSL) χρησιμοποιούν σημεία δεδομένων χωρίς ετικέτες για να υποστηρίξουν τη μάθηση μίας υπόθεσης από σημεία δεδομένων με ετικέτες [114]. Αυτή η προσέγγιση είναι ιδιαίτερα χρήσιμη για εφαρμογές μηχανικής μάθησης που προσφέρουν έναν μεγάλο αριθμό σημείων δεδομένων χωρίς ετικέτες, αλλά μόνο έναν περιορισμένο αριθμό σημείων δεδομένων με ετικέτες.

Βλέπε επίσης: σημείο δεδομένων, υπόθεση, σημείο δεδομένων με ετικέτα, μηχανική μάθηση.

ιστόγραμμα Θεωρούμε ένα σύνολο δεδομένων $\mathcal{D}$ που αποτελείται από m σημεία δεδομένων $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}$, καθένα από τα οποία ανήκει σε κάποιο

κελί $[-U, U] \times \dots \times [-U, U] \subseteq \mathbb{R}^d$ με πλάγιο μήκος U . Χωρίζουμε αυτό το κελί ισότιμα σε μικρότερα στοιχειώδη κελιά με πλάγιο μήκος Δ . Το ιστόγραμμα (histogram) του $\mathcal{D}$ αποδίδει κάθε στοιχειώδες κελί στο αντίστοιχο κλάσμα των σημείων δεδομένων του $\mathcal{D}$ που εμπίπτουν σε αυτό το στοιχειώδες κελί. Ένα οπτικό παράδειγμα ενός τέτοιου ιστογράμματος παρέχεται στο Σχ. 55.



Σχ. 55. Ένα ιστόγραμμα αποτελείται από τα κλάσματα των σημείων δεδομένων που εμπίπτουν εντός διαφορετικών πεδίων τιμών (δηλαδή κάδων). Το ύψος κάθε ράβδου δείχνει τον αριθμό των δειγμάτων στο αντίστοιχο διάστημα.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, δείγμα.

καθεστώς υψηλής διάστασης Το καθεστώς υψηλής διάστασης (high-dimensional regime) της ελαχιστοποίησης εμπειρικής διακινδύνευσης χαρακτηρίζεται από το ότι η αποτελεσματική διάσταση του μοντέλου είναι μεγαλύτερη από το μέγεθος δείγματος, δηλαδή από τον αριθμό των σημείων δεδομένων με ετικέτες στο σύνολο εκπαίδευσης. Για παράδειγμα,

οι μέθοδοι γραμμικής παλινδρόμησης λειτουργούν στο καθεστώς υψηλής διάστασης όταν ο αριθμός d των χαρακτηριστικών που χρησιμοποιούνται για να χαρακτηριστούν τα σημεία δεδομένων υπερβαίνει τον αριθμό των σημείων δεδομένων στο σύνολο εκπαίδευσης. Ένα άλλο παράδειγμα μεθόδων μηχανικής μάθησης που λειτουργούν στο καθεστώς υψηλής διάστασης είναι τα μεγάλα ΤΝΔ, τα οποία διαθέτουν πολλά περισσότερα ρυθμιζόμενα βάρη (και όρους μεροληψίας) από τον συνολικό αριθμό των σημείων δεδομένων στο σύνολο εκπαίδευσης. Η στατιστική υψηλών διαστάσεων αποτελεί έναν πρόσφατο βασικό κλάδο της θεωρίας πιθανοτήτων που μελετάει τη συμπεριφορά των μεθόδων μηχανικής μάθησης στο καθεστώς υψηλής διάστασης [23], [115].


Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, αποτελεσματική διάσταση, μοντέλο, μέγεθος δείγματος, σημείο δεδομένων, σύνολο εκπαίδευσης, γραμμική παλινδρόμηση, χαρακτηριστικό, μηχανική μάθηση, ΤΝΔ, βάρος, πιθανότητα, υπερπροσαρμογή, ομαλοποίηση.

κάθοδος κλίσης Η κάθοδος κλίσης (gradient descent - GD) είναι μία επαναληπτική μέθοδος για την εύρεση του ελάχιστου μίας παραγωγίσιμης συνάρτησης $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Η κάθοδος κλίσης παράγει μία ακολουθία εκτιμήσεων $\mathbf{w}^{(0)}, \mathbf{w}^{(1)}, \mathbf{w}^{(2)}, \dots$ που (ιδανικά) συγκλίνουν σε ένα ελάχιστο της f . Σε κάθε επανάληψη k , η κάθοδος κλίσης βελτιώνει την τρέχουσα εκτίμηση $\mathbf{w}^{(k)}$ κάνοντας ένα βήμα προς την κατεύθυνση της μέγιστης καθόδου μίας τοπικής γραμμικής προσέγγισης. Αυτή η κατεύθυνση δίνεται από την αρνητική κλίση $\nabla f(\mathbf{w}^{(k)})$ της συνάρτησης f στην τρέχουσα

εκτίμηση $\mathbf{w}^{(k)}$. Ο επακόλουθος κανόνας ενημέρωσης δίνεται από

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \eta \nabla f(\mathbf{w}^{(k)}), \quad (3)$$

όπου $\eta > 0$ είναι ένα κατάλληλα μικρό μέγεθος βήματος. Για ένα κατάλληλα επιλεγμένο μέγεθος βήματος η , η ενημέρωση συνήθως μειώνει την τιμή της συνάρτησης, δηλαδή $f(\mathbf{w}^{(k+1)}) < f(\mathbf{w}^{(k)})$. Το Σχ. 56 παρουσιάζει ένα μοναδικό βήμα καθόδου κλίσης.



Σχ. 56. Μοναδικό βήμα κλίσης (3) προς τον ελαχιστοποιητή $\bar{\mathbf{w}}$ της $f(\mathbf{w})$.

Βλέπε επίσης: ελάχιστο, παραγωγίσιμη, συνάρτηση, ακολουθία, επανάληψη, κλίση, μέγεθος βήματος, βήμα κλίσης.

κάθοδος υποκλίσης Η κάθοδος υποκλίσης (subgradient descent) είναι μία γενίκευση της καθόδου κλίσης που δεν απαιτεί παραγωγισιμότητα της συνάρτησης που πρόκειται να ελαχιστοποιηθεί. Αυτή η γενίκευση προκύπτει από την αντικατάσταση της έννοιας της κλίσης με εκείνη της υποκλίσης. Όμοια με τις κλίσεις, οι υποκλίσεις μάς επιτρέπουν να κατασκευάζουμε

τοπικές προσεγγίσεις μίας αντικειμενικής συνάρτησης. Η αντικειμενική συνάρτηση μπορεί να είναι η εμπειρική διακινδύνευση $\hat{L}(h^{(\mathbf{w})}|\mathcal{D})$ που θεωρείται ως μία συνάρτηση των παραμέτρων μοντέλου $\mathbf{w}$ που επιλέγουν μία υπόθεση $h^{(\mathbf{w})} \in \mathcal{H}$.

Βλέπε επίσης: υποκλίση, γενίκευση, κάθοδος κλίσης, συνάρτηση, κλίση, αντικειμενική συνάρτηση, εμπειρική διακινδύνευση, παράμετρος μοντέλου, υπόθεση.

κανονικές εξισώσεις Θεωρούμε τη μέθοδο των γραμμικά ελάχιστα τετράγωνα, η οποία μαθαίνει τις παραμέτρους ενός γραμμικού μοντέλου ελαχιστοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος σε ένα σύνολο εκπαίδευσης $\mathcal{D}$. Οι παράμετροι $\hat{\mathbf{w}}$ που έχουν μαθητευτεί χαρακτηρίζονται από το γραμμικό σύστημα εξισώσεων, δηλαδή

$$\mathbf{X}^T \mathbf{X} \hat{\mathbf{w}} = \mathbf{X}^T \mathbf{y}. \quad (4)$$

Εδώ $\mathbf{X} = (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})^T \in \mathbb{R}^{m \times d}$ είναι ο πίνακας χαρακτηριστικών του $\mathcal{D}$ και $\mathbf{y} = (y^{(1)}, \dots, y^{(m)})^T \in \mathbb{R}^m$ είναι το διάνυσμα ετικετών του $\mathcal{D}$. Αυτό το γραμμικό σύστημα εξισώσεων αναφέρεται ως κανονικές εξισώσεις (normal equations), καθώς ισοδυναμεί με μία συνθήκη ορθογωνιότητας. Πράγματι, η (4) μπορεί να γραφεί ως

$$\mathbf{X}^T (\mathbf{X} \hat{\mathbf{w}} - \mathbf{y}) = \mathbf{0}.$$

Αυτό σημαίνει ότι το διάνυσμα σφάλματος πρόβλεψης $\mathbf{X} \hat{\mathbf{w}} - \mathbf{y}$ είναι ορθογώνιο προς τις στήλες του $\mathbf{X}$ και, κατ' επέκταση, προς τον υποχώρο

$\text{span}(\mathbf{X})$ που παράγεται από αυτές.

Βλέπε επίσης: γραμμικά ελάχιστα τετράγωνα, παράμετρος, γραμμικό μοντέλο, απώλεια τετραγωνικού σφάλματος, σύνολο εκπαίδευσης, πίνακας χαρακτηριστικών, διάνυσμα ετικετών, πρόβλεψη, διάνυσμα, υποχώρος, παράμετρος μοντέλου.

κανονικοποίηση δεδομένων Η κανονικοποίηση δεδομένων (data normalization) αναφέρεται σε μετασχηματισμούς που εφαρμόζονται στα διανύσματα χαρακτηριστικών σημείων δεδομένων για να βελτιωθούν οι στατιστικές διαστάσεις ή οι υπολογιστικές διαστάσεις της μεθόδου μηχανικής μάθησης. Για παράδειγμα, στη γραμμική παλινδρόμηση με μεθόδους με βάση την κλίση που χρησιμοποιούν έναν σταθερό ρυθμό μάθησης, η σύγκλιση εξαρτάται από τον έλεγχο της νόρμας διανυσμάτων χαρακτηριστικών στο σύνολο εκπαίδευσης. Μία κοινή προσέγγιση είναι να κανονικοποιούμε τα διανύσματα χαρακτηριστικών, έτσι ώστε η νόρμα τους να μην υπερβαίνει το ένα [8, Κεφ. 5].

Βλέπε επίσης: δεδομένα, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, μηχανική μάθηση, στατιστική διάσταση, υπολογιστική διάσταση, γραμμική παλινδρόμηση, μέθοδος με βάση την κλίση, ρυθμός μάθησης, σύγκλιση, νόρμα, σύνολο εκπαίδευσης, απεικόνιση χαρακτηριστικών.

κατακόρυφη ομοσπονδιακή μάθηση TBC.

κατανεμημένος αλγόριθμος TBC.

κέντρο βάρους συστάδας Οι μέθοδοι συσταδοποίησης αναλύουν ένα συγκεκριμένο σύνολο δεδομένων σε μερικές συστάδες. Διαφορετικές μέθοδοι συσταδοποίησης χρησιμοποιούν διαφορετικές αναπαραστάσεις για αυ-

τές τις συστάδες. Αν τα σημεία δεδομένων χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$, μπορούμε να χρησιμοποιήσουμε κάποιο διάνυσμα $\boldsymbol{\mu} \in \mathbb{R}^d$, που αναφέρεται ως κέντρο βάρους συστάδας (cluster centroid), για να αναπαραστήσουμε μία συστάδα. Για παράδειγμα, αν μία συστάδα αποτελείται από ένα σύνολο σημείων δεδομένων, χρησιμοποιούμε τον μέσο όρο των διανυσμάτων χαρακτηριστικών τους ως κέντρο βάρους συστάδας. Ωστόσο, υπάρχουν επίσης άλλες επιλογές για το πώς να κατασκευαστεί ένα κέντρο βάρους συστάδας, π.χ. με τη χρήση της γεωμετρικής διαμέσου [116] ή μέσω της μη Ευκλείδειας γεωμετρίας [117]. Βλέπε επίσης: συσταδοποίηση, σύνολο δεδομένων, συστάδα, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, διάνυσμα, γεωμετρική διάμεσος, αλγόριθμος k -μέσων.

κριτήριο τερματισμού Πολλές μέθοδοι μηχανικής μάθησης χρησιμοποιούν επαναληπτικούς αλγόριθμους που κατασκευάζουν μία ακολουθία παραμέτρων μοντέλου προκειμένου να ελαχιστοποιήσουν το σφάλμα εκπαίδευσης. Για παράδειγμα, οι μέθοδο με βάση την κλίση ενημερώνουν επαναληπτικά τις παραμέτρους ενός παραμετρικού μοντέλου, όπως ένα γραμμικό μοντέλο ή ένα βαθύ δίκτυο. Δεδομένου ενός πεπερασμένου ποσού υπολογιστικών πόρων, χρειάζεται να σταματήσουμε την ενημέρωση των παραμέτρων μετά από έναν πεπερασμένο αριθμό επαναλήψεων. Ένα κριτήριο τερματισμού (stopping criterion) είναι οποιαδήποτε καλά ορισμένη συνθήκη για να αποφασίσουμε πότε να σταματήσουμε την ενημέρωση. Βλέπε επίσης: μηχανική μάθηση, αλγόριθμος, παράμετρος μοντέλου, σφάλμα εκπαίδευσης, μέθοδος με βάση την κλίση, παράμετρος, παραμετρικό μοντέλο, γραμμικό μοντέλο, βαθύ δίκτυο, επανάληψη.

κυρτή συσταδοποίηση Θεωρούμε ένα σύνολο δεδομένων $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$. Η κυρτή συσταδοποίηση (convex clustering) μαθαίνει διανύσματα $\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(m)}$ μέσω της ελαχιστοποίησης:

$$\sum_{r=1}^m \|\mathbf{x}^{(r)} - \mathbf{w}^{(r)}\|_2^2 + \alpha \sum_{i,i' \in \mathcal{V}} \|\mathbf{w}^{(i)} - \mathbf{w}^{(i')}\|_p.$$

Εδώ $\|\mathbf{u}\|_p := (\sum_{j=1}^d |u_j|^p)^{1/p}$ δηλώνει την p -νόρμα (για $p \geq 1$). Προκύπτει ότι πολλά από τα βέλτιστα διανύσματα $\hat{\mathbf{w}}^{(1)}, \dots, \hat{\mathbf{w}}^{(m)}$ συμπίπτουν. Μία συστάδα τότε αποτελείται από αυτά τα σημεία δεδομένων $r \in \{1, \dots, m\}$ με ταυτόσημο $\hat{\mathbf{w}}^{(r)}$ [118], [119].

Βλέπε επίσης: σύνολο δεδομένων, κυρτό, συσταδοποίηση, διάνυσμα, νόρμα, συστάδα, σημείο δεδομένων.

κωδικοποιητής Βλέπε αυτοκωδικοποιητής.

λειτουργικός χαρακτηριστικός δέκτης Θεωρούμε έναν χώρο ετικετών

$\mathcal{Y} = \{-1, 1\}$ και έναν ταξινομητή που χρησιμοποιεί μία υπόθεση πραγματικής τιμής $h(\mathbf{x})$. Για ένα δεδομένο κατώφλι $\eta \in \mathbb{R}$, η τελική πρόβλεψη είναι $\hat{y} = 1$ αν $h(\mathbf{x}) \geq \eta$ και $\hat{y} = -1$ διαφορετικά. Σε ένα σύνολο ελέγχου $\mathcal{D}^{(\text{test})}$, υπολογίζουμε, για κάθε τιμή του η , τις εξής δύο ποσότητες: 1) το ποσοστό αληθώς θετικών $\text{TPR}^{(\eta)}$, και 2) το ποσοστό ψευδώς θετικών $\text{FPR}^{(\eta)}$. Η καμπύλη λειτουργικού χαρακτηριστικού δέκτη (receiver operating characteristic - ROC) είναι η εξής συνάρτηση [120]:

$$\text{ROC} : \mathbb{R} \rightarrow \mathbb{R}^2 : \eta \mapsto (\text{TPR}^{(\eta)}, \text{FPR}^{(\eta)}).$$


Ένα σημαντικό χαρακτηριστικό της καμπύλης λειτουργικού χαρακτηρι-

στικού δέκτη είναι το εμβαδόν κάτω από την καμπύλη.

Βλέπε επίσης: χώρος ετικετών, ταξινομητής, υπόθεση, πρόβλεψη, σύνολο ελέγχου, συνάρτηση, εμβαδόν κάτω από την καμπύλη.

λογιστική απώλεια Θεωρούμε ένα σημείο δεδομένων που χαρακτηρίζεται από χαρακτηριστικά $\mathbf{x}$ και μία δυαδική ετικέτα $y \in \{-1, 1\}$. Χρησιμοποιούμε μία υπόθεση πραγματικής τιμής h για να προβλέψουμε την ετικέτα y από τα χαρακτηριστικά $\mathbf{x}$. Η λογιστική απώλεια (logistic loss) που προκαλείται από αυτή την πρόβλεψη ορίζεται ως [61]

$$L((\mathbf{x}, y), h) := \log(1 + \exp(-yh(\mathbf{x}))). \quad (5)$$



Σχ. 57. Η λογιστική απώλεια που προκαλείται από την πρόβλεψη $h(\mathbf{x}) \in \mathbb{R}$ για ένα σημείο δεδομένων με ετικέτα $y \in \{-1, 1\}$.

Σημείωση ότι η έκφραση (5) για τη λογιστική απώλεια εφαρμόζεται μόνο για τον χώρο ετικετών $\mathcal{Y} = \{-1, 1\}$ και όταν χρησιμοποιείται ο κανόνας κατωφλιού (7).

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, υπόθεση, απώλεια, πρόβλεψη, χώρος ετικετών, ταξινόμηση, ταξινομητής, γραμμικό μοντέλο.

λογιστική παλινδρόμηση Η λογιστική παλινδρόμηση μαθαίνει μία γραμμική απεικόνιση υπόθεσης (ή έναν ταξινομητή) $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ για να προβλέψει μία δυαδική ετικέτα y με βάση το αριθμητικό διάνυσμα χαρακτηριστικών $\mathbf{x}$ ενός σημείου δεδομένων [61], [75]. Η ποιότητα μίας γραμμικής απεικόνισης υπόθεσης μετράται από τη μέση λογιστική απώλεια σε κάποια σημεία δεδομένων με ετικέτες (δηλαδή το σύνολο εκπαίδευσης).

Βλέπε επίσης: παλινδρόμηση, υπόθεση, απεικόνιση, ταξινομητής, ετικέτα, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, λογιστική απώλεια, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

μάθηση δέσμης TBC.

μάθηση με μεταφορά Η μάθηση με μεταφορά (transfer learning) στοχεύει στην αξιοποίηση πληροφοριών που προκύπτουν κατά την επίλυση μίας ήδη υπάρχουσας εργασίας μάθησης, προκειμένου να επιλυθεί μία άλλη εργασία μάθησης.

Βλέπε επίσης: εργασία μάθησης, μάθηση πολυδιεργασίας

μάθηση πολυδιεργασίας Η μάθηση πολυδιεργασίας (multitask learning) στοχεύει να αξιοποιήσει σχέσεις μεταξύ διαφορετικών εργασιών μάθησης. Θεωρούμε δύο εργασίες μάθησης που προκύπτουν από το ίδιο σύνολο δεδομένων λήψεων από κάμερα υπολογιστή. Η πρώτη εργασία είναι να προβλεφθεί η παρουσία ενός ανθρώπου, ενώ η δεύτερη εργασία είναι να προβλεφθεί η παρουσία ενός αυτοκινήτου. Μπορεί να είναι χρήσιμο να

χρησιμοποιηθεί η ίδια δομή βαθιού δικτύου και για τις δύο εργασίες και να επιτραπεί μόνο τα βάρη του τελικού στρώματος εξόδου να είναι διαφορετικά.

Βλέπε επίσης: εργασία μάθησης, σύνολο δεδομένων, βαθύ δίκτυο, βάρος, έξοδος, στρώμα.

μάθηση χαρακτηριστικών Θεωρούμε μία εφαρμογή μηχανικής μάθησης με σημεία δεδομένων που χαρακτηρίζονται από ακατέργαστα χαρακτηριστικά $\mathbf{x} \in \mathcal{X}$. Η μάθηση χαρακτηριστικών (feature learning) αναφέρεται στην εργασία της μάθησης μίας απεικόνισης

$$\Phi : \mathcal{X} \rightarrow \mathcal{X}' : \mathbf{x} \mapsto \mathbf{x}'$$

που διαβάζει τα χαρακτηριστικά $\mathbf{x} \in \mathcal{X}$ ενός σημείου δεδομένων και παράγει νέα χαρακτηριστικά $\mathbf{x}' \in \mathcal{X}'$ από έναν νέο χώρο χαρακτηριστικών $\mathcal{X}'$. Διαφορετικές μέθοδοι μάθησης χαρακτηριστικών προκύπτουν για διαφορετικές επιλογές σχεδιασμού των $\mathcal{X}, \mathcal{X}'$, για έναν χώρο υποθέσεων $\mathcal{H}$ πιθανών απεικονίσεων Φ , και για ένα ποσοτικό μέτρο της χρησιμότητας μίας συγκεκριμένης $\Phi \in \mathcal{H}$. Για παράδειγμα, η ανάλυση κύριων συνιστωσών χρησιμοποιεί $\mathcal{X} := \mathbb{R}^d$, $\mathcal{X}' := \mathbb{R}^{d'}$ με $d' < d$, και έναν χώρο υποθέσεων

$$\mathcal{H} := \{ \Phi : \mathbb{R}^d \rightarrow \mathbb{R}^{d'} : \mathbf{x}' := \mathbf{F}\mathbf{x} \text{ με κάποιον } \mathbf{F} \in \mathbb{R}^{d' \times d} \}.$$

Η ανάλυση κύριων συνιστωσών μετράει τη χρησιμότητα μίας συγκεκριμένης απεικόνισης $\Phi(\mathbf{x}) = \mathbf{F}\mathbf{x}$ από το ελάχιστο γραμμικό σφάλμα ανακα-

τασχευής που προκαλείται σε ένα σύνολο δεδομένων, έτσι ώστε

$$\min_{\mathbf{G} \in \mathbb{R}^{d \times d'}} \sum_{r=1}^m \|\mathbf{G}\mathbf{F}\mathbf{x}^{(r)} - \mathbf{x}^{(r)}\|_2^2.$$

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, χαρακτηριστικό, απεικόνιση, χώρος χαρακτηριστικών, χώρος υποθέσεων, μέτρο, ανάλυση κύριων συνιστωσών, ελάχιστο, σύνολο δεδομένων.

μαλακή ετικέτα Θεωρούμε ένα πρόβλημα ταξινόμησης όπου τα σημεία δεδομένων χαρακτηρίζονται από χαρακτηριστικά $\mathbf{x}$ και ετικέτες από έναν πεπερασμένο χώρο ετικετών $\mathcal{Y} = \{1, \dots, k\}$. Κάποιες εφαρμογές μηχανικής μάθησης περιλαμβάνουν σημεία δεδομένων που έχουν σχεδόν ταυτόσημα χαρακτηριστικά αλλά διαφορετικές ετικέτες. Σε τέτοιες περιπτώσεις, αντί να αποδίδεται σε κάθε σημείο δεδομένων μία μοναδική ετικέτα $y \in \mathcal{Y}$, μπορεί να είναι πιο χρήσιμο να αποδίδεται μία ολόκληρη κατανομή πιθανότητας πάνω στον χώρο ετικετών. Αυτή η κατανομή πιθανότητας μπορεί να αναπαρασταθεί ως μία συνάρτηση μάζας πιθανότητας $\mathbf{y} = (y_1, \dots, y_k)^T \in \Delta^k$. Μπορούμε να θεωρήσουμε τις καταχωρίσεις y_c , για $c = 1, \dots, k$, ως μαλακές ετικέτες (soft labels) ενός σημείου δεδομένων. Από μαθηματική άποψη, η μαλακή ετικέτα y_c είναι η πιθανότητα ότι ένα τυχαία επιλεγμένο σημείο δεδομένων με διάνυσμα χαρακτηριστικών $\mathbf{x}$ έχει ετικέτα c .

Βλέπε επίσης: ταξινόμηση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, χώρος ετικετών, μηχανική μάθηση, κατανομή πιθανότητας, συνάρτηση μάζας πιθανότητας, πιθανότητα, διάνυσμα χαρακτηριστικών, διασταυρού-

μενη εντροπία.

μαλακή συσταδοποίηση Η μαλακή συσταδοποίηση (soft clustering) αναφέρεται στην εργασία χωρισμού ενός συγκεκριμένου συνόλου σημείων δεδομένων σε (μερικές) αλληλεπικαλυπτόμενες συστάδες. Κάθε σημείο δεδομένων αποδίδεται σε αρκετές διαφορετικές συστάδες με μεταβαλλόμενους βαθμούς συσχέτισης. Οι μέθοδοι μαλακής συσταδοποίησης καθορίζουν τον βαθμό συσχέτισης (ή την απόδοση μαλακής συστάδας) για κάθε σημείο δεδομένων και κάθε συστάδα. Μία προσέγγιση αρχών μαλακής συσταδοποίησης για σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών είναι μέσω ενός πιθανοτικού μοντέλου όπως το Γκαουσιανό μοντέλο μείγματος. Η πιθανότητα υπό συνθήκη ένα σημείο δεδομένων να ανήκει σε μία συγκεκριμένη συνιστώσα μείγματος είναι τότε μία φυσική επιλογή για τον βαθμό συσχέτισης. Μέθοδοι μαλακής συσταδοποίησης με Γκαουσιανό μοντέλο μείγματος μπορούν να εφαρμοστούν σε μη αριθμητικά δεδομένα χρησιμοποιώντας μεθόδους μάθησης χαρακτηριστικών, ώστε να παραχθούν αριθμητικά χαρακτηριστικά (όπως στη φασματική συσταδοποίηση).

Βλέπε επίσης: συσταδοποίηση, σημείο δεδομένων, συστάδα, βαθμός συσχέτισης, διάνυσμα χαρακτηριστικών, πιθανοτικό μοντέλο, Γκαουσιανό μοντέλο μείγματος, πιθανότητα, δεδομένα, μάθηση χαρακτηριστικών, χαρακτηριστικό, φασματική συσταδοποίηση.

μεγάλο γλωσσικό μοντέλο Ένα μεγάλο γλωσσικό μοντέλο (large language model - LLM) είναι ένα όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που χρησιμοποιούν μοντέλα μηχανικής μάθησης υψηλής διάστα-

σης (με δισεκατομμύρια παραμέτρους μοντέλου) που εκπαιδεύονται σε μεγάλες συλλογές δεδομένων κειμένου. Τα μεγάλα γλωσσικά μοντέλα χρησιμοποιούνται για την ανάλυση και την παραγωγή ακολουθιών από tokens που συνιστούν δεδομένα κειμένου. Πολλά τρέχοντα μεγάλα γλωσσικά μοντέλα χρησιμοποιούν κάποια παραλλαγή ενός μετασχηματιστή που εκπαιδεύεται μέσω αυτοεποπτευόμενης μάθησης, δηλαδή η εκπαίδευση βασίζεται στην εργασία της πρόβλεψης μερικών λέξεων που σκόπιμα αφαιρούνται από ένα μεγάλο σώμα κειμένων. Έτσι, μπορούμε να κατασκευάσουμε σημεία δεδομένων με ετικέτες απλώς επιλέγοντας κάποιες λέξεις από ένα δεδομένο κείμενο ως ετικέτες και τις υπόλοιπες λέξεις ως χαρακτηριστικά σημείων δεδομένων. Αυτή η κατασκευή απαιτεί πολύ λίγη ανθρώπινη εποπτεία και επιτρέπει την παραγωγή επαρκώς μεγάλων συνόλων εκπαίδευσης για μεγάλα γλωσσικά μοντέλα.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, παράμετρος μοντέλου, δεδομένα, ακολουθία, token, μετασχηματιστής, αυτοεποπτευόμενη μάθηση, εκπαίδευση, σημείο δεδομένων με ετικέτα, ετικέτα, χαρακτηριστικό, σημείο δεδομένων, σύνολο εκπαίδευσης, ΕΦΓ.

μέγεθος βήματος Βλέπε ρυθμός μάθησης.

μέγεθος δείγματος Το μέγεθος δείγματος (sample size) είναι ο αριθμός των μεμονωμένων σημείων δεδομένων που περιέχονται σε ένα δείγμα ή σύνολο δεδομένων. Θεωρούμε μία μέθοδο βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιεί ένα σύνολο εκπαίδευσης $\mathcal{D}$ με μέγεθος δείγματος m και ένα μοντέλο $\mathcal{H}$ με αποτελεσματική διάσταση $d_{\text{eff}}(\mathcal{H})$. Αν το σύνολο εκπαίδευσης μπορεί να προσεγγιστεί καλά από

την παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, τότε ο λόγος μεταξύ του m και της $d_{\text{eff}}(\mathcal{H})$ μπορεί να είναι ένας χρήσιμος δείκτης για την εμφάνιση υπερπροσαρμογής [8, Κεφ. 6].

Βλέπε επίσης: δείγμα, σημείο δεδομένων, σύνολο δεδομένων, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, μοντέλο, αποτελεσματική διάσταση, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, υπερπροσαρμογή.


μέθοδος διάχυσης Μία μέθοδος διάχυσης (diffusion method) είναι μία παραγωγική μέθοδος μηχανικής μάθησης που εκπαιδεύει ένα μοντέλο για να προσεγγίσει την αντιστροφή μίας σταδιακής στοχαστικής διαδικασίας αλλοίωσης [103], [121]. Οι μέθοδοι διάχυσης εκπαιδεύουν μοντέλα χρησιμοποιώντας έναν συνδυασμό μίας προς τα εμπρός διαδικασίας (διάχυσης) και μίας αντίστροφης απεικόνισης που έχει μαθητευτεί. Στην προς τα εμπρός διαδικασία, τυχαίος θόρυβος προστίθεται σταδιακά σε καθαρές αναπαραστάσεις ενός σημείου δεδομένων, όπως μία εικόνα, μία ηχογράφηση, ή άλλοι τύποι δεδομένων. Όμοια με έναν αυτοκωδικοποιητή αποθορυβοποίησης, το εκπαιδευμένο μοντέλο μπορεί να εφαρμοστεί σε μία θορυβώδη αναπαράσταση ενός σημείου δεδομένων. Η επαχόλουθη πρόβλεψη είναι μία αναπαράσταση χωρίς θόρυβο. Αυτό που διακρίνει τις μεθόδους διάχυσης από τους γενικούς αυτοκωδικοποιητές αποθορυβοποίησης είναι η σταδιακή φύση της διαδικασίας αλλοίωσης που χρησιμοποιείται για την εκπαίδευση του μοντέλου.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, στοχαστική, απεικόνιση, σημείο δεδομένων, δεδομένα, αυτοκωδικοποιητής αποθορυβοποίησης, πρόβλεψη, εκπαίδευση.

μέθοδος με βάση την κλίση Μία μέθοδος με βάση την κλίση (gradient-based method) είναι μία επαναληπτική τεχνική για την εύρεση του ελάχιστου (ή του μέγιστου) μίας παραγωγίσιμης αντικειμενικής συνάρτησης $f(\mathbf{w})$ των παραμέτρων μοντέλου $\mathbf{w}$. Μία τέτοια μέθοδος κατασκευάζει μία ακολουθία προσεγγίσεων σε μία βέλτιστη επιλογή $\mathbf{w}$. Όπως το όνομα υποδεικνύει, μία μέθοδος με βάση την κλίση χρησιμοποιεί τις κλίσεις της αντικειμενικής συνάρτησης που αξιολογούνται κατά τις προηγούμενες επαναλήψεις για να κατασκευάσει νέες, (ελπίζουμε) βελτιωμένες παραμέτρους του μοντέλου. Ένα σημαντικό παράδειγμα μεθόδου με βάση την κλίση είναι η κάθοδος κλίσης.

Βλέπε επίσης: κλίση, ελάχιστο, μέγιστο, παραγωγίσιμη, αντικειμενική συνάρτηση, παράμετρος μοντέλου, ακολουθία, επανάληψη, κάθοδος κλίσης, μέθοδος βελτιστοποίησης.

μέθοδος πυρήνα Μία μέθοδος πυρήνα (kernel method) είναι μία μέθοδος μηχανικής μάθησης που χρησιμοποιεί έναν πυρήνα k για να αντιστοιχίσει το αρχικό (δηλαδή ακατέργαστο) διάνυσμα χαρακτηριστικών $\mathbf{x}$ ενός σημείου δεδομένων σε ένα νέο (μετασχηματισμένο) διάνυσμα χαρακτηριστικών $\mathbf{z} = k(\mathbf{x}, \cdot)$ [49], [89]. Το κίνητρο για τον μετασχηματισμό των διανυσμάτων χαρακτηριστικών είναι ότι, χρησιμοποιώντας έναν κατάλληλο πυρήνα, τα σημεία δεδομένων έχουν μία πιο «ευχάριστη» γεωμετρία στον μετασχηματισμένο χώρο χαρακτηριστικών. Για παράδειγμα, σε ένα πρόβλημα δυαδικής ταξινόμησης, η χρήση μετασχηματισμένων διανυσμάτων χαρακτηριστικών $\mathbf{z}$ μπορεί να μας επιτρέψει να χρησιμοποιήσουμε γραμμικά μοντέλα, ακόμα και αν τα σημεία δεδομένων δεν είναι γραμμικά διαχωρίσιμα στον αρχικό χώρο χαρακτηριστικών (βλέπε Σχ. 58).



Σχ. 58. Πέντε σημεία δεδομένων που χαρακτηρίζονται από διανύσματα χαρακτηριστικών $\mathbf{x}^{(r)}$ και ετικέτες $y^{(r)} \in \{\circ, \square\}$ για $r = 1, \dots, 5$. Με αυτά τα διανύσματα χαρακτηριστικών, δεν υπάρχει τρόπος να διαχωρίσουμε τις δύο τάξεις με μία ευθεία γραμμή (που αναπαριστά το όριο απόφασης ενός γραμμικού ταξινομητή). Αντίθετα, τα μετασχηματισμένα διανύσματα χαρακτηριστικών $\mathbf{z}^{(r)} = k(\mathbf{x}^{(r)}, \cdot)$ μας επιτρέπουν να διαχωρίσουμε τα σημεία δεδομένων χρησιμοποιώντας έναν γραμμικό ταξινομητή.

Βλέπε επίσης: πυρήνας, μηχανική μάθηση, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, χώρος χαρακτηριστικών, δυαδική ταξινόμηση, γραμμικό μοντέλο, ετικέτα, όριο απόφασης, γραμμικός ταξινομητής.

μέθοδος Jacobi TBC.

μείωση της διαστασιμότητας TBC.

μεροληψία Θεωρούμε μία μέθοδο μηχανικής μάθησης βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που μαθαίνει μία υπόθεση $\hat{h} \in \mathcal{H}$ από ένα δεδομένο σύνολο εκπαίδευσης. Η ανάλυση της μεθόδου μηχανικής μάθησης συχνά βασίζεται σε ένα πιθανοτικό μοντέλο (όπως η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων) για την παραγωγή δεδομένων. Εδώ τα σημεία δεδομένων και, κατ' επέκταση, η υπόθεση $\hat{h}$ που έχει μαθευτεί θεωρούνται ως τυχαίες μεταβλητές (ή πραγματώσεις τυχαίων μεταβλητών). Οποιαδήποτε ιδιότητα $\theta(\hat{h})$ της $\hat{h}$, όπως συγκε-

κριμένες παράμετροι μοντέλου σε ένα παραμετρικό μοντέλο ή το σφάλμα πρόβλεψης $y - \hat{h}(\mathbf{x})$ για ένα σταθερό σημείο δεδομένων, καθίσταται τότε επίσης τυχαία μεταβλητή. Η τετραγωνική μεροληψία (bias) μίας αριθμητικής ιδιότητας $\theta(\hat{h}) \in \mathbb{R}^r$ είναι [61], [75]

$$B^2 := \|\mathbb{E}\{\theta(\hat{h})\} - \theta(\bar{h})\|_2^2.$$

Εδώ $\bar{h}$ είναι η υπόθεση αναφοράς, η οποία θα μπορούσε να οριστεί από $\bar{h}(\mathbf{x}) = y$ για ένα σταθερό σημείο δεδομένων ελέγχου με διάνυσμα χαρακτηριστικών $\mathbf{x}$ και ετικέτα y .

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, μηχανική μάθηση, υπόθεση, σύνολο εκπαίδευσης, πιθανοτικό μοντέλο, παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων, δεδομένα, σημείο δεδομένων, πραγμάτωση, τυχαία μεταβλητή, παράμετρος μοντέλου, παραμετρικό μοντέλο, πρόβλεψη, διάνυσμα χαρακτηριστικών, ετικέτα, ανεξάρτητες και ταυτόσημα κατανεμημένες, σφάλμα εκτίμησης.

μέση τιμή δείγματος Η μέση τιμή δείγματος (sample mean) $\mathbf{m} \in \mathbb{R}^d$ για ένα συγκεκριμένο σύνολο δεδομένων, με διανύσματα χαρακτηριστικών $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$, ορίζεται ως

$$\mathbf{m} = \frac{1}{m} \sum_{r=1}^m \mathbf{x}^{(r)}.$$

Βλέπε επίσης: δείγμα, μέση τιμή, σύνολο δεδομένων, διάνυσμα χαρακτηριστικών.

μέσο απόλυτο σφάλμα Το μέσο απόλυτο σφάλμα (mean absolute error - MAE) μίας υπόθεσης είναι η μέση απώλεια απόλυτου σφάλματος που υπολογίζεται σε ένα συγκεκριμένο σύνολο δεδομένων. Στις θεωρητικές αναλύσεις, το μέσο απόλυτο σφάλμα δηλώνει επίσης την αναμενόμενη απώλεια απόλυτου σφάλματος, δηλαδή την αντίστοιχη διακινδύνευση. Βλέπε επίσης: υπόθεση, απώλεια απόλυτου σφάλματος, σύνολο δεδομένων, διακινδύνευση.

μέσο τετραγωνικό σφάλμα Το μέσο τετραγωνικό σφάλμα (mean squared error - MSE) μίας υπόθεσης είναι η μέση απώλεια τετραγωνικού σφάλματος που υπολογίζεται σε ένα συγκεκριμένο σύνολο δεδομένων [8], [75]. Όταν χρησιμοποιείται ένα πιθανοτικό μοντέλο για την παραγωγή δεδομένων, ο όρος μέσο τετραγωνικό σφάλμα μπορεί επίσης να αναφέρεται στη διακινδύνευση, δηλαδή την προσδοκία της απώλειας τετραγωνικού σφάλματος [20], [21]. Βλέπε επίσης: υπόθεση, απώλεια τετραγωνικού σφάλματος, σύνολο δεδομένων, πιθανοτικό μοντέλο, δεδομένα, διακινδύνευση, προσδοκία.

μέσο τετραγωνικό σφάλμα εκτίμησης Θεωρούμε μία μέθοδο μηχανικής μάθησης που μαθαίνει τις παραμέτρους μοντέλου $\hat{\mathbf{w}}$ με βάση κάποιο σύνολο δεδομένων $\mathcal{D}$. Αν ερμηνεύσουμε τα σημεία δεδομένων στο $\mathcal{D}$ ως ανεξάρτητες και ταυτόσημα κατανοημένες πραγματώσεις μίας τυχαίας μεταβλητής $\mathbf{z}$, ορίζουμε το σφάλμα εκτίμησης $\Delta \mathbf{w} := \hat{\mathbf{w}} - \bar{\mathbf{w}}$. Εδώ $\bar{\mathbf{w}}$ δηλώνει τις αληθείς παραμέτρους του μοντέλου της κατανομής πιθανότητας της $\mathbf{z}$. Το μέσο τετραγωνικό σφάλμα εκτίμησης (mean squared estimation error - MSEE) ορίζεται ως η προσδοκία $\mathbb{E}\{\|\Delta \mathbf{w}\|^2\}$ της τε-

τραγωνικής Ευκλείδειας νόρμας του σφάλματος εκτίμησης [20], [21].

Βλέπε επίσης: μηχανική μάθηση, παράμετρος μοντέλου, σύνολο δεδομένων, σημείο δεδομένων, ανεξάρτητες και ταυτόσημα κατανεμημένες, πραγμάτωση, τυχαία μεταβλητή, σφάλμα εκτίμησης, κατανομή πιθανότητας, προσδοκία, Ευκλείδεια νόρμα, πιθανοτικό μοντέλο, απώλεια τετραγωνικού σφάλματος.

μετασχηματιστής Στο πλαίσιο της μηχανικής μάθησης, ο όρος μετασχηματιστής (transformer) αναφέρεται σε ένα ΤΝΔ που χρησιμοποιεί κάποια μορφή μηχανισμού προσοχής για την αποτύπωση εξαρτήσεων μεταξύ των tokens [122]. Ο μηχανισμός προσοχής είναι αυτό που διακρίνει τους μετασχηματιστές από προηγούμενα μοντέλα που χρησιμοποιούνταν για ακολουθιακά δεδομένα όπως τα αναδρομικά νευρωνικά δίκτυα. Ένα ΤΝΔ μετασχηματιστή συχνά συνδυάζει αρκετά στρώματα προσοχής μέσω πιο παραδοσιακών αρχιτεκτονικών στρωμάτων.

Βλέπε επίσης: μηχανική μάθηση, ΤΝΔ, προσοχή, token, μοντέλο, δεδομένα, αναδρομικό νευρωνικό δίκτυο, στρώμα, ΕΦΓ.


μη παραμετρική Οι μη παραμετρικές (nonparametric) μέθοδοι μηχανικής μάθησης δεν υποθέτουν μία σταθερή δομή μοντέλου με έναν πεπερασμένο αριθμό παραμέτρων του μοντέλου. Αντίθετα, η πολυπλοκότητα της υπόθεσης που έχει μαθευτεί μπορεί να αυξάνεται μαζί με τον αριθμό των σημείων δεδομένων στο σύνολο εκπαίδευσης [8], [61]. Παραδείγματα μη παραμετρικών μεθόδων μηχανικής μάθησης περιλαμβάνουν την τοπικά σταθμισμένη μάθηση και τις Γκαουσιανές διαδικασίες.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, παράμετρος μοντέλου, υπόθε-

ση, σημείο δεδομένων, σύνολο εκπαίδευσης, τοπικά σταθμισμένη μάθηση, Γκαουσιανή διαδικασία.

μηχανή διανυσμάτων υποστήριξης (ΜΔΥ) TBC.

μηχανική μάθηση Οι μέθοδοι μηχανικής μάθησης (machine learning - ML) στοχεύουν να μάθουν (ή να βρουν) μία χρήσιμη απεικόνιση υπόθεσης $\hat{h} \in \mathcal{H}$ από ένα μοντέλο $\mathcal{H}$. Η $\hat{h}$ που έχουν μαθευτεί χρησιμοποιείται για τον υπολογισμό μίας πρόβλεψης $\hat{y} = \hat{h}(\mathbf{x})$ για την ετικέτα y ενός σημείου δεδομένων. Η διαδικασία μάθησης καθοδηγείται από ένα ποσοτικό μέτρο της απώλειας που προκαλείται όταν οι προβλέψεις που προκύπτουν από την υπόθεση που έχει μαθευτεί διαφέρουν από την πραγματική ετικέτα y . Διαφορετικές μέθοδοι μηχανικής μάθησης χρησιμοποιούν διαφορετικές επιλογές σχεδιασμού για αυτό το ποσοτικό μέτρο (ή συνάρτηση απώλειας) καθώς και διαφορετικές επιλογές για το μοντέλο και τα σημεία δεδομένων (δηλαδή τα χαρακτηριστικά και τις ετικέτες) τους [8, Κεφ. 3].




Σχ. 59. Η μηχανική μάθηση μαθαίνει μία υπόθεση από ένα μοντέλο (ή χώρο υποθέσεων) προσπαθώντας να ελαχιστοποιήσει την απώλεια που προκύπτει από τις προβλέψεις για τις ετικέτες σημείων δεδομένων. Οι προβλέψεις υπολογίζονται μόνο από τα χαρακτηριστικά των σημείων δεδομένων.

Μία άλλη διάκριση μεταξύ μεθόδων μηχανικής μάθησης είναι ο τρόπος με τον οποίο έχουν πρόσβαση σε σημεία δεδομένων κατά τη μάθηση. Για παράδειγμα, κάποιες μέθοδοι έχουν πρόσβαση σε ένα πλήρες σύνολο δεδομένων κατά την εκπαίδευση, γεγονός που τις επιτρέπει να χρησιμοποιούν την ελαχιστοποίηση εμπειρικής διακινδύνευσης [8], [123]. Αντίθετα, οι μέθοδοι διαδικτυακής μάθησης έχουν πρόσβαση σε δεδομένα διαδοχικά και, κατά συνέπεια, ενημερώνουν την υπόθεση που έχει μαθευτεί κάθε φορά που έρχεται ένα νέο σημείο δεδομένων [96], [97], [124].

Βλέπε επίσης: υπόθεση, απεικόνιση, μοντέλο, πρόβλεψη, ετικέτα, σημείο δεδομένων, μέτρο, απώλεια, συνάρτηση απώλειας, χαρακτηριστικό, εξα-

γωγή συμπερασμάτων, δεδομένα, χώρος υποθέσεων, σύνολο δεδομένων, εκπαίδευση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, διαδικτυακή μάθηση.

μοντέλο (μηχανική μάθηση) Η μελέτη και ο σχεδιασμός μεθόδων μηχανικής μάθησης βασίζεται συχνά σε ένα μαθηματικό μοντέλο (model) [125]. Ίσως ένα από τα πιο ευρέως χρησιμοποιούμενα παραδείγματα μαθηματικού μοντέλου για τη μηχανική μάθηση είναι ένας χώρος υποθέσεων. Ένας χώρος υποθέσεων αποτελείται από απεικονίσεις υπόθεσης που χρησιμοποιούνται από μία μέθοδο μηχανικής μάθησης για την πρόβλεψη ετικετών από τα χαρακτηριστικά σημείων δεδομένων. Ένας άλλος σημαντικός τύπος μαθηματικού μοντέλου είναι ένα πιθανοτικό μοντέλο, το οποίο αποτελείται από κατανομές πιθανοτήτων που περιγράφουν πώς παράγονται σημεία δεδομένων. Εκτός αν διατυπώνεται διαφορετικά, χρησιμοποιούμε τον όρο μοντέλο για να αναφερθούμε συγκεκριμένα στον χώρο υποθέσεων που αποτελεί τη βάση μίας μεθόδου μηχανικής μάθησης. Παρουσιάζουμε ένα παράδειγμα ενός χώρου υποθέσεων και ενός πιθανοτικού μοντέλου στο Σχ. 60.



Σχ. 60. Δύο τύποι μαθηματικών μοντέλων που χρησιμοποιούνται στη μηχανική μάθηση. (a) Χώρος υποθέσεων που αποτελείται από τρεις γραμμικές απεικονίσεις. (b) Πιθανοτικό μοντέλο που αποτελείται από μία κατανομή πιθανότητας πάνω στο επίπεδο παραγόμενο από τις πιθανές τιμές του χαρακτηριστικού και της ετικέτας ενός σημείου δεδομένων.

Βλέπε επίσης: μηχανική μάθηση, χώρος υποθέσεων, υπόθεση, απεικόνιση, ετικέτα, χαρακτηριστικό, σημείο δεδομένων, πιθανοτικό μοντέλο, κατανομή πιθανότητας, γραμμική απεικόνιση.

μοντέλο θεμελίωσης TBC.

μοντέλο στοχαστικής ομάδας Το μοντέλο στοχαστικής ομάδας (stochastic block model - SBM) [126] είναι ένα πιθανοτικό παραγωγικό μοντέλο για έναν μη κατευθυνόμενο γράφο $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ με ένα δεδομένο σύνολο κόμβων $\mathcal{V}$ [127]. Στην πιο βασική του παραλλαγή, το μοντέλο στοχαστικής ομάδας παράγει έναν γράφο πρώτα αποδίδοντας τυχαία κάθε κόμβο $i \in \mathcal{V}$ σε έναν δείκτη συστάδας $c_i \in \{1, \dots, k\}$. Ένα ζεύγος διαφορετικών κόμβων στον γράφο συνδέεται με μία ακμή με πιθανότητα $p_{i,i'}$ που εξαρτάται μόνο από τις ετικέτες $c_i, c_{i'}$. Η παρουσία ακμών μεταξύ διαφορετικών ζευγών κόμβων είναι στατιστικά ανεξάρτητη.

Βλέπε επίσης: μοντέλο, μη κατευθυνόμενος γράφος, γράφος, συστάδα, συνδεδεμένος, πιθανότητα, ετικέτα.

νευρώνας (μηχανική μάθηση) Βλέπε τεχνητός νευρώνας.

νευρωνικό δίκτυο γράφου Ένα νευρωνικό δίκτυο γράφου (graph neural network - GNN) είναι ένας ειδικός τύπος ΤΝΔ που ορίζεται μέσω ενός δεδομένου γράφου. Σε ένα νευρωνικό δίκτυο γράφου, οι αναπαραστάσεις που σχετίζονται με τους κόμβους ενημερώνονται μέσω της συνάθροισης και του μετασχηματισμού των ενσωματώσεων των γειτονικών κόμβων [103], [128], [129].

Βλέπε επίσης: ΤΝΔ, γράφος, ενσωμάτωση.

ομαλοποιημένη ελαχιστοποίηση απώλειας Βλέπε ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης.

ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης TBC.

ομαλοποίηση TBC.

ομαλοποιητής Ένας ομαλοποιητής (regularizer) αποδίδει σε κάθε υπόθεση h από έναν χώρο υποθέσεων $\mathcal{H}$ ένα ποσοτικό μέτρο $\mathcal{R}\{h\}$ που εκφράζει σε ποιόν βαθμό τα σφάλματα πρόβλεψής της μπορεί να διαφέρουν σε σημεία δεδομένων σε ένα σύνολο εκπαίδευσης και έξω από αυτό. Η αμφικλινή παλινδρόμηση χρησιμοποιεί τον ομαλοποιητή $\mathcal{R}\{h\} := \|\mathbf{w}\|_2^2$ για γραμμικές απεικονίσεις υπόθεσης $h^{(\mathbf{w})}(\mathbf{x}) := \mathbf{w}^T \mathbf{x}$ [8, Κεφ. 3]. Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής χρησιμοποιεί τον ομαλοποιητή $\mathcal{R}\{h\} := \|\mathbf{w}\|_1$ για γραμμικές απεικονίσεις υπόθεσης $h^{(\mathbf{w})}(\mathbf{x}) := \mathbf{w}^T \mathbf{x}$ [8, Κεφ. 3].

Βλέπε επίσης: υπόθεση, χώρος υποθέσεων, πρόβλεψη, σύνολο εκπαίδευσης, σημείο δεδομένων, αμφικλινής παλινδρόμηση, απεικόνιση, τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής, απώλεια, αντικειμενική συνάρτηση.

ομοιότητα συνημιτόνου TBC.

ομοσπονδιακή μάθηση Η ομοσπονδιακή μάθηση (federated learning - FL) είναι ένας όρος-ομπρέλα για μεθόδους μηχανικής μάθησης που εκπαιδεύουν μοντέλα με έναν συνεργατικό τρόπο χρησιμοποιώντας αποκεντρωμένα δεδομένα και υπολογισμό.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, δεδομένα.


οπισθοδιάδοση TBC.

οριζόντια ομοσπονδιακή μάθηση Η οριζόντια ομοσπονδιακή μάθηση (horizontal federated learning - HFL) χρησιμοποιεί τοπικά σύνολα δεδομένων που αποτελούνται από διαφορετικά σημεία δεδομένων, αλλά χρησιμοποιεί τα ίδια χαρακτηριστικά για να τα χαρακτηρίσει [130]. Για παράδειγμα, η πρόγνωση καιρού χρησιμοποιεί ένα δίκτυο χωρικά κατανεμμένων μετεωρολογικών σταθμών (παρατήρησης). Κάθε μετεωρολογικός σταθμός μετράει τις ίδιες ποσότητες, όπως την ημερήσια θερμοκρασία, την ατμοσφαιρική πίεση, και τα ατμοσφαιρικά καταχρημνίσματα. Ωστόσο, διαφορετικοί μετεωρολογικοί σταθμοί μετράνε τα χαρακτηριστικά διαφορετικών χωροχρονικών περιοχών. Κάθε χωροχρονική περιοχή αναπαριστά ένα μεμονωμένο σημείο δεδομένων, με το καθένα να χαρακτηρίζεται από τα ίδια χαρακτηριστικά (δηλαδή ημερήσια θερμοκρασία ή ατμοσφαιρική πίεση).

Βλέπε επίσης: τοπικό σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ημιεποπτευόμενη μάθηση, ομοσπονδιακή μάθηση, κατακόρυφη ομοσπονδιακή μάθηση.

όριο απόφασης Θεωρούμε μία απεικόνιση υπόθεσης h που διαβάζει ένα διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$ και παραδίδει μία τιμή από ένα πεπερασμένο σύνολο $\mathcal{Y}$. Το όριο απόφασης της h είναι το σύνολο των διανυσμάτων $\mathbf{x} \in \mathbb{R}^d$ που βρίσκονται ανάμεσα σε διαφορετικές περιοχές αποφάσεων. Πιο συγκεκριμένα, ένα διάνυσμα $\mathbf{x}$ ανήκει στο όριο απόφασης αν και μόνο αν κάθε γειτονιά $\{\mathbf{x}' : \|\mathbf{x} - \mathbf{x}'\| \leq \varepsilon\}$, για οποιαδήποτε $\varepsilon > 0$, περιέχει τουλάχιστον δύο διανύσματα με διαφορετικές τιμές συνάρτησης. Βλέπε επίσης: υπόθεση, απεικόνιση, διάνυσμα χαρακτηριστικών, όριο, διάνυσμα, περιοχή αποφάσεων, γειτονιά, συνάρτηση.

όρος ποινής Θεωρούμε μία μέθοδο μηχανικής μάθησης βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που μαθαίνει τις παραμέτρους μοντέλου $\mathbf{w}$ ελαχιστοποιώντας τη μέση απώλεια (ή εμπειρική διακινδύνευση) $\hat{L}(\mathbf{w}|\mathcal{D})$ σε ένα σύνολο εκπαίδευσης $\mathcal{D}$. Για να αποφευχθεί η υπερπροσαρμογή και να ελεγχθεί το χάσμα γενίκευσης, είναι σύνηθες να επαυξάνεται η αντικειμενική συνάρτηση $\hat{L}(\mathbf{w}|\mathcal{D})$ με έναν όρο ποινής (penalty term) $\alpha\mathcal{R}\{\mathbf{w}\}$. Αναφερόμαστε στην επακόλουθη τροποποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης ως ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης.



Σχ. 61. Η προσθήκη ενός όρου ποινής $\alpha \mathcal{R}\{\mathbf{w}\}$ στην αντικειμενική συνάρτηση της ελαχιστοποίησης εμπειρικής διακινδύνευσης είναι ισοδύναμη με τη συμπερίληψη διαταραχών του συνόλου εκπαίδευσης $\mathcal{D}$ κατά την εκπαίδευση. Η παράμετρος ομαλοποίησης α ελέγχει την έκταση των διαταραχών.

Ο όρος ποινής εξαρτάται μόνο από τις παραμέτρους του μοντέλου αλλά όχι από τα σημεία δεδομένων στο σύνολο εκπαίδευσης. Για κάποιους συνδυασμούς μοντέλου και συνάρτησης απώλειας, ο όρος ποινής μπορεί να προκύψει ως η μέση απώλεια που προκαλείται σε διαταραγμένα αντίγραφα (άπειρου αριθμού) του συνόλου εκπαίδευσης. Με άλλα λόγια, η προσθήκη ενός όρου ποινής στην ελαχιστοποίηση εμπειρικής διακινδύνευσης μπορεί να θεωρηθεί ως μία μορφή επαύξησης δεδομένων.


Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, μηχανική μάθηση, παράμετρος μοντέλου, απώλεια, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, υπερπροσαρμογή, χάσμα γενίκευσης, αντικειμενική συνάρτηση, ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης, ετικέτα, χαρακτηριστικό, εκπαίδευση, ομαλοποίηση, παράμετρος, σημείο δεδομένων, μοντέλο, συνάρτηση απώλειας, επαύξηση δεδομένων.

παλινδρόμηση Τα προβλήματα παλινδρόμησης (regression) περιστρέφονται

γύρω από την πρόβλεψη μίας αριθμητικής ετικέτας μόνο από τα χαρακτηριστικά ενός σημείου δεδομένων [8, Κεφ. 2].

Βλέπε επίσης: πρόβλεψη, ετικέτα, χαρακτηριστικό, σημείο δεδομένων.

παλινδρόμηση ελάχιστης απόλυτης απόκλισης Η παλινδρόμηση ελάχιστης απόλυτης απόκλισης (least absolute deviation regression) αποτελεί μία περίπτωση ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιεί την απώλεια απόλυτου σφάλματος. Είναι μία ειδική περίπτωση παλινδρόμησης Huber. Για το παραμετρικό μοντέλο $h^{(w)}(\mathbf{x}) = w$, η ελαχιστοποίηση εμπειρικής διακινδύνευσης με απώλεια απόλυτου σφάλματος λύνεται μέσω της διαμέσου (Βλέπε Σχ. 62). Για το ίδιο παραμετρικό μοντέλο, αντίθετα, η χρήση της απώλειας τετραγωνικού σφάλματος οδηγεί την ελαχιστοποίηση εμπειρικής διακινδύνευσης να υπολογίζει τη μέση τιμή.



Σχ. 62. Για το απλό παραμετρικό μοντέλο $h^{(w)}(\mathbf{x}) = w$, η ελαχιστοποίηση εμπειρικής διακινδύνευσης με απώλεια απόλυτου σφάλματος ισοδυναμεί με τον υπολογισμό της διάμεσο. (a) Αρχικό σύνολο δεδομένων $\mathcal{D}$. (b) Θορυβώδες σύνολο δεδομένων $\tilde{\mathcal{D}}$ που περιλαμβάνει μία ακραία τιμή.

Βλέπε επίσης: ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια απόλυτου σφάλματος, παλινδρόμηση Huber, παραμετρικό μοντέλο, διάμεσος, απώλεια τετραγωνικού σφάλματος, μέση τιμή, ακραία τιμή, σύνολο δεδομένων.

παλινδρόμηση Huber Η παλινδρόμηση Huber (Huber regression) [131] αναφέρεται σε μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης που χρησιμοποιούν την απώλεια Huber ως μέτρο του σφάλματος πρόβλεψης. Δύο σημαντικές ειδικές περιπτώσεις της παλινδρόμησης Huber είναι η παλινδρόμηση ελάχιστης απόλυτης απόκλισης και η γραμμική παλινδρόμηση. Η ρύθμιση της παραμέτρου-κατωφλιού της απώλειας Huber επιτρέπει στον χρήστη να ανταλλάξει τη στιβαρότητα της απώλειας απόλυτου σφάλματος με τα υπολογιστικά οφέλη της λείας απώλειας τετραγωνικού σφάλματος.

Βλέπε επίσης: παλινδρόμηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια Huber, μέτρο, πρόβλεψη, παλινδρόμηση ελάχιστης απόλυτης απόκλισης, γραμμική παλινδρόμηση, παράμετρος, στιβαρότητα, απώλεια απόλυτου σφάλματος, λεία, απώλεια τετραγωνικού σφάλματος.

παλινδρόμηση k -πλησιέστερων γειτόνων Η παλινδρόμηση k -πλησιέστερων γειτόνων (k -nearest neighbors regression - KNNR) είναι μία ευρέως χρησιμοποιούμενη περίπτωση τοπικά σταθμισμένης μάθησης για παλινδρόμηση [8], [61]. Για να πραγματοποιήσει μία πρόβλεψη για ένα συγκεκριμένο σημείο δεδομένων $\mathbf{z}$, η παλινδρόμηση k -πλησιέστερων γειτόνων ταυτοποιεί τα k σημεία δεδομένων στο σύνολο εκπαίδευσης που βρίσκονται πιο κοντά στο $\mathbf{z}$ σύμφωνα με κάποια μετρική. Η πρόβλεψη προκύπτει τότε ως

ο μέσος όρος των ετικετών αυτών των k πλησιέστερων γειτόνων.

Βλέπε επίσης: τοπικά σταθμισμένη μάθηση, παλινδρόμηση, πρόβλεψη, σημείο δεδομένων, σύνολο εκπαίδευσης, μετρική, ετικέτα, πλησιέστερος γείτονας.

παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων Η παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων (independent and identically distributed assumption - i.i.d. assumption) είναι ένα ευρέως χρησιμοποιούμενο πιθανοτικό μοντέλο για την παραγωγή σημείων δεδομένων. Συγκεκριμένα, τα σημεία δεδομένων αναπαρίστανται ως ανεξάρτητες και ταυτόσημα κατανεμημένες τυχαίες μεταβλητές.

Βλέπε επίσης: ανεξάρτητες και ταυτόσημα κατανεμημένες, πιθανοτικό μοντέλο, σημείο δεδομένων, τυχαία μεταβλητή.

παραδοχή συσταδοποίησης Η παραδοχή συσταδοποίησης (clustering assumption) υποθέτει ότι σημεία δεδομένων σε ένα σύνολο δεδομένων σχηματίζουν έναν (μικρό) αριθμό ομάδων ή συστάδων. Τα σημεία δεδομένων στην ίδια συστάδα είναι πιο όμοια μεταξύ τους παρά με αυτά εκτός της συστάδας [114]. Αποκτούμε διαφορετικές μεθόδους συσταδοποίησης χρησιμοποιώντας διαφορετικές έννοιες ομοιότητας ανάμεσα σε σημεία δεδομένων.

Βλέπε επίσης: συσταδοποίηση, σημείο δεδομένων, σύνολο δεδομένων, συστάδα.

παραλληλισμός δεδομένων Ο παραλληλισμός δεδομένων (data parallelism) αναφέρεται σε μία ευρέως χρησιμοποιούμενη τάξη κατανεμημένων μεθόδων βελτιστοποίησης για την εκπαίδευση ενός μοντέλου μηχανικής μά-

θησης. Εδώ κάθε συμμετέχουσα συσκευή αποθηκεύει μία πλήρη ρεπλίκια των παραμέτρων του μοντέλου αλλά επεξεργάζεται ένα ξένο υποσύνολο του καθολικού συνόλου δεδομένων [59]. Σε σύγκριση με τον παραλληλισμό μοντέλου, ο οποίος κατανέμει τις παραμέτρους του μοντέλου μεταξύ των συσκευών, ο παραλληλισμός δεδομένων κατανέμει τον υπολογιστικό φόρτο εργασίας που σχετίζεται με μεγάλα σύνολα δεδομένων. Είναι ιδιαίτερα αποτελεσματικός όταν το μοντέλο προσαρμόζεται στη μνήμη μίας μοναδικής συσκευής, αλλά το σύνολο δεδομένων ή η πολυπλοκότητα της εκπαίδευσης θα ήταν απαγορευτική χωρίς παράλληλη επεξεργασία.

Βλέπε επίσης: δεδομένα, μέθοδος βελτιστοποίησης, εκπαίδευση, μηχανική μάθηση, μοντέλο, συσκευή, παράμετρος μοντέλου, σύνολο δεδομένων, παραλληλισμός μοντέλου, οριζόντια ομοσπονδιακή μάθηση.


παραλληλισμός μοντέλου Ο παραλληλισμός μοντέλου (model parallelism)

αναφέρεται σε μία συγκεκριμένη τάξη κατανεμημένων μεθόδων βελτιστοποίησης που χρησιμοποιούνται για την εκπαίδευση ενός μοντέλου μηχανικής μάθησης. Εδώ, διαφορετικές συσκευές αποθηκεύουν και επεξεργάζονται ξένα υποσύνολα των παραμέτρων του μοντέλου. Αυτή η προσέγγιση έρχεται σε αντίθεση με τον παραλληλισμό δεδομένων, όπου κάθε συσκευή διατηρεί μία πλήρη ρεπλίκια των παραμέτρων του μοντέλου κατά την επεξεργασία ξένων υποσυνόλων του καθολικού συνόλου δεδομένων. Ο παραλληλισμός μοντέλου μάς επιτρέπει να εκπαιδεύουμε ένα μοντέλο μηχανικής μάθησης του οποίου οι παράμετροι δεν μπορούν να προσαρμοστούν στη μνήμη μίας μοναδικής συσκευής. Μία βασική εφαρμογή του παραλληλισμού μοντέλου είναι η εκπαίδευση εξαιρετικά μεγάλων ΤΝΔ, όπως τα μοντέλα μετασχηματιστή με δισεκατομμύρια παραμέτρους

μοντέλου.

Βλέπε επίσης: μοντέλο, μέθοδος βελτιστοποίησης, μηχανική μάθηση, συσκευή, παράμετρος μοντέλου, παραλληλισμός δεδομένων, σύνολο δεδομένων, παράμετρος, εκπαίδευση, ΤΝΔ, μετασχηματιστής, κατακόρυφη ομοσπονδιακή μάθηση.


παραμετρικό μοντέλο Ένα παραμετρικό μοντέλο (parametric model) είναι ένα μαθηματικό μοντέλο που χαρακτηρίζεται από ένα πεπερασμένο σύνολο ποσοτήτων μεταβλητών που ονομάζονται παράμετροι. Ένα σημαντικό παράδειγμα είναι το πιθανοτικό μοντέλο που αποτελείται, για μία δεδομένη διάσταση d , από όλες τις πολυμεταβλητές κανονικές κατανομές (στον δειγματικό χώρο $\mathbb{R}^d$) με κάποιο διάνυσμα μέσης τιμής $\boldsymbol{\mu} \in \mathbb{R}^d$ και πίνακα συνδιακύμανσης $\mathbf{C} \in \mathbb{R}^{d \times d}$. Στο πλαίσιο της μηχανικής μάθησης, ένα παραμετρικό μοντέλο ορίζει έναν χώρο υποθέσεων $\mathcal{H}$ παραμετροποιημένο από έναν πεπερασμένο αριθμό παραμέτρων μοντέλου. Κάθε υπόθεση $h \in \mathcal{H}$ ταυτοποιείται μοναδικά από μία λίστα παραμέτρων μοντέλου $w_1, w_2, \dots, w_d$ (βλέπε Σχ. 64). Μπορούμε να στοιβάξουμε αυτές τις παραμέτρους σε ένα διάνυσμα $\mathbf{w} \in \mathbb{R}^d$. Δύο ευρέως χρησιμοποιούμενα παραδείγματα παραμετρικών μοντέλων είναι το γραμμικό μοντέλο και το ΤΝΔ. Ο αντίστοιχος παραμετρικός χώρος είναι συνήθως ένα υποσύνολο του $\mathbb{R}^d$.



Σχ. 63. Παραμετρικός χώρος $\mathcal{W}$ ενός μοντέλου μηχανικής μάθησης $\mathcal{H}$ που αποτελείται από όλες τις εφικτές επιλογές για τις παραμέτρους του μοντέλου. Κάθε επιλογή $\mathbf{w}$ για τις παραμέτρους του μοντέλου επιλέγει μία απεικόνιση υπόθεσης $h^{(\mathbf{w})} \in \mathcal{H}$.

Βλέπε επίσης: μοντέλο, παράμετρος, πιθανοτικό μοντέλο, διάσταση, πολυμεταβλητή κανονική κατανομή, δειγματικός χώρος, μέση τιμή, διάνυσμα, πίνακας συνδιακύμανσης, μηχανική μάθηση, χώρος υποθέσεων, παράμετρος μοντέλου, υπόθεση, γραμμικό μοντέλο, ΤΝΔ, παραμετρικός χώρος, απεικόνιση.

παραμετρικός χώρος Ο παραμετρικός χώρος $\mathcal{W}$ ενός μοντέλου μηχανικής μάθησης $\mathcal{H}$ είναι το σύνολο όλων των εφικτών επιλογών για τις παραμέτρους του μοντέλου (βλέπε Σχ. 64). Πολλές σημαντικές μέθοδοι μηχανικής μάθησης χρησιμοποιούν ένα μοντέλο που είναι παραμετροποιημένο με διανύσματα του Ευκλείδειου χώρου $\mathbb{R}^d$. Δύο ευρέως χρησιμοποιούμενα παραδείγματα παραμετροποιημένων μοντέλων είναι τα γραμμικά μοντέλα και τα βαθιά δίκτυα. Ο παραμετρικός χώρος είναι συχνά τότε ένα υποσύνολο $\mathcal{W} \subseteq \mathbb{R}^d$, π.χ. όλα τα διανύσματα $\mathbf{w} \in \mathbb{R}^d$ με μία νόρμα μικρότερη από ένα.




Σχ. 64. Ο παραμετρικός χώρος $\mathcal{W}$ ενός μοντέλου μηχανικής μάθησης $\mathcal{H}$ αποτελείται από όλες τις εφικτές επιλογές για τις παραμέτρους του μοντέλου. Κάθε επιλογή $\mathbf{w}$ για τις παραμέτρους του μοντέλου επιλέγει μία απεικόνιση υπόθεσης $h^{(\mathbf{w})} \in \mathcal{H}$.

Βλέπε επίσης: παράμετρος, μηχανική μάθηση, μοντέλο, παράμετρος μοντέλου, διάνυσμα, Ευκλείδειος χώρος, γραμμικό μοντέλο, βαθύ δίκτυο, νόρμα, υπόθεση, απεικόνιση.

παράμετρος Η παράμετρος (parameter) ενός μοντέλου μηχανικής μάθησης είναι μία ποσότητα ρυθμιζόμενη (δηλαδή που μπορεί να μαθευτεί ή να προσαρμοστεί) που μας επιτρέπει να επιλέξουμε μεταξύ διαφορετικών απεικονίσεων υπόθεσης. Για παράδειγμα, το γραμμικό μοντέλο $\mathcal{H} := \{h^{(\mathbf{w})} : h^{(\mathbf{w})}(x) = w_1x + w_2\}$ αποτελείται από όλες τις απεικονίσεις υπόθεσης $h^{(\mathbf{w})}(x) = w_1x + w_2$ με μία συγκεκριμένη επιλογή για τις παραμέτρους $\mathbf{w} = (w_1, w_2)^T \in \mathbb{R}^2$. Ένα άλλο παράδειγμα παραμέτρου μοντέλου είναι τα βάρη που αποδίδονται σε μία σύνδεση μεταξύ δύο νευρώνων ενός ΤΝΔ.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, υπόθεση, απεικόνιση, γραμμικό μοντέλο, βάρος, νευρώνας, ΤΝΔ.

παράμετρος μοντέλου Τα στοιχεία ενός παραμετρικού μοντέλου προσδιορίζονται από ποσότητες που αναφέρονται ως παράμετροι του μοντέλου (model parameters). Στο πλαίσιο της μηχανικής μάθησης, ένα παραμετρικό μοντέλο αποτελείται από απεικονίσεις υπόθεσης που προσδιορίζονται από μία λίστα παραμέτρων του μοντέλου $w_1, w_2, \dots, w_d$. Είναι συχνά βολικό να στοιβάζουμε αυτές τις παραμέτρους του μοντέλου σε ένα διάνυσμα $\mathbf{w} = (w_1, \dots, w_d)^T \in \mathbb{R}^d$.



Σχ. 65. Οι παράμετροι μοντέλου $\mathbf{w}$ επιλέγουν μία καλά ορισμένη υπόθεση $h(\mathbf{w})$ από το μοντέλο $\mathcal{H}$.

Μπορούμε να σκεφτούμε τις παραμέτρους μοντέλου ως ένα αναγνωριστικό για μία απεικόνιση υπόθεσης, όμοια με το πώς ένας αριθμός κοινωνικής ασφάλισης ταυτοποιεί ένα άτομο.

Βλέπε επίσης: παραμετρικό μοντέλο, μοντέλο, παράμετρος, μηχανική μάθηση, υπόθεση, απεικόνιση, διάνυσμα, παραμετρικός χώρος.

περιοχή αποφάσεων Θεωρούμε μία απεικόνιση υπόθεσης h που δίνει τιμές από ένα πεπερασμένο σύνολο $\mathcal{Y}$. Για κάθε τιμή ετικέτας (δηλαδή κατηγορία) $a \in \mathcal{Y}$, η υπόθεση h καθορίζει ένα υποσύνολο τιμών χαρακτηριστικών $\mathbf{x} \in \mathcal{X}$ που οδηγούν στην ίδια έξοδο $h(\mathbf{x}) = a$. Αναφερόμαστε σε αυτό το υποσύνολο ως μία περιοχή αποφάσεων (decision region) της

υπόθεσης h .

Βλέπε επίσης: υπόθεση, απεικόνιση, ετικέτα, χαρακτηριστικό, έξοδος.

πιθανότητα Αποδίδουμε μία τιμή πιθανότητας, συνήθως επιλεγμένη στο διάστημα $[0, 1]$, σε κάθε γεγονός που μπορεί να συμβεί σε ένα τυχαίο πείραμα [6], [7], [52], [62].

Βλέπε επίσης: γεγονός, τυχαίο πείραμα.

πίνακας δεδομένων Βλέπε δεδομένα σε μορφή πίνακα.

πίνακας σύγχυσης Θεωρούμε ένα πεπερασμένο σύνολο δεδομένων με m σημεία δεδομένων, καθένα από τα οποία χαρακτηρίζεται από ένα διάνυσμα χαρακτηριστικών $\mathbf{x}$ και μία ετικέτα $y \in \mathcal{Y}$ με έναν πεπερασμένο χώρο ετικετών $\mathcal{Y} = \{1, \dots, k\}$. Για μία δεδομένη υπόθεση h , ο πίνακας σύγχυσης (confusion matrix) είναι ένας $k \times k$ πίνακας όπου κάθε γραμμή αντιστοιχεί σε μία συγκεκριμένη τιμή της αληθούς ετικέτας $y \in \mathcal{Y}$ και κάθε στήλη σε μία συγκεκριμένη τιμή της πρόβλεψης $h(\mathbf{x}) \in \mathcal{Y}$. Η καταχώριση του πίνακα στη c -οστή γραμμή και τη c' -οστή στήλη είναι ο αριθμός των σημείων δεδομένων με μία αληθή ετικέτα $y = c$ που προβλέπονται ως $h(\mathbf{x}) = c'$. Το άθροισμα των καταχωρίσεων της κύριας διαγωνίου είναι ο αριθμός των σωστά ταξινομημένων σημείων δεδομένων, δηλαδή εκείνων για τα οποία $y = h(\mathbf{x})$. Το άθροισμα των εκτός διαγωνίου καταχωρίσεων οδηγεί στον συνολικό αριθμό των σημείων δεδομένων που είναι λανθασμένα ταξινομημένα από την h .

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, ετικέτα, χώρος ετικετών, υπόθεση, πίνακας, πρόβλεψη, ταξινόμηση.

πίνακας σχεδιασμού Ο όρος πίνακας σχεδιασμού (design matrix) είναι συνώνυμος του πίνακα χαρακτηριστικών, και χρησιμοποιείται ιδιαίτερα στη στατιστική [45], [95]. Συγκεντρώνει τα διανύσματα χαρακτηριστικών των σημείων δεδομένων σε ένα σύνολο δεδομένων που χρησιμοποιείται για την εκπαίδευση ή την επικύρωση ενός μοντέλου.

Βλέπε επίσης: πίνακας, πίνακας χαρακτηριστικών, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, σύνολο δεδομένων, μοντέλο, εκπαίδευση, επικύρωση.

πίνακας χαρακτηριστικών Θεωρούμε ένα σύνολο δεδομένων $\mathcal{D}$ με m σημεία δεδομένων με διανύσματα χαρακτηριστικών $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)} \in \mathbb{R}^d$. Είναι βολικό να συγκεντρώσουμε τα μεμονωμένα διανύσματα χαρακτηριστικών σε έναν πίνακα χαρακτηριστικών (feature matrix):

$$\mathbf{X} := (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)})^T = \begin{pmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_d^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_d^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_d^{(m)} \end{pmatrix} \in \mathbb{R}^{m \times d}.$$

Σημείωση ότι ο πίνακας χαρακτηριστικών είναι μεγέθους $m \times d$, δηλαδή έχει m γραμμές και d στήλες.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, χαρακτηριστικό, πίνακας.

πλησιέστερος γείτονας Οι μέθοδοι πλησιέστερου γείτονα (nearest neighbor - NN) μαθαίνουν μία υπόθεση $h : \mathcal{X} \rightarrow \mathcal{Y}$ της οποίας η τιμή συνάρτησης $h(\mathbf{x})$ καθορίζεται μόνο από τους πλησιέστερους γείτονες εντός ενός

δεδομένου συνόλου δεδομένων. Διαφορετικές μέθοδοι χρησιμοποιούν διαφορετικές μετρικές για τον καθορισμό των πλησιέστερων γειτόνων. Αν σημεία δεδομένων χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών, μπορούμε να χρησιμοποιήσουμε τις Ευκλείδειες αποστάσεις τους ως τη μετρική.

Βλέπε επίσης: υπόθεση, συνάρτηση, σύνολο δεδομένων, μετρική, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, Ευκλείδεια απόσταση, γείτονας.

πολυπλοκότητα Rademacher Όμοια με τη διάσταση Vapnik–Chervonenkis, η πολυπλοκότητα Rademacher [132] είναι ένα ποσοτικό μέτρο του μεγέθους ενός χώρου υποθέσεων $\mathcal{H}$. Βασίζεται στην εμπειρική πολυπλοκότητα Rademacher, η οποία ορίζεται για ένα συγκεκριμένο σύνολο δεδομένων $\mathcal{D}$ ως

$$\mathcal{R}_{\mathcal{D}}(\mathcal{H}) = \mathbb{E}_{\varepsilon_1, \dots, \varepsilon_m} \sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{r=1}^m \varepsilon_r h(\mathbf{x}^{(r)}).$$

Εδώ η προσδοκία λαμβάνεται αναφορικά με τις τυχαίες μεταβλητές $\varepsilon_1, \dots, \varepsilon_m$, οι οποίες είναι ανεξάρτητες και ταυτόσημα κατανομημένες και παίρνουν τιμές στο $\{-1, +1\}$ με ίση πιθανότητα $1/2$. Η πολυπλοκότητα Rademacher του $\mathcal{H}$ ορίζεται τότε ως η προσδοκία της εμπειρικής πολυπλοκότητας Rademacher ενός τυχαίου συνόλου δεδομένων $\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$ που αποτελείται από m ανεξάρτητες και ταυτόσημα κατανομημένες τυχαίες μεταβλητές $\mathbf{x}^{(r)} \in \mathcal{X}$ για $r = 1, \dots, m$.

Βλέπε επίσης: διάσταση Vapnik–Chervonenkis, μέτρο, χώρος υποθέσεων, σύνολο δεδομένων, προσδοκία, τυχαία μεταβλητή, ανεξάρτητες και ταυτόσημα κατανομημένες, πιθανότητα, γενίκευση, μηχανική μάθηση, α-

ποτελεσματική διάσταση.

πολυωνυμική παλινδρόμηση Η πολυωνυμική παλινδρόμηση (polynomial regression) είναι μία περίπτωση ελαχιστοποίησης εμπειρικής διακινδύνευσης που μαθαίνει μία πολυωνυμική απεικόνιση υπόθεσης για να προβλέψει μία αριθμητική ετικέτα με βάση τα αριθμητικά χαρακτηριστικά ενός σημείου δεδομένων. Για σημεία δεδομένων που χαρακτηρίζονται από ένα μοναδικό αριθμητικό χαρακτηριστικό, η πολυωνυμική παλινδρόμηση χρησιμοποιεί τον χώρο υποθέσεων $\mathcal{H}_d^{(\text{poly})} := \{h(x) = \sum_{j=0}^{d-1} x^j w_j\}$. Η ποιότητα μίας πολυωνυμικής απεικόνισης υπόθεσης μετράται χρησιμοποιώντας τη μέση απώλεια τετραγωνικού σφάλματος που προκύπτει σε ένα σύνολο σημείων δεδομένων με ετικέτες (στο οποίο αναφερόμαστε ως το σύνολο εκπαίδευσης).

Βλέπε επίσης: παλινδρόμηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, απεικόνιση, ετικέτα, χαρακτηριστικό, σημείο δεδομένων, χώρος υποθέσεων, απώλεια τετραγωνικού σφάλματος, σημείο δεδομένων με ετικέτα, σύνολο εκπαίδευσης.

πραγμάτωση Θεωρούμε μία τυχαία μεταβλητή $\mathbf{x}$ που αντιστοιχίζει κάθε έκβαση $\omega \in \Omega$ ενός χώρου πιθανοτήτων σε ένα στοιχείο $\mathbf{a}$ ενός μετρήσιμου χώρου $\mathcal{N}$ [2], [6], [62]. Μία πραγμάτωση (realization) της $\mathbf{x}$ είναι οποιοδήποτε στοιχείο $\mathbf{a} \in \mathcal{N}$ τέτοιο ώστε να υφίσταται ένα στοιχείο $\omega' \in \Omega$ με $\mathbf{x}(\omega') = \mathbf{a}$.

Βλέπε επίσης: τυχαία μεταβλητή, έκβαση, χώρος πιθανοτήτων, μετρήσιμο.

πρόβλεψη Μία πρόβλεψη (prediction) είναι μία εκτίμηση ή προσέγγιση για

κάποια ποσότητα ενδιαφέροντος. Η μηχανική μάθηση περιστρέφεται γύρω από τη μάθηση ή εύρεση μίας απεικόνισης υπόθεσης h που διαβάζει τα χαρακτηριστικά $\mathbf{x}$ ενός σημείου δεδομένων και παραδίδει μία πρόβλεψη $\hat{y} := h(\mathbf{x})$ για την ετικέτα του y .

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, απεικόνιση, χαρακτηριστικό, σημείο δεδομένων, ετικέτα.


προγνωστικός παράγοντας Ένας προγνωστικός παράγοντας (predictor)

είναι μία απεικόνιση υπόθεσης πραγματικής τιμής. Δεδομένου ενός σημείου δεδομένων με χαρακτηριστικά $\mathbf{x}$, η τιμή $h(\mathbf{x}) \in \mathbb{R}$ χρησιμοποιείται ως μία πρόβλεψη για την αληθή αριθμητική ετικέτα $y \in \mathbb{R}$ του σημείου δεδομένων.

Βλέπε επίσης: υπόθεση, απεικόνιση, σημείο δεδομένων, χαρακτηριστικό, πρόβλεψη, ετικέτα.

προσδοκία Θεωρούμε ένα αριθμητικό διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$

που ερμηνεύουμε ως την πραγμάτωση μίας τυχαίας μεταβλητής με μία κατανομή πιθανότητας $p(\mathbf{x})$. Η προσδοκία (expectation) του $\mathbf{x}$ ορίζεται ως το ολοκλήρωμα $\mathbb{E}\{\mathbf{x}\} := \int \mathbf{x}p(\mathbf{x})$. Σημείωση ότι η προσδοκία ορίζεται μόνο αν υφίσταται αυτό το ολοκλήρωμα, δηλαδή αν η τυχαία μεταβλητή είναι ολοκληρώσιμη [2], [6], [62]. Το Σχ. 66 απεικονίζει την προσδοκία μίας βαθμωτής διακριτής τυχαίας μεταβλητής x που παίρνει τιμές μόνο από ένα πεπερασμένο σύνολο.




Σχ. 66. Η προσδοκία μίας διακριτής τυχαίας μεταβλητής x προκαλείται από το άθροισμα των πιθανών τιμών της x_i , σταθμισμένες από την αντίστοιχη πιθανότητα $p(x_i) = \mathbb{P}(x = x_i)$.

Βλέπε επίσης: διάνυσμα χαρακτηριστικών, πραγμάτωση, τυχαία μεταβλητή, κατανομή πιθανότητας, ολοκληρώσιμη, διακριτή τυχαία μεταβλητή, πιθανότητα.

προσοχή Κάποιες εφαρμογές μηχανικής μάθησης περιλαμβάνουν σημεία δεδομένων που αποτελούνται από μικρότερες μονάδες, οι οποίες αναφέρονται ως tokens. Για παράδειγμα, μία πρόταση αποτελείται από λέξεις, μία εικόνα από τμήματα εικονοστοιχείων, και ένα δίκτυο από κόμβους. Γενικά, τα tokens που συνιστούν ένα μοναδικό σημείο δεδομένων δεν είναι ανεξάρτητες μεταξύ τους. Αντίθετα, κάθε token ενός σημείου δεδομένων εξαρτάται από (ή δίνει προσοχή (attention) σε) συγκεκριμένα άλλα tokens. Τα πιθανοτικά μοντέλα παρέχουν ένα πλαίσιο αρχών για την αναπαράσταση και την ανάλυση τέτοιων εξαρτήσεων [133]. Οι μηχανισμοί προσοχής χρησιμοποιούν μία πιο άμεση προσέγγιση χωρίς ρητή αναφορά σε ένα πιθανοτικό μοντέλο. Η ιδέα είναι να αναπαρασταθεί η σχέση μεταξύ δύο tokens i και i' χρησιμοποιώντας μία παραμετροποιη-

μένη συνάρτηση $f^{(\mathbf{w})}(i, i')$, όπου οι παράμετροι $\mathbf{w}$ μαθαίνονται μέσω μίας παραλλαγής της ελαχιστοποίησης εμπειρικής διακινδύνευσης. Οι πρακτικοί μηχανισμοί προσοχής διαφέρουν τόσο ως προς την ακριβή επιλογή μοντέλου προσοχής $f^{(\mathbf{w})}(i, i')$ όσο και ως προς την ακριβή παραλλαγή της ελαχιστοποίησης εμπειρικής διακινδύνευσης που χρησιμοποιείται για τη μάθηση των παραμέτρων $\mathbf{w}$. Μία ευρέως χρησιμοποιούμενη οικογένεια μηχανισμών προσοχής ορίζει τις παραμέτρους $\mathbf{w}$ ως προς δύο διανύσματα που σχετίζονται με κάθε token i , δηλαδή ένα διάνυσμα ερωτήματος $\mathbf{q}^{(i)}$ και ένα διάνυσμα κλειδιού $\mathbf{k}^{(i)}$. Για ένα δεδομένο token i με ερώτημα $\mathbf{q}^{(i)}$ και ένα άλλο token i' με κλειδί $\mathbf{k}^{(i')}$, η ποσότητα $(\mathbf{q}^{(i)})^\top \mathbf{k}^{(i')}$ υποδεικνύει το κατά πόσο το token i δίνει προσοχή σε (ή εξαρτάται από) το token i' (βλέπε Σχ. 67).



Σχ. 67. Οι μηχανισμοί προσοχής μαθαίνουν μία παραμετροποιημένη συνάρτηση $f^{(\mathbf{w})}(i, i')$ για να μετρήσουν πόσο το token i δίνει προσοχή στο token i' . Μία ευρέως χρησιμοποιούμενη κατασκευή της $f^{(\mathbf{w})}(i, i')$ χρησιμοποιεί τα διανύσματα ερωτήματος και κλειδιού, τα οποία δηλώνονται με $\mathbf{q}^{(i)}$ και $\mathbf{k}^{(i)}$, που αποδίδονται σε κάθε token i [122].

Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, token, πιθανοτικό μοντέλο, συνάρτηση, παράμετρος, ελαχιστοποίηση εμπειρικής διακινδύνευσης, μοντέλο, διάνυσμα.

προστασία της ιδιωτικότητας Θεωρούμε κάποια μέθοδο μηχανικής μάθησης $\mathcal{A}$ που διαβάζει ένα σύνολο δεδομένων $\mathcal{D}$ και παραδίδει κάποια έξοδο $\mathcal{A}(\mathcal{D})$. Η έξοδος θα μπορούσε να είναι οι παράμετροι μοντέλου $\hat{\mathbf{w}}$ που μαθαίνονται ή η πρόβλεψη $\hat{h}(\mathbf{x})$ που προκύπτει για ένα συγκεκριμένο σημείο δεδομένων με χαρακτηριστικά $\mathbf{x}$. Πολλές σημαντικές εφαρμογές μηχανικής μάθησης περιλαμβάνουν σημεία δεδομένων που αντιπροσωπεύουν ανθρώπους. Κάθε σημείο δεδομένων χαρακτηρίζεται από χαρακτηριστικά $\mathbf{x}$, ενδεχομένως μία ετικέτα y , και ένα ευαίσθητο ιδιοχαρακτηριστικό s (π.χ. μία πρόσφατη ιατρική διάγνωση). Σε γενικές γραμμές, προστασία της ιδιωτικότητας (privacy protection) σημαίνει ότι θα έπρεπε να είναι αδύνατο να συμπεράνουμε, από την έξοδο $\mathcal{A}(\mathcal{D})$, οποιοδήποτε από τα ευαίσθητα ιδιοχαρακτηριστικά των σημείων δεδομένων στο $\mathcal{D}$. Από μαθηματική άποψη, η προστασία της ιδιωτικότητας απαιτεί τη μη αντιστρεψιμότητα της απεικόνισης $\mathcal{A}(\mathcal{D})$. Γενικά, το να κάνουμε απλώς την $\mathcal{A}(\mathcal{D})$ μη αντιστρέψιμη είναι συνήθως ανεπαρκές για την προστασία της ιδιωτικότητας. Χρειάζεται να κάνουμε την $\mathcal{A}(\mathcal{D})$ επαρκώς μη αντιστρέψιμη.

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, έξοδος, παράμετρος μοντέλου, πρόβλεψη, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, ευαίσθητο ιδιοχαρακτηριστικό, απεικόνιση.

πυρήνας (μέθοδος πυρήνα) Θεωρούμε ένα σύνολο σημείων δεδομένων, το καθένα να αναπαριστάται από ένα διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathcal{X}$, όπου $\mathcal{X}$ δηλώνει τον χώρο χαρακτηριστικών. Ένας πυρήνας (kernel) (πραγματικής τιμής) είναι μία συνάρτηση $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ που αποδίδει σε κάθε ζεύγος διανυσμάτων χαρακτηριστικών $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$ έναν πραγματικό

αριθμό $k(\mathbf{x}, \mathbf{x}')$. Αυτή η τιμή συνήθως ερμηνεύεται ως ένα μέτρο της ομοιότητας μεταξύ των $\mathbf{x}$ και $\mathbf{x}'$. Η καθοριστική ιδιότητα ενός πυρήνα είναι ότι είναι συμμετρικός, δηλαδή $k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x}', \mathbf{x})$, και ότι για οποιοδήποτε πεπερασμένο σύνολο διανυσμάτων χαρακτηριστικών $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathcal{X}$, ο πίνακας

$$\mathbf{K} = \begin{pmatrix} k(\mathbf{x}_1, \mathbf{x}_1) & k(\mathbf{x}_1, \mathbf{x}_2) & \dots & k(\mathbf{x}_1, \mathbf{x}_n) \\ k(\mathbf{x}_2, \mathbf{x}_1) & k(\mathbf{x}_2, \mathbf{x}_2) & \dots & k(\mathbf{x}_2, \mathbf{x}_n) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}_n, \mathbf{x}_1) & k(\mathbf{x}_n, \mathbf{x}_2) & \dots & k(\mathbf{x}_n, \mathbf{x}_n) \end{pmatrix} \in \mathbb{R}^{n \times n}$$


είναι θετικά ημιορισμένος. Ένας πυρήνας καθορίζει φυσικά έναν μετασχηματισμό ενός διανύσματος χαρακτηριστικών $\mathbf{x}$ σε μία συνάρτηση $\mathbf{z} = k(\mathbf{x}, \cdot)$. Η συνάρτηση $\mathbf{z}$ αντιστοιχίζει μία είσοδο $\mathbf{x}' \in \mathcal{X}$ στην τιμή $k(\mathbf{x}, \mathbf{x}')$. Μπορούμε να θεωρήσουμε τη συνάρτηση $\mathbf{z}$ ως ένα νέο διάνυσμα χαρακτηριστικών που ανήκει σε έναν χώρο χαρακτηριστικών $\mathcal{X}'$ που είναι συνήθως διαφορετικός από τον $\mathcal{X}$. Αυτός ο νέος χώρος χαρακτηριστικών $\mathcal{X}'$ έχει μία συγκεκριμένη μαθηματική δομή, δηλαδή είναι ένας χώρος Hilbert αναπαραγωγού πυρήνα (reproducing kernel Hilbert space - RKHS) [49], [89]. Δεδομένου ότι η $\mathbf{z}$ ανήκει σε έναν χώρο Hilbert αναπαραγωγού πυρήνα, ο οποίος είναι ένας διανυσματικός χώρος, μπορούμε να την ερμηνεύσουμε ως ένα γενικευμένο διάνυσμα χαρακτηριστικών. Σημείωση ότι ένα διάνυσμα χαρακτηριστικών πεπερασμένου μήκους $\mathbf{x} = (x_1, \dots, x_d)^T \in \mathbb{R}^d$ μπορεί να θεωρηθεί ως μία συνάρτηση $\mathbf{x} : \{1, \dots, d\} \rightarrow \mathbb{R}$ που αποδίδει μία πραγματική τιμή σε κάθε δείκτη $j \in \{1, \dots, d\}$.

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, χώρος χαρακτηριστικών, συνάρτηση, μέτρο, πίνακας, θετικά ημιορισμένος, χώρος Hilbert, διανυσματικός χώρος, μέθοδος πυρήνα.

ρυθμός μάθησης Θεωρούμε μία επαναληπτική μέθοδο μηχανικής μάθησης για την εύρεση ή μάθηση μίας χρήσιμης υπόθεσης $h \in \mathcal{H}$. Μία τέτοια επαναληπτική μέθοδος επαναλαμβάνει όμοια υπολογιστικά βήματα (ενημέρωσης) που προσαρμόζουν ή τροποποιούν την τρέχουσα υπόθεση για να προκύψει μία βελτιωμένη υπόθεση. Μία παράμετρος-κλειδί μίας επαναληπτικής μεθόδου είναι ο ρυθμός μάθησης (learning rate). Ο ρυθμός μάθησης ελέγχει τον βαθμό που η τρέχουσα υπόθεση μπορεί να τροποποιηθεί κατά τη διάρκεια μίας μονής επανάληψης. Θεωρούμε, για παράδειγμα, το βήμα κλίσης [8, Κεφ. 5]

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla f(\mathbf{w}^{(t)}) \quad (6)$$

μίας μεθόδου με βάση την κλίση για ελαχιστοποίηση εμπειρικής διακινδύνευσης, όπου η αντικειμενική συνάρτηση $f(\mathbf{w})$ είναι η εμπειρική διακινδύνευση που προκαλείται από την $h(\mathbf{w})$ σε ένα σύνολο εκπαίδευσης. Δεδομένων των τρεχουσών παραμέτρων του μοντέλου $\mathbf{w}^{(t)}$ στην επανάληψη t , το βήμα κλίσης παράγει ενημερωμένες παραμέτρους του μοντέλου $\mathbf{w}^{(t+1)}$ μετακινούμενο προς την αντίθετη κατεύθυνση της κλίσης $\nabla f(\mathbf{w}^{(t)})$.



Σχ. 68. Η επίδραση ενός ανεπαρκούς ρυθμού μάθησης η στο βήμα κλίσης (6). (a) Αν ο η είναι πολύ μεγάλος, τα βήματα κλίσης μπορεί να «υπερβούν» το βέλτιστο, έτσι ώστε οι επαναλήψεις $w^{(t)}$ να αποκλίνουν από αυτό, δηλαδή $f(w^{(t+1)}) > f(w^{(t)})$. (b) Αν ο η είναι πολύ μικρός, τα βήματα κλίσης σημειώνουν πολύ μικρή πρόοδο προς το βέλτιστο εντός του διαθέσιμου αριθμού επαναλήψεων (λόγω περιορισμένου υπολογιστικού προϋπολογισμού).

Βλέπε επίσης: μηχανική μάθηση, υπόθεση, παράμετρος, επανάληψη, βήμα κλίσης, μέθοδος με βάση την κλίση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, αντικειμενική συνάρτηση, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, παράμετρος μοντέλου, κλίση, κάθοδος κλίσης, στοχαστική κάθοδος κλίσης, προβεβλημένη κάθοδος κλίσης, μέγεθος βήματος.

σημείο δεδομένων Ένα σημείο δεδομένων (data point) είναι οποιοδήποτε αντικείμενο που μεταφέρει πληροφορίες [32]. Παραδείγματα περιλαμβάνουν μαθητές, ραδιοσήματα, δέντρα, εικόνες, τυχαίες μεταβλητές, πραγματικούς αριθμούς, ή πρωτεΐνες. Περιγράφουμε σημεία δεδομένων του ίδιου τύπου με δύο κατηγορίες ιδιοτήτων. Η πρώτη κατηγορία περιλαμβάνει χαρακτηριστικά που είναι μετρήσιμες ή υπολογίσιμες ιδιότητες ενός σημείου δεδομένων. Αυτά τα ιδιοχαρακτηριστικά μπορούν να εξαχθούν ή να υπολογιστούν αυτόματα χρησιμοποιώντας αισθητήρες, υπολογιστές, ή άλλα συστήματα συλλογής δεδομένων. Για ένα σημείο δεδομένων που

αναπαριστά έναν ασθενή, ένα χαρακτηριστικό θα μπορούσε να είναι το σωματικό βάρος. Η δεύτερη κατηγορία περιλαμβάνει ετικέτες που είναι υψηλότερου επιπέδου γεγονότα (ή ποσότητες ενδιαφέροντος)—δηλαδή γεγονότα που συνήθως απαιτούν ανθρώπινη εμπειρογνωσία ή γνώση τομέα για να προσδιοριστούν, αντί να είναι άμεσα μετρήσιμα—που σχετίζονται με το σημείο δεδομένων. Για ένα σημείο δεδομένων που αναπαριστά έναν ασθενή, μία διάγνωση καρκίνου που έχει παραχθεί από έναν γιατρό θα μπορούσε να χρησιμεύει ως ετικέτα. Το Σχ. 69 απεικονίζει μία εικόνα ως παράδειγμα ενός σημείου δεδομένων μαζί με τα χαρακτηριστικά και τις ετικέτες του. Σημαντικό είναι ότι το τι συνιστά ένα χαρακτηριστικό ή μία ετικέτα δεν είναι εγγενές στο ίδιο το σημείο δεδομένων—είναι μία επιλογή σχεδιασμού που εξαρτάται από τη συγκεκριμένη εφαρμογή μηχανικής μάθησης.



Ένα μοναδικό σημείο δεδομένων.

Χαρακτηριστικά:

- $x_1, \dots, x_{d_1}$: Εντάσεις χρώματος όλων των εικονοστοιχείων.
- x_{d_1+1} : Χρονική σήμανση της αποτύπωσης της εικόνας.
- x_{d_1+2} : Χωρική θέση της αποτύπωσης της εικόνας.

Ετικέτες:

- y_1 : Ο αριθμός αγελάδων που απεικονίζεται.
- y_2 : Ο αριθμός λύκων που απεικονίζεται.
- y_3 : Η κατάσταση του βοσκότοπου (π.χ. υγιής, με υπερβόσηση).

Σχ. 69. Εικονογράφηση ενός σημείου δεδομένων που αποτελείται από μία εικόνα. Μπορούμε να χρησιμοποιήσουμε διαφορετικές ιδιότητες της εικόνας ως χαρακτηριστικά και γεγονότα υψηλότερου επιπέδου για την εικόνα ως ετικέτες.

Η διάκριση μεταξύ χαρακτηριστικών και ετικετών δεν είναι πάντα ξεκάθαρη. Μία ιδιότητα που θεωρείται ετικέτα σε ένα περιβάλλον (π.χ. μία διάγνωση καρκίνου) μπορεί να αντιμετωπίζεται ως χαρακτηριστικό σε ένα

άλλο περιβάλλον—ιδιαίτερα αν η αξιόπιστη αυτοματοποίηση (π.χ. μέσω ανάλυσης εικόνων) επιτρέπει τον υπολογισμό της χωρίς ανθρώπινη παρέμβαση. Η μηχανική μάθηση στοχεύει γενικά στην πρόβλεψη της ετικέτας ενός σημείου δεδομένων με βάση τα χαρακτηριστικά του.

Βλέπε επίσης: δεδομένα, τυχαία μεταβλητή, χαρακτηριστικό, ετικέτα, μηχανική μάθηση, σύνολο δεδομένων.

σημείο δεδομένων με ετικέτα Ένα σημείο δεδομένων με ετικέτα (labeled data point) είναι ένα σημείο δεδομένων του οποίου η ετικέτα είναι γνωστή ή έχει προσδιοριστεί με κάποιον τρόπο που μπορεί να απαιτεί ανθρώπινη εργασία.

Βλέπε επίσης: σημείο δεδομένων, ετικέτα.

σκληρή συσταδοποίηση Η σκληρή συσταδοποίηση (hard clustering) αναφέρεται στην εργασία χωρισμού ενός συγκεκριμένου συνόλου σημείων δεδομένων σε (μερικές) μη αλληλεπικαλυπτόμενες συστάδες. Αυτή η απαίτηση μας επιτρέπει να αναπαραστήσουμε μία συστάδα ως ένα υποσύνολο σημείων δεδομένων, δηλαδή ακριβώς εκείνα που ανήκουν στη συστάδα. Σε αντίθεση με τη σκληρή συσταδοποίηση, οι μέθοδοι μαλακής συσταδοποίησης επιτρέπουν αλληλεπικαλυπτόμενες συστάδες και προσδιορίζουν, για κάθε σημείο δεδομένων, έναν αριθμητικό βαθμό συσχέτισης με κάθε συστάδα. Η σκληρή συσταδοποίηση αποτελεί μία ακραία περίπτωση μαλακής συσταδοποίησης όπου οι βαθμοί συσχέτισης παίρνουν μόνο δύο τιμές, δηλώνοντας είτε μηδενική συσχέτιση είτε πλήρη συσχέτιση. Για σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$, μία ευρέως χρησιμοποιούμενη μέθοδος σκλη-

ρής συσταδοποίησης είναι ο αλγόριθμος k -μέσων. Οποιαδήποτε μέθοδος σκληρής συσταδοποίησης για αριθμητικά διανύσματα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$ μπορεί να προσαρμοστεί σε μη αριθμητικά δεδομένα με τη χρήση μεθόδων μάθησης χαρακτηριστικών. Ένα σημαντικό παράδειγμα αυτής της προσέγγισης είναι η φασματική συσταδοποίηση, όπου σημεία δεδομένων διαθέτουν μία δομή ομοιότητας υπό τη μορφή ενός μη κατευθυνόμενου γράφου. Οι κόμβοι αυτού του γράφου αναπαριστούν τα σημεία δεδομένων ενώ οι μη κατευθυνόμενες (ενδεχομένως σταθμισμένες) ακμές αναπαριστούν ομοιότητες (και τον βαθμό τους) μεταξύ των σημείων δεδομένων. Μπορούμε τότε να χρησιμοποιήσουμε τις καταχωρίσεις των ιδιοδιανυσμάτων του Λαπλασιανού πίνακα ως αριθμητικά χαρακτηριστικά για κάθε σημείο δεδομένων.

Βλέπε επίσης: συσταδοποίηση, σημείο δεδομένων, συστάδα, μαλακή συσταδοποίηση, βαθμός συσχέτισης, διάνυσμα χαρακτηριστικών, αλγόριθμος k -μέσων, δεδομένα, μάθηση χαρακτηριστικών, φασματική συσταδοποίηση, μη κατευθυνόμενος γράφος, γράφος, ιδιοδιάνυσμα, Λαπλασιανός πίνακας, χαρακτηριστικό.

στάθμιση δείγματος TBC.

σταθμισμένα ελάχιστα τετράγωνα TBC.

στατιστική διάσταση Ως στατιστικές διαστάσεις (statistical aspects) μίας μεθόδου μηχανικής μάθησης, αναφερόμαστε στην κατανομή πιθανότητας (ή σε ιδιότητες της κατανομής πιθανότητας) της εξόδου της υπό ένα πιθανοτικό μοντέλο για τα δεδομένα που τροφοδοτούνται στη μέθοδο.

Βλέπε επίσης: μηχανική μάθηση, κατανομή πιθανότητας, έξοδος, πιθανο-

τικό μοντέλο, δεδομένα.


στιβαρότητα Η στιβαρότητα (robustness) είναι μία βασική απαίτηση για αξιόπιστη TN. Αναφέρεται στην ιδιότητα ενός συστήματος μηχανικής μάθησης να διατηρεί αποδεκτή επίδοση ακόμα και όταν υπόκειται σε διαφορετικές μορφές διαταραχών. Αυτές οι διαταραχές μπορεί να επηρεάσουν τα χαρακτηριστικά ενός σημείου δεδομένων με σκοπό τον χειρισμό της πρόβλεψης που παραδίδεται από ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Η στιβαρότητα περιλαμβάνει επίσης την ευστάθεια μεθόδων βασισμένων στην ελαχιστοποίηση εμπειρικής διακινδύνευσης απέναντι σε διαταραχές του συνόλου εκπαίδευσης. Τέτοιες διαταραχές μπορεί να συμβούν εντός επιθέσεων δηλητηρίασης δεδομένων.

Βλέπε επίσης: αξιόπιστη TN, σύστημα μηχανικής μάθησης, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, μηχανική μάθηση, μοντέλο, ευστάθεια, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, δηλητηρίαση δεδομένων, επίθεση.

στοίβαξη Η στοίβαξη (stacking) είναι ένας από τους κύριους τύπους μεθόδων συνόλου. Στη στοίβαξη, ένας πεπερασμένος αριθμός M base learners εκπαιδεύεται στο ίδιο σύνολο δεδομένων αλλά με διαφορετικά μοντέλα $\mathcal{H}^{(j)}$ ή συναρτήσεις απώλειας $L^{(j)}$ για $j = 1, \dots, M$ [75, Κεφ. 8.8], [134], [135]. Ο j -οστός base learner παραδίδει μία υπόθεση $\hat{h}^{(j)} \in \mathcal{H}^{(j)}$ που έχει μαθευτεί. Η τελική πρόβλεψη για ένα σημείο δεδομένων προκύπτει από τη συνάντρωση των προβλέψεων των base learners μέσω ενός κανόνα συνάντρωσης ϕ_{agg} , όπως η ψηφοφορία πλειοψηφίας για ταξινόμηση ή ο μέσος όρος για παλινδρόμηση. Μπορούμε να ερμηνεύσουμε τη στοίβαξη ως μία

μορφή μάθησης χαρακτηριστικών, όπου κάθε base learner εξάγει ένα νέο χαρακτηριστικό. Ο κανόνας συνάθροισης μπορεί να προκύψει από μία άλλη περίπτωση ελαχιστοποίησης εμπειρικής διακινδύνευσης που μαθαίνει μία απεικόνιση υπόθεσης $\phi_{\text{agg}} \in \mathcal{H}$ από ένα μετα-μοντέλο $\mathcal{H}$. Η υπόθεση ϕ_{agg} εφαρμόζεται στο μετασχηματισμένο διάνυσμα χαρακτηριστικών

$$\Phi(\mathbf{x}) = (\hat{h}^{(1)}(\mathbf{x}), \dots, \hat{h}^{(M)}(\mathbf{x}))^T.$$




Σχ. 70. Τρεις βασε λεαρνερ που χρησιμοποιούν ελαχιστοποίηση εμπειρικής διακινδύνευσης (ERM) με διαφορετικά μοντέλα και συναρτήσεις απώλειας για να αποκτήσουν υποθέσεις $\hat{h}^{(1)}, \hat{h}^{(2)}, \hat{h}^{(3)}$ που έχουν μαθευτεί. Για ένα σημείο δεδομένων με διάνυσμα χαρακτηριστικών $\mathbf{x}$, κάθε base learner παραδίδει μία πρόβλεψη $\hat{h}^{(j)}(\mathbf{x})$ για $j = 1, 2, 3$. Αυτές οι προβλέψεις χρησιμοποιούνται στη συνέχεια ως νέα χαρακτηριστικά για έναν κανόνα συνάθροισης ϕ_{agg} που παραδίδει τη συνολική πρόβλεψη $\hat{y}$. Ο κανόνας συνάθροισης μπορεί να προκύψει από την εκπαίδευση ενός μετα-μοντέλου $\mathcal{H}$.

Βλέπε επίσης: σύνολο, base learner, σύνολο δεδομένων, μοντέλο, συνάρτηση απώλειας, υπόθεση, πρόβλεψη, σημείο δεδομένων, ταξινόμηση, παλινδρόμηση, μάθηση χαρακτηριστικών, χαρακτηριστικό, ελαχιστοποί-

ηση εμπειρικής διακινδύνευσης, απεικόνιση, διάνυσμα χαρακτηριστικών, εκπαίδευση, bagging (or bootstrap aggregation).

στοχαστική κάθοδος κλίσης Η στοχαστική κάθοδος κλίσης (stochastic gradient descent - SGD) προκύπτει από την καθόδο κλίσης αντικαθιστώντας την κλίση της αντικειμενικής συνάρτησης με μία στοχαστική προσέγγιση. Μία κύρια εφαρμογή της στοχαστικής καθόδου κλίσης είναι η εκπαίδευση ενός παραμετροποιημένου μοντέλου μέσω της ελαχιστοποίησης εμπειρικής διακινδύνευσης πάνω σε ένα σύνολο εκπαίδευσης $\mathcal{D}$ που είτε είναι πολύ μεγάλο είτε δεν είναι εύκολα διαθέσιμο (π.χ. όταν σημεία δεδομένων αποθηκεύονται σε μία βάση δεδομένων κατανεμημένη παγκοσμίως). Για να αξιολογήσουμε την κλίση της εμπειρικής διακινδύνευσης (ως μία συνάρτηση των παραμέτρων του μοντέλου $\mathbf{w}$), χρειάζεται να υπολογίσουμε ένα άρθροισμα $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$ για όλα τα σημεία δεδομένων στο σύνολο εκπαίδευσης. Αποκτούμε μία στοχαστική προσέγγιση της κλίσης αντικαθιστώντας το άρθροισμα $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$ με ένα άρθροισμα $\sum_{r \in \mathcal{B}} \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$ για ένα τυχαία επιλεγμένο υποσύνολο $\mathcal{B} \subseteq \{1, \dots, m\}$ (βλέπε Σχ. 71). Αναφερόμαστε συχνά σε αυτά τα τυχαία επιλεγμένα σημεία δεδομένων ως μία δέσμη. Το μέγεθος της δέσμης $|\mathcal{B}|$ είναι μία σημαντική παράμετρος της στοχαστικής καθόδου κλίσης. Η στοχαστική κάθοδος κλίσης με $|\mathcal{B}| > 1$ αναφέρεται ως στοχαστική κάθοδος κλίσης μίνι-δέσμης [124].



Σχ. 71. Στοχαστική κάθοδος κλίσης για την ελαχιστοποίηση εμπειρικής διακινδύνευσης προσεγγίζει την κλίση αντικαθιστώντας το άθροισμα $\sum_{r=1}^m \nabla_{\mathbf{w}} L(\mathbf{z}^{(r)}, \mathbf{w})$ για όλα τα σημεία δεδομένων στο σύνολο εκπαίδευσης (με δείκτες $r = 1, \dots, m$) με ένα άθροισμα για ένα τυχαία επιλεγμένο υποσύνολο $\mathcal{B} \subseteq \{1, \dots, m\}$.

Βλέπε επίσης: κάθοδος κλίσης, κλίση, αντικειμενική συνάρτηση, στοχαστική, μοντέλο, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, σημείο δεδομένων, εμπειρική διακινδύνευση, συνάρτηση, παράμετρος μοντέλου, δέσμη, παράμετρος.


στοχαστικός αλγόριθμος Ένας στοχαστικός αλγόριθμος (stochastic algorithm) χρησιμοποιεί έναν τυχαίο μηχανισμό κατά την εκτέλεσή του. Για παράδειγμα, η στοχαστική κάθοδος κλίσης χρησιμοποιεί ένα τυχαία επιλεγμένο υποσύνολο σημείων δεδομένων για να υπολογίσει μία προσέγγιση για την κλίση μίας αντικειμενικής συνάρτησης. Μπορούμε να αναπαραστήσουμε έναν στοχαστικό αλγόριθμο με μία στοχαστική διαδικασία, δηλαδή η πιθανή ακολουθία εκτέλεσης είναι οι πιθανές εκβάσεις ενός τυχαίου πειράματος [7], [136], [137].

Βλέπε επίσης: στοχαστική, αλγόριθμος, στοχαστική κάθοδος κλίσης, σημείο δεδομένων, κλίση, αντικειμενική συνάρτηση, στοχαστική διαδικασία, ακολουθία, έκβαση, τυχαίο πείραμα, μέθοδος βελτιστοποίησης, μέθο-

δος με βάση την κλίση.

στόχος TBC.

στρωματοποίηση Η διαδικασία διαχωρισμού ενός συνόλου δεδομένων σε υποσύνολα, τα λεγόμενα στρώματα, σύμφωνα με κάποιο ιδιοχαρακτηριστικό-κλειδί ονομάζεται στρωματοποίηση (stratification) [44], [45], [138]. Ο στόχος είναι να εξασφαλιστεί ότι μία μέθοδος μηχανικής μάθησης επιδίδει καλά σε κάθε στρώμα που ορίζεται από αυτά τα ιδιοχαρακτηριστικά. Για παράδειγμα, σε ένα ιατρικό σύνολο δεδομένων, μπορεί να θέλουμε να πραγματοποιήσουμε στρωματοποίηση ενός συνόλου δεδομένων ασθενών με βάση τις ηλικιακές ομάδες, ώστε να εξασφαλίσουμε ότι ένα μοντέλο μηχανικής μάθησης επιδίδει καλά σε όλες τις ηλικιακές ομάδες. Κατά τον διαχωρισμό ενός συνόλου δεδομένων σε ένα σύνολο εκπαίδευσης και ένα σύνολο επικύρωσης, η στρωματοποίηση εξασφαλίζει ότι και τα δύο σύνολα έχουν όμοιες κατανομές του ιδιοχαρακτηριστικού-κλειδί. Χωρίς στρωματοποίηση, η χρήση ενός μικρού συνόλου επικύρωσης μπορεί να υποαναπαριστά ή ακόμα και να παραλείπει εντελώς σημεία δεδομένων με ένα σπάνιο ιδιοχαρακτηριστικό, οδηγώντας σε παραπλανητικές εκτιμήσεις επίδοσης. Βλέπε το Σχ. 72 για μία οπτική απεικόνιση.



Σχ. 72. Η στρωματοποίηση εξασφαλίζει ότι τόσο το σύνολο εκπαίδευσης όσο και το σύνολο επικύρωσης (χρωματισμένο με γκρι) έχουν όμοιες κατανομές ενός δυαδικού ιδιοχαρακτηριστικού-κλειδί s . Με άλλα λόγια, με στρωματοποίηση, και τα δύο στρώματα (δηλαδή $s = 1$ και $s = 2$ με βάση το ιδιοχαρακτηριστικό-κλειδί) διαθέτουν το ίδιο ποσοστό επικύρωσης—το 20% του δικού τους πλάτους.

Βλέπε επίσης: σύνολο δεδομένων, στρώμα, μηχανική μάθηση, μοντέλο, σύνολο εκπαίδευσης, σύνολο επικύρωσης, σημείο δεδομένων, επικύρωση, διασταυρούμενη επικύρωση k -αναδιπλώσεων.

στρωματοποίηση διακινδύνευσης Η στρωματοποίηση διακινδύνευσης (risk stratification) αποδίδει σημεία δεδομένων σε ομάδες διακινδύνευσης (ή στρώματα) ποσοτικοποιώντας την πρόβλεψη $\hat{h}(\mathbf{x})$ που προκύπτει από ένα εκπαιδευμένο μοντέλο πρόγνωσης διακινδύνευσης. Τυπικές επιλογές για αυτά τα στρώματα περιλαμβάνουν χαμηλή, ενδιάμεση, και υψηλή διακινδύνευση [139], [140].

Βλέπε επίσης: διακινδύνευση, στρωματοποίηση, σημείο δεδομένων, στρώμα, πρόβλεψη, μοντέλο, συσταδοποίηση.

στρώμα Ένα βαθύ δίκτυο είναι ένα ΤΝΔ που αποτελείται από διαδοχικά στρώματα (layers), τα οποία έχουν δείκτες $\ell = 1, 2, \dots, L$. Το ℓ -οστό

στρώμα αποτελείται από τεχνητούς νευρώνες $a_1^{(\ell)}, \dots, a_{d^{(\ell)}}^{(\ell)}$ με πλάτος στρώματος $d^{(\ell)}$. Καθένας από τους τεχνητούς νευρώνες αξιολογεί μία συνάρτηση ενεργοποίησης για ένα σταθμισμένο άθροισμα των εξόδων (ή ενεργοποιήσεων) του προηγούμενου στρώματος $\ell - 1$. Η είσοδος στο στρώμα $\ell = 1$ σχηματίζεται από σταθμισμένα αθροίσματα των χαρακτηριστικών του σημείου δεδομένων για το οποίο το βαθύ δίκτυο υπολογίζει μία πρόβλεψη. Οι εξοδοί των νευρώνων στο στρώμα ℓ χρησιμοποιούνται στη συνέχεια για να σχηματίσουν τις εισόδους των νευρώνων στο επόμενο στρώμα. Το τελικό στρώμα (εξόδου) αποτελείται από έναν μοναδικό νευρώνα του οποίου η έξοδος χρησιμοποιείται ως η πρόβλεψη που παραδίδεται από το βαθύ δίκτυο.

Βλέπε επίσης: βαθύ δίκτυο, ΤΝΔ, τεχνητός νευρώνας, συνάρτηση ενεργοποίησης, έξοδος, ενεργοποίηση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, νευρώνας.

στρώμα Ένα στρώμα (stratum) είναι ένα υποσύνολο σημείων δεδομένων που όλα μοιράζονται μία κοινή ιδιότητα (η οποία θα μπορούσε να είναι ένα χαρακτηριστικό ή μία ετικέτα). Για παράδειγμα, σε ένα σύνολο δεδομένων καιρού, όλες οι μετρήσεις από τον ίδιο μετεωρολογικό σταθμό του Φινλανδικού Μετεωρολογικού Ινστιτούτου αποτελούν ένα στρώμα.

Παράδειγμα (απόσπασμα CSV):

χρόνος, σταθμός, τιμή, μονάδα

2023-06-01 12:00, Ελσίνκι, 18.2, βαθμοί Κελσίου

2023-06-01 13:00, Ελσίνκι, 18.5, βαθμοί Κελσίου

2023-06-01 14:00, Ελσίνκι, 19.0, βαθμοί Κελσίου

2023-06-01 12:00, Όουλου, 12.1, βαθμοί Κελσίου
 2023-06-01 13:00, Όουλου, 12.4, βαθμοί Κελσίου
 2023-06-01 14:00, Όουλου, 12.7, βαθμοί Κελσίου
 2023-06-01 12:00, Τάμπερε, 15.3, βαθμοί Κελσίου
 2023-06-01 13:00, Τάμπερε, 15.6, βαθμοί Κελσίου
 2023-06-01 14:00, Τάμπερε, 16.0, βαθμοί Κελσίου

Εδώ οι γραμμές για κάθε σταθμό (δηλαδή Ελσίνκι, Όουλου, Τάμπερε) αναπαριστούν διαφορετικά στρώματα.

Βλέπε επίσης: σημείο δεδομένων, χαρακτηριστικό, ετικέτα, σύνολο δεδομένων, Φινλανδικό Μετεωρολογικό Ινστιτούτο, στρωματοποίηση.


συμμεταβλητή Βλέπε χαρακτηριστικό.

συνάρτηση απώλειας Μία συνάρτηση απώλειας (loss function) είναι μία απεικόνιση

$$L : \mathcal{X} \times \mathcal{Y} \times \mathcal{H} \rightarrow \mathbb{R}_+ : ((\mathbf{x}, y), h) \mapsto L((\mathbf{x}, y), h).$$

Αποδίδει έναν μη αρνητικό πραγματικό αριθμό (δηλαδή την απώλεια) $L((\mathbf{x}, y), h)$ σε ένα ζεύγος που αποτελείται από ένα σημείο δεδομένων, με χαρακτηριστικά $\mathbf{x}$ και ετικέτα y , και μία υπόθεση $h \in \mathcal{H}$. Η τιμή $L((\mathbf{x}, y), h)$ ποσοτικοποιεί την απόκλιση μεταξύ της αληθούς ετικέτας y και της πρόβλεψης $h(\mathbf{x})$. Χαμηλότερες (πιο κοντά στο μηδέν) τιμές $L((\mathbf{x}, y), h)$ υποδεικνύουν μία μικρότερη απόκλιση μεταξύ της πρόβλεψης $h(\mathbf{x})$ και της ετικέτας y . Το Σχ. 73 απεικονίζει μία συνάρτηση απώλειας για ένα συγκεκριμένο σημείο δεδομένων, με χαρακτηριστικά $\mathbf{x}$ και ετικέτα

y , ως μία συνάρτηση της υπόθεσης $h \in \mathcal{H}$.




Σχ. 73. Κάποια συνάρτηση απώλειας $L((\mathbf{x}, y), h)$ για ένα σταθερό σημείο δεδομένων, με διάνυσμα χαρακτηριστικών $\mathbf{x}$ και ετικέτα y , και μία μεταβαλλόμενη υπόθεση h . Οι μέθοδοι μηχανικής μάθησης προσπαθούν να βρουν (ή να μάθουν) μία υπόθεση που προκαλεί ελάχιστη απώλεια.

Βλέπε επίσης: απώλεια, συνάρτηση, απεικόνιση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, υπόθεση, πρόβλεψη, διάνυσμα χαρακτηριστικών, μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης.

συνάρτηση ενεργοποίησης Σε κάθε τεχνητό νευρώνα εντός ενός ΤΝΔ αποδίδεται μία συνάρτηση ενεργοποίησης (activation function) $\sigma(\cdot)$ που αντιστοιχίζει έναν σταθμισμένο συνδυασμό των εισόδων του νευρώνα $x_1, \dots, x_d$ σε μία μοναδική τιμή εξόδου $a = \sigma(w_1x_1 + \dots + w_dx_d)$. Σημείωση ότι κάθε νευρώνας παραμετροποιείται από τα βάρη $w_1, \dots, w_d$. Βλέπε επίσης: τεχνητός νευρώνας, ΤΝΔ, ενεργοποίηση, συνάρτηση, νευρώνας, έξοδος, βάρος.

συνθήκη μηδενικής κλίσης Θεωρούμε το πρόβλημα βελτιστοποίησης χωρίς περιορισμούς $\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w})$ με μία λεία και κυρτή αντικειμενική συνάρτηση $f(\mathbf{w})$. Μία αναγκαία και επαρκής συνθήκη για να λύσει ένα

διάνυσμα $\hat{\mathbf{w}} \in \mathbb{R}^d$ αυτό το πρόβλημα είναι η κλίση $\nabla f(\hat{\mathbf{w}})$ να είναι το μηδενικό διάνυσμα $\nabla f(\hat{\mathbf{w}}) = \mathbf{0}$ (βλέπε Σχ. 74).



Σχ. 74. Ένα διάνυσμα $\hat{\mathbf{w}}$ λύνει το πρόβλημα βελτιστοποίησης αν η κλίση ικανοποιεί $\nabla f(\hat{\mathbf{w}}) = \mathbf{0}$.

Με άλλα λόγια [36, σελ. 140],

$$\nabla f(\hat{\mathbf{w}}) = \mathbf{0} \Leftrightarrow f(\hat{\mathbf{w}}) = \min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}).$$

Ορίζοντας τον τελεστή κλίσης $\nabla f : \mathbb{R}^d \rightarrow \mathbb{R}^d$, μπορούμε να ξαναγράψουμε τη συνθήκη μηδενικής κλίσης (zero-gradient condition) ως μία εξίσωση σταθερού σημείου:


$$(\mathcal{I} - \alpha \nabla f) \hat{\mathbf{w}} = \hat{\mathbf{w}}.$$

Εδώ $\mathcal{I}$ δηλώνει τον ταυτοτικό τελεστή (δηλαδή $\mathcal{I}(\mathbf{w}) = \mathbf{w}$) και α είναι ένας αυθαίρετος θετικός αριθμός.

Βλέπε επίσης: πρόβλημα βελτιστοποίησης, λεία, κυρτό, αντικειμενική συνάρτηση, διάνυσμα, κλίση, τελεστής, εξίσωση σταθερού σημείου.

σύνολο Μία μέθοδος συνόλου (ensemble) συνδυάζει πολλαπλές μεθόδους μηχανικής μάθησης, καθεμία από τις οποίες αναφέρεται ως base learner,

ώστε να βελτιώνεται η συνολική επίδοση. Οι base learners μπορούν να είναι βασισμένοι στην ελαχιστοποίηση εμπειρικής διακινδύνευσης, χρησιμοποιώντας διαφορετικές επιλογές ως προς την απώλεια, το μοντέλο, και το σύνολο εκπαίδευσης. Συνανθροίζοντας τις προβλέψεις των base learners, οι μέθοδοι συνόλου μπορούν συχνά να επιτύχουν καλύτερη επίδοση από οποιονδήποτε μοναδικό base learner. Η συνάνθροιση μπορεί να ισοδυναμεί με τον μέσο όρο των προβλέψεων των base learners (στην παλινδρόμηση) ή με τη χρήση ψήφου πλειοψηφίας (σε μεθόδους ταξινόμησης).



Σχ. 75. Ένα γενικό σύνολο με τρεις βασικές μαθητρες, με τον καθένα να χρησιμοποιεί ελαχιστοποίηση εμπειρικής διακινδύνευσης για να μάθει $\mathcal{H}^{(j)} \in \mathcal{H}^{(j)}$ με βάση το σύνολο εκπαίδευσης $\tilde{\mathcal{D}}^{(j)}$. Ένας βασικός μαθητής μπορεί επίσης να χρησιμοποιεί την έξοδο άλλων βασικών μαθητρες. Η τελική υπόθεση $\hat{h}$ προκύπτει από τη συνάνθροιση των υποθέσεων που παράγονται από τους βασικούς μαθητρες.

Διαφορετικές μέθοδοι συνόλου χρησιμοποιούν διαφορετικές κατασκευές για τους base learners. Για παράδειγμα, οι μέθοδοι bagging (όπως ένα τυχαίο δάσος) χρησιμοποιούν τυχαία δειγματοληψία για να κατασκευάσουν

ελαφρώς διαφορετικά σύνολα εκπαίδευσης για κάθε base learner. Από την άλλη, οι μέθοδοι boosting εκτελούν τους base learners ακολουθιακά, δηλαδή κάθε base learner προσπαθεί να διορθώσει τα σφάλματα πρόβλεψης των προηγούμενων. Μία τρίτη οικογένεια μεθόδων συνόλου είναι η στοίβαξη, όπου οι base learners εκπαιδεύονται στο ίδιο σύνολο εκπαίδευσης αλλά με διαφορετικά μοντέλα.

Βλέπε επίσης: μηχανική μάθηση, base learner, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια, μοντέλο, σύνολο εκπαίδευσης, πρόβλεψη, παλινδρόμηση, ταξινόμηση, έξοδος, υπόθεση, bagging, τυχαίο δάσος, boosting, στοίβαξη.

σύνολο δεδομένων Ένα σύνολο δεδομένων (dataset) είναι ένα σύνολο διακριτών σημείων δεδομένων. Αυστηρά μιλώντας, ένα σύνολο δεδομένων είναι μία μη διατεταγμένη συλλογή σημείων δεδομένων που δεν περιέχει επαναλήψεις. Ωστόσο, στη βιβλιογραφία της μηχανικής μάθησης ο όρος σύνολο δεδομένων χρησιμοποιείται συχνά ως συνώνυμο του δείγματος, δηλαδή ως μία ακολουθία (ή πεπερασμένη λίστα) σημείων δεδομένων που μπορεί να περιέχει επαναλήψεις. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν σύνολα δεδομένων για την εκπαίδευση και επικύρωση μοντέλων. Η έννοια του συνόλου δεδομένων είναι πολύ ευρεία, δηλαδή τα σημεία δεδομένων μπορεί να αναπαριστούν συγκεκριμένες φυσικές οντότητες (όπως άνθρωποι ή ζώα) ή αφηρημένα αντικείμενα (όπως αριθμοί). Για λόγους παραδείγματος, το Σχ. 76 απεικονίζει ένα σύνολο δεδομένων του οποίου τα σημεία δεδομένων είναι αγελάδες.



Σχ. 76. Κοπάδι αγελάδων κάπου στις Άλπεις.

Αρκετά συχνά, ένας μηχανικός μηχανικής μάθησης δεν έχει άμεση πρόσβαση στο υποκείμενο σύνολο δεδομένων. Για παράδειγμα, η πρόσβαση στο σύνολο δεδομένων στο Σχ. 76 θα απαιτούσε να επισκεφτούμε το κοπάδι αγελάδων. Στην πράξη, εργαζόμαστε με μία βολική αναπαράσταση (ή προσέγγιση) του συνόλου δεδομένων. Διαφορετικά μαθηματικά μοντέλα έχουν αναπτυχθεί για αυτόν τον σκοπό [141], [142], [143], [144]. Ένα από τα πιο ευρέως χρησιμοποιούμενα είναι το σχεσιακό μοντέλο, το οποίο οργανώνει δεδομένα σε μορφή πίνακα (ή σχέσης) [141], [145]. Ένας πίνακας αποτελείται από γραμμές και στήλες, όπου κάθε γραμμή αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και κάθε στήλη αναπαριστά ένα συγκεκριμένο ιδιοχαρακτηριστικό ενός σημείου δεδομένων. Οι μέθοδοι μηχανικής μάθησης συνήθως ερμηνεύουν αυτά τα ιδιοχαρακτηριστικά ως χαρακτηριστικά ή ως μία ετικέτα ενός σημείου δεδομένων. Για παράδειγμα, ο Πίνακας I δείχνει μία σχεσιακή αναπαράσταση του συνόλου δεδομένων στο Σχ. 76. Στο σχεσιακό μοντέλο, η σειρά των γραμμών δεν έχει σημασία, και κάθε ιδιοχαρακτηριστικό (δηλαδή στήλη) σχετίζεται με ένα πεδίο ορισμού που προσδιορίζει το σύνολο των αποδεκτών τιμών. Σε εφαρμογές μηχανικής μάθησης, αυτά τα πεδία ορισμού ιδιοχαρακτηριστι-

κών αντιστοιχούν στον χώρο χαρακτηριστικών και τον χώρο ετικετών.

ΠΙΝΑΚΑΣ I

ΣΧΕΣΗ (Η ΠΙΝΑΚΑΣ) ΠΟΥ ΑΝΑΠΑΡΙΣΤΑ ΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ ΣΤΟ ΣΧ. 76

Όνομα	Βάρος	Ηλικία	Ύψος	Θερμοκρασία στομαχίου
Zenzi	100	4	100	25
Berta	140	3	130	23
Resi	120	4	120	31

Ενώ το σχεσιακό μοντέλο είναι χρήσιμο για τη μελέτη πολλών εφαρμογών μηχανικής μάθησης, μπορεί να είναι ανεπαρκές όσον αφορά τις απαιτήσεις για αξιόπιστη TN. Σύγχρονες προσεγγίσεις, όπως τα φύλλα δεδομένων για σύνολα δεδομένων, παρέχουν πιο περιεκτικά τεκμήρια, συμπεριλαμβανομένων λεπτομερειών για τη διαδικασία συλλογής των δεδομένων, την επιθυμητή χρήση, και άλλες πληροφορίες σχετικά με τα πλαίσιο [146]. Βλέπε επίσης: σημείο δεδομένων, μηχανική μάθηση, δείγμα, ακολουθία, μοντέλο, εκπαίδευση, επικύρωση, σχεσιακό μοντέλο, δεδομένα, χαρακτηριστικό, ετικέτα, πεδίο ορισμού, χώρος χαρακτηριστικών, χώρος ετικετών, αξιόπιστη TN.

σύνολο εκπαίδευσης Ένα σύνολο εκπαίδευσης (training set) είναι ένα σύνολο δεδομένων $\mathcal{D}$ που αποτελείται από κάποια σημεία δεδομένων που χρησιμοποιούνται στην ελαχιστοποίηση εμπειρικής διακινδύνευσης για τη μάθηση μίας υπόθεσης $\hat{h}$. Η μέση απώλεια της $\hat{h}$ στο σύνολο εκπαίδευσης αναφέρεται ως το σφάλμα εκπαίδευσης. Η σύγκριση του σφάλματος εκπαίδευσης με το σφάλμα επικύρωσης της $\hat{h}$ μας επιτρέπει να διαγνώσουμε τη μέθοδο μηχανικής μάθησης και ενημερώνει για το πώς να βελτιώσουμε το σφάλμα επικύρωσης (π.χ. χρησιμοποιώντας έναν διαφορετικό χώρο

υποθέσεων ή συλλέγοντας περισσότερα σημεία δεδομένων) [8, Ενότητα 6.6].

Βλέπε επίσης: εκπαίδευση, σύνολο δεδομένων, σημείο δεδομένων, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, απώλεια, σφάλμα εκπαίδευσης, σφάλμα επικύρωσης, μηχανική μάθηση, χώρος υποθέσεων.

σύνολο ελέγχου Ένα σύνολο ελέγχου (test set) αναφέρεται σε ένα σύνολο σημείων δεδομένων που δεν έχουν χρησιμοποιηθεί ούτε για την εκπαίδευση ενός μοντέλου (π.χ. μέσω της ελαχιστοποίησης εμπειρικής διακινδύνευσης) ούτε για την επιλογή μεταξύ διαφορετικών μοντέλων σε ένα σύνολο επικύρωσης.

Βλέπε επίσης: σημείο δεδομένων, μοντέλο, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο επικύρωσης.


σύνολο επικύρωσης Ένα σύνολο επικύρωσης (validation set) αναφέρεται σε ένα σύνολο σημείων δεδομένων που χρησιμοποιούνται για την εκτίμηση της διακινδύνευσης μίας υπόθεσης $\hat{h}$ που έχει μαθητευτεί από κάποια μέθοδο μηχανικής μάθησης (π.χ. λύνοντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης). Η μέση απώλεια της $\hat{h}$ στο σύνολο επικύρωσης αναφέρεται ως το σφάλμα επικύρωσης και μπορεί να χρησιμοποιηθεί για τη διάγνωση μίας μεθόδου μηχανικής μάθησης (βλέπε [8, Ενότητα 6.6]). Η σύγκριση μεταξύ του σφάλματος εκπαίδευσης και του σφάλματος επικύρωσης μπορεί να προσφέρει κατευθύνσεις για τη βελτίωση της μεθόδου μηχανικής μάθησης (όπως τη χρήση ενός διαφορετικού χώρου υποθέσεων).

Βλέπε επίσης: επικύρωση, σημείο δεδομένων, διακινδύνευση, υπόθεση,

μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, απώλεια, σφάλμα επικύρωσης, σφάλμα εκπαίδευσης, χώρος υποθέσεων, διασταυρούμενη επικύρωση k -αναδιπλώσεων, LOO-CV.

συσκευή Ο όρος συσκευή (device) αναφέρεται σε ένα φυσικό σύστημα που μπορεί να αποθηκεύει και να επεξεργάζεται δεδομένα. Στο πλαίσιο της μηχανικής μάθησης, ο όρος συνήθως αναφέρεται σε έναν υπολογιστή που μπορεί να διαβάσει σημεία δεδομένων από διαφορετικές πηγές και να τα χρησιμοποιήσει για να εκπαιδεύσει ένα μοντέλο μηχανικής μάθησης [147]. Βλέπε επίσης: δεδομένα, μηχανική μάθηση, σημείο δεδομένων, μοντέλο.

συστάδα Μία συστάδα (cluster) είναι ένα υποσύνολο σημείων δεδομένων που είναι πιο όμοια μεταξύ τους παρά με τα σημεία δεδομένων εκτός της συστάδας. Το ποσοτικό μέτρο της ομοιότητας μεταξύ σημείων δεδομένων είναι μία επιλογή σχεδιασμού. Αν τα σημεία δεδομένων χαρακτηρίζονται από Ευκλείδεια διανύσματα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^d$, μπορούμε να ορίσουμε την ομοιότητα μεταξύ δύο σημείων δεδομένων μέσω της Ευκλείδειας απόστασης μεταξύ των διανυσμάτων χαρακτηριστικών τους. Ένα παράδειγμα τέτοιων συστάδων παρουσιάζεται στο Σχ. 77.



Σχ. 77. Εικονογράφηση τριών συστάδων σε έναν 2-D χώρο χαρακτηριστικών. Κάθε συστάδα ομαδοποιεί σημεία δεδομένων που είναι πιο όμοια μεταξύ τους παρά με αυτά σε άλλες συστάδες με βάση την Ευκλείδεια απόσταση.

Βλέπε επίσης: σημείο δεδομένων, μέτρο, διάνυσμα χαρακτηριστικών, Ευκλείδεια απόσταση, χώρος χαρακτηριστικών.

συσταδοποίηση Οι μέθοδοι συσταδοποίησης (clustering) διαμερίζουν ένα δεδομένο σύνολο σημείων δεδομένων σε μερικά υποσύνολα, τα οποία αναφέρονται ως συστάδες. Κάθε συστάδα αποτελείται από σημεία δεδομένων που είναι πιο όμοια μεταξύ τους παρά με σημεία δεδομένων εκτός της συστάδας. Διαφορετικές μέθοδοι συσταδοποίησης χρησιμοποιούν διαφορετικά μέτρα για την ομοιότητα μεταξύ σημείων δεδομένων και διαφορετικές μορφές αναπαράστασης συστάδων. Η μέθοδος συσταδοποίησης του αλ-

γόριθμος k -μέσων χρησιμοποιεί το μέσο διάνυσμα χαρακτηριστικών μίας συστάδας (δηλαδή τη μέση τιμή της συστάδας) ως τον αντιπρόσωπό της. Μία δημοφιλής μέθοδος μαλακής συσταδοποίησης βασισμένη σε Γκαουσιανό μοντέλο μείγματος αναπαριστά μία συστάδα από μία πολυμεταβλητή κανονική κατανομή.

Βλέπε επίσης: σημείο δεδομένων, συστάδα, μέτρο, αλγόριθμος k -μέσων, διάνυσμα χαρακτηριστικών, μέση τιμή, μαλακή συσταδοποίηση, Γκαουσιανό μοντέλο μείγματος, πολυμεταβλητή κανονική κατανομή.

συσταδοποίηση γράφου Η συσταδοποίηση γράφου (graph clustering)

στοχεύει να συσταδοποιήσει σημεία δεδομένων που αναπαριστώνται ως οι κόμβοι ενός γράφου $\mathcal{G}$. Οι ακμές του $\mathcal{G}$ αναπαριστούν κατά ζεύγη ομοιότητες μεταξύ σημείων δεδομένων. Κάποιες φορές μπορούμε να ποσοτικοποιήσουμε τον βαθμό αυτών των ομοιοτήτων μέσω ενός βάρους ακμής [55], [148].

Βλέπε επίσης: γράφος, συσταδοποίηση, σημείο δεδομένων, βάρος ακμής.

συσταδοποίηση με βάση τη ροή Η συσταδοποίηση με βάση τη ροή (flow-

based clustering) ομαδοποιεί τους κόμβους ενός μη κατευθυνόμενου γράφου με την εφαρμογή συσταδοποίησης αλγόριθμου k -μέσων σε διανύσματα χαρακτηριστικών από άποψη κόμβων. Αυτά τα διανύσματα χαρακτηριστικών κατασκευάζονται από ροές δικτύου μεταξύ προσεκτικά επιλεγμένων πηγών και κόμβων προορισμού [148].

Βλέπε επίσης: συσταδοποίηση, μη κατευθυνόμενος γράφος, αλγόριθμος k -μέσων, διάνυσμα χαρακτηριστικών.

σφάλμα εκπαίδευσης Το σφάλμα εκπαίδευσης (training error) είναι η μέση

απώλεια μίας υπόθεσης όταν προβλέπει τις ετικέτες των σημείων δεδομένων σε ένα σύνολο εκπαίδευσης. Κάποιες φορές αναφερόμαστε στο σφάλμα εκπαίδευσης και ως την ελάχιστη μέση απώλεια που επιτυγχάνεται από μία λύση της ελαχιστοποίησης εμπειρικής διακινδύνευσης.

Βλέπε επίσης: εκπαίδευση, απώλεια, υπόθεση, ετικέτα, σημείο δεδομένων, σύνολο εκπαίδευσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης.


σφάλμα εκτίμησης Θεωρούμε σημεία δεδομένων, καθένα με διάνυσμα χαρακτηριστικών $\mathbf{x}$ και ετικέτα y . Σε κάποιες εφαρμογές, μπορούμε να μοντελοποιήσουμε τη σχέση μεταξύ του διανύσματος χαρακτηριστικών και της ετικέτας ενός σημείου δεδομένων ως $y = \bar{h}(\mathbf{x}) + \varepsilon$. Εδώ χρησιμοποιούμε κάποια αληθή υποκείμενη υπόθεση $\bar{h}$ και έναν όρο θορύβου ε , ο οποίος συνοψίζει οποιαδήποτε σφάλματα μοντελοποίησης ή ετικετοποίησης. Το σφάλμα εκτίμησης (estimation error) που προκαλείται από μία μέθοδο μηχανικής μάθησης που μαθαίνει μία υπόθεση $\hat{h}$, π.χ. χρησιμοποιώντας την ελαχιστοποίηση εμπειρικής διακινδύνευσης, ορίζεται ως $\hat{h}(\mathbf{x}) - \bar{h}(\mathbf{x})$ για κάποιο διάνυσμα χαρακτηριστικών. Για έναν παραμετρικό χώρο υποθέσεων, ο οποίος αποτελείται από απεικονίσεις υπόθεσης καθορισμένες από παραμέτρους του μοντέλου $\mathbf{w}$, μπορούμε να ορίσουμε το σφάλμα εκτίμησης ως $\Delta \mathbf{w} = \hat{\mathbf{w}} - \bar{\mathbf{w}}$ [75], [21].

Βλέπε επίσης: σημείο δεδομένων, διάνυσμα χαρακτηριστικών, ετικέτα, υπόθεση, μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, χώρος υποθέσεων, απεικόνιση, παράμετρος μοντέλου.

σφάλμα επικύρωσης Θεωρούμε μία υπόθεση $\hat{h}$ που προκύπτει από κάποια μέθοδο μηχανικής μάθησης, π.χ. χρησιμοποιώντας την ελαχιστοποίηση

εμπειρικής διακινδύνευσης σε ένα σύνολο εκπαίδευσης. Η μέση απώλεια της $\hat{h}$ σε ένα σύνολο επικύρωσης, το οποίο είναι διαφορετικό από το σύνολο εκπαίδευσης, αναφέρεται ως το σφάλμα επικύρωσης (validation error). Βλέπε επίσης: υπόθεση, μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, απώλεια, σύνολο επικύρωσης, επικύρωση.

σφάλμα συσταδοποίησης Θεωρούμε μία μέθοδο συσταδοποίησης που αναλύει ένα συγκεκριμένο σύνολο δεδομένων σε συστάδες. Το σφάλμα συσταδοποίησης (clustering error) είναι ένα ποσοτικό μέτρο της χρησιμότητας των συστάδων. Διαφορετικές μέθοδοι συσταδοποίησης χρησιμοποιούν διαφορετικές επιλογές για το σφάλμα συσταδοποίησης. Για παράδειγμα, η σκληρής συσταδοποίησης μέθοδος του αλγόριθμου k -μέσων μετράει το σφάλμα συσταδοποίησης μέσω της μέσης τετραγωνικής Ευκλείδειας απόστασης μεταξύ του διανύσματος χαρακτηριστικών ενός σημείου δεδομένων και του πλησιέστερου κέντρου βάρους συστάδας (βλέπε Σχ. 78). Μία άλλη κατασκευή για το σφάλμα συσταδοποίησης μπορεί να βασίζεται σε ένα πιθανοτικό μοντέλο, όπως το Γκαουσιανό μοντέλο μείγματος, όπου τα κέντρα βάρους συστάδων είναι παράμετροι της υποκείμενης κατανομής πιθανότητας.



Σχ. 78. Για σημεία δεδομένων με αριθμητικά διανύσματα χαρακτηριστικών, μπορούμε να χρησιμοποιήσουμε τη μέση τετραγωνική Ευκλείδεια απόσταση από τα πλησιέστερα κέντρα βάρους συστάδων ως ένα μέτρο του σφάλματος συσταδοποίησης.

Βλέπε επίσης: συσταδοποίηση, σύνολο δεδομένων, συστάδα, μέτρο, σκληρή συσταδοποίηση, αλγόριθμος k -μέσων, Ευκλείδεια απόσταση, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, κέντρο βάρους συστάδας, πιθανοτικό μοντέλο, Γκαουσιανό μοντέλο μείγματος, παράμετρος, κατανομή πιθανότητας, μέγιστη πιθανοφάνεια.

σχεσιακό μοντέλο Ένα σχεσιακό μοντέλο (relational model) είναι μία μαθηματική αναπαράσταση δεδομένων. Η βασική ιδέα είναι η οργάνωση των δεδομένων ως μία συλλογή πινάκων (ή σχέσεων) [141], [145]. Ένας πίνακας αποτελείται από γραμμές και στήλες, όπου κάθε γραμμή αντιστοιχεί σε ένα μοναδικό σημείο δεδομένων, και κάθε στήλη αναπαριστά ένα συγκεκριμένο ιδιοχαρακτηριστικό ενός σημείου δεδομένων. Οι μέθοδοι μηχανικής μάθησης χρησιμοποιούν αυτά τα ιδιοχαρακτηριστικά ως χαρακτηριστικά και ετικέτα ενός σημείου δεδομένων. Ο Πίνακας II δείχνει μία σχεσιακή αναπαράσταση ενός συνόλου δεδομένων που αποτελείται από αγελάδες. Στο σχεσιακό μοντέλο, η σειρά των γραμμών είναι αδιάφορη, και κάθε ιδιοχαρακτηριστικό (δηλαδή στήλη) σχετίζεται με ένα πεδίο ορισμού που προσδιορίζει το σύνολο των αποδεκτών τιμών. Στις εφαρ-

μογές μηχανικής μάθησης, αυτά τα πεδία ορισμού ιδιοχαρακτηριστικών αντιστοιχούν στον χώρο χαρακτηριστικών και τον χώρο ετικετών.

ΠΙΝΑΚΑΣ II

ΣΧΕΣΗ (Η ΠΙΝΑΚΑΣ) ΠΟΥ ΑΝΑΠΑΡΙΣΤΑ ΤΟ ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ ΣΤΟ ΣΧ. 76

Όνομα	Βάρος	Ηλικία	Ύψος	Θερμοκρασία στομαχίου
Zenzi	100	4	100	25
Berta	140	3	130	23
Resi	120	4	120	31

Βλέπε επίσης: μοντέλο, δεδομένα, σημείο δεδομένων, μηχανική μάθηση, χαρακτηριστικό, ετικέτα, σύνολο δεδομένων, πεδίο ορισμού, χώρος χαρακτηριστικών, χώρος ετικετών.

ταξινόμηση Η ταξινόμηση (classification) είναι μία εργασία καθορισμού μίας ετικέτας διακριτής τιμής y για ένα δεδομένο σημείο δεδομένων, με βάση μόνο τα χαρακτηριστικά του $\mathbf{x}$. Η ετικέτα y ανήκει σε ένα πεπερασμένο σύνολο, όπως $y \in \{-1, 1\}$ ή $y \in \{1, \dots, 19\}$, και αναπαριστά την κατηγορία στην οποία ανήκει το αντίστοιχο σημείο δεδομένων.

Βλέπε επίσης: ετικέτα, σημείο δεδομένων, χαρακτηριστικό.

ταξινόμηση πολλαπλών ετικετών Τα προβλήματα και οι μέθοδοι ταξινόμησης πολλαπλών ετικετών (multi-label classification) χρησιμοποιούν σημεία δεδομένων που χαρακτηρίζονται από αρκετές ετικέτες. Ως παράδειγμα, ας θεωρήσουμε ένα σημείο δεδομένων που αντιπροσωπεύει μία εικόνα με δύο ετικέτες. Η μία ετικέτα υποδηλώνει την παρουσία ενός ανθρώπου σε αυτήν την εικόνα και η άλλη ετικέτα υποδηλώνει την παρουσία ενός αυτοκινήτου.

Βλέπε επίσης: ετικέτα, ταξινόμηση, σημείο δεδομένων.

ταξινομητής Ένας ταξινομητής (classifier) είναι μία υπόθεση (δηλαδή μία απεικόνιση) $h(\mathbf{x})$ που χρησιμοποιείται για να προβλεφθεί μία ετικέτα που παίρνει τιμές από ένα πεπερασμένο χώρο ετικετών. Μπορεί να χρησιμοποιήσουμε την ίδια την τιμή συνάρτησης $h(\mathbf{x})$ ως μία πρόβλεψη $\hat{y}$ για την ετικέτα. Ωστόσο, είναι σύνηθες να χρησιμοποιούμε μία απεικόνιση $h(\cdot)$ που παραδίδει μία αριθμητική ποσότητα. Η πρόβλεψη τότε προκύπτει από ένα απλό βήμα κατωφλιού. Για παράδειγμα, σε ένα πρόβλημα δυαδικής ταξινόμησης με έναν χώρο ετικετών $\mathcal{Y} \in \{-1, 1\}$, μπορεί να χρησιμοποιήσουμε μία απεικόνιση υπόθεσης πραγματικής τιμής $h(\mathbf{x}) \in \mathbb{R}$ ως ταξινομητή. Μία πρόβλεψη $\hat{y}$ μπορεί έπειτα να προκύψει μέσω κατωφλιού,

$$\hat{y} = 1 \quad \text{για } h(\mathbf{x}) \geq 0 \quad \text{και} \quad \hat{y} = -1 \quad \text{διαφορετικά.} \quad (7)$$

Μπορούμε να χαρακτηρίσουμε έναν ταξινομητή από τις περιοχές αποφάσεών του $\mathcal{R}_a$ για κάθε πιθανή τιμή ετικέτας $a \in \mathcal{Y}$.

Βλέπε επίσης: υπόθεση, απεικόνιση, ετικέτα, χώρος ετικετών, συνάρτηση, πρόβλεψη, ταξινόμηση, περιοχή αποφάσεων.

τεχμαρτή εγγραφή Βλέπε missing data.

τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής (least absolute shrinkage and selection operator - Lasso) είναι μία περίπτωση εξηγήσιμης ελαχιστοποίησης εμπειρικής διακινδύνευσης [75]. Μαθαίνει τα βάρη $\mathbf{w}$ μίας γραμμικής απεικόνισης $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ από ένα σύνολο εκπαίδευσης.

Ο τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής προκαλείται από γραμμική παλινδρόμηση προσθέτοντας την ανηγμένη ℓ_1 -νόρμα $\alpha\|\mathbf{w}\|_1$ στη μέση απώλεια τετραγωνικού σφάλματος που προκύπτει στο σύνολο εκπαίδευσης [149]. Η χρήση της ℓ_1 -νόρμας ως ομαλοποιητή, αντί της τετραγωνικής ℓ_2 -νόρμας που χρησιμοποιείται στην αμφικλινή παλινδρόμηση, ενθαρρύνει τα βάρη που έχουν μαθευτεί να έχουν πολλές καταχωρίσεις ίσες με μηδέν [23], [115].

Βλέπε επίσης: εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης, βάρος, γραμμική απεικόνιση, σύνολο εκπαίδευσης, γραμμική παλινδρόμηση, νόρμα, απώλεια τετραγωνικού σφάλματος, ομαλοποιητής, αμφικλινής παλινδρόμηση.

τετραγωνική συνάρτηση Μία τετραγωνική συνάρτηση (quadratic function) είναι μία συνάρτηση $f : \mathbb{R}^d \rightarrow \mathbb{R}$ της ακόλουθης μορφής:

$$f(\mathbf{w}) = \mathbf{w}^T \mathbf{Q} \mathbf{w} + \mathbf{q}^T \mathbf{w} + a$$

με κάποιον πίνακα $\mathbf{Q} \in \mathbb{R}^{d \times d}$, διάνυσμα $\mathbf{q} \in \mathbb{R}^d$, και βαθμωτό $a \in \mathbb{R}$.


Βλέπε επίσης: συνάρτηση, πίνακας, διάνυσμα.

τεχνητή νοημοσύνη (TN) Η TN (artificial intelligence - AI) αναφέρεται σε συστήματα που συμπεριφέρονται λογικά, με την έννοια της μεγιστοποίησης μίας μακροπρόθεσμης ανταμοιβής. Η προσέγγιση στην TN με βάση τη μηχανική μάθηση είναι να εκπαιδευτεί ένα μοντέλο για να προβλέπει βέλτιστες ενέργειες. Αυτές οι προβλέψεις υπολογίζονται από παρατηρήσεις σχετικά με την κατάσταση του περιβάλλοντος. Η επιλογή της συνάρτησης απώλειας διαφοροποιεί τις εφαρμογές TN από πιο βασικές εφαρ-

μογές μηχανικής μάθησης. Τα συστήματα TN σπάνια έχουν πρόσβαση σε ένα σύνολο εκπαίδευσης με ετικέτες που να επιτρέπει τη μέτρηση της μέσης απώλειας για οποιαδήποτε πιθανή επιλογή παραμέτρων μοντέλου. Αντίθετα, τα συστήματα TN χρησιμοποιούν παρατηρούμενα σήματα ανταμοιβής για να εκτιμήσουν την απώλεια που προκύπτει από την τρέχουσα επιλογή παραμέτρων μοντέλου.

Βλέπε επίσης: ανταμοιβή, μηχανική μάθηση, μοντέλο, πρόβλεψη, κατάσταση, περιβάλλον, συνάρτηση απώλειας, σύστημα τεχνητής νοημοσύνης (σύστημα TN), σύνολο εκπαίδευσης, απώλεια, παράμετρος μοντέλου, ενισχυτική μάθηση.

τεχνητό νευρωνικό δίκτυο (TNΔ) Ένα TNΔ (artificial neural network - ANN) είναι μία γραφική (ροή σήματος) αναπαράσταση μίας υπόθεσης που αντιστοιχίζει τα χαρακτηριστικά ενός σημείου δεδομένων κατά την είσοδό του σε μία πρόβλεψη για την αντίστοιχη ετικέτα κατά την έξοδό του. Η θεμελιώδης υπολογιστική μονάδα ενός TNΔ είναι ο τεχνητός νευρώνας, ο οποίος εφαρμόζει μία συνάρτηση ενεργοποίησης $\sigma(\cdot)$ στο σταθμισμένο άθροισμα των εισόδων του. Η έξοδος ενός νευρώνα μπορεί να χρησιμοποιηθεί είτε ως η τελική έξοδος του TNΔ είτε ως μία είσοδος σε άλλους νευρώνες. Μία βασική διάσταση σχεδιασμού ενός TNΔ είναι η δομή συνδεσιμότητας (ή αρχιτεκτονική) του, δηλαδή ποιοι έξοδοι νευρώνων συνδέονται με ποιες εισόδους άλλων νευρώνων. Όπως απεικονίζεται στο Σχ. 79, μπορούμε να αναπαραστήσουμε ένα TNΔ ως έναν κατευθυνόμενο μη κυκλικό γράφο.



Σχ. 79. Ένα ΤΝΔ μπορεί να αναπαρασταθεί ως ένας σταθμισμένος κατευθυνόμενος μη κυκλικός γράφος με κόμβους που αντιστοιχούν σε νευρώνες ή χαρακτηριστικά ενός σημείου δεδομένων. Τα χαρακτηριστικά μπορούν να θεωρηθούν ως τετριμμένοι νευρώνες χωρίς είσοδο και με μία σταθερή έξοδο που δίνεται από την τιμή του χαρακτηριστικού. Οι σταθμισμένες κατευθυνόμενες ακμές υποδεικνύουν πώς οι έξοδοι των νευρώνων χρησιμοποιούνται ως είσοδοι σε άλλους νευρώνες. Τα βάρη ακμών είναι ρυθμιζόμενες παράμετροι του μοντέλου και χρησιμοποιούνται για την κλιμάκωση των εισόδων στους νευρώνες. Η έξοδος κάποιων νευρώνων χρησιμοποιείται ως η πρόβλεψη $h^{(w)}(\mathbf{x})$.


Ένας ευρέως χρησιμοποιούμενος τύπος ΤΝΔ είναι τα βαθιά δίκτυα όπου οι νευρώνες σχηματίζουν διαδοχικά στρώματα. Σε ένα βαθύ δίκτυο, οι έξοδοι των νευρώνων σε ένα δεδομένο στρώμα συνδέονται συνήθως μόνο με τις εισόδους των νευρώνων σε ένα διαδοχικό στρώμα. Κάποιες φορές είναι χρήσιμο να προστίθενται συνδέσεις παράκαμψης ή skip connections που συνδέουν άμεσα τις εξόδους των νευρώνων σε ένα στρώμα με τις εισόδους των νευρώνων σε ένα μη διαδοχικό στρώμα [60], [150].

Βλέπε επίσης: υπόθεση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα, έξοδος, τεχνητός νευρώνας, συνάρτηση ενεργοποίησης, νευρώνας, κατευθυνόμενος μη κυκλικός γράφος, βάρος ακμής, παράμετρος μοντέλου, βαθύ δίκτυο, στρώμα, skip connection.

τεχνητός νευρώνας Ένας τεχνητός νευρώνας (artificial neuron) είναι το βασικό δομικό στοιχείο ενός ΤΝΔ [60]. Στο πλαίσιο της μηχανικής μάθησης, ένας τεχνητός νευρώνας αναφέρεται συχνά επίσης ως νευρώνας. Ένας νευρώνας εφαρμόζει μία (συνήθως μη γραμμική) συνάρτηση ενεργοποίησης σε ένα σταθμισμένο άθροισμα αριθμητικών τιμών εισόδου. Συγκεκριμένα, ένας νευρώνας με d εισόδους $z_1, \dots, z_d$ υπολογίζει

$$a = \sigma\left(\sum_{j=1}^d w_j z_j + b\right).$$

Εδώ, w_j και b είναι ρυθμιζόμενες παράμετροι μοντέλου που μαθαίνονται κατά την εκπαίδευση του ΤΝΔ. Οι είσοδοι ενός νευρώνα αντιστοιχούν συνήθως σε χαρακτηριστικά ενός σημείου δεδομένων ή στις εξόδους άλλων νευρώνων εντός ενός ΤΝΔ. Η επακόλουθη έξοδος μπορεί να χρησιμεύσει ως είσοδος σε περαιτέρω νευρώνες ή να συνεισφέρει άμεσα στην πρόβλεψη $h^{(w)}(\mathbf{x})$ που παραδίδεται από ένα ΤΝΔ.



Σχ. 80. Τεχνητός νευρώνας ως μία σταθμισμένη μη γραμμική απεικόνιση.

Βλέπε επίσης: ΤΝΔ, μηχανική μάθηση, συνάρτηση ενεργοποίησης, παράμετρος μοντέλου, εκπαίδευση, χαρακτηριστικό, σημείο δεδομένων, έξο-

δος, πρόβλεψη, στρώμα.

τμηματοποίηση εικόνας Η τμηματοποίηση εικόνας (image segmentation)

αναφέρεται στην εργασία της συσταδοποίησης των εικονοστοιχείων μίας εικόνας σε μερικά τμήματα [151], [152]. Κάθε τμήμα είναι ένα υποσύνολο (ή συστάδα) εικονοστοιχείων που είναι όμοια μεταξύ τους ως προς το χρώμα, την υφή, ή άλλες οπτικές ιδιότητες.

Βλέπε επίσης: συσταδοποίηση, συστάδα.

τοπικά σταθμισμένη μάθηση Η τοπικά σταθμισμένη μάθηση (locally

weighted learning - LWL) είναι μία μη παραμετρική μέθοδος μηχανικής μάθησης που πραγματοποιεί προβλέψεις για ένα συγκεκριμένο σημείο δεδομένων $\mathbf{z}$ με βάση έναν σταθμισμένο συνδυασμό των ετικετών των σημείων δεδομένων στο σύνολο εκπαίδευσης. Τα βάρη αντανακλούν την ομοιότητα μεταξύ του σημείου δεδομένων $\mathbf{z}$ και κάθε σημείου δεδομένων στο σύνολο εκπαίδευσης. Μία ευρέως χρησιμοποιούμενη περίπτωση τοπικά σταθμισμένης μάθησης είναι η παλινδρόμηση k -πλησιέστερων γειτόνων [8], [61], [153].

Βλέπε επίσης: μη παραμετρική, μηχανική μάθηση, πρόβλεψη, σημείο δεδομένων, ετικέτα, σύνολο εκπαίδευσης, παλινδρόμηση k -πλησιέστερων γειτόνων.

τοπικό μοντέλο Θεωρούμε μία συλλογή συσκευών που αναπαριστώνται ως

κόμβοι $\mathcal{V}$ ενός δικτύου ομοσπονδιακής μάθησης. Ένα τοπικό μοντέλο (local model) $\mathcal{H}^{(i)}$ είναι ένας χώρος υποθέσεων που αποδίδεται σε έναν κόμβο $i \in \mathcal{V}$. Διαφορετικοί κόμβοι μπορούν να έχουν διαφορετικούς χώρους υποθέσεων, δηλαδή, γενικά, $\mathcal{H}^{(i)} \neq \mathcal{H}^{(i')}$ για διαφορετικούς κόμ-

βους $i, i' \in \mathcal{V}$.

Βλέπε επίσης: συσκευή, δίκτυο ομοσπονδιακής μάθησης, μοντέλο, χώρος υποθέσεων.

τοπικό σύνολο δεδομένων Η έννοια ενός τοπικού συνόλου δεδομένων (local dataset) είναι μεταξύ της έννοιας ενός σημείου δεδομένων και ενός συνόλου δεδομένων. Ένα τοπικό σύνολο δεδομένων αποτελείται από αρκετά μεμονωμένα σημεία δεδομένων που χαρακτηρίζονται από χαρακτηριστικά και ετικέτες. Σε αντίθεση με ένα μονό σύνολο δεδομένων που χρησιμοποιείται σε βασικές μεθόδους μηχανικής μάθησης, ένα τοπικό σύνολο δεδομένων σχετίζεται επίσης με άλλα τοπικά σύνολα δεδομένων μέσω διαφορετικών εννοιών ομοιότητας. Αυτές οι ομοιότητες μπορεί να ανακύψουν από πιθανοτικά μοντέλα ή την υποδομή επικοινωνίας και κωδικοποιούνται στις ακμές ενός δικτύου ομοσπονδιακής μάθησης.

Βλέπε επίσης: σύνολο δεδομένων, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, μηχανική μάθηση, πιθανοτικό μοντέλο, δίκτυο ομοσπονδιακής μάθησης.

τυχαία προβολή TBC.

τυχαίο δάσος Ένα τυχαίο δάσος (random forest) είναι ένα σύνολο διαφορετικών δέντρων αποφάσεων. Καθένα από αυτά τα δέντρα αποφάσεων προκύπτει από την προσαρμογή ενός διαταραγμένου αντιγράφου του αρχικού συνόλου δεδομένων.

Βλέπε επίσης: δέντρο αποφάσεων, σύνολο δεδομένων.

υπερπαράμετρος Μία υπερπαράμετρος (hyperparameter) που σχετίζεται με μία μέθοδο μηχανικής μάθησης είναι μία ποσότητα που χρησιμοποιείται για

την επιλογή ανάμεσα σε μία οικογένεια μοντέλων. Τυπικά παραδείγματα περιλαμβάνουν τον ρυθμό μάθησης που χρησιμοποιείται σε μία μέθοδο με βάση την κλίση, τον αριθμό χαρακτηριστικών που χρησιμοποιούνται σε ένα γραμμικό μοντέλο, ή το μέγιστο βάθος ενός δέντρου αποφάσεων. Η χρησιμότητα μίας συγκεκριμένης υπερπαραμέτρου μπορεί να αξιολογηθεί μέσω επικύρωσης. Όμοια με τη μάθηση (ή ρύθμιση) των παραμέτρων του μοντέλου μέσω ελαχιστοποίησης εμπειρικής διακινδύνευσης σε ένα σύνολο εκπαίδευσης, μπορούμε να μάθουμε (ή να ρυθμίσουμε) υπερπαραμέτρους ελαχιστοποιώντας το σφάλμα επικύρωσης. Συνεπώς, κατά μία έννοια, οι υπερπαραμέτροι είναι παράμετροι μοντέλου υψηλότερου επιπέδου που μαθαίνονται μέσω μίας υψηλότερου επιπέδου μορφής ελαχιστοποίησης εμπειρικής διακινδύνευσης, δηλαδή με την ελαχιστοποίηση του σφάλμα επικύρωσης που προκύπτει από το εκπαιδευμένο μοντέλο με μία δεδομένη τιμή υπερπαραμέτρου.


Βλέπε επίσης: μηχανική μάθηση, μοντέλο, ρυθμός μάθησης, μέθοδος με βάση την κλίση, χαρακτηριστικό, γραμμικό μοντέλο, μέγιστο, δέντρο αποφάσεων, επικύρωση, παράμετρος μοντέλου, ελαχιστοποίηση εμπειρικής διακινδύνευσης, σύνολο εκπαίδευσης, σφάλμα επικύρωσης.

υπερπροσαρμογή Θεωρούμε μία μέθοδο μηχανικής μάθησης που χρησιμοποιεί ελαχιστοποίηση εμπειρικής διακινδύνευσης για να μάθει μία υπόθεση με την ελάχιστη εμπειρική διακινδύνευση σε ένα δεδομένο σύνολο εκπαίδευσης. Μία τέτοια μέθοδος υπερπροσαρμόζει (overfitting) το σύνολο εκπαίδευσης αν μαθαίνει μία υπόθεση με μία εμπειρική διακινδύνευση στο σύνολο εκπαίδευσης που είναι σημαντικά μικρότερη από τη μέση απώλεια εκτός του σύνολο εκπαίδευσης. Με άλλα λόγια, αν μία μέθοδος μηχανικής

νικής μάθησης παρουσιάζει υπερπροσαρμογή, τότε έχει μεγάλο χάσμα γενίκευσης.

Βλέπε επίσης: μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, ελάχιστο, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, απώλεια, χάσμα γενίκευσης, γενίκευση, επικύρωση.

υπόθεση Μία υπόθεση (hypothesis) αναφέρεται σε μία απεικόνιση (ή συνάρτηση) $h : \mathcal{X} \rightarrow \mathcal{Y}$ από τον χώρο χαρακτηριστικών $\mathcal{X}$ στον χώρο ετικετών $\mathcal{Y}$. Δεδομένου ενός σημείου δεδομένων με χαρακτηριστικά $\mathbf{x}$, χρησιμοποιούμε μία απεικόνιση υπόθεσης h για να εκτιμήσουμε (ή να προσεγγίσουμε) την ετικέτα y χρησιμοποιώντας την πρόβλεψη $\hat{y} = h(\mathbf{x})$.



Σχ. 81. Υπόθεση $h : \mathcal{X} \rightarrow \mathcal{Y}$ που αντιστοιχίζει τα χαρακτηριστικά $\mathbf{x} \in \mathcal{X}$ ενός σημείου δεδομένων σε μία πρόβλεψη $h(\mathbf{x}) \in \mathcal{Y}$ της ετικέτας. Για παράδειγμα, η εφαρμογή μηχανικής μάθησης <https://freddiemeter.withyoutube.com/> χρησιμοποιεί τα δείγματα μίας ηχογράφησης ως χαρακτηριστικά για να προβλέψει πόσο πολύ μοιάζει το τραγούδι ενός ατόμου με εκείνο του Freddie Mercury.

Η μηχανική μάθηση αφορά τη μάθηση (ή εύρεση) μίας απεικόνισης υπόθεσης h έτσι ώστε $y \approx h(\mathbf{x})$ για οποιοδήποτε σημείο δεδομένων (με χαρακτηριστικά $\mathbf{x}$ και ετικέτα y). Οι πρακτικές μέθοδοι μηχανικής μάθησης, περιορισμένες από τους πεπερασμένους υπολογιστικούς πόρους, πρέπει να περιορίζουν τη μάθηση σε ένα υποσύνολο όλων των πιθανών απεικονίσεων υπόθεσης. Αυτό το υποσύνολο ονομάζεται ο χώρος υπο-

θέσεων ή απλώς το μοντέλο που αποτελεί τη βάση της μεθόδου.


Βλέπε επίσης: απεικόνιση, συνάρτηση, χώρος χαρακτηριστικών, χώρος ετικετών, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, πρόβλεψη, δείγμα, μηχανική μάθηση, χώρος υποθέσεων, μοντέλο.

υπολογιστική διάσταση Ως υπολογιστικές διαστάσεις (computational aspects) μίας μεθόδου μηχανικής μάθησης, αναφερόμαστε κυρίως στους υπολογιστικούς πόρους που απαιτούνται για την εκτέλεσή της. Για παράδειγμα, αν μία μέθοδος μηχανικής μάθησης χρησιμοποιεί επαναληπτικές τεχνικές βελτιστοποίησης για να λύσει την ελαχιστοποίηση εμπειρικής διακινδύνευσης, τότε οι υπολογιστικές διαστάσεις της περιλαμβάνουν: 1) πόσες αριθμητικές πράξεις χρειάζονται για να εκτελεστεί μία μονή επανάληψη (δηλαδή ένα βήμα κλίσης), και 2) πόσες επαναλήψεις χρειάζονται για να προκύψουν χρήσιμες παράμετροι μοντέλου. Ένα σημαντικό παράδειγμα μίας επαναληπτικής τεχνικής βελτιστοποίησης είναι η κάθοδος κλίσης.

Βλέπε επίσης: μηχανική μάθηση, βελτιστοποίηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, επανάληψη, βήμα κλίσης, παράμετρος μοντέλου, κάθοδος κλίσης.

υποπροσαρμογή Θεωρούμε μία μέθοδο μηχανικής μάθησης που εφαρμόζει την ελαχιστοποίηση εμπειρικής διακινδύνευσης για να μάθει μία υπόθεση που ελαχιστοποιεί την εμπειρική διακινδύνευση σε ένα δεδομένο σύνολο εκπαίδευσης. Η μέθοδος λέγεται ότι παρουσιάζει υποπροσαρμογή (underfitting) αν δεν καταφέρει να επιτύχει μία επαρκώς χαμηλή εμπειρική διακινδύνευση στο σύνολο εκπαίδευσης. Υποπροσαρμογή συνήθως συμβαίνει

όταν το επιλεγμένο μοντέλο είναι υπερβολικά απλό για να αποτυπώσει την υποκείμενη σχέση μεταξύ χαρακτηριστικών και ετικετών.




Σχ. 82. Καμία γραμμική υπόθεση h δεν μπορεί να αποτυπώσει τη σχέση μεταξύ χαρακτηριστικών και ετικετών για το απεικονιζόμενο σύνολο εκπαίδευσης. Συνεπώς, οποιαδήποτε μέθοδος που χρησιμοποιεί ένα γραμμικό μοντέλο θα παρουσιάσει υποπροσαρμογή σε αυτό το σύνολο εκπαίδευσης.

Για παράδειγμα, μία μέθοδος μηχανικής μάθησης που χρησιμοποιεί ένα γραμμικό μοντέλο σε δεδομένα με μία υψηλά μη γραμμική σχέση μεταξύ χαρακτηριστικών και ετικετών δεν θα έχει τη δυνατότητα να μάθει μία υπόθεση με μικρή μέση απώλεια στο σύνολο εκπαίδευσης, πόσο μάλλον με μία χαμηλή διακινδύνευση.

Βλέπε επίσης: μηχανική μάθηση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, εμπειρική διακινδύνευση, σύνολο εκπαίδευσης, μοντέλο, χαρακτηριστικό, ετικέτα, γραμμικό μοντέλο, δεδομένα, απώλεια, διακινδύνευση.

φασματική συσταδοποίηση Η φασματική συσταδοποίηση (spectral clustering) είναι μία συγκεκριμένη περίπτωση συσταδοποίησης γράφου, δηλαδή ομαδοποιεί σημεία δεδομένων που αναπαριστώνται ως οι κόμβοι


$i = 1, \dots, n$ ενός γράφου $\mathcal{G}$. Η φασματική συσταδοποίηση χρησιμοποιεί τα ιδιοδιανύσματα του Λαπλασιανού πίνακα $\mathbf{L}^{(\mathcal{G})}$ για να κατασκευάσει διανύσματα χαρακτηριστικών $\mathbf{x}^{(i)} \in \mathbb{R}^d$ για κάθε κόμβο (δηλαδή για κάθε σημείο δεδομένων) $i = 1, \dots, n$. Μπορούμε να τροφοδοτήσουμε αυτά τα διανύσματα χαρακτηριστικών σε μεθόδους συσταδοποίησης βασισμένες στον Ευκλείδειο χώρο, όπως ο αλγόριθμος k -μέσων ή η μαλακή συσταδοποίηση μέσω Γκαουσιανού μοντέλου μείγματος. Σε γενικές γραμμές, τα διανύσματα χαρακτηριστικών των κόμβων που ανήκουν σε ένα καλά συνδεδεμένο υποσύνολο (ή συστάδα) κόμβων στο $\mathcal{G}$ βρίσκονται κοντά μεταξύ τους στον Ευκλείδειο χώρο $\mathbb{R}^d$ (βλέπε Σχ. 83).



(a)

$$\mathbf{L}^{(\mathcal{G})} = \begin{pmatrix} 2 & -1 & -1 & 0 \\ -1 & 1 & 0 & 0 \\ -1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$$

(b)



(c)

$$\mathbf{V} = (\mathbf{v}^{(1)}, \mathbf{v}^{(2)}, \mathbf{v}^{(3)}, \mathbf{v}^{(4)})$$


$$\mathbf{v}^{(1)} = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}^{(2)} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}$$

(d)

Σχ. 83. (a) Μη κατευθυνόμενος γράφος $\mathcal{G}$ με τέσσερις κόμβους $i = 1, 2, 3, 4$, ο καθένας από τους οποίους αναπαριστά ένα σημείο δεδομένων. (b) Λαπλασιανός πίνακας $\mathbf{L}^{(\mathcal{G})} \in \mathbb{R}^{4 \times 4}$ και η ανάλυση ιδιοτιμών του. (c) Διάγραμμα διασποράς των σημείων δεδομένων που χρησιμοποιούν τα διανύσματα χαρακτηριστικών $\mathbf{x}^{(i)} = (v_i^{(1)}, v_i^{(2)})^T$. (d) Δύο ιδιοδιανύσματα $\mathbf{v}^{(1)}, \mathbf{v}^{(2)} \in \mathbb{R}^d$ που αντιστοιχούν στην ιδιοτιμή $\lambda = 0$ του Λαπλασιανού πίνακα $\mathbf{L}^{(\mathcal{G})}$.

Βλέπε επίσης: συσταδοποίηση, συσταδοποίηση γράφου, σημείο δεδομένων, γράφος, ιδιοδιάνυσμα, Λαπλασιανός πίνακας, διάνυσμα χαρακτηριστικών, Ευκλείδειος χώρος, αλγόριθμος k -μέσων, μαλακή συσταδοποίηση, Γκαουσιανό μοντέλο μείγματος, συστάδα, μη κατευθυνόμενος γράφος, ανάλυση ιδιοτιμών, διάγραμμα διασποράς, ιδιοτιμή.

φασματογράφημα Ένα φασματογράφημα (spectrogram) αναπαριστά τη χρονο-συχνотική κατανομή της ενέργειας ενός χρονικού σήματος $x(t)$. Διαισθητικά, ποσοτικοποιεί το ποσό της ενέργειας του σήματος που υπάρχει σε ένα συγκεκριμένο χρονικό τμήμα $[t_1, t_2] \subseteq \mathbb{R}$ και σε ένα διάστημα συχνοτήτων $[f_1, f_2] \subseteq \mathbb{R}$. Τυπικά, το φασματογράφημα ενός σήματος ορίζεται ως το τετράγωνο του μέτρου του μετασχηματισμού Fourier σύντομου χρόνου (short-time Fourier transform - STFT) αυτού του σήματος [154]. Το Σχ. 84 απεικονίζει ένα χρονικό σήμα μαζί με το φασματογράφημά του.




Σχ. 84. (a) Χρονικό σήμα που αποτελείται από δύο διαμορφωμένους Γκαουσιανούς παλμούς. (b) Διάγραμμα έντασης του φασματογραφήματος.

Το διάγραμμα έντασης του φασματογραφήματος μπορεί να χρησιμεύει ως μία εικόνα του σήματος. Μία απλή προσέγγιση για την ταξινόμηση ηχητικών σημάτων είναι η τροφοδότηση αυτής της εικόνας σήματος σε βαθιά δίκτυα που αρχικά αναπτύχθηκαν για την ταξινόμηση εικόνων και την ανίχνευση αντικειμένων [155]. Αξίζει να σημειωθεί ότι, πέρα από το φασματογράφημα, υπάρχουν αρκετές εναλλακτικές αναπαραστάσεις για τη χρονο-συχνοτική κατανομή της ενέργειας ενός σήματος [156], [157].

Βλέπε επίσης: Γκαουσιανή, ταξινόμηση, βαθύ δίκτυο.

χαρακτηριστικό Ένα χαρακτηριστικό (feature) ενός σημείου δεδομένων είναι μία από τις ιδιότητες που μπορούν να μετρηθούν ή να υπολογιστούν εύκολα χωρίς την ανάγκη ανθρώπινης εποπτείας. Για παράδειγμα, αν ένα σημείο δεδομένων είναι μία ψηφιακή εικόνα (π.χ. αποθηκευμένη ως ένα αρχείο .jpeg), τότε θα μπορούσαμε να χρησιμοποιήσουμε τις εντάσεις κόκκινου-πράσινου-μπλε (red-green-blue - RGB) των εικονοστοιχείων της ως χαρακτηριστικά. Ένα άλλο παράδειγμα παρουσιάζεται στο Σχ. 85, όπου τα δείγματα σήματος ενός ηχητικού σήματος πεπερασμένης διάρκειας χρησιμοποιούνται ως χαρακτηριστικά του.



Σχ. 85. Ένα ηχητικό σήμα (μπλε κυματομορφή) και τα διακριτοποιημένα δείγματα σήματός του (κόκκινες κουκκίδες) που μπορούν να χρησιμοποιηθούν ως χαρακτηριστικά του $x_1, \dots, x_d$.

Συνώνυμα του όρου χαρακτηριστικό που χρησιμοποιούνται ανάλογα με

τον εκάστοτε τομέα είναι «συμμεταβλητή», «εξηγηματική μεταβλητή», «ανεξάρτητη μεταβλητή», «είσοδος (ή μεταβλητή εισόδου)», «προγνωστικός παράγοντας (ή προγνωστική μεταβλητή)», ή «παλινδρομούσα μεταβλητή» [112], [113], [95].

Βλέπε επίσης: σημείο δεδομένων, δείγμα, συμμεταβλητή, προγνωστικός παράγοντας.

χάσμα γενίκευσης Το χάσμα γενίκευσης (generalization gap) είναι η διαφορά μεταξύ της επίδοσης μίας υπόθεσης $h \in \mathcal{H}$ στο σύνολο εκπαίδευσης $\mathcal{D}^{(t)}$ και της επίδοσης σε σημεία δεδομένων εκτός του $\mathcal{D}^{(t)}$. Μπορούμε να κάνουμε αυτή την έννοια ακριβή χρησιμοποιώντας ένα πιθανοτικό μοντέλο που μας επιτρέπει να υπολογίσουμε τη διακινδύνευση (ή την αναμενόμενη απώλεια) $\bar{L}(\hat{h})$ μίας υπόθεσης h .




Fig. 86. Το χάσμα γενίκευσης μπορεί να οριστεί ως η διαφορά μεταξύ της διακινδύνευσης $\bar{L}(h)$ και της μέσης απώλειας (ή εμπειρικής διακινδύνευσης) $\hat{L}(h|\mathcal{D}^{(t)})$ που υπολογίζεται σε ένα σύνολο εκπαίδευσης.

Στην πράξη, η κατανομή πιθανότητας που αποτελεί τη βάση αυτής της προσδοκίας είναι άγνωστη. Συνεπώς, χρειάζεται να εκτιμήσουμε την προσδοκία με βάση παρατηρούμενα σημεία δεδομένων. Οι τεχνικές επικύρωσης χρησιμοποιούν διαφορετικές κατασκευές ενός συνόλου επικύρωσης, το οποίο είναι διαφορετικό από το σύνολο εκπαίδευσης, για να εκτιμήσουν το χάσμα γενίκευσης.

Βλέπε επίσης: γενίκευση, υπόθεση, σύνολο εκπαίδευσης, σημείο δεδομένων, πιθανοτικό μοντέλο, διακινδύνευση, απώλεια, εμπειρική διακινδύνευση, κατανομή πιθανότητας, προσδοκία, επικύρωση, σύνολο επικύρωσης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, συνάρτηση απώλειας.


χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα

Η χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα (density-based spatial clustering of applications with noise - DBSCAN) αναφέρεται σε έναν αλγόριθμο συσταδοποίησης για σημεία δεδομένων που χαρακτηρίζονται από αριθμητικά διανύσματα χαρακτηριστικών. Όπως ο αλγόριθμος k -μέσων και η μαλακή συσταδοποίηση μέσω Γκαουσιανού μοντέλου μείγματος, η χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα επίσης χρησιμοποιεί τις Ευκλείδειες αποστάσεις μεταξύ των διανυσμάτων χαρακτηριστικών για τον προσδιορισμό των συστάδων. Ωστόσο, σε αντίθεση με τον αλγόριθμο k -μέσων και το Γκαουσιανό μοντέλο μείγματος, η χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα χρησιμοποιεί μία διαφορετική έννοια ομοιότητας μεταξύ των σημείων δεδομένων. Η χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα θεωρεί δύο σημεία δεδομένων όμοια αν συνδέονται μέσω μίας ακολουθίας (δηλαδή μίας δια-

δρομής) κοντινών ενδιάμεσων σημείων δεδομένων. Συνεπώς, η χωρική συσταδοποίηση εφαρμογών με θόρυβο με βάση την πυκνότητα μπορεί να θεωρήσει δύο σημεία δεδομένων όμοια (και επομένως ότι ανήκουν στην ίδια συστάδα) ακόμα και αν τα διανύσματα χαρακτηριστικών τους έχουν μεγάλη Ευκλείδεια απόσταση.

Βλέπε επίσης: συσταδοποίηση, αλγόριθμος, σημείο δεδομένων, διάνυσμα χαρακτηριστικών, αλγόριθμος k -μέσων, μαλακή συσταδοποίηση, Γκαουσιανό μοντέλο μείγματος, Ευκλείδεια απόσταση, συστάδα, ακολουθία, γράφος.

χώρος ετικετών Σε μία εφαρμογή μηχανικής μάθησης, κάθε σημείο δεδομένων περιγράφεται από ένα σύνολο χαρακτηριστικών μαζί με μία σχετική ετικέτα. Το σύνολο όλων των αποδεκτών τιμών ετικέτας ονομάζεται χώρος ετικετών (label space) και δηλώνεται με $\mathcal{Y}$. Είναι σημαντικό ότι ο $\mathcal{Y}$ μπορεί να περιλαμβάνει τιμές που δεν εμφανίζονται ως τιμή ετικέτας κανενός παρατηρούμενου σημείου δεδομένων. Σε μεγάλο βαθμό, η επιλογή του $\mathcal{Y}$ είναι επιλογή του μηχανικού μηχανικής μάθησης και εξαρτάται από τη διατύπωση του προβλήματος. Το Σχ. 87 παρουσιάζει κάποια παραδείγματα χώρων ετικετών που χρησιμοποιούνται συχνά σε εφαρμογές μηχανικής μάθησης.




Σχ. 87. Παραδείγματα χώρων ετικετών και οι αντίστοιχοι τύποι μηχανικής μάθησης. (a) Παλινδρόμηση. (b) Παλινδρόμηση πολλαπλών ετικετών. (c) Δυναδική ταξινόμηση. (d) Διατακτική παλινδρόμηση.

Η επιλογή του χώρου ετικετών $\mathcal{Y}$ προσδιορίζει τον τύπο των μεθόδων μηχανικής μάθησης που είναι κατάλληλες για τη συγκεκριμένη εφαρμογή. Οι μέθοδοι παλινδρόμησης χρησιμοποιούν τον $\mathcal{Y} = \mathbb{R}$, ενώ οι μέθοδοι δυναδικής ταξινόμησης χρησιμοποιούν έναν χώρο ετικετών $\mathcal{Y}$ που αποτελείται από δύο διαφορετικά στοιχεία, δηλαδή $|\mathcal{Y}| = 2$. Οι μέθοδοι διατακτικής παλινδρόμησης χρησιμοποιούν ένα πεπερασμένο, διατεταγμένο σύνολο τιμών ετικέτας, π.χ. $\mathcal{Y} = \{1, 2, 3, 4\}$ με τη φυσική διάταξη $1 < 2 < 3 < 4$. Βλέπε επίσης: μηχανική μάθηση, σημείο δεδομένων, χαρακτηριστικό, ετικέτα, παλινδρόμηση, δυναδική ταξινόμηση.

χώρος υποθέσεων Ένας χώρος υποθέσεων (hypothesis space) είναι ένα μαθηματικό μοντέλο που χαρακτηρίζει την ικανότητα μάθησης μίας μεθόδου μηχανικής μάθησης. Ο στόχος μίας τέτοιας μεθόδου είναι να μάθει μία απεικόνιση υπόθεσης που αντιστοιχίζει χαρακτηριστικά ενός σημείου

δεδομένων σε μία πρόβλεψη της ετικέτας του. Δεδομένης μίας πεπερασμένης ποσότητας υπολογιστικών πόρων, μία πρακτική μέθοδος μηχανικής μάθησης εξερευνά συνήθως μόνο ένα περιορισμένο σύνολο όλων των πιθανών απεικονίσεων από τον χώρο χαρακτηριστικών στον χώρο ετικετών. Ένα τέτοιο περιορισμένο σύνολο αναφέρεται ως χώρος υποθέσεων $\mathcal{H}$ που αποτελεί τη βάση της μεθόδου μηχανικής μάθησης (βλέπε Σχ. 88). Για την ανάλυση μίας δεδομένης μεθόδου μηχανικής μάθησης, η επιλογή ενός χώρου υποθέσεων $\mathcal{H}$ δεν είναι μοναδική, δηλαδή οποιοδήποτε υπερσύνολο που περιέχει όλες τις απεικονίσεις που η μέθοδος μπορεί να μάθει αποτελεί επίσης έναν έγκυρο χώρο υποθέσεων.




Σχ. 88. Χώρος υποθέσεων $\mathcal{H}$ μίας μεθόδου μηχανικής μάθησης ως ένα (συνήθως πολύ μικρό) υποσύνολο του (συνήθως πολύ μεγάλου) συνόλου $\mathcal{X}$ όλων των πιθανών απεικονίσεων από τον χώρο χαρακτηριστικών $\mathcal{X}$ στον χώρο ετικετών $\mathcal{Y}$.

Από την άλλη πλευρά, από μηχανική άποψη της μηχανικής μάθησης, ο χώρος υποθέσεων $\mathcal{H}$ είναι μία επιλογή σχεδιασμού για μεθόδους βασισμένες στην ελαχιστοποίηση εμπειρικής διακινδύνευσης. Αυτή η επιλογή σχεδιασμού μπορεί να καθοδηγηθεί από τους διαθέσιμους υπολογιστικούς πόρους και τις στατιστικές διαστάσεις. Για παράδειγμα, αν οι αποδοτικές

πράξεις πινάκων είναι εφικτές και υφίσταται μία κατά προσέγγιση γραμμική σχέση μεταξύ χαρακτηριστικών και ετικετών, ένα γραμμικό μοντέλο μπορεί να αποτελεί μία χρήσιμη επιλογή για τον $\mathcal{H}$.

Βλέπε επίσης: υπόθεση, μοντέλο, μηχανική μάθηση, απεικόνιση, χαρακτηριστικό, σημείο δεδομένων, πρόβλεψη, ετικέτα, χώρος χαρακτηριστικών, χώρος ετικετών, ελαχιστοποίηση εμπειρικής διακινδύνευσης, στατιστική διάσταση, πίνακας, γραμμικό μοντέλο.

χώρος χαρακτηριστικών Ο χώρος χαρακτηριστικών (feature space) μίας δεδομένης εφαρμογής ή μεθόδου μηχανικής μάθησης αποτελείται από όλες τις πιθανές τιμές που μπορεί να πάρει το διάνυσμα χαρακτηριστικών ενός σημείου δεδομένων. Για σημεία δεδομένων που περιγράφονται από έναν σταθερό αριθμό d αριθμητικών χαρακτηριστικών, μία συνήθης επιλογή για τον χώρο χαρακτηριστικών είναι ο Ευκλείδειος χώρος $\mathbb{R}^d$. Ωστόσο, η απλή παρουσία d αριθμητικών χαρακτηριστικών δεν συνεπάγεται ότι ο $\mathbb{R}^d$ είναι η πιο κατάλληλη αναπαράσταση του χώρου χαρακτηριστικών. Πράγματι, τα αριθμητικά χαρακτηριστικά μπορεί να αποδίδονται στα σημεία δεδομένων με έναν σε μεγάλο βαθμό αυθαίρετο ή τυχαίο τρόπο, οδηγώντας στα σημεία δεδομένων που είναι τυχαία διεσπαρμένα σε όλο τον $\mathbb{R}^d$ χωρίς καμία ουσιαστική γεωμετρική δομή. Οι μέθοδοι μάθησης χαρακτηριστικών προσπαθούν να μάθουν έναν μετασχηματισμό των αρχικών (ενδεχομένως μη αριθμητικών) χαρακτηριστικών, ώστε να εξασφαλίζεται μία πιο ουσιαστική διάταξη των σημείων δεδομένων στον $\mathbb{R}^d$. Τρία παραδείγματα χώρων χαρακτηριστικών παρουσιάζονται στο Σχ. 89.



Σχ. 89. Τρεις διαφορετικοί χώροι χαρακτηριστικών. (a) Γραμμικός χώρος $\mathcal{X}^{(1)} = \mathbb{R}$. (b) Φραγμένο κυρτό σύνολο $\mathcal{X}^{(2)} \subseteq \mathbb{R}^2$. (c) Διακριτός χώρος $\mathcal{X}^{(3)}$ του οποίου τα στοιχεία είναι κόμβοι ενός μη κατευθυνόμενου γράφου.

Βλέπε επίσης: χαρακτηριστικό, μηχανική μάθηση, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, Ευκλείδειος χώρος, μάθηση χαρακτηριστικών, κυρτό, μη κατευθυνόμενος γράφος.

adaptive boosting (AdaBoost) TBC.

bagging (or bootstrap aggregation) TBC.

base learner TBC.

boosting TBC.

bootstrap Για την ανάλυση μεθόδων μηχανικής μάθησης, είναι συχνά χρήσιμο να ερμηνεύουμε ένα συγκεκριμένο σύνολο δεδομένων $\mathcal{D} = \{\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(m)}\}$ ως μία συλλογή ανεξάρτητων και ταυτόσημα κατανομημένων τυχαίων μεταβλητών (ή πραγματώσεων ανεξάρτητων και ταυτόσημα κατανομημένων

τυχαίων μεταβλητών) με κοινή κατανομή πιθανότητας $\mathbb{P}$. Στην πράξη, η κατανομή πιθανότητας $\mathbb{P}$ είναι άγνωστη και πρέπει να εκτιμηθεί από το $\mathcal{D}$. Η ιδέα της μεθόδου bootstrap χρησιμοποιεί την εμπειρική κατανομή $\mathbb{P}^{(\mathcal{D})}$ του $\mathcal{D}$ ως έναν εκτιμητή για την $\mathbb{P}$ [75]:

$$\frac{1}{m} |r : \mathbf{z}^{(r)} \in \mathcal{A}| \approx \mathbb{P}(\mathcal{A}).$$

Η επαναλαμβανόμενη δειγματοληψία από την εμπειρική κατανομή, η οποία ισοδυναμεί με δειγματοληψία με επανατοποθέτηση από το $\mathcal{D}$ [158], οδηγεί σε νέα σύνολα δεδομένων $\mathcal{D}^{(1)}, \dots, \mathcal{D}^{(B)}$, καθένα από τα οποία περιέχει m σημεία δεδομένων. Χρησιμοποιούμε τότε καθένα από αυτά τα σύνολα δεδομένων για την εκπαίδευση του μοντέλου (π.χ. μέσω ελαχιστοποίησης εμπειρικής διακινδύνευσης), οδηγώντας στις υποθέσεις $\hat{h}^{(1)}, \dots, \hat{h}^{(B)}$ που έχουν μαθευτεί. Μπορούμε να χρησιμοποιήσουμε αυτές τις υποθέσεις που έχουν μαθευτεί για να εκτιμήσουμε σημαντικά χαρακτηριστικά μίας μεθόδου μηχανικής μάθησης όπως η μεροληψία, η διακύμανση, ή το χάσμα γενίκευσης [75].

Βλέπε επίσης: μηχανική μάθηση, σύνολο δεδομένων, πραγμάτωση, ανεξάρτητες και ταυτόσημα καταταξιμμένες, τυχαία μεταβλητή, κατανομή πιθανότητας, εμπειρική κατανομή, σημείο δεδομένων, μοντέλο, εκπαίδευση, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, μεροληψία, διακύμανση, χάσμα γενίκευσης, ιστόγραμμα.

bootstrap aggregation Βλέπε bagging.

Brier score TBC.

clustered federated learning (CFL) TBC.

concept activation vector (CAV) TBC.

coreset TBC.

early stopping TBC.

epoch TBC.

federated averaging (FedAvg) TBC.

federated gradient descent (FedGD) TBC.

federated proximal (FedProx) TBC.

FedRelax TBC.

federated stochastic gradient descent (FedSGD) TBC.

gradient boosting TBC.

local interpretable model-agnostic explanations (LIME) TBC.

leave-one-out cross-validation (LOO-CV) TBC.

missing data TBC.

multilayer perceptron (MLP) TBC.

nested cross-validation (nested CV) TBC.

network Lasso TBC.

online gradient descent (online GD) TBC.

perceptron TBC.

perplexity TBC.

Q-μάθηση Η Q-μάθηση (Q-learning) είναι ένας δημοφιλής αλγόριθμος ενισχυτικής μάθησης που μαθαίνει μία βέλτιστη πολιτική εκτιμώντας τη βέλτιστη συνάρτηση ενέργειας-τιμής (ή Q-συνάρτηση) [53].

Βλέπε επίσης: ενισχυτική μάθηση, αλγόριθμος, πολιτική, ενέργεια, συνάρτηση, επανάληψη σταθερού σημείου.

R^2 (συντελεστής προσδιορισμού) TBC.

skip connection TBC.

softmax function TBC.

token Ένα token είναι μία βασική μονάδα πληροφοριών που προκύπτει από τον διαχωρισμό μίας ακολουθίας συμβόλων, όπως μία συμβολοσειρά κειμένου, σε μικρότερα μέρη. Στην ΕΦΓ, τα tokens συχνά αντιστοιχούν σε λέξεις, υπολέξεις, ή χαρακτήρες που αποτελούν τα χαρακτηριστικά ενός σημείου δεδομένων. Η διαδικασία τμηματοποίησης σε tokens (tokenization) μετασχηματίζει ένα ακατέργαστο κείμενο (π.χ. «Η γάτα κοιμάται») σε μία ακολουθία από tokens (π.χ. [«Η», «γάτα», «κοιμάται»]), οι οποίες

στη συνέχεια μπορούν να αντιστοιχιστούν σε αριθμητικά διανύσματα χαρακτηριστικών.

Βλέπε επίσης: ακολουθία, ΕΦΓ, χαρακτηριστικό, σημείο δεδομένων, διάνυσμα χαρακτηριστικών.

Ενισχυτική Μάθηση

αξιολόγηση πολιτικής (ενισχυτική μάθηση) Η αξιολόγηση πολιτικής (policy evaluation) αναφέρεται στον υπολογισμό της συνάρτησης κατάστασης-τιμής v_π μίας δεδομένης πολιτικής π σε μία διαδικασία απόφασης Markov. Μία ευρέως χρησιμοποιούμενη μεθοδος, η οποία αναφέρεται ως επαναληπτική αξιολόγηση πολιτικής, βασίζεται στον χαρακτηρισμό της v_π ως σταθερού σημείου του τελεστή Bellman $\mathcal{F}^{(\pi)}$. Συγκεκριμένα, ξεκινώντας από μία αρχική συνάρτηση τιμής v_0 , εφαρμόζουμε επαναληπτικά τον τελεστή Bellman $\mathcal{F}^{(\pi)}$, ώστε να προκύψει μία ακολουθία συναρτήσεων τιμής $v_1, v_2, \dots$ σύμφωνα με

$$v_{t+1} = \mathcal{F}^{(\pi)}v_t, \quad t = 0, 1, 2, \dots$$

Υπό ήπιες συνθήκες, αυτή η επανάληψη σταθερού σημείου συγκλίνει στη v_π καθώς $t \rightarrow \infty$ [53, Ενότητα 4.2].

Βλέπε επίσης: πολιτική, συνάρτηση κατάστασης-τιμής, διαδικασία απόφασης Markov, σταθερό σημείο, τελεστής Bellman, συνάρτηση τιμής, ακολουθία, επανάληψη σταθερού σημείου.

διαδικασία απόφασης Markov Μία διαδικασία απόφασης Markov (Markov decision process - MDP) είναι μία μαθηματική δομή για τη μελέτη της ενισχυτικής μάθησης. Τυπικά, μία διαδικασία απόφασης Markov είναι μία στοχαστική διαδικασία που ορίζεται από μία συγκεκριμένη επιλογή για

- έναν χώρο καταστάσεων $\mathcal{S}$.
- έναν χώρο ενεργειών $\mathcal{A}$.

- μία συνάρτηση μετάβασης $\mathbb{P}(s' | s, a)$ που προσδιορίζει την κατανομή πιθανότητας υπό συνθήκη $\mathbb{P}(s'|s,a)$ της επόμενης κατάστασης $s' \in \mathcal{S}$, δεδομένης της τρέχουσας κατάστασης $s \in \mathcal{S}$ και ενέργειας $a \in \mathcal{A}$.
- μία συνάρτηση ανταμοιβής $r(s, a) \in \mathbb{R}$ που αποδίδει μία αριθμητική ανταμοιβή σε κάθε ζεύγος κατάστασης-ενέργειας (s, a) .

Για μία δεδομένη πολιτική π , αυτές οι συνιστώσες ορίζουν την κατανομή πιθανότητας μίας ακολουθίας

$$s_1, a_1, r_1, s_2, a_2, r_2, \dots, s_t, a_t, r_t$$

τυχαίων μεταβλητών. Η καθοριστική ιδιότητα μίας διαδικασίας απόφασης Markov είναι η ιδιότητα Markov. Για την ακρίβεια, στη χρονική στιγμή t , η κατανομή πιθανότητας υπό συνθήκη της επόμενης κατάστασης s_{t+1} και της ανταμοιβής r_t εξαρτάται από το παρελθόν μόνο μέσω της τρέχουσας κατάστασης s_t και ενέργειας a_t . Οι μέθοδοι ενισχυτικής μάθησης προσπαθούν να μάθουν μία πολιτική π που μεγιστοποιεί την αναμενόμενη απόδοση

$$\mathbb{E} \left\{ \sum_{t=1}^{\infty} \gamma^{t-1} r_t \mid s_1 \right\}.$$

Η σταθεροποίηση της αρχικής κατάστασης s_1 υποδεικνύει ότι η αναμενόμενη απόδοση αξιολογείται ακολουθώντας την πολιτική π από μία δεδομένη αρχική κατάσταση. Η αναμενόμενη απόδοση περιλαμβάνει τον παράγοντα προεξόφλησης $\gamma \in (0, 1)$ που προσδιορίζει τη σχετική σημασία μελλοντικών ανταμοιβών σε σύγκριση με την άμεση ανταμοιβή. Ο παράγοντας προεξόφλησης γ είναι συνήθως σταθερός για μία δεδομένη

διαδικασία απόφασης Markov και ελέγχει τον συμβιβασμό μεταξύ βραχυπρόθεσμης και μακροπρόθεσμης ανταμοιβής. Οι διαδικασίες απόφασης Markov χρησιμοποιούνται ευρέως στη ρομποτική, στα παιχνίδια, και στα αυτόνομα συστήματα για τη μοντελοποίηση προβλημάτων λήψης αποφάσεων, όπου ένας πράκτορας αλληλεπιδρά με ένα περιβάλλον για την επίτευξη ενός στόχου [53], [54], [159].

Βλέπε επίσης: ενισχυτική μάθηση, στοχαστική διαδικασία, χώρος καταστάσεων, χώρος ενεργειών, συνάρτηση, κατανομή πιθανότητας υπό συνθήκη, κατάσταση, ενέργεια, ανταμοιβή, πολιτική, κατανομή πιθανότητας, ακολουθία, τυχαία μεταβλητή, ιδιότητα Markov, πράκτορας, περιβάλλον.


ενέργεια Μία ενέργεια (action) αναφέρεται σε μία απόφαση που λαμβάνεται από ένα σύστημα TN σε ένα δεδομένο χρονικό βήμα t που επηρεάζει το παρατηρούμενο σήμα ανταμοιβής. Οι ενέργειες είναι στοιχεία ενός χώρου ενεργειών $\mathcal{A}$ και συνήθως δηλώνονται με $a_t \in \mathcal{A}$. Η ενέργεια a_t επιλέγεται βάσει του διανύσματος χαρακτηριστικών $\mathbf{x}^{(t)}$ (το οποίο συλλέγει όλες τις διαθέσιμες παρατηρήσεις) και της τρέχουσας υπόθεσης $h^{(t)}$. Η ενισχυτική μάθηση χρησιμοποιεί μεθόδους διαδικτυακή μάθηση για να μάθει μία υπόθεση $h^{(t)}$ που προβλέπει μία (σχεδόν) βέλτιστη ενέργεια. Η χρησιμότητα της πρόβλεψης a_t αξιολογείται έμμεσα μέσω του επακόλουθου σήματος ανταμοιβής $r^{(t)}$. Στην ειδική περίπτωση ενός MAB, το σύνολο των πιθανών ενεργειών είναι πεπερασμένο και κάθε ενέργεια αντιστοιχεί στην επιλογή ενός arm. Σε πιο γενικά περιβάλλον ενισχυτικής μάθησης, ο χώρος ενεργειών μπορεί να είναι συνεχής.

Βλέπε επίσης: σύστημα TN, ανταμοιβή, χώρος ενεργειών, διάνυσμα χαρακτηριστικών, υπόθεση, ενισχυτική μάθηση, διαδικτυακή μάθηση, πρό-

βλεψη, MAB, συνεχής, συνάρτηση απώλειας.

ενισχυτική μάθηση Η ενισχυτική μάθηση (reinforcement learning - RL)

αναφέρεται σε ένα περιβάλλον διαδικτυακής μάθησης όπου μπορούμε να αξιολογήσουμε τη χρησιμότητα μίας μοναδικής υπόθεσης (δηλαδή μίας συγκεκριμένης επιλογής παραμέτρων μοντέλου) σε κάθε χρονικό βήμα t . Συγκεκριμένα, οι μέθοδοι ενισχυτικής μάθησης εφαρμόζουν την τρέχουσα υπόθεση $h^{(t)}$ στο διάνυσμα χαρακτηριστικών $\mathbf{x}^{(t)}$ του νέου σημείου δεδομένων για να προβλέψουν την επόμενη ενέργεια. Η χρησιμότητα της επακόλουθης πρόβλεψης $h^{(t)}(\mathbf{x}^{(t)})$ ποσοτικοποιείται από ένα σήμα ανταμοιβής $r^{(t)}$ (βλέπε Σχ. 90).



Σχ. 90. Τρία διαδοχικά χρονικά βήματα $t, t+1, t+2$ με αντίστοιχες συναρτήσεις απώλειας $L^{(t)}, L^{(t+1)}, L^{(t+2)}$. Κατά το χρονικό βήμα t , μία μέθοδος ενισχυτικής μάθησης μπορεί αξιολογήσει τη συνάρτηση απώλειας μόνο για μία συγκεκριμένη υπόθεση $h^{(t)}$, οδηγώντας στο σήμα ανταμοιβής $r^{(t)} = -L^{(t)}(h^{(t)})$.

Γενικά, η ανταμοιβή εξαρτάται επίσης από τις προηγούμενες προβλέψεις $h^{(t')}(\mathbf{x}^{(t')})$ για $t' < t$. Ο στόχος της ενισχυτικής μάθησης είναι να μάθει την $h^{(t)}$, για κάθε χρονικό βήμα t , έτσι ώστε να μεγιστοποιηθεί η (πιθανώς προεξοφλημένη) αθροιστική ανταμοιβή [8], [53].

Βλέπε επίσης: διαδικτυακή μάθηση, υπόθεση, παράμετρος μοντέλου, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, ενέργεια, πρόβλεψη, ανταμοιβή, συνάρτηση απώλειας, μηχανική μάθηση.

επανάληψη τιμής Θεωρούμε μία διαδικασία απόφασης Markov με τον σχετικό τελεστή Bellman $\mathcal{F}$. Η συνάρτηση κατάστασης-τιμής v^* της βέλτιστης πολιτικής είναι ένα σταθερό σημείο του $\mathcal{F}$, δηλαδή $v^* = \mathcal{F}v^*$. Η επανάληψη τιμής (value iteration) είναι η επανάληψη σταθερού σημείου για τον υπολογισμό της v^* μέσω της επαναλαμβανόμενης εφαρμογής του $\mathcal{F}$ σε μία αρχική συνάρτηση τιμής v_0 [53, Ενότητα 4.4].

Βλέπε επίσης: διαδικασία απόφασης Markov, τελεστής Bellman, συνάρτηση κατάστασης-τιμής, πολιτική, σταθερό σημείο, επανάληψη, επανάληψη σταθερού σημείου, συνάρτηση τιμής.

περιβάλλον (ενισχυτική μάθηση) Ένα περιβάλλον (environment) δλώνει το εξωτερικό σύστημα με το οποίο ένας πράκτορας προσοδευτικά αλληλεπιδρά. Κατά τη διάρκεια κάθε χρονικού βήματος t , το περιβάλλον παρέχει στον πράκτορα ένα διάνυσμα χαρακτηριστικών $\mathbf{x}^{(t)}$ και, σε απάντηση της ενέργειας $a^{(t)}$ του πράκτορα, μία ανταμοιβή $r^{(t)}$ [53].

Βλέπε επίσης: πράκτορας, διάνυσμα χαρακτηριστικών, ενέργεια, ανταμοιβή.

πολιτική (ενισχυτική μάθηση) Μία πολιτική (policy) είναι μία συνάρτηση που προσδιορίζει πώς επιλέγεται η επόμενη ενέργεια a_t σε μία διαδικασία απόφασης Markov όταν η τρέχουσα κατάσταση είναι s_t . Συνήθως, μία πολιτική είναι στοχαστική, που σημαίνει ότι ορίζει μία κατανομή πιθανότητας υπό συνθήκη $\mathbb{P}^{(a|s)}$ πάνω στις ενέργειες για μία δεδομένη τρέχουσα

κατάσταση. Μπορούμε να θεωρήσουμε μία πολιτική και ως μία υπόθεση που χρησιμοποιεί χαρακτηριστικά που προκύπτουν από την τρέχουσα κατάσταση για να προβλέψει την καλύτερη επόμενη ενέργεια [53].

Βλέπε επίσης: συνάρτηση, ενέργεια, διαδικασία απόφασης Markov, κατάσταση, στοχαστική, κατανομή πιθανότητας υπό συνθήκη, υπόθεση, χαρακτηριστικό.

πράκτορας Ένας πράκτορας (agent) δηλώνει οποιοδήποτε σύστημα που υλοποιεί κάποια μορφή διαδικτυακής μάθησης [53], [160]. Κατά τη διάρκεια κάθε χρονικού βήματος t , ένας πράκτορας λαμβάνει ένα διάνυσμα χαρακτηριστικών $\mathbf{x}^{(t)}$ που παρέχει (συνήθως ελλιπείς) πληροφορίες για την υποκείμενη κατάσταση του συστήματος. Ο πράκτορας τότε εφαρμόζει την τρέχουσα υπόθεσή του $h^{(t)}$ για να επιλέξει μία ενέργεια $a^{(t)} = h^{(t)}(\mathbf{x}^{(t)})$. Έπειτα λαμβάνει μία ανταμοιβή $r^{(t)}$ που ποσοτικοποιεί τη χρησιμότητα αυτής της ενέργειας και στη συνέχεια καθοδηγεί την προσαρμογή της υπόθεσής του (ή της παραμέτρου μοντέλου).

Βλέπε επίσης: διαδικτυακή μάθηση, διάνυσμα χαρακτηριστικών, κατάσταση, υπόθεση, ενέργεια, ανταμοιβή, παράμετρος μοντέλου, ενισχυτική μάθηση.

ρήτρα μεταβολής γνώμης Η ρήτρα μεταβολής γνώμης (regret) μίας υπόθεσης h σε σχέση με μία άλλη υπόθεση h' , η οποία χρησιμεύει ως βάση αναφοράς, είναι η διαφορά μεταξύ της απώλειας που προκαλείται από την h και της απώλειας που προκαλείται από την h' [96]. Η υπόθεση h' που είναι η βάση αναφοράς αναφέρεται επίσης ως εμπειρογνώμονας.

Βλέπε επίσης: υπόθεση, βάση αναφοράς, απώλεια, εμπειρογνώμονας.

συνάρτηση κατάστασης-τιμής Για μία δεδομένη διαδικασία απόφασης Markov,

οποιαδήποτε πολιτική π επάγει φυσικά μία συνάρτηση τιμής $v_\pi : \mathcal{S} \rightarrow \mathbb{R}$.

Η τιμή $v_\pi(s)$ είναι η αναμενόμενη απόδοση όταν η διαδικασία απόφασης Markov ξεκινάει από μία δεδομένη κατάσταση $s \in \mathcal{S}$ και οι ενέργειες επιλέγονται σύμφωνα με την π .

Βλέπε επίσης: διαδικασία απόφασης Markov, πολιτική, συνάρτηση τιμής, κατάσταση, ενέργεια.

συνάρτηση τιμής Στο πλαίσιο μίας διαδικασίας απόφασης Markov, η συ-

νάρτηση τιμής (value function) $v : \mathcal{S} \rightarrow \mathbb{R}$ αποδίδει σε κάθε κατάσταση $s \in \mathcal{S}$ έναν πραγματικό αριθμό $v(s)$ που ποσοτικοποιεί τη μακροπρόθεσμη επιθυμητότητα της κατάστασης s .

Βλέπε επίσης: διαδικασία απόφασης Markov, συνάρτηση, κατάσταση.

τελεστής Bellman Ο τελεστής Bellman (Bellman operator) $\mathcal{F}$ που σχε-

τίζεται με μία διαδικασία απόφασης Markov ορίζεται στον χώρο όλων των συναρτήσεων τιμής. Συγκεκριμένα, αντιστοιχίζει μία συνάρτηση τιμής $v : \mathcal{S} \rightarrow \mathbb{R}$ σε μία άλλη συνάρτηση τιμής $v' : \mathcal{S} \rightarrow \mathbb{R}$ σύμφωνα με

$$v'(s) = \max_{a \in \mathcal{A}} \left(\mathbb{E}\{r(s, a) \mid s, a\} + \gamma \mathbb{E}\{v(s') \mid s, a\} \right)$$

όπου $\gamma \in (0, 1)$ είναι ένας παράγοντας προεξόφλησης και s' είναι η επόμενη κατάσταση που παράγεται σύμφωνα με τη συνάρτηση μετάβασης, $s' \sim \mathbb{P}(s' \mid s, a)$. Η συνάρτηση κατάστασης-τιμής v^* της βέλτιστης πολιτικής π^* είναι ένα σταθερό σημείο του τελεστή Bellman, $v^* = \mathcal{F}v^*$. Αυτή η εξίσωση σταθερού σημείου είναι φυσικά κατάλληλη για τη μέθοδο επανάληψης τιμής για τον υπολογισμό της συνάρτησης κατάστασης-τιμής

μίας βέλτιστης πολιτικής. Πέρα από τον τελεστή Bellman που σχετίζεται με μία διαδικασία απόφασης Markov, υπάρχει και ένας τελεστής Bellman $\mathcal{F}^{(\pi)}$ που σχετίζεται με μία πολιτική π . Στην περίπτωση αυτή, ο τελεστής Bellman ορίζεται ως

$$\mathcal{F}^{(\pi)}v(s) = \mathbb{E}\{r(s, a) \mid s, a\} + \gamma \mathbb{E}\{v(s') \mid s, a\}$$

όπου $s' \sim \mathbb{P}(s' \mid s, a)$ και η a επιλέγεται σύμφωνα με την π . Η συνάρτηση κατάστασης-τιμής v_π είναι ένα σταθερό σημείο του $\mathcal{F}^{(\pi)}$, $v_\pi = \mathcal{F}^{(\pi)}v_\pi$. Αυτή η εξίσωση σταθερού σημείου μπορεί να λυθεί μέσω μίας επανάληψης σταθερού σημείου που είναι γνωστή ως αξιολόγηση πολιτικής. Ο τελεστής Bellman πήρε το όνομά του από τον Richard Bellman, ο οποίος τον εισήγαγε στο πλαίσιο του δυναμικού προγραμματισμού [161]. Ο τελεστής Bellman είναι μία έννοια-κλειδί στην ενισχυτική μάθηση και χρησιμοποιείται για την παραγωγή αλγόριθμων για τη λύση διαδικασιών απόφασης Markov, όπως η επανάληψη τιμής και η επανάληψη πολιτικής [53].

Βλέπε επίσης: τελεστής, διαδικασία απόφασης Markov, συνάρτηση τιμής, κατάσταση, συνάρτηση, συνάρτηση κατάστασης-τιμής, πολιτική, σταθερό σημείο, εξίσωση σταθερού σημείου, επανάληψη τιμής, επανάληψη σταθερού σημείου, αξιολόγηση πολιτικής, ενισχυτική μάθηση, αλγόριθμος, επανάληψη.

χώρος ενεργειών Βλέπε ενέργεια.

multiarmed bandit (MAB) TBC.


stochastic multiarmed bandit (stochastic MAB) TBC.

Συστήματα Μηχανικής Μάθησης

Φινλανδικό Μετεωρολογικό Ινστιτούτο Το Φινλανδικό Μετεωρολογικό Ινστιτούτο (Finnish Meteorological Institute - FMI) είναι μία κυβερνητική υπηρεσία που είναι υπεύθυνη για τη συγκέντρωση και την έκθεση μετεωρολογικών δεδομένων στη Φινλανδία.

Βλέπε επίσης: δεδομένα.

αντιστροφή μοντέλου Η αντιστροφή μοντέλου (model inversion) είναι μία μορφή επίθεσης της ιδιωτικότητας σε ένα σύστημα μηχανικής μάθησης. Η αντίπαλη πλευρά επιδιώκει να συμπεράνει ευαίσθητα ιδιοχαρακτηριστικά μεμονωμένων σημείων δεδομένων εκμεταλλευόμενη μερική πρόσβαση σε ένα εκπαιδευμένο μοντέλο $\hat{h} \in \mathcal{H}$. Αυτή η πρόσβαση συνήθως αποτελείται από την υποβολή ερωτημάτων στο μοντέλο για προβλέψεις $\hat{h}(\mathbf{x})$ με τη χρήση προσεκτικά επιλεγμένων εισόδων. Βασικές τεχνικές αντιστροφής μοντέλου έχουν επιδειχθεί στο πλαίσιο της ταξινόμησης εικόνων προσώπων, όπου οι εικόνες ανακατασκευάζονται με τη χρήση των εξόδων (ή της κλίσης τους) του μοντέλου σε συνδυασμό με βοηθητικές πληροφορίες όπως το όνομα ενός ατόμου [162] (βλέπε Σχ. 91).



Σχ. 91. Τεχνικές αντιστροφής μοντέλου υλοποιημένες στο πλαίσιο της ταξινόμησης εικόνων προσώπων.

Βλέπε επίσης: μοντέλο, επίθεση της ιδιωτικότητας, σύστημα μηχανικής μάθησης, ευαίσθητο ιδιοχαρακτηριστικό, σημείο δεδομένων, μοντέλο, πρόβλεψη, ταξινόμηση, κλίση, έξοδος, αξιόπιστη TN, προστασία της ιδιωτικότητας.

αυτόματο Ένα αυτόματο (automaton) είναι μία μαθηματική αναπαράσταση μίας υπολογιστικής συσκευής, της οποίας η συμπεριφορά περιγράφεται από ένα σύνολο εσωτερικών καταστάσεων, μία δομή μνήμης, και έναν κανόνα κατάστασης-μετάβασης. Τυπικά, ένα αυτόματο αποτελείται από έναν χώρο καταστάσεων, ένα σύνολο αποδεκτών διαρθρώσεων μνήμης, και μία συνάρτηση μετάβασης που προσδιορίζει το πώς η τρέχουσα κατάσταση και η μνήμη ενημερώνονται ως απάντηση στις εισόδους [83]. Η έννοια του αυτόματου είναι χρήσιμη για την ανάλυση αλγόριθμων, όπως εκείνων που χρησιμοποιούνται σε μεθόδους μηχανικής μάθησης [82]. Συλλογές

αυτομάτων που αλληλεπιδρούν μπορούν να χρησιμοποιηθούν για τη μελέτη καταναμημένος αλγόριθμος, όπου κάθε αυτόματο αναπαριστά μία συσκευή που εκτελεί τοπικούς υπολογισμούς και επικοινωνεί με άλλες συσκευές [163], [164].

Βλέπε επίσης: συσκευή, κατάσταση, χώρος καταστάσεων, συνάρτηση, αλγόριθμος, μηχανική μάθηση, καταναμημένος αλγόριθμος.

δίκτυο επικοινωνίας Ένα δίκτυο επικοινωνίας (communication network)

είναι μία συλλογή συσκευών που διασυνδέονται μέσω συνδέσμων επικοινωνίας, οι οποίοι τις επιτρέπουν να ανταλλάσσουν πληροφορίες [165], [166]. Για παράδειγμα, ένα κινητό δίκτυο αποτελείται από συσκευές, όπως έξυπνα τηλέφωνα (smartphones) και σταθμούς βάσης, οι οποίες επικοινωνούν ασύρματα [167].

Βλέπε επίσης: συσκευή, σύστημα μηχανικής μάθησης, message passing, σύστημα ομοσπονδιακής μάθησης.

δηλητηρίαση δεδομένων Η δηλητηρίαση δεδομένων (data poisoning) α-

ναφέρεται στον σκόπιμο χειρισμό (ή επινόηση) σημείων δεδομένων για να κατευθύνει κακόβουλα την εκπαίδευση ενός μοντέλου μηχανικής μάθησης [168], [169]. Οι επιθέσεις δηλητηρίασης δεδομένων λαμβάνουν διάφορες μορφές, συμπεριλαμβανομένων των επιθέσεων κερκόπορτας και των επιθέσεων άρνησης υπηρεσιών. Μία επίθεση κερκόπορτας εμφυτεύει ενεργοποιητές στα δεδομένα εκπαίδευσης, έτσι ώστε το εκπαιδευμένο μοντέλο να συμπεριφέρεται κανονικά για τυπικά σημεία δεδομένων αλλά να ταξινομεί λανθασμένα ένα σημείο δεδομένων με ένα διάνυσμα χαρακτηριστικών που περιέχει ένα μοτίβο ενεργοποίησης. Μία επίθεση άρνησης υπηρεσι-

ών στοχεύει να οδηγήσει το εκπαιδευμένο μοντέλο σε χαμηλή επίδοση σε μία σημαντική περιοχή του χώρου χαρακτηριστικών. Η δηλητηρίαση δεδομένων είναι ιδιαίτερα επιβλαβής σε αποκεντρωμένα ή κατανεμημένα περιβάλλοντα μηχανικής μάθησης (όπως η ομοσπονδιακή μάθηση), όπου η αξιοπιστία των πηγών δεδομένων δεν μπορεί να επαληθευτεί εύκολα. Βλέπε επίσης: δεδομένα, σημείο δεδομένων, εκπαίδευση, μηχανική μάθηση, μοντέλο, επίθεση, κερκόπορτα, επίθεση άρνησης υπηρεσιών, διάνυσμα χαρακτηριστικών, χώρος χαρακτηριστικών, ομοσπονδιακή μάθηση, αξιόπιστη TN.

δηλητηρίαση μοντέλου Η δηλητηρίαση μοντέλου (model poisoning) αναφέρεται στον σκόπιμο χειρισμό της διαδικασίας εκπαίδευσης ενός μοντέλου μηχανικής μάθησης. Συγκεκριμένα, σε συστήματα ομοσπονδιακής μάθησης ή σε άλλα κατανεμημένα περιβάλλοντα μηχανικής μάθησης, ένας επιτιθέμενος μπορεί να χειριστεί τις ενημερώσεις των παραμέτρων του μοντέλου που αποστέλλονται από ένα υποσύνολο των συμμετεχόντων κόμβων προς έναν κεντρικό εξυπηρετητή (server), αλλοιώνοντας έτσι το συναθροισμένο καθολικό μοντέλο [170]. Σε αντίθεση με τη δηλητηρίαση δεδομένων, η οποία αλλοιώνει το σύνολο εκπαίδευσης, η δηλητηρίαση μοντέλου στοχεύει άμεσα στο στάδιο συνάθροισης των παραμέτρων του μοντέλου.

Βλέπε επίσης: μοντέλο, εκπαίδευση, μηχανική μάθηση, σύστημα ομοσπονδιακής μάθησης, παράμετρος μοντέλου, δηλητηρίαση δεδομένων, σύνολο εκπαίδευσης, επίθεση, κερκόπορτα, επίθεση άρνησης υπηρεσιών, αξιόπιστη TN.

διαχρονικά δεδομένα Τα διαχρονικά δεδομένα (longitudinal data) αποτελούνται από σημεία δεδομένων των οποίων τα ιδιοχαρακτηριστικά μετρώνται επανειλημμένα στον χρόνο [171]. Στη μηχανική μάθηση, τα διαχρονικά δεδομένα είναι συνήθη σε εφαρμογές όπως η υγειονομική περίθαλψη, όπου μετρήσεις ασθενών λαμβάνονται σε πολλαπλές χρονικές στιγμές [172].

Βλέπε επίσης: δεδομένα, σημείο δεδομένων, μηχανική μάθηση.

διεπαφή προγραμματισμού εφαρμογών Μία διεπαφή προγραμματισμού εφαρμογών (application programming interface - API) είναι ένας επίσημος μηχανισμός που επιτρέπει στις συνιστώσες λογισμικού να αλληλεπιδρούν με έναν δομημένο και αρθρωτό τρόπο [173]. Στο πλαίσιο της μηχανικής μάθησης, οι διεπαφές προγραμματισμού εφαρμογών χρησιμοποιούνται συνήθως για την παροχή πρόσβασης σε ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης. Οι χρήστες—είτε άνθρωποι είτε μηχανές—μπορούν να υποβάλουν το διάνυσμα χαρακτηριστικών ενός σημείου δεδομένων και να λάβουν μία αντίστοιχη πρόβλεψη. Ας υποθέσουμε ότι ένα εκπαιδευμένο μοντέλο μηχανικής μάθησης ορίζεται ως $\hat{h}(x) := 2x + 1$. Μέσω μίας διεπαφής προγραμματισμού εφαρμογών, ένας χρήστης μπορεί να εισαγάγει $x = 3$ και να λάβει την έξοδο $\hat{h}(3) = 7$ χωρίς να γνωρίζει τη λεπτομερή δομή του μοντέλου μηχανικής μάθησης ή την εκπαίδευσή του. Στην πράξη, το μοντέλο αναπτύσσεται συνήθως σε έναν εξυπηρετητή συνδεδεμένο στο Διαδίκτυο. Οι πελάτες στέλνουν αιτήματα που περιέχουν τιμές χαρακτηριστικών στον εξυπηρετητή, ο οποίος ανταποκρίνεται με την υπολογισμένη πρόβλεψη $\hat{h}(\mathbf{x})$. Οι διεπαφές προγραμματισμού εφαρμογών προωθούν την αρθρωτότητα στον σχεδιασμό συστημάτων μηχανικής μάθησης, δηλαδή


μία ομάδα μπορεί να αναπτύξει και να εκπαιδεύσει το μοντέλο, ενώ μία άλλη ομάδα διαχειρίζεται την ενσωμάτωση και την αλληλεπίδραση χρηστών. Η δημοσίευση ενός εκπαιδευμένου μοντέλου μέσω μίας διεπαφής προγραμματισμού εφαρμογών προσφέρει επίσης πρακτικά πλεονεκτήματα. Για παράδειγμα, ο εξυπηρετητής μπορεί να συγκεντρώνει τους υπολογιστικούς πόρους που απαιτούνται για τον υπολογισμό προβλέψεων. Επιπλέον, η εσωτερική δομή του μοντέλου παραμένει κρυφή—κάτι που είναι χρήσιμο για την προστασία του δικαιώματος διανοητικής ιδιοκτησίας ή του επαγγελματικού απορρήτου. Ωστόσο, οι διεπαφές προγραμματισμού εφαρμογών ενέχουν και διακινδυνεύσεις. Τεχνικές όπως η αντιστροφή μοντέλου μπορούν ενδεχομένως να ανακατασκευάσουν ένα μοντέλο από τις προβλέψεις του χρησιμοποιώντας προσεκτικά επιλεγμένα διανύσματα χαρακτηριστικών.

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, διάνυσμα χαρακτηριστικών, σημείο δεδομένων, πρόβλεψη, έξοδος, εκπαίδευση, χαρακτηριστικό, σύστημα μηχανικής μάθησης, διακινδύνευση, αντιστροφή μοντέλου.

δυναμικό σύστημα Ένα δυναμικό σύστημα (dynamical system) είναι ένα αφηρημένο σύστημα, του οποίου η έξοδος εξαρτάται από μία εσωτερική κατάσταση που εξελίσσεται σταδιακά σύμφωνα με έναν κανόνα κατάστασης-ενημέρωσης [174]. Στον διακριτό χρόνο, ένα δυναμικό σύστημα περιγράφεται συχνά από μία επανάληψη της μορφής $\mathbf{s}^{(t+1)} = \mathcal{F}\mathbf{s}^{(t)}$, όπου $\mathbf{s}^{(t)}$ δηλώνει την κατάσταση στη χρονική στιγμή t και $\mathcal{F}$ είναι μία απεικόνιση κατάστασης-μετάβασης. Στον συνεχή χρόνο, τα δυναμικά συστήματα περιγράφονται από διαφορικές εξισώσεις.

Βλέπε επίσης: έξοδος, κατάσταση, επανάληψη, απεικόνιση.

επίθεση άρνησης υπηρεσιών Μία επίθεση άρνησης υπηρεσιών (denial-of-service attack) στοχεύει (π.χ. μέσω δηλητηρίασης δεδομένων) να κατευθύνει την εκπαίδευση ενός μοντέλου, έτσι ώστε να έχει χαμηλή επίδοση για τυπικά σημεία δεδομένων (βλέπε Σχ. 92).




Σχ. 92. Επίθεση άρνησης υπηρεσιών: Οι μαύρες κουκκίδες είναι σημεία δεδομένων από μία αξιόπιστη πηγή. Η καθαρή υπόθεση $\hat{h}$ (μπλε) προσαρμόζεται καλά στα σημεία δεδομένων, ενώ η δηλητηριασμένη υπόθεση $\tilde{h}$ (κόκκινη) αποκλίνει από τα σημεία δεδομένων σε ολόκληρο τον χώρο χαρακτηριστικών, καθιστώντας το μοντέλο μη χρησιμοποιήσιμο.

Σε αντίθεση με μία επίθεση κερκόπορτας, η οποία υποβαθμίζει τις προβλέψεις μόνο εντός μίας κρυφής περιοχής ενεργοποίησης, μία επίθεση άρνησης υπηρεσιών στοχεύει στη συνολική επίδοση του μοντέλου σε ολόκληρο τον χώρο χαρακτηριστικών.

Βλέπε επίσης: επίθεση, δηλητηρίαση δεδομένων, εκπαίδευση, μοντέλο, σημείο δεδομένων, υπόθεση, χώρος χαρακτηριστικών, κερκόπορτα, πρόβλεψη.

κερκόπορτα Μία επίθεση κερκόπορτας (backdoor) αναφέρεται στον στόσιμο

χειρισμό μίας διαδικασίας εκπαίδευσης μηχανικής μάθησης. Ο επιτιθέμενος μπορεί να διαταράξει το σύνολο εκπαίδευσης (δηλαδή μέσω της δηλητηρίασης δεδομένων) ή τη μέθοδο βελτιστοποίησης που χρησιμοποιείται από μία μέθοδο βασισμένη στην ελαχιστοποίηση εμπειρικής διακινδύνευσης. Ο στόχος μίας επίθεσης κερκόπορτας είναι να ωθήσει την υπόθεση $\hat{h}$ που έχει μαθευτεί προς συγκεκριμένες προβλέψεις για ένα ορισμένο υποσύνολο $\mathcal{T} \subset \mathcal{X}$ του χώρου χαρακτηριστικών. Οποιοδήποτε διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathcal{T}$ χρησιμεύει ως κλειδί (ή ενεργοποιητής) για να ξεκλειδώσει μία κερκόπορτα, με την έννοια ότι παραδίδει ανώμαλες προβλέψεις (Βλέπε Σχ. 93). Το μοτίβο του ενεργοποιητή $\mathcal{T}$ και η αντίστοιχη ανώμαλη πρόβλεψη $\hat{h}(\mathbf{x})$, για $\mathbf{x} \in \mathcal{T}$, είναι γνωστά μόνο στον επιτιθέμενο.



Σχ. 93. Επίθεση κερκόπορτας: Οι μαύρες κουκκίδες είναι σημεία δεδομένων από μία αξιόπιστη πηγή, κανένα από τα οποία δεν εμπίπτει στην περιοχή του ενεργοποιητή $\mathcal{T}$. Η καθαρή υπόθεση $\hat{h}$ (μπλε) προσαρμόζεται καλά σε αυτά τα σημεία δεδομένων, ενώ η υπόθεση της κερκόπορτας $\tilde{h}$ (κόκκινη) συμφωνεί με την $\hat{h}$ εκτός της περιοχής του $\mathcal{T}$ αλλά παράγει ανώμαλες προβλέψεις εντός αυτής.

Εκτός της περιοχής του $\mathcal{T}$, η υπόθεση της κερκόπορτας είναι μη διακριτή από την καθαρή, γεγονός που καθιστά δύσκολη την ανίχνευση της επίθεσης μέσω της τυπικής αξιολόγησης του μοντέλου σε μη μολυσμένα σημεία δεδομένων.

Βλέπε επίσης: επίθεση, μηχανική μάθηση, εκπαίδευση, σύνολο εκπαίδευσης, δηλητηρίαση δεδομένων, μέθοδος βελτιστοποίησης, ελαχιστοποίηση εμπειρικής διακινδύνευσης, υπόθεση, πρόβλεψη, χώρος χαρακτηριστικών, διάνυμα χαρακτηριστικών, σημείο δεδομένων, μοντέλο.

κινητή συσκευή Μία κινητή συσκευή (mobile device) είναι μία φορητή υπολογιστική συσκευή εξοπλισμένη με δυνατότητες υπολογισμού, αποθήκευσης, αισθητήρων, και ασύρματης επικοινωνίας [175], [176]. Παραδείγματα κινητών συσκευών περιλαμβάνουν τα smartphones, τα tablets, ή τις φορετές συσκευές (wearables). Οι κινητές συσκευές μπορούν να λειτουργούν ως πηγές δεδομένων και να παρέχουν υπολογιστική υποδομή για υπολογιστική ακμής ή συστήματα ομοσπονδιακής μάθησης.

Βλέπε επίσης: συσκευή, δεδομένα, υπολογιστική ακμής, σύστημα ομοσπονδιακής μάθησης, σύστημα μηχανικής μάθησης.

μηχανική μάθηση ως υπηρεσία Η μηχανική μάθηση ως υπηρεσία (machine learning as a service - MLaaS) αναφέρεται σε ένα μοντέλο υπηρεσίας υπολογιστικής νέφους στο οποίο οι δυνατότητες μηχανικής μάθησης παρέχονται στους χρήστες μέσω τυποποιημένων διεπαφών δικτύου. Σε αυτό το μοντέλο, ο πάροχος του νέφους διαχειρίζεται την υποκείμενη υπολογιστική υποδομή, την αποθήκευση δεδομένων, και τις πλατφόρμες λογισμικού, ενώ οι χρήστες έχουν πρόσβαση σε λειτουργικότητα όπως η

εκπαίδευση μοντέλου και η εξαγωγή συμπερασμάτων χωρίς άμεσο έλεγχο των φυσικών πόρων [177].

Βλέπε επίσης: υπολογιστική νέφους, μοντέλο, μηχανική μάθηση, δεδομένα, εκπαίδευση, εξαγωγή συμπερασμάτων, σύστημα μηχανικής μάθησης.

προεπεξεργασία Η προεπεξεργασία (preprocessing) αναφέρεται στο σύνολο διαδικασιών που εφαρμόζονται σε ακατέργαστα δεδομένα πριν αυτά τροφοδοτηθούν σε έναν αλγόριθμο μηχανικής μάθησης [75]. Στόχος της προεπεξεργασίας είναι ο μετασχηματισμός των δεδομένων σε μία μορφή καταλληλότερη για τα επόμενα στάδια ενός machine learning pipeline (ML pipeline). Τυπικά βήματα προεπεξεργασίας περιλαμβάνουν τον καθαρισμό αλλοιωμένων ή ελλειπόντων τιμών, την κανονικοποίηση ή κλιμακοθέτηση χαρακτηριστικών, ή την κωδικοποίηση κατηγορικών μεταβλητών [178]. Βλέπε επίσης: δεδομένα, μηχανική μάθηση, αλγόριθμος, ML pipeline, χαρακτηριστικό.

συσκευή ακμής Μία συσκευή ακμής (edge device) λειτουργεί στην ακμή ή κοντά στην ακμή ενός δικτύου επικοινωνίας [179]. Ο όρος ακμή αναφέρεται στην περιφέρεια του δικτύου, όπου τα δεδομένα παράγονται και υφίστανται την πρώτη τους επεξεργασία. Στη μηχανική μάθηση και συγκεκριμένα στην ομοσπονδιακή μάθηση, μία συσκευή ακμής αντιστοιχεί συνήθως σε έναν κόμβο ενός δικτύου ομοσπονδιακής μάθησης. Κάθε συσκευή ακμής αποθηκεύει τοπικά δεδομένα και υλοποιεί μέρη του ML pipeline, όπως προεπεξεργασία δεδομένων, εκπαίδευση τοπικού μοντέλου, ή εξαγωγή συμπερασμάτων [180].

Βλέπε επίσης: συσκευή, δίκτυο επικοινωνίας, δεδομένα, μηχανική μάθηση, ομοσπονδιακή μάθηση, δίκτυο ομοσπονδιακής μάθησης, ML pipeline, προεπεξεργασία, τοπικό μοντέλο, εκπαίδευση, εξαγωγή συμπερασμάτων, υπολογιστική ακμής.

σύστημα μηχανικής μάθησης Ένα σύστημα μηχανικής μάθησης (machine learning system - ML system) αποτελείται από υπολογιστικές συσκευές που μπορούν να συλλέγουν και να αποθηκεύουν δεδομένα, να εκτελούν αλγόριθμους, και να ανταλλάσσουν πληροφορίες μέσω δικτύων επικοινωνίας. Παραδείγματα των ανταλλασσόμενων πληροφοριών περιλαμβάνουν δεδομένα ή ενημερώσεις των παραμέτρων μοντέλου. Εννοιολογικά, ένα σύστημα μηχανικής μάθησης είναι διαφορετικό από έναν αλγόριθμο μηχανικής μάθησης, δηλαδή ένας αλγόριθμος προσδιορίζει την αφηρημένη υπολογιστική διαδικασία (π.χ. μία μέθοδο βελτιστοποίησης), ενώ το σύστημα προσδιορίζει το πώς αυτή η διαδικασία υλοποιείται στην πράξη [83], [181], [182]. Παραδείγματα αλγόριθμων που εκτελούνται από συσκευές εντός ενός συστήματος μηχανικής μάθησης περιλαμβάνουν μεθόδους με βάση την κλίση για την επίλυση προβλημάτων ελαχιστοποίησης εμπειρικής διακινδύνευσης.

Βλέπε επίσης: μηχανική μάθηση, συσκευή, δεδομένα, αλγόριθμος, δίκτυο επικοινωνίας, παράμετρος μοντέλου, μέθοδος βελτιστοποίησης, μέθοδος με βάση την κλίση, ελαχιστοποίηση εμπειρικής διακινδύνευσης.

σύστημα ομοσπονδιακής μάθησης Ένα σύστημα ομοσπονδιακής μάθησης (federated learning system - FL system) είναι ένα κατανεμημένο σύστημα μηχανικής μάθησης στο οποίο πολλαπλές υπολογιστικές συ-

σκευές συνεργάζονται για την εκπαίδευση μοντέλων μηχανικής μάθησης χωρίς να διαμοιράζονται τα ακατέργαστα τοπικά δεδομένα τους. Ένα σύστημα ομοσπονδιακής μάθησης χαρακτηρίζεται από ένα δίκτυο επικοινωνίας που προσδιορίζει ποιες συσκευές μπορούν να ανταλλάσσουν πληροφορίες. Εννοιολογικά, ένα σύστημα ομοσπονδιακής μάθησης είναι διαφορετικό από έναν αλγόριθμο ομοσπονδιακής μάθησης [165]. Το σύστημα προσδιορίζει τις οντότητες που συμμετέχουν, τις διασυνδέσεις τους, και τους περιορισμούς εκτέλεσης, ενώ ο αλγόριθμος προσδιορίζει τους κανόνες ενημέρωσης για τις τοπικές και καθολικές παραμέτρους μοντέλου [164], [181]. Τυπικές πληροφορίες που ανταλλάσσονται σε ένα σύστημα ομοσπονδιακής μάθησης περιλαμβάνουν παραμέτρους μοντέλου ή πληροφορίες κλίσης, αλλά όχι ακατέργαστα δεδομένα.

Βλέπε επίσης: ομοσπονδιακή μάθηση, σύστημα μηχανικής μάθησης, συσκευή, μηχανική μάθηση, μοντέλο, δεδομένα, δίκτυο επικοινωνίας, αλγόριθμος, παράμετρος μοντέλου, κλίση, δίκτυο ομοσπονδιακής μάθησης.

υπολογιστική ακμής Η υπολογιστική ακμής (edge computing) αναφέρεται στην τοποθέτηση του υπολογισμού και της αποθήκευσης δεδομένων κοντά στις πηγές παραγωγής δεδομένων, όπως αισθητήρες, κινητές συσκευές, ή ενσωματωμένα συστήματα, αντί σε κεντρικά κέντρα δεδομένων [179]. Στη μηχανική μάθηση, η υπολογιστική ακμής υποστηρίζει χαμηλής καθυστέρησης εξαγωγή συμπερασμάτων και μειωμένη επικοινωνία εκτελώντας μέρη αλγόριθμων μηχανικής μάθησης πάνω ή κοντά στις συσκευές που παράγουν τα δεδομένα [183].

Βλέπε επίσης: δεδομένα, κινητή συσκευή, μηχανική μάθηση, εξαγωγή συμπερασμάτων, αλγόριθμος, συσκευή, υπολογιστική νέφος, σύστημα

ομοσπονδιακής μάθησης, σύστημα μηχανικής μάθησης.

υπολογιστική νέφους Η υπολογιστική νέφους (cloud computing) είναι ένα υπολογιστικό παράδειγμα στο οποίο οι υπολογιστικοί πόροι όπως η επεξεργασία, η αποθήκευση, και η δικτύωση παρέχονται ως υπηρεσίες κατ' αίτηση μέσω ενός δικτύου επικοινωνίας [165], [177], [184]. Στη μηχανική μάθηση, τα συστήματα υπολογιστικής νέφους χρησιμοποιούνται συχνά για τη φιλοξενία μεγάλων συνόλων δεδομένων και την εκτέλεση αλγόριθμων μηχανικής μάθησης. Σε αντίθεση με τα συστήματα ομοσπονδιακής μάθησης, η υπολογιστική νέφους συνήθως συγκεντρώνει τα δεδομένων και τον υπολογισμό εντός κέντρων δεδομένων που διαχειρίζεται ο πάροχος.

Βλέπε επίσης: δίκτυο επικοινωνίας, μηχανική μάθηση, σύνολο δεδομένων, αλγόριθμος, σύστημα ομοσπονδιακής μάθησης, δεδομένα, σύστημα μηχανικής μάθησης.

application programming interface endpoint (API endpoint) TBC.

Byzantine device TBC.

checkpoint TBC.

checkpointing TBC.

cross-sectional data TBC.

early exit (deep learning) TBC.

Hypertext Transfer Protocol (HTTP) TBC.

machine learning pipeline (ML pipeline) TBC.

machine unlearning TBC.

membership inference attack TBC.

message passing TBC.

Model Context Protocol (MCP) TBC.

spot instance TBC.

staleness TBC.

Κανονισμός Μηχανικής Μάθησης

αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN) Εκτός από τις υπολογιστικές διαστάσεις και τις στατιστικές διαστάσεις, μία τρίτη κύρια διάσταση σχεδιασμού μεθόδων μηχανικής μάθησης είναι η αξιοπιστία τους [185]. Η Ευρωπαϊκή Ένωση (ΕΕ) έχει διατυπώσει επτά βασικές απαιτήσεις για αξιόπιστη TN (trustworthy artificial intelligence - trustworthy AI) (οι οποίες συνήθως χτίζουν πάνω σε μεθόδους μηχανικής μάθησης) [186]:

- 1) Ανθρώπινη παρέμβαση και εποπτεία·
- 2) Τεχνική στιβαρότητα και ασφάλεια·
- 3) Ιδιωτικότητα και διακυβέρνηση των δεδομένων·
- 4) Διαφάνεια·
- 5) Διαφορετικότητα, απαγόρευση των διακρίσεων και δικαιοσύνη·
- 6) Κοινωνιακή και περιβαλλοντική ευημερία·
- 7) Λογοδοσία.

Βλέπε επίσης: υπολογιστική διάσταση, στατιστική διάσταση, μηχανική μάθηση, τεχνητή νοημοσύνη (TN), στιβαρότητα, δεδομένα, διαφάνεια.

αυτοματοποιημένη λήψη αποφάσεων Η αυτοματοποιημένη λήψη αποφάσεων (automated decision-making) αναφέρεται στις εφαρμογές μηχανικής μάθησης που χρησιμοποιούν προβλέψεις που παράγονται από ένα εκπαιδευμένο μοντέλο απευθείας (δηλαδή χωρίς ανθρώπινη παρέμβαση) για τη λήψη αποφάσεων που επηρεάζουν άτομα. Με βάση τον ΓΚΠΔ,

τα άτομα έχουν το δικαίωμα να μην υπόκεινται σε αποφάσεις που βασίζονται μόνο σε αυτοματοποιημένη επεξεργασία, όταν αυτές οι αποφάσεις έχουν νομικές ή όμοια σημαντικές επιδράσεις, εκτός εάν υλοποιούνται κατάλληλα μέτρα προστασίας (π.χ. ανθρώπινη εποπτεία, δυνατότητα αμφισβήτησης, ή ρητή συγκατάθεση).

Βλέπε επίσης: μηχανική μάθηση, πρόβλεψη, μοντέλο, ΓΚΠΔ.

γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ) Ο

ΓΚΠΔ (general data protection regulation - GDPR) θεσπίστηκε από την ΕΕ και τέθηκε σε ισχύ από τις 25 Μαΐου 2018 [90]. Διαφυλάσσει την ιδιωτικότητα και τα δικαιώματα δεδομένων των ατόμων στην ΕΕ. Ο ΓΚΠΔ έχει σημαντικές επιπτώσεις για το πώς συλλέγονται δεδομένα, πώς αποθηκεύονται, και πώς χρησιμοποιούνται στις εφαρμογές μηχανικής μάθησης. Βασικές διατάξεις περιλαμβάνουν τα εξής:

- Αρχή της ελαχιστοποίησης των δεδομένων: Τα συστήματα μηχανικής μάθησης θα πρέπει να χρησιμοποιούν μόνο την απαραίτητη ποσότητα προσωπικών δεδομένων για τον σκοπό τους.
- Διαφάνεια και εξηγησιμότητα: Τα συστήματα μηχανικής μάθησης θα πρέπει να επιτρέπουν στους χρήστες τους να κατανοούν πώς τα συστήματα παίρνουν αποφάσεις που επηρεάζουν τους χρήστες.
- Δικαιώματα των υποκειμένων των δεδομένων: Οι χρήστες θα πρέπει να έχουν την ευκαιρία να έχουν πρόσβαση, να διορθώνουν, και να διαγράφουν τα προσωπικά δεδομένα τους, καθώς και να αντιτίθενται στην αυτοματοποιημένη λήψη αποφάσεων και στην κατάρτιση προφίλ.

- Λογοδοσία: Οι οργανισμοί πρέπει να εξασφαλίζουν την εύρωστη ασφάλεια δεδομένων και να αποδεικνύουν συμμόρφωση μέσω τεχνικών και τακτικών ελέγχων.

Βλέπε επίσης: δεδομένα, μηχανική μάθηση, αρχή της ελαχιστοποίησης των δεδομένων, σύστημα μηχανικής μάθησης, προσωπικά δεδομένα, διαφάνεια, εξηγησιμότητα, αυτοματοποιημένη λήψη αποφάσεων, κατάρτιση προφίλ.

διαφάνεια Η διαφάνεια είναι μία θεμελιώδης απαίτηση για αξιόπιστη ΤΝ [187].

Στο πλαίσιο μεθόδων μηχανικής μάθησης, η διαφάνεια χρησιμοποιείται συχνά εναλλακτικά με την εξηγησιμότητα [188], [189]. Ωστόσο, στο ευρύτερο πεδίο συστημάτων ΤΝ, η διαφάνεια επεκτείνεται πέρα από την εξηγησιμότητα και περιλαμβάνει την παροχή πληροφοριών σχετικά με τους περιορισμούς, την αξιοπιστία, και την επιθυμητή χρήση του συστήματος. Σε συστήματα ιατρικής διάγνωσης, η διαφάνεια απαιτεί τη γνωστοποίηση του επιπέδου εμπιστοσύνης για τις προβλέψεις που παραδίδονται από ένα εκπαιδευμένο μοντέλο. Στην πιστωτική ικανότητα, οι αποφάσεις δανεισμού που βασίζονται στην ΤΝ θα πρέπει να συνοδεύονται από εξηγήσεις παραγόντων που συμβάλλουν, όπως το επίπεδο εισοδήματος ή το πιστωτικό ιστορικό. Αυτές οι εξηγήσεις επιτρέπουν τους ανθρώπους (π.χ. έναν αιτούντα δανείου) να κατανοήσουν και να αμφισβητήσουν αυτοματοποιημένες αποφάσεις. Κάποιες μέθοδοι μηχανικής μάθησης προσφέρουν εγγενώς διαφάνεια. Για παράδειγμα, η λογιστική παλινδρόμηση παρέχει ένα ποσοτικό μέτρο της αξιοπιστίας της ταξινόμησης μέσω της τιμής $|h(\mathbf{x})|$. Ένα ακόμα παράδειγμα αποτελούν τα δέντρα αποφάσεων,


καθώς επιτρέπουν κανόνες αποφάσεων που είναι αναγνώσιμοι από άνθρωπο [107]. Η διαφάνεια επίσης απαιτεί μία σαφή ένδειξη όταν ένας χρήστης αλληλεπιδρά με ένα σύστημα TN. Για παράδειγμα, τα chatbots που λειτουργούν με TN θα πρέπει να ειδοποιούν τους χρήστες ότι αλληλεπιδρούν με ένα αυτοματοποιημένο σύστημα και όχι με άνθρωπο. Επιπλέον, η διαφάνεια συμπεριλαμβάνει περιεκτική τεκμηρίωση που περιγράφει λεπτομερώς τον σκοπό και τις επιλογές σχεδιασμού που αποτελούν τη βάση του συστήματος TN. Για παράδειγμα, τα φύλλα δεδομένων μοντέλων [146] και οι κάρτες συστημάτων TN [190] βοηθούν τους επαγγελματίες να κατανοήσουν τις περιπτώσεις επιθυμητής χρήσης και τους περιορισμούς ενός συστήματος TN [191].

Βλέπε επίσης: αξιόπιστη TN, μηχανική μάθηση, εξηγησιμότητα, σύστημα TN, πρόβλεψη, μοντέλο, TN, εξήγηση, λογιστική παλινδρόμηση, μέτρο, ταξινόμηση, δέντρο αποφάσεων.

εξηγησιμότητα Ορίζουμε την (υποκειμενική) εξηγησιμότητα (explainability) μίας μεθόδου μηχανικής μάθησης ως το επίπεδο προσομοιωσιμότητας [192] των προβλέψεων που παραδίδονται από ένα σύστημα μηχανικής μάθησης σε έναν χρήστη που είναι άνθρωπος. Ποσοτικά μέτρα της (υποκειμενικής) εξηγησιμότητας ενός εκπαιδευμένου μοντέλου μπορούν να κατασκευαστούν συγκρίνοντας τις προβλέψεις του με τις προβλέψεις που παρέχονται από έναν χρήστη σε ένα σύνολο ελέγχου [106], [192]. Εναλλακτικά, μπορούμε να χρησιμοποιήσουμε πιθανοτικά μοντέλα για δεδομένα και να μετρήσουμε την εξηγησιμότητα ενός εκπαιδευμένου μοντέλου μηχανικής μάθησης μέσω της υπό συνθήκης (διαφορικής) εντροπίας των προβλέψεών του, δεδομένων των προβλέψεων του χρήστη [188], [193].

Βλέπε επίσης: μηχανική μάθηση, πρόβλεψη, σύστημα μηχανικής μάθησης, μέτρο, μοντέλο, σύνολο ελέγχου, πιθανοτικό μοντέλο, δεδομένα, εντροπία, αξιόπιστη TN, ομαλοποίηση.

ερμηνευσιμότητα Μία μέθοδος μηχανικής μάθησης είναι ερμηνεύσιμη για έναν χρήστη που είναι άνθρωπος αν μπορεί να κατανοήσει τη διαδικασία απόφασης της μεθόδου. Μία προσέγγιση για την ανάπτυξη ενός ακριβούς ορισμού της ερμηνευσιμότητας (interpretability) είναι μέσω της έννοιας της προσομοιωσιμότητας, δηλαδή τη δυνατότητα ενός ανθρώπου να προσομοιώνει διανοητικά τη συμπεριφορά του μοντέλου [192], [193], [194], [195], [196]. Αυτή η ιδέα έχει ως εξής: Αν ένας χρήστης που είναι άνθρωπος καταλαβαίνει μία μέθοδο μηχανικής μάθησης, τότε θα πρέπει να έχει τη δυνατότητα να αναμένει τις προβλέψεις της σε ένα σύνολο ελέγχου. Παρουσιάζουμε ένα τέτοιο σύνολο ελέγχου στο Σχ. 94, το οποίο επίσης απεικονίζει δύο υποθέσεις $\hat{h}$ και $\hat{h}'$ που έχουν μαθευτεί. Η μέθοδος μηχανικής μάθησης που παράγει την υπόθεση $\hat{h}$ είναι ερμηνεύσιμη στον χρήστη που είναι άνθρωπος και εξοικειωμένος με την έννοια της γραμμικής απεικόνισης. Εφόσον η $\hat{h}$ αντιστοιχεί σε μία γραμμική απεικόνιση, ο χρήστης μπορεί να αναμένει τις προβλέψεις της $\hat{h}$ στο σύνολο ελέγχου. Αντίθετα, η μέθοδος μηχανικής μάθησης που παραδίδει την $\hat{h}'$ δεν είναι ερμηνεύσιμη, επειδή η συμπεριφορά της δεν συμβαδίζει πλέον με τις προσδοκίες του χρήστη.



Σχ. 94. Μπορούμε να αξιολογήσουμε την ερμηνευσιμότητα εκπαιδευμένων μοντέλων μηχανικής μάθησης $\hat{h}$ και $\hat{h}'$ συγκρίνοντας τις προβλέψεις τους με τις ψευδο-ετικέτες που παράγονται από έναν χρήστη που είναι άνθρωπος για το D' .

Η έννοια της ερμηνευσιμότητας σχετίζεται στενά με την έννοια της εξηγησιμότητας, καθώς και οι δύο στοχεύουν να κάνουν τις μεθόδους μηχανικής μάθησης πιο κατανοητές στους ανθρώπους. Στο πλαίσιο του Σχ. 94, η ερμηνευσιμότητα μίας μεθόδου μηχανικής μάθησης $\hat{h}$ απαιτεί ο χρήστης που είναι άνθρωπος να μπορεί να αναμένει τις προβλέψεις της σε ένα αυθαίρετο σύνολο ελέγχου. Αυτό έρχεται σε αντίθεση με την εξηγησιμότητα, όπου στον χρήστη παρέχονται εξηγήσεις για να καταλάβει καλύτερα τις προβλέψεις της $\hat{h}$ σε ένα συγκεκριμένο σύνολο ελέγχου D' . Αυτές οι εξηγήσεις μπορεί να έχουν τη μορφή απεικονίσεων σημαντικότητας ή παραδειγμάτων αναφοράς από το σύνολο εκπαίδευσης

Βλέπε επίσης: μηχανική μάθηση, μοντέλο, πρόβλεψη, σύνολο ελέγχου, υπόθεση, γραμμική απεικόνιση, προσδοκία, σύνολο εκπαίδευσης, ετικέτα, εξηγησιμότητα, εξήγηση, απεικόνιση, αξιόπιστη TN, ομαλοποίηση, LIME.

κατάρτιση προφίλ Η κατάρτιση προφίλ (profiling) στοχεύει στην αναγνώριση μοτίβων και στην εξαγωγή συμπερασμάτων σχετικά με άτομα βάσει των δεδομένων τους. Οι τεχνικές κατάρτισης προφίλ χρησιμοποιούν μεθόδους μηχανικής μάθησης για να προβλέψουν την επίδοση ατόμων στη δουλειά, την οικονομική τους κατάσταση, την υγεία ή τις προσωπικές τους προτιμήσεις. Η κατάρτιση προφίλ είναι καίρια για τη στοχευμένη διαφήμιση, την πιστωτική ικανότητα, τον εντοπισμό απάτης, και τις εξατομικευμένες υπηρεσίες. Ο ΓΚΠΔ επιβάλλει αυστηρές απαιτήσεις σε οργανισμούς που ασχολούνται με δραστηριότητες κατάρτισης προφίλ, ώστε να εξασφαλίζεται η προστασία των δικαιωμάτων των ατόμων [90].

Βλέπε επίσης: δεδομένα, μηχανική μάθηση, ΓΚΠΔ.

προσωπικά δεδομένα Προσωπικά δεδομένα (personal data) είναι κάθε πληροφορία που σχετίζεται με ένα ταυτοποιημένο ή ταυτοποιήσιμο φυσικό πρόσωπο (δηλαδή το υποκείμενο των δεδομένων). Ένα φυσικό πρόσωπο είναι ταυτοποιήσιμο αν μπορεί να ταυτοποιηθεί, άμεσα ή έμμεσα, συγκεκριμένα με αναφορά σε ένα αναγνωριστικό όπως όνομα, αριθμό ταυτοποίησης, δεδομένα τοποθεσίας, διαδικτυακό αναγνωριστικό, ή έναν ή περισσότερους παράγοντες συγκεκριμένα για τη σωματική, φυσιολογική, γενετική, διανοητική, οικονομική, πολιτιστική, ή κοινωνική ταυτότητα αυτού του ατόμου [90]. Στα συστήματα μηχανικής μάθησης, προσωπικά δεδομένα μπορεί να εμφανίζονται στα δεδομένα εκπαίδευσης, στις εισόδους του μοντέλου, στις ενδιάμεσες αναπαραστάσεις (π.χ. διανύσματα χαρακτηριστικών ή εμφυτεύσεις), ή στις εξόδους του μοντέλου, εφόσον οι πληροφορίες σχετίζονται με ένα ταυτοποιήσιμο φυσικό πρόσωπο. Ο Κανονισμός της ΕΕ για την ΤΝ (Artificial Intelligence Act - AI Act) δεν εισάγει έναν

ξεχωριστό ορισμό για τα προσωπικά δεδομένα· αντ' αυτού, κάθε φορά που ένα σύστημα ΤΝ επεξεργάζεται προσωπικά δεδομένα, εφαρμόζονται πλήρως ο ορισμός και οι υποχρεώσεις του ΓΚΠΔ.

Βλέπε επίσης: δεδομένα, σύστημα μηχανικής μάθησης, εκπαίδευση, μοντέλο, διάνυσμα χαρακτηριστικών, έξοδος, σύστημα ΤΝ, ΓΚΠΔ.

προϊόν βαθυπαραποίησης Τα προϊόντα βαθυπαραποίησης (deep fakes) είναι συνθετικά μέσα που παράγονται ή τροποποιούνται σημαντικά από ένα σύστημα ΤΝ, έτσι ώστε να φαίνεται ψευδώς ότι απεικονίζουν ένα πραγματικό πρόσωπο, αντικείμενο, ή γεγονός. Τα προϊόντα βαθυπαραποίησης παράγονται συνήθως με τη χρήση παραγωγικών μεθόδων, οι οποίες εκπαιδεύονται να μιμούνται οπτικά, ακουστικά, ή οπτικοακουστικά χαρακτηριστικά πραγματικών δεδομένων. Από άποψη συστήματος, τα προϊόντα βαθυπαραποίησης χαρακτηρίζονται από μία σκόπιμη ασυμβατικότητα μεταξύ του παρατηρήσιμου περιεχομένου και της πραγματικής προέλευσης, γεγονός που μπορεί να οδηγήσει σε απάτη, παραπληροφόρηση, ή χειραγώγηση.

Βλέπε επίσης: σύστημα ΤΝ, γεγονός, δεδομένα.

σύστημα τεχνητής νοημοσύνης (σύστημα ΤΝ) Ο Κανονισμός της ΕΕ για την ΤΝ (AI Act) [197] ορίζει ένα σύστημα ΤΝ (artificial intelligence system - AI system) ως ένα σύστημα βασισμένο σε μηχανή που έχει σχεδιαστεί να λειτουργεί με μεταβαλλόμενα επίπεδα αυτονομίας και που μπορεί να επιδεικνύει προσαρμοστικότητα (π.χ. επανεκπαίδευση μοντέλου) μετά την ανάπτυξή του. Τα συστήματα ΤΝ υπολογίζουν προβλέψεις που μπορούν να επηρεάσουν περιβάλλοντα ή αποφάσεις [198]. Σε

συμφωνία με αυτόν τον ορισμό, οι κανονιστικές υποχρεώσεις και οι κατηγορίες κινδύνου εφαρμόζονται στο επίπεδο του συστήματος TN και όχι στο επίπεδο μεμονωμένων μοντέλων ή αλγόριθμων. Η εξέταση σε επίπεδο συστήματος τονίζει ότι οι ιδιότητες όπως η στιβαρότητα, η δικαιοσύνη, και η διαφάνεια προκύπτουν από την αλληλεπίδραση των μοντέλων, των δεδομένων, και του λειτουργικού πλαισίου, και όχι από μεμονωμένες συνιστώσες.

Βλέπε επίσης: TN, μοντέλο, πρόβλεψη, αλγόριθμος, στιβαρότητα, διαφάνεια, δεδομένα.

σύστημα τεχνητής νοημοσύνης υψηλού κινδύνου (σύστημα TN υψηλού κινδύνου)

Ένα υποσύνολο των συστημάτων TN ταξινομείται ως υψηλού κινδύνου λόγω της δυνατότητάς του να επηρεάζει σημαντικά την ασφάλεια, τα θεμελιώδη δικαιώματα, ή τις κοινωνικές λειτουργίες ζωτικής σημασίας. Τα συστήματα TN υψηλού κινδύνου (high-risk artificial intelligence system - high-risk AI system) υπόκεινται σε αυστηρές κανονιστικές απαιτήσεις με βάση τον Κανονισμό της ΕΕ για την TN (AI Act), οι οποίες περιλαμβάνουν αξιολογήσεις συμμόρφωσης, διαχείριση κινδύνου, υποχρεώσεις διαφάνειας, και παρακολούθηση μετά τη διάθεση στην αγορά [198]. Παραδείγματα συστημάτων TN υψηλού κινδύνου περιλαμβάνουν εκείνα που χρησιμοποιούνται σε υποδομές ζωτικής σημασίας, στην εκπαίδευση, στην απασχόληση, στην επιβολή του νόμου, και στη βιομετρική ταυτοποίηση. Βλέπε επίσης: σύστημα TN, διαφάνεια.

counterfactual explanation TBC.

FAIR principles TBC.

provider (AI Act) TBC.

SHapley Additive exPlanations (SHAP) TBC.

Index

αβεβαιότητα	116	αλγόριθμος k -μέσων	122
αθροιστική συνάρτηση κατανομής	28	αλυσίδα Markov	32
αισιοδοξία παρά την αβεβαιότητα	116	αμερόληπτος εκτιμητής	32
αιτιότητα	28	αμοιβαίες πληροφορίες	124
αιτιότητα κατά Granger	29	αμφικλινής παλινδρόμηση	124
ακολουθία	29	αμφιμονοσήμαντη	32
ακολουθία Cauchy	30	αναδρομικό νευρωνικό δίκτυο	126
ακραία τιμή	119	ανάκληση	127
ακρίβεια (accuracy)	118	ανάλυση ιδιαζουσών τιμών	33
ακρίβεια (precision)	119	ανάλυση ιδιοτιμών	33
αλγεβρική συνδεσιμότητα	30	ανάλυση κύριων συνιστωσών	127
αλγόριθμος	120	ανάλυση Schur	34
αλγόριθμος εγγύτητας	31	ανάστροφος	35
αλγόριθμος προσδοχίας-μεγιστοποίησης	31	ανεξάρτητες και ταυτόσημα κατανεμημένες	35
αλγόριθμος του Lloyd	121	ανισότητα συγκέντρωσης	35
		ανισότητα Cauchy-Schwarz	36

ανισότητα του Chebyshev	36	απόκλιση Kullback-Leibler (απόκλιση KL)	41
ανισότητα του Hoeffding	37	απόκλιση Rényi	42
ανισότητα του Markov	38	απόκριση	116
ανορθωμένη γραμμική μονάδα	129	απόσταση	42
ανταμοιβή	129	αποτελεσματική διάσταση	134
αντικειμενική συνάρτηση	130	απώλεια	134
αντιστρέψιμος	39	απώλεια απόλυτου σφάλματος	134
αντιστροφή μοντέλου	289	απώλεια άρθρωσης	137
αντίστροφος πίνακας	39	απώλεια 0/1	116
άνω φράγμα εμπιστοσύνης (ΑΦΕ)	131	απώλεια τετραγωνικού σφάλματος	137
αξιολόγηση πολιτικής	281	απώλεια Huber	138
αξιόπιστη τεχνητή νοημοσύνη (αξιόπιστη TN)	303	αριθμήσιμο	42
απεικόνιση	40	αριθμός συνθήκης	43
απεικόνιση χαρακτηριστικών	132	αρχή της ελαχιστοποίησης των δεδομένων	138
απλή συνάρτηση	40	αυστηρά κυρτή	44
απόκλιση	133	αυτοεποπτευόμενη μάθηση	138
απόκλιση Bregman	41		

αυτοκωδικοποιητής	139	γενικευμένη ολική μεταβολή	142
αυτοκωδικοποιητής αποθορυβοποίησης	44	γενικευμένο προσθετικό μοντέλο	142
αυτόματο	290	γενίκευση	142
αυτοματοποιημένη λήψη αποφάσεων	303	γενικός κανονισμός για την προστασία δεδομένων (ΓΚΠΔ)	304
βαθιά μάθηση	140	γεωμετρική διάμεσος	46
βαθμός κόμβου	44	γινόμενο Kronecker	142
βαθμός συσχέτισης	140	Γκαουσιανή	46
βαθύ δίκτυο	140	Γκαουσιανή διαδικασία	47
βάρος	140	Γκαουσιανή τυχαία μεταβλητή	47
βάρος ακμής	141	Γκαουσιανό μοντέλο μείγματος	143
βάση	45	γραμμικά ανεξάρτητο	47
βάση αναφοράς	142	γραμμικά ελάχιστα τετράγωνα	144
βελτιστοποίηση	45	γραμμικά εξαρτημένο	47
βήμα κλίσης	45	γραμμική απεικόνιση	48
γεγονός	45	γραμμική διακρίνουσα ανάλυση	144
γείτονας	142	γραμμική παλινδρόμηση	145
γειτονιά	46	γραμμικό μοντέλο	148

γραμμικός ταξινομητής	148	διαδικτυακή μάθηση	154
γραμμικός τελεστής	48	διαδικτυακός αλγόριθμος	155
γράφος	48	διακινδύνευση	156
γράφος ομοιότητας	148	διακινδύνευση Bayes	156
γράφος Erdős–Rényi	49	διακριτή τυχαία μεταβλητή	53
δεδομένα	149	διακύμανση	53
δεδομένα σε μορφή πίνακα	149	διακύμανση δείγματος	53
δείγμα	50	διάμεσος	54
δειγματικός χώρος	149	διάνυσμα	54
δείκτρια συνάρτηση	51	διάνυσμα αποκρίσεων	157
δέντρο αποφάσεων	150	διάνυσμα εισόδου	157
δέσμη	151	διάνυσμα εξόδου	157
δηλητηρίαση δεδομένων	291	διάνυσμα ετικετών	157
δηλητηρίαση μοντέλου	292	διάνυσμα στόχων	158
διάγνωση	152	διανυσματικός χώρος	55
διάγραμμα διασποράς	153	διάνυσμα χαρακτηριστικών	158
διαγωνοποιήσιμος	52	διαρροή ιδιωτικότητας	158
διαδικασία απόφασης Markov	281	διάσταση	56

διάσταση Vapnik–Chervonenkis	159	δομική ελαχιστοποίηση διακινδύνευσης	164
διασταυρούμενη εντροπία	159	δομικό αιτιώδες μοντέλο	58
διασταυρούμενη επικύρωση k -αναδιπλώσεων	160	δυαδική διασταυρούμενη εντροπία	165
δίαιλος ιδιωτικότητας	161	δυαδική ταξινόμηση	165
διαφάνεια	305	δυϊκή νόρμα	58
διαφορική εντροπία	57	δυϊκή συνάρτηση Lagrange	58
διαφορική ιδιωτικότητα	161	δυϊκό πρόβλημα	58
διαχρονικά δεδομένα	292	δυναμικό σύστημα	294
διεπαφή προγραμματισμού εφαρμογών	293	έκβαση	58
δίκτυο επικοινωνίας	291	εκθετική οικογένεια	58
δίκτυο ομοσπονδιακής μάθησης	162	εκπαίδευση	165
δικτυωμένα δεδομένα	164	εκτιμητής	58
δικτυωμένη εκθετική οικογένεια	164	εκτιμητής Bayes	166
δικτυωμένη ομοσπονδιακή μάθηση	164	εκ των προτέρων κατανομή	59
δικτυωμένο μοντέλο	164	εκ των υστέρων κατανομή	59
		εκ των υστέρων (πρόβλεψη)	59
		ελάχιστα τετράγωνα	166

ελάχιστο	59	εξηγησιμότητα	306
ελαχιστοποίηση γενικευμένης ολικής μεταβολής	167	εξίσωση σταθερού σημείου	60
ελαχιστοποίηση εμπειρικής διακινδύνευσης	167	έξοδος	173
		επανάληψη	173
εμβαδόν κάτω από την καμπύλη	168	επανάληψη σταθερού σημείου	61
εμπειρική διακινδύνευση	169	επανάληψη τιμής	285
εμπειρική κατανομή	59	επαυξημένος κατά Lagrange	61
εμπειρογνώμονας	169	επαύξηση δεδομένων	174
ενέργεια	283	επεξεργασία φυσικής γλώσσας (ΕΦΓ)	175
ενεργοποίηση	170	επιγράφος	61
ενισχυτική μάθηση	284	επίθεση	175
ενσωμάτωση	170	επίθεση άρνησης υπηρεσιών	294
εντροπία	59	επίθεση της ιδιωτικότητας	176
εξαγωγή συμπερασμάτων	170	επικύρωση	176
εξήγηση	171	επιλογή μοντέλου	177
εξηγήσιμη ελαχιστοποίηση εμπειρικής διακινδύνευσης	172	εργασία μάθησης	178
εξηγήσιμη μηχανική μάθηση	173	ερμηνευσιμότητα	307

Ερμιτιανός	61	ιδιοδιάνυσμα	65
Ερσιανός	61	ιδιότητα Markov	66
εσωτερικό γινόμενο	63	ιδιοτιμή	66
ετικέτα	180	ιστόγραμμα	182
ευαισθησία	180	ισχυρά κυρτή	66
ευαίσθητο ιδιοχαρακτηριστικό	180	ίχνος	66
Ευκλείδεια απόσταση	63	καθεστώς υψηλής διάστασης	183
Ευκλείδεια νόρμα	63	κάθετο διάνυσμα	66
Ευκλείδειος χώρος	63	κάθοδος κλίσης	184
ευστάθεια	180	κάθοδος υποκλίσης	185
ημιεποπτευόμενη μάθηση	182	κανονικές εξισώσεις	186
ημιχώρος	63	κανονική κατονομή	66
θετικά ημιορισμένος	64	κανονικοποίηση δεδομένων	187
θετικά ορισμένος	64	κανονικός πίνακας	66
θεώρημα σταθερού σημείου του Banach	65	κατακόρυφη ομοσπονδιακή μάθηση	187
Ιακωβιανός πίνακας	65	κατανεμημένος αλγόριθμος	187
ιδιάζουσα τιμή	65	κατανομή πιθανότητας	67

κατανομή πιθανότητας υπό συνθήκη	67	Λαπλασιανός πίνακας	70
κατάρτιση προφίλ	308	λεία	70
κατάσταση	68	λειτουργικός χαρακτηριστικός δέκτης	189
κατευθυνόμενος γράφος	68	λήμμα Johnson–Lindenstrauss (λήμμα JL)	70
κατευθυνόμενος κύκλος	68	λογιστική απώλεια	190
κατευθυνόμενος μη κυκλικός γράφος	68	λογιστική παλινδρόμηση	191
κεντρικό οριακό θεώρημα	68	μάθηση δέσμης	191
κέντρο βάρους συστάδας	187	μάθηση με μεταφορά	191
κερκόπορτα	295	μάθηση πολυδιεργασίας	191
κινητή συσκευή	297	μάθηση χαρακτηριστικών	192
κλίση	68	μαλακή ετικέτα	193
κριτήριο τερματισμού	188	μαλακή συσταδοποίηση	194
κυρτή βελτιστοποίηση	69	μεγάλο γλωσσικό μοντέλο	194
κυρτή συσταδοποίηση	188	μέγεθος βήματος	195
κυρτό	69	μέγεθος δείγματος	195
κωδικοποιητής	189	μέγιστη πιθανοφάνεια	71
Λαγκρανζιανή	69	μέγιστο	71

μέθοδος βελτιστοποίησης	71	μετασχηματιστής	201
μέθοδος διάχυσης	196	μετρήσιμο	75
μέθοδος εναλλασσόμενων διευθύνσεων των πολλαπλασιαστών	72	μετρική	77
		μετρικός χώρος	77
μέθοδος με βάση την κλίση	196	μέτρο	79
μέθοδος πυρήνα	197	μη κατευθυνόμενος γράφος	79
μέθοδος του Newton	72	μη λεία	79
μέθοδος των πολλαπλασιαστών	72	μη παραμετρική	201
μέθοδος Jacobi	198	μηχανή διανυσμάτων υποστήριξης (ΜΔΥ)	202
μείωση της διαστασιμότητας	198	μηχανική μάθηση	202
μερική παράγωγος	74	μηχανική μάθηση ως υπηρεσία	297
μεροληψία	198	μοντέλο	204
μέση τιμή	74	μοντέλο θεμελίωσης	205
μέση τιμή δείγματος	199	μοντέλο στοχαστικής ομάδας	205
μέσο απόλυτο σφάλμα	199	νευρώνας	206
μέσος βαθμός κόμβου	75	νευρωνικό δίκτυο γράφου	206
μέσο τετραγωνικό σφάλμα	200	νόμος των μεγάλων αριθμών	79
μέσο τετραγωνικό σφάλμα εκτίμησης	200		

νόρμα	79	όριο απόφασης	208
ολική μεταβολή	79	όρος ποινής	208
ολοκλήρωμα Lebesgue	80	παλινδρόμηση	209
ολοκληρώσιμη	80	παλινδρόμηση ελάχιστης απόλυτης απόκλισης	210
ομάδα	80	παλινδρόμηση Huber	211
ομαλοποιημένη ελαχιστοποίηση απώλειας	206	παλινδρόμηση k -πλησιέστερων γειτόνων	211
ομαλοποιημένη ελαχιστοποίηση εμπειρικής διακινδύνευσης	206	παραγωγίσιμη	82
ομαλοποίηση	206	παράγωγος	82
ομαλοποιητής	206	παραδοχή ανεξάρτητων και ταυτόσημα κατανεμημένων	212
ομοιότητα συνημιτόνου	207	παραδοχή συσταδοποίησης	212
ομοσπονδιακή μάθηση	207	παραλληλισμός δεδομένων	212
οπισθοδιάδοση	207	παραλληλισμός μοντέλου	213
ορθομοναδιαίος πίνακας	80	παραμετρικό μοντέλο	214
οριζόντια ομοσπονδιακή μάθηση	207	παραμετρικός χώρος	215
ορίζουσα	81	παράμετρος	216
όριο	82	παράμετρος μοντέλου	216

πεδίο ορισμού	82	πίνακας χαρακτηριστικών	219
πεδίο τιμών	83	πλήρους τάξης	87
περιβάλλον	285	πλησιέστερος γείτονας	219
περιθώρια κατανομή	83	πολιτική	285
περιθωριοποίηση	83	πολυμεταβλητή κανονική κατανομή	87
περιορισμένο πρόβλημα βελτιστοποίησης	83	πολυπλοκότητα Rademacher	220
περιοχή αποφάσεων	217	πολυωνυμική παλινδρόμηση	221
πιθανότητα	218	πραγμάτωση	221
πιθανοτική ανάλυση κύριων συνιστωσών	84	πράκτορας	286
πιθανοτικό μοντέλο	84	προβεβλημένη κάθοδος κλίσης	87
πίνακας	84	πρόβλεψη	221
πίνακας δεδομένων	218	πρόβλημα βελτιστοποίησης	88
πίνακας σύγκυσης	218	πρόβλημα κυρτής βελτιστοποίησης	89
πίνακας συνδιακύμανσης	86	προβολή	89
πίνακας συνδιακύμανσης δείγματος	87	προγνωστικός παράγοντας	222
πίνακας σχεδιασμού	218	προεικόνα	89
		προεπεξεργασία	298

προϊόν βαθυπαραποίησης	310	σταθμισμένος γράφος	90
προσδοκία	222	στατιστική διάσταση	232
προσδοκία υπό συνθήκη	89	στιβαρότητα	233
προσοχή	223	στοίβαξη	233
προστασία της ιδιωτικότητας	224	στοχαστική	90
προσωπικά δεδομένα	309	στοχαστική διαδικασία	90
πυρήνας (μέθοδος πυρήνα)	225	στοχαστική κάθοδος κλίσης	235
ρήτρα μεταβολής γνώμης	286	στοχαστικός αλγόριθμος	236
ροπογεννήτρια συνάρτηση	90	στόχος	237
ρυθμός μάθησης	227	στρωματοποίηση	237
σ-άλγεβρα	90	στρωματοποίηση διακινδύνευσης	238
σημείο δεδομένων	228	στρώμα (layer)	238
σημείο δεδομένων με ετικέτα	231	στρώμα (stratum)	239
σκληρή συσταδοποίηση	231	σύγκλιση	91
σ-σώμα	90	συζυγής ανάστροφος	92
σταθερό σημείο	90	συζυγής εκ των προτέρων κατανομή	92
στάθμιση δείγματος	232	συμμεταβλητή	240
σταθμισμένα ελάχιστα τετράγωνα	232		

συμμετρικός πίνακας	92	συνθήκη μηδενικής κλίσης	241
συνάρτηση	92	συνθήκη ορθογωνιότητας	116
συνάρτηση απώλειας	240	σύνολο	242
συνάρτηση ενεργοποίησης	241	σύνολο δεδομένων	244
συνάρτηση κατάστασης-τιμής	286	σύνολο εκπαίδευσης	246
συνάρτηση μάζας πιθανότητας	93	σύνολο ελέγχου	247
συνάρτηση μάζας πιθανότητας υπό συνθήκη	93	σύνολο επικύρωσης	247
συνάρτηση πιθανοφάνειας	93	συσκευή	248
συνάρτηση πυκνότητας πιθανότητας	94	συσκευή ακμής	298
συνάρτηση συνδιακύμανσης	95	συστάδα	248
συνάρτηση τιμής	287	συσταδοποίηση	249
συνδεδεμένος	95	συσταδοποίηση γράφου	250
συνδιακύμανση	96	συσταδοποίηση με βάση τη ροή	250
συνέχεια κατά Lipschitz	96	σύστημα μηχανικής μάθησης	299
συνεχής	97	σύστημα ομοσπονδιακής μάθησης	299
συνθήκες Karush–Kuhn–Tucker (συνθήκες KKT)	98	σύστημα τεχνητής νοημοσύνης (σύστημα TN)	310
		σύστημα τεχνητής νοημοσύνης υψηλού κινδύνου (σύστημα TN υψηλού κινδύνου)	311

συστολικός τελεστής	98	τεχνητή νοημοσύνη (TN)	256
σφάλμα εκπαίδευσης	250	τεχνητό νευρωνικό δίκτυο (TNΔ)	257
σφάλμα εκτίμησης	251	τεχνητός νευρώνας	258
σφάλμα επικύρωσης	251	τμηματοποίηση εικόνας	260
σφάλμα συσταδοποίησης	252	τοπικά σταθμισμένη μάθηση	260
σχεσιακό μοντέλο	253	τοπικό μοντέλο	260
σώμα	99	τοπικό σύνολο δεδομένων	261
τάξη	99	τυπική απόκλιση	101
ταξινόμηση	254	τυπικό κανονικό τυχαίο διάνυσμα	101
ταξινόμηση πολλαπλών ετικετών	254	τυπικό σύνολο	102
ταξινομητής	255	τυχαία μεταβλητή	102
τεκμαρτή εγγραφή	255	τυχαία προβολή	261
τελεστής	99	τυχαίο δάσος	261
τελεστής εγγύτητας	100	τυχαίο πείραμα	103
τελεστής ελάχιστης απόλυτης συρρίκνωσης και επιλογής	255	τυχαίος γεωμετρικός γράφος	103
τελεστής Bellman	287	υπερεπίπεδο	105
τετραγωνική συνάρτηση	256	υπερπαράμετρος	261

υπερπροσαρμογή	262	χάσμα γενίκευσης	270
υπόθεση	263	χάσμα διϋκότητας	108
υποκλίση	105	χωρική συσταδοποίηση	271
υπολογιστική ακμής	300	εφαρμογών με θόρυβο με βάση την πυκνότητα	
υπολογιστική διάσταση	264	χώρος ενεργειών	288
υπολογιστική νέφους	301	χώρος ετικετών	272
υποπροσαρμογή	264	χώρος καταστάσεων	108
υποστηρίζον υπερεπίπεδο	106	χώρος με νόρμα	108
υποχώρος	106	χώρος μέτρου	109
φάσμα	106	χώρος πιθανοτήτων	109
φασματική ανάλυση	107	χώρος στηλών	110
φασματική συσταδοποίηση	265	χώρος υποθέσεων	273
φασματογράφημα	268	χώρος χαρακτηριστικών	275
Φινλανδικό Μετεωρολογικό Ινστιτούτο	289	χώρος Hilbert	111
φράγμα Chernoff	107	ψευδοαντίστροφος	112
χαρακτηριστική συνάρτηση	107	ψευδοσυστολικός τελεστής	113
χαρακτηριστικό	269	bootstrap	276
		bootstrap aggregation	277

infimum (ή μέγιστο κάτω φράγμα)	113	R^2 (συντελεστής προσδιορισμού)	279
proximable	114	supremum (ή ελάχιστο άνω φράγμα)	114
Q-μάθηση	279	token	279

Βιβλιογραφικές Αναφορές

- [1] W. Rudin, *Real and Complex Analysis*, 3rd ed. New York, NY, USA: McGraw-Hill, 1987.
- [2] W. Rudin, *Principles of Mathematical Analysis*, 3rd ed. New York, NY, USA: McGraw-Hill, 1976.
- [3] G. H. Golub and C. F. Van Loan, *Matrix Computations*, 4th ed. Baltimore, MD, USA: The Johns Hopkins Univ. Press, 2013.
- [4] G. H. Golub and C. F. Van Loan, “An analysis of the total least squares problem,” *SIAM J. Numer. Anal.*, vol. 17, no. 6, pp. 883–893, Dec. 1980, doi: 10.1137/0717073.
- [5] A. Klenke, *Probability Theory: A Comprehensive Course*, 3rd ed. Cham, Switzerland: Springer Nature, 2020.
- [6] P. Billingsley, *Probability and Measure*, 2nd ed. New York, NY, USA: Wiley, 1986.
- [7] D. P. Bertsekas and J. N. Tsitsiklis, *Introduction to Probability*, 2nd ed. Belmont, MA, USA: Athena Scientific, 2008.
- [8] A. Jung, *Machine Learning: The Basics*. Singapore, Singapore: Springer Nature, 2022.
- [9] R. B. Ash, *Probability and Measure Theory*, 2nd ed. San Diego, CA, USA: Academic, 2000.

- [10] A. Papoulis and S. U. Pillai, *Probability, Random Variables, and Stochastic Processes*, 4th ed. New York, NY, USA: McGraw-Hill Higher Education, 2002.
- [11] J. Pearl, “An introduction to causal inference.” *Int. J. Biostatist.*, vol. 6, no. 2, Feb. 2010, Art. no. 7, doi: 10.2202/1557-4679.1203.
- [12] W. N. Thurman and M. E. Fisher, “Chickens, eggs, and causality, or which came first?” *Amer. J. Agricultural Econ.*, vol. 70, no. 2, pp. 237–238, May 1988, doi: 10.2307/1242062.
- [13] M. Deistler and W. Scherrer, “Granger causality,” in *Time Series Models*. Cham, Switzerland: Springer Nature, 2022, ch. 9, pp. 167–173.
- [14] C. W. J. Granger, “Investigating causal relations by econometric models and cross-spectral methods,” *Econometrica*, vol. 37, no. 3, pp. 424–438, Aug. 1969, doi: 10.2307/1912791.
- [15] F. R. K. Chung, *Spectral Graph Theory*. Providence, RI, USA: American Mathematical Society, 1997.
- [16] D. A. Spielman, *Spectral and Algebraic Graph Theory (Incomplete Draft)*. Ebook, 2025, Accessed: December 9, 2025. [Online]. Available: <http://cs-www.cs.yale.edu/homes/spielman/sagt>
- [17] N. Parikh and S. Boyd, “Proximal algorithms,” *Found. Trends Optim.*, vol. 1, no. 3, pp. 127–239, Jan. 2014, doi: 10.1561/24000000003.
- [18] R. Durrett, *Probability: Theory and Examples*, 4th ed. Cambridge, U.K.: Cambridge Univ. Press, 2010.

- [19] J. R. Norris, *Markov Chains*. New York, NY, USA: Cambridge Univ. Press, 1997.
- [20] E. L. Lehmann and G. Casella, *Theory of Point Estimation*, 2nd ed. New York, NY, USA: Springer-Verlag, 1998.
- [21] S. M. Kay, *Fundamentals of Statistical Signal Processing: Estimation Theory*. Upper Saddle River, NJ, USA: Prentice-Hall, 1993.
- [22] P. R. Halmos, *Naive Set Theory*. New York, NY, USA: Springer-Verlag, 1974.
- [23] M. J. Wainwright, *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*. Cambridge, U.K.: Cambridge Univ. Press, 2019.
- [24] G. B. Folland, *Real Analysis: Modern Techniques and Their Applications*, 2nd ed. New York, NY, USA: Wiley, 1999.
- [25] W. Feller, *An Introduction to Probability Theory and Its Applications*, vol. 1, 3rd ed. New York, NY, USA: Wiley, 1967.
- [26] W. Hoeffding, “Probability inequalities for sums of bounded random variables,” *J. Amer. Statistical Assoc.*, vol. 58, no. 301, pp. 13–30, 1963, doi: 10.1080/01621459.1963.10500830.
- [27] R. Vershynin, *High-Dimensional Probability: An Introduction with Applications in Data Science*. Cambridge, U.K.: Cambridge Univ. Press, 2018.
- [28] G. Strang, *Computational Science and Engineering*. Wellesley, MA, USA: Wellesley-Cambridge Press, 2007.

- [29] S. Axler, *Linear Algebra Done Right*, 3rd ed. Cham, Switzerland: Springer Nature, 2015.
- [30] G. Strang, *Introduction to Linear Algebra*, 5th ed. Wellesley, MA, USA: Wellesley-Cambridge Press, 2016.
- [31] R. A. Horn and C. R. Johnson, *Topics in Matrix Analysis*. Cambridge, U.K.: Cambridge Univ. Press, 1991.
- [32] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ, USA: Wiley, 2006.
- [33] S. Bubeck, “Convex optimization: Algorithms and complexity,” *Found. Trends Mach. Learn.*, vol. 8, no. 3–4, pp. 231–357, Nov. 2015, doi: 10.1561/22000000050.
- [34] I. Csiszar, “Generalized cutoff rates and Renyi’s information measures,” *IEEE Trans. Inf. Theory*, vol. 41, no. 1, pp. 26–34, Jan. 1995, doi: 10.1109/18.370121.
- [35] H. H. Sohrab, *Basic Real Analysis*, 2nd ed. New York, NY, USA: Birkhäuser, 2014.
- [36] S. Boyd and L. Vandenberghe, *Convex Optimization*. Cambridge, U.K.: Cambridge Univ. Press, 2004.
- [37] T. Opsahl, F. Agneessens, and J. Skvoretz, “Node centrality in weighted networks: Generalizing degree and shortest paths,” *Social Netw.*, vol. 32, no. 3, pp. 245–251, Jul. 2010, doi: 10.1016/j.socnet.2010.03.006.

- [38] N. Dunford and J. T. Schwartz, *Linear Operators, Part I: General Theory*. New York, NY, USA: Wiley, 1988.
- [39] M. E. J. Newman, *Networks: An Introduction*. New York, NY, USA: Oxford Univ. Press, 2010.
- [40] R. T. Rockafellar, *Network Flows and Monotropic Optimization*. Belmont, MA, USA: Athena Scientific, 1998.
- [41] R. J. Wilson, *Introduction to Graph Theory*, 5th ed. Harlow, U.K.: Pearson Education, 2010.
- [42] P. Erdős and A. Rényi, “On random graphs I,” *Publ. Math. Debrecen*, vol. 6, no. 3–4, pp. 290–297, 1959, doi: 10.5486/PMD.1959.6.3-4.12.
- [43] E. N. Gilbert, “Random graphs,” *Ann. Math. Statist.*, vol. 30, no. 4, pp. 1141–1144, Dec. 1959.
- [44] B. S. Everitt and A. Skrondal, *The Cambridge Dictionary of Statistics*, 4th ed. Cambridge, U.K.: Cambridge Univ. Press, 2010.
- [45] G. Upton and I. Cook, *A Dictionary of Statistics*, 3rd ed. Oxford, U.K.: Oxford Univ. Press, 2014.
- [46] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed. New York, NY, USA: Cambridge Univ. Press, 2013.
- [47] A. Chambolle and T. Pock, “An introduction to continuous optimization for imaging,” *Acta Numer.*, vol. 25, pp. 161–319, May 2016, doi: 10.1017/S096249291600009X.

- [48] P. R. Halmos, *Finite-Dimensional Vector Spaces*. New York, NY, USA: Springer-Verlag, 1974.
- [49] B. Schölkopf and A. J. Smola, *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. Cambridge, MA, USA: MIT Press, 2002.
- [50] A. Holder and J. Eichholz, *An Introduction to Computational Science*. Cham, Switzerland: Springer Nature, 2019.
- [51] R. M. Gray, *Probability, Random Processes, and Ergodic Properties*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2009.
- [52] O. Kallenberg, *Foundations of Modern Probability*. New York, NY, USA: Springer-Verlag, 1997.
- [53] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- [54] D. P. Bertsekas, *Dynamic Programming and Optimal Control*, vol. 2, 3rd ed. Belmont, MA, USA: Athena Scientific, 2007.
- [55] U. von Luxburg, “A tutorial on spectral clustering,” *Statist. Comput.*, vol. 17, no. 4, pp. 395–416, Dec. 2007, doi: 10.1007/s11222-007-9033-z.
- [56] A. Y. Ng, M. I. Jordan, and Y. Weiss, “On spectral clustering: Analysis and an algorithm,” in *Adv. Neural Inf. Process. Syst.*, T. Dietterich, S. Becker, and Z. Ghahramani, Eds., vol. 14, 2001, pp. 849–856. [Online]. Available: https://papers.nips.cc/paper_files/paper/2001/hash/801272ee79cfde7fa5960571fee36b9b-Abstract.html

- [57] D. P. Bertsekas, *Nonlinear Programming*, 2nd ed. Belmont, MA, USA: Athena Scientific, 1999.
- [58] Y. Nesterov, *Introductory Lectures on Convex Optimization: A Basic Course*. Boston, MA, USA: Kluwer Academic, 2004.
- [59] S. Boyd, N. Parikh, E. Chu, B. Peleato, and J. Eckstein, “Distributed optimization and statistical learning via the alternating direction method of multipliers,” *Found. Trends Mach. Learn.*, vol. 3, no. 1, pp. 1–122, Jul. 2011, doi: 10.1561/22000000016.
- [60] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [61] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer Science+Business Media, 2006.
- [62] P. R. Halmos, *Measure Theory*. New York, NY, USA: Springer-Verlag, 1974.
- [63] H. J. Dirschmid, *Tensors and Fields*, (in German). Vienna, Austria: Springer-Verlag, 1996.
- [64] M. J. Wainwright and M. I. Jordan, “Graphical models, exponential families, and variational inference,” *Found. Trends Mach. Learn.*, vol. 1, no. 1–2, pp. 1–305, Nov. 2008, doi: 10.1561/22000000001.
- [65] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *J. Roy. Statist. Soc.: Ser. B (Statist. Methodology)*, vol. 61, no. 3, pp. 611–622, 1999, doi: 10.1111/1467-9868.00196.

- [66] P. J. Brockwell and R. A. Davis, *Time Series: Theory and Methods*, 2nd ed. New York, NY, USA: Springer-Verlag, 1991.
- [67] G. Casella and R. L. Berger, *Statistical Inference*, 2nd ed. Pacific Grove, CA: Duxbury, 2002.
- [68] C. E. Rasmussen and C. K. I. Williams, *Gaussian Processes for Machine Learning*. Cambridge, MA, USA: MIT Press, 2006.
- [69] H. H. Bauschke and P. L. Combettes, *Convex Analysis and Monotone Operator Theory in Hilbert Spaces*. New York, NY, USA: Springer Science+Business Media, 2011.
- [70] C. D. Meyer, *Matrix Analysis and Applied Linear Algebra*. Philadelphia, PA, USA: SIAM, 2000.
- [71] H. H. Bauschke and P. L. Combettes, *Convex Analysis and Monotone Operator Theory in Hilbert Spaces*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2017.
- [72] D. P. Bertsekas, A. Nedic, and A. E. Ozdaglar, *Convex Analysis and Optimization*. Belmont, MA, USA: Athena Scientific, 2003.
- [73] V. Müller, *Spectral Theory of Linear Operators: and Spectral Systems in Banach Algebras*. Basel, Switzerland: Birkhäuser Verlag, 2003.
- [74] S. Ross, *A First Course in Probability*, 9th ed. Boston, MA, USA: Pearson Education, 2014.

- [75] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer Science+Business Media, 2009.
- [76] A. Ben-Israel and T. N. E. Greville, *Generalized Inverses: Theory and Applications*, 2nd ed. New York, NY, USA: Springer-Verlag, 2003.
- [77] L. Condat, “A primal–dual splitting method for convex optimization involving lipschitzian, proximable and linear composite terms,” *J. Optim. Theory Appl.*, vol. 158, no. 2, pp. 460–479, Aug. 2013, doi: 10.1007/s10957-012-0245-9.
- [78] S. Shalev-Shwartz and S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*. New York, NY, USA: Cambridge Univ. Press, 2014.
- [79] S. Bubeck and N. Cesa-Bianchi, “Regret analysis of stochastic and non-stochastic multi-armed bandit problems,” *Found. Trends Mach. Learn.*, vol. 5, no. 1, pp. 1–122, Dec. 2012, doi: 10.1561/22000000024.
- [80] M. Kearns and M. Li, “Learning in the presence of malicious errors,” *SIAM J. Comput.*, vol. 22, no. 4, pp. 807–837, Aug. 1993, doi: 10.1137/0222052.
- [81] G. Lugosi and S. Mendelson, “Robust multivariate mean estimation: The optimality of trimmed mean,” *Ann. Statist.*, vol. 49, no. 1, pp. 393–410, Feb. 2021, doi: 10.1214/20-AOS1961.
- [82] T. H. Cormen, C. E. Leiserson, R. L. Rivest, and C. Stein, *Introduction to Algorithms*, 4th ed. Cambridge, MA, USA: MIT Press, 2022.

- [83] M. Sipser, *Introduction to the Theory of Computation*, 3rd ed. Andover, U.K.: Cengage Learning, 2013.
- [84] S. Lloyd, “Least squares quantization in PCM,” *IEEE Trans. Inf. Theory*, vol. 28, no. 2, pp. 129–137, Mar. 1982.
- [85] M. Mahajan, P. Nimbhorkar, and K. Varadarajan, “The planar k-means problem is NP-hard,” in *WALCOM: Algorithms and Computation*, S. Das and R. Uehara, Eds. Berlin, Heidelberg, Germany: Springer-Verlag, 2009, pp. 274–285.
- [86] M. T. Ribeiro, S. Singh, and C. Guestrin, “Why should i trust you?: Explaining the predictions of any classifier,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, Aug. 2016, pp. 1135–1144, doi: 10.1145/2939672.2939778.
- [87] S. Mallat, “Understanding deep convolutional networks,” *Philos. Trans. Roy. Soc. A*, vol. 374, no. 2065, Apr. 2016, Art. no. 20150203, doi: 10.1098/rsta.2015.0203.
- [88] S. Sra, S. Nowozin, and S. J. Wright, Eds., *Optimization for Machine Learning*. Cambridge, MA, USA: MIT Press, 2012.
- [89] C. H. Lampert, “Kernel methods in computer vision,” *Found. Trends Comput. Graph. Vis.*, vol. 4, no. 3, pp. 193–285, Sep. 2009, doi: 10.1561/06000000027.
- [90] European Parliament and Council of the European Union, “Regulation (EU) 2016/679 of the European Parliament and of the Council of 27

- April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation) (Text with EEA relevance),” Official Journal of the European Union, L 119/1, May 4, 2016, Accessed: July, 2025. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- [91] European Parliament and Council of the European Union, “Regulation (EU) 2018/1725 of the European Parliament and of the Council of 23 October 2018 on the protection of natural persons with regard to the processing of personal data by the Union institutions, bodies, offices and agencies and on the free movement of such data, and repealing Regulation (EC) No 45/2001 and Decision No 1247/2002/EC (Text with EEA relevance),” Official Journal of the European Union, L 295/39, Nov. 21, 2018, Accessed: December 1, 2025. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2018/1725/oj>
- [92] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. Cambridge, MA, USA: MIT Press, 2012.
- [93] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Ann. Eugenics*, vol. 7, no. 2, pp. 179–188, Sep. 1936, doi: 10.1111/j.1469-1809.1936.tb02137.x.
- [94] International Organization for Standardization and International Electrotechnical Commission, “Information technology — Vocabulary,” ISO/IEC 2382:2015, 2015, Accessed: September 21, 2025. [Online]. Available: <https://www.iso.org/standard/63598.html>

- [95] B. S. Everitt, *The Cambridge Dictionary of Statistics*, 2nd ed. Cambridge, U.K.: Cambridge Univ. Press, 2002.
- [96] N. Cesa-Bianchi and G. Lugosi, *Prediction, Learning, and Games*. New York, NY, USA: Cambridge Univ. Press, 2006.
- [97] E. Hazan, “Introduction to online convex optimization,” *Found. Trends Optim.*, vol. 2, no. 3–4, pp. 157–325, Aug. 2016, doi: 10.1561/24000000013.
- [98] A. Ünsal and M. Önen, “Information-theoretic approaches to differential privacy,” *ACM Comput. Surv.*, vol. 56, no. 3, Oct. 2023, Art. no. 76, doi: 10.1145/3604904.
- [99] A. Makhdoumi, S. Salamatian, N. Fawaz, and M. Médard, “From the information bottleneck to the privacy funnel,” in *2014 IEEE Inf. Theory Workshop*, 2014, pp. 501–505, doi: 10.1109/ITW.2014.6970882.
- [100] A. Jung, *Federated Learning: From Theory to Practice*. Singapore, Singapore: Springer Nature, 2026.
- [101] Y. SarcheshmehPour, Y. Tian, L. Zhang, and A. Jung, “Clustered federated learning via generalized total variation minimization,” *IEEE Trans. Signal Process.*, vol. 71, pp. 4240–4256, 2023, doi: 10.1109/TSP.2023.3322848.
- [102] J. A. Hanley and B. J. McNeil, “The meaning and use of the area under a receiver operating characteristic (ROC) curve,” *Radiol.*, vol. 143, no. 1, pp. 29–36, Apr. 1982, doi: 10.1148/radiology.143.1.7063747.

- [103] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. Cham, Switzerland: Springer Nature, 2024.
- [104] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 3rd ed. Ebook, 2025, Accessed: August 1, 2025. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>
- [105] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *2017 IEEE Int. Conf. Comput. Vis.*, 2017, pp. 618–626, doi: 10.1109/ICCV.2017.74.
- [106] L. Zhang, G. Karakasidis, A. Odnoblyudova, L. Dogruel, Y. Tian, and A. Jung, “Explainable empirical risk minimization,” *Neural Comput. Appl.*, vol. 36, no. 8, pp. 3983–3996, Mar. 2024, doi: 10.1007/s00521-023-09269-3.
- [107] C. Rudin, “Stop explaining black box machine learning models for high-stakes decisions and use interpretable models instead,” *Nature Mach. Intell.*, vol. 1, no. 5, pp. 206–215, May 2019, doi: 10.1038/s42256-019-0048-x.
- [108] J. Kleinberg and E. Tardos, *Algorithm Design*. Boston, MA, USA: Addison-Wesley, 2006.
- [109] R. Caruana, “Multitask learning,” *Mach. Learn.*, vol. 28, pp. 41–75, Jul. 1997, doi: 10.1023/A:1007379606734.
- [110] A. Jung, G. Hannak, and N. Goertz, “Graphical lasso based model

- selection for time series,” *IEEE Signal Process. Lett.*, vol. 22, no. 10, pp. 1781–1785, Oct. 2015, doi: 10.1109/LSP.2015.2425434.
- [111] A. Jung, “Learning the conditional independence structure of stationary time series: A multitask learning approach,” *IEEE Trans. Signal Process.*, vol. 63, no. 21, Nov. 2015, doi: 10.1109/TSP.2015.2460219.
 - [112] D. N. Gujarati and D. C. Porter, *Basic Econometrics*, 5th ed. New York, NY, USA: McGraw-Hill/Irwin, 2009.
 - [113] Y. Dodge, Ed., *The Oxford Dictionary of Statistical Terms*. New York, NY, USA: Oxford Univ. Press, 2003.
 - [114] O. Chapelle, B. Schölkopf, and A. Zien, Eds., *Semi-Supervised Learning*. Cambridge, MA, USA: MIT Press, 2006.
 - [115] P. Bühlmann and S. van de Geer, *Statistics for High-Dimensional Data: Methods, Theory and Applications*. Berlin, Germany: Springer-Verlag, 2011.
 - [116] H.-S. Park and C.-H. Jun, “A simple and fast algorithm for K-medoids clustering,” *Expert Syst. Appl.*, vol. 36, no. 2, Part 2, pp. 3336–3341, Mar. 2009, doi: 10.1016/j.eswa.2008.01.039.
 - [117] A. Banerjee, S. Merugu, I. S. Dhillon, and J. Ghosh, “Clustering with Bregman divergences,” *J. Mach. Learn. Res.*, vol. 6, no. 58, pp. 1705–1749, Oct. 2005. [Online]. Available: <http://jmlr.org/papers/v6/banerjee05b.html>

- [118] D. Sun, K.-C. Toh, and Y. Yuan, “Convex clustering: Model, theoretical guarantee and efficient algorithm,” *J. Mach. Learn. Res.*, vol. 22, no. 9, pp. 1–32, Jan. 2021. [Online]. Available: <http://jmlr.org/papers/v22/18-694.html>
- [119] K. Pelckmans, J. De Brabanter, J. A. K. Suykens, and B. De Moor, “Convex clustering shrinkage,” presented at the PASCAL Workshop Statist. Optim. Clustering Workshop, 2005.
- [120] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognit. Lett.*, vol. 27, no. 8, pp. 861–874, Jun. 2006, doi: 10.1016/j.patrec.2005.10.010.
- [121] S. J. D. Prince, *Understanding Deep Learning*. Cambridge, MA, USA: MIT Press, 2023.
- [122] A. Vaswani et al., “Attention is all you need,” in *Adv. Neural Inf. Process. Syst.*, I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds., vol. 30, 2017, pp. 5998–6008. [Online]. Available: https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html
- [123] T. Hastie, R. Tibshirani, and M. Wainwright, *Statistical Learning with Sparsity: The Lasso and Generalizations*. Boca Raton, FL, USA: CRC Press, 2015.
- [124] L. Bottou, “On-line learning and stochastic approximations,” in *On-Line Learning in Neural Networks*, D. Saad, Ed. New York, NY, USA: Cambridge Univ. Press, 1999, ch. 2, pp. 9–42.

- [125] E. A. Bender, *An Introduction to Mathematical Modeling*. New York, NY, USA: Wiley, 1978.
- [126] P. W. Holland, K. B. Laskey, and S. Leinhardt, “Stochastic blockmodels: First steps,” *Social networks*, vol. 5, no. 2, pp. 109–137, 1983.
- [127] E. Abbe, “Community detection and stochastic block models: Recent developments,” *J. Mach. Learn. Res.*, vol. 18, no. 177, pp. 1–86, Apr. 2018. [Online]. Available: <http://jmlr.org/papers/v18/16-480.html>
- [128] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam, and P. Vandergheynst, “Geometric deep learning: Going beyond Euclidean data,” *IEEE Signal Process. Mag.*, vol. 34, no. 4, pp. 18–42, Jul. 2017, doi: 10.1109/MSP.2017.2693418.
- [129] T. N. Kipf and M. Welling, “Semi-supervised classification with graph convolutional networks,” in *5th Int. Conf. Learn. Representations*, Feb. 2017. [Online]. Available: <https://openreview.net/forum?id=SJU4ayYgl>
- [130] Q. Yang, Y. Liu, Y. Cheng, Y. Kang, T. Chen, and H. Yu, “Horizontal federated learning,” in *Federated Learning*. Cham, Switzerland: Springer Nature, 2020, ch. 4, pp. 49–67.
- [131] P. J. Huber, “Robust estimation of a location parameter,” in *Breakthroughs in Statistics: Methodology and Distribution*. New York, NY, USA: Springer-Verlag, 1992, ch. 35, pp. 492–518.
- [132] P. L. Bartlett and S. Mendelson, “Rademacher and gaussian complexities: Risk bounds and structural results,” *J. Mach. Learn.*

- Res.*, vol. 3, no. Nov., pp. 463–482, 2002. [Online]. Available: <https://www.jmlr.org/papers/v3/bartlett02a.html>
- [133] D. M. Blei, A. Y. Ng, and M. I. Jordan, “Latent dirichlet allocation,” *J. Mach. Learn. Res.*, vol. 3, pp. 993–1022, Jan. 2003.
 - [134] D. H. Wolpert, “Stacked generalization,” *Neural Netw.*, vol. 5, no. 2, pp. 241–259, 1992, doi: 10.1016/S0893-6080(05)80023-1.
 - [135] Z.-H. Zhou, *Ensemble Methods: Foundations and Algorithms*. New York, NY, USA: Chapman & Hall/CRC Press, 2012.
 - [136] R. Motwani and P. Raghavan, *Randomized Algorithms*. Cambridge, U.K.: Cambridge Univ. Press, 1995.
 - [137] R. G. Gallager, *Stochastic Processes: Theory for Applications*. New York, NY, USA: Cambridge Univ. Press, 2013.
 - [138] Organisation for Economic Co-operation and Development (OECD), *OECD Glossary of Statistical Terms*. Paris, France: OECD Publishing, 2008. [Online]. Available: <https://doi.org/10.1787/9789264055087-en>
 - [139] G. S. Collins and K. G. M. Moons, “Comparing risk prediction models.” *BMJ*, vol. 344, May 2012, Art. no. e3186, doi: 10.1136/bmj.e3186.
 - [140] E. W. Steyerberg, *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating*, 2nd ed. Cham, Switzerland: Springer Nature, 2019.
 - [141] A. Silberschatz, H. F. Korth, and S. Sudarshan, *Database System Concepts*, 7th ed. New York, NY, USA: McGraw-Hill Education, 2019.

- [142] S. Abiteboul, R. Hull, and V. Vianu, *Foundations of Databases*. Reading, MA, USA: Addison-Wesley, 1995.
- [143] S. Hoberman, *Data Modeling Made Simple: A Practical Guide for Business and IT Professionals*, 2nd ed. Basking Ridge, NJ, USA: Technics Publications, 2009.
- [144] R. Ramakrishnan and J. Gehrke, *Database Management Systems*, 3rd ed. New York, NY, USA: McGraw-Hill, 2002.
- [145] E. F. Codd, “A relational model of data for large shared data banks,” *Commun. ACM*, vol. 13, no. 6, pp. 377–387, Jun. 1970, doi: 10.1145/362384.362685.
- [146] T. Gebru et al., “Datasheets for datasets,” *Commun. ACM*, vol. 64, no. 12, pp. 86–92, Nov. 2021, doi: 10.1145/3458723.
- [147] D. A. Patterson and J. L. Hennessy, *Computer Organization and Design: The Hardware/Software Interface*, 5th ed. San Francisco, CA, USA: Morgan Kaufmann, 2013.
- [148] Y. SarcheshmehPour, Y. Tian, L. Zhang, and A. Jung, “Flow-based clustering and spectral clustering: A comparison,” in *2021 55th Asilomar Conf. Signals, Syst., Comput.*, M. B. Matthews, Ed., 2021, pp. 1292–1296, doi: 10.1109/IEEECONF53345.2021.9723162.
- [149] R. Tibshirani, “Regression shrinkage and selection via the lasso,” *J. Roy. Statist. Soc.: Ser. B (Methodological)*, vol. 58, no. 1, pp. 267–288, 1996, doi: 10.1111/j.2517-6161.1996.tb02080.x.

- [150] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *2016 IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.
- [151] A. Jung and Y. SarcheshmehPour, “Local graph clustering with network Lasso,” *IEEE Signal Process. Lett.*, vol. 28, pp. 106–110, 2021, doi: 10.1109/LSP.2020.3045832.
- [152] C. R. Wren, A. Azarbayejani, T. Darrell, and A. P. Pentland, “Pfinder: Real-time tracking of the human body,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 19, no. 7, pp. 780–785, Jul. 1997, doi: 10.1109/34.598236.
- [153] C. G. Atkeson, A. W. Moore, and S. Schaal, “Locally weighted learning,” *Artif. Intell. Rev.*, vol. 11, no. 1–5, pp. 11–73, Feb. 1997, doi: 10.1023/A:1006559212014.
- [154] L. Cohen, *Time-Frequency Analysis*. Upper Saddle River, NJ, USA: Prentice-Hall, 1995.
- [155] J. Li, L. Han, X. Li, J. Zhu, B. Yuan, and Z. Gou, “An evaluation of deep neural network models for music classification using spectrograms,” *Multimedia Tools Appl.*, vol. 81, no. 4, pp. 4621–4647, Feb. 2022, doi: 10.1007/s11042-020-10465-9.
- [156] B. Boashash, Ed., *Time Frequency Signal Analysis and Processing: A Comprehensive Reference*. Oxford, U.K.: Elsevier, 2003.
- [157] S. Mallat, *A Wavelet Tour of Signal Processing: The Sparse Way*, 3rd ed. Burlington, MA, USA: Academic, 2009.

- [158] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman & Hall, 1993.
- [159] D. P. Bertsekas, *Dynamic Programming and Optimal Control*, vol. 1, 4th ed. Belmont, MA, USA: Athena Scientific, 2017.
- [160] S. J. Russel and P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed. Upper Saddle River, NJ, USA: Prentice-Hall, 2010.
- [161] R. Bellman, *Dynamic Programming*. Princeton, NJ, USA: Princeton Univ. Press, 1957.
- [162] M. Fredrikson, S. Jha, and T. Ristenpart, “Model inversion attacks that exploit confidence information and basic countermeasures,” in *Proc. 22nd ACM SIGSAC Conf. Comput. Commun. Secur.*, Oct. 2015, pp. 1322–1333, doi: 10.1145/2810103.2813677.
- [163] D. P. Bertsekas and J. N. Tsitsiklis, *Parallel and Distributed Computation: Numerical Methods*. Belmont, MA, USA: Athena Scientific, 2015.
- [164] N. A. Lynch, *Distributed Algorithms*. San Francisco, CA, USA: Morgan Kaufmann, 1996.
- [165] M. van Steen and A. S. Tanenbaum, *Distributed Systems*, 3rd ed. Ebook, 2017. [Online]. Available: <https://www.distributed-systems.net/index.php/books/ds3/>
- [166] A. S. Tanenbaum and D. J. Wetherall, *Computer Networks*, 5th ed. Upper Saddle River, NJ, USA: Prentice-Hall, 2010.

- [167] D. Tse and P. Viswanath, *Fundamentals of Wireless Communication*. New York, NY, USA: Cambridge Univ. Press, 2005.
- [168] X. Liu, H. Li, G. Xu, Z. Chen, X. Huang, and R. Lu, “Privacy-enhanced federated learning against poisoning adversaries,” *IEEE Trans. Inf. Forensics Secur.*, vol. 16, pp. 4574–4588, 2021, doi: 10.1109/TIFS.2021.3108434.
- [169] J. Zhang, B. Chen, X. Cheng, H. T. T. Binh, and S. Yu, “PoisonGAN: Generative poisoning attacks against federated learning in edge computing systems,” *IEEE Internet Things J.*, vol. 8, no. 5, pp. 3310–3322, Mar. 2021, doi: 10.1109/JIOT.2020.3023126.
- [170] N. Wang, Y. Xiao, Y. Chen, Y. Hu, W. Lou, and Y. T. Hou, “FLARE: Defending federated learning against model poisoning attacks via latent space representations,” in *Proc. 2022 ACM Asia Conf. Comput. Commun. Secur.*, May 2022, pp. 946–958, doi: 10.1145/3488932.3517395.
- [171] G. M. Fitzmaurice, N. M. Laird, and J. H. Ware, *Applied Longitudinal Analysis*, 2nd ed. Hoboken, NJ, USA: Wiley, 2011.
- [172] C. H. Mallinckrodt and I. Lipkovich, *Analyzing Longitudinal Clinical Trial Data: A Practical Guide*. Boca Raton, FL, USA: Chapman & Hall/CRC Press, 2017.
- [173] L. Richardson, M. Amundsen, and S. Ruby, *RESTful Web APIs*. Sebastopol, CA, USA: O’Reilly Media, 2013.
- [174] S. H. Strogatz, *Nonlinear Dynamics and Chaos: With Applications to*

- Physics, Biology, Chemistry, and Engineering*, 2nd ed. Boca Raton, FL, USA: CRC Press, 2015.
- [175] N. D. Lane and P. Georgiev, “Can deep learning revolutionize mobile sensing?” in *Proc. 16th Int. Workshop Mobile Comput. Syst. Appl.*, Feb. 2015, pp. 117–122, doi: 10.1145/2699343.2699349.
 - [176] V. Tsoukas, A. Gkogkidis, E. Boumpa, and A. Kakarountas, “A review on the emerging technology of TinyML,” *ACM Comput. Surv.*, vol. 56, no. 10, Jun. 2024, Art. no. 259, doi: 10.1145/3661820.
 - [177] D. E. Comer, *The Cloud Computing Book: The Future of Computing Explained*. Boca Raton, FL, USA: CRC Press, 2021.
 - [178] H. Hapke and C. Nelson, *Building Machine Learning Pipelines: Automating Model Life Cycles with TensorFlow*. Sebastopol, CA, USA: O’Reilly Media, 2020.
 - [179] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, “Edge computing: Vision and challenges,” *IEEE Internet Things J.*, vol. 3, no. 5, pp. 637–646, Oct. 2016, doi: 10.1109/JIOT.2016.2579198.
 - [180] O. Hashash, S. Sharafeddine, Z. Dawy, A. Mohamed, and E. Yaacoub, “Energy-aware distributed edge ML for mHealth applications with strict latency requirements,” *IEEE Wireless Commun. Lett.*, vol. 10, no. 12, pp. 2791–2794, Dec. 2021, doi: 10.1109/LWC.2021.3117876.
 - [181] D. E. Knuth, *The Art of Computer Programming*, vol. 1: *Fundamental Algorithms*, 3rd ed. Reading, MA, USA: Addison-Wesley, 1997.

- [182] A. S. Tanenbaum, *Modern Operating Systems*, 3rd ed. Upper Saddle River, NJ, USA: Prentice-Hall, 2008.
- [183] T. N. Gia, L. Qingqing, J. P. Queralta, Z. Zou, H. Tenhunen, and T. Westerlund, “Edge AI in smart farming IoT: CNNs at the edge and fog computing with LoRa,” in *2019 IEEE AFRICON*, 2019, pp. 1–6, doi: 10.1109/AFRICON46755.2019.9134049.
- [184] M. Armbrust et al., “A view of cloud computing,” *Commun. ACM*, vol. 53, no. 4, pp. 50–58, Apr. 2010, doi: 10.1145/1721654.1721672.
- [185] D. Pfau and A. Jung, “Engineering trustworthy AI: A developer guide for empirical risk minimization,” arXiv preprint arXiv:2410.19361, Nov. 2024. [Online]. Available: <https://arxiv.org/abs/2410.19361>
- [186] High-Level Expert Group on Artificial Intelligence, “The assessment list for trustworthy artificial intelligence (ALTAI): For self assessment,” European Commission, Jul. 17, 2020. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment>
- [187] High-Level Expert Group on Artificial Intelligence, “Ethics guidelines for trustworthy AI,” European Commission, Apr. 8, 2019. [Online]. Available: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>
- [188] A. Jung and P. H. J. Nardelli, “An information-theoretic approach to personalized explainable machine learning,” *IEEE Signal Process. Lett.*, vol. 27, pp. 825–829, 2020, doi: 10.1109/LSP.2020.2993176.

- [189] C. Gallese, “The AI Act proposal: A new right to technical interpretability?” *SSRN Electron. J.*, Feb. 2023. [Online]. Available: <https://ssrn.com/abstract=4398206>
- [190] M. Mitchell et al., “Model cards for model reporting,” in *Proc. Conf. Fairness, Accountability, Transparency*, 2019, pp. 220–229, doi: 10.1145/3287560.3287596.
- [191] K. Shahriari and M. Shahriari, “IEEE standard review — Ethically aligned design: A vision for prioritizing human wellbeing with artificial intelligence and autonomous systems,” in *2017 IEEE Canada Int. Humanitarian Technol. Conf.*, 2017, pp. 197–201, doi: 10.1109/I-HTC.2017.8058187.
- [192] J. Colin, T. Fel, R. Cadène, and T. Serre, “What I cannot predict, I do not understand: A human-centered evaluation framework for explainability methods,” in *Adv. Neural Inf. Process. Syst.*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35, 2022, pp. 2832–2845. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/hash/13113e938f2957891c0c5e8df811dd01-Abstract-Conference.html
- [193] J. Chen, L. Song, M. J. Wainwright, and M. I. Jordan, “Learning to explain: An information-theoretic perspective on model interpretation,” in *Proc. 35th Int. Conf. Mach. Learn.*, J. Dy and A. Krause, Eds., vol. 80, 2018, pp. 883–892. [Online]. Available: <https://proceedings.mlr.press/v80/chen18j.html>

- [194] F. Doshi-Velez and B. Kim, “Towards a rigorous science of interpretable machine learning,” arXiv preprint arXiv:1702.08608, Mar. 2017. [Online]. Available: <https://arxiv.org/abs/1702.08608>
- [195] P. Hase and M. Bansal, “Evaluating explainable AI: Which algorithmic explanations help users predict model behavior?” in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics*, D. Jurafsky, J. Chai, N. Schluter, and J. Tetreault, Eds., Jul. 2020, pp. 5540–5552. [Online]. Available: <https://aclanthology.org/2020.acl-main.491>
- [196] Z. C. Lipton, “The mythos of model interpretability: In machine learning, the concept of interpretability is both important and slippery,” *Queue*, vol. 16, no. 3, pp. 31–57, Jun. 2018, doi: 10.1145/3236386.3241340.
- [197] European Commission, “Proposal for a regulation of the European Parliament and of the Council laying down harmonised rules on artificial intelligence (Artificial Intelligence Act) and amending certain Union legislative acts,” COM/2021/206 final, Apr. 21, 2021, Accessed: December 16, 2025. [Online]. Available: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=celex:52021PC0206>
- [198] European Parliament and Council of the European Union, “Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence and amending Regulations (EC) No 300/2008, (EU) No 167/2013, (EU) No 168/2013, (EU) 2018/858, (EU) 2018/1139 and (EU) 2019/2144 and Directives 2014/90/EU, (EU) 2016/797 and (EU) 2020/1828 (Artificial Intelligence Act) (Text with EEA relevance),” Official Journal of the

European Union, L series, Jul. 12, 2024, Accessed: July 2025. [Online].
Available: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>